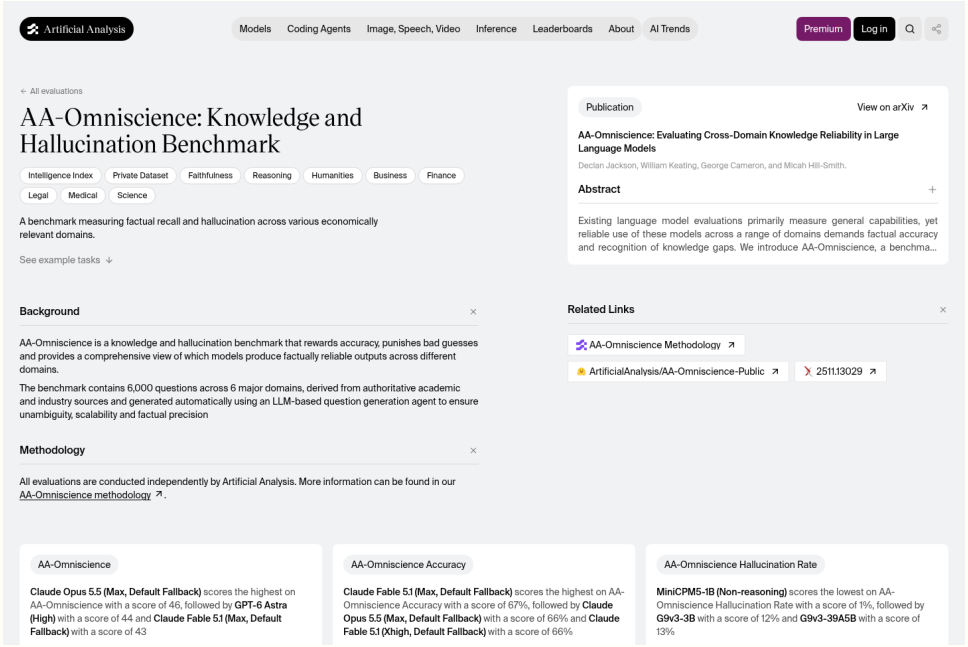
AA-Omniscience

Artificial Analysis Omniscience

正確な知識と、分からないときの回答保留を評価する

sasakiy84

AA-Omniscience の公式評価ページ



[1] Artificial Analysis (2026-10-25 参照), AA-Omniscience: Knowledge and Hallucination Benchmark.
https://artificialanalysis.ai/evaluations/omniscience

1. 知識の正確さと公開例
2. 採点とモデルの到達水準
3. 問題の構築と分野の広がり
4. 評価での利用と公開データ

1. 知識の正確さと公開例

知っている事実と、分からない問題への応答を測る

- AA-Omniscience は、専門分野の短い事実質問に答える評価データである。モデルは検索や補助資料を使わず、内部に持つ知識から答える。
- 確信がなければ回答を保留してよい。正しい答えを増やす力と、誤った推測を控える力の両方を評価する。

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

評価用 6,000 問のうち、 600 問を公開している

- 公式のモデル比較には 6,000 問を使う。公開版 AA-Omniscience-Public は、その 10% に当たる 600 問を含む。
- ここで示す 13 例は公開 600 問から選んだ。質問、参照回答、日本語訳を対応させ、ソフトウェア、金融、法律、健康、人文・社会、自然科学を扱う。

[1] Artificial Analysis (2025), AA-Omniscience-Public.
https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

例 1 Python の標準パッケージ

問題の原文（全文）

> What is the exact package name introduced by PEP 371?

日本語訳（全文）

PEP 371 で追加されたパッケージの正確な名前は何か。

正解： multiprocessing

PEP は Python の機能提案をまとめる文書である。 PEP 371 は、multiprocessing を標準ライブラリへ追加する提案だった。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Noller and Oudkerk (2008), PEP 371. https://peps.python.org/pep-0371/

例 2 オプション価格理論の受賞者

問題の原文（全文）

> Among the original co-authors of the 1973 Black and Scholes option pricing paper, who received the 1997 Nobel Prize in Economic Sciences?

日本語訳（全文）

1973 年の Black と Scholes によるオプション価格理論の論文の共著者のうち、 1997 年のノーベル経済学賞を受賞したのは誰か。

正解： Myron Scholes

1997 年の受賞者は Scholes と Merton である。 1973 年の Black–Scholes 論文の共著者という条件に合うのは、 Myron Scholes となる。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Nobel Prize Outreach (n.d.), Myron Scholes – Facts. https://www.nobelprize.org/prizes/economic-sciences/1997/scholes/facts/

例 3 判例に登場する農場の所在地

問題の原文（全文）

> In the Arkansas Supreme Court case Loveless v. Diehl (1963 decision), which county contained the 79-acre farm at issue?

日本語訳（全文）

アーカンソー州最高裁判所の Loveless v. Diehl 事件（ 1963 年の判決）で、争いの対象となった 79 エーカーの農場はどの郡にあったか。

正解： Faulkner County （フォークナー郡）

判決本文は、 79 エーカーの農場の所在地を Faulkner County と記す。判例に含まれる具体的な事実を、郡の名前で答える問題である。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Arkansas Supreme Court (1962/1963), Loveless v. Diehl. https://law.justia.com/cases/arkansas/supreme-court/1963/5-2841-0.html

2. 採点とモデルの到達水準

確信があるときだけ、答えを簡潔に返す

- 回答指示では、分野と小分野を示し、説明を付けずに答えだけを返すよう求める。分からない場合や、文脈・ツールが必要な場合は、その旨を明示する。
- 採点では、回答を参照回答と意味で比較する。表記が同じかだけでなく、求められた情報がそろっているかを判定する。

[1] Artificial Analysis (2025), AA-Omniscience-Public.
https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

回答を四つの状態に分類する

判定	内容	得点
正解	求められた情報が完全に正しい	+1
部分的な回答	正確だが、求める詳しさと合わない	0
誤答	参照回答と意味が異なる	−1
回答保留	答えず、知識や情報の不足を示す	0

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

正解を加点し、誤答を同じ大きさで減点する

- Omniscience Index = 100 ×（正解数 − 誤答数）÷ 全問題数。正解は +1 、誤答は− 1 、部分的な回答と回答保留は 0 として平均する。
- 値は− 100 から 100 の範囲を取る。正解数と誤答数が等しければ 0 、正解が誤答より多ければ正になる。

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

正解率と幻覚率を併せて読む

- 正解率は、全問題のうち完全に正しく答えた割合である。部分的な回答は正解に含めない。
- ここでの幻覚率は、誤答数を「部分的な回答・誤答・回答保留の合計」で割った値である。完全正解でなかった問題で、どれほど誤った答えを返したかを示す。

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

2025 年の公開時、最高の指数は 4.8 だった

- 2025 年 11 月の論文では 36 モデルを評価し、 Claude 4.1 Opus の指数 4.8 が最高だった。正の指数を得たのは 3 モデルだった。
- 当時の Claude 4.1 Opus の正解率は 36% だった。正解率だけでなく、誤答と回答保留の違いがモデルの評価を左右した。

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

公式ページは、指数 46 に達したモデルを報告する

モデル・推論設定	指数
Claude Opus 5.5 / Max, Default Fallback	46
GPT-6 Astra / High	44
Claude Fable 5.1 / Max, Default Fallback	43

2026-10-25 参照。公式ページの代表値。全 6,000 問を対象とする。

[1] Artificial Analysis (2026-10-25 参照), AA-Omniscience: Knowledge and Hallucination Benchmark.
https://artificialanalysis.ai/evaluations/omniscience

採点モデルは、公開後に更新されている

- 2026 年 10 月 25 日の公式ページは、 Opus 、 GPT 、 Fable などの新しいモデルの成績を掲載している。単独の指数に加え、正解率と幻覚率も公開する。
- 2025 年の評価では Gemini 2.5 Flash Preview が採点を担当した。現行の公式手順では GPT-5.6 Luna （ medium ）を使い、 6,000 問を 1 回ずつ評価する。

[1] Artificial Analysis (2026-10-25 参照), Intelligence Benchmarking Methodology. https://artificialanalysis.ai/methodology/intelligence-benchmarking

3. 問題の構築と分野の広がり

権威ある資料から、事実を問う質問を作る

- 学術・産業の資料を基に、質問生成エージェントが設問と答えを作る。重複、曖昧さ、難しさを検査し、質問を修正・除外する。
- 2025 年の構築では、生成・選別・改訂に GPT-5 を用いた。人はレビューと検証に関わる。対象は名前、日付、数値、場所など、短く正確に答えられる事実である。

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

時点やバージョンを含め、答えを一つに定める

- 曖昧な質問は、時期や対象を補って修正する。例えば、特定の判例を問うなら裁判所や判決年を、ソフトウェアなら必要なバージョンを設問に含める。
- 資料の更新日そのものを覚えているか、といった出典への依存が強い候補は除く。一方、法律の条文番号など、分野の理解に必要な識別子は扱う。

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

6 分野・ 42 トピックの専門知識を扱う

分野	内容の例
ビジネス	会計、経済、金融、経営
人文・社会科学	歴史、文学、哲学、社会科学
健康	医学、歯学、公衆衛生
法律	判例、法律・規制
自然科学・工学・数学	生物、化学、工学、数学
ソフトウェア工学	プログラミング言語とライブラリ

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

公開 600 問は、全体の成績を近似するために選ばれた

- 公開版は、公開時点でモデルの総合成績が全 6,000 問と近くなるように抽出された。自分のモデルで知識と回答保留の傾向を調べられる。
- 分野・小分野ごとの公開問題数は少ない。詳細な分野別比較を行う場合は、公式の全体集合の結果や、必要な対象分野の追加評価も参照する。

[1] Artificial Analysis (2025), AA-Omniscience-Public.
https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

4. 評価での利用と公開データ

内部知識の信頼性を、分野ごとに比較する

- AA-Omniscience は、検索や入力文書の内容に基づく回答とは別に、モデルが既に持つ知識を評価する。分野ごとの成績から、業務で必要な知識との対応を調べる。
- 現在の Artificial Analysis Intelligence Index では、正解率と非幻覚率を別の成分として組み込む。 AA-Omniscience 単独の指数とは集約の仕方が異なる。

[1] Artificial Analysis (2026-10-25 参照), Intelligence Benchmarking Methodology.
https://artificialanalysis.ai/methodology/intelligence-benchmarking

公開 CSV から、質問と参照回答を読み取れる

- 公式の Hugging Face 配布に、 600 問の CSV とデータカードがある。 domain 、 topic 、 subtopic で分野を、 question と answer で設問と参照回答を確認できる。
- 公開版は Apache License 2.0 で配布される。再配布ではライセンスと必要な帰属情報を保持する。

[1] Artificial Analysis (2025), AA-Omniscience-Public.
https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

一問の分野・設問・参照回答を読む

```
from datasets import load_dataset

ds = load_dataset(
    "ArtificialAnalysis/AA-Omniscience-Public",
    split="train"
)
row = ds[0]
print(row["domain"], row["question"], row["answer"])
```

公開 CSV を読み込む。 question が設問、 answer が参照回答を持つ。

[1] Artificial Analysis (2025), AA-Omniscience-Public.
https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

事実の知識と、分からないときの応答を評価する

- AA-Omniscience は、 6 分野・ 42 トピックの 6,000 問から、短く正確な事実回答を評価する。誤った推測を減点し、回答保留との違いを可視化する。
- 公開 600 問で質問と答えを確認し、指数・正解率・幻覚率を併せて読む。公式成績を利用するときは、対象モデルの設定と採点手順の時点を確かめる。

[1] Jackson et al. (2025), AA-Omniscience.
https://arxiv.org/abs/2511.13029

Appendix

1. 分野の異なる追加例
2. 参考文献

1. 分野の異なる追加例

例 4 タイムゾーンの検索パス

問題の原文（全文）

What type of paths may zoneinfo.TZPATH contain?

日本語訳（全文）

zoneinfo.TZPATH に含められるのは、どの種類のパスか。

正解： absolute （絶対パス）

Python の zoneinfo は、 TZPATH からタイムゾーン情報を探す。公式文書は、 TZPATH には絶対パスだけを含められると定めている。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Python Software Foundation (n.d.), zoneinfo — IANA time zone support. https://docs.python.org/3/library/zoneinfo.html

例 5 Python 2.7 のサポート終了

問題の原文（全文）

> What Requests version (major.minor.patch) removed support for Python 2.7?

日本語訳（全文）

Requests が Python 2.7 のサポートを終了したバージョンは何か。major.minor.patch の形式で答えよ。

正解： 2.28.0

Requests は HTTP 通信を行う Python ライブラリである。設問が指定する major.minor.patch の 3 つの番号をそろえて答える。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Requests (n.d.), Frequently Asked Questions. https://requests.readthedocs.io/en/stable/community/faq/

例 6 国連文書の発行日

問題の原文（全文）

> What was the exact date (month, day, year) on which the General Assembly document A/57/532/Add.1 was issued?

日本語訳（全文）

国連総会文書 A/57/532/Add.1 が発行された正確な日付はいつか。月・日・年で答えよ。

正解： December 12, 2002 （ 2002 年 12 月 12 日）

文書の表紙に、発行日として 12 December 2002 と記されている。文書番号と、発行日という日付の種類を対応させて答える。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] United Nations (2002), A/57/532/Add.1. https://digitallibrary.un.org/record/481736/files/A_57_532_Add-1-EN.pdf

例 7 軍事介入を論じた著者

問題の原文（全文）

> Who authored the 1995–6 Survival article titled “The Politics and Ethics of Military Intervention”?

日本語訳（全文）

1995 ～ 1996 年の Survival 誌に掲載された論文「 The Politics and Ethics of Military Intervention 」の著者は誰か。

正解： Hoffmann （ Stanley Hoffmann ）

出版社の書誌情報は、 Stanley Hoffmann の論文として掲載する。題名と掲載時期から著者を特定する問題である。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Stanley Hoffmann (1995), The Politics and Ethics of Military Intervention. https://doi.org/10.1080/00396339508442814

例 8 抗壊血病因子の同定

問題の原文（全文）

> In what year was vitamin C (ascorbic acid) first identified as the antiscorbutic factor?

日本語訳（全文）

ビタミン C （アスコルビン酸）が、壊血病を防ぐ因子として初めて同定されたのは何年か。

正解： 1932 年

1932 年の Svirbely と Szent-Györgyi の報告は、 hexuronic acid が壊血病を防ぐ因子であることを扱っている。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Svirbely and Szent-Györgyi (1932), Hexuronic Acid as the Antiscorbutic Factor. https://www.nature.com/articles/129576a0

例 9 歯周病学の研究者の受賞年

問題の原文（全文）

> In what year did Yvonne L. Hernandez-Kapila (also known as Yvonne Kapila) receive the American Academy of Periodontology (AAP) Distinguished Scientist Award?

日本語訳（全文）

Yvonne L. Hernandez-Kapila （ Yvonne Kapila としても知られる）が、米国歯周病学会（ AAP ）の Distinguished Scientist Award を受賞したのは何年か。

正解： 2019 年

[1] Artificial Analysis (2025), AA-Omniscience-Public.
https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

例 9 歯周病学の研究者の受賞年：解説

学会の Distinguished Scientist Award 受賞者一覧は、 2019 年欄に Yvonne Kapila を挙げている。設問では氏名の別表記も示される。

[1] American Academy of Periodontology (n.d.), Award Recipients.
https://www.perio.org/for-members/aap-organizational-information/academy-awards/award-recipients/

例 10 野生のダイオウイカの写真

問題の原文（全文）

> In what year were the first photographs of a live Architeuthis dux in its natural habitat published?

日本語訳（全文）

自然の生息環境にいる、生きた Architeuthis dux （ダイオウイカ）の最初の写真が公表されたのは何年か。

正解： 2005 年

Kubodera と Mori の報告は 2005 年に公表された。写真は 2004 年 9 月 30 日に撮影されており、設問は公表年を求めている。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Kubodera and Mori (2005), First-ever observations of a live giant squid in the wild. https://pmc.ncbi.nlm.nih.gov/articles/PMC1559985/

例 11 単子葉植物の根の中心

問題の原文（全文）

> In monocot roots, which simple tissue type composes the central region of the vascular cylinder (stele)?

日本語訳（全文）

単子葉植物の根では、中心柱（ stele ）の中心部はどの種類の単純組織でできているか。

正解： parenchyma （柔組織）

単子葉植物の根の中央には髄があり、柔組織がその部分を構成する。設問は、中心部を作る組織の種類を求めている。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] OpenStax (2018), Biology 2e: Roots. https://openstax.org/books/biology-2e/pages/30-3-roots

例 12 企業の連結財務諸表

問題の原文（全文）

What was the cash and cash equivalents balance (in € millions) in adidas’s consolidated IFRS financial statements as of December 31, 2018?

日本語訳（全文）

2018 年 12 月 31 日時点で、 adidas の IFRS 連結財務諸表における現金及び現金同等物の残高は何百万ユーロだったか。

正解： 2,629 （百万ユーロ）

[1] Artificial Analysis (2025), AA-Omniscience-Public.
https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

例 12 企業の連結財務諸表：解説

adidas の 2019 年連結財務諸表にも、比較対象の 2018 年残高として 2,629 が掲載されている。残高の時点と百万ユーロという単位を対応させる。

[1] adidas (2020), Consolidated Statement of Financial Position.
https://report.adidas-group.com/2019/en/consolidated-financial-statements/consolidated-statement-of-financial-position.html

例 13 州最高裁判決の年

問題の原文（全文）

> In what year was the Oregon Supreme Court case State v. Mellenberger decided?

日本語訳（全文）

オレゴン州最高裁判所の State v. Mellenberger 事件の判決は何年に下されたか。

正解： 1939 年

公開された判決記録は、 1939 年のオレゴン州最高裁判決として収録されている。事件名と裁判所から、判決年を特定する問題である。

[1] Artificial Analysis (2025), AA-Omniscience-Public. https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public
[2] Oregon Supreme Court (1939), State v. Mellenberger. https://law.justia.com/cases/oregon/supreme-court/1939/163-or-233.html

2. 参考文献

参考文献

AA-Omniscience: Evaluating Cross-Domain Knowledge Reliability in Large Language Models

Declan Jackson et al. (2025). arXiv:2511.13029.

6,000 問の構築と、回答保留を含む採点・初期評価を報告する。

https://arxiv.org/abs/2511.13029

Public Dataset for AA-Omniscience: Evaluating Cross-Domain Knowledge Reliability in Large Language Models

Artificial Analysis Team (2025). Hugging Face, Apache License 2.0.

公開 600 問の設問・参照回答と、回答・採点の指示を示す。

https://huggingface.co/datasets/ArtificialAnalysis/AA-Omniscience-Public

参考文献

AA-Omniscience: Knowledge and Hallucination Benchmark

Artificial Analysis (n.d.). 2026-10-25 参照 .

新しいモデルの指数、正解率、幻覚率と分野別の比較を継続して公開する。

https://artificialanalysis.ai/evaluations/omniscience

Artificial Analysis Intelligence Benchmarking Methodology

Artificial Analysis (n.d.). 2026-10-25 参照 .

各評価の対象と設定をまとめ、採点モデルの変更と総合指標への組み込み方を記す。

https://artificialanalysis.ai/methodology/intelligence-benchmarking