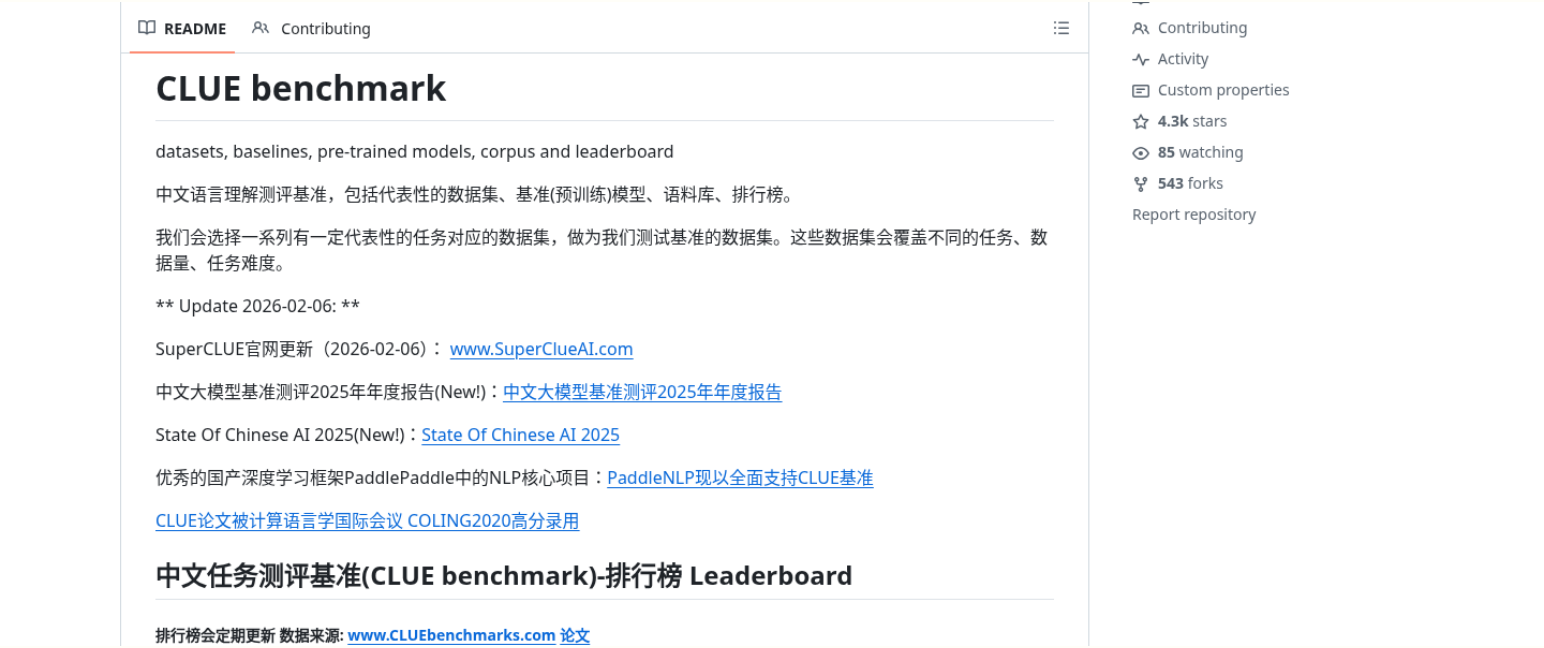
AFQMC

Ant Financial Question Matching Corpus

金融相談の二つの文を、意味で照合する

sasakiy84

AFQMC を公開する、 CLUE の公式リポジトリ



README Contributing

CLUE benchmark

datasets, baselines, pre-trained models, corpus and leaderboard

中文语言理解测评基准，包括代表性的数据集、基准(预训练)模型、语料库、排行榜。

我们会选择一系列有一定代表性的任务对应的数据集，做为我们测试基准的数据集。这些数据集会覆盖不同的任务、数据量、任务难度。

** Update 2026-02-06: **

SuperCLUE官网更新（2026-02-06）：www.SuperClueAI.com

中文大模型基准测评2025年年度报告(New!)：中文大模型基准测评2025年年度报告

State Of Chinese AI 2025(New!)：State Of Chinese AI 2025

优秀的国产深度学习框架PaddlePaddle中的NLP核心项目：PaddleNLP现以全面支持CLUE基准

CLUE论文被计算语言学国际会议 COLING2020高分录用

中文任务测评基准(CLUE benchmark)-排行榜 Leaderboard

排行榜会定期更新 数据来源: www.CLUEbenchmarks.com 论文

Contributing
Activity
Custom properties
4.3k stars
85 watching
543 forks
Report repository

[1] CLUE team. CLUE 公式 README 、 AFQMC の定義と公開分割。固定版 9e61ddd3659d 。 現在の公式 README 。 2020 年の論文成績とは区別する。
https://github.com/CLUEbenchmark/CLUE

1. 二つの金融相談を比べる
2. 出所と、公開ラベルの構造
3. 評価の分母と比較条件
4. CLEVA での採用と利用条件

二つの金融相談を比べる

同じ商品名より、何を尋ねているかを読む

- AFQMC は、金融サービスに関する二つの中国語文を読み、意味が似ているか、異なるかを判定するデータセット。
- 花呗・借呗・支付宝などの名称が頻出する。同じサービス名があっても、利用開始、支払方法、返済、返金など、尋ねている対象や操作は異なる。
- この課題の出力は、二つの文の意味についてのラベル。返済日や手数料への実際の回答を生成する課題ではない。

[1] CLUE team. CLUE 公式 README 、 AFQMC の定義と公開分割。固定版 9e61ddd3659d 。 https://github.com/CLUEbenchmark/CLUE

文１・文２の関係を、０か１で答える

- 配布ラベルは、１が「意味が似ている」、０が「意味が異なる」。サービスへの賛否や、相談内容の正しさを示す値ではない。
- 原データの項目は sentence1 、 sentence2 、 label 。短い相談、口語、誤字、伏せ字なども、そのまま公開されている。
- 以下の例は公式公開データの全文と配布ラベル。訳にはサービスの実際の仕様や、原文にない返済条件を書き足さない。

[1] CLUE team. CLUE 公式 README 、 AFQMC の定義と公開分割。固定版 9e61ddd3659d 。 https://github.com/CLUEbenchmark/CLUE

実例１：店の決済開通と、開通できない理由

公式 ZIP / train.json / 0 起算行 6 / 2 文とも全文

中国語原文（全文）

文１：商家怎么开通花呗支付
文２：为什么无法开通花呗

日本語訳（全文）

文１：店舗側はどうすれば花呗決済を利用できるようになりますか。
文２：なぜ花呗を利用開始できないのですか。

正解：意味が異なる（０）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 train.json 、 0 起算行 6 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

利用開始という語だけでは、同じ問いにならない

- 同じ開通という語があっても、店側の手続きと利用できない理由は異なる。 HELM 公開説明例と全文・正解が一致する。
- 文 1 は商家、つまり店側が花呗決済を使えるようにする手順を尋ねる。文 2 は利用開始できない理由を尋ねている。
- HELM の公開説明例では、 A が「不是」、 B が「是」で、正解は A 。原データの 0 と対応するが、すべての設定の選択肢順まで推測しない。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip
[2] Stanford CRFM. CLEVAParaphraseIdentificationScenario / Converter. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

実例２：注文での利用不可と、支払選択肢

公式 ZIP / dev.json / 0 起算行 5 / 2 文とも全文

中国語原文（全文）

文１：为什么这个订单不可以花呗支付
文２：为什么支付时没有出现用花呗支付

日本語訳（全文）

文１：なぜこの注文では花呗で支払えないのですか。
文２：なぜ支払うとき、花呗で支払う選択肢が出なかったのですか。

正解：意味が似ている（１）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 5 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

支払えない状態を、別の表現で尋ねる

- 表現が異なっていても、配布ラベルは同じ意味とする。語の重なりだけでは判定しない。
- 文 1 は注文で花呗を使えない理由、文 2 は支払時に花呗の選択肢が出ない理由を問う。配布データはラベル 1 としている。
- 意味が近いという注釈を、語が一字一句同じという条件へ置き換えない。文脈や問いの焦点を併せて読む。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例３：早めの分割払いと、繰上げ完済

公式 ZIP / dev.json / 0 起算行 13 / 2 文とも全文

中国語原文（全文）

文１：花呗提前分期利息怎么算
文２：花呗分期提前结清会有手续费吗

日本語訳（全文）

文１：花呗で早めに分割払いにするとき、利息はどう計算されますか。
文２：花呗の分割払いを繰上げ完済すると、手数料はかかりますか。

正解：意味が異なる（０）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 13 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

利息の計算と、完済時の手数料を分ける

- 分割払いの利息の計算方法と、完済手数料の有無を区別する。配布ラベルを保持し、金融上の回答を補わない。
- 文 1 は早めに分割払いにする際の利息の計算、文 2 は分割払いを繰上げ完済する際の手数料の有無を尋ねている。
- 二つの文を似ていると感じても、ここでは公式配布の 0 を保持する。新しい正解を作って、元ラベルを上書きしない。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

出所と、公開ラベルの構造

元の出所は、 ATEC の開発者向け大会

- 2020 年の CLUE 正式論文は、 AFQMC を Ant Technology Exploration Conference （ ATEC ）の Developer competition 由来と説明する。
- 文ペアの意味が似ているかを判定する二値分類で、 CLUE の表はデータの分野を online customer service と示す。
- 元大会の配布経路は論文脚注にあるが、今回の取得では応答を得られなかった。原大会と CLUE 公開版の全レコード同一性は確認できていない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] Ant Technology Exploration Conference. CLUE 正式論文が示す元大会の経路。 https://dc.cloud.alipay.com/index#/topic/intro?id=3

公開 3 分割：ラベルを読める範囲が異なる

ファイル	0 ：異なる	1 ：似ている	全件
train.json	23,761	10,573	34,334
dev.json	2,978	1,338	4,316
test.json	非公開	非公開	3,861

3 ファイルの合計は 42,511 組。 test の件数を、正解を確認できる件数へ加算しない。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

原ラベルと、コードが置く仮の値を分ける

- 公開 test には正解ラベルがない。読み込みコードが置く仮の 0 を、配布正解とみなして採点しない。
- 公式 AfqmcProcessor は、 train/dev では label を読む。test では実行に必要な仮値として文字列「 0 」を入れる。
- この 0 を使って全 test の正答率を計算しても、意味のある評価にならない。ラベル非公開の test と、正解付き dev を区別する。

[1] CLUE team. AfqmcProcessor. CLUE official PyTorch baseline 、 9e61ddd3659d 。
https://github.com/CLUEbenchmark/CLUE/blob/master/baselines/models_pytorch/classifier_pytorch/processors/clue.py

原文の省略、誤字、伏せ字を保持する

- 「***」は配布された文字列の一部。月や金額が伏せられていても、実際の値を推測して復元しない。
- 原文には断片的な相談や誤字もある。原文を勝手に整文せず、日本語訳では意味が確認できる範囲で自然に表す。
- 花呗、借呗、友付宝などは原文の商品・サービス名を区別して残す。似た字の別名へ訂正しない。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

同じ単文と、同じ文ペアは別の単位

- 分割間に同じ単文が現れても、二つの文を組にしたレコードが同じとは限らない。単文の共有と文ペアの共有を分けて数える。
- 取得版では、 train ・ dev ・ test の間に同一の文ペアは見つからなかった。文 1 と文 2 を入れ替えた組として比較しても、分割間の共有は 0 組。
- 一方で単文文字列の共有は、 train–dev170 種類、 train–test174 種類、 dev–test33 種類。数字・空白・記号を変えずに照合した。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

評価の分母と比較条件

AFQMC の基本指標は、二値の正答率

- CLUE 正式論文と公式 compute_metrics は、 AFQMC を accuracy で評価する。配布正解と予測ラベルが一致した割合である。
- 同じファイルには F1 を計算する関数もあるが、 AFQMC の分岐が返す値は accuracy 。関数が存在するだけで、この課題の公式主指標とはしない。
- 以降のモデル成績は 2020 年論文の報告値。今回、モデルを新しく学習・推論して得た結果ではない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUE team. compute_metrics / simple_accuracy. CLUE official PyTorch baseline 、 9e61ddd3659d 。 https://github.com/CLUEbenchmark/CLUE/tree/master/baselines/models_pytorch/classifier_pytorch/metrics

dev で定数予測を採点し、分母を確かめる

予測する値	一致数／全件	正答率
すべて 0	2,978 / 4,316	69.00%
すべて 1	1,338 / 4,316	31.00%

公式 simple_accuracy と compute_metrics をそのままローカル実行。モデル成績ではなく、正解付き dev での定数予測。

[1] CLUE team. compute_metrics / simple_accuracy. CLUE official PyTorch baseline 、 9e61ddd3659d 。
https://github.com/CLUEbenchmark/CLUE/tree/master/baselines/models_pytorch/classifier_pytorch/metrics

2020 年の CLUE 論文： AFQMC の test 成績

モデル	正答率
BERT-base	73.70%
ALBERT-xxlarge	75.60%
RoBERTa-wwm-ext-large	76.55%

2020 年論文の AFQMC 成績。 CLUE 全課題の平均値や、 dev 定数予測との同条件比較ではない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/

3 回の学習から、 dev で選んだ test 結果

- 論文はモデルを課題ごとに fine-tune し、 dev の成績でハイパーパラメータと early stopping のチェックポイントを選んだと説明する。
- 各モデルを 3 回 fine-tune し、 dev で最も良かったモデルの test 結果を報告する。 3 回の test 正答率を平均した値とは説明していない。
- 公開の全 test 予測は今回取得していない。論文の 73.70% などを、独立に再採点した値とは呼ばない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/

人手評価は、別の 100 件を多数決で判定した

- 人手の 81.0% は、 test から無作為に選んだ 100 件に対する、3 人の多数決の正答率。モデルの全 test 成績とは分母が異なる。
- 判定者は、事前に dev の 30 〜 50 件を解き、正解と比べて誤りや疑問を話し合った。その後、無作為に選んだ test100 件を判定した。
- AFQMC では 3 人が 83.0% 、 81.0% 、 76.0% 、平均 80.0% 、多数決 81.0% 。この多数決の正答率は、データ作成時の注釈者間一致度ではない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/

CLEVA での採用と利用条件

CLEVA は、金融質問の意味照合に採用する

- CLEVA は、 paraphrase_identification の financial_question で、二つの質問が同じ意味かを選択式で尋ねる。
- HELM の公開説明例は、「商家怎么开通花呗支付」と「为什么无法开通花呗」。公式 AFQMC train の 0 起算行 6 に全文一致し、原ラベル 0 と公開正解 A も対応する。
- CLEVA 論文の CLUE/FewCLUE という出所の説明に加え、この原文・正解の一致で AFQMC との対応を確認できる。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM. CLEVAParaphraseIdentificationScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

実装の存在と、公開実行の結果を分ける

- HELM v0.4.0 の言い換え判定クラスは、 financial_question を扱う。 prompt_id は 0 〜 5 の 6 通り。実際の文面と候補順は、変換済みテンプレートに依存する。
- 固定 Classic v0.4.0 の公開 8,526run には、 CLEVA の実行は 0 件。 AFQMC 採用版の実要求出力や得点を、この版から再採点できない。
- CLEVA の選定原票と全テンプレートは取得できていない。公式 AFQMC の 42,511 組を、そのまま CLEVA の評価件数に置き換えない。

[1] Stanford CRFM. CLEVAParaphraseIdentificationScenario / Converter. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py
[2] Stanford CRFM. HELM Classic v0.4.0 、 2023-11-17 固定公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/

配布データと、実装・論文の権利を分ける

- CLUE 公式 README は AFQMC の定義、分割、公式 ZIP を示す。ZIP は取得日と SHA256 で版を特定し、取り出した各ファイルも区別して参照する。
- 原大会由来の設問を、 CLUE の論文・モデル実装・翻訳と区別する。サブディレクトリにあるモデルコードの Apache ライセンスを、データ全体の許諾とみなさない。
- 確認した公式経路では、 AFQMC データ固有の包括的なライセンスを特定できていない。元の出所と著者への帰属を保って参照する。

[1] CLUE team. CLUE 公式 README 、 AFQMC の定義と公開分割。固定版 9e61ddd3659d 。 https://github.com/CLUEbenchmark/CLUE
[2] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

二つの文の焦点を、ラベルと併せて読む

- AFQMC は、金融相談の二つの文が似た意味かどうかを測る文ペア分類。語の重なりより、対象、操作、条件、尋ねている量に注意する。
- 公開 train/dev の正解、ラベル非公開 test 、コード中の仮値を区別する。元大会・ CLUE 公開版・ CLEVA 採用版も、同じ集合と仮定しない。
- モデル成績は学習・選択・評価の分母を確認して解釈する。人手の多数決、注釈一致度、定数予測の得点を混ぜない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/

Appendix

1. 追加の相談文と配布ラベル
2. 原位置・集計・実装の補足
3. 研究と参考文献

追加の相談文と配布ラベル

実例 4 ：受取側の金額制限

公式 ZIP / dev.json / 0 起算行 10 / 2 文とも全文

中国語原文（全文）

文 1 ：花呗收款额度限制
文 2 ：收钱码，对花呗支付的金额有限制吗

日本語訳（全文）

文 1 ：花呗で受け取る金額の制限。
文 2 ：代金受取用コードでは、花呗で支払う金額に制限がありますか。

正解：意味が似ている（ 1 ）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 10 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例５：支払い遅延の後、使えるまでの期間

公式 ZIP / dev.json / 0 起算行 19 / 2 文とも全文

中国語原文（全文）

文１：之前有逾期账单，，什么时候才能用花呗
文２：花呗逾期后多久能用

日本語訳（全文）

文１：以前、支払いが遅れた請求がありました。いつになれば花呗を使えますか。
文２：花呗で支払いが遅れた後、どのくらいで使えますか。

正解：意味が似ている（１）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 19 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例６：電話番号を変えた後の利用

公式 ZIP / dev.json / 0 起算行 22 / 2 文とも全文

中国語原文（全文）

文１：我开通花呗的手机号坏了，现在换了手机号怎么找回原来的号
文２：我以前的号码开通的支付宝，然后号码不用了，现在我开花呗要用不用的号码，能解决么

日本語訳（全文）

文１：花呗を利用開始した携帯電話の番号が使えなくなりました。番号を変えた今、元の番号をどう取り戻せますか。
文２：以前の電話番号で支付宝を利用開始しましたが、その番号はもう使っていません。今、花呗を利用開始しようとすると、使わなくなった番号が必要になります。解決できますか。

正解：意味が似ている（１）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 22 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例 7 ：誤って解除した利用許可

公式 ZIP / dev.json / 0 起算行 28 / 2 文とも全文

中国語原文（全文）

文 1 ：借呗授权取消了还能再次授权借呗吗
文 2 ：借呗授权不小心关闭还能在授权吗

日本語訳（全文）

文 1 ：借呗の利用許可を取り消した後、もう一度、借呗の利用を許可できますか。
文 2 ：借呗の利用許可をうっかり無効にしました。もう一度許可できますか。

正解：意味が似ている（ 1 ）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 28 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例 8 ：請求前の表示と、支払期限

公式 ZIP / dev.json / 0 起算行 35 / 2 文とも全文

中国語原文（全文）

文 1 ：花呗提示未出账，还款是什么时候还
文 2 ：今天用花呗买了 什么时候还款

日本語訳（全文）

文 1 ：花呗に「まだ請求が出ていない」と表示されます。返済はいつすればよいですか。
文 2 ：今日、花呗で買い物をしました。いつ返済すればよいですか。

正解：意味が似ている（ 1 ）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 35 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例９：返金された後も、返済が必要か

公式 ZIP / dev.json / 0 起算行 36 / 2 文とも全文

中国語原文（全文）

文１：订单退款成功了，为什么仍然要还花呗
文２：退款到了花呗，为什么还要还款

日本語訳（全文）

文１：注文の返金は完了したのに、なぜまだ花呗に返済しなければならないのですか。
文２：返金が花呗に戻ったのに、なぜまだ返済が必要なのですか。

正解：意味が似ている（１）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 36 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例 10 ：本人確認と、開設できる数

公式 ZIP / dev.json / 0 起算行 7 / 2 文とも全文

中国語原文（全文）

文１：一个身份证能办几个花呗
文２：花呗身份验证为何不亮

日本語訳（全文）

文１：１枚の身分証で、花呗はいくつ開設できますか。
文２：なぜ花呗の本人確認の表示が点灯しないのですか。

正解：意味が異なる（０）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 7 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例 11 ：返済日の勘違いと、日付の変更

公式 ZIP / dev.json / 0 起算行 14 / 2 文とも全文

中国語原文（全文）

文 1 ：记错借呗的还款日期 这几天没去注意 怎么办
文 2 ：支付借呗怎么修改还款日期

日本語訳（全文）

文 1 ：借呗の返済日を覚え間違え、この数日、気にしていませんでした。どうすればよいですか。
文 2 ：借呗への返済日をどう変更すればよいですか。

正解：意味が異なる（ 0 ）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 14 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例 12 ：伏せ字を含む請求月と、過去の明細

公式 ZIP / dev.json / 0 起算行 15 / 2 文とも全文

中国語原文（全文）

文 1 ： *** 月份的花呗为什么出现在 *** 月份的账单里
文 2 ：花呗的往期账单怎么查

日本語訳（全文）

文 1 ：なぜ *** 月の花呗の利用分が、 *** 月の請求明細に出てくるのですか。
文 2 ：花呗の過去の請求明細は、どう確認できますか。

正解：意味が異なる（ 0 ）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 15 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

実例 13 ：高速鉄道の乗車券と、支払サービス

公式 ZIP / dev.json / 0 起算行 1 / 2 文とも全文

中国語原文（全文）

文 1 ：花呗支持高铁票支付吗
文 2 ：为什么友付宝不支持花呗付款

日本語訳（全文）

文 1 ：花呗は高速鉄道の乗車券の支払いに対応していますか。
文 2 ：なぜ友付宝は花呗での支払いに対応していないのですか。

正解：意味が異なる（ 0 ）

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。 dev.json 、 0 起算行 1 。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

原位置・集計・実装の補足

原位置：ファイル名と 0 起算行で特定する

実例	ファイル	0 起算行	配布ラベル
1	train.json	6	0
2	dev.json	5	1
3	dev.json	13	0
4	dev.json	10	1
5	dev.json	19	1
6	dev.json	22	1
7	dev.json	28	1

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

原位置：追加例の後半

実例	ファイル	0 起算行	配布ラベル
8	dev.json	35	1
9	dev.json	36	1
10	dev.json	7	0
11	dev.json	14	0
12	dev.json	15	0
13	dev.json	1	0

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

同じ文ペアと、同じ単文の分割間共有

分割の組	文ペア	単文文字列
train–dev	0	170
train–test	0	174
dev–test	0	33

文ペアは順序付きでも、文 1/ 文 2 を入れ替えた比較でも共有 0 。単文は文 1 ・文 2 の位置を区別せず集合化。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

分割内の原文形式を、そのまま数える

ファイル	*** を含む組	同文同士の組
train.json	3,548	2
dev.json	439	0
test.json	409	0

train は順序付きの重複 0 だが、文を入れ替えた組で重複が 2 組ある。原レコードを削除せず保持する。

[1] Ant Financial / CLUE team. AFQMC 公式公開 ZIP 、 2026-10-18 取得。元設問の権利は出所に帰属。
https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

dev の多数派だけを答える場合の正答率

```
import json
from pathlib import Path
rows = [json.loads(s) for s in
        Path('dev.json').read_text().splitlines()]
correct = sum(r['label'] == '0' for r in rows)
print(correct, len(rows), correct / len(rows))
```

出力は 2978 、 4316 、 0.6899907321594069 。正式モデルの test 得点ではない。

[1] CLUE team. compute_metrics / simple_accuracy. CLUE official PyTorch baseline 、 9e61ddd3659d 。
https://github.com/CLUEbenchmark/CLUE/tree/master/baselines/models_pytorch/classifier_pytorch/metrics

2020 年： AFQMC のモデル比較①

モデル	正答率（%）
BERT-base	73.70
BERT-wwm-ext-base	74.07
ALBERT-tiny	69.92
ALBERT-xxlarge	75.60
ERNIE-base	73.83

2020 年論文の AFQMC test 報告値。全予測から再計算した得点ではない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/

2020 年： AFQMC のモデル比較②

モデル	正答率（%）
XLNet-mid	70.50
RoBERTa-large	74.02
RoBERTa-wwm-ext-base	74.04
RoBERTa-wwm-ext-large	76.55

2020 年論文の AFQMC test 報告値。 CLUE 全課題の平均とは分けて読む。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/

公開 baseline の実行設定は、論文全体と分ける

- 公式 BERT baseline の AFQMC 用シェルには、max_seq_length128 、 batch32 、学習率 2e−5 、 3epoch の設定がある。
- これは一つの公開実装の設定であり、論文の全 9 モデルに同一のハイパーパラメータを使ったことを意味しない。
- 同じ設定を CLEVA の提示例数や生成数として転用しない。CLEVA の完全な infer_params は今回取得できていない。

[1] CLUE team. CLUE 公式 README 、 AFQMC の定義と公開分割。固定版 9e61ddd3659d 。 https://github.com/CLUEbenchmark/CLUE

研究と参考文献

AFQMC を収録した、 CLUE のベンチマーク研究

- 2020 年の CLUE 論文は、 Liang Xu ・ Hai Hu ・ Xuanwei Zhang ら CLUE team による COLING 論文。中国語理解の複数課題をまとめ、教師あり学習の基準値と人手評価を報告した。
- AFQMC の原大会由来という説明と、 CLUE による配布・評価を分けて読む。原大会データの全注釈手順や、 CLUE 分割を作った乱数 seed は、確認した一次資料では特定できていない。
- AFQMC と他の短文意味照合データは、出所・分割・ラベルの基準を分けて読む。 CLEVA 採用版も、元 AFQMC の全件とは別の集合として扱う。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, 4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUE team. CLUE 公式 README 、 AFQMC の定義と公開分割。固定版 9e61ddd3659d 。 https://github.com/CLUEbenchmark/CLUE

参考文献

CLUE: A Chinese Language Understanding Evaluation Benchmark

Xu et al. · 2020 · COLING 4762–4772

AFQMC の出所、評価指標、教師ありモデル成績と人手評価を報告する。

https://aclanthology.org/2020.coling-main.419/

CLUE: official repository and AFQMC description

CLUE team · fixed commit 9e61ddd3659d

AFQMC の正式名称、二値ラベル、公開分割とデータ入手先を示す。

https://github.com/CLUEbenchmark/CLUE

参考文献

AFQMC public data archive

Ant Financial / CLUE team · official GCS ZIP

原文ペアと train/dev のラベル、ラベル非公開 test を配布する。

https://storage.googleapis.com/cluebenchmark/tasks/afqmc_public.zip

ATEC Developer competition: original route

Ant Technology Exploration Conference · cited in CLUE2020

AFQMC の出所として元論文が挙げる大会の経路。今回の応答は未取得。

https://dc.cloud.alipay.com/index#/topic/intro?id=3

参考文献

AfqmcProcessor and compute_metrics

CLUE team · official PyTorch baseline · 9e61ddd3659d

2 文の読み込み、 test 仮ラベル、 AFQMC の accuracy 分岐を定義する。

https://github.com/CLUEbenchmark/CLUE/tree/master/baselines/models_pytorch/classifier_pytorch

CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations 186–217

金融質問を含む、質問ペアの意味照合という後続利用を説明する。

https://aclanthology.org/2023.emnlp-demo.17/

参考文献

CLEVAParaphraseIdentificationScenario and Converter

Stanford CRFM · HELM v0.4.0

AFQMC 原例と一致する説明例、候補の変換、正解タグを定義する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

HELM Classic v0.4.0 public release

Stanford CRFM · release 2023-11-17

固定 8,526run の一覧。 CLEVA 実行の有無を調べる対象。

https://crfm.stanford.edu/helm/classic/v0.4.0/