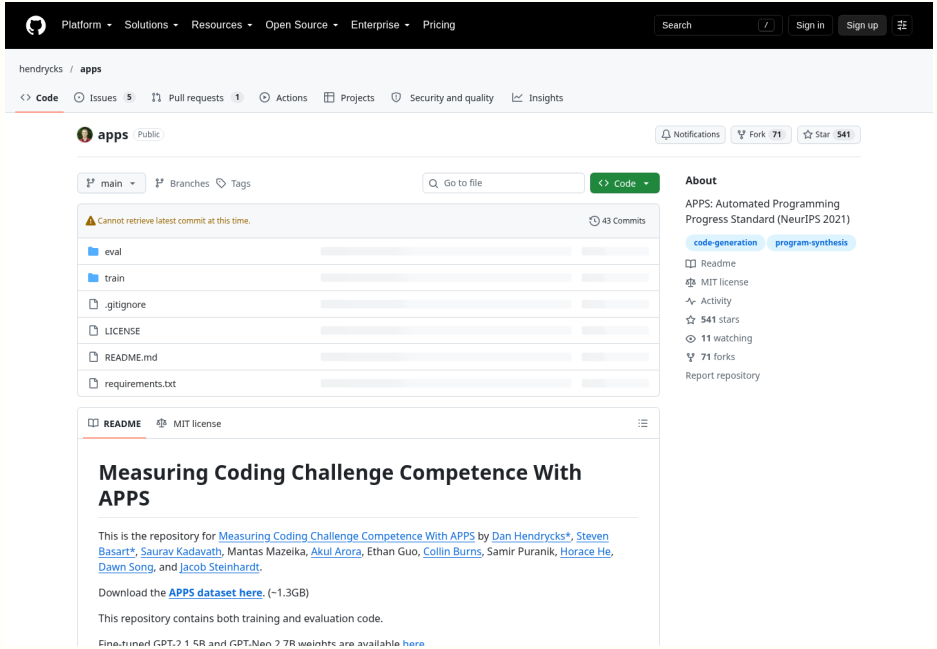
APPS

Automated Programming Progress Standard

自然言語の仕様から、テストを通るプログラムを書く

sasakiy84

APPS の公開ページ



[1] APPS 公式公開ページ。 2026-10-18 参照。 https://github.com/hendrycks/apps

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

仕様に合ったプログラムを、実行して採点する

- 英語の問題文を入力し、 Python の解答を生成する 10,000 問の課題である。入門、面接、競技の 3 水準を含む。
- 関数を呼び出す形式と、標準入力を読んで標準出力へ書く形式がある。実例には問題文と配布テストの一部を示す。

[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

入力・出力と配布フィールド

フィールド	意味
question / starter_code	問題文と、ある場合は開始コード
input_output	入力・期待値・関数名を持つ JSON 文字列
solutions / difficulty	参照実装と難易度

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 https://huggingface.co/datasets/codeparrot/apps

実例１： N 番目の偶数

関連する入力・回答／左：原文　右：日本語

Return the Nth Even Number
The input will not be 0.
{"fn_name":"nth_even","inputs":[[1],[2]],"outputs":[[0],[2]]}

問題文１： N 番目の偶数を返す。
問題文２：入力が 0 になることはない。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 4459 。 https://huggingface.co/datasets/codeparrot/apps

実例２：数字１の出現回数（原文）

原文

Given an integer n, count the total number of digit 1 appearing in all non-negative integers less than or equal to n.
Example:
Input: 13
Output: 6
Explanation: Digit 1 occurred in the following numbers: 1, 10, 11, 12, 13.
Tests (excerpt): {"fn_name":"countDigitOne","inputs":[[13]],"outputs":[6]}

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 397 。 https://huggingface.co/datasets/codeparrot/apps

実例２：数字１の出現回数（日本語訳）

日本語訳

整数 n が与えられる。 n 以下のすべての非負整数に、数字の 1 が合計何回現れるかを数える。
例：
入力： 13
出力： 6
説明：数字の 1 は、 1 、 10 、 11 、 12 、 13 に現れる。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 397 。 https://huggingface.co/datasets/codeparrot/apps

実例３：剰余の最大値（原文 1/2 ）

原文

You are given a sequence a consisting of n integers. Find the maximum possible value of $a_{i} \operatorname{mod} a_{j}$ (integer remainder of a_{i} divided by a_{j}), where 1 ≤ i, j ≤ n and a_{i} ≥ a_{j}.
-----Input-----
The first line contains integer n — the length of the sequence (1 ≤ n ≤ 2·10^5).
The second line contains n space-separated integers a_{i} (1 ≤ a_{i} ≤ 10^6).
-----Output-----
Print the answer to the problem.

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2191 。 https://huggingface.co/datasets/codeparrot/apps

実例 3 ：剰余の最大値（原文 2/2 ）

原文

```
-----Examples-----
Input
3
3 4 5
Output
2
Tests (excerpt): {"inputs":["3\n3 4 5\n","3\n1 2 4\n"],"outputs":
["2\n","0\n"]}
```

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2191 。 https://huggingface.co/datasets/codeparrot/apps

実例３：剰余の最大値（日本語訳 1/2）

日本語訳

n 個の整数からなる列 a が与えられる。 1 ≤ i, j ≤ n 、 a_i ≥ a_j のとき、 a_i mod a_j 、すなわち a_i を a_j で割った余りの最大値を求める。
入力
最初の行には、列の長さ n が与えられる（ 1 ≤ n ≤ 2×10^5 ）。
2 行目には、空白で区切られた n 個の整数 a_i が与えられる（ 1 ≤ a_i ≤ 10^6 ）。
出力
問題の答えを出力する。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2191 。 https://huggingface.co/datasets/codeparrot/apps

実例 3 ：剰余の最大値（日本語訳 2/2 ）

日本語訳

例
入力
3
3 4 5
出力
2
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2191 。 https://huggingface.co/datasets/codeparrot/apps

作成方法とデータの構成

作成の背景

- コードの見た目や参照実装との語句の一致だけでは、仕様どおりに動くかを測れない。
- オンラインのプログラミング課題を集め、同じ問題に複数の実装があり得るため、テストで正しく動くかを評価する。

[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

収集と品質の確認

- Codeforces 、 Codewars 、 AtCoder などの公開課題から、英語の仕様、 Python 解答、入力と期待値を収集した。
- 収集した解答をテストし、問題を入門・面接・競技の 3 水準に分けた。 10,000 問に対し、 232,421 件の解答プログラムを報告している。

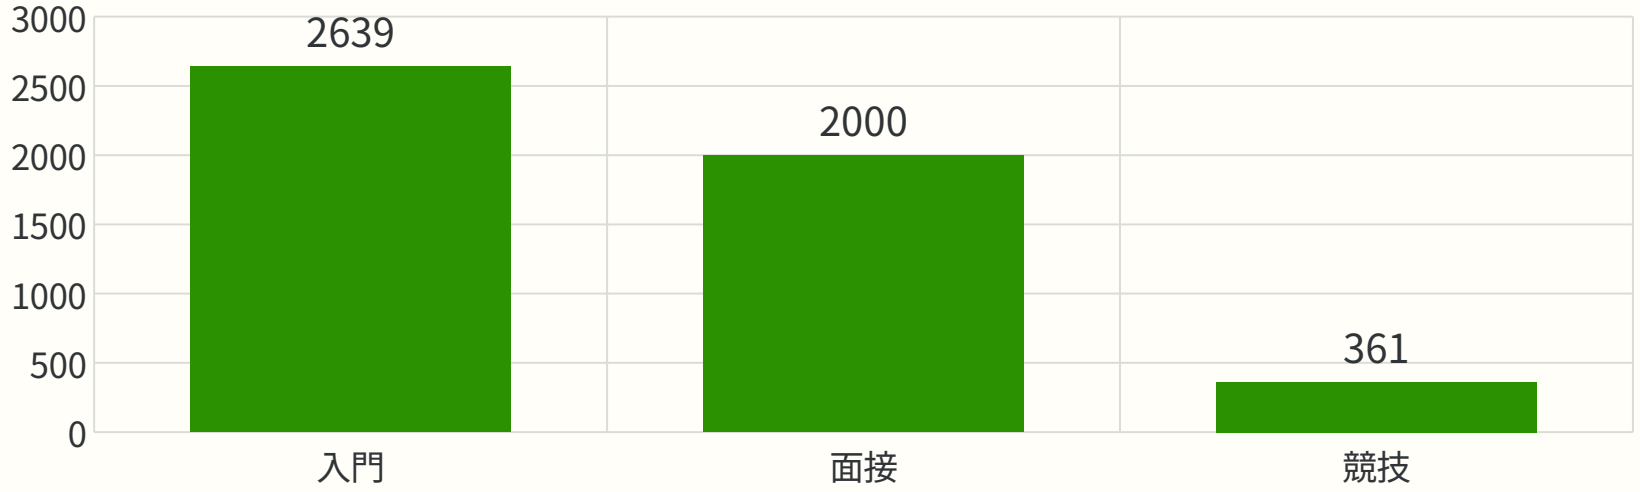
[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

分割と件数

集合・対象	件数	役割
train	5,000	入門 2,639 ・面接 2,000 ・競技 361
test	5,000	入門 1,000 ・面接 3,000 ・競技 1,000
本資料の実例	train の 13 問	問題文とテストを照合

[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

train の難易度構成



train 全 5,000 問を配布 difficulty で集計。縦軸は問題数。

[1] APPS 、 train 全 5,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/codeparrot/apps

採点方法とモデルの成績

何を 1 件として、どう採点するか

- Test Case Average は、各問題で通ったテストの割合を求め、その値を問題間で平均する。
- Strict Accuracy は、全テストを通った問題の割合。 2 問でそれぞれ 3/4 、 1/1 を通った場合、前者は 87.5% 、後者は 50% 。

[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

初期の代表的な評価

GPT-Neo 2.7B ／入門問題	Top-1	Top-5
Test Case Average （％）	14.7	19.9
Strict Accuracy （％）	3.9	5.5

APPS で微調整し、 1 候補と 5 候補の最良結果を比較。

[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

HELM での評価条件

- HELM の APPS は test から 1,000 問、最大 2 例提示、 3 試行。各入力で 1 候補を生成する。
- 温度 0.2 、最大 600 トークン。 Test Case Average と Strict Accuracy を採点する。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	テスト平均（%）	全通過（%）
code-cushman-001 （2021）	4.82	2.03
code-davinci-002 （2022）	20.04	10.80

test 1,000 問、最大 2 例提示、 3 試行。各入力 1 候補。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

実行で採点するコード生成評価へつながる

- APPS は、参照コードとの類似度から、仕様を満たすかを実行で調べる評価への移行を示す。
- 2026-10-18 時点で公式のデータと評価実装、 HELM の APPS シナリオが公開されている。 HumanEval の関数課題に比べ、長い仕様や標準入出力も扱う。

[1] APPS 公式公開ページ。 2026-10-18 参照。 https://github.com/hendrycks/apps

入手方法と利用条件

- 公式 GitHub と codeparrot/apps から取得できる。question に加え、 JSON 文字列の input_output と solutions を復号する。
- 本資料は train 全 5,000 問を取得した。テストがあるレコードから 13 問を選び、問題文の表示範囲と実際の期待値を照合した。
- 公式リポジトリと Hugging Face のデータカードは MIT を掲げている。

[1] APPS 公式公開ページ。 2026-10-18 参照。 https://github.com/hendrycks/apps

APPS の要点

- 10,000 問のプログラミング課題を、複数の難易度と入出力形式で評価する。
- テストを一部通る能力と、全テストを通る能力を、二つの指標で分けて読める。

[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：平均の計算

関連する入力・回答／原文と日本語

Write function avg which calculates average of numbers in given list.
{"fn_name":"find_average","inputs":[[[1,2,3]]],"outputs":[[2]]}

問題文１：与えられたリスト内の数値の平均を計算する関数 avg を書く。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 4243 。 https://huggingface.co/datasets/codeparrot/apps

追加例２：時刻の減算

関連する入力・回答／左：原文　右：日本語

Get n seconds before the target time. See Example Test Cases about the format.
{"fn_name":"seconds_ago","inputs":[["2000-01-01 00:00:00",1],["0001-02-03 04:05:06",7]],"outputs":[["1999-12-31 23:59:59"],["0001-02-03 04:04:59"]]}

問題文１：指定時刻の n 秒前を求める。形式については、テストケースの例を参照する。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 4550 。 https://huggingface.co/datasets/codeparrot/apps

追加例３：１個おきに２倍

関連する入力・回答／原文と日本語

Write a function, that doubles every second integer in a list starting from the left.
{"fn_name":"double_every_other","inputs":[[[1,2,3,4,5]],[[1,19,6,2,12,-3]]],"outputs":[[[1,4,3,8,5]],[[1,38,6,4,12,-6]]]}

問題文１：リストの左から２番目、４番目、６番目と、１個おきの整数を２倍にする関数を書く。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭２件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 4686 。 https://huggingface.co/datasets/codeparrot/apps

追加例 4 ： 16 進数の変換

関連する入力・回答／原文と日本語

Complete the function which converts hex number (given as a string) to a decimal number.
{"fn_name":"hex_to_dec","inputs":[["1"],["a"]],"outputs":[[1],[10]]}

問題文 1 ： 16 進数を表す文字列を、 10 進数へ変換する関数を完成させる。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 3708 。 https://huggingface.co/datasets/codeparrot/apps

追加例 5 ：最長の回文（原文）

原文

Given a string s, find the longest palindromic substring in s. You may assume that the maximum length of s is 1000.
Example 1:
Input: "babad"
Output: "bab"
Note: "aba" is also a valid answer.
Example 2:
Input: "cbbd"
Output: "bb"
Tests (excerpt): {"fn_name":"longestPalindrome","inputs": [["\"babad\""]],"outputs":["bab"]}

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 422 。 https://huggingface.co/datasets/codeparrot/apps

追加例 5 ：最長の回文（日本語訳）

日本語訳

文字列 s の最長の回文部分文字列を求める。 s の長さは最大 1,000 と仮定してよい。
例 1 ：
入力： "babad"
出力： "bab"
注： "aba" も有効な答えである。
例 2 ：
入力： "cbbd"
出力： "bb"
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 422 。 https://huggingface.co/datasets/codeparrot/apps

追加例 6 ：文字列の交ぜ合わせ（原文）

原文

Given s1, s2, s3, find whether s3 is formed by the interleaving of s1 and s2.
Example 1:
Input: s1 = "aabcc", s2 = "dbbca", s3 = "aadbbcbcac"
Output: true
Example 2:
Input: s1 = "aabcc", s2 = "dbbca", s3 = "aadbbbaccc"
Output: false
Tests (excerpt): {"fn_name":"isInterleave","inputs": [["\"aabcc\"","\"dbbca\"","\"aadbbcbcac\""]],"outputs":[false]}

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 323 。 https://huggingface.co/datasets/codeparrot/apps

追加例 6 ：文字列の交ぜ合わせ（日本語訳）

日本語訳

s1 、 s2 、 s3 が与えられる。 s1 と s2 の文字順をそれぞれ保って混ぜ合わせることで、 s3 を作れるか判定する。
例 1 ：
入力： s1 = "aabcc", s2 = "dbbca", s3 = "aadbbcbcac"
出力： true
例 2 ：
入力： s1 = "aabcc", s2 = "dbbca", s3 = "aadbbbaccc"
出力： false
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 323 。 https://huggingface.co/datasets/codeparrot/apps

実例の補足：文字列の交ぜ合わせ

- 配布テストでは引数の文字列に引用符自体が入り、期待値は false になっている。問題文の例 1 では引用符を表記に使っており、入力の内容が異なる。配布値を加工せず掲載した。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 https://huggingface.co/datasets/codeparrot/apps

追加例 7 ：平方数の和（原文）

原文

Given a positive integer n, find the least number of perfect square numbers (for example, 1, 4, 9, 16, ...) which sum to n.
Example 1:
Input: n = 12
Output: 3
Explanation: 12 = 4 + 4 + 4.
Example 2:
Input: n = 13
Output: 2
Explanation: 13 = 4 + 9.
Tests (excerpt): {"fn_name":"numSquares","inputs":[[12]],"outputs":[3]}

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 343 。 https://huggingface.co/datasets/codeparrot/apps

追加例 7 ：平方数の和（日本語訳 1/2 ）

日本語訳

正の整数 n を、完全平方数（ 1 、 4 、 9 、 16 など）の和で表すとき、必要な個数の最小値を求める。
例 1 ：
入力： n = 12
出力： 3
説明： 12 = 4 + 4 + 4 。
例 2 ：
入力： n = 13
出力： 2
説明： 13 = 4 + 9 。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 343 。 https://huggingface.co/datasets/codeparrot/apps

追加例 7 ：平方数の和（日本語訳 2/2 ）

日本語訳

配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 343 。 https://huggingface.co/datasets/codeparrot/apps

追加例 8 ：素数と分数の和（原文 1/3 ）

原文

Let's assume that v(n) is the largest prime number, that does not exceed n;
 u(n) is the smallest prime number strictly greater than n.
Find $\sum_{i = 2}^{n} \frac{1}{v(i) u(i)}$.
-----Input-----
The first line contains integer t (1 ≤ t ≤ 500) — the number of testscases.
Each of the following t lines of the input contains integer n (2 ≤ n ≤ 10^9).

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2172 。 https://huggingface.co/datasets/codeparrot/apps

追加例 8 ：素数と分数の和（原文 2/3 ）

原文

-----Output-----
Print t lines: the i-th of them must contain the answer to the i-th test as an irreducible fraction "p/q", where p, q are integers, q > 0.
-----Examples-----
Input
2
2
3
Output
1/6
7/30

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2172 。 https://huggingface.co/datasets/codeparrot/apps

追加例 8 ：素数と分数の和（原文 3/3 ）

原文

Tests (excerpt): {"inputs":["2\n2\n3\n","1\n1000000000\n"],"outputs":["1/6\n7/30\n","999999941999999673/1999999887999999118\n"]}

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2172 。 https://huggingface.co/datasets/codeparrot/apps

追加例 8 ：素数と分数の和（日本語訳 1/2 ）

日本語訳

n 以下の最大の素数を v(n) とする。
n より大きい最小の素数を u(n) とする。
i = 2 から n までの 1 / (v(i)u(i)) の総和を求める。
入力
最初の行には、テストケース数 t が与えられる（ 1 ≤ t ≤ 500 ）。
続く t 行には、それぞれ整数 n が与えられる（ 2 ≤ n ≤ 10^9 ）。
出力
t 行を出力する。 i 行目には、 i 番目のテストの答えを既約分数 "p/q" で出力する。 p と q は整数で、 q > 0 とする。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2172 。 https://huggingface.co/datasets/codeparrot/apps

追加例 8 ：素数と分数の和（日本語訳 2/2 ）

日本語訳

例
入力
2
2
3
出力
1/6
7/30
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2172 。 https://huggingface.co/datasets/codeparrot/apps

追加例 9 ：隣接交換と回文（原文 1/2 ）

原文

You are given a string S consisting of lowercase English letters. Determine whether we can turn S into a palindrome by repeating the operation of swapping two adjacent characters. If it is possible, find the minimum required number of operations.
-----Constraints-----
 - 1 \leq |S| \leq 2 × 10^5
 - S consists of lowercase English letters.
-----Input-----
Input is given from Standard Input in the following format:
S

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2296 。 https://huggingface.co/datasets/codeparrot/apps

追加例 9 ：隣接交換と回文（原文 2/2 ）

原文

-----Output-----
If we cannot turn S into a palindrome, print -1. Otherwise, print the minimum required number of operations.
-----Sample Input-----
eel
-----Sample Output-----
1
We can turn S into a palindrome by the following operation:
 - Swap the 2-nd and 3-rd characters. S is now ele.
Tests (excerpt): {"inputs":["eel\n","ataatmma\n"],"outputs":["1\n","4\n"]}

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2296 。 https://huggingface.co/datasets/codeparrot/apps

追加例９：隣接交換と回文（日本語訳 1/2）

日本語訳

英小文字からなる文字列 S が与えられる。
隣り合う 2 文字の交換を繰り返して S を回文にできるか判定する。可能なら、必要な操作回数の最小値を求める。
制約
1 ≤ |S| ≤ 2×10^5 。
S は英小文字のみで構成される。
入力
標準入力から、次の形式で与えられる。
S

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2296 。 https://huggingface.co/datasets/codeparrot/apps

追加例 9 ：隣接交換と回文（日本語訳 2/2 ）

日本語訳

出力
S を回文にできない場合は -1 を、それ以外の場合は必要な操作回数の最小値を出力する。
入力例
eel
出力例
1
次の操作で S を回文にできる。
2 文字目と 3 文字目を交換すると、 S は ele になる。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2296 。 https://huggingface.co/datasets/codeparrot/apps

追加例 10 ：隣接差の種類（原文 1/3 ）

原文

Permutation p is an ordered set of integers p_1, p_2, ..., p_{n}, consisting of n distinct positive integers not larger than n. We'll denote as n the length of permutation p_1, p_2, ..., p_{n}.
Your task is to find such permutation p of length n, that the group of numbers |p_1 - p_2|, |p_2 - p_3|, ..., |p_{n} - 1 - p_{n}| has exactly k distinct elements.
-----Input-----
The single line of the input contains two space-separated positive integers n, k (1 ≤ k < n ≤ 10^5).

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2099 。 https://huggingface.co/datasets/codeparrot/apps

追加例 10 ：隣接差の種類（原文 2/3 ）

原文

-----Output-----
Print n integers forming the permutation. If there are multiple answers, print any of them.
-----Examples-----
Input
3 2
Output
1 3 2
Input
3 1
Output
1 2 3

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2099 。 https://huggingface.co/datasets/codeparrot/apps

追加例 10 ：隣接差の種類（原文 3/3 ）

原文

Input
5 2
Output
1 3 2 4 5
-----Note-----
By |x| we denote the absolute value of number x.
Tests (excerpt): {"inputs":["3 2\n","3 1\n"],"outputs":["1 3 2\n","1 2 3\n"]}

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2099 。 https://huggingface.co/datasets/codeparrot/apps

追加例 10 ：隣接差の種類（日本語訳 1/3 ）

日本語訳

長さ n の順列 p とは、 n 以下の相異なる正の整数 n 個を並べた p_1, p_2, ..., p_n である。
|p_1 − p_2|, |p_2 − p_3|, ..., |p_(n−1) − p_n| に、異なる値がちょうど k 個含まれるような長さ n の順列を求める。
入力
1 行に、空白で区切られた正の整数 n 、 k が与えられる（ 1 ≤ k < n ≤ 10^5 ）。
出力
順列を構成する n 個の整数を出力する。複数の答えがある場合は、いずれを出力してもよい。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2099 。 https://huggingface.co/datasets/codeparrot/apps

追加例 10 ：隣接差の種類（日本語訳 2/3 ）

日本語訳

例
入力
3 2
出力
1 3 2
入力
3 1
出力
1 2 3

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2099 。 https://huggingface.co/datasets/codeparrot/apps

追加例 10 ：隣接差の種類（日本語訳 3/3 ）

日本語訳

入力
5 2
出力
1 3 2 4 5
注
|x| は数 x の絶対値を表す。
配布テストの抜粋： inputs は引数列または標準入力、 outputs は対応する配布期待値。先頭 2 件までを掲載。
配布表記の補足：原文末尾の式は配布表記のまま。訳では隣接する 2 項の差を示す。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 train / problem_id 2099 。 https://huggingface.co/datasets/codeparrot/apps

集計と評価条件

train のテスト情報を実測した

項目	問題数
全問題	5,000
input_output あり	4,805
うち関数呼出形式	3,063

input_output の有無と fn_name で判別。

[1] APPS 、 train 全 5,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/codeparrot/apps

配布されたテスト情報を読む

```
import json
record = dataset[0]
tests = json.loads(record["input_output"])
print(tests.get("fn_name"))
print(tests["inputs"][0])
print(tests["outputs"][0])
```

関数名の有無から入出力形式を確認し、入力と期待値の対応を読む。

[1] codeparrot/apps 、改訂 21e74ddf 。 2026-10-18 参照。 https://huggingface.co/datasets/codeparrot/apps

研究と参考文献

研究者と発表の位置付け

- 第一著者 Dan Hendrycks と Steven Basart は等しく貢献したと記載されている。最終著者は Jacob Steinhardt 。
- UC Berkeley 、 UChicago 、 Cornell などの共同研究で、NeurIPS Datasets and Benchmarks 2021 で発表した。

[1] Dan Hendrycks et al. (2021). Measuring Coding Challenge Competence With APPS. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2105.09938

参考文献

Measuring Coding Challenge Competence With APPS

Dan Hendrycks, Steven Basart, Saurav Kadavath, Mantas Mazeika, Akul Arora, Ethan Guo, Collin Burns, Samir Puranik, Horace He, Dawn Song, Jacob Steinhardt / NeurIPS Datasets and Benchmarks 2021

APPS の目的、作成方法、評価をまとめた研究。

https://arxiv.org/abs/2105.09938

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

APPS ：公開データ

codeparrot/apps / 改訂 21e74ddf / 2026-10-18 参照

原文・正解の 13 例と、対象集合の全件集計に用いた公開資源。

https://huggingface.co/datasets/codeparrot/apps