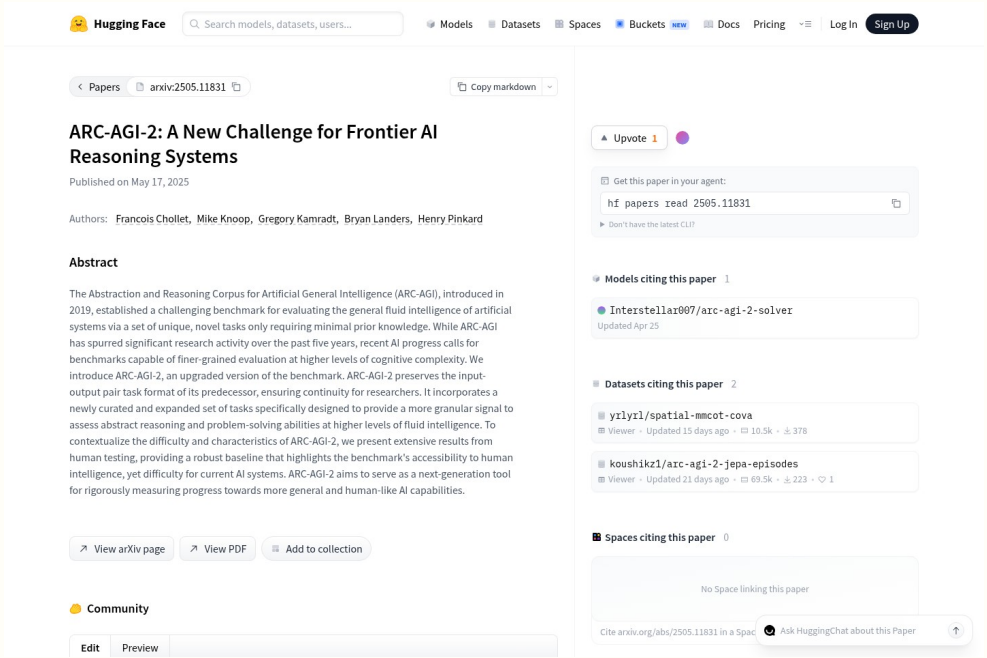
ARC-AGI-2

少数の格子の例から規則を見つけ、出力をつくる
抽象推論を評価するデータセット

sasakiy84

ARC-AGI-2 の論文紹介ページ



Chollet et al. ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. Hugging Face Papers 掲載ページ。 https://huggingface.co/papers/2505.11831

1. 格子の変換規則と実例

2. 完全一致の採点とモデル評価

3. 課題の作成方法と構成

4. 系列の発展と入手方法

1. 格子の変換規則と実例

少数の入出力例から、新しい出力をつくる

- ARC-AGI-2 は、色付きの格子に表された物体・数・形・位置関係を使う推論課題の集合である。
- 各課題でいくつかの入力と出力の例を見て、共通する変換規則を見つける。テスト入力には、その規則を適用して出力をつくる。
- 出力では、格子の縦横の大きさと、全セルの色を決める。格子は最大 30×30 、色は 0 ～ 9 の 10 種類。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

実例は公開評価 120 課題から選ぶ

- 本編では、凡例による色の置換、図形の拡大と配置、穴の数による色分けの 3 課題を紹介する。
- 実例は公開評価集合の 13 課題。各課題の提示例 1 組と、テスト入力 1 個・その正解を示す。
- Appendix では、条件に応じた移動、経路の復元、周期の延長など、異なる規則の 10 課題を追加する。

ARC Prize Foundation. Abstraction and Reasoning Corpus for Artificial General Intelligence v2. 2026-10-16 参照。 https://github.com/arcprize/ARC-AGI-2

1 課題の JSON に提示例とテストをまとめる

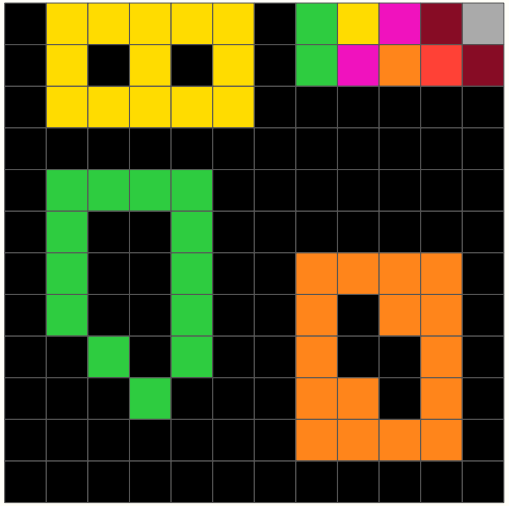
フィールド	内容と役割
train	規則を推定するための入力・出力の提示例
test の input	解くべき新しい入力
test の output	採点に使う正解の出力

公開 JSON には正解も含む。出題時は提示例とテスト入力を渡す。

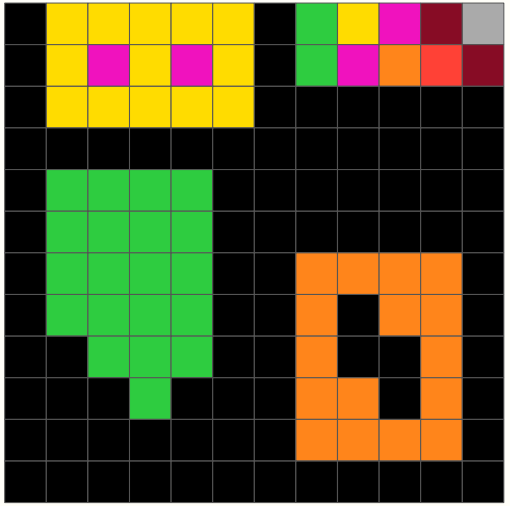
ARC Prize Foundation. Abstraction and Reasoning Corpus for Artificial General Intelligence v2. 2026-10-16 参照。 https://github.com/arcprize/ARC-AGI-2

実例 1 ：凡例で穴を塗る色を決める

提示例 1 の入力



対応する出力

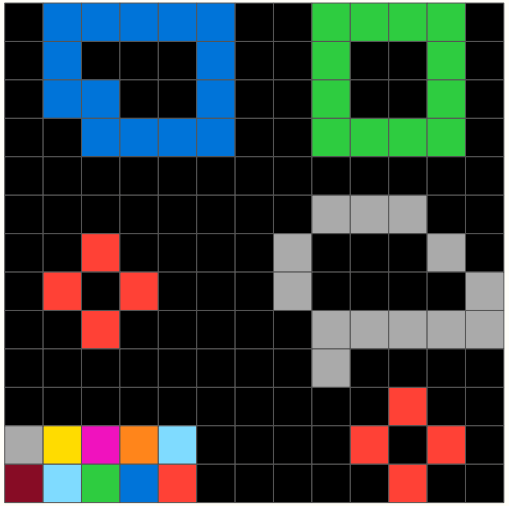


提示例は全 3 組、テスト入力は全 1 個。ここでは各 1 番目を表示。

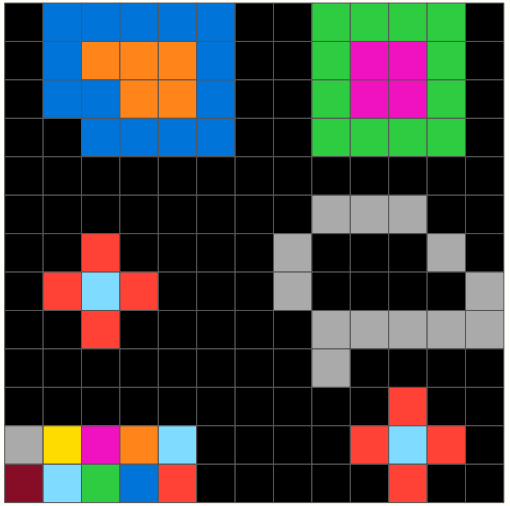
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: dbff022c. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/dbff022c.json

実例 1 ：凡例で穴を塗る色を決める

テスト入力 1



配布データの正解

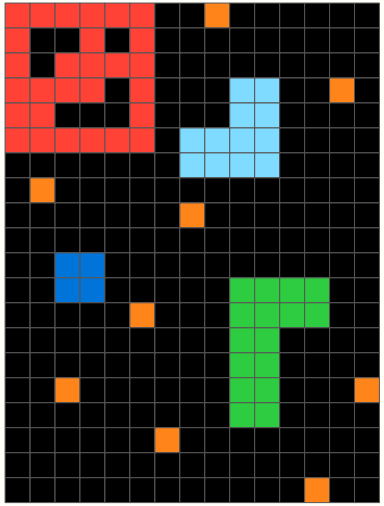


小さな凡例の色の対応を読み、各物体の内側を対応する色で埋める。

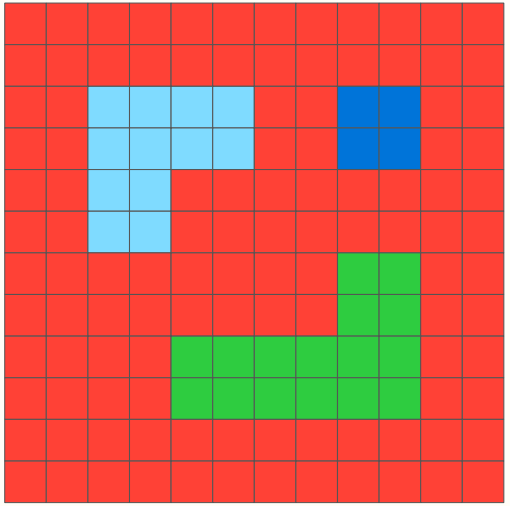
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: dbff022c. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/dbff022c.json

実例２：切り取り・拡大・配置

提示例１の入力



対応する出力

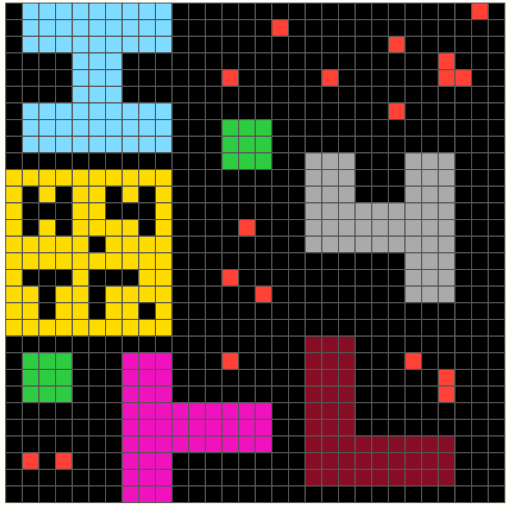


提示例は全２組、テスト入力は全１個。ここでは各１番目を表示。

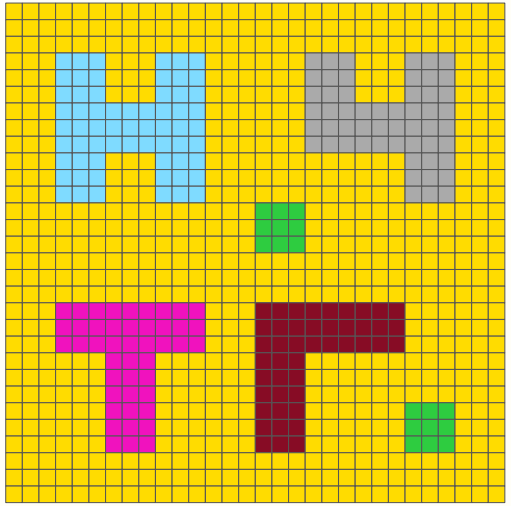
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 898e7135. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/898e7135.json

実例２：切り取り・拡大・配置

テスト入力１



配布データの正解

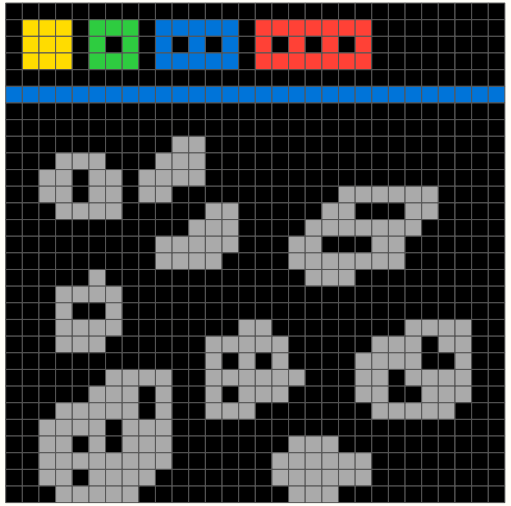


枠内を切り取り、同じ形の穴に合う倍率で図形を拡大して配置する。

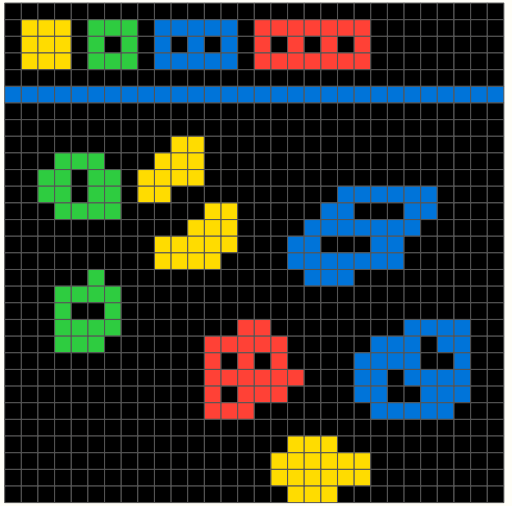
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 898e7135. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/898e7135.json

実例３：穴の数から色を割り当てる

提示例１の入力



対応する出力

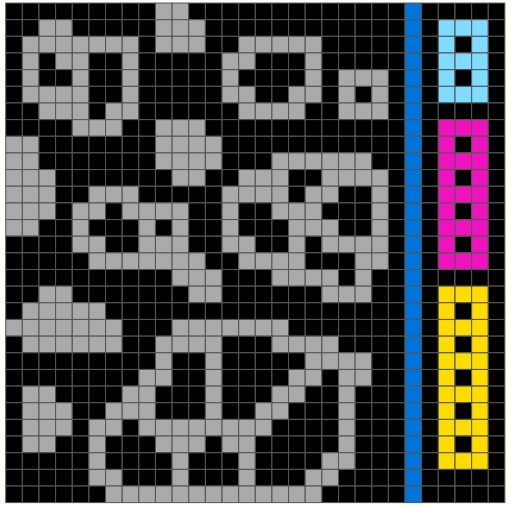


提示例は全２組、テスト入力は全２個。ここでは各１番目を表示。

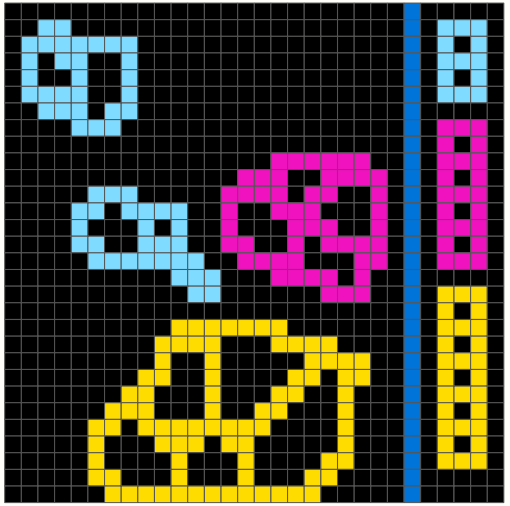
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: e3721c99. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/e3721c99.json

実例３：穴の数から色を割り当てる

テスト入力１



配布データの正解



凡例と穴の数を対応させ、各物体を対応する色で塗る。

ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: e3721c99. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/e3721c99.json

2. 完全一致の採点とモデル評価

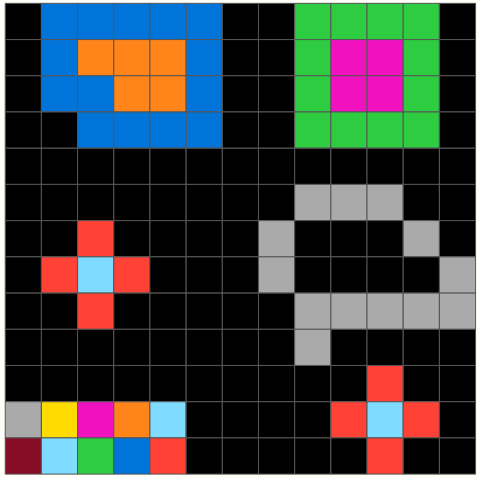
格子全体が一致した出力を正解とする

- 各テスト入力に対して、出力候補を 2 つ提出できる。一方が正解と完全に一致すれば、そのテスト入力を正解とする。
- 比較するのは格子の縦横と全セルの値である。色の意味や変換の説明文を提出する形式ではなく、出力の格子そのものを採点する。
- 公式評価実装は、テスト入力ごとの正誤を課題内で平均し、その課題ごとの得点をさらに平均する。

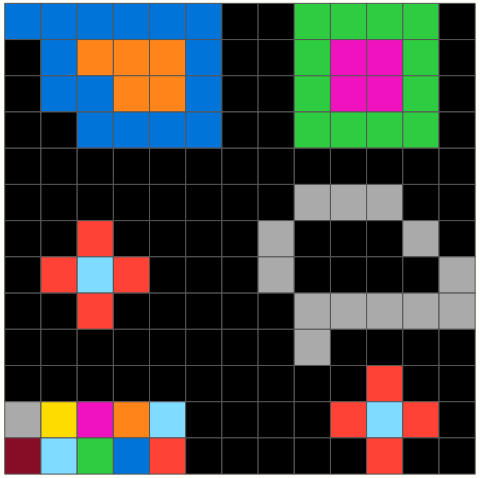
ARC Prize Foundation. ARCScorer.score_task / score_submission. 公式採点実装。改訂 9e2828f 。
https://github.com/arcprize/arc-agi-benchmarking/blob/9e2828f/src/arc_agi_benchmarking/scoring/scoring.py

採点例：１セルの違いも不一致になる

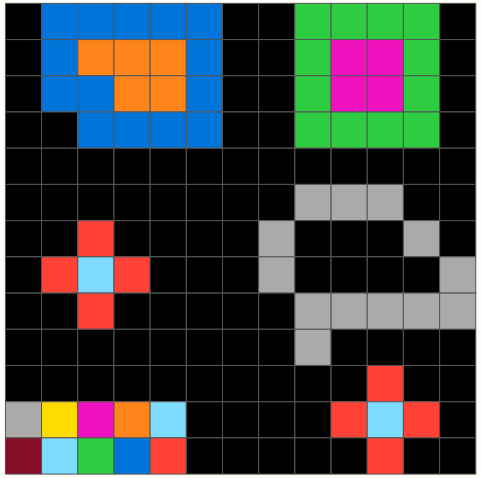
正解の格子



提出候補 A ：不一致



提出候補 B ：一致



候補 B が一致するので、このテスト入力は正解。

ARC Prize Foundation. ARCScorer.score_task / score_submission. 公式採点実装。改訂 9e2828f 。 採点例は公開評価 dbff022c のテスト入力 1 を使用。
https://github.com/arcprize/arc-agi-benchmarking/blob/9e2828f/src/arc_agi_benchmarking/scoring/scoring.py

採点例：課題内で平均し、課題間で平均する

課題	テスト入力ごとの正誤	課題の得点
A	2 個中 1 個が正解	0.5
B	1 個中 1 個が正解	1.0

全体の得点 = (0.5 + 1.0) ÷ 2 = 0.75 → 75% 。

ARC Prize Foundation. ARCScorer.score_task / score_submission. 公式採点実装。改訂 9e2828f 。
https://github.com/arcprize/arc-agi-benchmarking/blob/9e2828f/src/arc_agi_benchmarking/scoring/scoring.py

登場時は ARC-AGI-1 から得点が下がった

手法／推論設定	ARC-AGI-1	ARC-AGI-2
o3 / Medium	53.0%	3.0%
o4-mini / Medium	41.8%	2.4%
Claude 3.7 / 8K	21.2%	0.9%
ARChitects / 2024 年大会	56.0%	2.5%

Chollet らの Semi-Private 評価。 2025-05-14 時点。
Medium と 8K は推論設定、 8K は思考用トークンの予算。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

現行モデルの公式比較にも使われている

モデル／推論設定	ARC-AGI-2
Gemini 3.1 Pro / High	77.1%
Claude Opus 4.6 / Max	68.8%
GPT-5.2 / xhigh	52.9%

Google DeepMind の公式表、 ARC Prize Verified 欄。
High ・ Max ・ xhigh は各モデルの推論設定。

Google DeepMind (2026). Gemini 3.1 Pro. Performance: ARC-AGI-2 / ARC Prize Verified. 2026-10-16 参照。 https://deepmind.google/models/gemini/pro/

複数の規則や、条件による使い分けを問う

設計の特徴	課題で行うこと
複数の規則	切り取り、拡大、配置を組み合わせる
複数段階	前の配置に合わせて次の物体を置く
条件に応じた適用	枠の色に応じて移動先を変える
その場で定まる記号	凡例から穴の数と色の対応を読む

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

3. 課題の作成方法と構成

ARC-AGI-1 の到達水準に合わせて更新した

- ARC は Chollet が 2019 年に提案した。対象は、少ない経験から新しい課題に適応する能力である。
- ARC-AGI-2 は 2021 年末から開発を始めた。単純なプログラム探索で解ける問題を減らし、複数の概念を組み合わせる課題を増やした。
- 入力と出力の格子という形式を保ち、人による解きやすさを測定して評価集合を構成した。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

407 人が候補課題を解く実験を行った

- 候補は ARC Prize Foundation のスタッフ・協力者による新作と、以前の版で未使用だった課題から集めた。
- 2024 年 11 月〜 2025 年 5 月に 3 回のテストを行った。参加者は会議室の PC で、使い方の説明後、ランダムに割り当てられた課題を解いた。
- 407 人・ 515 回の参加セッションで、採用前の候補も含む 1,848 種類のテスト入力を試した。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

人による解答と重複の確認で課題を選んだ

- 最初の 2 回以内に少なくとも一つのテスト入力を解いた人が、独立に 2 人以上いる課題を次の選考へ進めた。
- 同じプログラムで解けそうな課題を比較画面で探し、複数人のレビューで重複を整理した。
- 評価集合は全課題を少なくとも 2 人が解けることを確認。さらに内部レビューを加え、格子の不整合も修正した。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

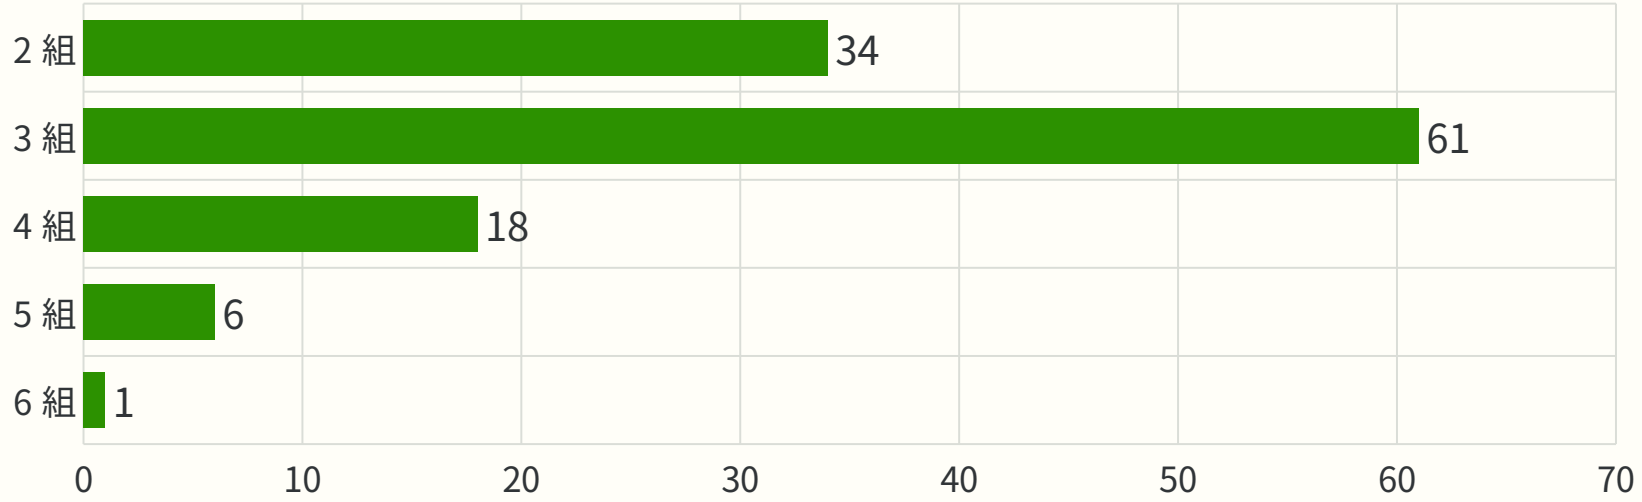
公開・非公開を合わせて 1,360 課題

集合	課題数	用途
Public Training	1,000	学習・基本概念の提示
Public Evaluation	120	公開の評価・研究
Semi-Private Evaluation	120	外部 API モデルの検証
Private Evaluation	120	大会で解法を独立実行

評価 3 集合は、人の平均正解率の差を 1 ポイント以内にそろえた。

ARC Prize Foundation. Abstraction and Reasoning Corpus for Artificial General Intelligence v2. 2026-10-16 参照。 https://github.com/arcprize/ARC-AGI-2

公開評価では、提示例 3 組の課題が 61 件



課題内の train 配列の長さを集計。横軸は課題数、全 120 課題。

ARC Prize Foundation. ARC-AGI-2: 公開評価 120 課題の JSON を集計。改訂 f3283f7 、 2026-10-16 。 https://github.com/arcprize/ARC-AGI-2/tree/f3283f7/data/evaluation

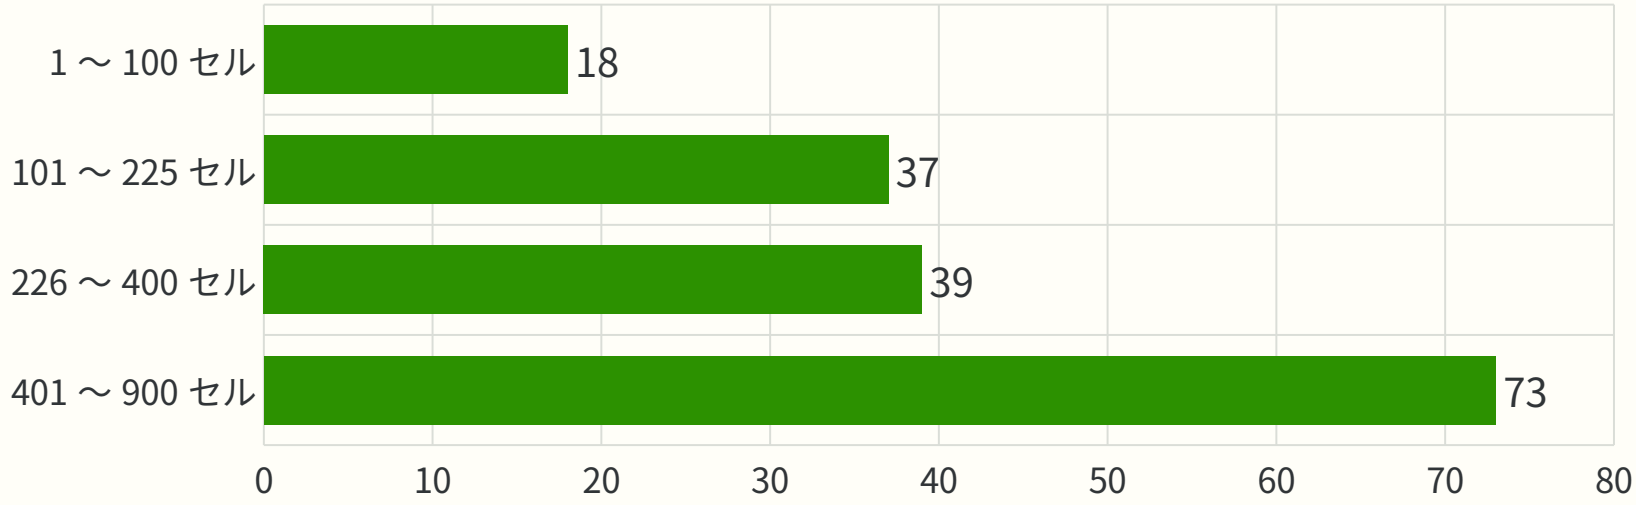
公開評価のテスト入力は合計 167 個

1 課題のテスト入力数	該当する課題数
1 個	75
2 個	43
3 個	2

75 × 1 + 43 × 2 + 2 × 3 = 167 個。
各課題の test 配列の長さを集計した。

ARC Prize Foundation. ARC-AGI-2: 公開評価 120 課題の JSON を集計。改訂 f3283f7 、 2026-10-16 。 https://github.com/arcprize/ARC-AGI-2/tree/f3283f7/data/evaluation

出力は大きな格子まで含む



公開評価 167 個の正解出力。横軸は出力格子の個数。

ARC Prize Foundation. ARC-AGI-2: 公開評価 120 課題の JSON を集計。改訂 f3283f7 、 2026-10-16 。 https://github.com/arcprize/ARC-AGI-2/tree/f3283f7/data/evaluation

出力の縦横の大きさも推定する

テスト入力と正解出力の縦横	テスト入力数
同じ大きさ	119
異なる大きさ	48

公開評価 167 個について、入力と出力の行数・列数を比較。

ARC Prize Foundation. ARC-AGI-2: 公開評価 120 課題の JSON を集計。改訂 f3283f7 、 2026-10-16 。 https://github.com/arcprize/ARC-AGI-2/tree/f3283f7/data/evaluation

4. 系列の発展と入手方法

ARC-AGI-1 と 2 は格子の変換形式を共有する

系列・初公開年	公開データと変更
ARC-AGI-1 / 2019	学習 400 、評価 400 課題。格子の変換形式を導入
ARC-AGI-2 / 2025	学習 1,000 、評価 120 課題。規則の組合せと人による難度調整を強化

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

ARC-AGI-3 は環境を操作する課題へ進んだ

- ARC-AGI-3 では、エージェントが画面を観察し、行動を選び、変化した画面から環境の規則と目標を探る。
- 公式 Toolkit では、環境を作り、利用できる行動を調べ、行動を送ると新しい観測が返る。ゲームの進行と達成状況を記録する。
- ARC-AGI-2 の入出力例から格子を完成させる評価から、操作と観測を繰り返す対話的な評価へ対象が広がった。

ARC Prize Foundation (2026 参照). ARC-AGI Toolkit: ARC-AGI-3 interactive environments. https://github.com/arcprize/ARC-AGI

公開後に提示例や正解の不整合を修正した

日付	変更内容
2025-03-24	ARC-AGI-2 の 1,360 課題を公開
2025-04-14	公開評価のセル誤差や曖昧さを修正
2025-04-17	d8e07eb2 の提示例 1 組を更新

本資料の実例と集計は、公開リポジトリの改訂 f3283f7 に対応する。

ARC Prize Foundation. ARC Dataset v2 Changelog. 2025 年 3 〜 4 月の公開・修正。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/changelog.md

JSON を読み、提示例とテスト入力を取り出す

```
import json
from pathlib import Path

p = Path("data/evaluation/dbff022c.json")
task = json.loads(p.read_text())
example = task["train"][0]
test_input = task["test"][0]["input"]
```

配布リポジトリの data/evaluation 内に、課題ごとの JSON がある。

ARC Prize Foundation. Abstraction and Reasoning Corpus for Artificial General Intelligence v2. 2026-10-16 参照。 https://github.com/arcprize/ARC-AGI-2

公開データと評価コードを入手できる

- 公式 GitHub に学習 1,000 課題と公開評価 120 課題を置き、 Apache License 2.0 で配布する。
- arc-agi-benchmarking では、複数のモデルへの出題、出力候補の保存、採点、費用の集計を行える。
- 評価結果には、データ改訂、評価集合、候補数、モデルと推論設定を対応させる。

ARC Prize Foundation. Testing systems with ARC-AGI. 公式評価コード。 2026-10-16 参照。 https://github.com/arcprize/arc-agi-benchmarking

少ない例から、規則を組み合わせて適用する

- ARC-AGI-2 は、格子の入出力例から規則を見つけ、出力の大きさと全セルの色を作る推論課題である。
- 複数の規則、段階的な処理、条件による適用、その場で決まる記号の意味を扱う。
- 人による解答と難度の調整を経た公開・非公開の評価集合を持ち、現行モデルの公式評価にも使われている。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

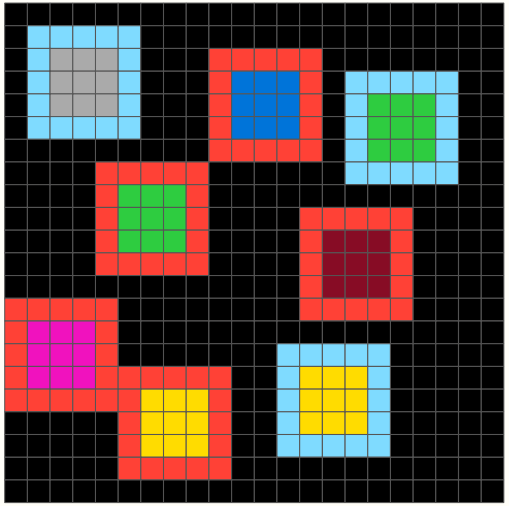
Appendix

1. 規則の異なる追加例
2. 公開データと採点の詳細
3. 著者と参考文献

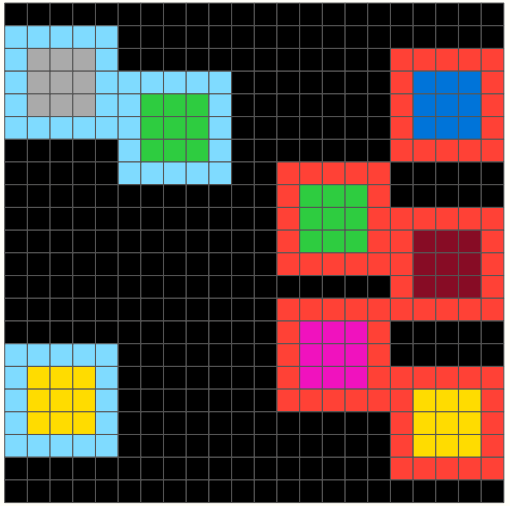
1. 規則の異なる追加例

追加例 1 ：枠の色に応じて物体を移動する

提示例 1 の入力



対応する出力

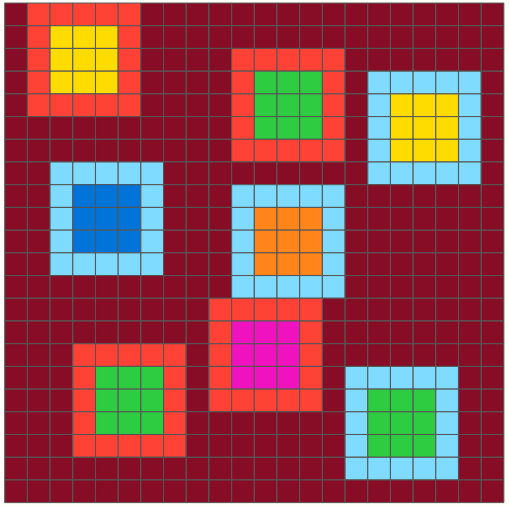


提示例は全 3 組、テスト入力は全 1 個。ここでは各 1 番目を表示。

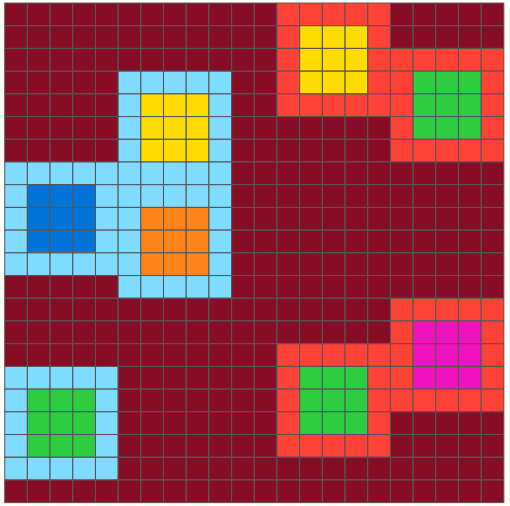
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: b5ca7ac4. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/b5ca7ac4.json

追加例１：枠の色に応じて物体を移動する

テスト入力１



配布データの正解

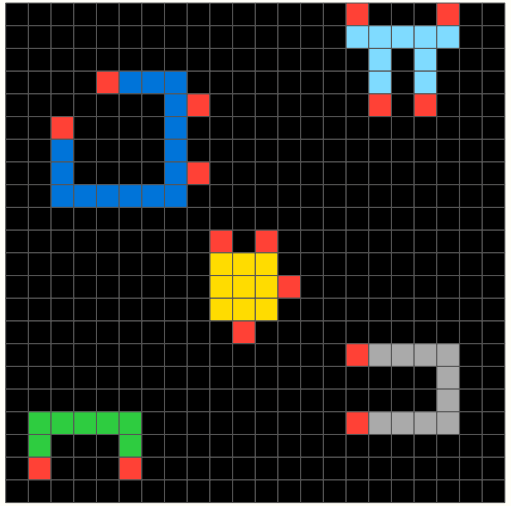


外枠の色を条件に、物体を左側と右側へ分けて並べる。

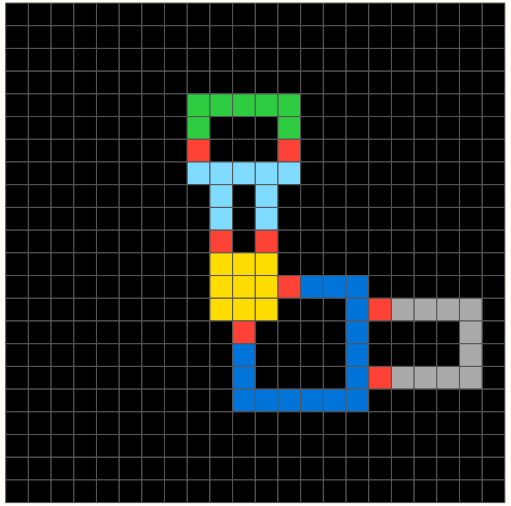
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: b5ca7ac4. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/b5ca7ac4.json

追加例 2 ：印の位置に合わせて物体をつなぐ

提示例 1 の入力



対応する出力

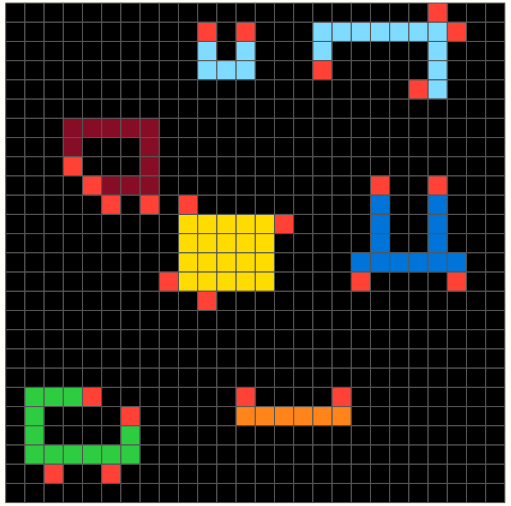


提示例は全 2 組、テスト入力は全 2 個。ここでは各 1 番目を表示。

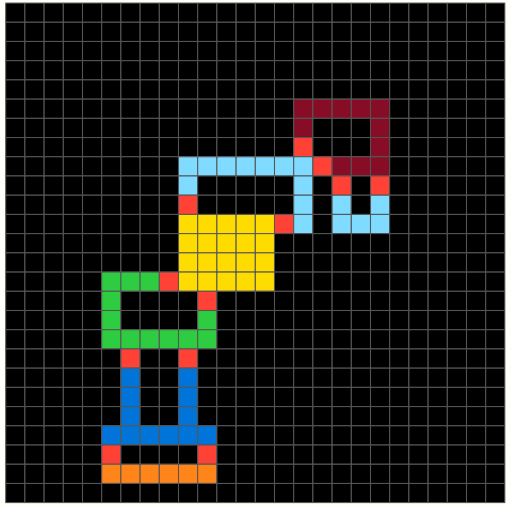
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: cbebaa4b. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/cbebaa4b.json

追加例２：印の位置に合わせて物体をつなぐ

テスト入力１



配布データの正解

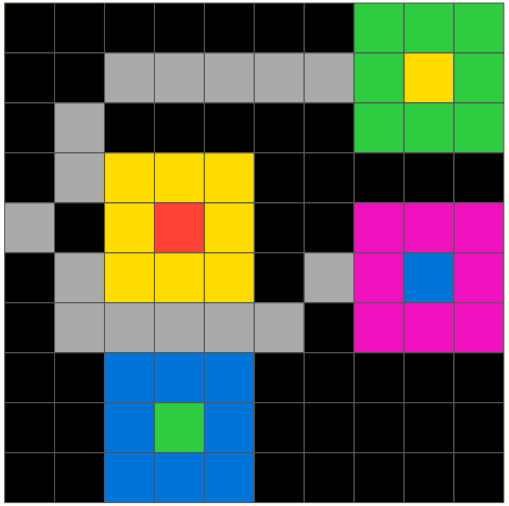


接続する印を合わせ、前に置いた物体の位置に応じて次を配置する。

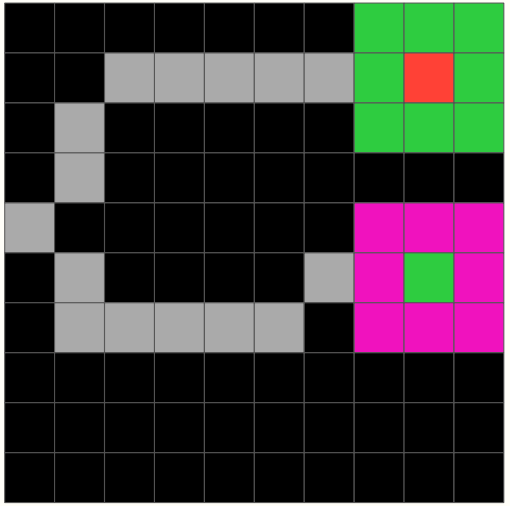
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: cbebaa4b. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/cbebaa4b.json

追加例３：経路で物体を対応させる

提示例１の入力



対応する出力

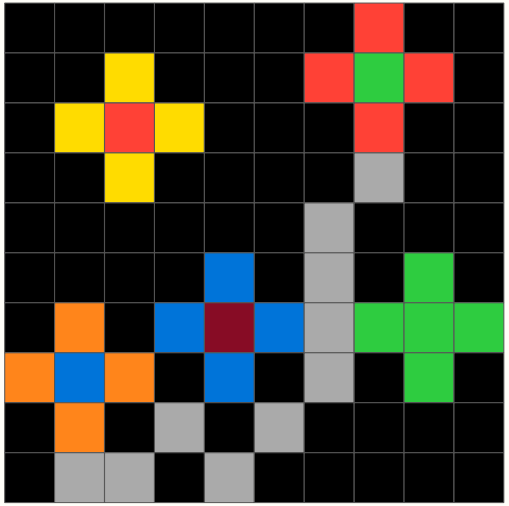


提示例は全３組、テスト入力は全３個。ここでは各１番目を表示。

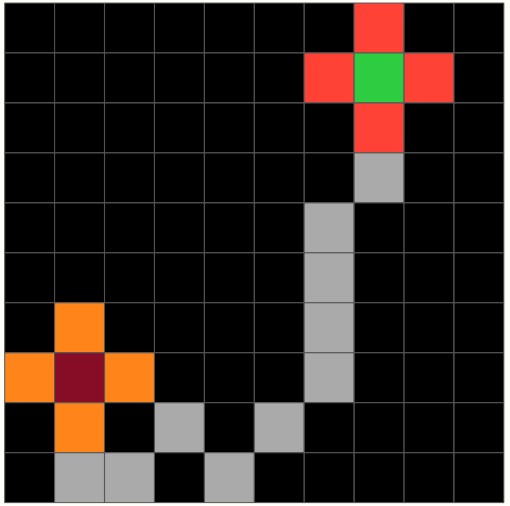
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: d35bdbdc. f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/d35bdbdc.json

追加例３：経路で物体を対応させる

テスト入力１



配布データの正解

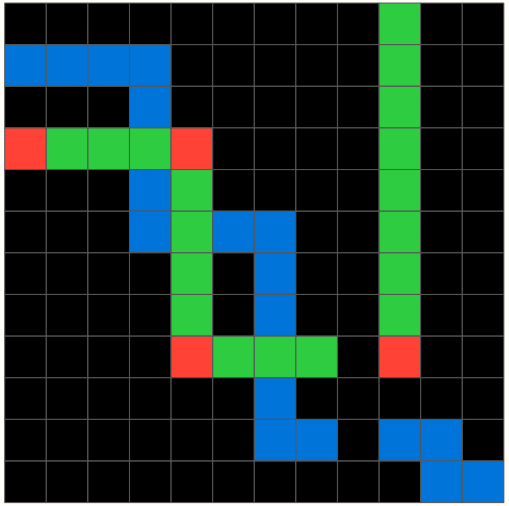


灰色の経路に沿う物体の対応を読み、残す物体の中心の色を更新する。

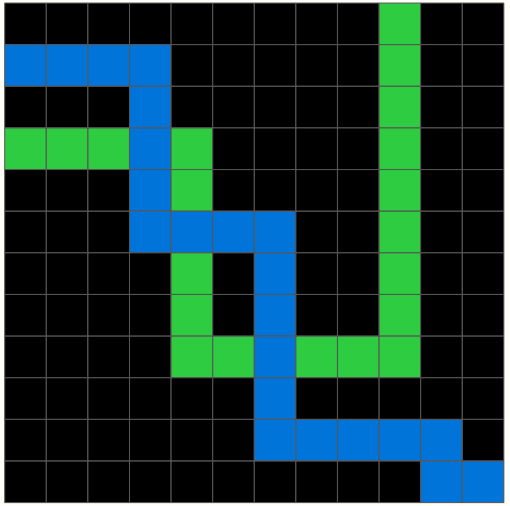
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: d35bdbdc. f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/d35bdbdc.json

追加例 4 ：切れた経路を復元する

提示例 1 の入力



対応する出力

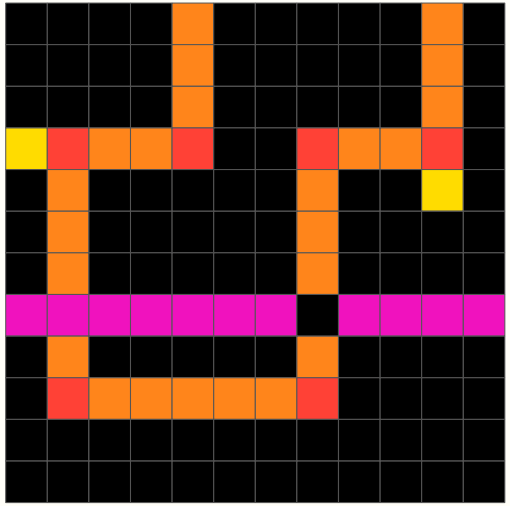


提示例は全 4 組、テスト入力は全 1 個。ここでは各 1 番目を表示。

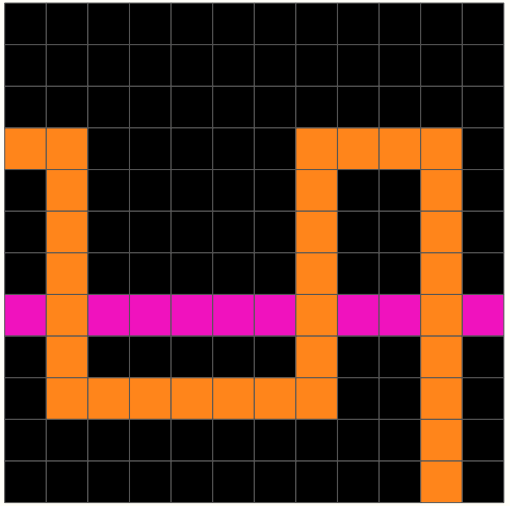
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: faa9f03d. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/faa9f03d.json

追加例 4 ：切れた経路を復元する

テスト入力 1



配布データの正解

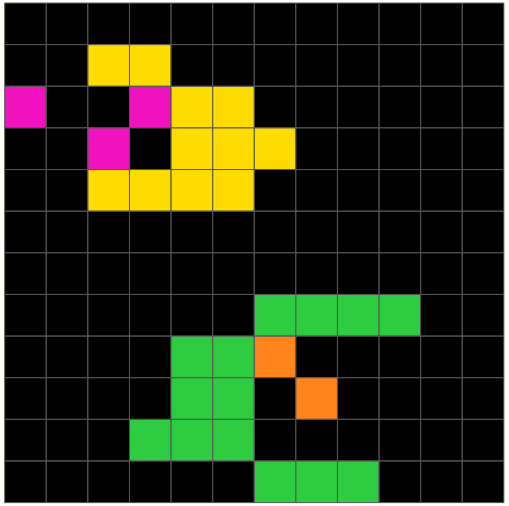


同じ色の経路をつなぎ、曲がり角の印を経路の色へ置き換える。

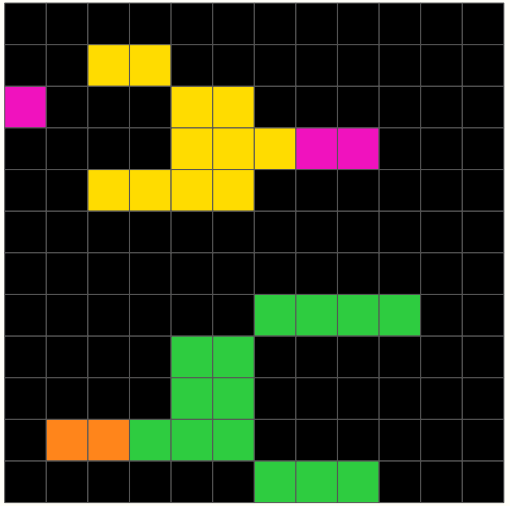
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: faa9f03d. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/faa9f03d.json

追加例 5 ：矢印の中のセルを外側の線に変える

提示例 1 の入力



対応する出力

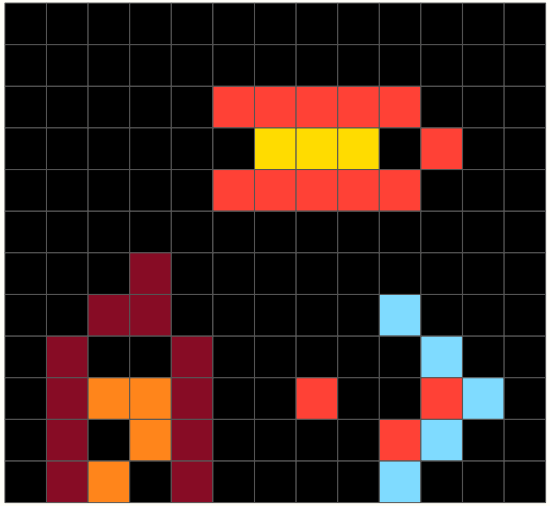


提示例は全 3 組、テスト入力は全 1 個。ここでは各 1 番目を表示。

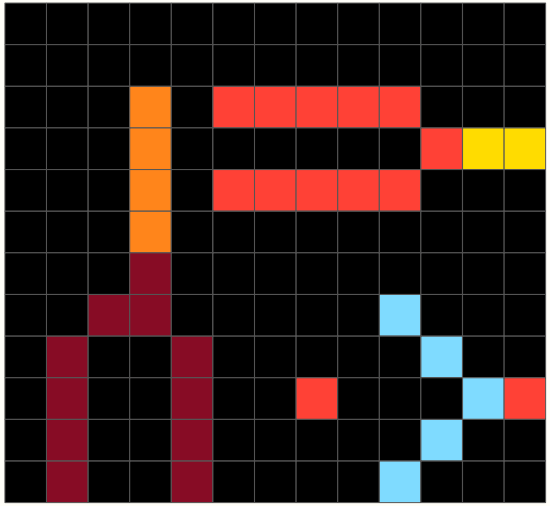
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 3dc255db. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/3dc255db.json

追加例 5 ：矢印の中のセルを外側の線に変える

テスト入力 1



配布データの正解

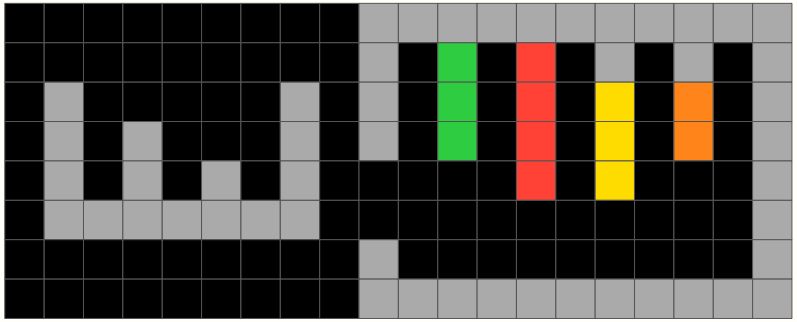


矢印の内側にある色付きセルを数え、その色の線を矢印の向きへ伸ばす。

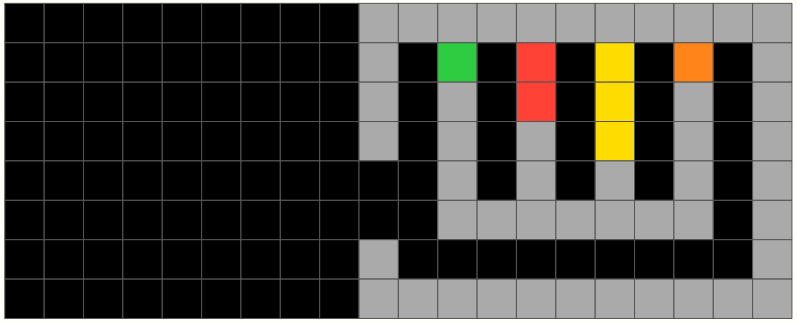
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 3dc255db. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/3dc255db.json

追加例 6 ：棒の高さを別の領域へ適用する

提示例 1 の入力



対応する出力

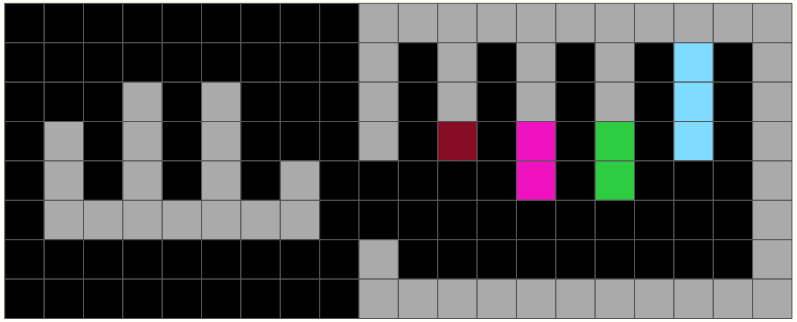


提示例は全 2 組、テスト入力は全 2 個。ここでは各 1 番目を表示。

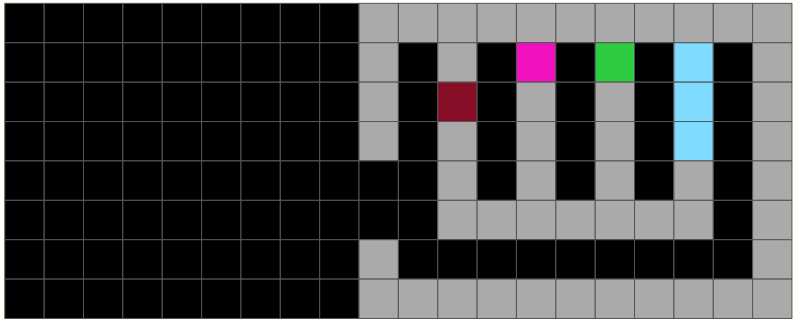
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 4c3d4a41. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/4c3d4a41.json

追加例 6 ：棒の高さを別の領域へ適用する

テスト入力 1



配布データの正解

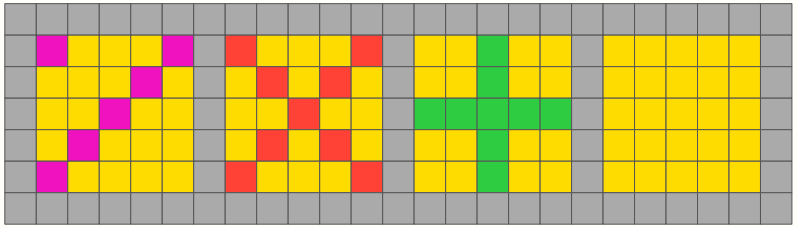


左の灰色の棒の形を読み、右側の色付きの棒と灰色の部分へ対応させる。

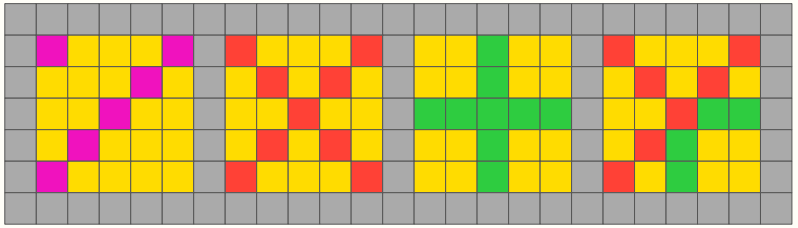
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 4c3d4a41. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/4c3d4a41.json

追加例 7 ：重ねた模様から見える部分をつくる

提示例 1 の入力



対応する出力

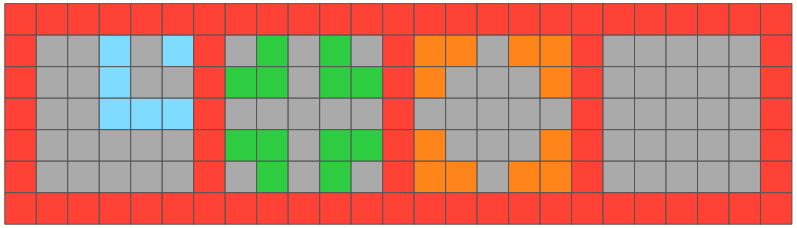


提示例は全 4 組、テスト入力は全 1 個。ここでは各 1 番目を表示。

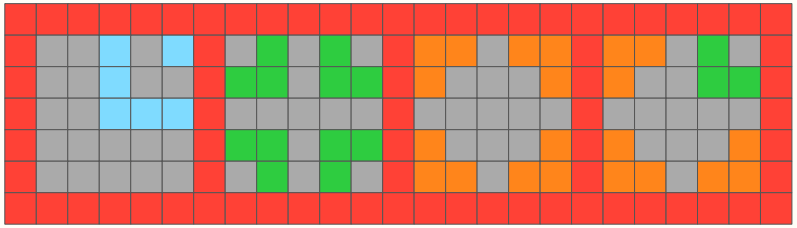
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 7491f3cf. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/7491f3cf.json

追加例 7 ：重ねた模様から見える部分をつくる

テスト入力 1



配布データの正解

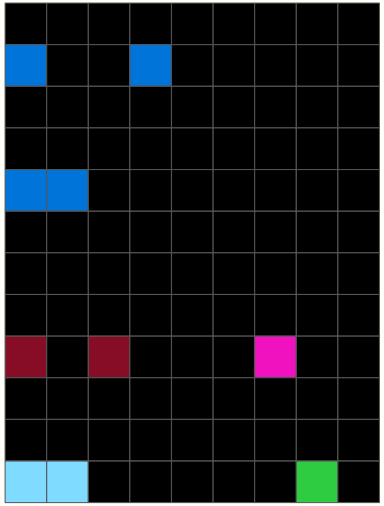


左の 3 枚の模様を順に重ね、後の模様が前の色を覆う結果を右端へ描く。

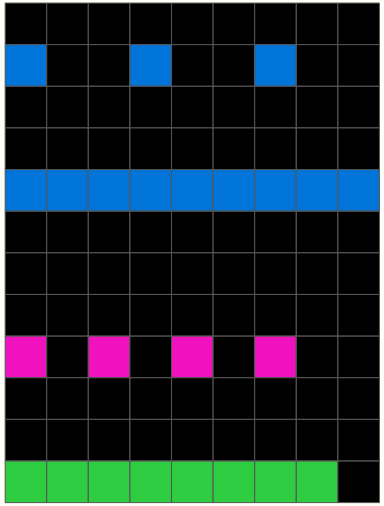
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 7491f3cf. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/7491f3cf.json

追加例 8 ：点の間隔で線を延長する

提示例 1 の入力



対応する出力

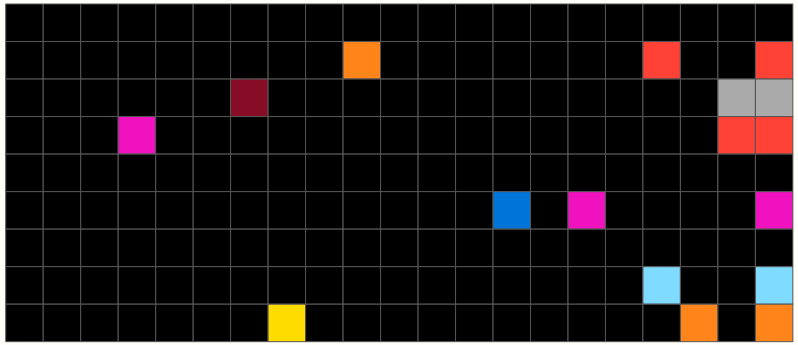


提示例は全 3 組、テスト入力は全 2 個。ここでは各 1 番目を表示。

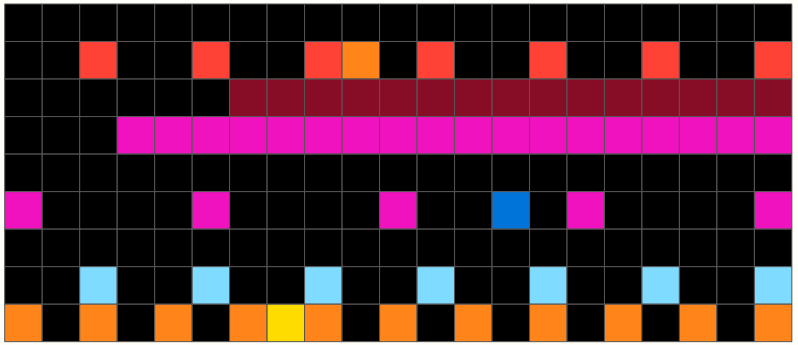
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 16de56c4. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/16de56c4.json

追加例 8 ：点の間隔で線を延長する

テスト入力 1



配布データの正解

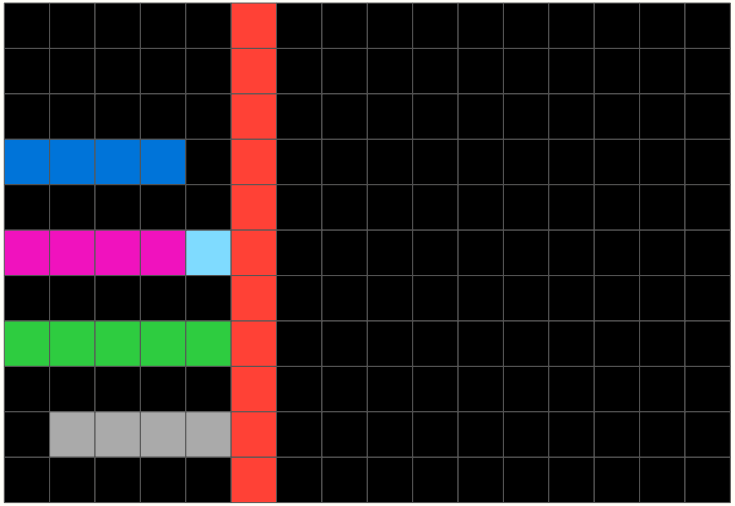


並んだ点や隣接セルを手掛かりに、色と周期を対応させて列や行を埋める。

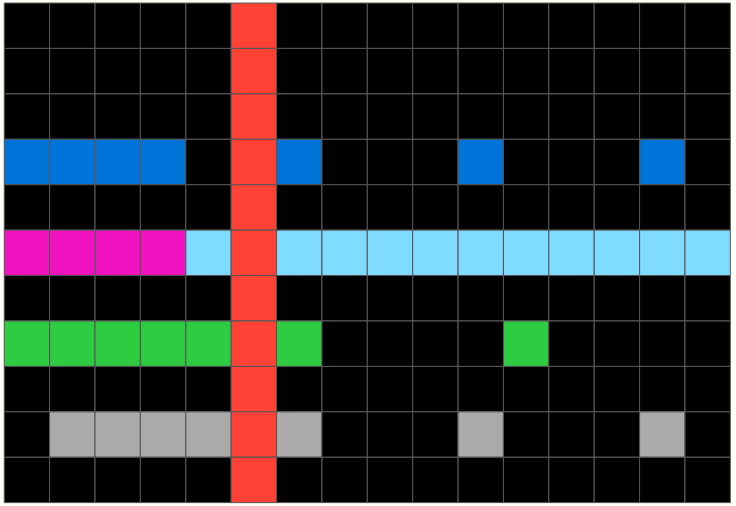
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 16de56c4. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/16de56c4.json

追加例 9 ：境界を越えて周期を続ける

提示例 1 の入力



対応する出力

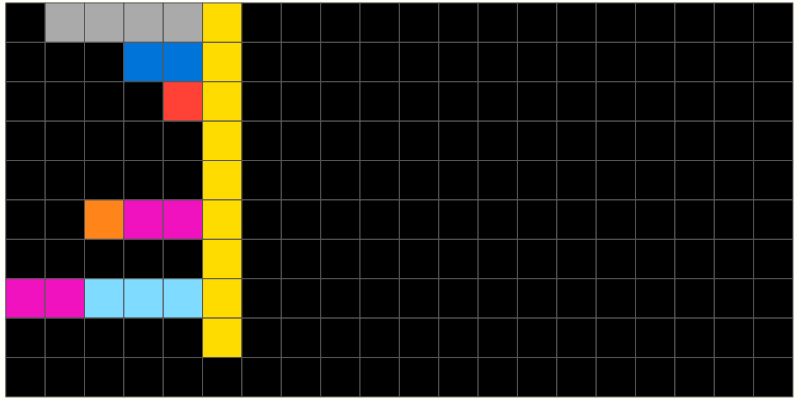


提示例は全 3 組、テスト入力は全 3 個。ここでは各 1 番目を表示。

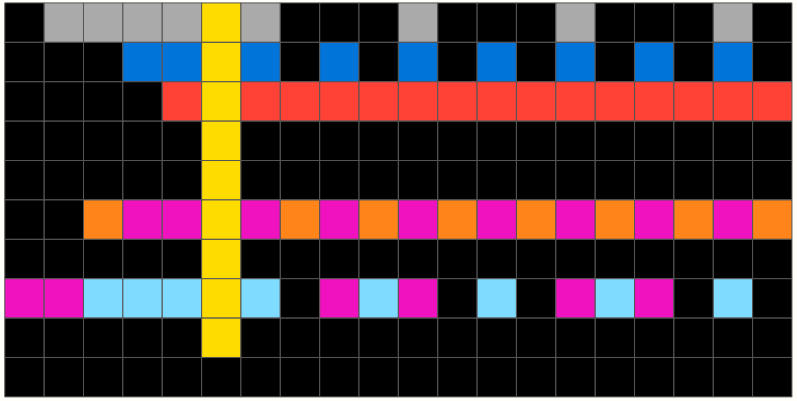
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 1ae2feb7. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/1ae2feb7.json

追加例 9 ：境界を越えて周期を続ける

テスト入力 1



配布データの正解

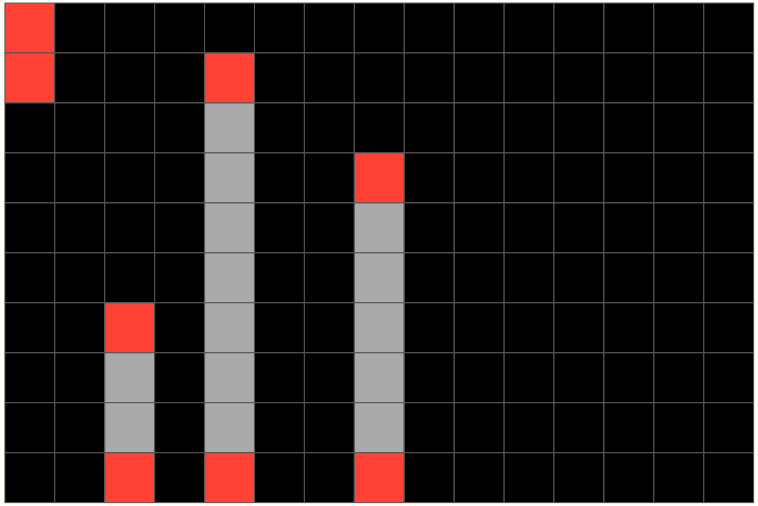


境界の片側にある色列を、同じ周期を使って反対側へ延長する。

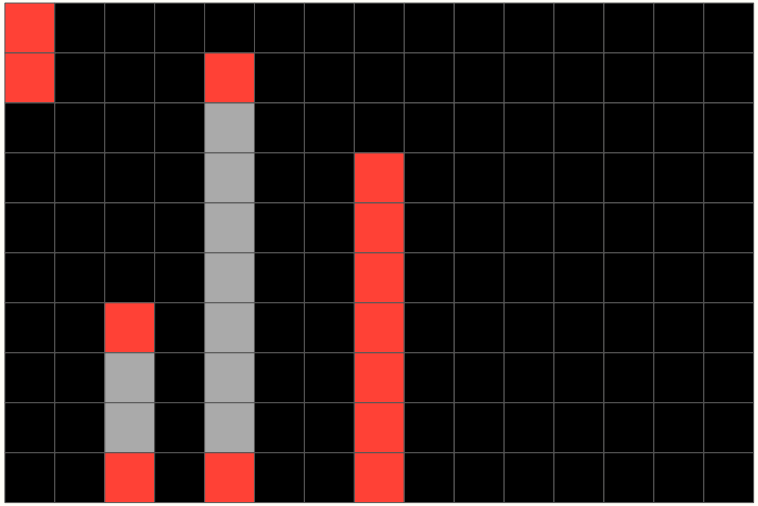
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 1ae2feb7. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/1ae2feb7.json

追加例 10 ：高さの条件に合う棒を塗る

提示例 1 の入力



対応する出力

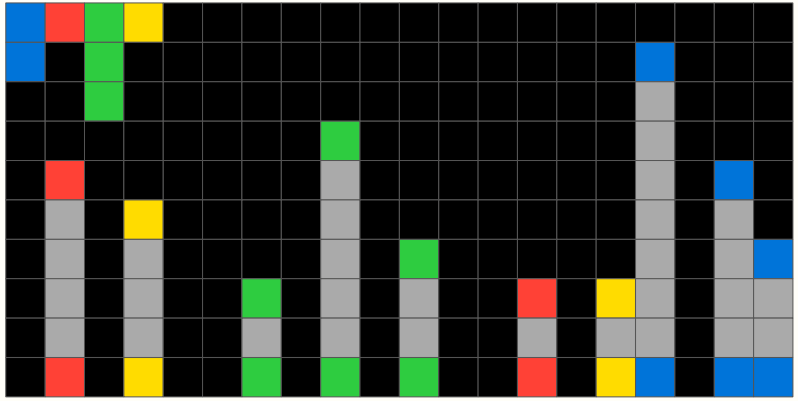


提示例は全 3 組、テスト入力は全 1 個。ここでは各 1 番目を表示。

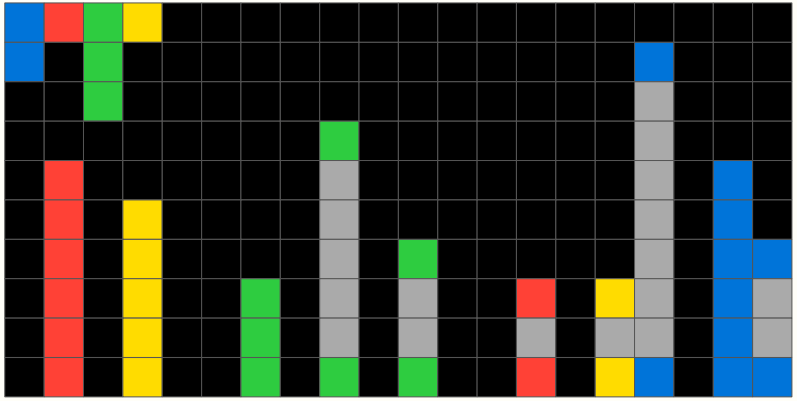
ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 97d7923e. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/97d7923e.json

追加例 10 ：高さの条件に合う棒を塗る

テスト入力 1



配布データの正解



端の色付きセルを手掛かりに、条件に合う高さの棒の内部を同じ色にする。

ARC Prize Foundation. ARC-AGI-2 / Public Evaluation. ID: 97d7923e. 改訂 f3283f7 。 https://github.com/arcprize/ARC-AGI-2/blob/f3283f7/data/evaluation/97d7923e.json

2. 公開データと採点の詳細

学習集合と公開評価集合のレコード数

対象	学習集合	公開評価
課題ファイル	1,000	120
提示例の入出力ペア	3,232	359
テスト入力と正解のペア	1,076	167

両集合の公開 JSON を全件集計。格子は各ペアに入力と出力の 2 枚ある。

ARC Prize Foundation. ARC-AGI-2: 公開学習 1,000 課題・公開評価 120 課題の JSON を全件集計。 2026-10-16 。 https://github.com/arcprize/ARC-AGI-2/tree/f3283f7/data

学習集合の提示例数の分布（前半）

1 課題の提示例数	課題数
2 組	158
3 組	575
4 組	189
5 組	49

ARC Prize Foundation. Abstraction and Reasoning Corpus for Artificial General Intelligence v2. 2026-10-16 参照。 https://github.com/arcprize/ARC-AGI-2

学習集合の提示例数の分布（後半）

1 課題の提示例数	課題数
6 組	18
7 組	8
8 組	2
10 組	1

ARC Prize Foundation. Abstraction and Reasoning Corpus for Artificial General Intelligence v2. 2026-10-16 参照。 https://github.com/arcprize/ARC-AGI-2

実例の正解と候補を完全一致で比較する

```
gold = task["test"][0]["output"]
wrong = [row[:] for row in gold]
wrong[0][0] = (wrong[0][0] + 1) % 10
candidates = [wrong, gold]
correct = any(pred == gold for pred in candidates)
# correct: True
```

正解を複製して 1 セル変えた候補と、正解の候補を比較する採点例。

ARC Prize Foundation. ARCScorer.score_task / score_submission. 公式採点実装。改訂 9e2828f 。
https://github.com/arcprize/arc-agi-benchmarking/blob/9e2828f/src/arc_agi_benchmarking/scoring/scoring.py

公式実装は課題ごとの得点と費用を集計する

- score_task は各テスト入力の候補を正解と比較し、一つでも完全一致すれば 1 点とする。課題の得点は、その平均。
- score_submission は各課題の得点を合計し、採点した課題数で割る。併せて費用、トークン数、処理時間を集計する。
- 公開の評価コードには複数モデルのアダプターがあり、同じ形式で出力と実行条件を保存できる。

ARC Prize Foundation. ARCScorer.score_task / score_submission. 公式採点実装。改訂 9e2828f 。
https://github.com/arcprize/arc-agi-benchmarking/blob/9e2828f/src/arc_agi_benchmarking/scoring/scoring.py

人のテストを使って評価集合の難度を調整する

- 参加者は 90 分のセッションに参加し、課題を解くごとに追加の報酬を得た。各候補の解けた割合を難度の指標とした。
- 評価の 3 集合は人の平均正解率が 1 ポイント以内でそろうよう構成した。新作は優先して非公開集合へ割り当てた。
- 最終採用課題の人によるテスト入力の正解率は 66% 。論文の人による実験で得られた基準値である。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

3. 著者と参考文献

Chollet の ARC を ARC Prize Foundation が発展

- 第一著者の François Chollet は、 2019 年の On the Measure of Intelligence で ARC と評価の考え方を提案した。
- ARC-AGI-2 の共著者は Mike Knoop 、 Gregory Kamradt 、 Bryan Landers 、 Henry Pinkard 。論文は課題設計、人による実験、評価集合を説明する。
- 初公開は 2025 年 3 月。技術報告の初稿は 2025 年 5 月で、本資料では 2026 年 1 月の第 2 版を参照する。

Chollet et al. (2025; 2026 改訂). ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems. arXiv:2505.11831v2. https://arxiv.org/abs/2505.11831v2

参考文献

ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems

François Chollet, Mike Knoop, Gregory Kamradt, Bryan Landers, Henry Pinkard
2025 初稿・ 2026 改訂 / arXiv:2505.11831v2

複数規則の課題設計、選別と難度調整、初期モデル評価を報告する。

https://arxiv.org/abs/2505.11831v2

On the Measure of Intelligence

François Chollet / 2019 / arXiv:1911.01547

技能の水準と、新しい課題へ適応する効率を区別し、 ARC の形式と基礎となる知識を提案した。

https://arxiv.org/abs/1911.01547

参考文献

Abstraction and Reasoning Corpus for Artificial General Intelligence v2 (ARC-AGI-2)

ARC Prize Foundation / GitHub / 2026-10-16 参照

公開の学習・評価課題、 JSON の形式、利用条件、変更履歴を配布する。

https://github.com/arcprize/ARC-AGI-2

Testing systems with ARC-AGI

ARC Prize Foundation / GitHub / 2026-10-16 参照

モデルへの出題、出力の保存、完全一致による採点、費用・トークン数の集計を行う公式実装。

https://github.com/arcprize/arc-agi-benchmarking

参考文献

ARC-AGI Toolkit

ARC Prize Foundation / GitHub / 2026-10-16 参照

ARC-AGI-3 の対話的な環境を作り、行動・観測・ゲームの進行を扱う Python API を提供する。

https://github.com/arcprize/ARC-AGI

Gemini 3.1 Pro

Google DeepMind / 2026 / Model performance

ARC-AGI-2 を含むモデル比較と、 ARC Prize Verified の結果を掲載する。

https://deepmind.google/models/gemini/pro/