ARC-AGI-3

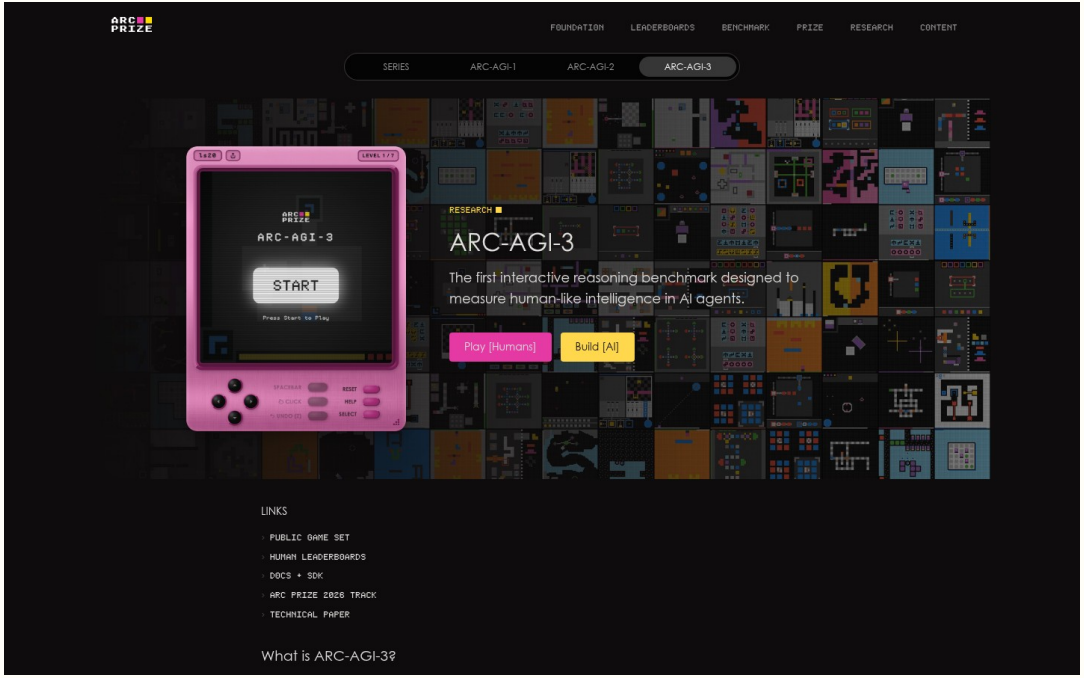
ARC: Abstraction and Reasoning Corpus

AGI: Artificial General Intelligence

未知の環境で、観測と行動からルールを学ぶ

sasakiy84

ARC-AGI-3 の公式サイト



[1] ARC Prize Foundation. ARC-AGI-3. https://arcprize.org/arc-agi/3

1. 観測と行動から課題を知る
2. 人間基準の得点と到達水準
3. 環境の作成と公開セット
4. 使い方と評価の読み方

1. 観測からルールを学ぶ

最終回答より、学び方を測る

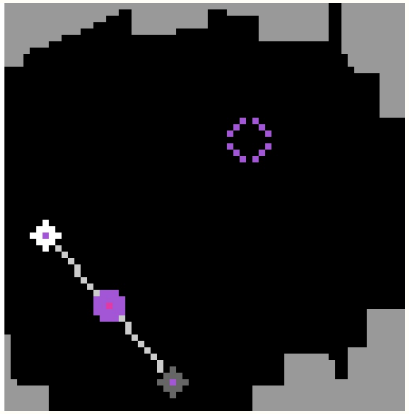
- 初めて見るゲームを操作し、目標とルールを自分で見つける。自然言語による遊び方の説明は与えられない。
- 入力は 64×64 の 16 色の画面。出力はキー操作や、座標を指定するクリックである。
- 観測 → 行動 → 次の観測を繰り返し、全レベルを少ない行動で完了する。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

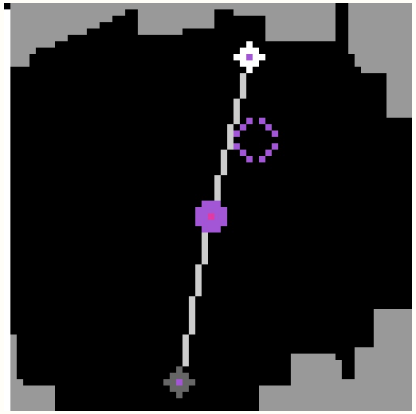
実例 1 ：中点を同じ色の輪へ運ぶ

r11l / レベル 1 からレベル 2 へ　SDK で実行した成功例

開始時

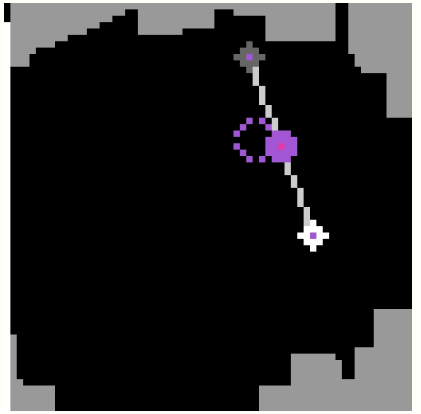


操作 1 後



ACTION6 (38, 8)

操作 3 の途中



端点を選択 → (48,36)

二つの端点を動かし、紫色の中点を輪へ重ねると、次の盤面へ進む。

レベル 1 を達成

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ） . https://arcprize.org/tasks

実例１：端点の移動が中点を変える

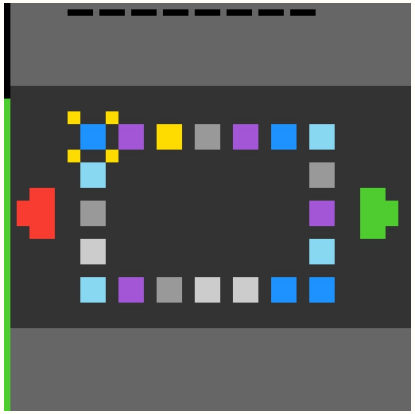
- 白い端点を動かすと、線の中点にある紫色の図形も動く。二つの端点を調整し、紫色の図形を同じ色の輪へ重ねる。
- 実行した操作はクリック (38,8) 、もう一方の端点を選ぶクリック (28,57) 、移動先を指すクリック (48,36) 。
- 3 回目の操作で図形が点滅し、完了レベル数が 0 から 1 へ増えた。表示も次のレベルへ切り替わる。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ） . https://arcprize.org/tasks

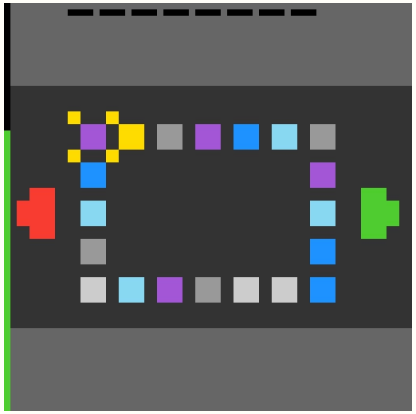
実例２：色列を動かして目印を合わせる

lp85 / レベル 1 からレベル 2 へ　公開の人間操作ログを SDK で再生

操作 4 後

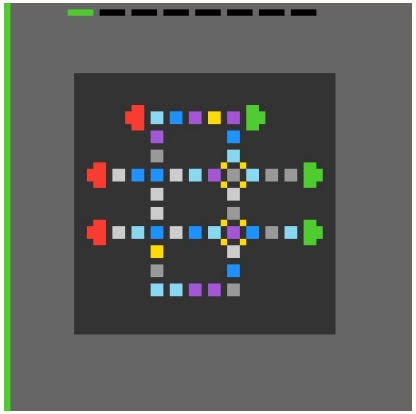


操作 5 後



ACTION6 (6, 33)

操作 6 後



ACTION6 (6, 33)

赤いボタンで色列を動かし、目印を合わせると次の盤面へ進む。

レベル 1 を達成

[1] ARC Prize Foundation. 公開人間試験ログ（公式記事が参照するミラー）. https://huggingface.co/datasets/magic-sword/arc_agi_3_public_demo_human_testing

実例２：色列の移動で目印を合わせる

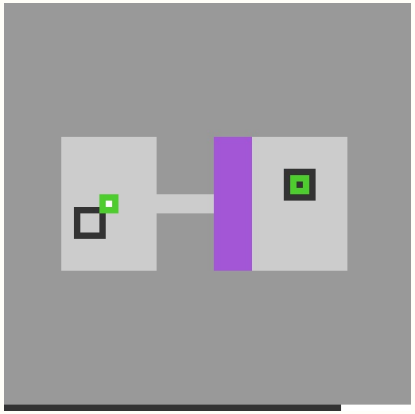
- 赤いボタンをクリックすると、輪に並んだ色のマスが移る。黄色の角が付いた目印に、対応するマスを合わせる。
- 人間の公開操作ログでは、６回のクリックで最初のレベルを完了した。最後の３回は同じ位置 (6,33) をクリックしている。
- 成功すると上部の進捗表示が緑になり、新しい盤面へ切り替わる。観測した反応から、操作の規則と目標を結び付けられる。

[1] ARC Prize Foundation. 公開人間試験ログ（公式記事が参照するミラー）. https://huggingface.co/datasets/magic-sword/arc_agi_3_public_demo_human_testing

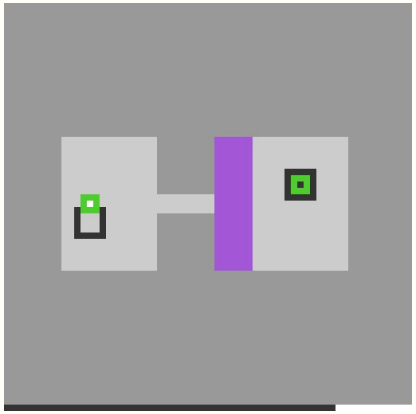
実例３：二つの駒をそれぞれ枠へ入れる

ka59 / レベル 1 からレベル 2 へ　公開の人間操作ログを SDK で再生

操作 17 後

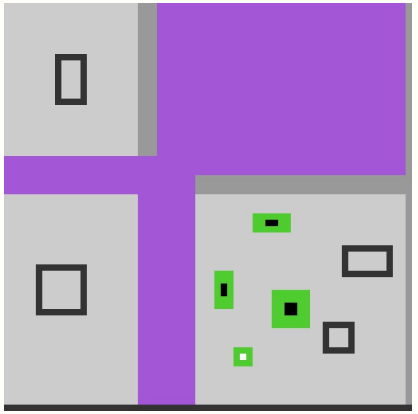


操作 18 後



ACTION3

操作 19 後



ACTION2

右の駒を枠に残し、左の駒も枠に入れると、次の盤面へ進む。

レベル 1 を達成

[1] ARC Prize Foundation. 公開人間試験ログ（公式記事が参照するミラー）. https://huggingface.co/datasets/magic-sword/arc_agi_3_public_demo_human_testing

実例３：操作する駒を切り替える

- 左右の緑の駒を、それぞれ黒い枠の中へ移す。キーで動かす駒は、クリックして切り替えられる。
- 公開の人間ログでは、先に右の駒を枠へ入れ、次に左の駒へ切り替えて動かす。最後に左の駒が枠へ入り、次のレベルへ進んだ。
- 同じ方向キーでも、どの駒を選んでいるかで結果が変わる。画面の変化と直前の選択を一緒に記憶する必要がある。

[1] ARC Prize Foundation. 公開人間試験ログ（公式記事が参照するミラー）. https://huggingface.co/datasets/magic-sword/arc_agi_3_public_demo_human_testing

ARC-AGI-2 から何が変わったか

観点	ARC-AGI-2	ARC-AGI-3
提示内容	入力と出力の例	操作できる未知の環境
解答の形	完成した出力グリッド	観測に応じた行動列
学ぶ機会	提示された例	自分の操作と反応
採点の中心	出力の正しさ	完了と行動効率

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

試す・モデル化する・目標を知る・計画する

- 探索では、何を操作すれば情報が得られるかを選ぶ。無反応のクリックも、仮説を更新する材料になる。
- 環境のモデルを作り、物の動きや操作の効果を予測する。勝利条件も、画面と反応から推定する。
- 発見したルールを後のレベルへ持ち越し、長い行動列を計画する。最初のレベルは操作を学ぶ導入として易しく作られる。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

2. 人間基準の得点と性能

成功と行動数を一緒に採点する

- 得点は RHAE （ Relative Human Action Efficiency ）。人間が使った行動数に対する、エージェントの効率を表す。
- レベルを完了した場合、人間基準 ÷ AI の行動数を二乗する。未完了のレベルは 0 点になる。
- 人間基準が 10 手なら、 20 手で 25% 、 100 手で 1% 。完了するだけでは高い得点にならない。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621
[2] ARC Prize Foundation. ARC-AGI Toolkit 0.9.9. https://github.com/arcprize/arc-agi

公開時のモデルは 1% 未満だった

モデル（2026 年 3 月公表）	RHAE
Opus 4.6 (Max)	0.50%
Gemini 3.1 Pro Preview	0.40%
GPT 5.4 (High)	0.20%
Grok-4.20 (Beta 0309 Reasoning)	0.10%

semi-private 55 環境。論文 v2 が報告する公開時の性能。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

現在は実行基盤による差が大きい

モデル / 実行基盤	RHAE
GPT-5.6 Sol (Max) / Standard	7.8%
Claude Opus 5 (High) / Standard	30.2%
GPT-6 Astra (Max) / Standard	62.7%
GPT-6 Astra (High) / Provider Adapter	99.9%

semi-private 。 2026-10-20 確認。 Standard は共通の履歴管理、 Provider Adapter は提供元固有の状態を保持する。

[1] ARC Prize Foundation. ARC-AGI-3 leaderboard （ 2026-10-20 確認） . https://arcprize.org/leaderboard

99.9% はモデル名だけでは読めない

- OpenAI の Astra 紹介でも ARC-AGI-3 を採用し、 99.9% と報告している。公式リーダーボードでは Provider Adapter / High の結果に対応する。
- 同じ Astra でも Standard / Max では 62.7% 。行動間で何を記憶し、長い履歴をどう要約するかが結果に関わる。
- 公開セットの実験では、 Sol の記憶保持と履歴の要約を有効にすると、 13.3% から 38.3% へ上がった。

[1] OpenAI (2026). GPT-6 Astra: A new generation of intelligence. https://openai.com/index/gpt-6-astra/
[2] Ilan Bigio & Ted Sanders (2026-07-29). How enabling two settings tripled our scores on the ARC-AGI-3 benchmark. https://openai.com/index/how-two-settings-tripled-our-arc-agi-3-scores/

後のレベルほど採点への重みが大きい

- レベル１、２、3... の重みは１、２、3... となる。環境の得点は、全レベルの重みの合計を分母にした加重平均である。
- SDK 0.9.9 ではレベル得点の上限が 115% 。環境全体には、完了したレベルの重みの割合による上限もある。
- 最後に、評価した全環境の得点を平均する。短い導入レベルだけを速く解いても、環境全体の高得点にはつながらない。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621
[2] ARC Prize Foundation. ARC-AGI Toolkit 0.9.9. https://github.com/arcprize/arc-agi

同じ完了率でも行動数で得点が変わる

説明用の 3 レベル	人間と同じ手数	人間の 2 倍
レベル 1 （重み 1 ）	100%	25%
レベル 2 （重み 2 ）	100%	25%
レベル 3 （重み 3 ）	100%	25%
環境全体	100%	25%

[1] ARC Prize Foundation. ARC-AGI Toolkit 0.9.9. https://github.com/arcprize/arc-agi

3. 環境の作成と公開セット

専用のゲームスタジオが環境を作る

- ARC Prize Foundation の開発者が、新しい仕組みを持つ環境を設計する。既存ゲームの知識ではなく、物体・空間・因果などの基本的な理解を使う。
- 構想の共同レビュー、内部試遊、外部の人間による試遊を経て、採用する環境を決める。
- Python の共通エンジンと自動検査で、表示・操作・評価をそろえ、バグや単純すぎる環境を調べる。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

人間が初見で解けることを採用条件にする

- 各環境を 10 人が試し、少なくとも 2 人が初見で全レベルを完了できた環境を採用する。
- 採点の人間基準には、各レベルを完了した人を行動数順に並べた中央の人を使う。成功者が 4 人でも 5 人でも 3 番目を選ぶ。
- 全候補の試験では 486 人が 414 環境を試し、 2,893 回の試行を記録した。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

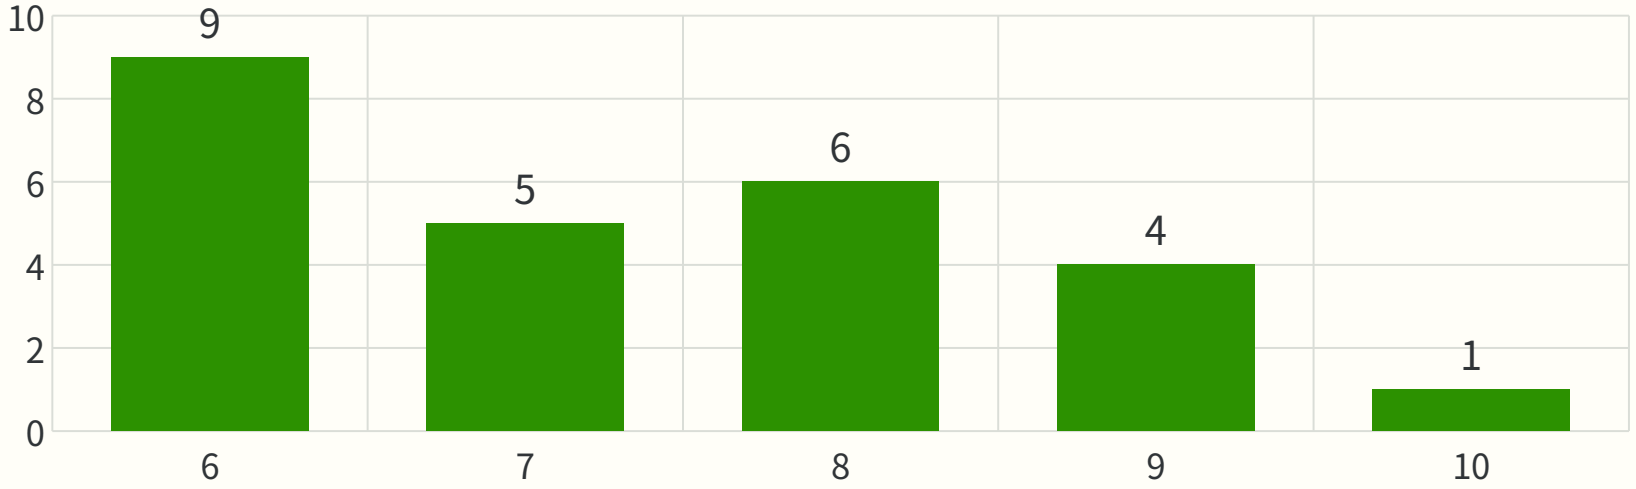
135 環境を 3 種類の集合に分ける

集合	環境数	役割
公開デモ	25	形式と基本操作を試す
Semi-private	55	外部 API モデルの評価
Fully private	55	競技用の非公開評価

非公開側は、公開デモと重ならない仕組みを多く含む。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

公開 25 環境は 6 〜 10 レベルを持つ



横軸：レベル数　縦軸：環境数。公開 25 環境・計 183 レベル。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ）. https://arcprize.org/tasks

操作の組合せも環境ごとに違う

公開メタデータの操作タグ	環境数
キーとクリック（ keyboard_click ）	13
クリック（ click ）	7
キー（ keyboard ）	4
タグなし	1

25 環境の配布タグを集計。実際に使える操作は、環境が返す available_actions で確かめる。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ）. https://arcprize.org/tasks

4. 使い方と評価の読み方

長い対話では、何を記憶するかも変わる

- Standard は共通のテキスト履歴を使い、モデルが残したメモを次の行動へ持ち越す。
- Provider Adapter は、提供元の対話状態や推論状態を保ち、長い履歴を要約して続ける。
- 公開実験の 13.3→38.3% と、非公開評価の 7.8% は、対象集合と実行基盤が異なる。

[1] ARC Prize Foundation. ARC-AGI-3 Benchmarking. https://github.com/arcprize/arc-agi-3-benchmarking
[2] Ilan Bigio & Ted Sanders (2026-07-29). How enabling two settings tripled our scores on the ARC-AGI-3 benchmark. https://openai.com/index/how-two-settings-tripled-our-arc-agi-3-scores/

人間の試遊と SDK から始められる

- 公式サイトの Public Game Set では、ブラウザで 25 環境を試遊できる。リプレイから操作と反応を見返せる。
- Python の arc-agi を導入すると、同じインターフェースでローカル実行と API 実行を扱える。
- 公開ゲームは取得して動かせる。非公開評価の課題そのものは配布せず、汎化を測るために保持する。

[1] ARC Prize Foundation. ARC-AGI-3. https://arcprize.org/arc-agi/3
[2] ARC Prize Foundation. ARC-AGI Toolkit 0.9.9. https://github.com/arcprize/arc-agi

SDK で観測を読み、次の操作を出す

```
import arc_agi
from arcengine import GameAction

arc = arc_agi.Arcade()
env = arc.make("ls20")
obs = env.reset()
obs = env.step(GameAction.ACTION4)
```

返る観測には画面、完了レベル数、状態、利用可能な操作が含まれる。

[1] ARC Prize Foundation. ARC-AGI Toolkit 0.9.9. https://github.com/arcprize/arc-agi

利用条件と評価対象を選ぶ

- Toolkit と公式 Benchmarking 実装は MIT License 。 Python 側の実行基盤として利用・改変できる。
- ベンチマークを報告するときは、評価集合、モデルと推論設定、実行基盤、得点の定義を対応させる。
- 公開セットは仕組みの確認や開発に向く。モデルの未知の環境への適応は、非公開セットで確かめる。

[1] ARC Prize Foundation. ARC-AGI Toolkit 0.9.9. https://github.com/arcprize/arc-agi
[2] ARC Prize Foundation. ARC-AGI-3 Benchmarking. https://github.com/arcprize/arc-agi-3-benchmarking

ARC-AGI-3 が見せるのは初見の学習効率

- 固定の例から一度だけ答える課題を、観測と行動を繰り返す未知の環境へ広げた。
- 人間が初見で解ける環境を作り、完了までの行動数を人間基準と比べる。
- 現在の高得点は、モデルだけでなく履歴や推論状態を保持する実行基盤と結び付いている。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621
[2] ARC Prize Foundation. ARC-AGI-3 leaderboard （2026-10-20 確認）. https://arcprize.org/leaderboard

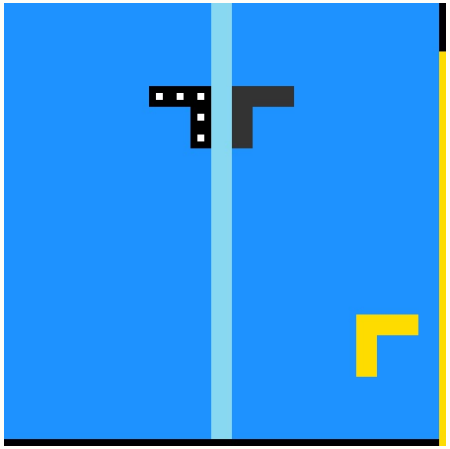
Appendix

1. 追加 10 環境の観測
2. 公開セットの内訳
3. 参考文献

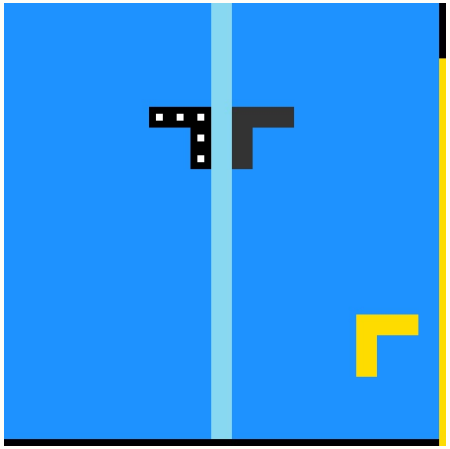
実例 4 ：左右の移動を比べる

ar25 / レベル 1　連続する 3 回の観測

操作 10 後

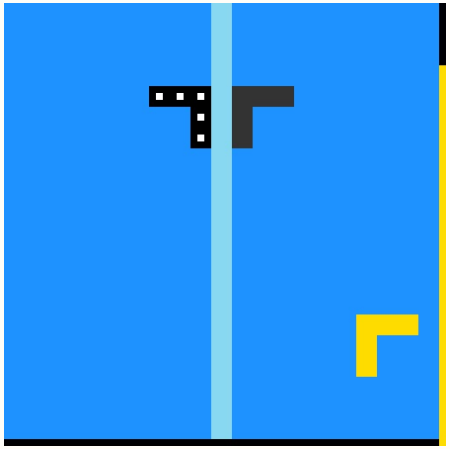


操作 11 後



ACTION2

操作 12 後



ACTION1

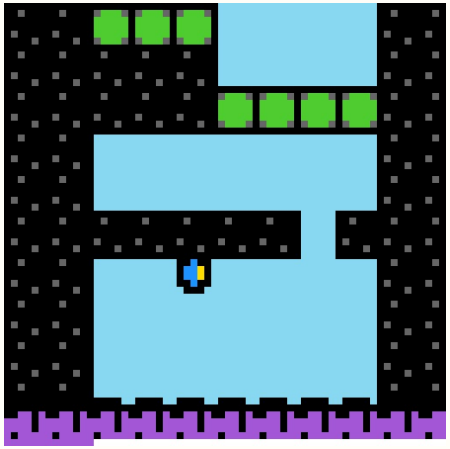
黒い折れ曲がった図形が左へ移り、次の操作で元の位置へ戻る。水色の縦線と黄色の図形は同じ場所に残る。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ）. https://arcprize.org/tasks

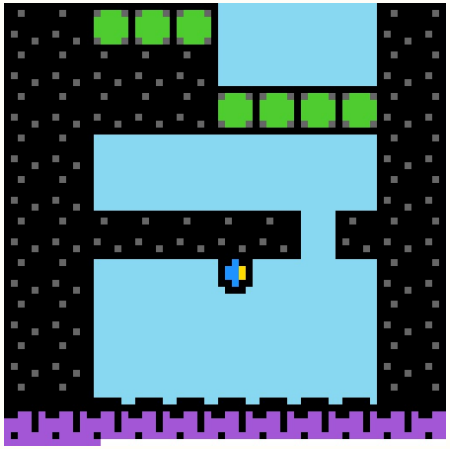
実例 5 ：地形そのものが変わる

bp35 / レベル 1　連続する 3 回の観測

操作 13 後

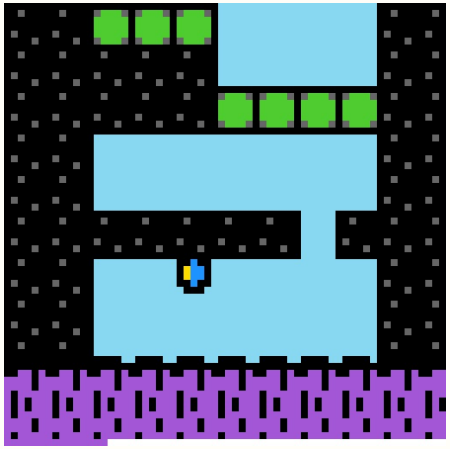


操作 14 後



ACTION4

操作 15 後



ACTION3

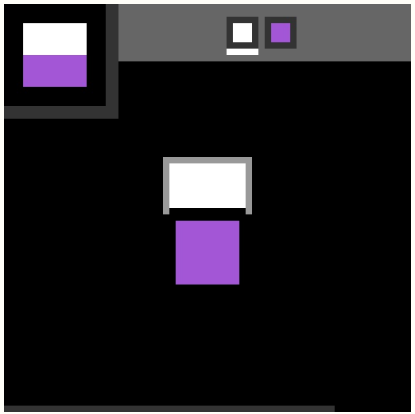
水色の足場の下端が、 3 枚目では上へ移る。紫色の領域との距離が変わり、操作前と同じ地形ではなくなる。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ） . https://arcprize.org/tasks

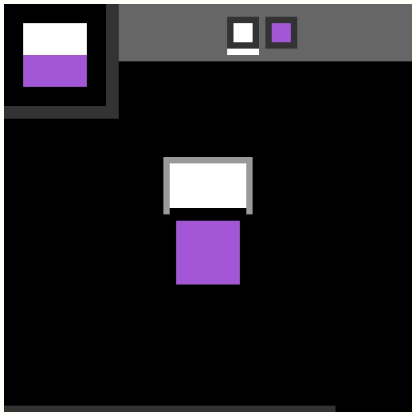
実例 6 ：図形を枠へ合わせる

cd82 / レベル 1 からレベル 2 へ　公開の人間操作ログを SDK で再生

操作 42 後

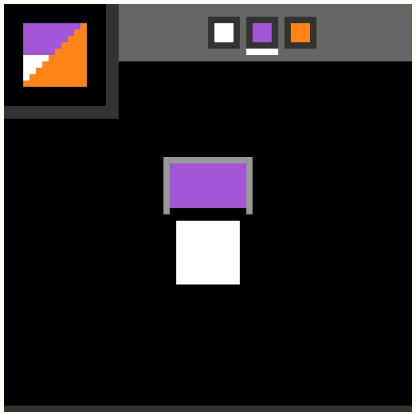


操作 43 後



ACTION2

操作 44 後



ACTION5

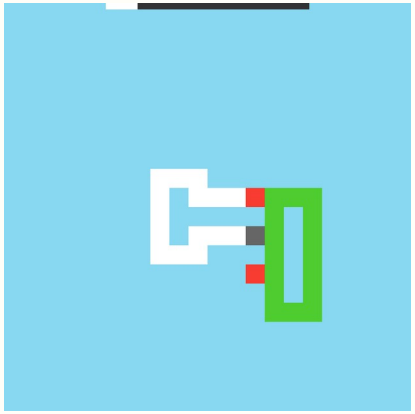
最後の操作で図形がそろい、完了数が増えて次の盤面へ進む。

レベル 1 を達成

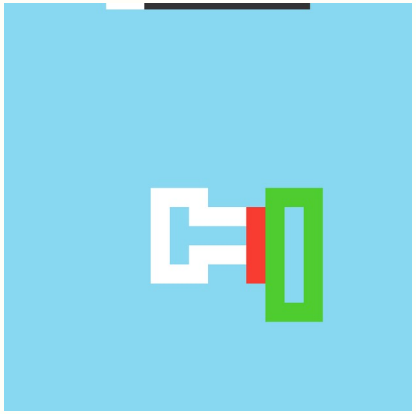
[1] ARC Prize Foundation. 公開人間試験ログ（公式記事が参照するミラー）. https://huggingface.co/datasets/magic-sword/arc_agi_3_public_demo_human_testing

実例 7 ：向きと位置をそろえる

cn04 / レベル 1 からレベル 2 へ
操作 12 後

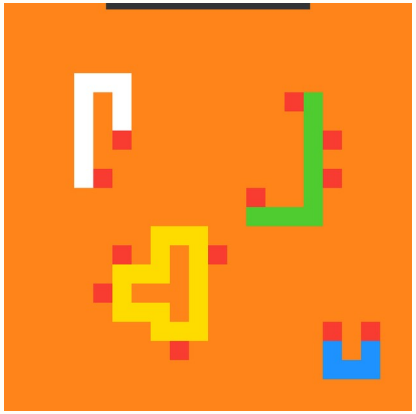


SDK で実行した成功例
操作 13 後



ACTION2

操作 14 後



ACTION2

白い図形を回転・移動し、赤い端点を緑の図形に合わせる。

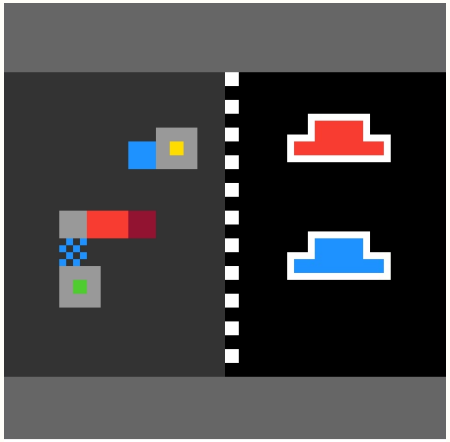
レベル 1 を達成

[1] ARC Prize Foundation. Public Game Set / SDK 観測（2026-10-20）. https://arcprize.org/tasks

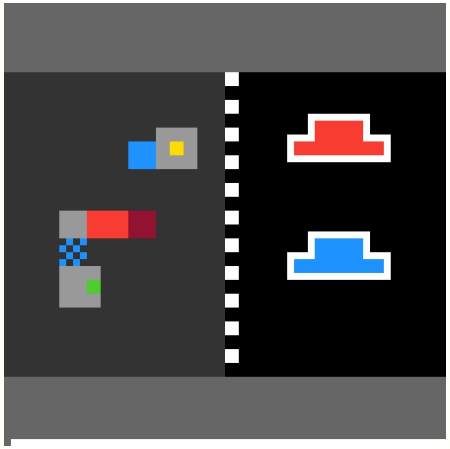
実例 8 ：小さな位置変化を読む

dc22 / レベル 1　連続する 3 回の観測

開始時

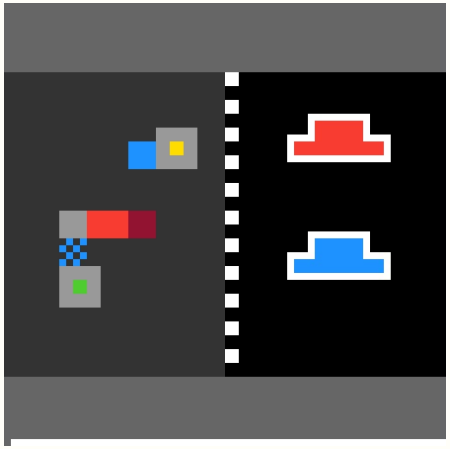


操作 1 後



ACTION4

操作 2 後



ACTION3

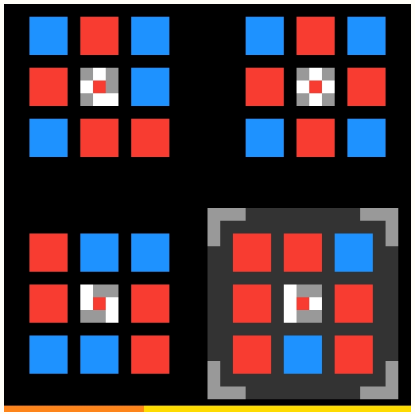
左下の灰色のマスと緑色の印が横へ移る。赤い棒や右側の二つの図形は、同じ位置に残っている。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ） . https://arcprize.org/tasks

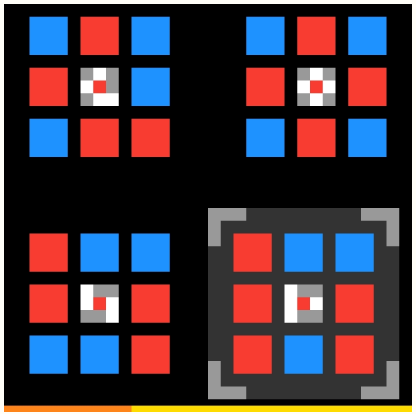
実例 9 ：赤と青の並びを合わせる

ft09 / レベル 1 からレベル 2 へ　公開の人間操作ログを SDK で再生

操作 41 後

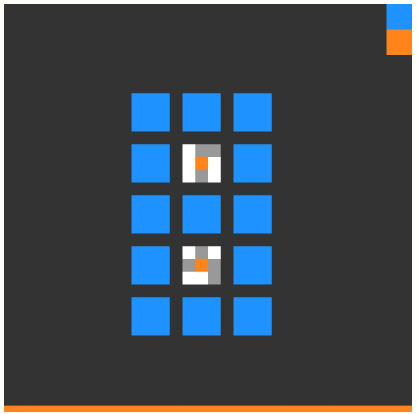


操作 42 後



ACTION6 (48, 37)

操作 43 後



ACTION6 (54, 55)

クリックで赤と青の並びを変え、完成すると次の盤面へ進む。

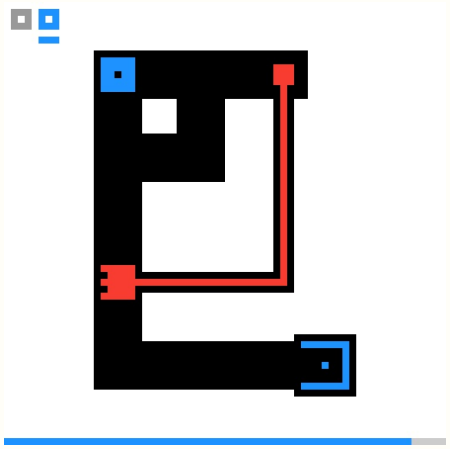
レベル 1 を達成

[1] ARC Prize Foundation. 公開人間試験ログ（公式記事が参照するミラー）. https://huggingface.co/datasets/magic-sword/arc_agi_3_public_demo_human_testing

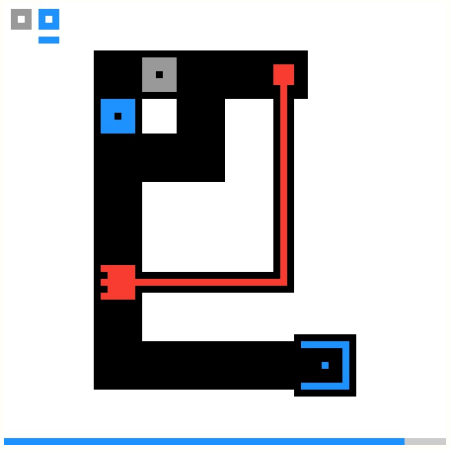
実例 10 ：別の駒が反応する

g50t / レベル 1　連続する 3 回の観測

操作 11 後

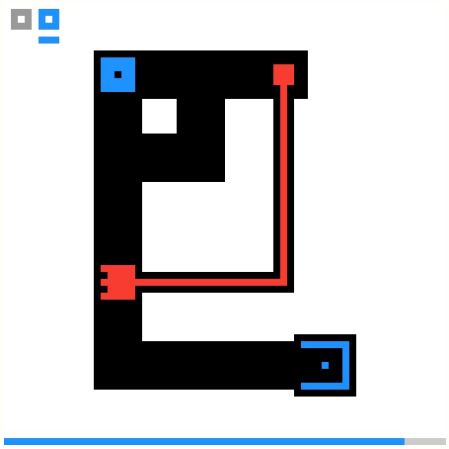


操作 12 後



ACTION2

操作 13 後



ACTION1

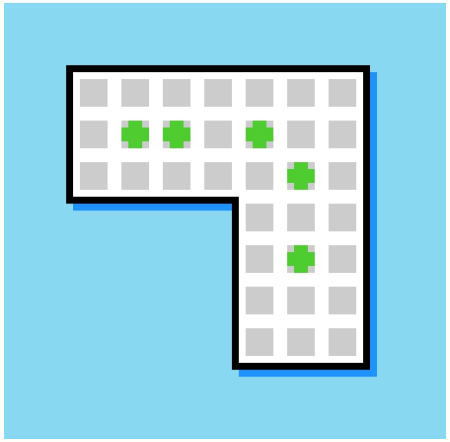
上側の小さい駒の配置が変わり、次の操作で戻る。盤面の赤い経路と右下の青い図形は同じまま見えている。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ） . https://arcprize.org/tasks

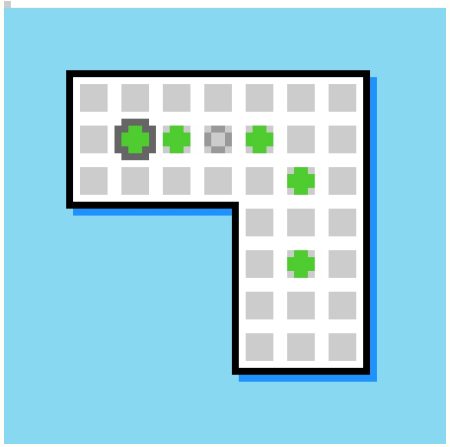
実例 11 ：選んだマスの反応を調べる

lf52 / レベル 1　連続する 3 回の観測

開始時

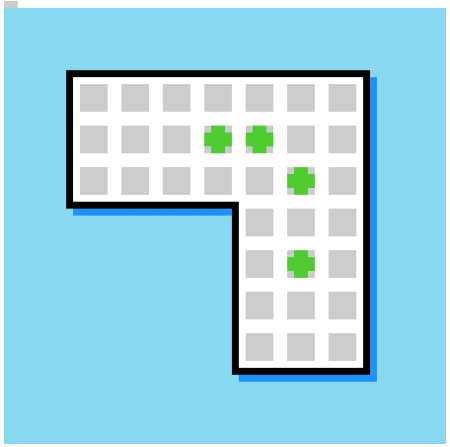


操作 1 後



ACTION6 (19, 19)

操作 2 後



ACTION6 (31, 19)

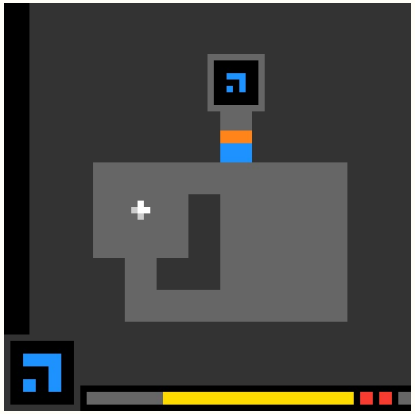
緑のマスを選び、その先をクリックすると盤面が変わる。選択する場所と移動先を組み合わせて、反応を調べる。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ） . https://arcprize.org/tasks

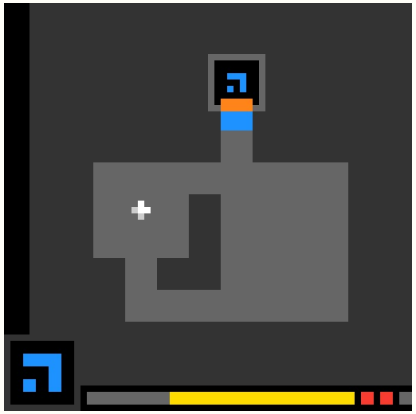
実例 12 ：操作を重ねてレベルを完了する

ls20 / レベル 1 からレベル 2 へ　公開の人間操作ログを SDK で再生

操作 61 後

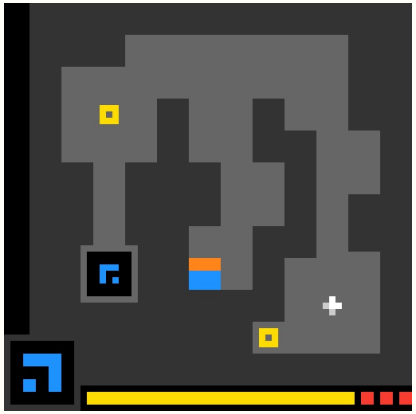


操作 62 後



ACTION1

操作 63 後



ACTION1

移動を重ねて目標へ達すると、完了数が増え、次の盤面へ進む。

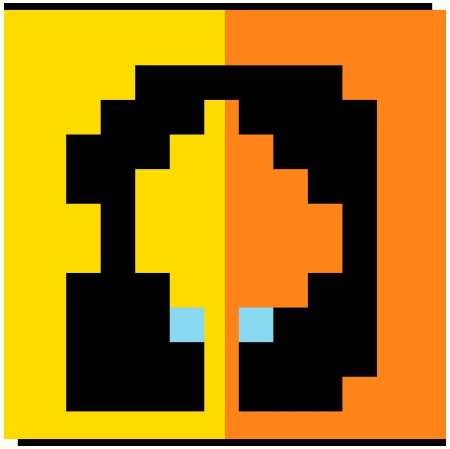
レベル 1 を達成

[1] ARC Prize Foundation. 公開人間試験ログ（公式記事が参照するミラー）. https://huggingface.co/datasets/magic-sword/arc_agi_3_public_demo_human_testing

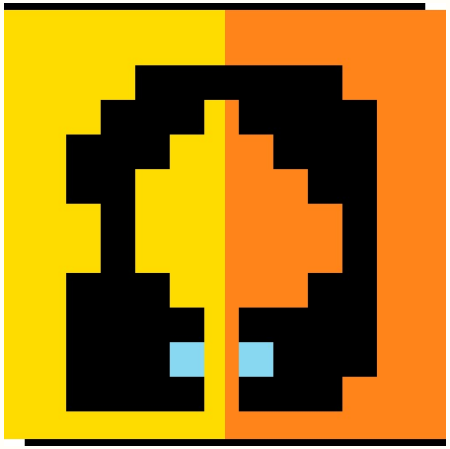
実例 13 ：動く部分と背景を見分ける

m0r0 / レベル 1　連続する 3 回の観測

操作 5 後

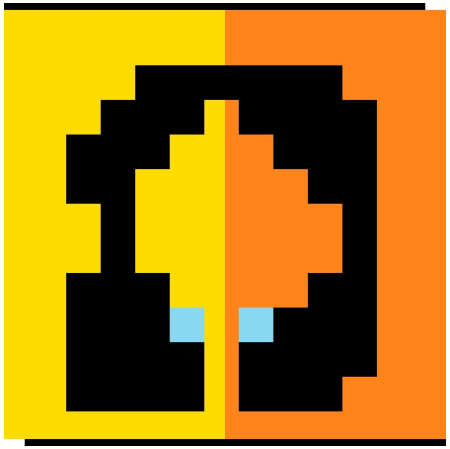


操作 6 後



ACTION2

操作 7 後



ACTION1

水色の横棒が下へ移り、続く操作で上へ戻る。黄色と橙色の背景や黒い輪郭は同じ場所に残る。

[1] ARC Prize Foundation. Public Game Set / SDK 観測（ 2026-10-20 ） . https://arcprize.org/tasks

公開セットの環境とレベル数（1/2）

環境	レベル数
ar25	8
bp35	9
cd82	6
cn04	6
dc22	6
ft09	6
g50t	7

環境	レベル数
ka59	7
lf52	10
lp85	8
ls20	7
m0r0	6
r11l	6

[1] ARC Prize Foundation. Public Game Set / SDK 観測（2026-10-20）. https://arcprize.org/tasks

公開セットの環境とレベル数（2/2）

環境	レベル数
re86	8
s5i5	8
sb26	8
sc25	6
sk48	8
sp80	6
su15	9

環境	レベル数
tn36	7
tr87	6
tu93	9
vc33	7
wa30	9

[1] ARC Prize Foundation. Public Game Set / SDK 観測（2026-10-20）. https://arcprize.org/tasks

人間試験は、解けた理由も調べる

- 専用の試験会場で週に複数回の試遊を行い、参加者ごとの環境は初見 1 回に限った。現在のレベルのリセットは認めた。
- 統計だけでなくリプレイも調べ、詰まりやすい仕組みや表示の問題を直した。
- 全候補の総プレイ時間は 427.9 時間。 1 試行の中央値は 7.4 分だった。

[1] ARC Prize Foundation (2026). ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence, v2. https://arxiv.org/abs/2603.24621

参考文献（1/3）

ARC-AGI-3: A New Challenge for Frontier Agentic Intelligence

ARC Prize Foundation, 2026. arXiv:2603.24621, v2.

環境の構築、人間試験、評価集合と採点の説明。

https://arxiv.org/abs/2603.24621

Announcing ARC-AGI-3

Greg Kamradt, ARC Prize, 2026-03-25.

公開時の目的と、対話型の課題への移行を紹介。

https://arcprize.org/blog/arc-agi-3-launch

参考文献（2/3）

ARC-AGI Toolkit

ARC Prize Foundation, version 0.9.9, 2026.

観測・操作の API と、ローカル実行の入口。

https://github.com/arcprize/arc-agi

ARC-AGI-3 Benchmarking

ARC Prize Foundation, 2026.

Standard と Provider Adapter の実行方法。

https://github.com/arcprize/arc-agi-3-benchmarking

参考文献（ 3/3 ）

GPT-6 Astra: A new generation of intelligence

OpenAI, 2026.

ARC-AGI-3 の採用と、 99.9% の実行条件。

https://openai.com/index/gpt-6-astra/

How enabling two settings tripled our scores on the ARC-AGI-3 benchmark

Ilan Bigio and Ted Sanders, OpenAI, 2026-07-29.

記憶と履歴要約を変えた公開セットの比較実験。

https://openai.com/index/how-two-settings-tripled-our-arc-agi-3-scores/