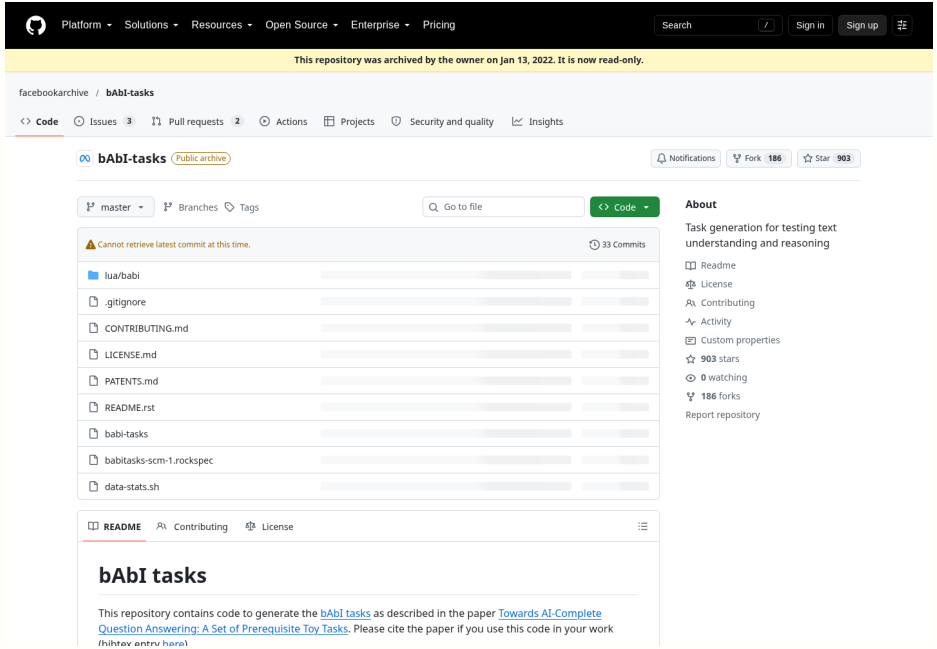
bAbI

物語中の事実を使う 20 種類の推論課題

sasakiy84

bAbI の公開ページ



[1] bAbI 公式公開ページ。 2026-10-18 参照。 https://github.com/facebookarchive/bAbI-tasks

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

何が推論を難しくするかを、課題ごとに調べる

- 短い物語と質問を読み、場所、個数、人物、経路などを答える。物語・質問・正解は、世界の状態を管理するシミュレーターで生成する。
- 一つの事実だけで答える課題から、複数の事実の統合、否定、帰納、経路探索まで、 20 種類に分けている。

[1] Jason Weston et al. (2015). Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. arXiv:1502.05698, 2015. https://arxiv.org/abs/1502.05698

入力・出力と配布フィールド

フィールド	意味
passage	質問より前に現れた物語の事実
question / answer	質問と正解の語句
task	20 種類の推論課題の番号

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 https://huggingface.co/datasets/Muennighoff/babi

実例 1 ：課題 1

関連する入力・回答／左：原文　右：日本語

Passage: Mary moved to the office.
Passage: John moved to the garden.
Question: Where is John?
Answer: garden

正解： garden

物語：メアリーはオフィスに移動した。
物語：ジョンは庭に移動した。
質問：ジョンはどこにいるか。
回答：庭

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 1 / test 行 530 。 https://huggingface.co/datasets/Muennighoff/babi

実例２：課題２

関連する入力・回答／左：原文　右：日本語

Passage: John got the milk there.
Passage: John went back to the office.
Question: Where is the milk?
Answer: office

正解： office

物語：ジョンはそこでミルクを手に取った。
物語：ジョンはオフィスに戻った。
質問：ミルクはどこにあるか。
回答：オフィス

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 2 / test 行 1910 。 https://huggingface.co/datasets/Muennighoff/babi

実例 3 ：課題 19

原文

The office is west of the bedroom.
The bathroom is west of the garden.
The kitchen is east of the garden.
The office is east of the hallway.
The kitchen is north of the office.
Question: How do you go from the garden to the office?
Answer: east south

日本語訳

正解： east south

オフィスは寝室の西にある。
浴室は庭の西にある。
キッチンは庭の東にある。
オフィスは廊下の東にある。
キッチンはオフィスの北にある。
質問：庭からオフィスへは、どの順に進めばよいか。
回答：東、南

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 19 / test 行 18310 。 https://huggingface.co/datasets/Muennighoff/babi

作成方法とデータの構成

作成の背景

- 自然な文章の質問応答だけでは、失敗の原因が知識不足なのか、複数の事実を結び付ける能力なのかを分けにくい。
- そこで、必要な推論操作を制御できる小さな世界を作り、推論能力を個別に試す課題を用意した。

[1] Jason Weston et al. (2015). Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. arXiv:1502.05698, 2015. https://arxiv.org/abs/1502.05698

収集と品質の確認

- 人物の移動、物の受け渡し、位置関係などを生成し、シミュレーター内の状態から質問と正解を作る。
- 元の形式には回答を支える事実の番号も付く。研究では、回答だけで学習する条件と、根拠の事実も教える条件を分けた。

[1] Jason Weston et al. (2015). Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. arXiv:1502.05698, 2015. https://arxiv.org/abs/1502.05698

分割と件数

集合・対象	件数	役割
en-valid train	18,013	ミラーの全課題を実測
en-valid valid	1,987	同じミラーの開発問題
en-valid test	20,000	20 課題 × 各 1,000 問

[1] bAbI 、 en-valid/test 全 20,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/Muennighoff/babi

課題を混ぜる前に、何を答えるかを見る

- 単一の事実の参照、複数の事実の統合、位置関係、受け渡し、数え上げなど、 20 種類の操作を別々に生成した。
- 取得した test は各課題 1,000 問で均等。 en-valid の train は 18,013 問、 valid は 1,987 問だった。

[1] bAbI 、 en-valid/test 全 20,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/Muennighoff/babi

採点方法とモデルの成績

何を 1 件として、どう採点するか

- 回答語句が正解と一致すれば 1 点。課題ごとに正解率を求め、 20 課題の平均も示せる。
- 2015 年の研究では、正解率 95% 以上をその課題の達成基準にした。経路の s,w などは、 HELM では south west のような単語へ変換する。

[1] Jason Weston et al. (2015). Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. arXiv:1502.05698, 2015. https://arxiv.org/abs/1502.05698

初期の代表的な評価

各課題 1,000 問で学習	20 課題の平均（%）
N-gram 分類器	34
LSTM （回答のみの教師）	49
MemNN AM + NG + NL	93

MemNN 拡張は根拠の事実も教師に使う。

[1] Jason Weston et al. (2015). Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. arXiv:1502.05698, 2015. https://arxiv.org/abs/1502.05698

HELM での評価条件

- en-valid 由来。 20 課題をまとめた候補から最大 1,000 問を評価し、最大 5 例提示、 3 試行、温度 0 。
- 表は test 906 問の完全一致率。残る 94 問は valid であり、test と混ぜずに示す。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	正解率（%）	試行数
text-davinci-003 （2022）	62.73	3
Anthropic v4-s3 （2022）	46.06	3

test 906 問、最大 5 例提示。完全一致率。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

制御した推論の診断へ使われる

- 自然な文章を集めたベンチマークが増えた後も、 bAbI は推論の段数や世界の状態を制御できる診断用データとして残った。
- HELM は同じ短い回答形式で、学習済みモデルへ少数例を見せて評価した。生成器と HELM 由来の変換コードは 2026-10-18 にも公開されている。

[1] bAbI 公式公開ページ。 2026-10-18 参照。 https://github.com/facebookarchive/bAbI-tasks

入手方法と利用条件

- 公式の生成器は facebookarchive/bAbI-tasks で公開されている。英語のほか、ヒンディー語や語順を変えた版もある。生成器は BSD 、データカードは CC BY 3.0 を掲げる。
- 掲載例は Muennighoff/babi の en-valid 変換ミラー。README が HELM と同じ変換手順を示しており、 test 全 20,000 問を取得した。

[1] bAbI 公式公開ページ。 2026-10-18 参照。 https://github.com/facebookarchive/bAbI-tasks

bAbI の要点

- シミュレーターで作った物語を使い、 20 種類の推論操作を個別に測る。
- 根拠の事実を教師として与えた学習と、少数例提示の言語モデル評価は、学習条件が異なる。

[1] Jason Weston et al. (2015). Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. arXiv:1502.05698, 2015. https://arxiv.org/abs/1502.05698

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例 1 ：課題 3

原文

Mary picked up the milk.
John went back to the garden.
Mary went back to the hallway.
Mary went back to the office.
Question: Where was the milk before the office?
Answer: hallway

日本語訳

正解： hallway

メアリーはミルクを手に取った。
ジョンは庭に戻った。
メアリーは廊下に戻った。
メアリーはオフィスに戻った。
質問：オフィスに来る前、ミルクはどこにあったか。
回答：廊下

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 3 / test 行 2300 。 https://huggingface.co/datasets/Muennighoff/babi

追加例２：課題５

関連する入力・回答／左：原文　右：日本語

Passage: Jeff grabbed the milk there.
Passage: Jeff gave the milk to Bill.
Question: Who gave the milk?
Answer: Jeff

正解： Jeff

物語：ジェフはそこでミルクをつかんだ。
物語：ジェフはビルにミルクを渡した。
質問：誰がミルクを渡したか。
回答：ジェフ

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 5 / test 行 4635 。 https://huggingface.co/datasets/Muennighoff/babi

追加例３：課題６

関連する入力・回答／左：原文　右：日本語

Passage: Mary got the apple there.
Passage: John moved to the office.
Question: Is John in the office?
Answer: yes

正解： yes

物語：メアリーはそこでリンゴを手に取った。
物語：ジョンはオフィスに移動した。
質問：ジョンはオフィスにいるか。
回答：はい

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 6 / test 行 5250 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 4 ：課題 7

関連する入力・回答／左：原文　右：日本語

Passage: John went to the office.
Passage: John got the milk there.
Question: How many objects is John carrying?
Answer: one

正解： one

物語：ジョンはオフィスに行った。
物語：ジョンはそこでミルクを手に取った。
質問：ジョンはいくつ物を持っているか。
回答： 1 個

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 7 / test 行 6770 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 5 ：課題 8

関連する入力・回答／左：原文　右：日本語

Passage: Daniel picked up the milk there.
Passage: Daniel picked up the football there.
Question: What is Daniel carrying?
Answer: milk,football

正解： milk,football

物語：ダニエルはそこでミルクを拾った。
物語：ダニエルはそこでサッカーボールを拾った。
質問：ダニエルは何を持っているか。
回答：ミルク、サッカーボール

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 8 / test 行 7590 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 6 ：課題 9

関連する入力・回答／左：原文　右：日本語

Passage: Mary is in the garden.
Passage: Mary is not in the garden.
Question: Is Mary in the garden?
Answer: no

正解： no

物語：メアリーは庭にいる。
物語：メアリーは庭にいない。
質問：メアリーは庭にいるか。
回答：いいえ

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 9 / test 行 8715 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 7 ：課題 10

関連する入力・回答／左：原文　右：日本語

Passage: Fred is in the park.
Passage: Mary is either in the park or the office.
Question: Is Mary in the park?
Answer: maybe

正解： maybe

物語：フレッドは公園にいる。
物語：メアリーは公園かオフィスのどちらかにいる。
質問：メアリーは公園にいるか。
回答：いるかもしれない

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 10 / test 行 9870 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 8 ：課題 14

関連する入力・回答／左：原文　右：日本語

Passage: This morning Fred went to the park.
Passage: Yesterday Fred went to the cinema.
Question: Where was Fred before the park?
Answer: cinema

正解： cinema

物語：今朝、フレッドは公園に行った。
物語：昨日、フレッドは映画館に行った。
質問：公園に行く前、フレッドはどこにいたか。
回答：映画館

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 14 / test 行 13905 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 9 ：課題 15 （原文）

原文

正解： sheep

Cats are afraid of sheep.
Emily is a cat.
Winona is a cat.
Sheep are afraid of mice.
Mice are afraid of cats.
Wolves are afraid of cats.
Jessica is a wolf.
Gertrude is a cat.
Question: What is emily afraid of?
Answer: sheep

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 15 / test 行 14024 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 9 ：課題 15 （日本語訳）

正解： sheep

日本語訳

ネコはヒツジを怖がる。
エミリーはネコである。
ウィノナはネコである。
ヒツジはネズミを怖がる。
ネズミはネコを怖がる。
オオカミはネコを怖がる。
ジェシカはオオカミである。
ガートルードはネコである。
質問：エミリーは何を怖がるか。
回答：ヒツジ

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 15 / test 行 14024 。 https://huggingface.co/datasets/Muennighoff/babi

追加例 10 ：課題 20

関連する入力・回答／左：原文　右：日本語

Passage: Yann is tired.
Question: Where will yann go?
Answer: bedroom

正解： bedroom

物語：ヤンは疲れている。
質問：ヤンはどこへ行くか。
回答：寝室

[1] Muennighoff/babi 、改訂 1da25875 。 2026-10-18 参照。 en-valid / task 20 / test 行 19078 。 https://huggingface.co/datasets/Muennighoff/babi

集計と評価条件

20 課題と実測した分割（1/4）

課題	train	valid	test
1. 一つの根拠	900	100	1,000
2. 二つの根拠	900	100	1,000
3. 三つの根拠	900	100	1,000
4. 二項関係	900	100	1,000
5. 三項関係	900	100	1,000
6. Yes ／ No	900	100	1,000

[1] bAbI 、 en-valid/test 全 20,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/Muennighoff/babi

20 課題と実測した分割（2/4）

課題	train	valid	test
7. 数え上げ	900	100	1,000
8. リスト・集合	900	100	1,000
9. 否定	900	100	1,000
10. 不確かな知識	900	100	1,000
11. 代名詞照応	900	100	1,000
12. 接続	900	100	1,000

[1] bAbI 、 en-valid/test 全 20,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/Muennighoff/babi

20 課題と実測した分割（3/4）

課題	train	valid	test
13. 複合照応	900	100	1,000
14. 時間	900	100	1,000
15. 演繹	900	100	1,000
16. 帰納	900	100	1,000
17. 位置関係	904	96	1,000
18. 大きさ	905	95	1,000

[1] bAbI 、 en-valid/test 全 20,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/Muennighoff/babi

20 課題と実測した分割（4/4）

課題	train	valid	test
19. 経路探索	900	100	1,000
20. 動機	904	96	1,000

[1] bAbI 、 en-valid/test 全 20,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/Muennighoff/babi

研究と参考文献

研究者と発表の位置付け

- 第一著者 Jason Weston 、最終著者 Tomas Mikolov を含む Facebook AI Research の 7 名による研究。
- 2015 年に公開。小さな世界での質問応答を通じ、推論能力を診断する一連の課題を提案した。

[1] Jason Weston et al. (2015). Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. arXiv:1502.05698, 2015. https://arxiv.org/abs/1502.05698

参考文献

Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks

Jason Weston, Antoine Bordes, Sumit Chopra, Alexander M. Rush, Bart van Merriënboer, Armand Joulin, Tomas Mikolov / arXiv:1502.05698, 2015

bAbI の目的、作成方法、評価をまとめた研究。

https://arxiv.org/abs/1502.05698

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

bAbI ：公開データ

Muennighoff/babi / 改訂 1da25875 / 2026-10-18 参照

原文・正解の 13 例と、対象集合の全件集計に用いた公開資源。

https://huggingface.co/datasets/Muennighoff/babi