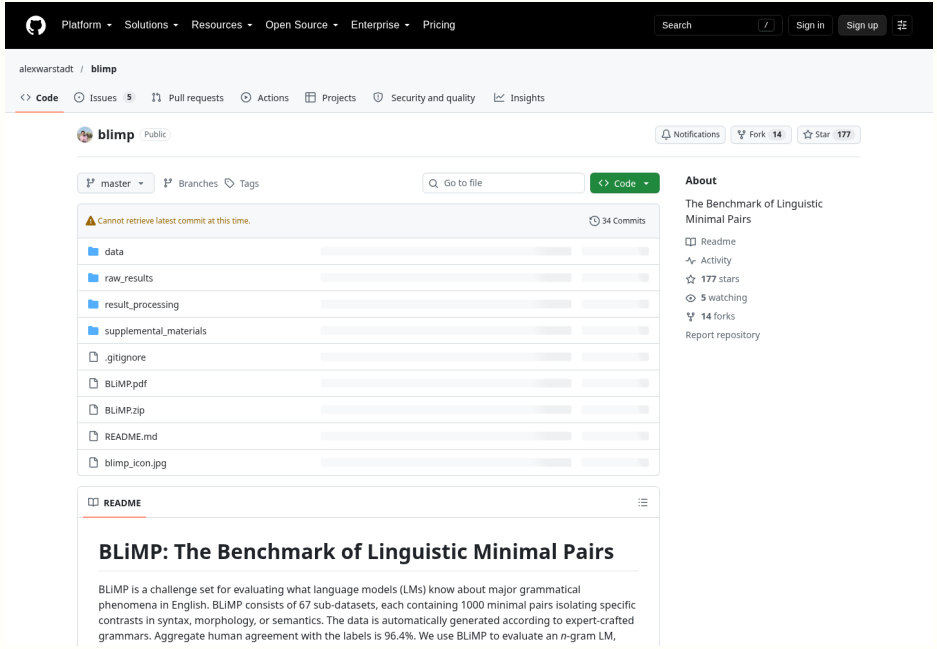
BLiMP

The Benchmark of Linguistic Minimal Pairs for English

文の最小対から、英語の文法知識を測る

sasakiy84

BLiMP の公開ページ



[1] BLiMP 公式公開ページ。 2026-10-18 参照。 https://github.com/alexwarstadt/blimp

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

似た二つの文で、文法上の違いを検出する

- 文法的に許容される文と、特定の文法規則に違反する文を対にした英語の評価集合である。 1 対を 1 問として扱う。
- 生成に使った 67 種類のパターンごとに 1,000 対、合計 67,000 対を収録する。翻訳では英語の文法的な違いが消えるため、意味の訳と違反箇所の説明を添える。

[1] Alex Warstadt et al. (2020). BLiMP: The Benchmark of Linguistic Minimal Pairs for English. TACL 8, 2020. https://aclanthology.org/2020.tacl-1.25/

入力・出力と配布フィールド

フィールド	意味
sentence_good / sentence_bad	許容文と非許容文
UID / pair_id	生成パターンと、その中の対の番号
linguistics_term	対象とする言語学上の現象

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 https://huggingface.co/datasets/nyu-mll/blimp

実例 1 ：再帰代名詞の性

正解：上の文

許容文と非許容文／原文と日本語

Susan hid herself.
Susan hid itself.

許容文の意味：スーザンは自分自身を隠した。
対立点： herself を、スーザンと一致しない itself へ変えている。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 anaphor_gender_agreement / pair_id 604 。 https://huggingface.co/datasets/nyu-mll/blimp

実例２：再帰代名詞の数

正解：上の文

許容文と非許容文／原文と日本語

Jodi left herself.
Jodi left themselves.

許容文の意味：ジョディは自分自身を置いていった。
対立点：この生成設定では Jodi を単数・女性として扱い、 herself と themselves の数の対応を対比する。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 anaphor_number_agreement / pair_id 60 。 https://huggingface.co/datasets/nyu-mll/blimp

実例３：指示詞と名詞の数

正解：上の文

許容文と非許容文／原文と日本語

Becky hid that face.
Becky hid that faces.

許容文の意味：ベッキーはあの顔を隠した。
対立点：単数の that に、複数形 faces を続けた不一致。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 determiner_noun_agreement_1 / pair_id 579 。 https://huggingface.co/datasets/nyu-mll/blimp

作成方法とデータの構成

作成の背景

- 言語モデルの文章予測性能が高くても、主語と動詞の一致や、疑問詞と空所の関係を理解しているかは別に調べる必要があった。
- 語彙や構造の違いを小さくした対を多数作り、どの文法現象を見分けられるかを測る。

[1] Alex Warstadt et al. (2020). BLiMP: The Benchmark of Linguistic Minimal Pairs for English. TACL 8, 2020. https://aclanthology.org/2020.tacl-1.25/

収集と品質の確認

- 言語学者が作成した文法テンプレートと、 3,000 語以上の語彙を組み合わせて文の対を生成した。
- 67 パターンから各 5 対を抽出し、各対を 20 人が検証した。個々の判断と、多数決によるラベル一致を分けて報告している。

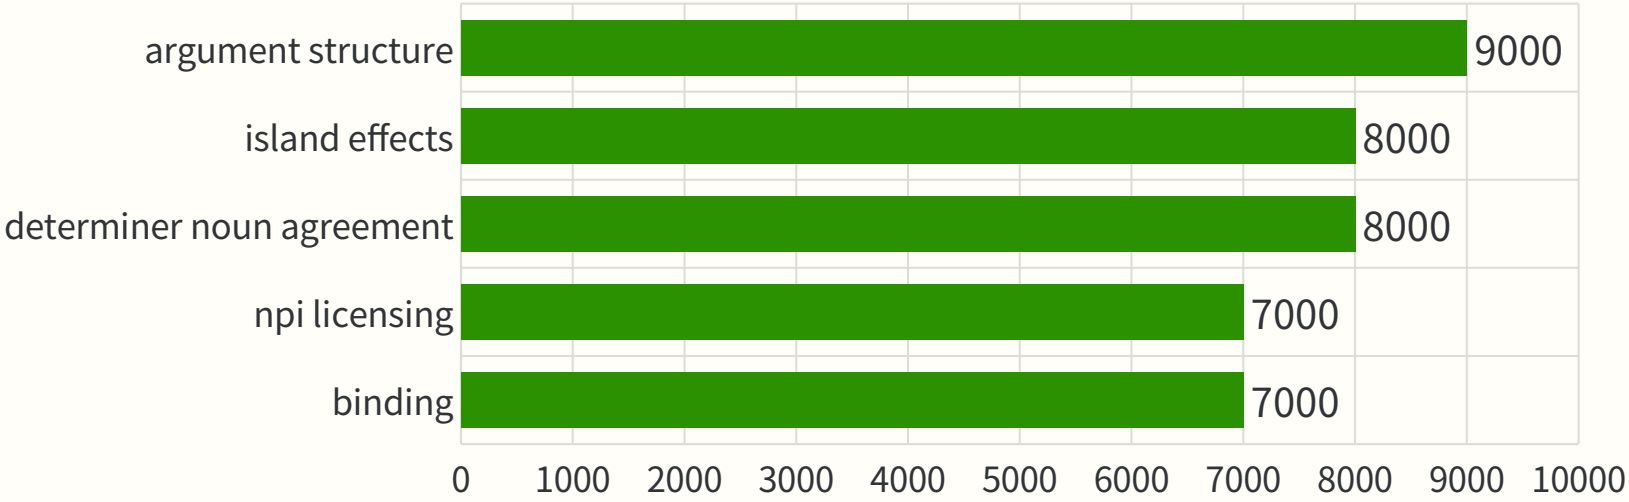
[1] Alex Warstadt et al. (2020). BLiMP: The Benchmark of Linguistic Minimal Pairs for English. TACL 8, 2020. https://aclanthology.org/2020.tacl-1.25/

分割と件数

集合・対象	件数	役割
67 パターン	各 1,000 対	合計 67,000 対
公式の用途	評価集合	各文の確率を比較する
公開ミラーの分割名	train	配布上の名称

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。
https://huggingface.co/datasets/nyu-mll/blimp

文法現象ごとの対の数



全 67,000 対。 12 大分類のうち件数上位 5 。 s-selection は項構造に統合。

[1] BLiMP 、 67 configurations/train 全 67,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/nyu-mll/blimp

採点方法とモデルの成績

何を 1 件として、どう採点するか

- 許容文の確率が非許容文の確率より高ければ正解とする。10 対中 8 対で高ければ、正解率は 80% 。
- 全文の確率を比べる基本方式のほか、共通の前半に続く部分だけを比べる方式もある。 HELM の表では全文を別々に採点する。

[1] Alex Warstadt et al. (2020). BLiMP: The Benchmark of Linguistic Minimal Pairs for English. TACL 8, 2020. https://aclanthology.org/2020.tacl-1.25/

初期の代表的な評価

2020 年の評価	全体の正解率（%）
5-gram	60.5
LSTM	68.9
GPT-2	80.1
人の直接判断	88.6

強制二択で評価。多数決ラベルの一致率 96.4% とは別の量。

[1] Alex Warstadt et al. (2020). BLiMP: The Benchmark of Linguistic Minimal Pairs for English. TACL 8, 2020. https://aclanthology.org/2020.tacl-1.25/

HELM での評価条件

- HELM は binding 、 irregular_forms 、 island_effects 、 quantifiers の 4 現象を評価した。
- 表は binding からの test 1,000 対。提示例 0 件、 1 試行、 multiple_choice_separate_original で文全体の尤度を比較する。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	正解率（%）	試行数
text-davinci-003 （2022）	82.40	1
Anthropic v4-s3 （2022）	82.50	1

binding の test 1,000 対、提示例 0 件、 1 試行。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

文法現象ごとの診断に利用される

- 大規模モデルの総合評価とは別に、英語のどの文法現象で失敗するかを比較できる。
- 2026-10-18 時点の Evaluation Harness にも BLiMP のパターン別定義がある。パターンの平均から、 12 の大分類へまとめた評価を読める。

[1] EleutherAI. Language Model Evaluation Harness. 2026-10-18 参照。 https://github.com/EleutherAI/lm-evaluation-harness

入手方法と利用条件

- 公式 GitHub は、 JSONL 形式の文の対と生成に関する情報を公開している。各ファイルが一つのパターンに対応する。
- 本資料は nyu-mll/blimp の固定改訂を用い、全 67,000 対を取得・集計した。
- データカードは CC BY 4.0 を掲げ、出典の表示を求めている。

[1] BLiMP 公式公開ページ。 2026-10-18 参照。 https://github.com/alexwarstadt/blimp

BLiMP の要点

- 67 パターンの最小対により、英語の文法現象ごとの知識を調べる。
- 日本語訳だけでは一致や語順の違反が見えにくい。英語の対と、変化した語・構造を対応させると課題が分かる。

[1] Alex Warstadt et al. (2020). BLiMP: The Benchmark of Linguistic Minimal Pairs for English. TACL 8, 2020. https://aclanthology.org/2020.tacl-1.25/

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：主語と動詞の一致

正解：上の文

許容文と非許容文／原文と日本語

Ann sees Tanya.
Ann see Tanya.

許容文の意味：アンはターニャを見る。
対立点：三人称単数の主語 Ann に対し、 sees から -s を除いている。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 regular_plural_subject_verb_agreement_1 / pair_id 915 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例２：過去分詞と過去形

正解：上の文

許容文と非許容文／原文と日本語

The taken pie is bad.
The took pie is bad.

許容文の意味：取られたパイはまずい。
対立点：名詞を修飾する過去分詞 taken を、過去形 took へ変えている。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 irregular_past_participle_adjectives / pair_id 833 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例３：否定極性表現

正解：上の文

許容文と非許容文／原文と日本語

Chad can not ever nod.
Chad can probably ever nod.

許容文の意味：チャドは決してうなずくことができない。
対立点：否定の not を probably へ置き換えると、否定極性表現 ever を認可できない。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 sentential_negation_npi_licensor_present / pair_id 235 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例 4 ：疑問詞と空所

正解：上の文

許容文と非許容文／原文と日本語

Tiffany sees a cafe that hurts Lori.
Tiffany sees who a cafe hurts Lori.

許容文の意味：ティファニーは、ローリを傷つけるカフェを見る。
対立点： that 節の主語に当たる空所と、 who の位置の対応を崩している。
意味が奇妙な文も含む。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 wh_questions_subject_gap / pair_id 373 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例 5 ：存在構文と量化詞

正解：上の文

許容文と非許容文／原文と日本語

There is a cake baking.
There is every cake baking.

許容文の意味：ケーキが 1 個、焼かれている。
対立点：存在構文 there is に続く a cake を、 every cake へ変えている。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 existential_there_quantifiers_1 / pair_id 469 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例 6 ：再帰代名詞の局所性

正解：上の文

許容文と非許容文／原文と日本語

Joel says that Beth helps him.
Joel says that Beth helps himself.

許容文の意味：ジョエルは、ベスが彼を助けると言っている。
対立点：埋め込み節の主語 Beth と一致しない himself を置き、再帰代名詞の局所性に違反する。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 principle_A_domain_1 / pair_id 906 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例 7 ：複合名詞句の島

正解：上の文

許容文と非許容文／原文と日本語

Who would a bird that found Marla find?
Who would Marla find a bird that found?

許容文の意味：マーラを見つけた鳥は、誰を見つけるだろうか。
対立点：複合名詞句の内部から疑問詞を取り出す、島の制約への違反を対比する。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 complex_NP_island / pair_id 662 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例 8 ：名詞句の省略

正解：上の文

許容文と非許容文／原文と日本語

Diana has one rough car and the lady has three.
Diana has one car and the lady has three rough.

許容文の意味：ダイアナはごつごつした車を 1 台持ち、その女性は 3 台持っている。
対立点：名詞を省略した three の後に、形容詞 rough だけを続けている。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 ellipsis_n_bar_1 / pair_id 74 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例９：動詞の項構造

許容文と非許容文／左：原文　右：日本語

Guy hides.
Guy sees.

正解：上の文

許容文の意味：ガイは隠れる。
対立点：生成テンプレートでは hide を自動詞、 see を目的語が必要な他動詞として扱っている。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 inchoative / pair_id 998 。 https://huggingface.co/datasets/nyu-mll/blimp

追加例 10 ：使役と自他

正解：上の文

許容文と非許容文／原文と日本語

Jason stretched Sara.
Jason fell Sara.

許容文の意味：ジェイソンはサラの体を伸ばした。
対立点：他動詞として使える stretched を、この使役用法を取れない fell へ変えている。

[1] nyu-mll/blimp 、改訂 877fba08 。 2026-10-18 参照。 causative / pair_id 223 。 https://huggingface.co/datasets/nyu-mll/blimp

集計と評価条件

12 大分類の全体像（ 1/2 ）

現象	対の数
anaphor agreement	2,000
argument structure	9,000
binding	7,000
control raising	5,000
determiner noun agreement	8,000
ellipsis	2,000

[1] BLiMP 、 67 configurations/train 全 67,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/nyu-mll/blimp

12 大分類の全体像（ 2/2 ）

現象	対の数
filler gap dependency	7,000
irregular forms	2,000
island effects	8,000
npi licensing	7,000
quantifiers	4,000
subject verb agreement	6,000

[1] BLiMP 、 67 configurations/train 全 67,000 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/nyu-mll/blimp

研究と参考文献

研究者と発表の位置付け

- 第一著者 Alex Warstadt 、最終著者 Samuel R. Bowman ら、 New York University の 7 名による研究。
- 言語学と自然言語処理の観点を合わせ、 TACL 2020 で 67 パターンの最小対を報告した。

[1] Alex Warstadt et al. (2020). BLiMP: The Benchmark of Linguistic Minimal Pairs for English. TACL 8, 2020. https://aclanthology.org/2020.tacl-1.25/

参考文献

BLiMP: The Benchmark of Linguistic Minimal Pairs for English

Alex Warstadt, Alicia Parrish, Haokun Liu, Anhad Mohananey, Wei Peng, Sheng-Fu Wang, Samuel R. Bowman / TACL 8, 2020

BLiMP の目的、作成方法、評価をまとめた研究。

https://aclanthology.org/2020.tacl-1.25/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

BLiMP ：公開データ

nyu-mll/blimp / 改訂 877fba08 / 2026-10-18 参照

原文・正解の 13 例と、対象集合の全件集計に用いた公開資源。

https://huggingface.co/datasets/nyu-mll/blimp