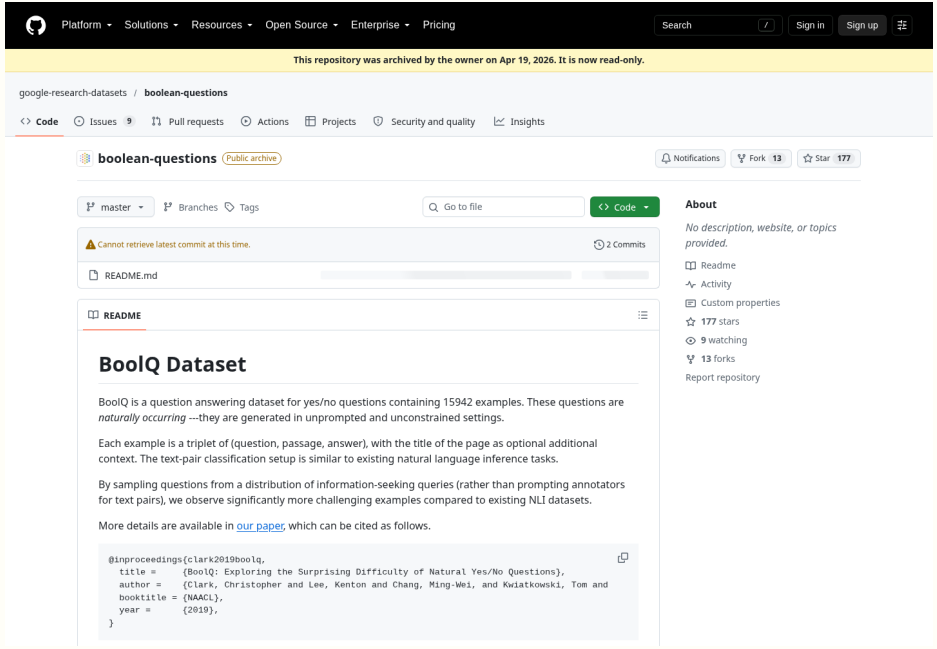
BoolQ

自然な Yes ／ No の質問を
段落を根拠に判定する

sasakiy84

BoolQ の公式公開ページ



[1] BoolQ 公式公開ページ。 2026-10-17 参照。 https://github.com/google-research-datasets/boolean-questions

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

段落を読んで、質問へ Yes か No で答える

- BoolQ は、自然に生じた英語の質問と Wikipedia の段落を組にした読解データセットである。答えは Yes か No で示す。
- 入力は質問と段落、正解は真偽のラベルである。本文から答えの文字列を抜き出す形式とは異なる。
- 否定、言い換え、数量、出来事の前後関係などを読み取り、段落が質問をどう裏付けるかを判断する。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

入力と正解の対応

配布フィールド	意味
question	ユーザーが検索時に入力した質問
passage	質問に関連する Wikipedia の段落
answer	True ＝ Yes 、 False ＝ No

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 https://huggingface.co/datasets/google/boolq

実例１：トマトピューレとソース

原文

Question: is pureed tomatoes the same as tomato sauce
Passage: Tomato purée is a thick liquid made by cooking and straining tomatoes. The difference between tomato paste, tomato purée, and tomato sauce is consistency; tomato puree has a thicker consistency and a deeper flavour than sauce.

日本語訳

正解： No

質問：トマトピューレはトマトソースと同じものですか。
段落：トマトピューレは、トマトを加熱して裏ごしした、とろみのある液体である。トマトペースト、トマトピューレ、トマトソースの違いは濃度にあり、ピューレはソースよりも濃厚で風味が強い。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 43 。 正解： No 。 https://huggingface.co/datasets/google/boolq

実例 1 の読み取り

- 同じ原料でも、濃度と風味が異なる。
- 質問と段落の表現を対応付け、配布ラベルの Yes ／ No がどの記述から分かるかを確認する。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 https://huggingface.co/datasets/google/boolq

実例２：代表選手のその後

関連する入力・回答／原文と日本語訳

正解： Yes

Question: did anyone from the 1980 us hockey team play in the nhl
Passage: Of the 20 players on Team USA, 13 eventually played in the NHL. Five of them went on to play over 500 NHL games, and three would play over 1,000 NHL games.

質問： 1980 年の米国アイスホッケー代表で、 NHL でプレーした選手はいますか。
段落：米国代表 20 人のうち、 13 人が後に NHL でプレーした。そのうち 5 人は 500 試合を超え、 3 人は 1,000 試合を超えて出場した。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 64 。 正解： Yes 。 https://huggingface.co/datasets/google/boolq

実例 2 の読み取り

- 13 人という記述が、少なくとも 1 人いたことを裏付ける。
- 質問と段落の表現を対応付け、配布ラベルの Yes ／ No がどの記述から分かるかを確認する。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 https://huggingface.co/datasets/google/boolq

実例３：形容詞の位置

原文

Question: do adjectives have to come before a noun
Passage: A postpositive or postnominal adjective is an attributive adjective that is placed after the noun or pronoun that it modifies. This contrasts with prepositive adjectives, which come before the noun or pronoun.

日本語訳

正解： No

質問：形容詞は名詞の前に置かなければなりませんか。
段落：後置形容詞とは、修飾する名詞や代名詞の後ろに置かれる限定用法の形容詞である。名詞や代名詞の前に置かれる前置形容詞とは対照的である。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 311 。 正解： No 。 https://huggingface.co/datasets/google/boolq

実例 3 の読み取り

- 後ろに置く用法があるので、必ず前とはいえない。
- 質問と段落の表現を対応付け、配布ラベルの Yes ／ No がどの記述から分かるかを確認する。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 https://huggingface.co/datasets/google/boolq

作成方法とデータの構成

質問を考える前に、答えを見せない

- 読解データでは、作業者が段落を読んでから質問を書くことが多かった。質問の語彙や内容が、提示された段落に引き寄せられやすい。
- BoolQ では、検索エンジンの利用者が自発的に入力した質問を先に集めた。特定の段落を見て質問を作るようには指示していない。
- 二択の質問でも、答えを導くのが簡単とは限らない。質問と段落の表現が異なる場合や、段落中の一部の記述を組み合わせる場合がある。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

検索質問と Wikipedia を結び付けた

- 検索ログから Yes ／ No 形式の質問を集め、検索結果に Wikipedia が含まれるものを候補にした。
- クラウドワーカーが記事中から関連する段落を選び、その段落に基づいて Yes ／ No を付けた。答えられないものは除外した。
- 質問と答えの関係を確認し、自然な質問に対して段落が根拠となる組を残した。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

No は「根拠が見つからない」ではない

- No は、質問への答えが否定となるラベルである。無関係な段落や、答えが分からない段落を一律に No とする設計ではない。
- トマトの実例では濃度の違いが否定の根拠となる。形容詞の実例では、後置する用法の存在が「必ず前に置く」を否定する。
- この区別を保つことで、文章からの推論と、知識が不足した場合の回答保留を混同せずに評価できる。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

分割と件数

集合	件数	役割
train	9,427	学習とプロンプト内の解答例に利用
validation	3,270	正解付きで公開された開発集合
test	3,245	論文のテスト集合。正解は一般公開されていない

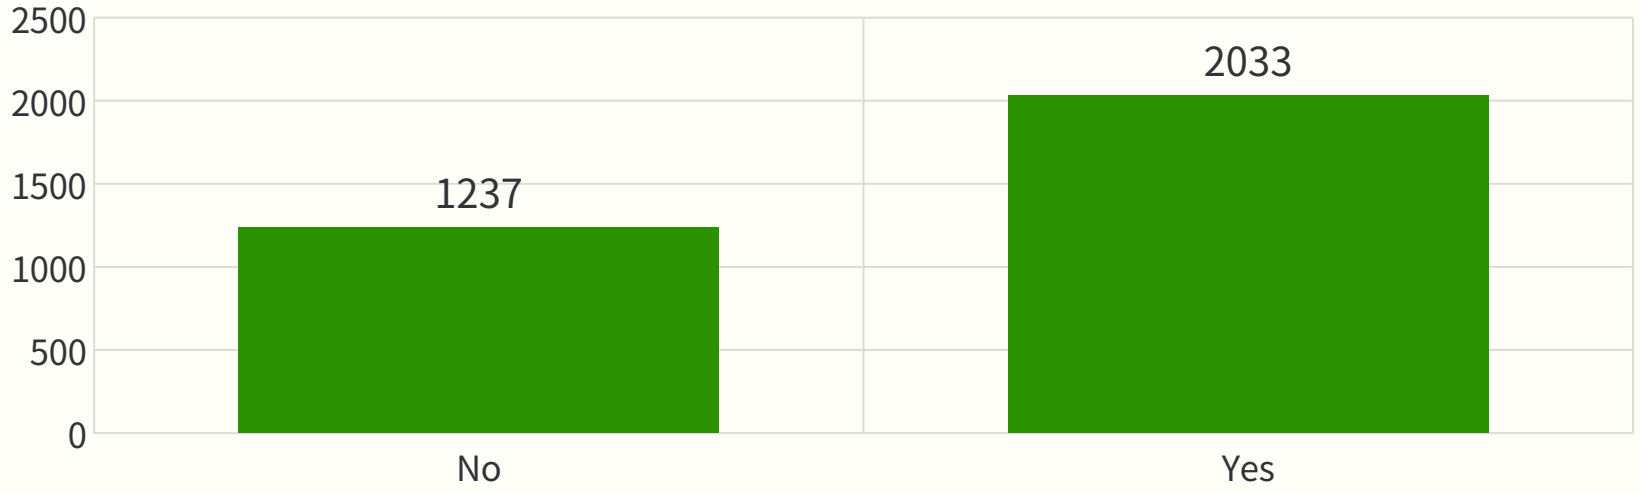
[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

Yes に答え続けても一定の点数になる

- 公開 validation では Yes が 2,033 問、 No が 1,237 問で、Yes は 62.17% を占める。
- 二択だから偶然の正解率が必ず 50% になるわけではない。クラス分布に合わせた多数派ベースラインも比較に使う。
- 実例は Yes ／ No の両方から選び、否定、別名、数量、翻案の順序など、異なる読み取りを含めた。

[1] google/boolq 、改訂 35b264d0 。 validation 全 3,270 件を集計。 https://huggingface.co/datasets/google/boolq

公開集合のラベル分布



validation 全 3,270 問。縦軸は質問数。

[1] google/boolq 、改訂 35b264d0 。 validation 全 3,270 件を集計。 https://huggingface.co/datasets/google/boolq

採点方法とモデルの成績

正解率は Yes ／ No 判定の平均である

- 1 問ごとに、予測した Yes ／ No が配布ラベルと一致すれば 1 、一致しなければ 0 とする。
- 正解率＝正しく答えた質問数 ÷ 評価した質問数。 1,000 問中 793 問なら 79.3% となる。
- HELM では答えを生成させ、大文字・小文字などを正規化して一致を測る quasi-exact match を使う。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

登場時の代表的な結果

2019 年の方法	テスト正解率
多数派の Yes を常に選ぶ	62.31%
BERT-Large	76.70%
BERT-Large ＋ MultiNLI での学習	80.43%

論文 Table 4 。 BoolQ の学習集合で微調整し、非公開のテスト集合で評価。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

HELM での評価条件

- HELM Classic v0.4.0 （ 2023-11-17 ）の公開結果を参照する。評価は validation の 1,000 問で、プロンプトに最大 5 問の解答例を示す。
- 表は canonical 設定の quasi-exact match 。 OPT と text-davinci-003 は例の選び方を変えた 3 試行、 Llama 2 は 1 試行である。
- 論文のテスト全件での微調整後の成績と、 HELM の少数例提示による成績は、それぞれの条件で読む。

[1] HELM Classic v0.4.0 。公開 run_specs と実行別 stats の canonical 設定を照合。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の比較

モデル	正解率	試行数
OPT-175B	79.30%	3
text-davinci-003	88.13%	3
Llama 2 70B	88.60%	1

valid 1,000 件、最大 5 例提示。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

得点と評価条件を一緒に読む

- この比較は、指定 URL が指す 2023 年 11 月 17 日の HELM Classic の結果である。現在の最高性能の一覧を意図していない。
- 少数例提示では、例題の選び方や、候補の並べ方、入力の長さが条件になる。表には評価集合と試行数を添えた。
- 正解率のほか、入力を少し変えた際の頑健性や、自信のある予測がどの程度正しいかも評価できる。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

転移学習の比較から汎用モデルの読解評価へ

- 2019 年の比較では、 MultiNLI で文章間の含意関係を学習してから BoolQ へ微調整する方法が有効だった。
- BoolQ は SuperGLUE にも組み込まれ、複数の課題をまとめた言語理解評価の一部として使われている。
- HELM では正解率に加え、入力の変化への頑健性や、回答への確信と正しさの関係も調べる。

[1] Wang et al. (2019). SuperGLUE: A Stickier Benchmark for General-Purpose Language Understanding Systems. NeurIPS. https://arxiv.org/abs/1905.00537

データの入手と利用

- 公式リポジトリは 2026 年 4 月にアーカイブされた。Google の公開ミラー google/boolq では、 train と validation の質問・段落・正解ラベルを読める。
- データは CC BY-SA 3.0 で公開されている。質問や段落を再利用する際は、配布元とライセンスを確認する。

[1] BoolQ 公式公開ページ。 2026-10-17 参照。 https://github.com/google-research-datasets/boolean-questions

公開データを読み込む

```
from datasets import load_dataset
ds = load_dataset("google/boolq",
                  revision="35b264d0")
example = ds["validation"][0]
print(example["question"])
```

この資料で照合した改訂を指定して読み込む。各フィールドの意味は本編の対応表を参照。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 https://huggingface.co/datasets/google/boolq

BoolQ の要点

- 自然な検索質問へ、 Wikipedia の段落を根拠に Yes ／ No で答える。答えの短さと、推論の簡単さは一致しない。
- 構築時には質問を先に集め、関連する段落と真偽のラベルを付けた。公開 validation は Yes が約 62% を占める。
- 微調整、少数例提示、評価集合の違いを条件に添えて、正解率と頑健性を読む。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：動脈と静脈

関連する入力・回答／原文と日本語訳

正解： No

Question: is there a right and left brachiocephalic artery
Passage: There is no brachiocephalic artery for the left side of the body. The left common carotid, and the left subclavian artery, come directly off the aortic arch. However, there are two brachiocephalic veins.

質問：腕頭動脈は左右にありますか。
段落：体の左側には腕頭動脈がない。左総頸動脈と左鎖骨下動脈は大動脈弓から直接分岐する。一方、腕頭静脈は２本ある。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 77 。 正解： No 。 https://huggingface.co/datasets/google/boolq

追加例 2 ：映画評価の 0%

関連する入力・回答／原文と日本語訳

正解： Yes

Question: is there a movie with 0 on rotten tomatoes
Passage: On the film review aggregation website Rotten Tomatoes, films that all surveyed critics consider bad have a 0% rating. Some of these are often considered some of the worst films ever made.

質問： Rotten Tomatoes で評価が 0% の映画はありますか。
段落：映画評の集約サイト Rotten Tomatoes では、集計対象の批評家全員が悪いと判断した映画の評価は 0% になる。その中には、史上最悪の映画の一つとされる作品もある。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 88 。 正解： Yes 。 https://huggingface.co/datasets/google/boolq

追加例３：ドラマの撮影地

関連する入力・回答／左：原文　右：日本語訳

Question: is anne with an e filmed on pei
Passage: The series is filmed partially in Prince Edward Island as well as locations in Southern Ontario (including Millbrook and Caledon).

正解： Yes

質問：『アンという名の少女』はプリンスエドワード島で撮影されていますか。
段落：このシリーズは、プリンスエドワード島のほか、オンタリオ州南部の各地（ミルブルックやカレドンを含む）でも撮影されている。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 94 。 正解： Yes 。 https://huggingface.co/datasets/google/boolq

追加例 4 ：へその呼び方

原文

Question: is navel and belly button the same thing
Passage: The navel (clinically known as the umbilicus, colloquially known as the belly button, or tummy button) is a hollowed or sometimes raised area on the abdomen at the attachment site of the umbilical cord. All placental mammals have a navel.

日本語訳

正解： Yes

質問： navel と belly button は同じものですか。
段落：へそ（医学的には umbilicus 、日常語では belly button や tummy button と呼ぶ）は、臍帯が付着していた腹部の、くぼんだ、または盛り上がった部分である。すべての有胎盤哺乳類にはへそがある。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 146 。 正解： Yes 。 https://huggingface.co/datasets/google/boolq

追加例 5 ：湖から海への航路

原文

Question: can you boat from lake michigan to atlantic ocean
Passage: The waterway allows passage from the Atlantic Ocean to the inland port of Duluth on Lake Superior, a distance of 2,340 miles (3,770 km) and to Chicago, on Lake Michigan, at 2,250 miles (3,620 km).

日本語訳

正解： Yes

質問：ミシガン湖から大西洋まで船で行けますか。
段落：この水路により、大西洋からスペリオル湖の内陸港ダルースまで 2,340 マイル（3,770km ）、ミシガン湖のシカゴまで 2,250 マイル（3,620km ）の航行が可能となる。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 183 。 正解： Yes 。 https://huggingface.co/datasets/google/boolq

追加例 6 ：英国の国民保険番号

原文

Question: do all ni numbers have a letter at the end
Passage: The format of the number is two prefix letters, six digits, and one suffix letter. The example used is typically QQ123456C. Often, the number is printed with spaces to pair off the digits, like this: QQ 12 34 56 C.

正解： Yes

日本語訳

質問：国民保険番号はすべて末尾が英字ですか。
段落：番号は、先頭の英字 2 文字、数字 6 桁、末尾の英字 1 文字からなる。通常、例には QQ123456C を使う。数字を 2 桁ずつ空白で区切り、 QQ 12 34 56 C のように印字することも多い。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 228 。 正解： Yes 。 https://huggingface.co/datasets/google/boolq

追加例 7 ：エンジンの別名

関連する入力・回答／原文と日本語訳

正解： No

Question: is there a difference between 2 cycle and 2 stroke
Passage: Two-stroke oil (also referred to as two-cycle oil, 2-cycle oil, 2T oil, 2-stroke oil or petroil) is a special type of motor oil intended for use in crankcase compression two-stroke engines.

質問： 2-cycle と 2-stroke には違いがありますか。
段落： 2 ストロークオイル（ two-cycle oil 、 2-cycle oil 、 2T oil 、 2-stroke oil 、 petroil とも呼ぶ）は、クランクケース圧縮式 2 ストロークエンジン用の特殊なエンジンオイルである。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 236 。 正解： No 。 https://huggingface.co/datasets/google/boolq

追加例 8 ：陸上の国境

原文

Question: is there a border between england and scotland
Passage: The Anglo-Scottish border between England and Scotland runs for 96 miles (154 km) between Marshall Meadows Bay on the east coast and the Solway Firth in the west. It is Scotland's only land border.

日本語訳

正解： Yes

質問：イングランドとスコットランドの間に国境はありますか。
段落：イングランドとスコットランドの境界は、東のマーシャル・メドウズ湾から西のソルウェー湾まで 96 マイル（ 154km ）続く。これはスコットランドで唯一の陸上の国境である。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 303 。 正解： Yes 。 https://huggingface.co/datasets/google/boolq

追加例 9 ：脚本から小説への順序

関連する入力・回答／原文と日本語訳

正解： No

Question: was the movie insomnia based on a book
Passage: Robert Westbrook adapted the screenplay to novel form, which was published by Alex in May 2002.

質問：映画『インソムニア』は本をもとに作られましたか。
段落：ロバート・ウェストブルックが脚本を小説化し、 2002 年 5 月に Alex から刊行された。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 350 。 正解： No 。 https://huggingface.co/datasets/google/boolq

追加例 10 ：フィクションか実話か

原文

Question: was the color purple based on a true story
Passage: The Color Purple is a 1982 epistolary novel by American author Alice Walker which won the 1983 Pulitzer Prize for Fiction and the National Book Award for Fiction. It was later adapted into a film and musical of the same name.

日本語訳

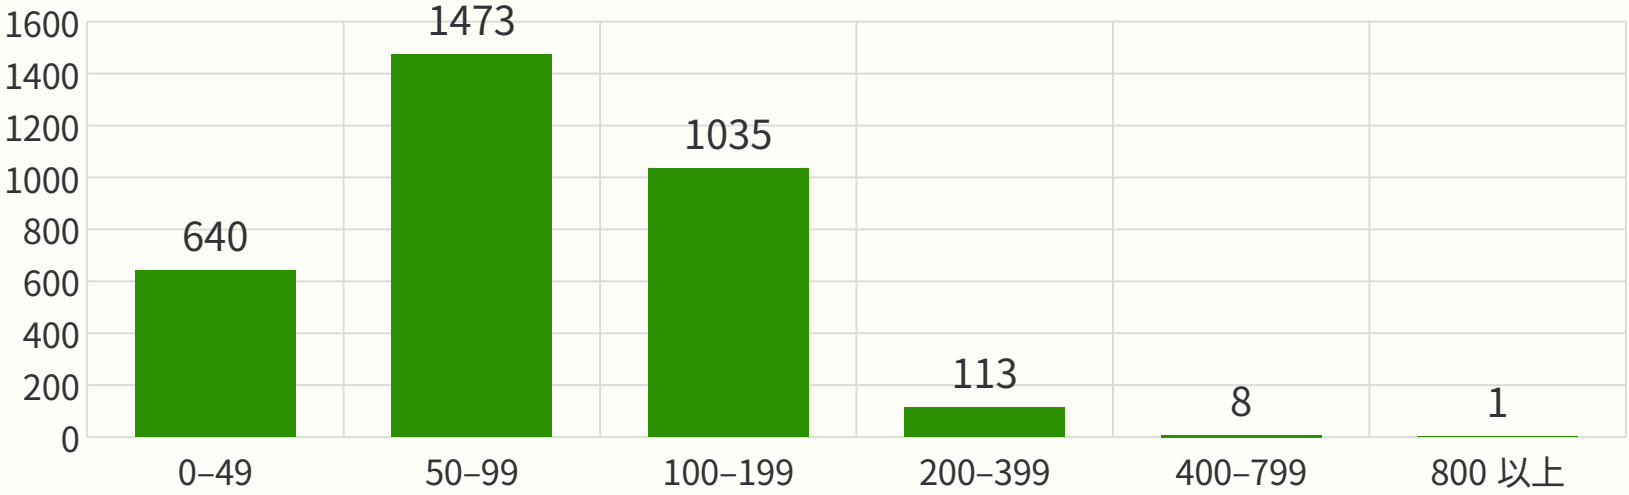
正解： No

質問：『カラーパープル』は実話をもとにしていますか。
段落：『カラーパープル』は米国の作家アリス・ウォーカーによる1982 年の書簡体小説で、 1983 年のピュリツァー賞小説部門と全米図書賞小説部門を受賞した。後に同名の映画とミュージカルになった。

[1] google/boolq 、改訂 35b264d0 。 2026-10-17 参照。 validation の 0 始まり行 367 。 正解： No 。 https://huggingface.co/datasets/google/boolq

集計と評価条件

入力の語数分布



validation 全 3,270 件。横軸は空白区切りの語数、縦軸は件数。

[1] google/boolq 、改訂 35b264d0 。 validation 全 3,270 件を集計。 https://huggingface.co/datasets/google/boolq

入力の長さを同じ方法で集計した

統計量	空白区切りの語数
平均	92.2
中央値	82.0
母標準偏差	55.0
最小	8.0
最大	813.0

入力は passage 。質問文とは別に集計。

[1] google/boolq 、改訂 35b264d0 。 validation 全 3,270 件を集計。 https://huggingface.co/datasets/google/boolq

集計の対象と測り方

- 対象は改訂 35b264d0 の validation 全 3,270 件。表示した 13 例だけの集計ではない。
- 語数は Python の str.split() による空白区切り。母標準偏差を用い、分位点は NumPy の線形補間で求めた。
- 図は 0 〜 49 、 50 〜 99 、 100 〜 199 、 200 〜 399 、 400 〜 799 、 800 以上の階級で、最後の階級に長い入力もすべて含める。

[1] google/boolq 、改訂 35b264d0 。 validation 全 3,270 件を集計。 https://huggingface.co/datasets/google/boolq

研究と参考文献

研究者と発表の位置付け

- Christopher Clark は、発表時にワシントン大学の Paul G. Allen School に所属していた。
- 最終著者の Kristina Toutanova らは Google AI Language の研究者として参加した。論文は NAACL-HLT 2019 で発表された。

[1] Christopher Clark et al. (2019). BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions. NAACL-HLT 2019. https://aclanthology.org/N19-1300/

参考文献

BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions

Christopher Clark, Kenton Lee, Ming-Wei Chang, Tom Kwiatkowski, Michael Collins, Kristina Toutanova / NAACL-HLT 2019

BoolQ の作成方法、実例、初期評価を報告した研究。

https://aclanthology.org/N19-1300/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

HELM のシナリオ、評価指標、少数例提示による多面的な比較をまとめる。

https://arxiv.org/abs/2211.09110

参考文献

BoolQ ：公開データと配布情報

google/boolq / 改訂 35b264d0 / 2026-10-17 参照

掲載した 13 例の原文・正解と、公開集合の全件集計を照合した。

https://huggingface.co/datasets/google/boolq

参考文献

SuperGLUE: A Stickier Benchmark for General-Purpose Language Understanding Systems

Alex Wang et al. / NeurIPS 2019

BoolQ を含む複数の言語理解課題と、統合した評価を提案した。

https://arxiv.org/abs/1905.00537