BUSTM

OPPO XiaoBu Dialogue Short Text Matching Dataset

小布助手の短い発話から、意味の一致を判定する

sasakiy84

公式公開元： OPPO 小布助手の BUSTM



README

小布助手对话短文本匹配数据集（BUSTM）

本数据集来自于OPPO小布助手。小布助手是OPPO公司为旗下多种品牌手机和IoT智能设备研发的智能助手，为上亿用户提供便捷的对话式服务。

意图识别是对话系统中的核心任务，而对话短文本语义匹配是意图识别的主流算法方案之一，在实际业务应用中会面临有监督样本不足等问题，迫切需要小样本条件下关键算法模型的突破。基于这个目的，特开放此数据集，希望能和业界同行一起促进相关算法技术的发展。

对话段文本语义匹配任务要求根据短文本query-pair，预测它们是否属于同一语义。

数据量：训练集（32），验证集（32），公开测试集（1772），测试集（2000），无标签语料（4251） 距离：{"id": 5, "sentence1": "女孩子到底是不是你", "sentence2": "你不是女孩子吗", "label": "1"} {"id": 18, "sentence1": "小影,你说话慢了", "sentence2": "那你说慢一点", "label": "0"}

数据链接

该数据集是FewCLUE评测基本的子任务之一，数据可以在以下链接下载：

https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

引用

@misc{BUSTM, title={BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset}, author={OPPO XiaoBu Conversational-AI Center}, year={2021}, howpublished={\url{https://github.com/xiaobu-coai/BUSTM}}, }

1 watching
0 forks
Report repository

© 2026 GitHub, Inc. Terms Privacy Security Status Community Docs Contact Manage cookies Do not share my personal information

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM

1. 二つの発話が同じ意味かを判定する
2. 少数の学習例と複数の分割
3. 正解率と 2021 年の到達水準
4. CLEVA での利用と公開範囲

二つの発話が同じ意味かを判定する

入力は二つの発話、答えは「同じ意味」かどうか

- BUSTM は、 OPPO の音声アシスタント「小布助手」に由来する、短文の意味照合データ。口語の二つの発話を読み、意味が一致するなら 1 、一致しないなら 0 を返す。
- 同じ操作の言い換えを見分けることは、利用者の意図を認識するために役立つ。話題や語句が似た発話から、依頼や質問の違いを読み取る。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM

実例１：言い方が違っても、怒りっぽさを尋ねる

中国語原文：二つの発話

1. 你的火气大吗
2. 你火气大不大

日本語訳

1. あなたは怒りっぽい？
2. あなたは怒りっぽいの？

正解：１（意味が一致する）

語尾や語順が違っても、問う内容は同じ。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例２：「歌って」と「曲を流して」を分ける

中国語原文：二つの発話

1. 给我唱首歌吧
2. 放首歌给我们听听

日本語訳

1. 私に歌を 1 曲歌って。
2. 私たちに曲を 1 曲流して。

正解：０（意味が一致しない）

歌う動作と、音楽を再生する動作の違い。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例３：通話中に画面が暗くなる

中国語原文：二つの発話

1. 通话时黑屏黑屏

2. 手机通话时黑屏

日本語訳

1. 通話中に画面が真っ暗、真っ暗。

2. 携帯電話で通話中に画面が真っ暗になる。

正解：１（意味が一致する）

繰り返しや言い換えがあっても、同じ症状を伝える。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

同じ話題でも、求める動作や時間を見分ける

- 「歌ってほしい」と「曲を流してほしい」は、音楽の話でも求める動作が違う。「けがをしそう」と「すでにけがをした」では、出来事が起きたかどうかが変わる。
- 入力には語順の崩れ、繰り返し、短い名詞句もある。口語の意図を、短い文字列から読み取る課題である。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

少数の学習例と複数の分割

元の会話サービスから、少数例の評価へ

小布助手は、スマートフォンや IoT 機器に対する依頼・質問の意図を認識する。

BUSTM は、このような短い口語の発話を二つずつ組にし、意味が一致するかをラベルで示す。

FewCLUE は、 32 件の学習例を使う少数例学習の課題として BUSTM を採用した。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM

32 件の学習例で、意味の対応を学べるかを調べる

- 教師ありデータを大量に用意しにくい実務上の課題を受け、OPPO は 2021 年に BUSTM を公開した。 FewCLUE は、中国語の少数例学習を比べる九つの課題の一つに採用した。
- BUSTM では、意味が一致する対と一致しない対を合わせて 32 件の学習例を用いる。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM
[2] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

学習・開発は 32 件、評価は千件単位

ファイル群	レコード数	正解ラベル
train_0 〜 4	各 32 （5 組）	あり
dev_0 〜 4	各 32 （5 組）	あり
test_public	1,772	あり
test	2,000	なし
unlabeled	4,251	なし

train_few_all と dev_few_all は、五つの小集合をまとめた各 160 件の配布。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

公開テストと、提出用テストを使い分ける

- test_public.json は正解を含み、研究用の実験に使える。test.json は入力のみで、 2021 年のコンテストでは予測結果を提出して評価を受ける集合だった。
- 学習・開発には五つの組があり、少数の例の選ばれ方による性能の揺れを調べられる。コンテスト第 2 段階では、五つの組とそれらをまとめた all の計六つの学習条件で評価した。

[1] CLUE team (2021). FewCLUE — README. https://github.com/CLUEbenchmark/FewCLUE/blob/main/README.md

1 行に二つの発話と正解ラベルを収める

```
{
  "id": 35,
  "sentence1": "你的火气大吗",
  "sentence2": "你火气大不大",
  "label": "1"
}
```

sentence1 と sentence2 が二つの発話。 label は文字列の "0" （不一致）または "1" （一致）。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

公開テストは、二つのラベルが同数

集合	0 ：不一致	1 ：一致	計
train_few_all	90	70	160
dev_few_all	82	78	160
test_public	886	886	1,772

学習・開発のラベルの割合は、組ごとに異なる。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

正解率と 2021 年の到達水準

正解率は、ラベルを正しく予測した発話対の割合

- 二つの発話から 0 または 1 を予測し、正解ラベルと一致した件数を、評価した発話対の数で割る。
- 公開テストは 1,772 対で、二つのラベルが同数ある。いつも同じラベルを予測する方法の正解率は 50% 。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

少数例の EFL は 71.8% 、直接微調整は 60.7%

2021 年の方式	BUSTM Accuracy (%)
一定ラベル（ Majority ）	50.0
RoBERTa ・ゼロショット	50.6
RoBERTa ・直接微調整	60.7
PET	56.0
P-tuning ・ RoBERTa	60.9
EFL	71.8

2021 年の公開テスト正解率。学習する方式は少数例を使う。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] CLUE team (2021). FewCLUE — README. https://github.com/CLUEbenchmark/FewCLUE/blob/main/README.md

予測の形式を変えて、少数例を生かす

- PET は二つの発話の関係を穴埋め形式に直し、同じ意味かを表す語を予測する。 P-tuning は、学習可能なプロンプト表現を加えてモデルを適応させる。
- EFL は各課題を含意判定へ直す方式。中国語へ翻訳した自然言語推論データ CMNLI で先に学習し、その後に少数例で微調整する。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

基盤モデルが変わると、方式ごとの結果も変わる

方式（ 2021 年）	RoBERTa	ERNIE 1.0
直接微調整	60.7	60.4
PET	56.0	58.4
P-tuning	60.9	60.8
EFL	71.8	54.6

BUSTM の正解率（ % ）。 RoBERTa 側は chinese_roberta_wwm_ext を使用。 EFL の結果は、基盤モデルによって 71.8% と 54.6% に分かれる。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

人間評価は 88% 、各注釈者が 100 問を解く

- 人間評価では、開発例 30 〜 50 件で正解と照らして議論した後、各注釈者がテスト例 100 件を解いた。 BUSTM で報告された正解率は 88% 。
- モデルの公開テスト 1,772 件に対し、人間は各 100 問で評価した結果である。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

公式 PET 実装は「相／不」を予測する

```
入力：sentence1 + "和" + sentence2 + "意思[MASK]同"

label = "1"  →  "相"  →  意思相同（同じ意味）
label = "0"  →  "不"  →  意思不同（異なる意味）
```

二つの発話をつなぐ文の穴を埋め、「同じ意味」か「異なる意味」かを予測する。

[1] CLUE team. pet_bustm.py 、 BUSTM 向け穴埋め形式・ラベル・採点の実装。
https://github.com/CLUEbenchmark/FewCLUE/blob/main/baselines/models_keras/pet/pet_bustm.py

CLEVA での利用と公開範囲

CLEVA は、短い発話の言い換え判定へ採用した

- 2023 年の CLEVA は、 CLUE と FewCLUE の発話対を二択形式に直し、同じことを述べているかを正解率で評価する。短い発話の課題に BUSTM を用いる。
- 実例 1 の「怒りっぽいか」を尋ねる二つの発話は、 CLEVA 論文にも掲載されている。 HELM にも同課題の評価実装が公開されている。
- CLEVA が評価に使った BUSTM の問題数は、公開説明には記されていない。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

公式配布から入手でき、利用条件の確認が必要

- OPPO の公式リポジトリは、 FewCLUE での BUSTM 配布を案内し、 2021 年のデータセットの引用方法を示している。
- OPPO のリポジトリにはライセンスが明示されていない。FewCLUE の README でも、ライセンス欄は「追加中」とされている。再利用・再配布の条件は配布元へ確認する。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM
[2] CLUE team (2021). FewCLUE — README. https://github.com/CLUEbenchmark/FewCLUE/blob/main/README.md

まとめ：口語の意味を、少数例で照合する

- BUSTM は、小布助手に由来する短い中国語発話対の二値判定データ。言い換え、異なる操作、時点や欲求の違いを扱い、学習・開発を各 32 件から始める。
- FewCLUE の公開テストは 1,772 件。 2021 年の EFL の報告正解率は 71.8% で、各 100 問を解いた人間評価は 88% 。後に CLEVA の短い発話の言い換え判定にも採用された。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

Appendix

1. 追加 10 対の原文と日本語訳
2. 入力の読み方と二択への変換
3. 参考文献

実例 4 ：好意と問いかけを含む二つの発話

中国語原文：二つの発話

1. 我喜欢你那你喜欢我吗

2. 你喜欢我不我也喜欢你

日本語訳

1. 私はあなたが好き。あなたは私が好き？

2. 私のことが好き？私もあなたが好き。

正解： 0 （意味が一致しない）

どちらも好意と問いかけを含むが、この対の正解ラベルは 0 。判断理由や対話履歴は付いていない。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 5 ：音声アシスタントを替えたい

中国語原文：二つの発話

1. 请求换一个语音助手
2. 能不能换一个语音助手？

日本語訳

1. 音声アシスタントの変更をお願いします。
2. 音声アシスタントを変更できる？

正解： 1 （意味が一致する）

依頼の表し方が変わっても、求める操作は同じ。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 6 ：音声で答えてほしい

中国語原文：二つの発話

1. 用语音来回答我你可以吗
2. 你可以用语音回答我吗

日本語訳

1. 音声で答えてもらえますか。
2. 音声で答えてくれますか。

正解： 1 （意味が一致する）

語順が違う、音声による応答の依頼。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 7 ：同じ単位換算でも、問う量は違う

中国語原文：二つの発話

1. 六十平方千米等于多少公顷

2. 一吨等于多少千克

日本語訳

1. 60 平方キロメートルは何ヘクタール？

2. 1 トンは何キログラム？

正解： 0 （意味が一致しない）

換算という話題だけでは、同じ内容の問いにならない。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 8 ：これからと、すでに起きたこと

中国語原文：二つの発話

1. 我刚要受伤
2. 我已经受伤了

日本語訳

1. 私は今にもけがをしそうだ。
2. 私はもうけがをしている。

正解： 0 （意味が一致しない）

けがが起きる前と、起きた後の違い。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例９：好みと、そのときの欲求

中国語原文：二つの発話

1. 我爱吃苹果
2. 我想吃苹果

日本語訳

1. 私はリンゴを食べるのが好きだ。
2. 私はリンゴを食べたい。

正解：０（意味が一致しない）

食べるのが好きなことと、食べたいという欲求は同じ意味ではない。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 10 ：連絡先の復元と、重複

中国語原文：二つの発話

1. 手机联系人恢复
2. 手机重复联系人

日本語訳

1. 携帯電話の連絡先を復元する。
2. 携帯電話の連絡先が重複している。

正解： 0 （意味が一致しない）

同じ連絡先という語を含んでも、問題と操作が異なる。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 11 ：ボタンを特定する問いか、名詞句か

中国語原文：二つの発話

1. 下面三个按钮，哪一个是菜单键

2. 下面那三个按钮

日本語訳

1. 下の三つのボタンのうち、どれがメニューボタン？

2. 下のあの三つのボタン。

正解： 0 （意味が一致しない）

同じボタンを指しても、名詞句だけではメニューボタンを尋ねたことにならない。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 12 ：崩れた語順を読み取る

中国語原文：二つの発話

1. 聊什么你想和我
2. 你想和我聊些什么

日本語訳

1. 何を話したいの、私と。
2. 私と何を話したいの？

正解： 1 （意味が一致する）

口語的に崩れた語順も収録されている。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

実例 13 ：表現そのものと、その意味を尋ねる

中国語原文：二つの発話

1. 阿伟死了
2. 阿伟死了是什么梗

日本語訳

1. 「アーウェイが死んだ」。
2. 「アーウェイが死んだ」とは、どういうネットのネタ？

正解： 0 （意味が一致しない）

同じ語句の使用と、その語句についての質問を分ける。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

入力の読み方と二択への変換

JSONL から二つの発話と正解を読み出す

```
import json
with open("train_0.json", encoding="utf-8") as f:
    pair = json.loads(next(f))
print(pair["sentence1"])
print(pair["sentence2"])
print("正解:", pair["label"])
```

train_0.json は 1 行に 1 対の JSON を収める。最初の発話対と、その正解ラベルを表示する。

[1] CLUE team (2021). FewCLUE — BUSTM. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

二択形式では「いいえ」「はい」から答える

下面这两个句子表达的意思是相同的吗？
1. 我喜欢你那你喜欢我吗
2. 你喜欢我不我也喜欢你
A. 不是
B. 是
答：

次の二つの文は同じ意味を表している？
1. 私はあなたが好き。あなたは私が好き？
2. 私のことが好き？私もあなたが好き。
A. いいえ
B. はい
答え：

正解： A （いいえ）

[1] Stanford CRFM. CLEVAParaphraseIdentificationScenario / Converter. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

参考文献

BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset

OPPO XiaoBu Conversational-AI Center · 2021 · 公式公開

スマートフォンと IoT 機器向けアシスタントの短文意味照合データ。 FewCLUE 配布へのリンクと引用方法を示す。

https://github.com/xiaobu-coai/BUSTM

FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark

Liang Xu, Xiaojing Lu, Chenyang Yuan, Xuanwei Zhang, Huilin Xu, Hu Yuan, Guoao Wei, Xiang Pan, Xin Tian, Libo Qin, Hai Hu · 2021 · arXiv:2107.07498v2

中国語の九つの少数例学習課題と、直接微調整・穴埋め形式・含意判定などの比較を報告する。

https://arxiv.org/abs/2107.07498

参考文献

FewCLUE — Official Dataset Distribution

CLUE team · 2021 · 公式配布

32 件ずつの学習・開発組、公開正解付きテスト、提出用入力、未ラベル対を JSONL 形式で公開する。

https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

FewCLUE — README and Evaluation Protocol

CLUE team · 2021 年の実験・コンテスト条件

公開テストと提出用テストの役割、複数学習条件の提出、人間評価とモデル比較、ライセンス欄を示す。

https://github.com/CLUEbenchmark/FewCLUE/blob/main/README.md

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al. · 2023 · EMNLP: System Demonstrations

中国語モデルを多様な課題で評価するプラットフォーム。短い発話対の言い換え判定に元データを採用する。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVAParaphraseIdentificationScenario / Converter

Stanford CRFM · HELM v0.4.0 · Python 実装

二つの発話を二択形式へ変換する課題。外部データ・テンプレートの読込と、正解参照の変換を実装する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

pet_bustm.py

CLUE team · FewCLUE 公式実装

発話対を穴埋め文に変え、「相」「不」のラベル語を予測する。学習・開発・公開テストの読込と採点を実装する。

https://github.com/CLUEbenchmark/FewCLUE/blob/main/baselines/models_keras/pet/pet_bustm.py