# BUSTM

OPPO XiaoBu Dialogue Short Text Matching Dataset

小布助手の短い発話から、意味の一致を判定する

sasakiy84

# 公式公開元： OPPO 小布助手の BUSTM



README

## 小布助手对话短文本匹配数据集（BUSTM）

本数据集来自于OPPO小布助手。小布助手是OPPO公司为旗下多种品牌手机和IoT智能设备研发的智能助手，为上亿用户提供便捷的对话式服务。

意图识别是对话系统中的核心任务，而对话短文本语义匹配是意图识别的主流算法方案之一，在实际业务应用中会面临有监督样本不足等问题，迫切需要小样本条件下关键算法模型的突破。基于这个目的，特开放此数据集，希望能和业界同行一起促进相关算法技术的发展。

对话段文本语义匹配任务要求根据短文本query-pair，预测它们是否属于同一语义。

数据量：训练集（32），验证集（32），公开测试集（1772），测试集（2000），无标签语料（4251） 距离：{"id": 5, "sentence1": "女孩子到底是不是你", "sentence2": "你不是女孩子吗", "label": "1"} {"id": 18, "sentence1": "小影,你说话慢了", "sentence2": "那你说慢一点", "label": "0"}

### 数据链接

该数据集是FewCLUE评测基本的子任务之一，数据可以在以下链接下载：

https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/bustm

### 引用

@misc{BUSTM, title={BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset}, author={OPPO XiaoBu Conversational-AI Center}, year={2021}, howpublished={\url{https://github.com/xiaobu-coai/BUSTM}}, }

1 watching
0 forks
Report repository

© 2026 GitHub, Inc. Terms Privacy Security Status Community Docs Contact Manage cookies Do not share my personal information

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM

1. 二つの発話が同じ意味かを判定する
2. 少数の学習例と複数の分割
3. 正解率と 2021 年の到達水準
4. CLEVA での利用と公開範囲

# 二つの発話が同じ意味かを判定する

# 入力は二つの発話、答えは「同じ意味」かどうか

- BUSTM は、 OPPO の音声アシスタント「小布助手」で使う短文の意味照合データ。口語の二つの発話を読み、意味が一致するなら 1 、一致しないなら 0 を返す。
- 同じ操作の言い換えを見分けることは、利用者の意図を認識するために役立つ。話題や語句が似ているだけでは、同じ依頼・質問とは限らない。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM

# 実例１：言い方が違っても、怒りっぽさを尋ねる

中国語原文：二つの発話

1. 你的火气大吗
2. 你火气大不大

日本語訳

1. あなたは怒りっぽい？
2. あなたは怒りっぽいの？

**正解：１（意味が一致する）**

語尾や語順が違っても、問う内容は同じ。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 train_few_all.json:36 行 / id=35
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例２：「歌って」と「曲を流して」を分ける

中国語原文：二つの発話

1. 给我唱首歌吧
2. 放首歌给我们听听

日本語訳

1. 私に歌を 1 曲歌って。
2. 私たちに曲を 1 曲流して。

**正解：０（意味が一致しない）**

歌う動作と、音楽を再生する動作の違い。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:11 行 / id=479
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例３：通話中に画面が暗くなる

中国語原文：二つの発話

1. 通话时黑屏黑屏

2. 手机通话时黑屏

日本語訳

1. 通話中に画面が真っ暗、真っ暗。

2. 携帯電話で通話中に画面が真っ暗になる。

**正解：１（意味が一致する）**

繰り返しや言い換えがあっても、同じ症状を伝える。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:17 行 / id=2363
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 同じ話題でも、求める動作や時間を見分ける

- 「歌ってほしい」と「曲を流してほしい」は、音楽の話でも求める動作が違う。「けがをしそう」と「すでにけがをした」では、出来事が起きたかどうかが変わる。
- 入力には語順の崩れ、繰り返し、短い名詞句もある。文法の整った文だけを比較する課題とは異なり、口語の意図を短い文字列から読み取る。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 少数の学習例と複数の分割

# 元の会話サービスから、少数例の評価へ

**小布助手**

発話の意味を照合し
意図認識に利用

→

**BUSTM**

口語の短い発話を
二つずつ組にする

→

**FewCLUE**

32 件の学習例で
意味の一致を学ぶ

スマートフォンや IoT 機器への依頼・質問を含む。意図のカテゴリ名を出すのではなく、二つの発話が同じ意味かを二値で判定する。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM

# 32 件の学習例で、意味の対応を学べるかを調べる

- 教師ありデータを大量に用意しにくい実務上の課題を受け、OPPO は 2021 年に BUSTM を公開した。 FewCLUE は中国語の少数例学習を比べる九つの課題の一つに採用した。
- FewCLUE では、ラベルが三種類以下の課題に合計 32 件の学習例を用意する。 BUSTM の 32 件は各ラベル 32 件ではなく、二つのラベルを合わせた件数。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM
[2] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

# 学習・開発は 32 件、評価は千件単位

| ファイル群 | レコード数 | 正解ラベル |
|---|---|---|
| train_0 ～ 4 | 各 32 （5 組） | あり |
| dev_0 ～ 4 | 各 32 （5 組） | あり |
| test_public | 1,772 | あり |
| test | 2,000 | なし |
| unlabeled | 4,251 | なし |

train_few_all と dev_few_all は各 160 行。五つの小集合をまとめた配布で、それぞれ異なる発話対は 156 種類。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

[2] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 公開テストと、提出用テストを使い分ける

- test_public.json は正解を含み、研究用の実験に使える。test.json は入力のみで、 2021 年のコンテストでは予測結果を提出して評価を受ける集合だった。
- 複数の学習・開発組を用意することで、少数の例の選ばれ方による揺れを調べる。コンテスト第 2 段階では 0 〜 4 と all の六つの学習条件ごとに test への予測を提出する。

[1] CLUE team. FewCLUE README 、公式の実験・提出・配布条件。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/README.md

# 一行に二つの発話と文字列の正解を持つ

```
{
  "id": 35,
  "sentence1": "你的火气大吗",
  "sentence2": "你火气大不大",
  "label": "1"
}
```

train_few_all.json の 36 行。 label は文字列の "0" または "1" 。 test と unlabeled には label 欄がない。 id はファイルをまたいで一意とは限らない。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 公開テストは、二つのラベルが同数

| 集合 | 0 ：不一致 | 1 ：一致 | 計 |
|---|---|---|---|
| train_few_all | 90 | 70 | 160 |
| dev_few_all | 82 | 78 | 160 |
| test_public | 886 | 886 | 1,772 |

固定版の全レコードを集計。学習の 5 組は、それぞれ必ず 16 対 16 になるわけではない。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 正解率と 2021 年の到達水準

# Accuracy は、配布ラベルと一致した対の割合

- 二つの発話から 0 または 1 を予測し、正解ラベルと一致した件数を評価件数で割る。 test_public の 1,772 対では、いつも同じラベルを出すだけなら 886 対が正しく、正解率は 50% 。
- 意味が近く見える対にも、配布ラベルが 0 の例がある。正解率を再現するときは元のラベルを使い、解釈だけで正解を付け替えない。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 少数例の EFL は 71.8% 、直接微調整は 60.7%

| 2021 年の方式 | BUSTM Accuracy (%) |
|---|---|
| 一定ラベル（ Majority ） | 50.0 |
| RoBERTa ・ゼロショット | 50.6 |
| RoBERTa ・直接微調整 | 60.7 |
| PET | 56.0 |
| P-tuning ・ RoBERTa | 60.9 |
| EFL | 71.8 |

2021 年の公開テスト正解率。学習する方式は少数例を使う。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] CLUE team. FewCLUE README 、公式の実験・提出・配布条件。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/README.md

# 予測の形式を変えて、少数例を生かす

- PET は二つの発話の関係を穴埋め形式に直し、同じ意味かを表す語を予測する。 P-tuning は、学習可能なプロンプト表現を加えてモデルを適応させる。
- EFL は各課題を含意判定へ直す方式。中国語へ翻訳した自然言語推論データ CMNLI で先に学習し、その後に少数例で微調整する。追加学習の条件も含めて結果を読む。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

# 基盤モデルが変わると、方式ごとの結果も変わる

| 方式（2021 年） | RoBERTa | ERNIE 1.0 |
|---|---|---|
| 直接微調整 | 60.7 | 60.4 |
| PET | 56.0 | 58.4 |
| P-tuning | 60.9 | 60.8 |
| EFL | 71.8 | 54.6 |

BUSTM Accuracy (%)。 RoBERTa 側は chinese_roberta_wwm_ext を基盤に使う。異なる基盤で、同じ手法が常に同じ改善を生むとは限らない。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

# 人間評価は 88% 、各注釈者が 100 問を解く

- 新しく加えた課題の人間評価では、まず開発例 30 〜 50 件を解き、正解と比べて議論する。その後、各注釈者がテスト例 100 件を解く手順を用いた。 BUSTM の公表正解率は 88% 。
- 人間評価の 100 問という単位は、モデルを評価する公開テスト全件とは異なる。少数例学習の性能を、人間の意味判断の到達水準と比較するための結果。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498

# 公式 PET 実装は「相／不」を予測する

```
入力：sentence1 + "和" + sentence2 + "意思[MASK]同"

label = "1"  →  "相"  →  意思相同（同じ意味）
label = "0"  →  "不"  →  意思不同（異なる意味）
```

PET 実装は train の指定組で学習し、 dev_few_all の正解率でモデルを選び、 test_public で評価する。

[1] CLUE team. pet_bustm.py 、 BUSTM 向け穴埋め形式・ラベル・採点の実装。
https://github.com/CLUEbenchmark/FewCLUE/blob/main/baselines/models_keras/pet/pet_bustm.py

# CLEVA での利用と公開範囲

# CLEVA は、短い発話の言い換え判定へ採用した

- 2023 年の CLEVA は、 CLUE と FewCLUE の発話対を二択形式に直し、同じことを述べているかを正解率で評価する。短い発話の下位課題 short_utterance として BUSTM を扱う。
- 公開論文の掲載例は、実例 1 の「怒りっぽいか」を尋ねる二つの発話と一致する。元データでは train_few_all の 36 行、train_1 の 4 行にある。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

# HELM には実装があり、公開実行は 0 件

- HELM v0.4.0 の CLEVAParaphraseIdentificationScenario は、実例 4 の「好きかどうか」を尋ねる対を掲載する。元ラベル 0 は、二択の A 「不是」（いいえ）へ対応する。
- short_utterance には prompt_id 0 〜 5 の六つの設定がある。Classic v0.4.0 公開 run_specs 全 8,526 件には CLEVA 実行がなく、実際の得点や提示例数、生成条件は確認できない。

[1] Stanford CRFM. CLEVAParaphraseIdentificationScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

# 元の配布と、 CLEVA の採用集合は別の範囲

| 対象 | 公開・確認できた範囲 |
| --- | --- |
| BUSTM 元データ | 公式が案内する FewCLUE の 15 ファイル |
| CLEVA 論文 | 言い換え判定の定義と、元データに一致する掲載例 |
| HELM 実装・設定 | 入力変換、二択の説明例、六つの prompt ID |
| CLEVA 全採用集合 | 外部評価 ZIP は未取得。元配布との同一性は未確認。 |

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM. CLEVAParaphraseIdentificationScenario / Converter. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

# 配布元は明確だが、利用許諾は確定していない

- OPPO の公式リポジトリは FewCLUE の BUSTM 配布を案内し、2021 年のデータセット引用を示す。元の発話はアシスタント利用に由来する。
- 取得した OPPO の固定ツリーにライセンスファイルはない。FewCLUE の固定 README でも License 欄は「追加中」となっている。公開されていることと、再配布や商用利用の許諾を同じものとして扱わない。

[1] OPPO XiaoBu Conversational-AI Center (2021). BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset. https://github.com/xiaobu-coai/BUSTM
[2] CLUE team. FewCLUE README 、公式の実験・提出・配布条件。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/README.md

# まとめ：口語の意味を、少数例で照合する

- BUSTM は小布助手に由来する短い中国語発話対の二値判定データ。言い換え、異なる操作、時点や欲求の違いを扱い、学習・開発を各 32 件から始める。
- FewCLUE の公開テストは 1,772 件で、 EFL の公表正解率は 71.8% 、人間評価は 88% 。 CLEVA での後利用を含め、正解付き元配布・提出用入力・未取得の採用集合を区別する。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

# Appendix

1. 追加 10 対の原文と日本語訳
2. 全ファイル・重複・形式の補足
3. 参考文献

# 実例 4 ：語句が近い対でも、配布ラベルを読む

中国語原文：二つの発話

1. 我喜欢你那你喜欢我吗

2. 你喜欢我不我也喜欢你

日本語訳

1. 私はあなたが好き。あなたは私が好き？

2. 私のことが好き？私もあなたが好き。

**正解： 0 （意味が一致しない）**

二つの発話は近いが、配布ラベルは 0 。追加の対話文脈や注釈理由は配布されていない。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 train_0.json:3 行 / id=2
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 5 ：音声アシスタントを替えたい

中国語原文：二つの発話

1. 请求换一个语音助手
2. 能不能换一个语音助手？

日本語訳

1. 音声アシスタントの変更をお願いします。
2. 音声アシスタントを変更できる？

**正解： 1 （意味が一致する）**

依頼の表し方が変わっても、求める操作は同じ。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:19 行 / id=408
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 6 ：音声で答えてほしい

中国語原文：二つの発話

1. 用语音来回答我你可以吗
2. 你可以用语音回答我吗

日本語訳

1. 音声で答えてもらえますか。
2. 音声で答えてくれますか。

**正解： 1 （意味が一致する）**

語順が違う、音声による応答の依頼。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:26 行 / id=2274
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 7 ：同じ単位換算でも、問う量は違う

中国語原文：二つの発話

1. 六十平方千米等于多少公顷

2. 一吨等于多少千克

日本語訳

1. 60 平方キロメートルは何ヘクタール？

2. 1 トンは何キログラム？

**正解： 0 （意味が一致しない）**

換算という話題だけでは、同じ内容の問いにならない。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:20 行 / id=1336
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 8 ：これからと、すでに起きたこと

中国語原文：二つの発話

1. 我刚要受伤
2. 我已经受伤了

日本語訳

1. 私は今にもけがをしそうだ。
2. 私はもうけがをしている。

**正解： 0 （意味が一致しない）**

けがが起きる前と、起きた後の違い。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:33 行 / id=2126
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例９：好みと、そのときの欲求

中国語原文：二つの発話

1. 我爱吃苹果
2. 我想吃苹果

日本語訳

1. 私はリンゴを食べるのが好きだ。
2. 私はリンゴを食べたい。

**正解：０（意味が一致しない）**

食べるのが好きなことと、食べたいという欲求は同じ意味ではない。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:41 行 / id=68
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 10 ：連絡先の復元と、重複

中国語原文：二つの発話

1. 手机联系人恢复
2. 手机重复联系人

日本語訳

1. 携帯電話の連絡先を復元する。
2. 携帯電話の連絡先が重複している。

**正解： 0 （意味が一致しない）**

同じ連絡先という語を含んでも、問題と操作が異なる。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:54 行 / id=2380
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 11 ：ボタンを特定する問いか、名詞句か

中国語原文：二つの発話

1. 下面三个按钮，哪一个是菜单键

2. 下面那三个按钮

日本語訳

1. 下の三つのボタンのうち、どれがメニューボタン？

2. 下のあの三つのボタン。

**正解： 0 （意味が一致しない）**

同じボタンを指しても、名詞句だけではメニューボタンを尋ねたことにならない。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:53 行 / id=2470
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 12 ：崩れた語順を読み取る

中国語原文：二つの発話

1. 聊什么你想和我
2. 你想和我聊些什么

日本語訳

1. 何を話したいの、私と。
2. 私と何を話したいの？

**正解： 1 （意味が一致する）**

口語的に崩れた語順も収録されている。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 test_public.json:12 行 / id=510
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 実例 13 ：表現そのものと、その意味を尋ねる

中国語原文：二つの発話

1. 阿伟死了
2. 阿伟死了是什么梗

日本語訳

1. 「アーウェイが死んだ」。
2. 「アーウェイが死んだ」とは、どういうネットのネタ？

**正解： 0 （意味が一致しない）**

同じ語句の使用と、その語句についての質問を分ける。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。 train_0.json:20 行 / id=19
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 全ファイル・重複・形式の補足

# 学習の五つの小集合は各 32 行

| ファイル | 0 ：不一致 | 1 ：一致 |
|---|---|---|
| train_0.json | 16 | 16 |
| train_1.json | 18 | 14 |
| train_2.json | 21 | 11 |
| train_3.json | 18 | 14 |
| train_4.json | 17 | 15 |

各ファイル 32 行・ 32 種類。小集合のラベル比率は組ごとに異なる。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 開発の五つの小集合は各 32 行

| ファイル | 0 ：不一致 | 1 ：一致 |
|---|---|---|
| dev_0.json | 15 | 17 |
| dev_1.json | 16 | 16 |
| dev_2.json | 18 | 14 |
| dev_3.json | 14 | 18 |
| dev_4.json | 19 | 13 |

各ファイル 32 行・ 32 種類。小集合のラベル比率は組ごとに異なる。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 集約・評価・未ラベルの五つのファイル

| ファイル | 行数 | 発話対の種類数 |
|---|---|---|
| train_few_all.json | 160 | 156 |
| dev_few_all.json | 160 | 156 |
| test_public.json | 1,772 | 1,772 |
| test.json | 2,000 | 2,000 |
| unlabeled.json | 4,251 | 4,251 |

「種類」は sentence1 と sentence2 を順序付きで比較した数。 train/dev の集約は、五つの小集合を重複込みでつないだ内容と一致。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 集約内の重複と、集合間の一致を区別する

- train_few_all と dev_few_all は各 160 行で、同一の順序付き発話対をまとめると各 156 種類になる。複数の小集合で選ばれた同じ対を、独立した新しい問題とは数えない。
- train_few_all 、 dev_few_all 、 test_public 、 test 、 unlabeled の全 10 組み合わせで、順序付き発話対の文字列完全一致は 0 だった。意味が近い表現まで分割間に存在しないことを示す検査ではない。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 公開テストの発話は、 1 件あたり平均 7.37 文字

| 対象 | 最短 | 最長 | 平均 |
|---|---|---|---|
| train_few_all | 3 | 15 | 7.33 |
| dev_few_all | 4 | 18 | 7.38 |
| test_public | 2 | 25 | 7.37 |
| test | 3 | 26 | 7.4 |
| unlabeled | 2 | 29 | 7.44 |

二つの発話を別々に数えた Unicode 文字数。空白・句読点を含み、トークン数とは異なる。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# HELM の説明例は、近い表現でも正解 A

下面这两个句子表达的意思是相同的吗？
1. 我喜欢你那你喜欢我吗
2. 你喜欢我不我也喜欢你
A. 不是
B. 是
答：

次の二つの文は同じ意味を表している？
1. 私はあなたが好き。あなたは私が好き？
2. 私のことが好き？私もあなたが好き。
A. いいえ
B. はい
答え：

**正解： A （いいえ）**

[1] Stanford CRFM. CLEVAParaphraseIdentificationScenario / Converter. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

# 正解理由が付かない対は、文脈を補わずに読む

- 実例 4 の二つの発話は、どちらも好意と相手への問いを含む。しかし、配布ラベルは 0 で、追加の対話履歴や個別の注釈理由は含まれていない。
- この資料では元ラベルを保持し、なぜ 0 になったかを推測で説明しない。ラベルの解釈や品質を調べる場合にも、元の発話対と正解を参照できる形が必要になる。

[1] CLUE team. FewCLUE / BUSTM 公式配布、 commit 62a02c6f31cf32814cfe522f78ef088228840f8d 、 2026-10-18 参照。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

# 参考文献

# 参考文献


## BUSTM: OPPO XiaoBu Dialogue Short Text Matching Dataset

OPPO XiaoBu Conversational-AI Center · 2021 · 公式公開

スマートフォンと IoT 機器向けアシスタントの短文意味照合データ。 FewCLUE 配布へのリンクと引用方法を示す。

https://github.com/xiaobu-coai/BUSTM

## FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark

Liang Xu, Xiaojing Lu, Chenyang Yuan, Xuanwei Zhang, Huilin Xu, Hu Yuan, Guoao Wei, Xiang Pan, Xin Tian, Libo Qin, Hai Hu · 2021 · arXiv:2107.07498v2

中国語の九つの少数例学習課題と、直接微調整・穴埋め形式・含意判定などの比較を報告する。

https://arxiv.org/abs/2107.07498

# 参考文献


## FewCLUE — Official Dataset Distribution

CLUE team · 固定 commit 62a02c6f31cf32814cfe522f78ef088228840f8d

32 件ずつの学習・開発組、公開正解付きテスト、提出用入力、未ラベル対を JSONL 形式で公開する。

https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/bustm

## FewCLUE — README and Evaluation Protocol

CLUE team · 2021 年の実験・コンテスト条件

公開テストと提出用テストの役割、複数学習条件の提出、人間評価とモデル比較、ライセンス欄を示す。

https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/README.md

# 参考文献


## CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al. · 2023 · EMNLP: System Demonstrations

中国語モデルを多様な課題で評価するプラットフォーム。短い発話対の言い換え判定に元データを採用する。

https://aclanthology.org/2023.emnlp-demo.17/

## CLEVAParaphraseIdentificationScenario / Converter

Stanford CRFM · HELM v0.4.0 · Python 実装

二つの発話を二択形式へ変換する課題。外部データ・テンプレートの読込と、正解参照の変換を実装する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

# 参考文献

## pet_bustm.py

CLUE team · FewCLUE 公式実装

発話対を穴埋め文に変え、「相」「不」のラベル語を予測する。学習・開発・公開テストの読込と採点を実装する。

https://github.com/CLUEbenchmark/FewCLUE/blob/main/baselines/models_keras/pet/pet_bustm.py

## run_specs_cleva_v1.conf

Stanford CRFM · HELM v0.4.0 · CLEVA 設定

短い発話対の下位課題 short_utterance について、 0 〜 5 の六つの prompt ID を登録する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf