C^3

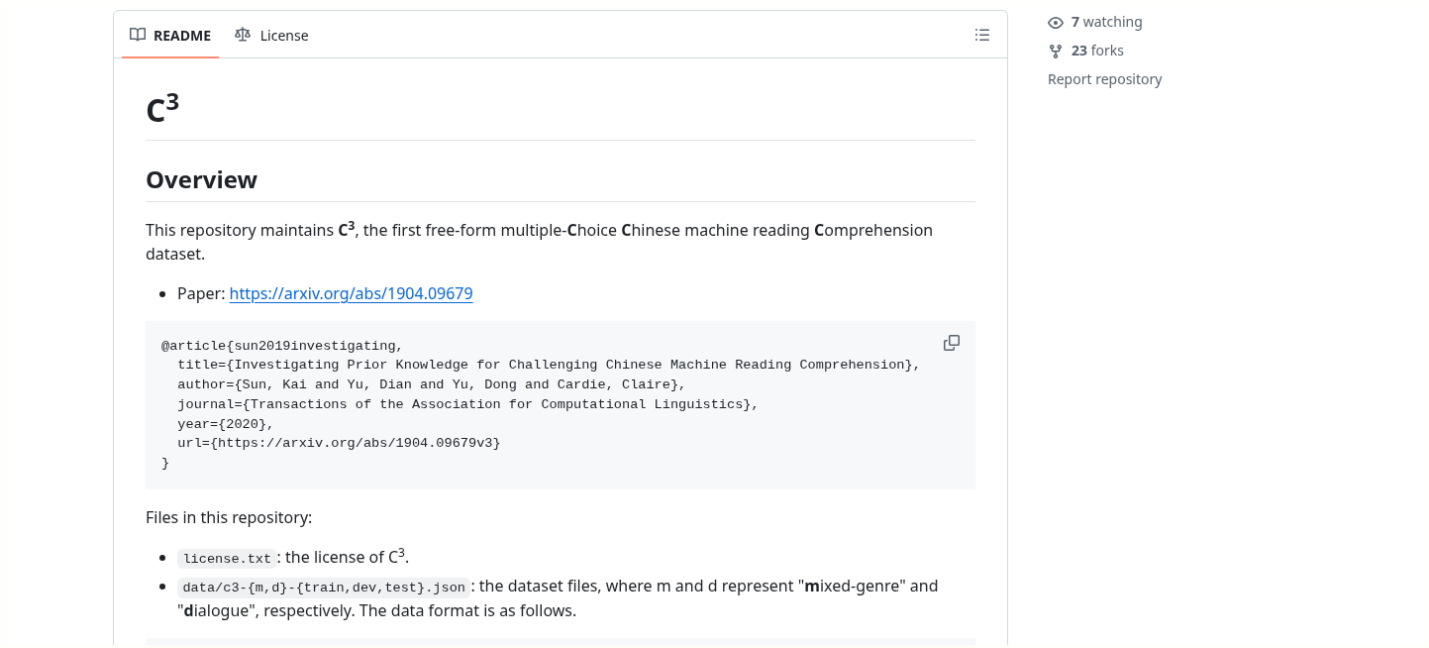
free-form multiple-Choice Chinese

machine reading Comprehension

中国語の対話や文章を読み、知識で答えを選ぶ

sasakiy84

C³ の公式公開リポジトリ



README License

C³

Overview

This repository maintains **C³**, the first free-form multiple-**C**hoice **C**hinese machine reading **C**omprehension dataset.

- Paper: https://arxiv.org/abs/1904.09679

```
@article{sun2019investigating,
  title={Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension},
  author={Sun, Kai and Yu, Dian and Yu, Dong and Cardie, Claire},
  journal={Transactions of the Association for Computational Linguistics},
  year={2020},
  url={https://arxiv.org/abs/1904.09679v3}
}
```

Files in this repository:

- `license.txt` : the license of C³.
- `data/c3-{m,d}-{train,dev,test}.json` : the dataset files, where m and d represent "**m**ixed-genre" and "**d**ialogue", respectively. The data format is as follows.

7 watching
23 forks
Report repository

[1] Sun et al. C³ 公式データ・実装。 https://github.com/nlpdata/c3

1. 文書から、正しい選択肢を選ぶ
2. 収集と、問われる知識
3. 正答率と構築時の性能
4. 公式データの入手と使い方

文書から、正しい選択肢を選ぶ

文書・質問・候補から、正解を一つ選ぶ

- C^3 は、中国語を第二言語として学ぶ人向けの試験問題から作られた選択式読解データ。対話と、物語・ニュース・独白・広告などの文章を含む。
- 入力は文書、自由な形式の質問、全選択肢。正解は必ず一つで、候補は 2 ～ 4 個ある。文章中の位置をそのまま抜き出す課題ではない。
- 2019 年に公開され、正式な研究論文は 2020 年に TACL へ掲載された。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/
[2] Sun et al. (2019). Probing Prior Knowledge Needed in Challenging Chinese Machine Reading Comprehension. https://arxiv.org/abs/1904.09679v1

実例１：父子の関係と、会話の不足

中国語原文（文書・質問・全選択肢）

女：听说你儿子跟你的关系不是很好？
男：说实话我不是一个好父亲，因为忙，没时间管他，我们之间几乎没有沟通。因为我，他也有很大的压力。
问题：男的和儿子的关系为什么不好？
A. 儿子态度不好
B. 双方缺少交流
C. 儿子工作很忙
D. 父亲压力太大

正解： B　双方缺少交流

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例１：父子の関係と、会話の不足（日本語訳）

日本語訳（文書・質問・全選択肢）

女：息子さんとの関係があまりよくないそうですね？
男：正直に言うと、私はよい父親ではありません。忙しくて息子の面倒を見る時間がなく、私たちの間にはほとんど会話がないんです。私のせいで、息子にも大きな重圧がかかっています。
質問：男性と息子の関係がよくないのはなぜですか？
A. 息子の態度が悪い
B. 双方の意思疎通が足りない
C. 息子が仕事で忙しい
D. 父親の重圧が大きすぎる

正解： B　双方の意思疎通が足りない

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

父親は、会話の不足を理由に挙げている

- 父親が理由として述べたのは、息子との会話がほとんどないこと。重圧がかかっているのは息子である。
- 父親が忙しいこと、会話がないこと、息子に重圧があることを、話者と因果関係に沿って結び付ける。

[1] Sun et al. C^3 データセット。 https://github.com/nlpdata/c3/tree/master/data

実例２：批判を受け止める人物像

中国語原文（文書・質問・全選択肢）

梅兰芳是中国著名的京剧演员。有一次，在他表演的时候，一位老人说他演得不好。梅兰芳当时觉得很奇怪。表演结束以后，他开车把那个老人接到了家里，很有礼貌地对老人说：“给我提意见的人就是我的老师。您说我演得不好，请您多帮助我啊。”老先生就告诉了他哪个地方演得不好。以后，梅兰芳表演的时候，都会请那位老人去看他表演，并且请他给自己提意见。
问题：梅兰芳是一个什么样的人？
A. 他是一位年纪大的老人
B. 他是喜欢看京剧的人
C. 他是一个很虚心的人
D. 他是一个没礼貌的人

正解：C　他是一个很虚心的人

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例２：批判を受け止める人物像（日本語訳）

日本語訳（文書・質問・全選択肢）

梅蘭芳は中国の有名な京劇俳優である。ある公演の最中、一人の老人が彼の演技はよくないと言った。梅蘭芳はそのとき不思議に思った。公演後、車で老人を自宅へ招き、とても礼儀正しくこう言った。「意見をくださる方は私の先生です。演技がよくないとおっしゃいましたね。どうかご指導ください。」老人は、どこがよくなかったのかを教えた。それ以後、梅蘭芳は公演のたびに老人を招いて見てもらい、意見を求めた。
質問：梅蘭芳はどのような人物ですか？
A. 年老いた老人である
B. 京劇を見るのが好きな人である
C. とても謙虚な人である
D. 礼儀を知らない人である

正解： C　とても謙虚な人である

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

行動から、人物の性格を判断する

- 批判した人を招き、以後も助言を求める行動から「虚心＝謙虚に学ぶ姿勢」を読み取る。
- 正解は「虚心」という人物の性質。本文の一部分を機械的に抜き出すだけではなく、複数の行動をまとめて解釈する。
- このような非対話文を C^3-Mixed 、二人以上の会話を C^3-Dialogue として分ける。どちらも質問と候補から答えを選ぶ。

[1] Sun et al. C^3 データセット。 https://github.com/nlpdata/c3/tree/master/data

実例３：到着時刻から出発時刻を逆算する

中国語原文・全文

从上海坐火车到北京需要 14 个小时，我明天早上 8 点到北京。
问题：他是几点出发的？
A. 20 点
B. 18 点
C. 19 点

日本語訳・全文

上海から北京までは列車で 14 時間かかる。私は明日の朝 8 時に北京へ着く。
質問：何時に出発しましたか？
A. 20 時
B. 18 時
C. 19 時

正解： B 18 点

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

本文の数値を、答えの時刻へ変換する

- 翌朝 8 時から 14 時間を引くと、前日の 18 時。本文に正解時刻そのものは書かれていない。
- 3 候補のうち B を選ぶ。正解を表す語句が本文にそのまま存在しなくても、本文と日常的な計算から導ける。
- C^3 の正解候補の 80.4 %は、本文からそのまま抜き出せない。読解には、表現の言い換えや一般常識の利用が含まれる。

[1] Sun et al. C^3 データセット。 https://github.com/nlpdata/c3/tree/master/data
[2] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

試験から集め、必要な知識を調べる

中国語の聴解・読解試験から収集

- 収集元は HSK （漢語水平考試）と MHK （民族漢語考試）。留学生、華僑、少数民族など、第二言語として中国語を学ぶ人の能力を測る試験である。
- インターネット上で公開された本試験と模擬試験を使い、重複する問題を除いた。聴解に由来する内容も、配布データではテキストとして扱う。
- 文書と付随する質問をまとめた問題単位で、学習 60 %・開発 20 %・テスト 20 %へ無作為に分けた。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

13,369 文書に、 19,577 問を収録

集合	Mixed 文書 / 問	Dialogue 文書 / 問	全体 文書 / 問
学習	3,138 / 6,013	4,885 / 5,856	8,023 / 11,869
開発	1,046 / 1,991	1,628 / 1,825	2,674 / 3,816
テスト	1,045 / 2,002	1,627 / 1,890	2,672 / 3,892
合計	5,229 / 10,006	8,140 / 9,571	13,369 / 19,577

一つの文書に複数の質問が付くため、文書数より質問数が多い。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

対話と単一テキストは、長さも異なる

特徴	Mixed	Dialogue
文書長：平均 / 最大	180.2 / 1,274 文字	76.3 / 1,540 文字
質問数：平均 / 最大	1.9 / 6 問	1.2 / 6 問
正解をそのまま抜き出せない割合	81.9 %	78.9 %
主な文書	物語・報道・広告	日常的な会話

文章の文字数は、構築時に報告された統計。対話は平均が短くても、長い問題がある。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

言語・専門・一般常識の知識を問う

- 言語知識：言い換え、語の意味、文法や談話上の関係。単語が一致しなくても、同じ内容を述べていると捉える。
- 専門知識：特定分野の知識。一般常識：計算、感情の含み、因果、含意、部分と全体、前提条件、場面、その他の 8 種に分ける。
- 開発・テストから計 600 問を抽出し、著者 2 人が必要な知識を注釈した。必要な知識は一問に複数付くことがある。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

知識が必要だった問題は、注釈 600 問の 86.8 %

注釈の観点	割合
ほぼそのままの語句照合	13.2 %
何らかの事前知識	86.8 %
うち言語知識	39.8 %
うち専門知識	0.8 %
うち一般常識	57.3 %

600 問＝ Mixed 300 ＋ Dialogue 300 （開発・テスト各 150 ）。知識種別は重複するため、下位割合は合計 100 %にならない。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

答えを支える範囲にも差がある

- 正解を明示的・暗示的に支える最小の文数も注釈した。 600 問の 36.7 %は 1 文、 62.0 %は複数文、 1.3 %は文脈に依存しない。
- Dialogue では 77.0 %が複数文に支えられる。離れた発言、話者の関係、省略された場面をつなぐ必要がある。
- 注釈者間の一致度は Cohen の $\kappa = 0.62$ 。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

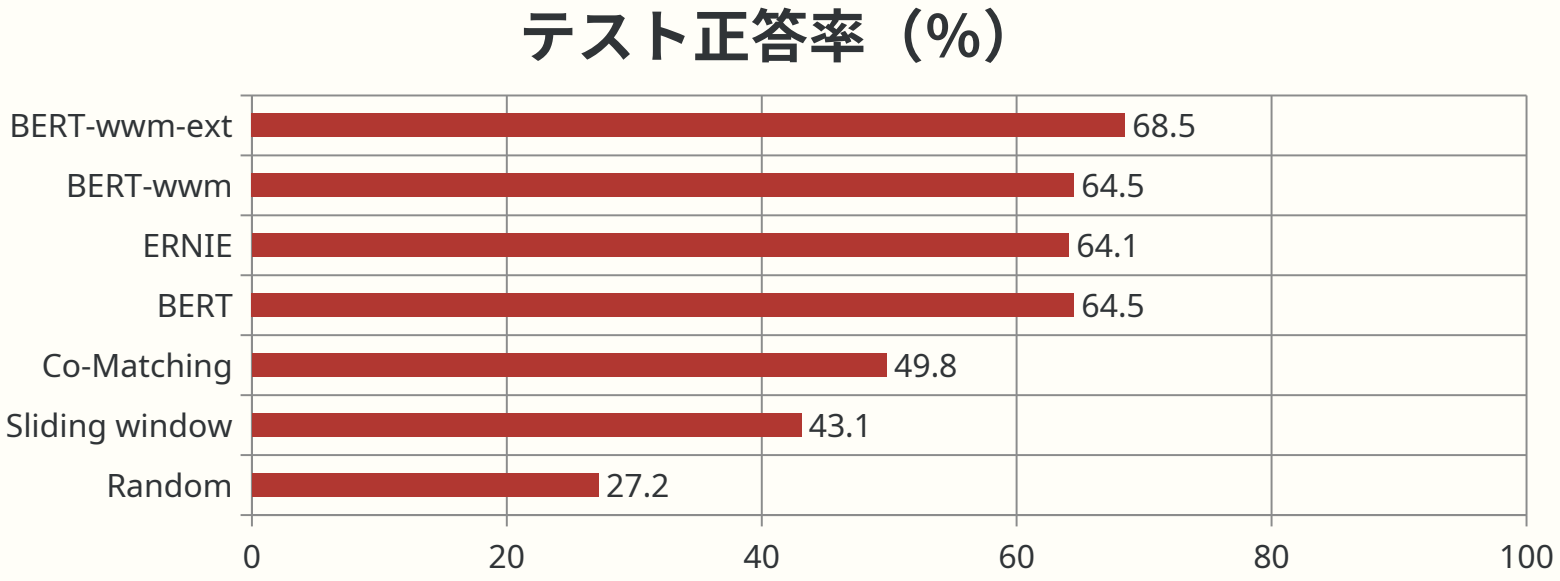
正答率と構築時の性能

正しい候補を選んだ割合で評価する

- 基本指標は正答率。正しい候補を選べた質問数を、評価した質問数で割る。
- BERT 系モデルを微調整して評価した。長い入力は、文書・質問・候補のうち最長の列から切り詰める。
- 候補の表面上の似方にも影響される。本文に似ているだけの誤答候補があると、正解を選びにくくなる。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

構築時のモデルは、テスト正答率 68.5 %



[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

人は注釈付きテスト部分で、 96.0 %の正答率

対象	Mixed test	Dialogue test	全体 test
BERT-wwm-ext ：全テスト	68.0 %	68.9 %	68.5 %
人：テストの 300 問	93.3 %	98.7 %	96.0 %

人の値は、知識注釈のあるテスト 300 問（ Mixed ・ Dialogue 各 150 問）で測ったもの。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

事前知識の必要な問題に、モデルは苦戦する

- 構築時の最良モデルと人の差は、特に事前知識を必要とする問題で大きかった。語句の表面的一致だけでは解きにくい例が多い。
- 誤答候補のもっともらしさ、英語の関連読解データを翻訳して増やす方法なども検討された。学習量と候補の作り方が性能へ影響する。
- C^3 は、文書と候補を与えた状態で、知識を使って正しい選択をする能力を測る。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

公式データの入手と使い方

公式データと知識注釈を JSON で取得する

- 公式リポジトリでは、文書・質問・候補・正解を含む 6 個の JSON と、 600 問の知識注釈が公開されている。
- テストを含む全問に正解が付き、各問の answer には、 choice に並んだ候補のうち正解の文字列が入る。正答率の評価に加え、知識注釈を使った問題種別の分析にも使える。
- license.txt に記載された利用条件は「非商用の研究目的のみ」である。

[1] Sun et al. C³ 公式データ・実装。 https://github.com/nlpdata/c3
[2] Sun et al. C³ 利用条件。 https://github.com/nlpdata/c3/blob/master/license.txt

C^3 は、文書と日常知識を結ぶ読解データ

- 中国語の試験から集めた 19,577 問。対話と多様な単一テキストを読み、２～４候補から唯一の正解を選ぶ。
- 語句照合だけでなく、言い換え・場面・因果・計算などが必要になる。 600 問の知識注釈が、その性質を具体的に示す。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

Appendix

1. 追加の公開実例
2. データの読み方
3. 研究と参考文献

追加の公開実例

実例 4 ：本文に明示された行動

中国語原文・全文

男：请问现在能预订晚上的座位吗？
女：可以。您贵姓？几位？
男：我姓张，两位。大概六点半到，麻烦给我留个靠窗的位置。
女：好，我们最晚给您保留到七点，请尽早过来。
问题：男的在做什么？
A. 看急诊
B. 开发票
C. 组织聚会
D. 预订座位

日本語訳・全文

男：今から今晩の席を予約できますか？
女：はい。お名前は？何名様ですか？
男：張と申します。２名です。６時半ごろ着きますので、窓際の席をお願いします。
女：承知しました。お席を確保できるのは７時までです。早めにお越しください。
質問：男性は何をしていますか？
A. 救急外来を受診している
B. 領収書を発行している
C. 集まりを企画している
D. 席を予約している

正解： D　预订座位

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 5 ：設備更新のための融資

中国語原文（文書・質問・全選択肢）

女：张总，银行来电话说我们的贷款申请批下来了。
男：太好了，贷款一到位我们就更新设备。
女：这样每个月的出货量大概能提高百分之三十。
男：对，让市场部抓紧时间多联系些新客户。
问题：他们想用那批贷款做什么？
A. 建分厂
B. 买新设备
C. 购买原料
D. 为职工上保险

正解： B　买新设备

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 5 ：設備更新のための融資（日本語訳）

日本語訳（文書・質問・全選択肢）

女：張社長、銀行から電話があり、融資の申請が承認されたそうです。
男：よかった。融資が実行されたら設備を更新しよう。
女：そうすれば毎月の出荷量をおよそ 30 %増やせます。
男：そうだな。マーケティング部には急いで新規顧客へもっと連絡するよう伝えてくれ。
質問：その融資で何をしようとしていますか？
A. 分工場を建てる
B. 新しい設備を買う
C. 原料を買う
D. 従業員に保険をかける

正解： B　新しい設備を買う

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例６：「もうすぐ着く」の言い換え

中国語原文・全文

女：喂，你到哪儿了？我们都在等你呢！
男：马上，我马上就到！我已经下了公交车了，正往你们那儿赶呢！
问题：从这段对话中，我们可以知道什么？
A. 女的很生气
B. 男的在车上
C. 男的就要到了
D. 女的挂了电话

日本語訳・全文

女：もしもし、今どこ？みんな待っているのよ！
男：すぐ、すぐ着くよ！もうバスを降りて、そっちへ急いでいるところ！
質問：この会話から何が分かりますか？
A. 女性はとても怒っている
B. 男性は車内にいる
C. 男性はもうすぐ着く
D. 女性は電話を切った

正解：C　男的就要到了

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例７：控えめな表現から評価を読む

中国語原文・全文

女：听说你去看昨天的演出了，怎么样？
男：一般吧，我看了一半就走了。
问题：男的觉得演出怎么样？
A. 不好
B. 很好
C. 特别好

日本語訳・全文

女：昨日の公演を見に行ったそうね。どうだった？
男：まあ普通かな。半分見たところで帰ったよ。
質問：男性は公演をどう思っていますか？
A. よくない
B. とてもよい
C. 非常によい

正解： A　不好

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 8 ：省略された道具を補う

中国語原文（文書・質問・全選択肢）

男：好，就站在那儿，笑一个。咦，怎么突然拍不了了？
女：刚才用的时候还好好的，不会突然坏了吧？
男：哦，应该是没电了，你带备用电池了吗？
女：没有，但是包里有充电器，要不找个地方充一下电吧。
问题：根据对话，可以知道什么？
A. 他们想去买电池
B. 男的不喜欢拍照
C. 照相机没电了
D. 女的不太高兴

正解： C　照相机没电了

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 8 ：省略された道具を補う（日本語訳）

日本語訳（文書・質問・全選択肢）

男：よし、そこに立って、笑って。あれ、急に撮れなくなったぞ？
女：さっきは普通に使えていたのに、急に壊れたんじゃないでしょうね？
男：ああ、たぶん電池切れだ。予備の電池は持ってきた？
女：持っていないけど、バッグに充電器がある。どこかで充電しようか。
質問：会話から何が分かりますか？
A. 電池を買いに行きたい
B. 男性は写真を撮るのが嫌い
C. カメラの電池が切れた
D. 女性はあまりうれしくない

正解： C　カメラの電池が切れた

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例９：毎週訪ねる家には、住んでいない

中国語原文・全文

我不住在这儿，这房子是我朋友的，他出国了。我每周来一次，帮他打扫一下房间，照顾一下花草。
问题：他住在朋友的房子里。
A. 正确
B. 错误

日本語訳・全文

私はここには住んでいない。この家は友人のもので、彼は外国へ行った。私は毎週１回来て、部屋を掃除したり、花や草の世話をしたりしている。
質問：彼は友人の家に住んでいる。
A. 正しい
B. 誤り

正解： B　错误

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 10 ：貸出期間を足し合わせる

中国語原文・全文

这本书我已经从图书馆借了二十天了，我还没有看完呢，还有十天就该还了。
问题：这本书他可以借 30 天。
A. 正确
B. 错误

日本語訳・全文

この本を図書館から借りて、もう 20 日になる。まだ読み終えておらず、あと 10 日で返さなければならない。
質問：この本は 30 日間借りられる。
A. 正しい
B. 誤り

正解： A　正确

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 11 ：説明しない理由を読む

中国語原文・全文

“你为什么不跟他们说清楚，让他们知道这不是你的错呢？”我生气地问哥哥。
“他们已经这样认为了，说了他们也不会相信的，事情也不会有什么变化，那我为什么还要说？”
问题：哥哥不说，是因为：
A. 没办法说清楚
B. 他们听不明白
C. 觉得说也没用

日本語訳・全文

「どうして彼らにはっきり説明して、あなたのせいではないと分かってもらわないの？」と私は怒って兄に聞いた。「もうそう思い込んでいるんだ。説明しても信じないだろうし、何も変わらない。それなら、どうして説明する必要がある？」
質問：兄が説明しないのは、なぜですか？
A. うまく説明できない
B. 相手には説明が理解できない
C. 説明しても無駄だと思う

正解： C　觉得说也没用

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 12 ：救助の動機を読み直す

中国語原文（文書・質問・全選択肢）

小吉姆勇敢地走过薄薄的冰层，救起了掉进水里的朋友。他成了大家心目中的英雄。“你冒着生命危险救了你的朋友一命！”大家钦佩地说。“没办法，”小吉姆说，“他穿着我新买的冰鞋呢。”
问题：请选出与试题内容一致的一项。
A. 小吉姆掉进了水里
B. 小吉姆是为了冰鞋而救朋友的
C. 大家都觉得小吉姆非常聪明
D. 朋友把小吉姆的冰鞋扔进了水里

正解： B 小吉姆是为了冰鞋而救朋友的

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 12 ：救助の動機を読み直す（日本語訳）

日本語訳（文書・質問・全選択肢）

幼いジムは勇敢にも薄い氷の上を渡り、水に落ちた友人を助け上げた。みんなにとって彼は英雄になった。「命を懸けて友達を救ったんだね！」と人々は感心して言った。「仕方なかったんです」とジムは言った。「彼が、ぼくの買ったばかりのスケート靴を履いていたので。」
質問：本文の内容と一致するものを選んでください。
A. ジムが水に落ちた
B. ジムはスケート靴のために友人を助けた
C. みんなはジムがとても賢いと思った
D. 友人がジムのスケート靴を水へ投げ込んだ

正解： B　ジムはスケート靴のために友人を助けた

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 13 ：東西の関係を反転する

中国語原文・全文

学校西边有书店，东边有公园和邮局，还有一个新开的超市。
问题：学校在超市的：
A. 西边
B. 东边
C. 南边

日本語訳・全文

学校の西側には書店があり、東側には公園と郵便局、それから新しくできたスーパーがある。
質問：学校はスーパーのどちら側にありますか？
A. 西側
B. 東側
C. 南側

正解： A　西边

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

実例 1 〜 5 ：答えを支える手掛かり

実例	読み取ること
1	父親が明言する「ほとんど会話がない」が理由。重圧がかかっているのは息子。
2	批判した人を招き、以後も助言を求める行動から「虚心＝謙虚に学ぶ姿勢」を読み取る。
3	翌朝 8 時から 14 時間を引くと、前日の 18 時。本文に正解時刻そのものは書かれていない。
4	「预订」と「预订座位」が直接対応する。知識注釈は語句照合／ 1 文。
5	融資を受けた後に設備を更新する。知識注釈は前提条件／複数文。

表の「知識注釈」は公開注釈に基づく。その他は解答の解説。

[1] Sun et al. C³ 知識注釈。 https://github.com/nlpdata/c3/tree/master/annotation

実例 6 〜 9 ：答えを支える手掛かり

実例	読み取ること
6	「马上就到」と「就要到了」が対応する。知識注釈は言語知識／複数文。
7	「一般吧」だけでなく、途中で帰った行動も評価の手掛かり。知識注釈は含みのある感情・語調／複数文。
8	撮影、電池、充電器からカメラだと補う。知識注釈は場面の知識／複数文。
9	毎週訪ねていても、その家に住んでいるわけではない。知識注釈は言語知識／１文。

[1] Sun et al. C³ 知識注釈。 https://github.com/nlpdata/c3/tree/master/annotation

実例 10 〜 13 ：答えを支える手掛かり

実例	読み取ること
10	経過した 20 日と残り 10 日を足す。知識注釈は算術と言語知識／ 1 文。
11	反語と理由のつながりを読み、「言っても仕方がない」という判断を選ぶ。知識注釈は言語知識と因果／複数文。
12	スケート靴のための救助。知識注釈は因果／複数文。
13	スーパーは学校の東側なので、学校はスーパーの西側。知識注釈は一般常識の「その他」／ 1 文。

[1] Sun et al. C³ 知識注釈。 https://github.com/nlpdata/c3/tree/master/annotation

データの読み方

2 〜 4 個の候補から、一つを選ぶ

候補数	質問数	全 19,577 問に占める割合
2 候補	894	4.57 %
3 候補	2,389	12.20 %
4 候補	16,294	83.23 %

2 候補の真偽問題も、正解を一つ選ぶ同じ形式で収録される。

[1] Sun et al. C³ 公式データ・実装。 https://github.com/nlpdata/c3

JSON から、実例 1 の文書と設問を読む

```
import json
with open("c3-d-train.json", encoding="utf-8") as f:
    rows = json.load(f)
document, questions, _ = next(r for r in rows if r[2] == "37-153")
question = questions[0]
print("\n".join(document))
print(question["question"])
print(question["choice"])
print(question["answer"])
```

実例 1 の文書、質問、全選択肢、正解の文字列が得られる。

[1] Sun et al. C³ データセット。 https://github.com/nlpdata/c3/tree/master/data

研究と参考文献

中国語の読解で、事前知識を分析する

- Kai Sun 、 Dian Yu 、 Dong Yu 、 Claire Cardie による共同研究。中国語の自由な質問形式の選択式読解を整備し、知識が必要な問題を分類した。
- 英語の RACE と DREAM に対応する、中国語の単一テキスト・対話の両方を含む。既存の中国語データで多かった抜き出し型の読解を補う位置付けを持つ。
- 公開データと注釈が分かれているため、全体を使った正答率の評価と、 600 問を使った知識種別の分析を組み合わせられる。

[1] Sun et al. (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL. https://aclanthology.org/2020.tacl-1.10/

参考文献

Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension

Kai Sun, Dian Yu, Dong Yu, Claire Cardie · 2020 · TACL 8:141–155

C^3 の収集、 Dialogue/Mixed 、知識注釈と構築時の評価を記述する正式論文。

https://aclanthology.org/2020.tacl-1.10/

Probing Prior Knowledge Needed in Challenging Chinese Machine Reading Comprehension

Kai Sun, Dian Yu, Dong Yu, Claire Cardie · 2019 · arXiv:1904.09679v1

C^3 を初めて公開したプレプリント。後続版と正式刊行では題名が Investigating へ変わる。

https://arxiv.org/abs/1904.09679v1

参考文献

C³: official data, annotations and baseline instructions

Kai Sun et al. (n.d.). nlpdata/c3 。参照 2026-10-19 。

元の 6 データファイル、 4 知識注釈、基準モデルの実行方法、利用条件を公開する。

https://github.com/nlpdata/c3

C³: data usage conditions

Kai Sun et al. (n.d.). 公式利用条件。参照 2026-10-19 。

元データの利用を非商用の研究目的に限定する。

https://github.com/nlpdata/c3/blob/master/license.txt