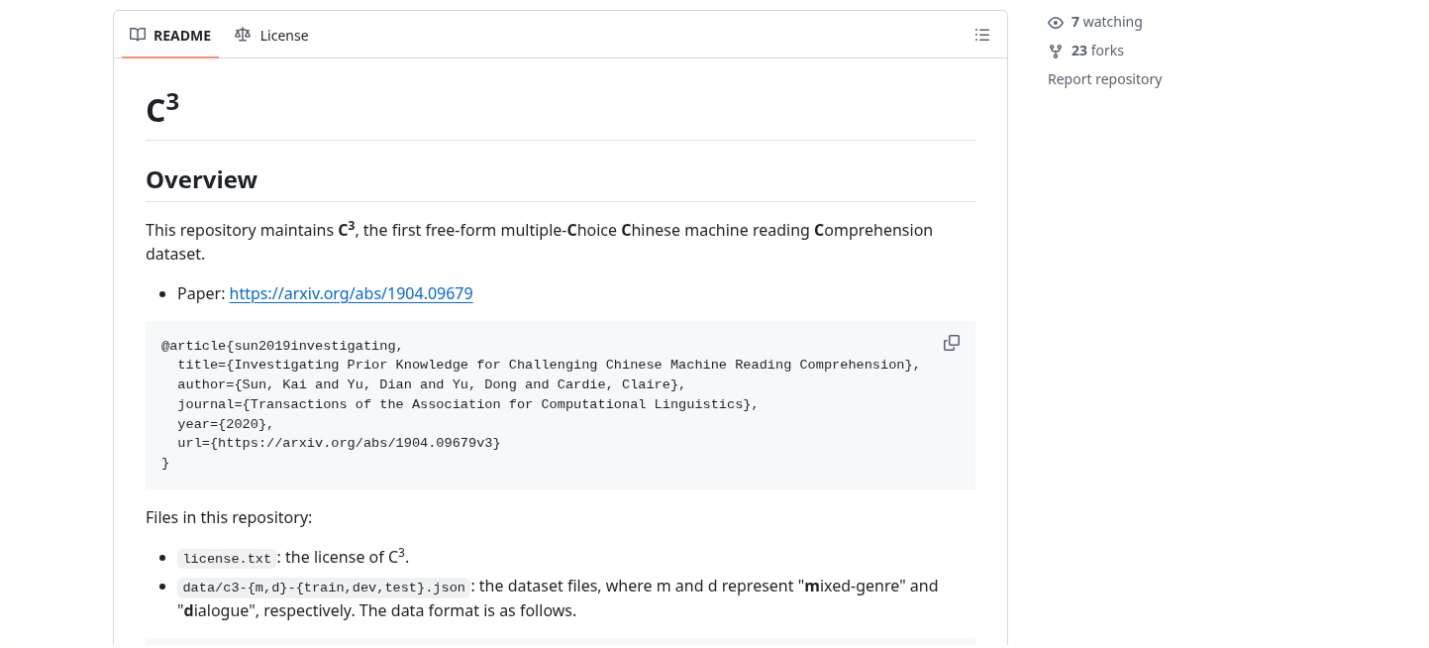
C^3

free-form multiple-Choice Chinese
machine reading Comprehension

中国語の対話と文章で、知識を伴う読解を問う

sasakiy84

C³ の公式公開リポジトリ



README License

C³

Overview

This repository maintains **C³**, the first free-form multiple-**C**hoice **C**hinese machine reading **C**omprehension dataset.

- Paper: https://arxiv.org/abs/1904.09679

```
@article{sun2019investigating,
  title={Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension},
  author={Sun, Kai and Yu, Dian and Yu, Dong and Cardie, Claire},
  journal={Transactions of the Association for Computational Linguistics},
  year={2020},
  url={https://arxiv.org/abs/1904.09679v3}
}
```

Files in this repository:

- `license.txt` : the license of C³.
- `data/c3-{m,d}-{train,dev,test}.json` : the dataset files, where m and d represent "**m**ixed-genre" and "**d**ialogue", respectively. The data format is as follows.

7 watching
23 forks
Report repository

[1] Sun et al. C³ official repository. commit 1f41682e. https://github.com/nlpdata/c3

1. 文書から、正しい選択肢を選ぶ
2. 収集と、問われる知識
3. 評価と歴史的な性能
4. CLUE ・ CLEVA での利用

書かれたことと、分かることをつなぐ

文書・質問・候補から、正解を一つ選ぶ

- C^3 は、中国語を第二言語として学ぶ人向けの試験問題から作られた選択式読解データ。対話と、物語・ニュース・独白・広告などの文章を含む。
- 入力は文書、自由な形式の質問、全選択肢。正解は必ず一つで、候補は 2 ～ 4 個ある。文章中の位置をそのまま抜き出す課題ではない。
- 2019 年に公開され、正式な研究論文は 2020 年に TACL へ掲載された。後に CLUE や CLEVA の読解課題にも採用された。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

[2] Sun et al. (2019). Probing Prior Knowledge Needed in Challenging Chinese Machine Reading Comprehension. arXiv:1904.09679v1. https://arxiv.org/abs/1904.09679v1

実例１：父子の関係と、会話の不足

C³-Dialogue / train / ID 37-153 / 質問 1

中国語原文（文書・質問・全選択肢）

女：听说你儿子跟你的关系不是很好？
男：说实话我不是一个好父亲，因为忙，没时间管他，我们之间几乎没有沟通。因为我，他也有很大的压力。
问题：男的和儿子的关系为什么不好？
A. 儿子态度不好
B. 双方缺少交流
C. 儿子工作很忙
D. 父亲压力太大

正解： B　双方缺少交流

[1] Sun et al. C³-D / train / 37-153 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-train.json

実例１：父子の関係と、会話の不足（日本語訳）

C³-Dialogue / train / ID 37-153 / 質問 1

日本語訳（文書・質問・全選択肢）

女：息子さんとの関係があまりよくないそうですね？
男：正直に言うと、私はよい父親ではありません。忙しくて息子の面倒を見る時間がなく、私たちの間にはほとんど会話がないんです。私のせいで、息子にも大きな重圧がかかっています。
質問：男性と息子の関係がよくないのはなぜですか？
A. 息子の態度が悪い
B. 双方の意思疎通が足りない
C. 息子が仕事で忙しい
D. 父親の重圧が大きすぎる

正解： B　双方の意思疎通が足りない

[1] Sun et al. C³-D / train / 37-153 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-train.json

似た語があっても、理由の主体は違う

- 父親が明言する「ほとんど会話がない」が理由。息子にかかる重圧を、父親自身の重圧と取り違えない。
- 父親が忙しいこと、会話がないこと、息子に重圧があることを、話者と因果関係に沿って結び付ける。
- この父子会話は CLEVA の論文にも例として載る。ここでは、元 C^3 の公開学習データにある一問として示した。

[1] Sun et al. C^3-D / train / 37-153 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-train.json
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例２：批判を受け止める人物像

C³-Mixed / dev / ID 11-67 / 質問 1

中国語原文（文書・質問・全選択肢）

梅兰芳是中国著名的京剧演员。有一次，在他表演的时候，一位老人说他演得不好。梅兰芳当时觉得很奇怪。表演结束以后，他开车把那个老人接到了家里，很有礼貌地对老人说：“给我提意见的人就是我的老师。您说我演得不好，请您多帮助我啊。”老先生就告诉了他哪个地方演得不好。以后，梅兰芳表演的时候，都会请那位老人去看他表演，并且请他给自己提意见。
问题：梅兰芳是一个什么样的人？
A. 他是一位年纪大的老人
B. 他是喜欢看京剧的人
C. 他是一个很虚心的人
D. 他是一个没礼貌的人

正解： C 他是一个很虚心的人

[1] Sun et al. C³-M / dev / 11-67 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

実例２：批判を受け止める人物像（日本語訳）

C³-Mixed / dev / ID 11-67 / 質問 1

日本語訳（文書・質問・全選択肢）

梅蘭芳は中国の有名な京劇俳優である。ある公演の最中、一人の老人が彼の演技はよくないと言った。梅蘭芳はそのとき不思議に思った。公演後、車で老人を自宅へ招き、とても礼儀正しくこう言った。「意見をくださる方は私の先生です。演技がよくないとおっしゃいましたね。どうかご指導ください。」老人は、どこがよくなかったのかを教えた。それ以後、梅蘭芳は公演のたびに老人を招いて見てもらい、意見を求めた。
質問：梅蘭芳はどのような人物ですか？
A. 年老いた老人である
B. 京劇を見るのが好きな人である
C. とても謙虚な人である
D. 礼儀を知らない人である

正解： C　とても謙虚な人である

[1] Sun et al. C³-M / dev / 11-67 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

行動から、人物の性格を判断する

- 批判した人を招き、以後も助言を求める行動から「虚心＝謙虚に学ぶ姿勢」を読み取る。
- 正解は「虚心」という人物の性質。本文の一部分を機械的に抜き出すだけではなく、複数の行動をまとめて解釈する。
- このような非対話文を C³-Mixed 、二人以上の会話を C³-Dialogue として分ける。どちらも質問と候補から答えを選ぶ。

[1] Sun et al. C³-M / dev / 11-67 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

実例３：到着時刻から出発時刻を逆算する

C³-Mixed / test / ID 9-120 / 質問 1

中国語原文・全文

从上海坐火车到北京需要 14 个小时，我明天早上 8 点到北京。
问题：他是几点出发的？
A. 20 点
B. 18 点
C. 19 点

日本語訳・全文

上海から北京までは列車で 14 時間かかる。私は明日の朝 8 時に北京へ着く。
質問：何時に出発しましたか？
A. 20 時
B. 18 時
C. 19 時

正解： B 18 点

[1] Sun et al. C³-M / test / 9-120 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-test.json

本文の数値を、答えの時刻へ変換する

- 翌朝 8 時から 14 時間を引くと、前日の 18 時。本文に正解時刻そのものは書かれていない。
- 3 候補のうち B を選ぶ。正解を表す語句が本文にそのまま存在しなくても、本文と日常的な計算から導ける。
- C^3 の正解候補の 80.4 %は、本文からそのまま抜き出せない。読解には、表現の言い換えや一般常識の利用が含まれる。

[1] Sun et al. C^3-M / test / 9-120 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-test.json

[2] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

一つの文書に、複数の質問が付く

文書
対話 または 単一テキスト

→

質問ごとの候補
2 〜 4 個から一つを選ぶ

→

正解
候補の文字列を保持

同じ文書に最大 6 問が付く。文書数と質問数は異なる。各実例は文書全文と選んだ一問の全内容を示し、同じ文書の別の質問は含めない。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

試験から集め、必要な知識を調べる

中国語の聴解・読解試験から収集

- 収集元は HSK （漢語水平考試）と MHK （民族漢語考試）。留学生、華僑、少数民族など、第二言語として中国語を学ぶ人の能力を測る試験である。
- インターネット上で公開された本試験と模擬試験を使い、重複する問題を除いた。聴解に由来する内容も、配布データではテキストとして扱う。
- 文書と付随する質問をまとめた問題単位で、学習 60 %・開発 20 %・テスト 20 %へ無作為に分けた。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

13,369 文書に、 19,577 問を収録

集合	Mixed 文書 / 問	Dialogue 文書 / 問	全体 文書 / 問
学習	3,138 / 6,013	4,885 / 5,856	8,023 / 11,869
開発	1,046 / 1,991	1,628 / 1,825	2,674 / 3,816
テスト	1,045 / 2,002	1,627 / 1,890	2,672 / 3,892
合計	5,229 / 10,006	8,140 / 9,571	13,369 / 19,577

文書と質問を分けて数える。学習・開発・テストの件数は、元の 6 ファイルと一致。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

対話と単一テキストは、長さも異なる

特徴	Mixed	Dialogue
文書長：平均 / 最大	180.2 / 1,274 文字	76.3 / 1,540 文字
質問数：平均 / 最大	1.9 / 6 問	1.2 / 6 問
正解が非抜出し	81.9 %	78.9 %
主な文書	物語・報道・広告	日常的な会話

文章の文字数は、構築時に報告された統計。対話は平均が短くても、長い問題がある。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

語句の照合を越えて、必要な知識を分ける

- 言語知識：言い換え、語の意味、文法や談話上の関係。単語が一致しなくても、同じ内容を述べていると捉える。
- 専門知識：特定分野の知識。一般常識：計算、感情の含み、因果、含意、部分と全体、前提条件、場面、その他の 8 種に分ける。
- 開発・テストから計 600 問を抽出し、著者 2 人が必要な知識を注釈した。必要な知識は一問に複数付くことがある。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

知識が必要だった問題は、注釈 600 問の 86.8 %

注釈の観点	割合
ほぼそのままの語句照合	13.2 %
何らかの事前知識	86.8 %
うち言語知識	39.8 %
うち専門知識	0.8 %
うち一般常識	57.3 %

600 問＝ Mixed 300 ＋ Dialogue 300 （開発・テスト各 150 ）。知識種別は重複するため、下位割合は合計 100 %にならない。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

答えを支える範囲にも差がある

- 正解を明示的・暗示的に支える最小の文数も注釈した。 600 問の 36.7 %は 1 文、 62.0 %は複数文、 1.3 %は文脈に依存しない。
- Dialogue では 77.0 %が複数文に支えられる。離れた発言、話者の関係、省略された場面をつなぐ必要がある。
- 注釈者間の一致度は Cohen の κ = 0.62 。 86.8 %などは、この 600 問の分析結果である。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

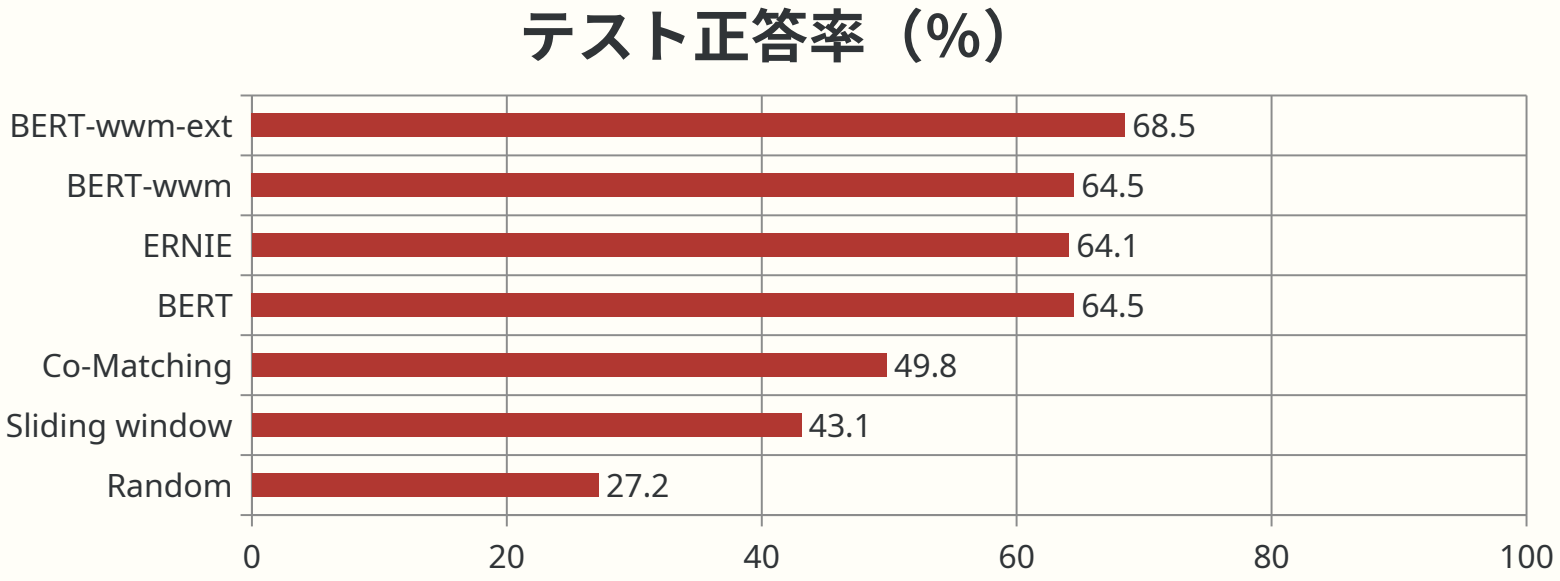
正答率を、対象と条件に沿って読む

評価の単位は、一問の正しい選択

- 基本指標は正答率。正しい候補を選べた質問数を、評価した質問数で割る。すべての選択肢数を 4 個と仮定しない。
- BERT 系は学習率 0.00002 、バッチ 24 、最大 512 トークン、 8 エポックで微調整した。長い入力は、文書・質問・候補のうち最長の列から切り詰める。
- 候補の表面上の似方にも影響される。本文に似ているだけの誤答候補があると、正解を選びにくくなる。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

構築時のモデルは、テスト正答率 68.5 %



[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155.
https://aclanthology.org/2020.tacl-1.10/

人とモデルは、評価した集合を分けて読む

対象	Mixed test	Dialogue test	全体 test
BERT-wwm-ext ：全テスト	68.0 %	68.9 %	68.5 %
人：注釈されたテスト部分	93.3 %	98.7 %	96.0 %

人の値は全 3,892 問の実測ではない。モデル全体の値と、人が解いた注釈部分の値は母集団が異なる。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

事前知識を使う読解に、研究上の余地を残す

- 構築時の最良モデルと人の差は、特に事前知識を必要とする問題で大きかった。語句の表面的一致だけでは解きにくい例が多い。
- 誤答候補のもっともらしさ、英語の関連読解データを翻訳して増やす方法なども検討された。学習量と候補の作り方が性能へ影響する。
- C^3 は、知識そのものを自由回答で説明する課題ではない。文書と候補を与えた状態で、知識を使い正しい選択をする能力を測る。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

元データと、後続の評価を分ける

公開 C^3 、 CLUE 、 CLEVA の役割

系列	含まれるもの・役割
C^3 公開元	Dialogue / Mixed の学習・開発・テスト。全て正解付き。
CLUE 1.0	元の学習・開発を利用。旧テストは 3,892 問、配布 ZIP では正解なし。
CLUE 1.1	学習・開発は同じ。新テストは 1,625 問、配布 ZIP では正解なし。
CLEVA v1	C^3 の一部を採用。専用データとプロンプトで読解を評価。

CLUE の新テストや CLEVA の採用部分を、元 C^3 の全体と同一視しない。

[1] CLUEbenchmark. C3 public data, CLUE 1.0 / 1.1. https://storage.googleapis.com/cluebenchmark/tasks/c3_public.zip
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

CLUE のテスト更新は、別の問題集合

- CLUE 配布 ZIP の学習・開発 4 ファイルは、元 C³ の同じ 4 ファイルとバイト単位で一致する。
- test1.0 は 2,672 文書・ 3,892 問。文書・質問・候補を照合すると、元 C³ のテスト全問と一致する。正解欄は除かれ、提出用 ID が付く。
- test1.1 は 1,080 文書・ 1,625 問。元 C³ 全 6 ファイルとの同一問題は学習 2 問・テスト 1 問で、残り 1,622 問は一致しない。

[1] CLUEbenchmark. C3 public data, CLUE 1.0 / 1.1. https://storage.googleapis.com/cluebenchmark/tasks/c3_public.zip

CLEVA では、中国語の読解課題として採用

- CLEVA は 2023 年の中国語言語モデル評価基盤。読解には C^3 から採った選択式問題を使い、正答率で評価すると説明する。
- HELM v0.4.0 の実装では reading_comprehension のデータと、train/test ・ prompts.json ・ infer_params.json を読み込む。
- 同梱設定には prompt_id 0 〜 5 の 6 通りがある。 Classic v0.4.0 の公開 run 索引では、 CLEVA を名に含む実行は 0 件。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

[2] Stanford CRFM. CLEVAReadingComprehensionScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

利用する版を決め、権利条件を先に読む

- 元の公式 repo では、 6 データファイルと 4 注釈ファイルを公開している。文書 ID 、質問、候補、正解文字列を保持して取得できる。
- license.txt は「非商用の研究目的のみ」と定める。元の試験問題が公開されていることと、利用条件が無制限であることは別である。
- 公開資料は、読解の入力、必要な知識、歴史的な比較を追う入口になる。後続利用では分割・プロンプト・評価条件も合わせて記録する。

[1] Sun et al. C³ official repository. commit 1f41682e. https://github.com/nlpdata/c3
[2] Sun et al. C³ license.txt. Non-commercial research purpose only. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/license.txt

C^3 は、文書と日常知識を結ぶ読解データ

- 中国語の試験から集めた 19,577 問。対話と多様な単一テキストを読み、 2 〜 4 候補から唯一の正解を選ぶ。
- 語句照合だけでなく、言い換え・場面・因果・計算などが必要になる。 600 問の知識注釈が、その性質を具体的に示す。
- 構築時の性能、 CLUE のテスト更新、 CLEVA の採用部分を分けると、何をどの条件で比較しているのかが明確になる。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

Appendix

1. 追加の公開実例
2. 版・原位置・再現
3. 研究と参考文献

追加の公開実例

実例 4 ：本文に明示された行動

C³-Dialogue / dev / ID 11-30 / 質問 1

中国語原文・全文

男：请问现在能预订晚上的座位吗？
女：可以。您贵姓？几位？
男：我姓张，两位。大概六点半到，麻烦给我留个靠窗的位置。
女：好，我们最晚给您保留到七点，请尽早过来。
问题：男的在做什么？
A. 看急诊
B. 开发票
C. 组织聚会
D. 预订座位

日本語訳・全文

男：今から今晩の席を予約できますか？
女：はい。お名前は？何名様ですか？
男：張と申します。２名です。６時半ごろ着きますので、窓際の席をお願いします。
女：承知しました。遅くとも７時までのお取り置きですので、早めにお越しください。
質問：男性は何をしていますか？
A. 救急外来を受診している
B. 領収書を発行している
C. 集まりを企画している
D. 席を予約している

正解： D 预订座位

[1] Sun et al. C³-D / dev / 11-30 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-dev.json

実例 5 ：設備更新のための融資

C³-Dialogue / dev / ID 11-57 / 質問 1

中国語原文（文書・質問・全選択肢）

女：张总，银行来电话说我们的贷款申请批下来了。
男：太好了，贷款一到位我们就更新设备。
女：这样每个月的出货量大概能提高百分之三十。
男：对，让市场部抓紧时间多联系些新客户。
问题：他们想用那批贷款做什么？
A. 建分厂
B. 买新设备
C. 购买原料
D. 为职工上保险

正解： B 买新设备

[1] Sun et al. C³-D / dev / 11-57 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-dev.json

実例 5 ：設備更新のための融資（日本語訳）

C³-Dialogue / dev / ID 11-57 / 質問 1

日本語訳（文書・質問・全選択肢）

女：張社長、銀行から電話があり、融資の申請が承認されたそうです。
男：よかった。融資が実行されたら設備を更新しよう。
女：そうすれば毎月の出荷量をおよそ 30 %増やせます。
男：そうだな。マーケティング部には急いで新規顧客へもっと連絡するよう伝えてくれ。
質問：その融資で何をしようとしていますか？
A. 分工場を建てる
B. 新しい設備を買う
C. 原料を買う
D. 従業員に保険をかける

正解： B 新しい設備を買う

[1] Sun et al. C³-D / dev / 11-57 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-dev.json

実例６：「もうすぐ着く」の言い換え

C³-Dialogue / dev / ID 17-3 / 質問 1

中国語原文・全文

女：喂，你到哪儿了？我们都在等你呢！
男：马上，我马上就到！我已经下了公交车了，正往你们那儿赶呢！
问题：从这段对话中，我们可以知道什么？
A. 女的很生气
B. 男的在车上
C. 男的就要到了
D. 女的挂了电话

日本語訳・全文

女：もしもし、今どこ？みんな待っているのよ！
男：すぐ、すぐ着くよ！もうバスを降りて、そっちへ急いでいるところ！
質問：この会話から何が分かりますか？
A. 女性はとても怒っている
B. 男性は車内にいる
C. 男性はもうすぐ着く
D. 女性は電話を切った

正解：C　男的就要到了

[1] Sun et al. C³-D / dev / 17-3 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-dev.json

実例７：控えめな表現から評価を読む

C³-Dialogue / dev / ID 28-8 / 質問 1

中国語原文・全文

女：听说你去看昨天的演出了，怎么样？
男：一般吧，我看了一半就走了。
问题：男的觉得演出怎么样？
A. 不好
B. 很好
C. 特别好

日本語訳・全文

女：昨日の公演を見に行ったそうね。どうだった？
男：まあ普通かな。半分見たところで帰ったよ。
質問：男性は公演をどう思っていますか？
A. よくない
B. とてもよい
C. 特によい

正解： A　不好

[1] Sun et al. C³-D / dev / 28-8 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-dev.json

実例 8 ：省略された道具を補う

C³-Dialogue / dev / ID 37-120 / 質問 1

中国語原文（文書・質問・全選択肢）

男：好，就站在那儿，笑一个。咦，怎么突然拍不了了？
女：刚才用的时候还好好的，不会突然坏了吧？
男：哦，应该是没电了，你带备用电池了吗？
女：没有，但是包里有充电器，要不找个地方充一下电吧。
问题：根据对话，可以知道什么？
A. 他们想去买电池
B. 男的不喜欢拍照
C. 照相机没电了
D. 女的不太高兴

正解： C 照相机没电了

[1] Sun et al. C³-D / dev / 37-120 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-dev.json

実例８：省略された道具を補う（日本語訳）

C³-Dialogue / dev / ID 37-120 / 質問 1

日本語訳（文書・質問・全選択肢）

男：よし、そこに立って、笑って。あれ、急に撮れなくなったぞ？
女：さっきは普通に使えていたのに、急に壊れたんじゃないでしょうね？
男：ああ、電池切れのはずだ。予備の電池は持ってきた？
女：持っていないけど、バッグに充電器がある。どこかで充電しようか。
質問：会話から何が分かりますか？
A. 電池を買いに行きたい
B. 男性は写真を撮るのが嫌い
C. カメラの電池が切れた
D. 女性はあまりうれしくない

正解：C　カメラの電池が切れた

[1] Sun et al. C³-D / dev / 37-120 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-dev.json

実例９：訪問と居住を区別する

C³-Mixed / dev / ID 8-707 / 質問 1

中国語原文・全文

我不住在这儿，这房子是我朋友的，他出国了。我每周来一次，帮他打扫一下房间，照顾一下花草。
问题：他住在朋友的房子里。
A. 正确
B. 错误

日本語訳・全文

私はここには住んでいない。この家は友人のもので、彼は外国へ行った。私は毎週１回来て、部屋を掃除したり、花や草の世話をしたりしている。
質問：彼は友人の家に住んでいる。
A. 正しい
B. 誤り

正解： B　错误

[1] Sun et al. C³-M / dev / 8-707 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

実例 10 ：貸出期間を足し合わせる

C³-Mixed / dev / ID 8-160 / 質問 1

中国語原文・全文

这本书我已经从图书馆借了二十天了，我还没有看完呢，还有十天就该还了。
问题：这本书他可以借 30 天。
A. 正确
B. 错误

日本語訳・全文

この本を図書館から借りて、もう 20 日になる。まだ読み終えておらず、あと 10 日で返さなければならない。
質問：この本は 30 日間借りられる。
A. 正しい
B. 誤り

正解： A　正确

[1] Sun et al. C³-M / dev / 8-160 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

実例 11 ：説明しない理由を読む

C³-Mixed / dev / ID 9-269 / 質問 1

中国語原文・全文

“你为什么不跟他们说清楚，让他们知道这不是你的错呢？”我生气地问哥哥。“他们已经这样认为了，说了他们也不会相信的，事情也不会有什么变化，那我为什么还要说？”
问题：哥哥不说，是因为：
A. 没办法说清楚
B. 他们听不明白
C. 觉得说也没用

日本語訳・全文

「どうして彼らにはっきり説明して、あなたのせいではないと分かってもらわないの？」と私は怒って兄に聞いた。「もうそう思い込んでいるんだ。説明しても信じないだろうし、何も変わらない。それなら、どうして説明する必要がある？」
質問：兄が説明しないのは、なぜですか？
A. うまく説明できない
B. 相手には説明が理解できない
C. 説明しても無駄だと思う

正解： C 觉得说也没用

[1] Sun et al. C³-M / dev / 9-269 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

実例 12 ：救助の動機を読み直す

C³-Mixed / dev / ID 11-14 / 質問 1

中国語原文（文書・質問・全選択肢）

小吉姆勇敢地走过薄薄的冰层，救起了掉进水里的朋友。他成了大家心目中的英雄。“你冒着生命危险救了你的朋友一命！”大家钦佩地说。“没办法，”小吉姆说，“他穿着我新买的冰鞋呢。”
问题：请选出与试题内容一致的一项。
A. 小吉姆掉进了水里
B. 小吉姆是为了冰鞋而救朋友的
C. 大家都觉得小吉姆非常聪明
D. 朋友把小吉姆的冰鞋扔进了水里

正解： B 小吉姆是为了冰鞋而救朋友的

[1] Sun et al. C³-M / dev / 11-14 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

実例 12 ：救助の動機を読み直す（日本語訳）

C³-Mixed / dev / ID 11-14 / 質問 1

日本語訳（文書・質問・全選択肢）

幼いジムは勇敢にも薄い氷の上を渡り、水に落ちた友人を助け上げた。みんなにとって彼は英雄になった。「命を懸けて友達を救ったんだね！」と人々は感心して言った。「仕方なかったんです」とジムは言った。「彼が、ぼくの買ったばかりのスケート靴を履いていたので。」
質問：本文の内容と一致するものを選んでください。
A. ジムが水に落ちた
B. ジムはスケート靴のために友人を助けた
C. みんなはジムがとても賢いと思った
D. 友人がジムのスケート靴を水へ投げ込んだ

正解： B ジムはスケート靴のために友人を助けた

[1] Sun et al. C³-M / dev / 11-14 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-dev.json

実例 13 ：東西の関係を反転する

C³-Mixed / test / ID 8-255 / 質問 1

中国語原文・全文

学校西边有书店，东边有公园和邮局，还有一个新开的超市。
问题：学校在超市的：
A. 西边
B. 东边
C. 南边

日本語訳・全文

学校の西側には書店があり、東側には公園と郵便局、それから新しくできたスーパーがある。
質問：学校はスーパーのどちら側にありますか？
A. 西側
B. 東側
C. 南側

正解： A 西边

[1] Sun et al. C³-M / test / 8-255 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-m-test.json

各実例で使う手掛かり

実例 / ID	読み取ること
1 / 37-153	父親が明言する「ほとんど会話がない」が理由。息子にかかる重圧を、父親自身の重圧と取り違えない。
2 / 11-67	批判した人を招き、以後も助言を求める行動から「虚心＝謙虚に学ぶ姿勢」を読み取る。
3 / 9-120	翌朝 8 時から 14 時間を引くと、前日の 18 時。本文に正解時刻そのものは書かれていない。
4 / 11-30	「预订」と「预订座位」が直接対応する。公式注釈は matching ／ 1 文。
5 / 11-57	融資を受けた後に設備を更新する。公式注釈は前提条件／複数文。

「公式注釈」は公開された知識・支持文数の分類。実例 1 の説明は本資料による。

[1] Sun et al. C³ knowledge annotations, dev/test. https://github.com/nlpdata/c3/tree/1f41682ebb684d63afe7c583c8f38e137fc8a826/annotation

各実例で使う手掛かり

実例 / ID	読み取ること
6 / 17-3	「马上就到」と「就要到了」が対応する。公式注釈は言語知識／複数文。
7 / 28-8	「一般吧」だけでなく、途中で帰った行動も評価の手掛かり。公式注釈は含みのある感情・語調／複数文。
8 / 37-120	撮影、電池、充電器からカメラだと補う。公式注釈は場面の知識／複数文。
9 / 8-707	毎週の訪問と居住を区別する。公式注釈は言語知識／ 1 文。

「公式注釈」は公開された知識・支持文数の分類。実例 1 の説明は本資料による。

[1] Sun et al. C³ knowledge annotations, dev/test. https://github.com/nlpdata/c3/tree/1f41682ebb684d63afe7c583c8f38e137fc8a826/annotation

各実例で使う手掛かり

実例 / ID	読み取ること
10 / 8-160	経過した 20 日と残り 10 日を足す。公式注釈は算術と言語知識／ 1 文。
11 / 9-269	反語と理由のつながりを読み、「言っても仕方がない」という判断を選ぶ。公式注釈は言語知識と因果／複数文。
12 / 11-14	人々の英雄視と本人の最後の発言を区別する。公式注釈は因果／複数文。
13 / 8-255	スーパーは学校の東側なので、学校はスーパーの西側。公式注釈は一般常識の「その他」／ 1 文。

「公式注釈」は公開された知識・支持文数の分類。実例 1 の説明は本資料による。

[1] Sun et al. C³ knowledge annotations, dev/test. https://github.com/nlpdata/c3/tree/1f41682ebb684d63afe7c583c8f38e137fc8a826/annotation

版・原位置・再現

13 実例の公開位置を固定する

実例 / 文書 ID	ファイル	配列 index / 質問 index
1 / 37-153	c3-d-train.json	941 / 0
2 / 11-67	c3-m-dev.json	0 / 0
3 / 9-120	c3-m-test.json	12 / 0
4 / 11-30	c3-d-dev.json	2 / 0
5 / 11-57	c3-d-dev.json	1 / 0
6 / 17-3	c3-d-dev.json	3 / 0
7 / 28-8	c3-d-dev.json	6 / 0

index は 0 起算。固定 commit 1f41682… 、各ファイル SHA256 と原レコードを付属記録へ保存。

[1] Sun et al. C³ official repository. commit 1f41682e. https://github.com/nlpdata/c3

13 実例の公開位置を固定する

実例 / 文書 ID	ファイル	配列 index / 質問 index
8 / 37-120	c3-d-dev.json	11 / 0
9 / 8-707	c3-m-dev.json	1 / 0
10 / 8-160	c3-m-dev.json	4 / 0
11 / 9-269	c3-m-dev.json	8 / 0
12 / 11-14	c3-m-dev.json	39 / 0
13 / 8-255	c3-m-test.json	38 / 0

index は 0 起算。固定 commit 1f41682… 、各ファイル SHA256 と原レコードを付属記録へ保存。

[1] Sun et al. C³ official repository. commit 1f41682e. https://github.com/nlpdata/c3

候補数は、一律 4 個ではない

候補数	質問数	全 19,577 問に占める割合
2 候補	894	4.57 %
3 候補	2,389	12.20 %
4 候補	16,294	83.23 %

固定 6 ファイルから再集計。 2 候補の真偽判定も、同じ一問一正解の読解形式に含まれる。

[1] Sun et al. C³ official repository. commit 1f41682e. https://github.com/nlpdata/c3

600 問の注釈を、全 19,577 問へ拡張しない

- 公開注釈は Dialogue と Mixed それぞれの開発・テストに 150 問ずつ、計 600 問。 documentID と questionIndex で元質問に結び付く。
- m は語句の照合、 l は言語知識、 s は専門知識。 c- で始まる 8 種は一般常識。複数の知識は | で併記される。
- || の後の 0 は 1 文、 1 は複数文、 2 は文脈に依存しない問題を表す。これは正解の候補番号ではない。

[1] Sun et al. C³ knowledge annotations, dev/test. https://github.com/nlpdata/c3/tree/1f41682ebb684d63afe7c583c8f38e137fc8a826/annotation

公開元の一問を、 ID 付きで読み出す

```
import json
with open('c3-d-train.json', encoding='utf-8') as f:
    rows = json.load(f)
document, questions, doc_id = rows[941]
question = questions[0]
assert doc_id == '37-153'
assert question['answer'] in question['choice']
print(document, question['question'])
print(question['choice'], question['answer'])
```

配列の位置と元 ID を併用する。正解文字列と候補の順序を保つ。

[1] Sun et al. C³-D / train / 37-153 / question 1. https://github.com/nlpdata/c3/blob/1f41682ebb684d63afe7c583c8f38e137fc8a826/data/c3-d-train.json

CLEVA の設定と、実際の公開実行は別

- Converter は候補を Reference へ変換し、 label に含まれる候補 index へ CORRECT タグを付ける。テンプレートで文書・質問・候補を整形する。
- prompt の meta.mul_as_gen に応じ、生成、選択肢の一括提示、候補ごとの比較を切り替える。具体的な推論値は infer_params.json から読む。
- この調査では CLEVA v1 の変換済み読解データ全体と推論パラメータを取得できていない。元 C^3 の分割や全問数を、そのまま実行条件に置き換えない。

[1] Stanford CRFM. CLEVAReadingComprehensionScenario / Converter. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

[2] Stanford CRFM. CLEVA v1 run configuration. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

公開 run 索引 0 件の確認範囲

- Classic v0.4.0 の run_specs 公開リスト 8,526 件と、runs_to_run_suites のキーを対象に、 cleva を名に含む項目を照合した。該当は 0 件だった。
- 一方、同リリースには CLEVA v1 の実行設定が含まれ、reading_comprehension の prompt_id 0 〜 5 を指定している。
- 設定が存在することは、公開済みのモデル出力や集計結果があることを意味しない。 CLEVA 全体の論文結果と、ここで確認した公開 run を区別する。

[1] Stanford CRFM. HELM Classic release v0.4.0, public run index. https://crfm.stanford.edu/helm/classic/v0.4.0/

[2] Stanford CRFM. CLEVA v1 run configuration. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

初回公開と、正式刊行を分けて記録

- arXiv の初回投稿は 2019 年 4 月 21 日。初期版の題名は Probing Prior Knowledge Needed in Challenging Chinese Machine Reading Comprehension 。
- 正式刊行名は Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension 。 TACL 第 8 巻、141 〜 155 頁、 2020 年に掲載された。
- C^3 の公開年は 2019 年として扱い、正式論文は 2020 年、 CLEVA による後続利用は 2023 年として区別する。

[1] Sun et al. (2019). Probing Prior Knowledge Needed in Challenging Chinese Machine Reading Comprehension. arXiv:1904.09679v1. https://arxiv.org/abs/1904.09679v1

[2] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

研究と参考文献

中国語の読解で、事前知識を分析する

- Kai Sun 、 Dian Yu 、 Dong Yu 、 Claire Cardie による共同研究。中国語の自由な質問形式の選択式読解を整備し、知識が必要な問題を分類した。
- 英語の RACE と DREAM に対応する、中国語の単一テキスト・対話の両方を含む。既存の中国語データで多かった抜出し型の読解を補う位置付けを持つ。
- 公開データと注釈が分かれているため、全体を使った正答率の評価と、 600 問を使った知識種別の分析を組み合わせられる。

[1] Sun, Yu, Yu & Cardie (2020). Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. TACL 8:141–155. https://aclanthology.org/2020.tacl-1.10/

参考文献

Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension

Kai Sun, Dian Yu, Dong Yu, Claire Cardie · 2020 · TACL 8:141–155

C^3 の収集、 Dialogue/Mixed 、知識注釈と構築時の評価を記述する正式論文。

https://aclanthology.org/2020.tacl-1.10/

Probing Prior Knowledge Needed in Challenging Chinese Machine Reading Comprehension

Kai Sun, Dian Yu, Dong Yu, Claire Cardie · 2019 · arXiv:1904.09679v1

C^3 を初めて公開したプレプリント。後続版と正式刊行では題名が Investigating へ変わる。

https://arxiv.org/abs/1904.09679v1

参考文献

C³: official data, annotations and baseline instructions

Kai Sun et al. · nlpdata/c3 · commit 1f41682...

元の 6 データファイル、 4 知識注釈、基準モデルの実行方法、利用条件を公開する。

https://github.com/nlpdata/c3

C3 data: CLUE release 1.0 / 1.1

CLUEbenchmark · CLUE public distribution

学習・開発と、正解を含まない旧・新テストを配布する。 README がテスト更新を説明する。
https://storage.googleapis.com/cluebenchmark/tasks/c3_public.zip

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations

中国語モデルの多面的評価基盤。付録 B.2 に C^3 由来の選択式読解と父子会話例を示す。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVAReadingComprehensionScenario and Converter

Stanford CRFM · 2023 · HELM v0.4.0 implementation

変換済みデータとテンプレートを読み、候補、正解タグ、入力と出力を組み立てる。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py