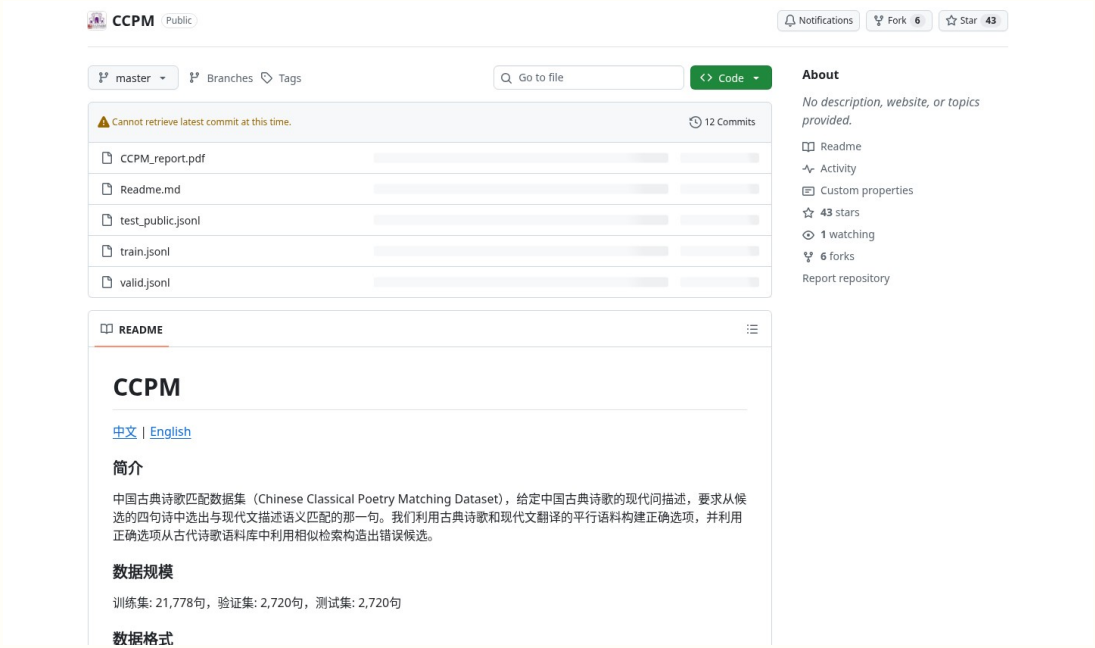
CCPM

Chinese Classical Poetry Matching Dataset

現代中国語の説明に合う、中国古典の詩句を選ぶ

sasakiy84

公式配布： CCPM のデータと技術報告



[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

1. 現代語の説明から古典詩句を選ぶ
2. 対訳と似た詩句から問題を作る
3. 正解率で意味の対応を評価する
4. CLEVA での後利用と公開配布

現代語の説明から古典詩句を選ぶ

四つの似た詩句から、説明に対応する一つを選ぶ

- CCPM は、中国古典詩の意味理解を調べる四択データセット。現代中国語の説明を読み、意味が最も対応する古典詩句を選ぶ。古典詩句と現代語訳の対が、正解の根拠になる。
- 候補には、正解に似た語や表現を持つ別の詩句も含まれる。似た言葉の中から、意味の違いを読み取ることが求められる。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

実例１：遠い故郷を恨まない

中国語原文：現代語の説明と古典候補

現代語：也不要埋怨故乡太遥远。
A. 莫恨故乡遥
B. 谁道故乡遥
C. 故乡应渐遥
D. 莫动故乡情

日本語訳：説明と各候補の意味

現代語：故郷があまりにも遠いことを、恨んでもいけない。
A. 故郷が遠いことを恨むな。
B. 誰が故郷は遠いと言ったのか。
C. 故郷は次第に遠くなるはずだ。
D. 故郷への思いをかき立てるな。

正解： A　莫恨故乡遥

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例２：山の雨が晴れ始める

中国語原文：現代語の説明と古典候補

現代語：山间连绵阴雨刚刚有了一点停止的意思。
A. 寒雨初开霁
B. 山晓雨初霁
C. 宿雨天初霁
D. 山雨初含霁

日本語訳：説明と各候補の意味

現代語：山間で降り続いた雨に、ようやく少しやむ気配が見えてきた。
A. 冷たい雨が、今しがた上がった。
B. 明け方の山で、雨が今しがた上がった。
C. 一晩降った雨で曇った空が、今しがた晴れた。
D. 山の雨に、ようやく晴れる兆しが見え始めた。

正解： D　山雨初含霁

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例３：病を抱えて独り高台へ登る

中国語原文：現代語の説明と古典候補

現代語：一生当中疾病缠身今日独上高台。
A. 一春多病几登台
B. 百年多病独登台
C. 百年多病负登临
D. 况多愁病独登台

日本語訳：説明と各候補の意味

現代語：一生のあいだ病に苦しみ、今日、独りで高台へ登る。
A. 春のあいだ病がちで、幾度高台へ登っただろう。
B. 長い一生を病がちに過ごし、独り高台へ登る。
C. 長い一生を病がちに過ごし、高みに登ることもかなわない。
D. まして、憂いも病も多く、独り高台へ登る。

正解： B　百年多病独登台

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

短い詩句の中に、主体・時間・感情が含まれる

- 「莫恨」と「谁道」では、故郷が遠いという話題が同じでも、「恨むな」と「誰が言った」の違いがある。「初含霽」は晴れ始める気配を表し、雨の場所や時間も候補ごとに変わる。
- 五言・七言の一行を中心とし、二行で一つの問題になる例もある。現代語の長い説明から、短い詩句へ圧縮された意味を対応させる。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

対訳と似た詩句から問題を作る

対訳を整え、正解に似た三つの候補を集める

約 6,000 段落の古典文と現代語訳を Web から収集する。

句読点や Web 上の行境界で分割し、五言・七言の詩型に合う 27,218 の対訳を残す。二行の対も含む。

正解に似た別の詩句を三つ選び、正解と混ぜて四択問題にする。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

五言・七言の一行と二行を対象にする

- 収集した古典文には、詩以外の文学も含まれていた。そこで、よく使われる五言・七言の詩型に合う長さの詩句を残した。
- 二行で連続した意味を持つ対は、そのまま二行単位で扱う。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

正解の詩句に似た候補を、詩のコーパスから探す

- 中国古典詩で事前学習した BERT-CCPoem を使い、各詩句をベクトルで表す。正解とのコサイン類似度を求め、局所性鋭敏型ハッシュ（ LSH ）で似た候補を効率よく探す。
- 検索の素材は CCPC-Full v1.0 で、 926,024 作品、 8,933,162 文を含む。意味の類似度に、文字列の最長共通部分列（ LCS ）も加え、候補の順序を付け直す。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

意味と文字列の似方を合わせ、負例を選ぶ

```
Sim(A, B) = 0.4 × LCS(A, B) + 0.6 × EMB(A, B)

負例１：最も似た候補
負例２：類似度順位２～５から無作為に一つ
負例３：類似度順位６～10から無作為に一つ
```

EMB は詩句ベクトルのコサイン類似度。三つの負例を正解と混ぜ、選択肢の順番を入れ替える。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

27,218 問を学習・検証・テストに分ける

分割	問題数	公開の正解欄
学習 train	21,778	あり（0〜3）
検証 valid	2,720	あり（0〜3）
test_public	2,720	なし

学習・検証には正解が付く。公開テストの正解は非公開。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979
[2] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

一行の問題が全体の約 9 割を占める

形式	問題数	割合
五言・一行	12,706	46.68%
七言・一行	11,738	43.13%
五言・二行	1,281	4.71%
七言・二行	1,493	5.49%

全 27,218 問。形式別の件数は、データ構築時の集計。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

データは説明・四候補・正解番号を持つ

```
{
  "translation": "也不要埋怨故乡太遥远。",
  "choices": ["莫恨故乡遥", "谁道故乡遥",
              "故乡应渐遥", "莫动故乡情"],
  "answer": 0
}
```

translation が問題文、 choices が四候補。 answer=0 は先頭の候補 A を指す。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

正解率で意味の対応を評価する

評価は、正しい候補を選んだ問題の割合

- 選んだ候補が正解と一致した問題の割合を、 Accuracy （正解率）で評価する。
- 2021 年の実験では、学習 21,778 問で BERT を微調整し、テスト 2,720 問で評価した。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

BERT の二方式は、テストで約 83 〜 85% の正解率

方式（ 2021 年）	テスト Accuracy (%)
BERT-Cls	84.96
BERT-Match	82.60

2021 年の報告値。同じテスト 2,720 問で評価。両方式の基盤は bert-base-chinese 。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

説明と候補を一緒に読むか、別々に表すか

BERT-Cls
説明＋候補を連結
↓
BERT の [CLS] 表現
↓
一致するかを分類

BERT-Match
説明と候補を別々に符号化
↓
それぞれのベクトル
↓
コサイン類似度が最大の候補

Cls は説明と詩句の間で注意機構が働く。 Match は別々の表現を作り、その近さで選ぶ。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

CLEVA での後利用と公開配布

CLEVA は、古典中国語理解の評価へ採用した

- 2023 年の CLEVA は、中国語モデルを多様な課題で評価するプラットフォーム。 CCPM の四択問題を、古典中国語理解の評価に用いる。
- 現代語の説明と四候補を提示し、選んだ候補の正誤を正解率で評価する。実例 2 の雨の問題は、 CLEVA 論文にも掲載されている。
- HELM にも同課題の評価実装が公開されている。 CLEVA で評価した問題の総数は、公開説明には記されていない。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP 2023: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

公式 GitHub で問題と技術報告を公開する

- 公式 GitHub は、学習・検証・公開テストの JSONL と技術報告を公開している。利用時には CCPM の論文を引用する。
- リポジトリにはライセンスが明示されていない。再利用・再配布の条件は、配布元へ確認する。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

まとめ：似た言葉の中から、対応する意味を選ぶ

- CCPM は、現代中国語の説明と古典詩句の対応を問う 27,218 問の四択データ。正解との対訳に、似た詩句を検索した三つの負例を組み合わせる。
- 2021 年の BERT 二方式は、テストで 84.96% と 82.60% の正解率を示した。後に CLEVA の古典中国語理解にも採用され、中国語モデルの意味理解を調べる課題となった。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP 2023: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

Appendix

1. 追加 10 問の原文と日本語訳
2. 入力形式と詩句の読み方
3. 参考文献

実例 4 ：消えた灯を再びともす

中国語原文：現代語の説明と古典候補

現代語：昏暗的灯熄灭了又被重新点亮。
A. 渔灯灭复明
B. 残灯灭又然
C. 残灯暗复明
D. 残灯灭又明

日本語訳：説明と各候補の意味

現代語：薄暗い灯が消え、またともされた。
A. 漁火が消え、また明るくなる。
B. 消えかけの灯が消え、また燃える。
C. 消えかけの灯が暗くなり、また明るくなる。
D. 消えかけの灯が消え、また明るくなる。

正解： D　残灯灭又明

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 5 ：清らかな泉を愛する

中国語原文：現代語の説明と古典候補

現代語：清冽的泉水纯净透明，惹人喜爱。
A. 却爱石泉清
B. 寒泉自清洁
C. 爱此寒泉清
D. 爱此清秋光

日本語訳：説明と各候補の意味

現代語：澄んで冷たい泉の水は、清らかで透明で、心を引く。
A. かえって、岩間の泉の清らかさを愛する。
B. 冷たい泉は、おのずと清らかだ。
C. この冷たい泉の清らかさを愛する。
D. この澄んだ秋の光を愛する。

正解： C　 爱此寒泉清

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 6 ：西風に帰る時を尋ねる

中国語原文：現代語の説明と古典候補

現代語：曾经听说秦地刮起西风就会下雨，西风啊，你什么时候回去啊？
A. 为问西风来几日，夕阳宫殿亦秋声。
B. 尝闻秦地西风雨，为问西风早晚回。
C. 驿使回时曾寄语，西风早晚渡秦川。
D. 并州旧日风声恶，怅望乡书早晚回。

日本語訳：説明と各候補の意味

現代語：秦の地では西風が吹くと雨になると聞いた。西風よ、いつ帰ってゆくのか。
A. 西風に、来て何日になるか尋ねる。夕日の宮殿にも秋の響き。
B. 秦の地の西風は雨をもたらすと聞く。西風に、いつ帰るのか尋ねる。
C. 使者が戻る時に言葉を託した。西風はいつ秦の地を渡るのか。
D. 并州の昔日の風は激しかった。故郷の便りを待ち望む、いつ帰るのか。

正解： B　尝闻秦地西风雨，为问西风早晚回。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 7 ：雨と水煙のもの寂しい景色

中国語原文：現代語の説明と古典候補

現代語：大雨激起水雾，空蒙一片，天地都是萧瑟的景象。
A. 村烟空处渡，野色望中开。
B. 空烟迷雨色，萧飒望中来。
C. 乱山烟雨外，欲望失苍苍。
D. 空蒙迷远望，萧瑟送寒声。

日本語訳：説明と各候補の意味

現代語：大雨が水煙を巻き上げ、辺りはかすみ、天地はもの寂しい景色になった。
A. 村の煙が途切れる所を渡り、野の景色が眺めの中で開ける。
B. 立ちこめる煙が雨の景色をかすませ、もの寂しさが視界に迫る。
C. 幾重もの山は煙る雨の向こう。眺めようとしても青々とした姿を見失う。
D. かすみが遠くの眺めを覆い、寒々しい物音がもの寂しく響く。

正解： B　空烟迷雨色，萧飒望中来。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 8 ：半ばは修道、半ばは君ゆえ

中国語原文：現代語の説明と古典候補

現代語：这缘由，一半是因为修道人的清心寡欲，一半是因为曾经拥有过的你。
A. 半缘修道半缘君
B. 尘缘悟后道缘长
C. 半缘山野半缘君
D. 生缘断处参吾道

日本語訳：説明と各候補の意味

現代語：そのわけは、半分は修道者として欲を抑えて心静かに暮らすため、半分はかつてともにいたあなたのためだ。
A. 半ばは道を修めるゆえ、半ばは君ゆえ。
B. 俗世との縁を悟った後、道との縁は長くなる。
C. 半ばは山野ゆえ、半ばは君ゆえ。
D. 生の縁が断たれる所で、私の道を究める。

正解： A　半缘修道半缘君

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例９：取り戻されない河湟の地

中国語原文：現代語の説明と古典候補

現代語：国土一角仍沦陷，天子没有收河湟。
A. 未收天子河湟地
B. 天子新收秦陇地
C. 天不收子地容君
D. 全收朔雪天王地

日本語訳：説明と各候補の意味

現代語：国土の一角はいまだ敵の手にあり、天子は河湟の地を取り戻していない。
A. 天子は、河湟の地をまだ取り戻していない。
B. 天子は、秦隴の地を新たに取り戻した。
C. 天は子を受け入れず、地は君を受け入れる。
D. 天王の地である、雪深い北方をすべて取り戻す。

正解： A　未收天子河湟地

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 10 ：白髪が簪を支えられない

中国語原文：現代語の説明と古典候補

現代語：白发越搔越短，简直要不能插簪了。
A. 近欲不胜簪
B. 浑欲不胜簪
C. 酒秃不胜簪
D. 浑欲不胜愁

日本語訳：説明と各候補の意味

現代語：白髪はかくほどに短くなり、もう簪を挿せないほどだ。
A. ほとんど、簪を支えられなくなりそうだ。
B. まったく、簪を支えられなくなりそうだ。
C. 酒で髪が抜け、簪を支えられない。
D. まったく、憂いに堪えられなくなりそうだ。

正解： B　浑欲不胜簪

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 11 ：深い雲の中にいる人を探す

中国語原文：現代語の説明と古典候補

現代語：可是林深云密，我也不知道他到底在哪。
A. 云深不可知
B. 云深杳何处
C. 云迷不知处
D. 云深不知处

日本語訳：説明と各候補の意味

現代語：けれど林は深く雲は濃く、私にも、あの人がいったいどこにいるのか分からない。
A. 雲が深く、知りようがない。
B. 雲が深く、いずことも知れない。
C. 雲にかすみ、居場所が分からない。
D. 雲が深く、居場所が分からない。

正解： D　云深不知处

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 12 ：秋の野風に鳴く蝉

中国語原文：現代語の説明と古典候補

現代語：初秋寒蝉在野外晨风中嘶声噪鸣。
A. 猿啸野风秋
B. 蝉噪风前急
C. 蝉噪野风秋
D. 萤散野风秋

日本語訳：説明と各候補の意味

現代語：初秋の蝉が、野の朝風の中で、声をからして鳴いている。
A. 猿が、秋の野風の中で叫ぶ。
B. 蝉が、風の前でせわしなく鳴く。
C. 蝉が、秋の野風の中で鳴く。
D. 蛍が、秋の野風の中で散る。

正解： C　蝉噪野风秋

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

実例 13 ：北を望み、飛ぶ鳥を眺める

中国語原文：現代語の説明と古典候補

現代語：我向北方观望，一片渺茫，鸟儿可以自由地飞来飞去。
A. 茫茫极浦舟南北，渺渺长空鸟去来。
B. 云水苍茫共渺然，眼看飞鸟没苍烟。
C. 六合茫茫天共远，五湖杳杳雁飞还。
D. 北望茫茫渺渺间，鸟飞不尽又飞还。

日本語訳：説明と各候補の意味

現代語：北を望むと、はるかにかすみ、鳥は自由に行き来している。
A. 広々とした遠い水辺を舟が南北に行く。はるかな空を鳥が行き来する。
B. 雲も水も一様に果てしなくかすむ。飛ぶ鳥が青いもやへ消えるのを見る。
C. 天地は果てしなく遠い。いくつもの湖を雁が遠くへ飛び、また帰る。
D. 北を望めば、果てしなく、はるかにかすむ。鳥は尽きることなく飛び、また帰る。

正解： D　北望茫茫渺渺间，鸟飞不尽又飞还。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

入力形式と詩句の読み方

同じ説明に、異なる候補の組が付く

候補	候補の組 1	候補の組 2
A	寒雨初开雾	山雨初含雾
B	山晓雨初雾	久雨初收雾
C	宿雨天初雾	山晓雨初雾
D	山雨初含雾	山雨幸初雾
正解	**D**	**A**

共通の説明：「山间连绵阴雨刚刚有了一点停止的意思。」
候補の組 1 が、実例 2 と CLEVA 論文に掲載された問題。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

正解位置は、学習・検証ともほぼ均等

正解の候補	学習	検証
A	5,324	709
B	5,455	677
C	5,452	661
D	5,547	673

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

一部の問題には、説明の欠落や形式の例外がある

- 公開テストには、説明が空の問題が 1 問ある。四候補は残っているが、説明との意味対応を評価するための入力が欠けている。
- 五言・七言の詩型に当てはまらない文や、特殊な漢字表記を含む問題もある。
- 学習と公開テストで、説明と四候補が一致する問題が 1 問ある。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

JSONL から問題文・候補・正解を読み出す

```
import json
with open("train.jsonl", encoding="utf-8") as f:
    question = json.loads(next(f))
print(question["translation"])
for i, verse in enumerate(question["choices"]):
    print(f"{chr(65+i)}. {verse}")
print("正解:", chr(65 + question["answer"]))
```

train.jsonl は 1 行に 1 問の JSON を収める。最初の問題の説明、四候補、正解記号を表示する。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

候補の細かな語と、説明の意味を対応させる

- 実例 11 の候補 A 「云深不可知」と D 「云深不知処」は、共通する語が多い。 A は「雲が深く、知りようがない」、 D は「雲が深く、居場所が分からない」と読める。
- 現代語の説明には「不知道他到底在哪」（あの人がどこにいるのか分からない）とあり、場所を表す「処」との対応が判断の手掛かりになる。

[1] THUNLP-AIPoet (2021). CCPM. https://github.com/THUNLP-AIPoet/CCPM

参考文献

参考文献

CCPM: A Chinese Classical Poetry Matching Dataset

Wenhao Li, Fanchao Qi, Maosong Sun, Xiaoyuan Yi, Jiarui Zhang · 2021 · arXiv:2106.01979v1

古典詩と現代語訳から四択問題を構成し、似た詩句を負例として検索する。BERT 二方式の評価を報告する。

https://arxiv.org/abs/2106.01979

CCPM — Official Dataset Repository

THUNLP-AIPoet · 2021

学習・検証・正解非公開テストの JSONL と技術報告、データ形式、正解率による評価方法を公開する。

https://github.com/THUNLP-AIPoet/CCPM

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al. · 2023 · EMNLP: System Demonstrations

中国語モデルの多様な能力を評価するプラットフォーム。 CCPM を古典中国語理解の課題へ採用する。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVAClassicalChineseUnderstandingScenario / Converter

Stanford CRFM · HELM v0.4.0 · Python 実装

外部配布データとテンプレートを読み込み、現代語説明・候補・ラベルを HELM の入力と参照へ変換する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova · 2019 · NAACL-HLT

双方向 Transformer の事前学習と、文分類などへの微調整を提案する。

https://aclanthology.org/N19-1423/

BERT-CCPoem

Zhipeng Guo, Jinyi Hu, Maosong Sun · 2020 · 公式実装

古典詩コーパスで学習したモデルと表現を公開し、 CCPM では似た詩句の検索に利用される。

https://github.com/THUNLP-AIPoet/BERT-CCPoem