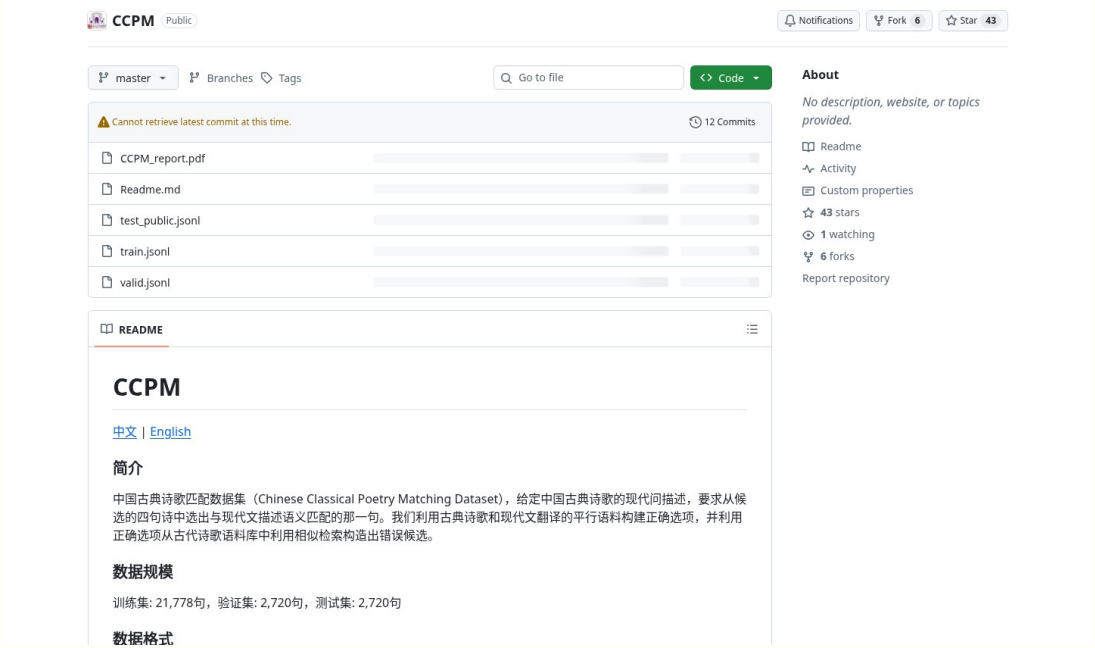
CCPM

Chinese Classical Poetry Matching Dataset

現代中国語の説明に合う、中国古典の詩句を選ぶ

sasakiy84

公式配布： CCPM のデータと技術報告



[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

1. 現代語の説明から古典詩句を選ぶ
2. 対訳と似た詩句から問題を作る
3. 正解率で意味の対応を評価する
4. CLEVA での後利用と公開配布

現代語の説明から古典詩句を選ぶ

四つの似た詩句から、説明に対応する一つを選ぶ

- CCPM は、中国古典詩の意味理解を調べる四択データセット。現代中国語で書かれた説明を読み、意味が最も対応する古典詩句を選ぶ。古典詩句と現代語訳の対を、正解の根拠として使う。
- 候補には、正解に似た語や表現を持つ別の詩句を含める。詩を新しく書く課題ではなく、与えられた候補の意味の違いを識別する。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

実例１：遠い故郷を恨まない

中国語原文：現代語の説明と古典候補

現代語：也不要埋怨故乡太遥远。
A. 莫恨故乡遥
B. 谁道故乡遥
C. 故乡应渐遥
D. 莫动故乡情

日本語訳：説明と各候補の意味

現代語：故郷があまりにも遠いことを、恨んでもいけない。
A. 故郷が遠いことを恨むな。
B. 誰が故郷は遠いと言ったのか。
C. 故郷は次第に遠くなるはずだ。
D. 故郷への思いをかき立てるな。

正解： A　莫恨故乡遥

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 train.jsonl:14 行 / answer=0
https://github.com/THUNLP-AIPoet/CCPM

実例２：山の雨が晴れ始める

中国語原文：現代語の説明と古典候補

現代語：山间连绵阴雨刚刚有了一点停止的意思。
A. 寒雨初开霁
B. 山晓雨初霁
C. 宿雨天初霁
D. 山雨初含霁

日本語訳：説明と各候補の意味

現代語：山間で降り続いた雨に、ようやく少しやむ気配が見えてきた。
A. 冷たい雨が、今しがた上がった。
B. 明け方の山で、雨が今しがた上がった。
C. 一晩降った雨で曇った空が、今しがた晴れた。
D. 山の雨に、ようやく晴れる兆しが見え始めた。

正解： D　山雨初含霁

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 train.jsonl:18823 行 / answer=3
https://github.com/THUNLP-AIPoet/CCPM

実例３：病を抱えて独り高台へ登る

中国語原文：現代語の説明と古典候補

現代語：一生当中疾病缠身今日独上高台。
A. 一春多病几登台
B. 百年多病独登台
C. 百年多病负登临
D. 况多愁病独登台

日本語訳：説明と各候補の意味

現代語：一生のあいだ病に苦しみ、今日、独りで高台へ登る。
A. 春のあいだ病がちで、幾度高台へ登っただろう。
B. 長い一生を病がちに過ごし、独り高台へ登る。
C. 長い一生を病がちに過ごし、高みに登ることもかなわない。
D. まして、憂いも病も多く、独り高台へ登る。

正解： B　百年多病独登台

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 train.jsonl:14876 行 / answer=1
https://github.com/THUNLP-AIPoet/CCPM

短い詩句の中に、主体・時間・感情が含まれる

- 「莫恨」と「谁道」では、故郷が遠いという話題が同じでも、「恨むな」と「誰が言った」の違いがある。「初含霽」は晴れ始める気配を表し、雨の場所や時間も候補ごとに変わる。
- 五言・七言の一行を中心とし、二行で一つの問題になる例もある。現代語の長い説明から、短い詩句へ圧縮された意味を対応させる。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

対訳と似た詩句から問題を作る

対訳を整え、正解に似た三つの候補を集める

Web の古典文と現代語訳を収集 → 行ごとに分割し詩型で絞り込む → 似た詩句から負例を三つ選ぶ → 正解と混ぜて四択問題にする

約 6,000 段落の古典文と現代語訳から始め、分割・形式の絞り込みを経て、 27,218 の対訳にした。句読点や Web 上の行境界で区切り、一行に分けきれない二行の対も残した。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

五言・七言の一行と二行を対象にする

- 収集した古典文には、詩以外の文学も含まれていた。そこで、よく使われる五言・七言の詩型に合う長さの詩句を残した。
- 二行で連続した意味を持つ対は、そのまま二行単位で扱う。ここでいう 27,218 件は問題数であり、詩の作品数や作者数ではない。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

正解の詩句に似た候補を、詩のコーパスから探す

- 中国古典詩で事前学習した BERT-CCPoem を使い、各詩句をベクトルで表す。正解とのコサイン類似度を求め、局所性鋭敏型ハッシュ（ LSH ）で似た候補を効率よく探す。
- 検索の素材は CCPC-Full v1.0 で、 926,024 作品、 8,933,162 文を含む。意味の類似度に、文字列の最長共通部分列（ LCS ）も加え、候補の順序を付け直す。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

意味と文字列の似方を合わせ、負例を選ぶ

```
Sim(A, B) = 0.4 × LCS(A, B) + 0.6 × EMB(A, B)

負例１：最も似た候補
負例２：類似度順位２～５から無作為に一つ
負例３：類似度順位６～10から無作為に一つ
```

EMB は詩句ベクトルのコサイン類似度。三つの負例を正解と混ぜ、選択肢の順番を入れ替える。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

27,218 問を学習・検証・テストに分ける

分割	問題数	公開の正解欄
学習 train	21,778	あり（0〜3）
検証 valid	2,720	あり（0〜3）
test_public	2,720	なし

件数は配布ファイルの全行と一致。論文のテスト正解率と、公開テストの正解なし配布を区別する。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979
[2] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

一行の問題が全体の約 9 割を占める

形式	問題数	割合
五言・一行	12,706	46.68%
七言・一行	11,738	43.13%
五言・二行	1,281	4.71%
七言・二行	1,493	5.49%

全 27,218 問。形式別の件数は構築時の集計。配布文字列には特殊な表記を含む少数の例もある。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

データは説明・四候補・正解番号を持つ

```
{
  "translation": "也不要埋怨故乡太遥远。",
  "choices": ["莫恨故乡遥", "谁道故乡遥",
              "故乡应渐遥", "莫动故乡情"],
  "answer": 0
}
```

answer は 0 始まりの位置。表示上の A/B/C/D は、元の候補順へ対応させる。元 JSONL には問題 ID ・詩題・作者の欄はない。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

説明文だけでは、問題を一意に特定できない

比較する単位	学習	検証	公開テスト
レコード数	21,778	2,720	2,720
説明文の種類	21,483	2,710	2,716
説明＋四候補の種類	21,778	2,720	2,720

2026-10-18 、配布全件の文字列を加工せず集計。学習と公開テストには、説明と四候補が同じ問題が 1 件ある。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

正解率で意味の対応を評価する

評価は、正しい候補を選んだ問題の割合

- 指標は Accuracy （正解率）。各問題で予測した選択肢が元の answer と一致したかを数え、評価した問題数で割る。四つの候補から一つを選ぶため、各問の正誤は 0 か 1 になる。
- 2021 年の実験は、学習分割で BERT を微調整し、テスト分割で評価した。公開テストの正解は非公開で、比較表には 2021 年の報告値を示す。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

BERT の二方式は、テストで約 83 〜 85% の正解率

方式（ 2021 年）	テスト Accuracy (%)
BERT-Cls	84.96
BERT-Match	82.60

CCPM の同じテスト 2,720 問を対象とする、構築時の報告値。 BERT の基盤は bert-base-chinese 。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

説明と候補を一緒に読むか、別々に表すか

BERT-Cls
説明＋候補を連結
↓
BERT の [CLS] 表現
↓
一致するかを分類

BERT-Match
説明と候補を別々に符号化
↓
それぞれのベクトル
↓
コサイン類似度が最大の候補

Cls は説明と詩句の間で注意機構が働く。 Match は別々の表現を作り、その近さで選ぶ。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

両方式を同じ学習設定で微調整した

項目	設定
文の符号化器	bert-base-chinese
最適化手法	Adam
初期学習率	2×10^{-5} 、線形に減衰
学習回数	4 epochs

BERT-CCPoem は負例の検索に使うモデルで、ここで評価した二方式の基盤とは区別する。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

CLEVA での後利用と公開配布

CLEVA は、古典中国語理解の評価へ採用した

- 2023 年の CLEVA は、中国語モデルを多様な課題で評価するプラットフォーム。古典中国語理解の課題として CCPM から四択問題を抽出し、現代語と古典候補の意味の対応を正解率で評価する。
- 掲載例は実例 2 の「山間の雨が晴れ始める」問題で、公式 train の 18,823 行と四候補・正解 D が一致する。同じ説明文に別候補が付く問題もある。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP 2023: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

HELM にも課題の実装があり、公開実行は 0 件

- HELM v0.4.0 には CLEVAClassicalChineseUnderstandingScenario があり、実例 1 と同じ説明・候補・正解 A を記す。データとテンプレートを外部 ZIP から読み、候補の番号を正解参照へ変換する。
- Classic v0.4.0 の公開 run_specs 全 8,526 件には CLEVA 実行がない。 CLEVA 用評価 ZIP も取得できていないため、 HELM での得点、実際の学習例数や生成条件は示さない。

[1] Stanford CRFM. CLEVAClassicalChineseUnderstandingScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

元の CCPM 配布と、後利用の集合を区別する

対象	確認できた内容
CCPM 公式配布	全 27,218 問、 train/valid 正解、 test_public 正解なし
CLEVA 論文	CCPM から抽出する課題と、候補まで一致した掲載例
HELM 実装・設定	同課題のクラス、外部データ読込、 6 テンプレート ID
HELM 公開実行	0 件。 CLEVA 評価集合・保存 request は未取得

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP 2023: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM. CLEVAClassicalChineseUnderstandingScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

公式 JSONL を取得でき、再利用条件は確認が必要

- 公式 GitHub は train.jsonl 、 valid.jsonl 、 test_public.jsonl と技術報告を公開し、利用時には CCPM の引用を求める。 2021 年 8 月 21 日の更新版には、これらを含む五つのファイルがある。
- 取得したリポジトリにはライセンスファイルがなく、元 Web 素材の個別出所・作者も各レコードには含まれない。古典詩の原句、現代語説明、収集データの利用条件を同じものとして推定せず、配布元を確認して利用する。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

まとめ：似た言葉の中から、対応する意味を選ぶ

- CCPM は現代中国語の説明と古典詩句の対応を問う 27,218 問の四択データ。正解との対訳に、似た詩句を検索した三つの負例を組み合わせる。
- 2021 年の BERT 二方式はテスト正解率 84.96% と 82.60% 。後に CLEVA の古典中国語理解へ採用された。公開元データ・掲載例・未取得の後利用集合を対応させて読む。

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP 2023: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

Appendix

1. 追加 10 問の原文と日本語訳
2. 分割・重複・入力形式の補足
3. 参考文献

実例 4 ：消えた灯を再びともす

中国語原文：現代語の説明と古典候補

現代語：昏暗的灯熄灭了又被重新点亮。
A. 渔灯灭复明
B. 残灯灭又然
C. 残灯暗复明
D. 残灯灭又明

日本語訳：説明と各候補の意味

現代語：薄暗い灯が消え、またともされた。
A. 漁火が消え、また明るくなる。
B. 消えかけの灯が消え、また燃える。
C. 消えかけの灯が暗くなり、また明るくなる。
D. 消えかけの灯が消え、また明るくなる。

正解： D　残灯灭又明

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:1 行 / answer=3
https://github.com/THUNLP-AIPoet/CCPM

実例 5 ：清らかな泉を愛する

中国語原文：現代語の説明と古典候補

現代語：清冽的泉水纯净透明，惹人喜爱。
A. 却爱石泉清
B. 寒泉自清洁
C. 爱此寒泉清
D. 爱此清秋光

日本語訳：説明と各候補の意味

現代語：澄んで冷たい泉の水は、清らかで透明で、心を引く。
A. かえって、岩間の泉の清らかさを愛する。
B. 冷たい泉は、おのずと清らかだ。
C. この冷たい泉の清らかさを愛する。
D. この澄んだ秋の光を愛する。

正解： C　 爱此寒泉清

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:5 行 / answer=2
https://github.com/THUNLP-AIPoet/CCPM

実例 6 ：西風に帰る時を尋ねる

中国語原文：現代語の説明と古典候補

現代語：曾经听说秦地刮起西风就会下雨，西风啊，你什么时候回去啊？
A. 为问西风来几日，夕阳宫殿亦秋声。
B. 尝闻秦地西风雨，为问西风早晚回。
C. 驿使回时曾寄语，西风早晚渡秦川。
D. 并州旧日风声恶，怅望乡书早晚回。

日本語訳：説明と各候補の意味

現代語：秦の地では西風が吹くと雨になると聞いた。西風よ、いつ帰ってゆくのか。
A. 西風に、来て何日になるか尋ねる。夕日の宮殿にも秋の響き。
B. 秦の地の西風は雨をもたらすと聞く。西風に、いつ帰るのか尋ねる。
C. 使者が戻る時に言葉を託した。西風はいつ秦の地を渡るのか。
D. 并州の昔日の風は激しかった。故郷の便りを待ち望む、いつ帰るのか。

正解： B　尝闻秦地西风雨，为问西风早晚回。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:14 行 / answer=1
https://github.com/THUNLP-AIPoet/CCPM

実例 7 ：雨と水煙のもの寂しい景色

中国語原文：現代語の説明と古典候補

現代語：大雨激起水雾，空蒙一片，天地都是萧瑟的景象。
A. 村烟空处渡，野色望中开。
B. 空烟迷雨色，萧飒望中来。
C. 乱山烟雨外，欲望失苍苍。
D. 空蒙迷远望，萧瑟送寒声。

日本語訳：説明と各候補の意味

現代語：大雨が水煙を巻き上げ、辺りはかすみ、天地はもの寂しい景色になった。
A. 村の煙が途切れる所を渡り、野の景色が眺めの中で開ける。
B. 立ちこめる煙が雨の景色をかすませ、もの寂しさが視界に迫る。
C. 幾重もの山は煙る雨の向こう。眺めようとしても青々とした姿を見失う。
D. かすみが遠くの眺めを覆い、もの寂しい様子が寒々しい音を送る。

正解： B　空烟迷雨色，萧飒望中来。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:24 行 / answer=1
https://github.com/THUNLP-AIPoet/CCPM

実例 8 ：半ばは修道、半ばは君ゆえ

中国語原文：現代語の説明と古典候補

現代語：这缘由，一半是因为修道人的清心寡欲，一半是因为曾经拥有过的你。
A. 半缘修道半缘君
B. 尘缘悟后道缘长
C. 半缘山野半缘君
D. 生缘断处参吾道

日本語訳：説明と各候補の意味

現代語：そのわけは、半分は修道者として欲を抑えて心静かに暮らすため、半分はかつてともにいたあなたのためだ。
A. 半ばは道を修めるゆえ、半ばは君ゆえ。
B. 俗世との縁を悟った後、道との縁は長くなる。
C. 半ばは山野ゆえ、半ばは君ゆえ。
D. 生の縁が断たれる所で、私の道を究める。

正解： A　半缘修道半缘君

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:25 行 / answer=0
https://github.com/THUNLP-AIPoet/CCPM

実例９：取り戻されない河湟の地

中国語原文：現代語の説明と古典候補

現代語：国土一角仍沦陷，天子没有收河湟。
A. 未收天子河湟地
B. 天子新收秦陇地
C. 天不收子地容君
D. 全收朔雪天王地

日本語訳：説明と各候補の意味

現代語：国土の一角はいまだ敵の手にあり、天子は河湟の地を取り戻していない。
A. 天子は、河湟の地をまだ取り戻していない。
B. 天子は、秦隴の地を新たに取り戻した。
C. 天は子を受け入れず、地は君を受け入れる。
D. 天王の地である、雪深い北方をすべて取り戻す。

正解： A　未收天子河湟地

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:35 行 / answer=0
https://github.com/THUNLP-AIPoet/CCPM

実例 10 ：白髪が簪を支えられない

中国語原文：現代語の説明と古典候補

現代語：白发越搔越短，简直要不能插簪了。
A. 近欲不胜簪
B. 浑欲不胜簪
C. 酒秃不胜簪
D. 浑欲不胜愁

日本語訳：説明と各候補の意味

現代語：白髪はかくほどに短くなり、もう簪を挿せないほどだ。
A. ほとんど、簪を支えられなくなりそうだ。
B. まったく、簪を支えられなくなりそうだ。
C. 酒で髪が抜け、簪を支えられない。
D. まったく、憂いに堪えられなくなりそうだ。

正解： B　浑欲不胜簪

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:47 行 / answer=1
https://github.com/THUNLP-AIPoet/CCPM

実例 11 ：深い雲の中にいる人を探す

中国語原文：現代語の説明と古典候補

現代語：可是林深云密，我也不知道他到底在哪。
A. 云深不可知
B. 云深杳何处
C. 云迷不知处
D. 云深不知处

日本語訳：説明と各候補の意味

現代語：けれど林は深く雲は濃く、私にも、あの人がいったいどこにいるのか分からない。
A. 雲が深く、知りようがない。
B. 雲が深く、いずことも知れない。
C. 雲にかすみ、居場所が分からない。
D. 雲が深く、居場所が分からない。

正解： D　云深不知处

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:52 行 / answer=3
https://github.com/THUNLP-AIPoet/CCPM

実例 12 ：秋の野風に鳴く蝉

中国語原文：現代語の説明と古典候補

現代語：初秋寒蝉在野外晨风中嘶声噪鸣。
A. 猿啸野风秋
B. 蝉噪风前急
C. 蝉噪野风秋
D. 萤散野风秋

日本語訳：説明と各候補の意味

現代語：初秋の寒蝉が、野の朝風の中で、声をからして鳴いている。
A. 猿が、秋の野風の中で叫ぶ。
B. 蝉が、風の前でせわしなく鳴く。
C. 蝉が、秋の野風の中で鳴く。
D. 蛍が、秋の野風の中で散る。

正解： C　蝉噪野风秋

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:60 行 / answer=2
https://github.com/THUNLP-AIPoet/CCPM

実例 13 ：北を望み、飛ぶ鳥を眺める

中国語原文：現代語の説明と古典候補

現代語：我向北方观望，一片渺茫，鸟儿可以自由地飞来飞去。
A. 茫茫极浦舟南北，渺渺长空鸟去来。
B. 云水苍茫共渺然，眼看飞鸟没苍烟。
C. 六合茫茫天共远，五湖杳杳雁飞还。
D. 北望茫茫渺渺间，鸟飞不尽又飞还。

日本語訳：説明と各候補の意味

現代語：北を望むと、はるかにかすみ、鳥は自由に行き来している。
A. 広々とした遠い水辺を舟が南北に行く。はるかな空を鳥が行き来する。
B. 雲も水も一様に果てしなくかすむ。飛ぶ鳥が青いもやへ消えるのを見る。
C. 天地は果てしなく遠い。いくつもの湖を雁が遠くへ飛び、また帰る。
D. 北を望めば、果てしなく、はるかにかすむ。鳥は尽きることなく飛び、また帰る。

正解： D　北望茫茫渺渺间，鸟飞不尽又飞还。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 valid.jsonl:65 行 / answer=3
https://github.com/THUNLP-AIPoet/CCPM

分割・重複・入力形式の補足

同じ雨の説明でも、候補と正解位置が変わる

候補	train 18,823 行	train 21,287 行
A	寒雨初开霁	山雨初含霁
B	山晓雨初霁	久雨初收霁
C	宿雨天初霁	山晓雨初霁
D	山雨初含霁	山雨幸初霁
正解	**D （answer=3）**	**A （answer=0）**

両方の説明は「山间连绵阴雨刚刚有了一点停止的意思。」。 CLEVA 掲載例は 18,823 行。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

形式別件数の内訳

形式	学習	検証	テスト	合計
五言・一行	10,166	1,270	1,270	12,706
七言・一行	9,392	1,173	1,173	11,738
五言・二行	1,025	128	128	1,281
七言・二行	1,195	149	149	1,493
合計	21,778	2,720	2,720	27,218

[1] Li, Qi, Sun, Yi & Zhang (2021). CCPM: A Chinese Classical Poetry Matching Dataset. arXiv:2106.01979v1. https://arxiv.org/abs/2106.01979

正解位置は、学習・検証ともほぼ均等

answer / 表示	学習	検証
0 / A	5,324	709
1 / B	5,455	677
2 / C	5,452	661
3 / D	5,547	673

公開テストには answer がない。候補順を維持し、 0 始まりの番号を A 〜 D へ対応させた。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

分割間の一致は、比較する単位で異なる

組み合わせ	共通の説明文	共通の説明＋四候補
学習 × 検証	65	0
学習 × 公開テスト	82	1
検証 × 公開テスト	11	0

全行の説明文と四候補を、表記を変えずに比較した共通要素数。説明＋候補の一致 1 件は train14,734 行と test_public1,020 行。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

配布文字列には、空の説明や特殊な表記もある

- 公開テスト 2,026 行の translation は空文字列で、四候補は残っている。正解が非公開のため、意図した説明や答えは補っていない。
- 学習 6,518 行には「公曰：勿杀」という五言・七言に収まらない正解文字列がある。別の行には拡張漢字や文字コードを表すような文字列もあり、配布物を一律に標準漢字だけへ直していない。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

一つの JSONL 行から四候補と参照位置を読む

```
record = json.loads(line)
modern = record["translation"]
choices = record["choices"]
# train / valid
answer_index = record["answer"]  # 0, 1, 2, 3
answer_text = choices[answer_index]
```

CCPM 配布の読み方。 CLEVA の実際の prompt は、別途配布されるテンプレートで組み立てる。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

候補の細かな語と、説明の意味を対応させる

- 実例 11 の候補 A 「云深不可知」と D 「云深不知处」は、共通する語が多い。 A は「雲が深く、知りようがない」、 D は「雲が深く、居場所が分からない」と読める。
- 現代語の説明には「不知道他到底在哪」（あの人がどこにいるのか分からない）とあり、場所を表す「处」との対応が判断の手掛かりになる。

[1] THUNLP-AIPoet. CCPM. 公式配布、 commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5 、 2026-10-18 参照。 https://github.com/THUNLP-AIPoet/CCPM

参考文献

参考文献

CCPM: A Chinese Classical Poetry Matching Dataset

Wenhao Li, Fanchao Qi, Maosong Sun, Xiaoyuan Yi, Jiarui Zhang · 2021 · arXiv:2106.01979v1

古典詩と現代語訳から四択問題を構成し、似た詩句を負例として検索する。BERT 二方式の評価を報告する。

https://arxiv.org/abs/2106.01979

CCPM — Official Dataset Repository

THUNLP-AIPoet · 2021 · commit e7db1a0dc1ac1ffdd0ec91f74793c29ae9c8efa5

学習・検証・正解非公開テストの JSONL と技術報告、データ形式、正解率による評価方法を公開する。

https://github.com/THUNLP-AIPoet/CCPM

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al. · 2023 · EMNLP: System Demonstrations

中国語モデルの多様な能力を評価するプラットフォーム。 CCPM を古典中国語理解の課題へ採用する。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVAClassicalChineseUnderstandingScenario / Converter

Stanford CRFM · HELM v0.4.0 · Python 実装

外部配布データとテンプレートを読み込み、現代語説明・候補・ラベルを HELM の入力と参照へ変換する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova · 2019 · NAACL-HLT

双方向 Transformer の事前学習と、文分類などへの微調整を提案する。

https://aclanthology.org/N19-1423/

BERT-CCPoem

Zhipeng Guo, Jinyi Hu, Maosong Sun · 2020 · 公式実装

古典詩コーパスで学習したモデルと表現を公開し、 CCPM では似た詩句の検索に利用される。

https://github.com/THUNLP-AIPoet/BERT-CCPoem

参考文献

run_specs_cleva_v1.conf

Stanford CRFM · HELM v0.4.0 · CLEVA 設定

古典中国語理解を含む課題と prompt ID を設定し、同課題には 0 〜 5 の六つの ID を登録する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf