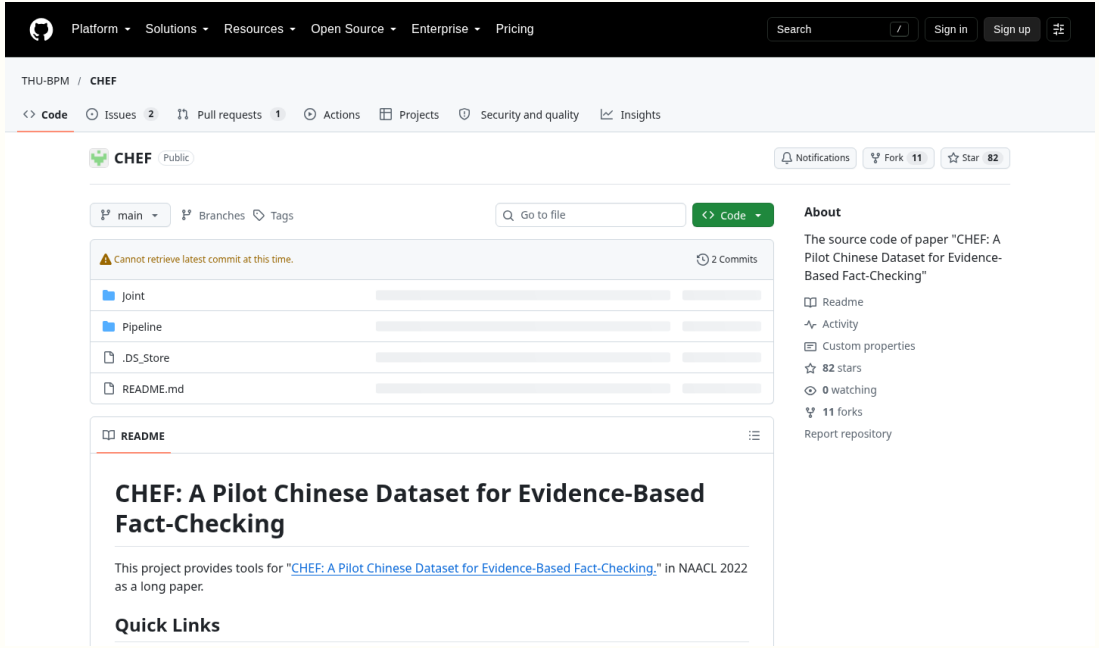
CHEF

CHinese Evidence-based Fact-checking

中国語の実在する主張を、根拠に照らして検証する

sasakiy84

CHEF の公式配布と実装



[1] THU-BPM. CHEF 公式データ・実装。 https://github.com/THU-BPM/CHEF

1. 主張と根拠を対応させる
2. 作成方法と配布の構成
3. 根拠の検索と真偽の評価
4. 利用方法と、 CLEVA への応用

主張と根拠を対応させる

主張の真偽を、根拠とともに判断する

- CHEF は、中国語で実際に流通した 10,000 件の主張を、支持・反証・情報不足の 3 ラベルで整理したデータセット。2022 年の NAACL で発表された。
- 関連文書から根拠を選び、その根拠を使って主張の真偽を判断する。各レコードは検索文書と、最大 5 文の人が選んだ根拠を持つ。実例では、主張とこの根拠を全文で示す。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

3 ラベルは、主張と根拠の関係を表す

配布 ID	ラベル	判断の意味
0	Supported / 支持	根拠によって主張が支持される
1	Refuted / 反証	根拠によって主張が反証される
2	Not Enough Information	主張を確定する情報が足りない

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

実例 1 ：金星で生命は発見されたか

中国語：主張と根拠の全文 ／ 日本語訳

主张： 2021 年，金星上没有发现生命。
标注证据：
1. 索萨・席尔瓦教授表示，金星上生存生命只是一种推测。

主張： 2021 年、金星では生命は発見されていない。
根拠：
1. ソウザ・シルバ教授は、金星に生命が存在するというのは推測にすぎないと述べた。

正解：支持

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

根拠は、生命の存在を推測と位置付ける

- 金星に生命が存在する可能性が論じられていることと、生命が発見されたことは異なる。根拠は、生命の存在は推測にとどまると述べている。

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例２：成都の受験者数と募集範囲

中国語：主張と根拠の全文

主张： 2019 年成都中考 12.08 万人招生计划只有 4.3 万。
标注证据：
1. 而 43015 是中心城区的招生计划数，中心城区是指 11+2 区域，不是整个成都市，这个计划数不是全成都市的招生计划数，直接拿中心城区计划数对比全成都市参考人数是不对的。
2. 此外，除中心城区外，其他区（市）县高中招生计划由当地教育行政部门制定并公布。

正解：反証

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例２：成都の受験者数と募集範囲（訳）

日本語訳：主張と根拠の全文

主張： 2019 年の成都の高校入試では、受験者 12 万 800 人に対し募集計画は 4 万 3,000 人しかない。
根拠：
1. 4 万 3,015 人は中心市街地の募集計画数である。中心市街地とは 11 ＋ 2 の区域を指し、成都市全体ではない。この計画数は成都市全体の募集計画ではなく、中心市街地の計画数を成都市全体の受験者数と直接比較するのは誤りである。
2. また、中心市街地以外の区・市・県の高校募集計画は、それぞれの教育行政部門が策定し、公表する。

正解：反証

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

同じ数値でも、比較する範囲が違う

- 人数を数えた地域の範囲が異なる。中心市街地の募集数と市全体の受験者数を比較していることが、反証の理由になる。

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例３：白いコウモリの体重と画像

中国語：主張と根拠の全文 ／ 日本語訳

主张：宏都拉斯白蝙蝠體重僅 5g，專吃無花果。
标注证据：
1. 網傳照片為絨毛玩具，並非真實的宏都拉斯白蝙蝠。
2. 確實有宏都拉斯白蝙蝠，牠的學名為「ectophylla alba」，身長平均 3.7 到 4.7 公分，布在中美洲地區，以無花果為主食。

主張：ホンジュラスシロヘラコウモリは体重わずか 5g で、イチジクだけを食べる。
根拠：
1. ネットで広まった写真はぬいぐるみであり、本物のホンジュラスシロヘラコウモリではない。
2. ホンジュラスシロヘラコウモリは実在する。学名は「ectophylla alba」で、平均体長は 3.7 〜 4.7cm 、中米地域に分布し、イチジクを主食とする。

正解：情報不足

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

一部が分かっても、主張全体は確定しない

- 正解は情報不足。根拠は写真と主食には触れるが、体重 5g や「それだけを食べる」という主張の全てを確定する情報はない。

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

作成方法と配布の構成

中国語の実在する主張と、多様なウェブ根拠

- 従来の検証データは英語が中心で、 Wikipedia から人工的に作った主張も多かった。 CHEF は中国語で元々書かれた主張と、複数のウェブ情報源を対象にする。
- 事実検証サイトとニュースサイトから 14,770 記事を収集。抽出した主張に時点・場所を補い、疑問形を断定文へ言い換えて、単独で検証できる形に整えた。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

検索結果から、最大 5 文の根拠を選ぶ

検証記事や報道から主張を抽出し、時点や場所を補い、断定文の形に整える。
Google 検索の上位 10 結果を収集し、誤情報サイトや答えを直接示す事実検証サイトを除く。残った文書から人が最大 5 文の根拠を選ぶ。
関連する根拠が見つからなかった主張候補 5.6 %は、作成時に除外された。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

学習 8,002 件、開発・テスト各 999 件

split	支持	反証	情報不足	合計
train	2,877	4,349	776	8,002
dev	333	333	333	999
test	333	333	333	999
計	3,543	5,015	1,442	10,000

学習は反証が多く、開発・テストは 3 ラベルが各 333 件。

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

領域は公衆衛生と社会が多い

分野	件数	割合
公衆衛生	3,679	36.79 %
社会	3,013	30.13 %
文化	1,661	16.61 %
政治	1,132	11.32 %
科学	508	5.08 %
生活	7	0.07 %

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

25 人の注釈チームが、別途の検証も行う

- 注釈者は中国語を母語とする 25 人で、うち 5 人は検証だけを担当した。著者による訓練と、複数回の試行注釈を行った。
- 310 件の主張を 5 人が再注釈し、 Fleiss の κ は 0.74 。さらに別の 310 件では、根拠だけから付けたラベルの正答率は 88.7 %、十分な情報があるとされた例が 83.6 %だった。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

根拠の検索と真偽の評価

根拠を先に選ぶ方法と、同時に学ぶ方法

方式	根拠の扱い
Pipeline	TF-IDF ・ BERT ・混合順位付けなどで先に根拠を選び、真偽分類器へ渡す
Joint	分類の学習から根拠選択にもフィードバックする。REINFORCE ・ Multi-task ・ Latent を比較
Gold Evidence	人が選んだ根拠を直接与え、分類の性能を測る

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

Micro F1 と Macro F1 を、 5 試行で比較する

- Micro F1 は全体の分類結果を集計する。 1 件 1 ラベルの 3 クラス分類では、正解率と同じ値になる。 Macro F1 は各クラスの F1 を等しい重みで平均する。
- 2022 年の比較は、独立した 5 回の実行による平均と標準偏差を報告する。 BERT 系・ Attention 系・ Graph 系の 3 分類器を、根拠の条件を変えて評価した。
- テストは 999 件で各クラス 333 件。根拠を選ぶ段階から評価する条件と、人が選んだ根拠を直接与える条件を比較する。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

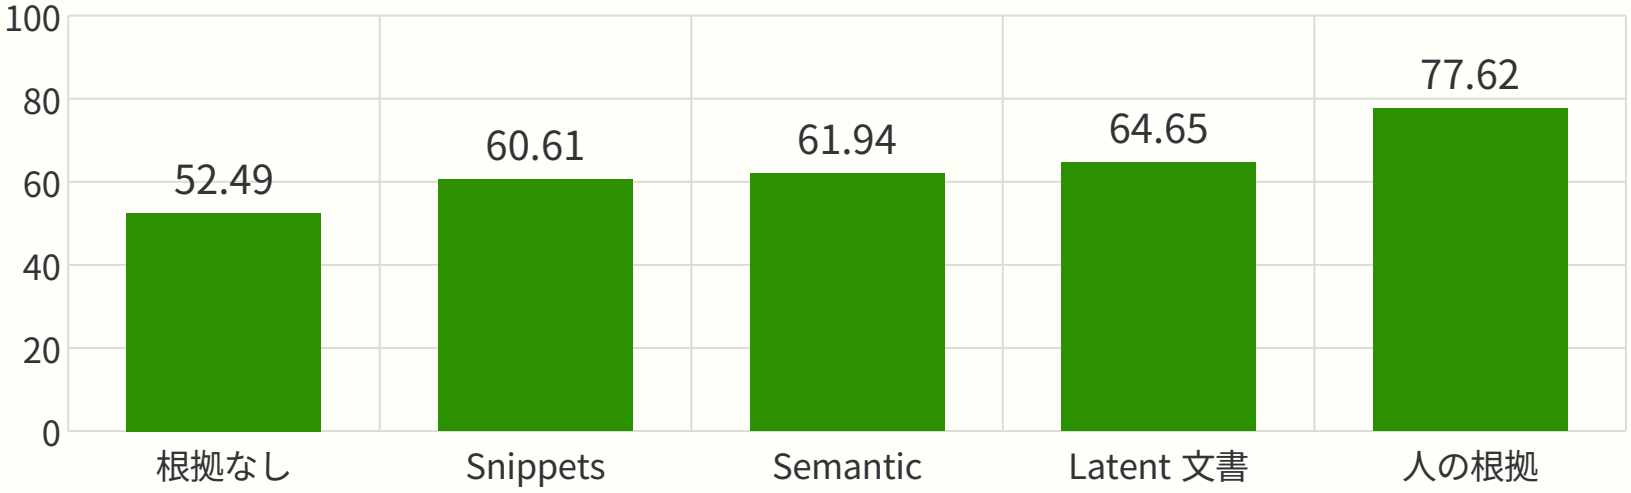
BERT 分類器：根拠の条件で性能が変わる

方式・根拠	Micro F1	Macro F1
Pipeline ／根拠なし	54.46±2.89	52.49±2.44
Pipeline ／ Semantic	63.47±1.71	61.94±1.66
Joint Latent ／文書	66.77±1.43	64.65±1.74
Pipeline ／人の根拠	78.99±0.82	77.62±1.02

F1 （%）。同じ BERT 分類器を使い、 5 回の実行の平均 ± 標準偏差を示す。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

根拠なしと、人が選んだ根拠の差



同じ BERT 分類器で、根拠の与え方を変えた Macro F1 （%）。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

根拠検索が、事実検証の課題になる

- 人が選んだ根拠を使う BERT 系の Macro F1 は 77.62 、文書から選ぶ Latent では 64.65 。根拠を見つける段階にも課題が残る。
- Graph 系 Latent の文書条件は Micro 69.12 、 Macro 65.26 。人の根拠を使う Graph 系は 79.84 、 78.47 だった。
- 検索結果の短い要約だけでは、時点・数値の範囲・否定など、判断に必要な情報が欠ける場合がある。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

利用方法と、 CLEVA への応用

CLEVA では、主張を三択で判定する

- 中国語モデル評価プラットフォーム CLEVA は、事実確認課題に CHEF の主張を採用した。
- HELM の公開コードにある金星の例は、「真実・虚假・信息不足」から答える三択式で、根拠文を入力に含めない。元の CHEF には、根拠を検索・選択する課題もある。
- CLEVA で使われた全問題や抽出範囲は、公開説明からは確認できない。

[1] Li et al. (2023). CLEVA. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM. HELM: CLEVAFactCheckingScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

CLEVA での出題例：金星の生命発見

请判断以下陈述是否为真实的。
陈述： 2021 年，金星上没有发现生命。
A. 真实　B. 虚假　C. 信息不足
答案：

次の記述が真実か判定する。
記述： 2021 年、金星で生命は発見されていない。
A. 真実　B. 虚偽　C. 情報不足
答え：

正解： A （真実）／ CHEF では支持

[1] Stanford CRFM. HELM: CLEVAFactCheckingScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

主張・検索文書・根拠を JSON で取得する

- 公式リポジトリから CHEF.tar.gz を取得すると、学習・開発・テスト用の JSON が得られる。
- claim は主張、 label は 3 分類の正解。 evidence は検索文書、gold evidence は人が選んだ根拠を格納する。
- Joint/LICENSE の MIT ライセンスは実装コードへの許諾。データ全体の利用許諾は明示されておらず、記事本文の権利は各提供元に帰属する。

[1] THU-BPM. CHEF 公式データ・実装。 https://github.com/THU-BPM/CHEF
[2] Stanford CRFM. HELM: CLEVAFactCheckingScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

主張・根拠・ラベルの対応を読む

- CHEF は、実在する中国語の主張 10,000 件に、検索文書と人が選んだ根拠を結び付けた事実検証データである。
- 支持・反証・情報不足は、根拠と主張の関係を表す。成都の例では人数の地域範囲、金星の例では発見と推測の差が判断の要点になる。
- 人が選んだ根拠を与えた場合より、根拠を検索・選択する場合の成績が低く、必要な根拠を見つけることが課題として残る。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/
[2] Li et al. (2023). CLEVA. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

Appendix

1. 追加 10 件の主張と根拠
2. 根拠データの特徴と評価結果
3. 研究と参考文献

追加 10 件の主張と根拠

実例 4 ：発熱のない感染者と伝播

中国語：主張と根拠の全文

主张：有些感染了新冠病毒的病人没有发热，但也会传染给别人。
标注证据：
1. 不过有些患者仅出现很轻微的症状，在隔离观察期间也不一定会被发现，也常常被认为是无症状。
2. 这些传染性疾病的一个特点是无症状感染患者和有症状的患者会共同存在，而现在的新冠病毒也是如此。
3. 从群体水平来看，由无症状感染者传播的病例占总发病人数的构成比有 4.4% 。

正解：支持

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 4 ：発熱のない感染者と伝播（訳）

日本語訳：主張と根拠の全文

主張：新型コロナウイルスに感染した患者の中には発熱がなくても、他人へ感染させる人がいる。
根拠：
1. ただし、ごく軽い症状しか出ない患者もおり、隔離観察中にも発見されるとは限らず、無症状と見なされることも多い。
2. こうした感染症の特徴の一つは、無症状の感染者と症状のある患者が共存することで、今回の新型コロナウイルスも同様である。
3. 集団全体で見ると、無症状感染者から伝播した症例は、総発症者数の 4.4 %を占める。

正解：支持

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 5 ：地下鉄カードの無料配布という告知

中国語：主張と根拠の全文 ／ 日本語訳

主张： 2020 年 12 月太原地铁限量版地铁卡免费送
标注证据：
1. 对此，太原中铁轨道交通建设运营有限公司作为太原地铁乘车票卡的独家发行方，在此特别提醒：目前有关太原地铁 2 号线所有乘车票卡还未正式对外发售，会适时在相应官方平台对外发布地铁 2 号线所有的种类、样式车票及购买方式，市民莫要轻信网上不实信息。

主張： 2020 年 12 月、太原地下鉄の限定版乗車カードを無料配布する。
根拠：
1. これに対し、太原中鉄軌道交通建設運営有限公司は、太原地下鉄乗車カードの独占発行者として注意を呼びかけた。現在、太原地下鉄 2 号線の乗車カードは、どの種類も正式には発売していない。種類・デザイン・購入方法は、適切な時期に公式媒体で公表する。市民はネット上の虚偽情報を軽々しく信じないでほしい。

正解：反証

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 6 ：地球の自転と地震の相関

中国語：主張と根拠の全文

主张：地球自转变慢，导致地震频繁。
标注证据：
1. 目前研究显示，地球自转和地球上地震活动之间的相关性并不显著。
2. 因为之前文章有类似题材，也提到过增速自转和地震活动之间的关系，虽然有一些统计结果，但分析认为统计关系不是非常显著，不能作为地球活动增强或者预测某一种趋势的依据。
3. 地球上的一些大地震都是板块构造运动的结果，委内瑞拉东北部沿岸近海地区发生 7.3 级地震，与之前的印尼龙目岛地震都处于环太平洋地震带。

正解：反証

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 6 ：地球の自転と地震の相関（訳）

日本語訳：主張と根拠の全文

主張：地球の自転が遅くなると、地震が頻発する。
根拠：
1. 現在の研究では、地球の自転と地震活動の間に、顕著な相関は認められていない。
2. 以前の記事でも似た題材として、自転の加速と地震活動の関係に触れていた。統計的な結果はあるが、分析では統計的関係はそれほど顕著でなく、地球活動の活発化や特定の傾向を予測する根拠にはできないとされた。
3. 地球上の大地震の一部は、プレートの構造運動による。ベネズエラ北東部沿岸沖で起きたマグニチュード 7.3 の地震も、それ以前のインドネシア・ロンボク島の地震も、環太平洋地震帯で発生した。

正解：反証

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 7 ：かみ跡で金の真偽を判定できるか

中国語：主張と根拠の全文 ／ 日本語訳

主张：用牙齿咬可以辨别黄金真假。
标注证据：
1. 据了解，人牙齿的莫氏硬度为 6 ，黄金和银的相对莫氏硬度为 2.53 ，纯铜的莫氏硬度为 3 ，铁为 4 ，很多金属材料的硬度都比较低，用牙齿咬都会留下明显的咬痕，所以用牙咬来判断真伪没有科学依据。

主張：歯でかめば、金が本物かどうか見分けられる。
根拠：
1. 調べたところ、人の歯のモース硬度は 6 、金と銀の相対的なモース硬度は 2.53 、純銅は 3 、鉄は 4 である。多くの金属は硬度が比較的低く、歯でかめば明瞭なかみ跡が残る。このため、かみ跡による真偽の判定には科学的根拠がない。

正解：反証

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 8 ：ビタミン C と A の「黄金法則」

中国語：主張と根拠の全文

主张：早上使用具有抗氧化作用的维生素 C 类产品，晚上使用抗衰老的维生素 A 类产品，是护肤的黄金法则。
标注证据：
1. 这种“黄金公式”搭配并不是因为维生素 C 和维生素 A 是美白抗老界的完美 CP ，有可能只是因为叫着顺嘴或是为了捆绑销售。
2. 这也是为什么视黄醇在皮肤学界公认具有抗衰老作用。

正解：情報不足

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 8 ：ビタミン C と A の「黄金法則」（訳）

日本語訳：主張と根拠の全文

主張：朝は抗酸化作用のあるビタミン C 製品を使い、夜は抗老化作用のあるビタミン A 製品を使うことが、スキンケアの黄金法則である。
根拠：
1. この「黄金の組合せ」は、ビタミン C とビタミン A が美白・抗老化の完璧な相棒だからというわけではない。単に言いやすい名前だから、あるいは抱き合わせ販売のためかもしれない。
2. これも、皮膚科学界でレチノールの抗老化作用が認められている理由である。

正解：情報不足

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 9 ：歌手の親族関係と曲名

中国語：主張と根拠の全文 ／ 日本語訳

主张：帕華洛帝的孫女演唱親愛的爺爺。
标注证据：
1. 網傳影片中的歌手為荷蘭女音樂家艾蜜拉．維莉哈根，她並非義大利男高音帕華洛帝的孫女。
2. 網傳影片中的曲目為義大利作曲家普契尼（ Puccini ）作品〈親愛的爸爸〉，並非「親愛的爺爺」。

主張：パヴァロッティの孫娘が「親愛なるおじいさん」を歌っている。
根拠：
1. ネットで広まった動画の歌手は、オランダの音楽家アミラ・ウィルハーフンであり、イタリアのテノール歌手パヴァロッティの孫娘ではない。
2. 動画の曲は、イタリアの作曲家プッチーニの作品「私のお父さん」であり、「親愛なるおじいさん」ではない。

正解：反証

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 10 ：人民元の基準値と前営業日

中国語：主張と根拠の全文 ／ 日本語訳

主张： 2020 年 11 月 30 日人民币对美元汇率中间价下调 27 个基点。
标注证据：
1. 新华社上海 11 月 30 日电 来自中国外汇交易中心的数据显示， 30 日人民币对美元汇率中间价报 6.5782 ，较前一交易日下调 27 个基点。
2. 前一交易日，人民币对美元汇率中间价报 6.5755 。

主張： 2020 年 11 月 30 日、人民元の対米ドル為替基準値は 27 ベーシスポイントの人民元安となった。
根拠：
1. 新華社上海 11 月 30 日電。中国外貨取引センターのデータによると、 30 日の人民元の対米ドル為替基準値は 6.5782 で、前営業日から 27 ベーシスポイントの人民元安となった。
2. 前営業日の人民元の対米ドル為替基準値は 6.5755 だった。

正解：支持

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 11 ：映画会社が公表した作品一覧

中国語：主張と根拠の全文

主张： 2020 年华人影业发布新片片单，《三叉戟》《巨齿鲨 2 》在列。
标注证据：
1. 中新网 12 月 10 日电 9 日， 2020 华人影业战略发布会在北京举行，并揭晓了片单。
2. 华人影业一口气公布 29 部新片片单，并邀请了众多影片主创到场推介。
3. 29 部新片涵盖了不同题材、不同风格，其中也包括高群书执导的《三叉戟》和惊险大片《巨齿鲨 2 》。

正解：支持

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 11 ：映画会社が公表した作品一覧（訳）

日本語訳：主張と根拠の全文

主張： 2020 年、華人影業が新作映画の一覧を公表し、「三叉戟」と「巨歯鮫 2 」が含まれた。
根拠：
1. 中国新聞網 12 月 10 日電。 9 日、 2020 年華人影業戦略発表会が北京で開かれ、作品一覧が公表された。
2. 華人影業は 29 本の新作一覧を一度に公表し、多数の制作関係者を招いて紹介した。
3. 29 本は多様な題材・作風にわたり、高群書監督の「三叉戟」とスリラー大作「巨歯鮫 2 」も含まれる。

正解：支持

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 12 ：「 60 年で最も寒い冬」という予測

中国語：主張と根拠の全文

主张： 2020 年冬天是 60 年来最冷寒冬。
标注证据：
1. 而最近，冷空气又在发力，于是，网络上关于“最冷冬天”的消息、短视频不断发酵，有人称“根据气象学专家分析， 2020 年有可能成为 2008 年以来最寒冷的冬天”“‘拉尼娜现象’持续升级，专家表示今冬明春恐多有暴雪，今年可能是 60 年来最冷的冬天。
2. “60 年来最冷”每次拉尼娜事件的影响不尽相同今冬偏冷还是偏暖需科学分析综合研判“今冬将现 60 年来最寒冷冬天、最严重降雪”“ 2008 年以来的最冷一年”“这一切都与拉尼娜有关”……最近多个小视频和帖子在微博、微信、朋友圈、论坛等广为流传，而且言之凿凿。

正解：情報不足

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 12 ：「 60 年で最も寒い冬」という予測（訳）

日本語訳：主張と根拠の全文

主張： 2020 年の冬は、過去 60 年間で最も寒い冬である。
根拠：
1. 最近また寒気が強まり、ネットで「最も寒い冬」の情報や短い動画が広がっている。「気象専門家の分析では、 2020 年は 2008 年以来最も寒い冬になる可能性がある」「ラニーニャ現象が強まり続け、専門家は今冬から来春にかけて大雪が多く、今年は過去 60 年間で最も寒い冬になるかもしれないと述べた」とするものもある。
2. 「 60 年で最も寒い」。ラニーニャ現象の影響は毎回異なり、今冬が平年より寒いか暖かいかは、科学的に分析し総合判断する必要がある。「今冬は 60 年で最も寒く、雪も最も多い」「 2008 年以来最も寒い年」「全てラニーニャが原因だ」……。最近、こうした動画や投稿が微博・微信・朋友圏・掲示板などで広まり、断定的に語られている。

正解：情報不足

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

実例 13 ：デジタル人民元と紙幣の共存

中国語：主張と根拠の全文 ／ 日本語訳

主张：数字人民币和纸钞将长期并存。
标注证据：
1. “ 在可预见的将来，数字人民币和纸钞将长期并存。
2. 在可预见的将来，数字人民币和纸钞将长期并存。
3. 我个人觉得，在可预见的将来，数字人民币和纸钞将长期并存。

主張：デジタル人民元と紙幣は、長期にわたり共存する。
根拠：
1. 「予見できる将来において、デジタル人民元と紙幣は長期にわたり共存する。
2. 予見できる将来において、デジタル人民元と紙幣は長期にわたり共存する。
3. 私個人は、予見できる将来において、デジタル人民元と紙幣は長期にわたり共存すると思う。

正解：支持

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

根拠データの特徴と評価結果

人が選んだ根拠がある主張は 7,842 件

対象	学習	開発	テスト	計
根拠が空の主張	1,552	310	296	2,158
人が選んだ根拠文	16,254	1,775	1,856	19,885
検索文書	34,985	4,057	4,030	43,072

根拠が空の 2,158 件にも、支持 394 件・反証 897 件・情報不足 867 件のラベルが付く。根拠を入力に使う場合は、この欠測を考慮する。

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

BERT 系：根拠別の評価結果（1/2）

方式・根拠	Micro F1	Macro F1
Pipeline / 根拠なし	54.46±2.89	52.49±2.44
Pipeline / Snippets	62.07±2.55	60.61±2.96
Pipeline / Surface	63.17±1.67	61.47±2.02
Pipeline / Semantic	63.47±1.71	61.94±1.66
Pipeline / Hybrid	63.29±1.65	61.80±2.31
REINFORCE / Snippets	63.76±1.52	61.74±1.88

平均 ± 標準偏差、5 独立実行。REINFORCE ・ Multi-task ・ Latent は Joint 。—は未報告。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

BERT 系：根拠別の評価結果（2/2）

方式・根拠	Micro F1	Macro F1
REINFORCE / Documents	64.37±1.65	62.46±1.72
Multi-task / Snippets	62.78±1.41	61.98±2.59
Multi-task / Documents	65.02±1.46	63.12±1.78
Latent / Snippets	64.45±1.68	62.52±2.23
Latent / Documents	66.77±1.43	64.65±1.74
Pipeline / Gold	78.99±0.82	77.62±1.02

平均 ± 標準偏差、5 独立実行。REINFORCE ・ Multi-task ・ Latent は Joint 。—は未報告。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

Attention 系：根拠別の評価結果（1/2）

方式・根拠	Micro F1	Macro F1
Pipeline / 根拠なし	54.87±1.95	53.47±2.82
Pipeline / Snippets	62.42±2.31	60.24±2.56
Pipeline / Surface	63.77±1.89	62.65±2.32
Pipeline / Semantic	63.95±1.46	62.80±1.33
Pipeline / Hybrid	63.48±1.22	62.74±1.30
REINFORCE / Snippets	64.06±1.76	61.97±1.04

平均 ± 標準偏差、 5 独立実行。 REINFORCE ・ Multi-task ・ Latent は Joint 。 —は未報告。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

Attention 系：根拠別の評価結果（2/2）

方式・根拠	Micro F1	Macro F1
REINFORCE / Documents	64.86±1.83	62.66±1.32
Multi-task / Snippets	64.43±1.72	61.58±1.34
Multi-task / Documents	65.45±1.59	62.94±2.03
Latent / Snippets	65.73±1.75	63.44±1.68
Latent / Documents	67.62±1.48	64.81±1.26
Pipeline / Gold	79.18±1.07	78.36±1.40

平均 ± 標準偏差、 5 独立実行。 REINFORCE ・ Multi-task ・ Latent は Joint 。 —は未報告。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

Graph 系：根拠別の評価結果（1/2）

方式・根拠	Micro F1	Macro F1
Pipeline / 根拠なし	—	—
Pipeline / Snippets	62.78±1.70	61.06±2.59
Pipeline / Surface	64.58±1.45	61.46±1.72
Pipeline / Semantic	64.67±1.54	62.28±1.50
Pipeline / Hybrid	64.37±1.66	62.58±1.43
REINFORCE / Snippets	65.77±1.23	62.34±1.11

平均 ± 標準偏差、 5 独立実行。 REINFORCE ・ Multi-task ・ Latent は Joint 。 —は未報告。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

Graph 系：根拠別の評価結果（2/2）

方式・根拠	Micro F1	Macro F1
REINFORCE / Documents	66.58±1.45	63.47±1.58
Multi-task / Snippets	66.21±1.57	63.15±1.46
Multi-task / Documents	67.46±1.72	64.31±1.81
Latent / Snippets	67.81±1.74	64.34±1.57
Latent / Documents	69.12±1.13	65.26±1.67
Pipeline / Gold	79.84±1.24	78.47±1.17

平均 ± 標準偏差、5 独立実行。REINFORCE ・ Multi-task ・ Latent は Joint 。— は未報告。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

JSON から、主張・正解・根拠を読む

```
import json
rows = json.load(open("train.json", encoding="utf-8"))
claim = "2021 年，金星上没有发现生命。"
record = next(r for r in rows if r["claim"] == claim)
print(record["claim"])
print(["支持", "反証", "情報不足"][record["label"]])
for sentence in record["gold evidence"].values():
    if sentence["text"]:
        print(sentence["text"])
```

実例 1 の主張、正解「支持」、人が選んだ根拠文が得られる。

[1] THU-BPM. CHEF データセット。 https://drive.google.com/file/d/1QKe9i-yXDKh87p4ukRFSnzE03-hAzMto/view

研究と参考文献

中国語の検証基盤を、検索と推論へ広げる

- Xuming Hu 、 Zhijiang Guo 、 Guanyu Wu 、 Aiwei Liu 、 Lijie Wen 、 Philip S. Yu が 2022 年に発表。第一著者 Hu と Guo は同等貢献と記される。
- 清華大学、ケンブリッジ大学、イリノイ大学シカゴ校の研究者による研究で、非英語の実在主張を検証する資源を整備した。

[1] Hu et al. (2022). CHEF. NAACL-HLT. https://aclanthology.org/2022.naacl-main.246/

参考文献

CHEF: A Pilot Chinese Dataset for Evidence-Based Fact-Checking

Xuming Hu, Zhijiang Guo, Guanyu Wu, Aiwei Liu, Lijie Wen, Philip S. Yu · 2022 · NAACL-HLT, pp3362–3376

中国語の実在主張、検索文書、注釈根拠を構築し、 Pipeline と Joint の検証モデルを比較する。

https://aclanthology.org/2022.naacl-main.246/

CHEF — official repository and dataset

THU-BPM · 公式データ・実装

原 train/dev/test の配布リンクと、根拠選択・分類のモデル実装を公開する。

https://github.com/THU-BPM/CHEF

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al.・2023・EMNLP System Demonstrations, pp186–217

中国語モデルを多様な課題で評価するプラットフォームで、事実確認の素材に CHEF を採用する。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVAFactCheckingScenario

Stanford CRFM・HELM v0.4.0・Python 実装

CLEVA 形式の事実確認課題を HELM へ適用し、金星の主張を使った選択式の公開例を示す。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py