ChID

Chinese IDiom Dataset for Cloze Test

文脈と類義語の違いから、中国語の成語を選ぶ

sasakiy84

公式公開元：原論文版とコンテスト版の案内

README Apache-2.0 license

ChID-Dataset

The ChID Dataset for paper **ChID: A Large-scale Chinese IDiom Dataset for Cloze Test**.

If you have any problem or suggestion, feel free to contact me: chujiezhengchn@gmail.com

If your research is related to or based on our ChID dataset (or the version adapted for the competition), please kindly cite it:

```
@inproceedings{zheng-etal-2019-chid,
    title = "{C}h{ID}: A Large-scale {C}hinese {ID}iom Dataset for Cloze Test",
    author = "Zheng, Chujie  and
      Huang, Minlie  and
      Sun, Aixin",
    booktitle = "ACL",
    year = "2019"
}
```

Download Link

HuggingFace.

Data Description

One example is shown below:

```
{
    "content": "世锦赛的整体水平远高于亚洲杯，要如同亚洲杯那样“鱼与熊掌兼得”，就需要各方面密切配合、#idiom#。",
    "realCount": 2,
    "groundTruth": ["通力合作", "有的放矢"],
    "candidates": [
        ["凭空捏造", "高头大马", "通力合作", "同舟共济", "和衷共济", "莲头蚯面", "紧锣密鼓"],
        ["叫苦连天", "量体裁衣", "全榜题名", "百战不殆", "知彼知己", "有的放矢", "风流才子"]
    ]
}
```

- `content` : The given passage where the original idioms are replaced by placeholders `#idiom#`
- `realCount` : The number of placeholders or blanks

[1] Zheng, Huang & Sun (2019). ChID-Dataset. https://github.com/chujiezheng/ChID-Dataset

1. 文章に合う成語を、候補から選ぶ
2. 成語の語彙・文章・候補の作り方
3. 空欄ごとの正解率と候補の難しさ
4. 配布形式の違いと CLEVA での利用

文章に合う成語を、候補から選ぶ

文章の空欄に、もっとも合う成語を入れる

- ChID は、中国語の成語を選ぶ穴埋め読解データ。成語は、短い形に意味が凝縮された慣用表現で、このデータでは四字の成語を対象とする。
- 文章内の成語を空欄記号に置き換え、もとの成語を選ぶ。原論文版では、各空欄に七つの候補が付く。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

実例１：足場の材料に求める条件

中国語：在印度和亚洲其他国家，竹子因 #idiom# 、易于切割和运输常被用于搭建脚手架。
日本語：インドやアジアのほかの国々では、竹は ____ で、切ったり運んだりしやすいため、足場を組むのによく使われる。

A. 供不应求：需要に供給が追いつかない
B. 物美价廉：品質が良く、価格が安い
C. 货真价实：本物で、値段に見合う
D. 独树一帜：独自の特色を持つ

E. 两小无猜：幼い男女が無邪気に親しむ
F. 监主自盗：管理する物を自ら盗む
G. 自由自在：自由で気まま

正解： B　物美价廉

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例２：才能を得るまでの経験を述べる

中国語：不过，要想变得 #idiom#, 要想自己能够成就一番事业的话，不是说来就来的，或者说任何一个出色的人，他们都得经历过不少的磨难，以及在经受住了一些挫折之后，才能真正成才成人，才能成为一个实力超群的人物，让自己的人生过得越来越顺当 ...
日本語：しかし、 ____ になり、自分で何かを成し遂げようと思っても、すぐにできるものではない。優れた人は誰でも、多くの苦難を経験し、挫折に耐えた後で初めて本当に成長し、実力の抜きんでた人物となり、人生がますます順調に進むようになる…

A. 足智多谋：知恵と策略に富む
B. 低眉顺眼：目を伏せて従順にする
C. 问长问短：あれこれ細かく尋ねる
D. 嘘寒问暖：暮らしや体調を気遣う
E. 语无伦次：話の筋が通らない
F. 绣花枕头：見かけだけ立派で中身がない
G. 牵肠挂肚：気がかりで心が離れない

正解： A　足智多谋

[1] CLUE team (2021). FewCLUE — ChID. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/chid

実例３：映画の台詞が三姉妹の定評になる

中国語： 1997 年上映的电影《宋家王朝》中 , 影星杨紫琼 , 张曼玉 , 邬君梅 , 分别扮演宋霭龄 , 宋庆龄 , 宋美龄 , 其片头语“遥远的旧中国有三姐妹 , 一个爱钱 , 一个爱国 , 一个爱权”不胫而走 , 却也 #idiom#, 成为对宋氏三姐妹的总体评价。图中是《宋家王朝》的 ...
日本語： 1997 年公開の映画『宋家王朝』では、楊紫瓊、張曼玉、鄔君梅が、それぞれ宋靄齢、宋慶齢、宋美齢を演じた。冒頭の「遠い昔の中国に三人の姉妹がいた。一人は金を、一人は国を、一人は権力を愛した」という言葉は広く伝わり、一方で ____ 、宋家の三姉妹への総括的な評価となった。写真は『宋家王朝』の…

A. 异想天开：突飛な空想をする
B. 时移世易：時が移り世の中が変わる
C. 半生半熟：生煮えで、まだ未熟
D. 言之凿凿：確信に満ちた言い方をする
E. 大有可为：大いに力を発揮できる
F. 喧宾夺主：脇役が主役をしのぐ
G. 焕然一新：すっかり新しくなる

正解： D　言之凿凿

[1] CLUE team (2021). FewCLUE — ChID. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/chid

文字だけでなく、成語全体の使い方を読む

- 成語には、構成する文字から意味をそのまま足し合わせられない表現がある。「绣花枕头」は、見かけが立派でも中身がないという比喩。「足智多谋」は知恵や策略に富むことを表す。
- 近い意味を持つ成語でも、話す様子、話の内容、態度など、使う対象が異なる。文章の前後と候補の細かな違いを照合する。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

成語の語彙・文章・候補の作り方

成語を整え、文章を集め、候補を付ける

表記を整え、学習に十分な出現頻度のある四字成語 3,848 種類を選ぶ。

ニュース・小説・エッセイから文章を集め、長さや成語の頻度を調整して空欄を作る。

正解に、意味の似た成語三つと無作為の成語三つを加え、七択問題にする。候補選びには人手による意味関係の調査も用いた。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

表記をそろえ、学習できる頻度の成語を残す

- 成語辞典の 23,000 件超から四字の表現を残し、事前学習済みの単語ベクトルを持たない語を除いた。同じ意味で一字や語順だけが違う表記は、辞典の参照関係を使ってそろえる。
- コーパスで 20 回未満しか現れない語も除き、候補に使う 3,848 種類の成語を選んだ。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

段落を基本単位にし、十分な文脈を残す

- ニュースは THUCNews 、小説とエッセイはインターネット上の文章から集めた。二重引用符内の成語は、そのままでは推測しにくい名前などを含むため、空欄化の対象から外した。
- 100 文字未満の段落は次の段落と結合し、 600 文字を超える文章は除く方針を用いた。頻出成語だけを含む文章の一部も除き、頻度の偏りを抑えた。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

七候補は、正解一つ・似た三語・無作為の三語

1. 正解とのベクトル類似度が 0.7 より高い語を除く
2. 残った上位 10 語から、三語を無作為に選ぶ
3. 上位 10 語以外から、さらに三語を無作為に選ぶ
4. 正解一語と合わせ、候補の順番を入れ替える

同義語そのものを避けつつ、似ているが使い分けの必要な語を含めるための設計。類似度は成語ベクトルのコサイン類似度。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

原論文版は 580,807 文章、 728,713 空欄

集合	文章数	空欄数	正解
Train	520,711	648,920	あり
Dev	20,000	24,822	あり
Test	20,000	24,948	あり
Out	20,096	30,023	あり

Ran と Sim は、 Test と同じ文章で候補だけを変えた評価集合。 Ran は無作為の候補、Sim は似た候補が中心。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/
[2] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

エッセイで、領域外への一般化を調べる

範囲	文章の領域	平均語数	一文章の空欄数
領域内 Train/Dev/Test	ニュース・小説	99	1.25 / 1.24 / 1.25
領域外 Out	エッセイ	127	1.49

語数は、 Jieba による分かち書きで数えた値。 Out の文章は、領域内の文章より長く、空欄も多い。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

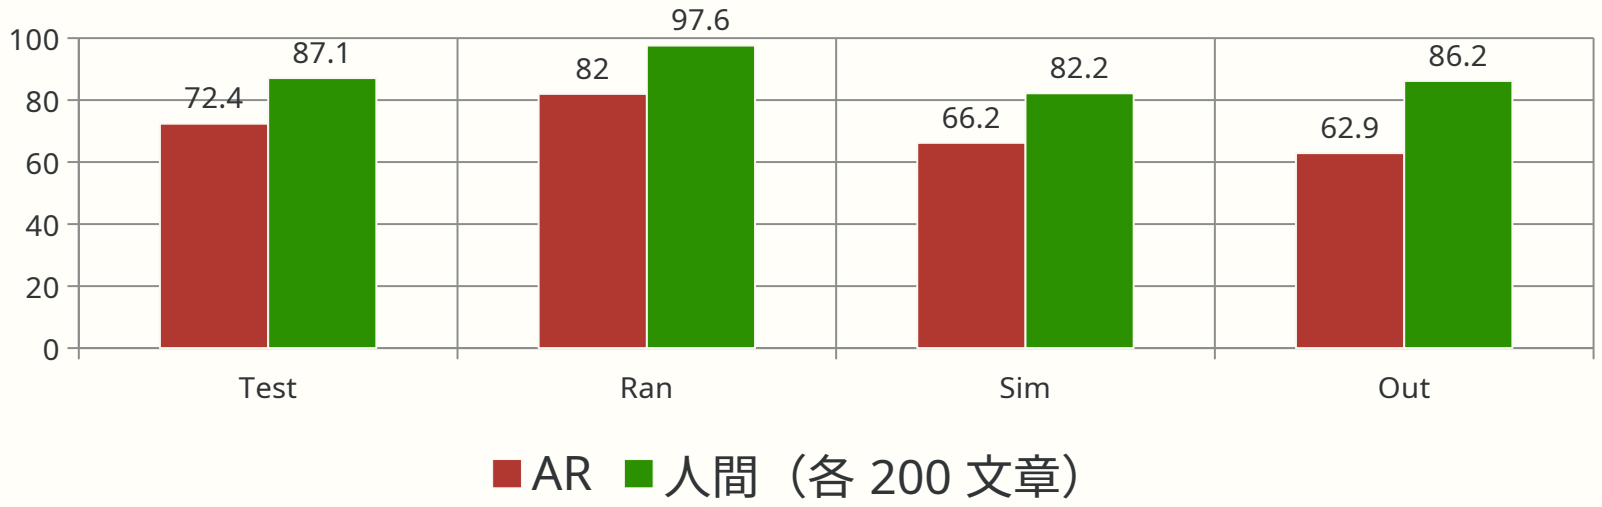
空欄ごとの正解率と候補の難しさ

評価は、各空欄で正しい候補を選べた割合

- 空欄ごとに一つの候補を予測し、正解した空欄数を、評価した空欄数で割る。複数の空欄がある文章も、一つずつ採点する。
- 原論文版は各空欄が七択。各候補を等確率に選ぶ場合の期待正解率は約 14.29% 。モデルは文章の文脈を使い、もとの成語を選ぶ。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

候補が似ているほど、人もモデルも選びにくい



Accuracy (%)。 Ran は無作為の候補、 Sim は似た候補が中心。 AR は各集合全空欄、人間は各 200 文章を 3 人が解いた平均。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

文脈へ注意を向ける AR は、 Test で 72.4%

2019 年の評価対象	Test	Out
双方向 LSTM 言語モデル（ LM ）	71.5	61.5
Attentive Reader （ AR ）	72.4	62.9
Stanford Attentive Reader （ SAR ）	71.5	61.7

Accuracy (%) 。 LM は空欄位置の表現から候補を選び、 AR/SAR は周囲の文脈へ注意を向けて候補を比較する。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

AR は、成語全体のベクトルで最も高い精度

成語の表現（2019 年）	Test Accuracy (%)
成語を一語として表す	72.4
四文字のベクトルを平均する	63.8
四文字のベクトルを MLP で合成する	66.5

同じ AR で表現方法を比較。 MLP は文字の表現から成語の表現を学ぶ多層パーセプトロン。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

配布形式の違いと CLEVA での利用

同じ ChID でも、候補を共有する単位が違う

配布・利用	入力と候補
ACL 2019 原論文版	一つの文章、空欄ごとに七候補
コンテスト / CLUE 版	複数文章の組が、十候補を共有
FewCLUE 版	一つの空欄と七候補、少数例学習
CLEVA の公開紙面	文化知識の成語問題、掲載例では三候補

[1] Zheng, Huang & Sun (2019). ChID-Adapt. https://github.com/chujiezheng/ChID-Dataset/blob/master/Competition/README.md
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

CLUE 版では、複数の文章が十候補を共有する

分割	問題群	文章	空欄
train	84,709	461,242	577,157
dev	3,218	18,644	23,011
test 1.0	3,231	18,725	23,209
test 1.1	3,447	34,470	34,470

学習・開発の正解は別の JSON に入っている。公開 ZIP には、 test 1.0 と test 1.1 の正解は含まれない。

[1] CLUE team. ChID 公式公開 ZIP 、原配布 README の CLUE 1.0 / 1.1 。 https://storage.googleapis.com/cluebenchmark/tasks/chid_public.zip

FewCLUE は、正解位置ごとに六問ずつ選ぶ

ファイル群	問題数	正解
train_0 ～ 4 / dev_0 ～ 4	各 42	0 ～ 6 、各位置 6 問
train_few_all / dev_few_all	各 202	あり
test_public	2,002	各位置 286 問
test / unlabeled	2,000 / 7,585	なし

学習・開発の集約版は、五つの小集合を合わせ、重複を除いた各 202 問。一つの空欄と七候補を持つ。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498
[2] CLUE team (2021). FewCLUE — ChID. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/chid

CLEVA は、成語の穴埋めで文化知識を評価する

- CLEVA は、中国語モデルの文化知識を調べる課題として、 ChID の成語の穴埋めを用いる。公開論文の例は実例 2 と同じ文章で、「足智多谋」「语无伦次」「绣花枕头」の三候補から正解 A を選ぶ。
- HELM にも同課題の実装があり、実例 3 の映画の文章を七候補で示している。いずれの例も FewCLUE の公開問題に含まれる。
- CLEVA で評価に使った問題の総数は、公開説明には記されていない。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM. CLEVACulturalKnowledgeScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

公式配布を入手し、 ChID 論文を引用して利用する

- 作者の公式 GitHub は、原論文版とコンテスト版の配布を案内し、利用時に ChID 論文の引用を求める。リポジトリのライセンスは Apache License 2.0 。
- 素材にはニュースや文学作品が含まれる。元文章の権利や引用条件は、作品・配布元の情報を確認する。

[1] Zheng, Huang & Sun (2019). ChID-Dataset. https://github.com/chujiezheng/ChID-Dataset
[2] ChID-Dataset. Apache License 2.0. https://github.com/chujiezheng/ChID-Dataset/blob/master/LICENSE

まとめ：文脈に合う成語を選ぶ

- ChID 原論文版は 580,807 文章・ 728,713 空欄で、正解に似た候補を含む七択を作る。成語全体の意味と、類義語の使い分けを測る読解課題。
- 2019 年の AR の正解率は Test で 72.4% 、似た候補が中心の Sim で 66.2% 。後に、十候補を共有する CLUE 版や少数例学習の FewCLUE 版が公開され、 CLEVA の文化知識の評価にも用いられた。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP: System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

Appendix

1. 追加 10 問の原文と日本語訳
2. 入力の読み方と候補選び
3. 参考文献

実例 4 ：欠場者の多いチームの見通し

中国語：不过从目前双方的态势来看，掘金队全队士气高涨。而火箭队则是伤病不断，刚要凑齐主要阵容，主控阿尔斯通又要缺阵。今晚的比赛对火箭队来说是 #idiom# 。
日本語：現在の両チームを見ると、ナゲッツは全員の士気が高い。一方、ロケッツではけがや体調不良が相次ぎ、主力がそろいかけたところで、司令塔のアルストンがまた欠場する。今夜の試合はロケッツにとって ____ だ。

A. 一鳞一爪：全体のごく一部
B. 凶多吉少：悪い成り行きの可能性が高い
C. 强弩之末：勢いが尽きかけている
D. 德才兼备：人格と才能を兼ね備える
E. 十有八九：十中八九
F. 来者不善：やって来た者に敵意がある
G. 聪明才智：聡明で才能がある

正解： B　凶多吉少

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 5 ：費用増で揺らぐ収益の見通し

中国語：阿尔托贝罗指出，目前唯一值得担心的是商品成本问题。他指出，如果商品成本大幅增加，那么该公司的盈利前景就可能变得 #idiom# 。
日本語：アルトベッロは、今唯一心配すべきなのは商品コストだと指摘した。商品コストが大幅に増えれば、その会社の収益の見通しは ___ になるかもしれないという。

A. 名噪一时：一時名声をとどろかせる
B. 铁面无私：公正で私情を挟まない
C. 危在旦夕：危険が目前に迫る
D. 名存实亡：名前だけで実体がない

E. 岌岌可危：不安定で、非常に危うい
F. 腹背受敌：前後から敵を受ける
G. 人才济济：有能な人が大勢集まる

正解： E　岌岌可危

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 6 ：犬の小物に描かれる場面

中国語：红色皮革设计制作的小狗摆件，既为餐桌勾勒出 #idiom# 的生活场面，又不缺少实用功能，将餐具随手插入预留的皮袋中，既可爱又实用。
日本語：赤い革で作った犬の置物は、食卓に ____ 生活の場面を描き出すだけでなく、実用性も備える。用意された革の袋に食器を差し込めばよく、かわいらしく実用的だ。

A. 大兴土木：大規模な建設を行う
B. 活龙活现：生き生きと本物そっくり
C. 触景生情：景色に触れて感情が湧く
D. 千姿百态：姿や形がさまざま

E. 气象万千：壮大で変化に富む
F. 器宇轩昂：風采が堂々としている
G. 巧夺天工：人の技とは思えぬ巧みさ

正解： B　活龙活现

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 7 ：会話で相手の話を聞く

中国語：哈 : 那么 , 先生 , 我一定会 #idiom# 的。请你把帽子戴好 , 它是用在头顶上的。奥 : 谢谢 , 殿下 , 今天很热。哈 : 不 , 相信我 , 今天很冷 , 在吹著北风呢。奥 : 是蛮冷的 , 殿下 , 真的是。
日本語：ハ：では、先生、私は必ず ____ 。帽子をおかぶりください。頭にかぶるためのものです。 オ：ありがとうございます、殿下。今日は暑いですね。 ハ：いや、信じてください。今日は寒い。北風が吹いています。 オ：本当に寒いですね、殿下。まったくです。

A. 别无二致：まったく違いがない
B. 成竹在胸：あらかじめ計画ができている
C. 大彻大悟：すっかり悟る
D. 一触即发：少し触れればすぐに事が起きる
E. 泰然自若：落ち着き払っている
F. 不亢不卑：卑屈にも尊大にもならない
G. 洗耳恭听：謹んで相手の話を聞く

正解： G　洗耳恭听

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 8 ：新人の育成で人材不足に対応する

中国語：分析人士表示，虽然基金新手经验普遍不足需要磨练，但在优秀基金经理普遍短缺的情况下，以老带新，加快新人培养步伐或许是缓解基金业人才荒的 #idiom# 。
日本語：分析関係者によると、ファンドの新人は概して経験が足りず、鍛える必要がある。しかし、優れた運用責任者が全般に不足する中、経験者が新人を指導して育成を速めることは、業界の人材不足を和らげる ____ かもしれない。

A. 不二法门：ほかに代えがたい最善の方法
B. 一表人物：堂々とした立派な人物
C. 舍本逐末：本末を取り違える
D. 出奇制胜：意表を突いて勝つ
E. 颠扑不破：覆しようのない正しさ
F. 多才多艺：多方面の才能がある
G. 井井有条：秩序立って整っている

正解： A　不二法门

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例９：無線通信の問題を一度で解決する

中国語：点评：在民用领域完全可以考虑放宽对 Wi-Fi 的限制，这样不但可以充分利用现有的固网优势，而且还 #idiom# 地解决了无线互联网的带宽问题，上网本从此也能够真正“生机无限”！
日本語：論評：民間分野では Wi-Fi への制限を緩めることを十分検討できる。既存の固定網の強みを十分活用できるだけでなく、無線インターネットの帯域の問題も ____ 解決でき、ネットブックもそこから本当に「活力にあふれる」ようになる！

A. 高枕无忧：安心して暮らす
B. 花言巧语：巧みな言葉でごまかす
C. 挖空心思：知恵を絞り尽くす
D. 立竿见影：すぐに効果が現れる

E. 一劳永逸：一度の苦労で、後はずっと楽になる
F. 斩草除根：根を断って災いを除く
G. 莫衷一是：意見が分かれて結論が出ない

正解： E　一劳永逸

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 10 ：通信統合への見方（中国語）

中国語原文：李可表示，“三网融合”费时费钱，大运营商更希望 #idiom# ，而中小运营商却在担心自己的命运。“无所作为也就 #idiom# 了。”

空欄 1 （登場順）：
A. 为非作歹
B. 循序渐进
C. 目瞪口呆
D. 揠苗助长
E. 步步为营
F. 千钧一发
G. 一朝一夕

空欄 2 （登場順）：
A. 不足为奇
B. 麻木不仁
C. 顺理成章
D. 喜闻乐见
E. 当务之急
F. 比比皆是
G. 自然而然

正解：空欄 1 B 循序渐进 ／ 空欄 2 A 不足为奇

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 10 ：通信統合への見方（日本語訳）

日本語訳：李可は、「三網融合」は時間も費用もかかり、大手事業者は ___ ことを望む一方、中小事業者は自分たちの行く末を心配していると述べた。「何もしないのも、 ___ ということだ。」

空欄 1 （登場順）：
A. 悪事を働く
B. 順序を追って少しずつ進む
C. 驚いて言葉を失う
D. 成長を急いでかえって害する
E. 慎重に足場を固めながら進む
F. きわめて危険な瀬戸際
G. ごく短い時間

空欄 2 （登場順）：
A. 不思議ではない
B. 感覚が麻痺して無関心
C. 道理に従い自然に成り行く
D. 見聞きして喜ぶ
E. 今すぐ取り組むべきこと
F. どこにでも見られる
G. 自然にそうなる

正解：空欄 1 B ／ 空欄 2 A

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 11 ：清らかな景色を踏むのが惜しい

中国語：下地一阵寒噤， #idiom# 的世界，真舍不得踩下脚去。
日本語：地面に降りると、ひとしきり身震いした。 ___ 世界に、足を踏み下ろすのが実に惜しくなる。

A. 国色天香：国一番の美しさ
B. 心安理得：心にやましいところがない
C. 倾国倾城：国を傾けるほどの美貌
D. 冰清玉洁：氷や玉のように清らか

E. 对牛弹琴：話が通じない相手に説く
F. 闭月羞花：花が隠れるほどの美しさ
G. 大千世界：この広大な世界

正解： D　冰清玉洁

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 12 ：文学の才能があると信じる

中国語：当然，如果硬要我用一句话 #idiom# 地回答这个问题，那就是：我相信我自己有文学才能，我应该做这件事。但是这句话正如一个嫌疑犯说自己没杀人一样不可信。所以信不信由你罢。
日本語：もしどうしても一言で ____ この問いに答えろと言うなら、私は自分に文学の才能があり、これに取り組むべきだと信じている、ということだ。ただ、その言葉は、容疑者が自分は人を殺していないと言うのと同じように信じがたい。信じるかどうかは、あなた次第だ。

A. 瞒天过海：人を欺く巧妙な手段
B. 言简意赅：簡潔で、要点を尽くす
C. 直截了当：遠回しにせず率直に言う
D. 斩钉截铁：きっぱり断言する
E. 一丘之貉：同じ穴のむじな
F. 快人快语：思ったことをすぐ率直に言う
G. 推波助澜：勢いを増すようあおる

正解： C　直截了当

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 13 ：恩師を忘れず、霊を慰める（中国語）

中国語原文：西克教授早在 20 世纪 50 年代去世。季羡林对恩师的情意 #idiom# 。在完成了《弥勒会见记剧本》的工作后，他写道：“我心里感到了很大的安慰，我可以告慰恩师 #idiom# 了。”

空欄 1 （登場順）：
A. 丰功伟绩
B. 日落西山
C. 永志不忘
D. 刻骨铭心
E. 兴师动众
F. 死而后已
G. 浩浩荡荡

空欄 2 （登場順）：
A. 罪孽深重
B. 恩重如山
C. 面目全非
D. 家喻户晓
E. 死得其所
F. 在天之灵
G. 鸡犬不宁

正解：空欄 1 C 永志不忘 ／ 空欄 2 F 在天之灵

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

実例 13 ：恩師を忘れず、霊を慰める（日本語訳）

日本語訳：西克教授は 1950 年代にすでに亡くなっていた。季羨林は恩師への思いを ___ 。『弥勒会見記劇本』の仕事を終えた後、彼は「心に大きな慰めを得た。恩師の ___ を慰められる」と書いた。

空欄 1 （登場順）：
A. 大きな功績
B. 日が西に沈むように、衰えが進む
C. 心に深く刻み、忘れない
D. 骨身に刻むほど忘れがたい
E. 大勢を動員し大がかりに行う
F. 死ぬまで力を尽くす
G. 勢いが大きく盛ん

空欄 2 （登場順）：
A. 罪がきわめて重い
B. 大きな恩を受ける
C. 元の姿が分からないほど変わる
D. どの家にも広く知れ渡る
E. 価値のある死を遂げる
F. 天にある故人の霊
G. ひどく騒がしく落ち着かない

正解：空欄 1 C ／ 空欄 2 F

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

入力の読み方と候補選び

一部の文章は重複し、文脈が欠ける例もある

- 学習と Test には、同じ文章が 110 種類含まれる。学習と Out にも 1,829 種類が共通する。候補の組は異なる場合がある。
- 開発集合には、文章が空欄記号だけになっている問題が 1 問ある。候補は付いているが、選ぶ手掛かりとなる文脈が欠けている。

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

ベクトルの近さと、意味の一致を人手で調べた

- 候補選びの前に、ベクトル類似度 0.5 〜 0.9 を八つの区間に分け、各区間 200 対、計 1,600 対を五人が評価した。同義、近義、無関係または反対の三種類で判断する。
- 類似度が高すぎる語には同じ意味のものが多く含まれる。正解に近い候補を入れながら同義語そのものを避けるため、 0.7 を超える語を除いてから候補を選ぶ。

[1] Zheng, Huang & Sun (2019). ChID: A Large-scale Chinese IDiom Dataset for Cloze Test. ACL, pp.778–787. https://aclanthology.org/P19-1075/

JSONL から文章・候補・正解の成語を読み出す

```
import json
with open("dev_data.txt", encoding="utf-8") as f:
    example = json.loads(next(f))
print(example["content"])
for choices, gold in zip(example["candidates"],
                         example["groundTruth"]):
    print("候補:", choices, "正解:", gold)
```

原論文版は 1 行に 1 文章の JSON を収める。 candidates と groundTruth は、文章中の空欄の順に並ぶ。

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original

正解欄の形式も、配布ごとに異なる

配布	入力・候補	正解の形式
原論文版	content / 空欄別 candidates	groundTruth ：成語の配列
CLUE 版	content の配列 / 共有 candidates	別 JSON ：空欄 ID → 0 〜 9
FewCLUE 版	content / 七 candidates	answer ： 0 〜 6

候補の番号は 0 から始まる。原版は正解の成語そのものを、 CLUE と FewCLUE は候補の番号を保存する。

[1] Zheng, Huang & Sun (2019). ChID — Original Data Distribution. https://huggingface.co/datasets/thu-coai/chid/tree/main/original
[2] CLUE team. ChID 公式公開 ZIP 、原配布 README の CLUE 1.0 / 1.1 。 https://storage.googleapis.com/cluebenchmark/tasks/chid_public.zip

参考文献

参考文献

ChID: A Large-scale Chinese IDiom Dataset for Cloze Test

Chujie Zheng, Minlie Huang, Aixin Sun · 2019 · ACL, pp.778–787

中国語の成語の穴埋め読解データを構築し、候補の似方、成語の表現、領域の違いによる性能変化を調べる。

https://aclanthology.org/P19-1075/

ChID-Dataset

Chujie Zheng, Minlie Huang, Aixin Sun · 公式リポジトリ

原論文版とコンテスト版の形式、配布へのリンク、ベースライン実装、更新履歴と引用方法を公開する。

https://github.com/chujiezheng/ChID-Dataset

参考文献

ChID — Original Data Distribution

thu-coai · 作者が案内する配布

学習・開発・ Test ・ Out と、同じ Test の候補を変えた Ran/Sim を、正解付きの行形式で公開する。

https://huggingface.co/datasets/thu-coai/chid/tree/main/original

ChID-Adapt — Competition Data

Chujie Zheng et al. · 2019 年コンテスト向け公式説明

複数文章が十候補を共有し、文脈間の比較を利用して空欄を埋める形式。データと RNN/BERT ベースラインを案内する。

https://github.com/chujiezheng/ChID-Dataset/blob/master/Competition/README.md

参考文献

CLUE: A Chinese Language Understanding Evaluation Benchmark

Liang Xu et al. · 2020 · COLING, pp.4762–4772

中国語の共通評価基盤。 ChID を含む課題でモデルを微調整し、テスト性能と人間評価を報告する。

https://aclanthology.org/2020.coling-main.419/

ChID — CLUE Public Release

CLUE team · 公開 ZIP · test 1.0 / 1.1

学習・開発と新旧テスト、空欄 ID の正解対応を配布し、 CLUE 1.1 へのテスト切替えを説明する。

https://storage.googleapis.com/cluebenchmark/tasks/chid_public.zip

参考文献

FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark

Liang Xu et al. · 2021 · arXiv:2107.07498v2

九つの中国語課題による少数例学習評価。 ChID には正解位置ごとに六問、合計 42 問の学習・開発組を用意する。

https://arxiv.org/abs/2107.07498

FewCLUE — ChID Data

CLUE team

一空欄・七候補の 15 ファイル。 CLEVA 紙面と HELM 説明に一致する公開問題を含む。

https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/chid

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al. · 2023 · EMNLP: System Demonstrations

文化知識の課題に ChID の成語問題を採用する。公開紙面は三候補の問題例と正解を示す。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVACulturalKnowledgeScenario / Converter

Stanford CRFM · HELM v0.4.0 · Python 実装

文化知識の課題に対し、外部データとテンプレートを読み、入力・選択肢・正解参照へ変換する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

Apache License, Version 2.0

ChID-Dataset · LICENSE

リポジトリの利用許諾条件を示す。

https://github.com/chujiezheng/ChID-Dataset/blob/master/LICENSE