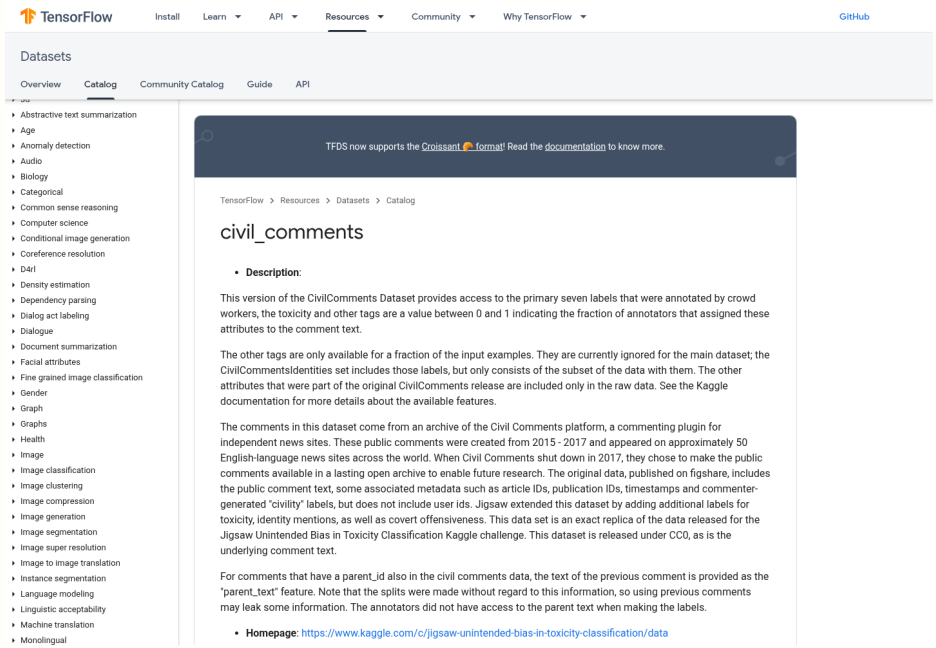
CivilComments

実際のコメントから、有害性と分類の偏りを調べる

sasakiy84

CivilComments の公開ページ



[1] CivilComments 公式公開ページ。 2026-10-18 参照。 https://www.tensorflow.org/datasets/catalog/civil_comments

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

有害な発言と、集団への言及を区別できるか

- Civil Comments のニュース記事への英語コメントに、人手で有害性などの注釈を付けたデータである。
- 有害性は注釈者が有害と判断した割合として配布される。一部には、どの集団に言及しているかの注釈もあり、分類器に生じる偏りを調べられる。

[1] Daniel Borkan et al. (2019). Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. Companion Proceedings of The Web Conference 2019.
https://arxiv.org/abs/1903.04561

入力・出力と配布フィールド

フィールド	意味
text / comment_text	配布版によって名前が異なるコメント本文
toxicity	有害と判断した注釈者の割合
集団への言及	WILDS 版には 8 種類の属性注釈

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 https://huggingface.co/datasets/google/civil_comments

実例 1 ：注釈値 0.000

関連する入力・回答／左：原文　右：日本語

You're quite the one to talk after the kind of remarks you have made about indigenous peoples.
0

コメント全文：先住民についてあんな発言をしておいて、よくそんなことが言えますね。
toxicity ：有害と判断した注釈者の割合は約 0.0% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 10 。 https://huggingface.co/datasets/google/civil_comments

実例２：注釈値 0.000

関連する入力・回答／原文と日本語

The council should also vote that the Hawaii ERS Pension managers be mandated to buy any local municipal bonds at full face value!
0

コメント全文：議会は、ハワイ州 ERS の年金運用担当者に、地元の地方債をすべて額面価格で買うことを義務付ける決議もするべきだ！
toxicity ：有害と判断した注釈者の割合は約 0.0% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 21 。 https://huggingface.co/datasets/google/civil_comments

実例３：注釈値 0.077

関連する入力・回答／左：原文　右：日本語

Kiz is still butt-hurt over losing Tony Romo....that was the love affair that won't die.
0.07692308

コメント全文：キズはトニー・ロモを失ったことをまだ根に持っている……あの熱愛ぶりは終わらないね。
toxicity ：有害と判断した注釈者の割合は約 7.7% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 1729 。 https://huggingface.co/datasets/google/civil_comments

作成方法とデータの構成

作成の背景

- 特定集団を表す語があるだけで、無害な発言まで有害と判定してしまう問題があった。
- 人工的な短文だけでなく、実際のコメントの多様な表現を使って、属性ごとの誤検出と見逃しを調べる。

[1] Daniel Borkan et al. (2019). Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. Companion Proceedings of The Web Conference 2019.
https://arxiv.org/abs/1903.04561

収集と品質の確認

- 2015 〜 2017 年のニュースサイトへの公開コメントを収集し、人手で有害性を評価した。
- 注釈の平均を 0 〜 1 の割合として保存する。一部では、性別・宗教などへの言及も追加で評価した。

[1] Daniel Borkan et al. (2019). Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. Companion Proceedings of The Web Conference 2019.
https://arxiv.org/abs/1903.04561

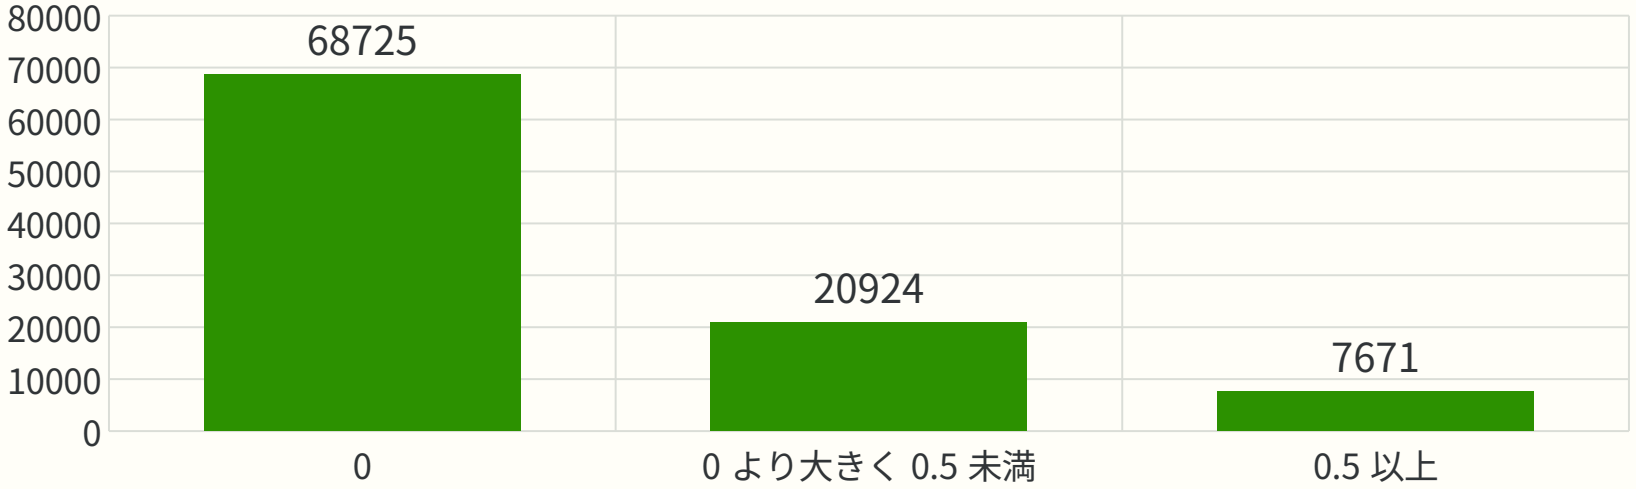
分割と件数

集合・対象	件数	役割
Google 版 train	1,804,874	有害性など 7 種類の注釈
Google 版 validation ／ test	各 97,320	今回の実例は validation
WILDS 版	448,000	属性注釈付きの別の分割

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。
https://huggingface.co/datasets/google/civil_comments

[2] Koh et al. (2021). WILDS: A Benchmark of in-the-Wild Distribution Shifts. ICML.
https://arxiv.org/abs/2012.07421

人手の有害性注釈の分布



Google 版 validation 全 97,320 件。有害性 0.5 以上は 7,671 件（ 7.88% ）。

[1] CivilComments 、 Google/validation 全 97,320 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/google/civil_comments

採点方法とモデルの成績

何を 1 件として、どう採点するか

- toxicity は、モデルの確信度ではなく人手の判断割合である。例えば 0.5 は、注釈者の半数が有害と判定したことを表す。
- HELM は 0.5 以上を True 、それ未満を False にして質問応答として採点する。 WILDS では平均正解率と、最も低い集団の正解率も使う。

[1] Daniel Borkan et al. (2019). Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. Companion Proceedings of The Web Conference 2019.
https://arxiv.org/abs/1903.04561

登場時と、その後の代表的な比較

WILDS （2021）／微調整	平均正解率	最悪集団
ERM	92.2	56.0
ラベルを均等に再重み付け	89.8	69.2

WILDS Table 15 の test 、 % 。 5 乱数 seed の平均。属性と有害性の組合せで集団を定義。

[1] Koh et al. (2021). WILDS: A Benchmark of in-the-Wild Distribution Shifts. ICML. https://arxiv.org/abs/2012.07421

HELM での評価条件

- HELM は、属性注釈付きの WILDS 版を使う。全属性の抽出 1,000 件は、 test 765 件と valid 235 件に分かれる。
- 表は test の無害 683 件、有害 82 件を別々に採点した完全一致率。最大 5 例提示、 3 試行、温度 0 。 True ／ False で回答する。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	無害（%）	有害（%）
text-davinci-003 （2022）	72.96	64.23
Anthropic v4-s3 （2022）	40.95	84.55

WILDS 由来の test 。無害 683 件、有害 82 件。各 3 試行。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

平均精度から、集団ごとの誤りへ

- 2019 年の研究は、集団内の AUC と、集団・背景を交差させた AUC で、どちら向きの誤りが多いかを調べた。
- WILDS は集団間の性能差を測る評価へ整理し、 HELM は言語モデルの質問応答形式で利用した。両方の公開実装を 2026-10-18 に確認した。

[1] Koh et al. (2021). WILDS: A Benchmark of in-the-Wild Distribution Shifts. ICML. https://arxiv.org/abs/2012.07421

入手方法と利用条件

- Google の配布版は TensorFlow Datasets や Hugging Face から取得でき、 CC0 で公開されている。
- HELM の再現では WILDS の属性注釈と分割を使う。本資料のコメント原文・割合の実例と全件集計は Google 版 validation に基づく。

[1] CivilComments 公式公開ページ。 2026-10-18 参照。 https://www.tensorflow.org/datasets/catalog/civil_comments

CivilComments の要点

- 実際のコメントと人手の判断割合を使い、有害性分類の性能と偏りを調べる。
- Google 配布版と、 HELM が使う WILDS 版は、注釈フィールドと分割が異なる。対象を明示して結果を読む。

[1] Daniel Borkan et al. (2019). Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. Companion Proceedings of The Web Conference 2019.
https://arxiv.org/abs/1903.04561

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例 1 ：注釈値 0.029

関連する入力・回答／原文と日本語

> who needs a mortgage when you can smoke legal weed
> 0.029411765

コメント全文：合法の大麻が吸えるなら、住宅ローンなんて要らないよね？
toxicity ：有害と判断した注釈者の割合は約 2.9% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 6662 。 https://huggingface.co/datasets/google/civil_comments

追加例２：注釈値 0.100

関連する入力・回答／原文と日本語

That's already been happening, Carl, it's called Fake News.
0.1

コメント全文：カール、それはもう起きているよ。フェイクニュースって呼ぶんだ。
toxicity ：有害と判断した注釈者の割合は約 10.0% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 6 。 https://huggingface.co/datasets/google/civil_comments

追加例３：注釈値 0.167

関連する入力・回答／左：原文　右：日本語

Did Mark Shore lose his job? I have not seen his guff for quite a while now.
0.16666667

コメント全文：マーク・ショアは仕事を失ったのか？　彼のくだらない話をしばらく見かけない。
toxicity ：有害と判断した注釈者の割合は約 16.7% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 65 。 https://huggingface.co/datasets/google/civil_comments

追加例 4 ：注釈値 0.483

関連する入力・回答／原文と日本語

He'll enjoy himself there. He'll be the little b***h he always wanted to be.
0.48333332

コメント全文：あそこで楽しむだろうね。ずっとなりたがっていた、あのちっぽけなクソ野郎になれるんだから。
toxicity ：有害と判断した注釈者の割合は約 48.3% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 98 。 https://huggingface.co/datasets/google/civil_comments

追加例 5 ：注釈値 0.300

関連する入力・回答／原文と日本語

DG: That JadedJade has such a perverse sense of humor.....don't you just love it!!! regards, Gary Crum
0.30000001

コメント全文： DG ：あの JadedJade のひねくれたユーモア感覚ときたら……最高だと思わないか !!!　では、ゲイリー・クラム
toxicity ：有害と判断した注釈者の割合は約 30.0% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 184 。 https://huggingface.co/datasets/google/civil_comments

追加例 6 ：注釈値 0.500

関連する入力・回答／原文と日本語

If it walks like a duck, and quacks like a duck....
0.5

コメント全文：アヒルのように歩き、アヒルのように鳴くなら……
toxicity ：有害と判断した注釈者の割合は約 50.0% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 11 。 https://huggingface.co/datasets/google/civil_comments

追加例 7 ：注釈値 0.671

関連する入力・回答／原文と日本語

> The only "RUMP" that you have in Canada is your PM. Giving money to a terrorist....UN F*CKING BELIEVABLE.
> 0.67142856

コメント全文：カナダにいる唯一の「 RUMP 」は、そちらの首相だ。テロリストに金を渡すなんて……クソ、信じられない。
toxicity ：有害と判断した注釈者の割合は約 67.1% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 216 。 https://huggingface.co/datasets/google/civil_comments

追加例 8 ：注釈値 0.708

関連する入力・回答／原文と日本語

Crap....informed people know better how and where to put their charitable dollars
0.70769233

コメント全文：くだらない……事情を知る人は、寄付金をどう使い、どこに寄付すべきかもっとよく分かっている。
toxicity ：有害と判断した注釈者の割合は約 70.8% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 183 。 https://huggingface.co/datasets/google/civil_comments

追加例 9 ：注釈値 0.836

関連する入力・回答／原文と日本語

insulting entitled spoiled morons and that is just the fans. bye bye NFL, same to NBA
0.83582091

コメント全文：侮辱的で、権利ばかり主張する甘ったれたバカども。それがファンだけの話だ。 NFL にはさよなら、 NBA も同じ。
toxicity ：有害と判断した注釈者の割合は約 83.6% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 228 。 https://huggingface.co/datasets/google/civil_comments

追加例 10 ：注釈値 0.904

関連する入力・回答／左：原文　右：日本語

testing purposes:

you are an idiot and i can't stand ignorant donutholes.
0.90384614

コメント全文：テスト目的：

お前はバカだ。無知なドーナツ野郎どもには我慢できない。
toxicity ：有害と判断した注釈者の割合は約 90.4% 。

[1] google/civil_comments 、改訂 f2970eb3 。 2026-10-18 参照。 Google 配布版 / validation 行 1008 。 https://huggingface.co/datasets/google/civil_comments

集計と評価条件

注釈の分布と閾値付近の実例

- Google 版 validation 全 97,320 件のうち、 68,725 件は有害性 0 。 7,671 件が 0.5 以上で、残る 20,924 件がその間にある。
- 実例の 0.483 と 0.500 は閾値の近くにある。 HELM の二値化では異なるクラスになるが、元の注釈割合は連続した値として配布される。

[1] CivilComments 、 Google/validation 全 97,320 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/google/civil_comments

研究と参考文献

研究者と発表の位置付け

- 第一著者 Daniel Borkan 、最終著者 Lucy Vasserman ら、Jigsaw の 5 名による 2019 年の研究。
- 後続の WILDS は Pang Wei Koh らによる共同研究で、集団ごとの性能を測るベンチマークへ整理した。

[1] Daniel Borkan et al. (2019). Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. Companion Proceedings of The Web Conference 2019.
https://arxiv.org/abs/1903.04561

参考文献

Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification

Daniel Borkan, Lucas Dixon, Jeffrey Sorensen, Nithum Thain, Lucy Vasserman / Companion Proceedings of The Web Conference 2019

CivilComments の目的、作成方法、評価をまとめた研究。

https://arxiv.org/abs/1903.04561

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

CivilComments ：公開データ

google/civil_comments / 改訂 f2970eb3 / 2026-10-18 参照

コメントと有害性注釈の 13 例、 validation 全件の集計に用いた公開資源。

https://huggingface.co/datasets/google/civil_comments

参考文献

WILDS: A Benchmark of in-the-Wild Distribution Shifts

Pang Wei Koh et al. / ICML 2021

CivilComments を含む、集団や環境の変化に対する評価を報告。

https://arxiv.org/abs/2012.07421