CLEVA

Chinese Language Models EVAluation Platform

中国語モデルを、課題と評価軸の両面から比べる

sasakiy84

公式リポジトリの README

README License

3 forks
Report repository

CLEVA: Chinese Language Models EVAluation Platform

Stars 65 License CC BY-NC-ND 4.0 Ask me anything

🌐Website • 📜Paper [EMNLP 2023 Demo] • 📌Instructions • ✉️Email

English | 简体中文

🎯 Introduction

CLEVA is a Chinese Language Models EVAluation Platform developed by CUHK LaVi Lab. CLEVA would like to thank Shanghai AI Lab for the great collaboration in the process. The main features of CLEVA include:

- A comprehensive **Chinese Benchmark**, featuring 31 tasks (11 application assessments + 20 ability evaluation tasks), with a total of 370K Chinese test samples (33.98% are newly collected, mitigating *data contamination* issues);
- A standardized **Prompt-Based Evaluation Methodology**, incorporating unified pre-processing for all data and using *a consistent set* of Chinese prompt templates for evaluation.
- A trustworthy **Leaderboard**, as CLEVA uses a significant amount of new data to minimize data contamination and regularly organizes evaluations.

The leaderboard is evaluated and maintained by CLEVA using new test data. Past leaderboard data (processed test samples, annotated prompt templates, etc.) are made available to users for local evaluation runs.



[1] LaVi Lab, CLEVA. 公式 README ・ローカル評価・参照結果・利用条件。 README 冒頭のブラウザ画面。 https://github.com/LaVi-Lab/CLEVA

1. 公開例から見る中国語評価
2. プロンプトと九つの評価軸
3. 新しい評価集合と比較の条件
4. HELM での利用と公開範囲

公開例から見る中国語評価

中国語モデルを、多面的に評価する基盤

- CLEVA は、中国語の言語モデルを幅広い課題で評価するために、 2023 年に公開されたプラットフォーム。
- 課題、入力の整形、プロンプト、指標、モデルの呼出しをそろえて比較する。単一の正答率だけでモデルの性質を表さない。
- 実務に近い 11 課題と、特定の能力を調べる 20 課題を含む。まず、公開されている三つの説明例を見る。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

公開例と、評価集合を区別する

- 本編 3 件と追加 10 件は、 CLEVA 論文で公開された課題の説明例。印刷された入力・選択肢・回答を対応させ、日本語訳を添えた。
- 元データの評価 ID や、実行時の全テンプレートを復元したものではない。課題によっては、説明例の中に省略記号もある。
- 個別データセットの収集方法や評価は、それぞれの資料で扱う。ここでは、 CLEVA の評価手順と結果の読み方を説明する。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例１：代名詞が指す相手

公開例の原文

蒋盈波原来所在的教研室有位副教授去德国参加一个学术活动，活动中结识了一位华裔德籍的同行，那同行在自己家中招待了他一次，言谈之间，双方忽然都感到巧事真多，而世界真小
在这里，“他”的意思是“同行”。是或否？

参照回答：否

対応する日本語訳

蒋盈波が以前所属していた研究室の准教授が、学術行事に参加するためドイツへ行った。そこで中国系ドイツ人の同業者と知り合い、その同業者は彼を自宅に一度招いた。話すうちに、二人とも、偶然が重なるものだ、世界は狭いものだと感じた。
ここで「彼」は「同業者」を指すか。はい、または、いいえ。

参照回答：いいえ

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS1.Px2 ／ 共参照解決。 https://arxiv.org/html/2308.04813

指示対象を、文脈から区別する

- 実例 1 では、自宅に招かれた人が、准教授と同業者のどちらなのかを区別する。参照回答は「同業者ではない」。
- CLEVA は CLUEWSC からこの課題を採り、代名詞と候補の人物を示す二択の質問へ整形している。出力の解釈には、質問の形と回答ラベルの対応が必要になる。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例２：父と息子の関係が悪い理由

会話と指示（原文）

阅读以下内容，选择合适的选项回答： 女：听说你儿子跟你的关系不是很好？ 男：说实话我不是一个好父亲，因为忙，没时间管他，我们之间几乎没有沟通。因为我，他也有很大的压力。

質問・選択肢（原文）

问题：男的和儿子的关系为什么不好？
选项：
A. 儿子态度不好
B. 双方缺少交流
C. 儿子工作很忙
D. 父亲压力太大

答： B

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS2.SSS0.Px1 ／ C3 。 https://arxiv.org/html/2308.04813

実例２：父と息子の関係が悪い理由（訳）

会話と指示（日本語訳）

次の内容を読み、適切な選択肢で答えなさい。 女性：息子さんとの関係があまりよくないと聞きましたが。 男性：正直に言うと、私はよい父親ではありません。忙しくて息子の面倒を見る時間がなく、私たちはほとんど話をしていません。私のせいで、息子も大きな重圧を感じています。

質問・選択肢（日本語訳）

問：男性と息子の関係が悪いのはなぜか。
A. 息子の態度が悪い
B. 二人の会話が少ない
C. 息子が仕事で忙しい
D. 父親が大きな重圧を感じている

参照回答： B. 二人の会話が少ない

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS2.SSS0.Px1 ／ C3 。 https://arxiv.org/html/2308.04813

会話中の理由を、選択肢へ対応させる

- 実例 2 は C3 を用いた選択式の読解。父親は、忙しくて息子とほとんど話していないと説明している。選択肢 B は、この会話不足に対応する。
- 忙しいのは父親であり、選択肢 C の「息子が忙しい」とは異なる。原文、質問、全選択肢の対応を保つことが、評価の前提になる。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例３：アヒルより多いニワトリの数

公開例の原文

问题：一个饲养场，养鸭1200 只，养的鸡比养的鸭多(3/5)，养的鸡比鸭多多少只？答案：

参照回答： 720

対応する日本語訳

問：ある飼育場ではアヒルを1,200 羽飼っている。ニワトリの数は、アヒルの数よりアヒルの数の 3/5 だけ多い。ニワトリはアヒルより何羽多いか。

参照回答： 720 羽

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS3.Px2 ／数学的推論。 https://arxiv.org/html/2308.04813

求める量と、回答形式をそろえる

- 実例 3 の Math23K では、ニワトリの総数ではなく、アヒルとの差を問う。 1,200×3/5 ＝ 720 で、参照回答は 720 。
- 同じ中国語の課題でも、文章の理解、選択肢の判別、数量関係の計算では、モデルに求める処理が異なる。
- CLEVA は課題を分け、選択問題の正答率や生成回答の完全一致など、出力に応じた指標で評価する。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

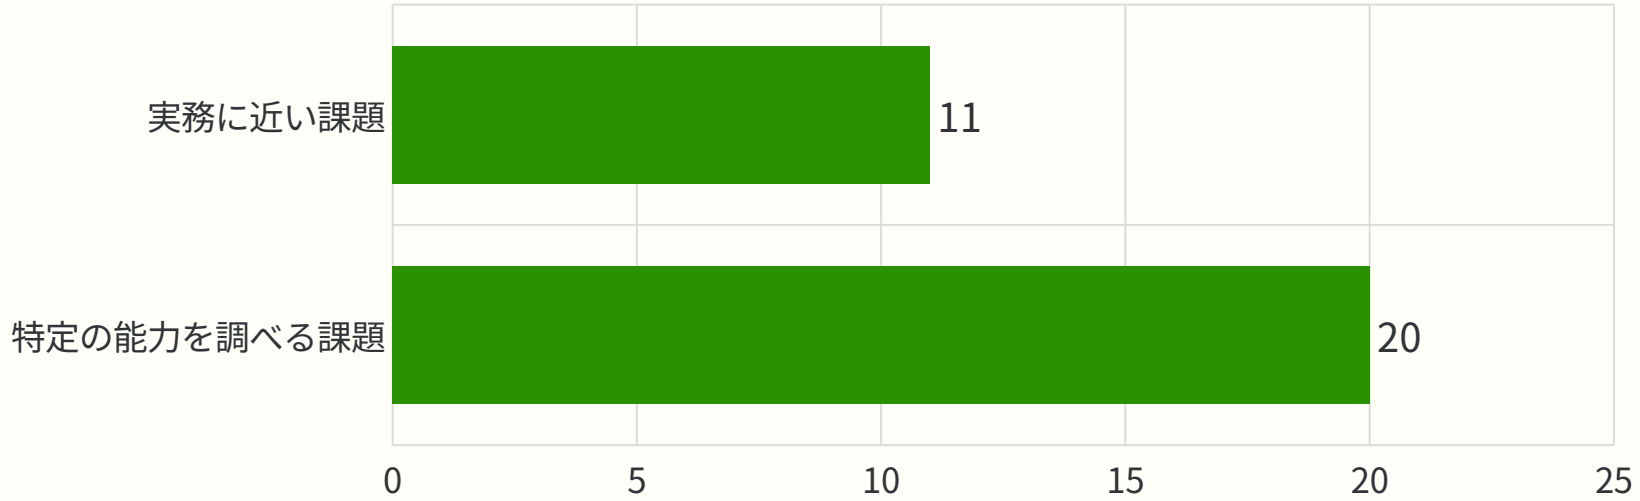
プロンプトと九つの評価軸

中国語評価の比較条件をそろえる

- 中国語の既存データを集めるだけでなく、ピンイン変換など中国語に固有の課題や、既存資源が少ない課題も加えた。
- 意味が近い質問でも、書き方でモデルの回答が変わる。CLEVA では、データとプロンプトを共通化し、複数の書き方に対する結果を集計する。
- テストデータが学習に含まれる問題にも対処するため、新たなデータの収集と、評価回ごとの集合の抽出を組み合わせる。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

課題は、実務と能力の二方向に広がる



31 は課題の種類。収録データセット数や、実際にモデルへ送る問い合わせ数とは異なる。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

同じ意味でも、問い方は複数ある

要素	CLEVA の扱い
入力	元レコードの項目を、共通のテンプレートへ入れる
問い方	1 評価集合あたり平均 3.95 個のテンプレートを用意
出力	選択・文章生成などに応じて回答を解釈する
集計	テンプレート間の平均・標準偏差・最小・最大を調べる

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

テンプレートは、入力と回答をつなぐ

```
“{sentence1}”和“{sentence2}”
这两个问题是在问同一件事情吗？
```

論文で例示されたテンプレート。二つの入力文を埋め込み、「同じことを尋ねているか」と問う。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

選択肢の送り方も、結果に影響する

- 選択肢を一つずつ別に評価する Separate と、全選択肢を一つの入力へまとめる Joint では、モデルの振る舞いが変わる。
- 2023 年の比較では、指示に合わせる学習をしていないモデルは Separate で有利な傾向があった。一方、指示に従うモデルでは Joint が有利な場合がある。
- Chatbot 形式の会話履歴と、すべてを文章として連結する Completion 形式にも差がある。課題名だけでなく、入力形式までそろえて比較する。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

正答のほかに、信頼性と条件を見る

評価軸	主に何を見るか
正確性	選択の正答率、完全一致、 F1 、 ROUGE など
確信度の較正	自信と正答率の対応（ ECE など）
頑健性	意味を保つ入力変更での最悪性能
公平性	社会集団に関係する入力変更による扱いの差
効率	API の 1 秒あたり処理数（ QPS ）

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

生成文の性質も、別の軸で評価する

評価軸	主に何を見るか
偏り・ステレオタイプ	集団への言及の偏りや、属性との結び付き
有害性	侮辱や憎悪表現などの生成
多様性	応答の表現がどの程度変化するか
プライバシー	生成文に現れる個人を識別しうる情報

九つは評価の観点。各課題にすべての指標が適用されるわけではない。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

分類課題と、生成文の測定を分ける

- COLD による有害表現の検出や、 CDial-Bias による偏りの判定は、与えられた文を分類する課題。
- 一方、有害性や偏りを生成文から測る指標は、モデルが書いた内容を調べる。分類の正答率が高いことだけでは、生成文の性質までは分からない。
- 課題名が似ていても、入力・出力・測る対象を対応させて結果を読む。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

新しい評価集合と比較の条件

件数の単位を区別する

単位	2023 年の報告
課題	31 種類
収録データセット	84 件
テスト事例	約 37 万件
拡張・複数プロンプト後	約 900 万回の問い合わせ
新たに収集した割合	33.98% （テストデータに対する報告値）

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

新しいデータと、評価回ごとの抽出

- CLEVA は、規則による合成や人手による収集・注釈を行い、既存の公開データだけに依存しない評価集合を作る。
- オンライン評価ではモデルの重みではなく API を使い、モデル開発者へ評価集合全体を配布せず、抽出した入力をモデルへ送る。
- 評価回ごとに異なる部分集合を使う。新規収集と組み合わせ、学習データへの混入による影響を減らそうとする設計である。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

抽出量は、順位の安定性と結び付ける

- すべての課題から同じ割合を抜くのではなく、モデル間の順位を区別できるかという基準に応じて、課題ごとの抽出量を調整する。
- 報告する基準は、許容する近似誤差の範囲で、任意のモデル対を正しく順位付けする確率が少なくとも 70% となること。
- この 70% は、モデルの問題正答率でも、全モデルを完全に並べ替えられる確率でもない。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

2023 年の比較は、 23 モデルを対象とした

- 公開時の実験では、 API で利用するモデルと、重みが公開されたモデルの計 23 種を、中国語の課題で比較した。モデル一覧と、利用時点が分かる API 版を記載している。
- 同じモデルでも、課題や評価軸によって結果が異なる。課題別の性能と、複数プロンプトでの変動を合わせて見る構成である。
- これは 2023 年の結果であり、その後のモデルの順位を示すものではない。次に、公式 README が示す HELM での参照結果を見る。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

提示例は、多ければよいとは限らない

- 2023 年の実験では、 8 モデルを四つの課題で比較した。多くの場合、提示例を増やすと性能が上がり、 4 〜 8 例前後で伸びが頭打ちになった。
- 一方、文章分類では、提示例を増やすと性能が下がるモデルも見られた。著者は、ラベルの種類が多く、例の追加が判断を妨げた可能性を挙げている。
- これは 31 課題すべてに共通する最適例数の報告ではない。モデル、課題、入力形式を固定した比較として読む。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

HELM 実行と、プラットフォームの参照値

課題／指標	HELM	CLEVA
対話要約／ ROUGE-2	0.3045	0.3065
英語→中国語／ SacreBLEU	60.48	59.23
事実確認／完全一致	0.4595	0.4528
地域バイアス判定／ Micro F1	0.5656	0.5589

gpt-3.5-turbo-0613 を用いた公式 README の比較。指標と尺度が異なるため、行をまたぐ平均は取らない。

[1] LaVi Lab, CLEVA. 公式 README ・ローカル評価・参照結果・利用条件。 https://github.com/LaVi-Lab/CLEVA

小さな差も、条件の違いとともに読む

- 公式 README は、乱数の違いで文脈内の提示例が変わることと、 CLEVA と HELM で使った ChatGPT の版が完全には一致しないことを、得点差の主な理由としている。
- 前ページの値は、同じ条件の二重測定による誤差だけを示すものではない。プロンプト、提示例、モデル版をそろえてから比較する。

[1] LaVi Lab, CLEVA. 公式 README ・ローカル評価・参照結果・利用条件。 https://github.com/LaVi-Lab/CLEVA

HELM での利用と公開範囲

HELM には、ローカル評価の実装がある

- 2023 年 11 月、 CLEVA のデータ形式・プロンプト・摂動・中国語の指標が HELM へ統合された。
- v1 の設定では、課題・下位課題・プロンプト ID を指定する。選択問題と生成課題で入力の整形や回答の処理が変わる。
- v0.4.0 の Classic 公開 run 索引には CLEVA の実行結果がなく、公式 README の参照値が別に公表されている。

[1] Stanford CRFM, HELM v0.4.0. CLEVA scenario / Converter.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

設定ファイルと、論文の規模は別の単位

対象	確認できる数
論文の課題	31
v0.4.0 設定の課題	31
設定の課題 × 下位課題	65 組
設定のプロンプト記述	253 項目
Classic 公開 run 索引の CLEVA	0 件

設定の組合せ・プロンプト数と、収録データセット数は別の単位。

[1] Stanford CRFM, HELM v0.4.0. CLEVA v1 run configuration.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

入手先と、現在確認できる範囲

- 公式 GitHub は、 CLEVA v1 のダウンロード方法と HELM での評価方法を公開している。
- 取得時には、公式のオンライン画面と v1 配布ファイルに接続できなかった。公開論文と固定実装は取得でき、説明例・入力形式・指標を確認できる。
- C3 や Math23K など、採用元の公開データは別の配布元から取得できる。 CLEVA v1 での選定範囲、整形、分割とは区別して利用する。

[1] LaVi Lab, CLEVA. 公式 README ・ローカル評価・参照結果・利用条件。 https://github.com/LaVi-Lab/CLEVA

比較の目的から、課題と指標を選ぶ

- 中国語のモデルを幅広く比べるには、どの課題で何を出力させたかをそろえる必要がある。 CLEVA は、その手順と評価軸をまとめた基盤である。
- 複数プロンプトと九つの評価軸は、平均的な正しさだけでなく、変動や生成文の性質も調べるために使う。
- 実行時点・モデル版・入力形式・参照回答・抽出集合を確かめて、比較できる範囲の結果を読む。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

Appendix

1. 追加の公開例
2. 設定・統計・利用条件
3. 研究と参考文献

追加の公開例

実例 4 ：雨がやみかけた山の詩句

公開例の原文

“山间连绵阴雨刚刚有了一点停止的意思。”这句话可以用以下哪句古文来表达：
A. 寒雨初开霁
B. 山晓雨初霁
C. 宿雨天初霁
D. 山雨初含霁
答：

参照回答： D

対応する日本語訳

「山間で降り続いていた雨が、ようやく少しやみかけた。」この文は、次のどの古典詩句で表せるか。
A. 冷たい雨がやみ、空が晴れ始める
B. 山の夜明け、雨がやみ、空が晴れ始める
C. 夜通し降った雨がやみ、空が晴れ始める
D. 山の雨が、かすかに晴れ間を見せ始める

参照回答： D

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS1.Px5 ／ 古典中国語の理解。 https://arxiv.org/html/2308.04813

実例 5 ：文脈に合う慣用句

公開説明例の原文（表示範囲を保持）

不过，要想变得 ____ ，要想自己能够成就一番事业的话，不是说来就来的，或者说任何一个出色的人，他们都得经历过不少的磨难，以及在经受住了一些挫折之后，才能真正成才成人，才能成为一个实力超群的人物，让自己的人生过得越来越顺当…
上面这个句子下划线处可以填写哪个成语？
A. 足智多谋
B. 语无伦次
C. 绣花枕头
答：

参照回答： A

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS2.Px2 ／ 文化的知識。 https://arxiv.org/html/2308.04813

実例 5 ：文脈に合う慣用句（訳）

対応する日本語訳

しかし、 ___ になって、自分で何かを成し遂げたいと思っても、簡単に実現できるわけではない。どんな優れた人も、多くの苦難や挫折を経験してこそ、本当に成長し、抜きん出た力を持ち、人生をより順調に歩めるようになる……。
下線部には、どの慣用句を入れられるか。
A. 知恵や策略に富む
B. 話が支離滅裂である
C. 見かけはよいが中身がない

参照回答： A. 足智多谋（知恵や策略に富む）

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS2.Px2 ／ 文化的知識。 https://arxiv.org/html/2308.04813

実例 6 ：売り声から何が分かるか

公開例の原文

是否可以从“篮子嘛，一块钱，一块钱啊。”中推断出“这个篮子是可以卖的。”？
A. 总是可以
B. 有时可以
C. 不可以
答：

参照回答： A

対応する日本語訳

「かごだよ、１元、１元だよ。」という発言から、「このかごは販売されている」と推論できるか。
A. 常にできる
B. 場合によってはできる
C. できない

参照回答： A

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS3.Px2 ／常識推論・含意判定。 https://arxiv.org/html/2308.04813

実例 7 ：数式が扱う図形を答える

公開例の原文

婆罗摩笈多公式描述了 __ ->

参照回答：四边形

対応する日本語訳

ブラーマグプタの公式が扱うのは __ →

参照回答：四辺形

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS2.Px1 ／分野別知識。 https://arxiv.org/html/2308.04813

実例 8 ：映画賞に関する主張を判定する

公開例の原文

第 33 届金鸡奖揭晓：黄晓明、周冬雨再拿最佳男女主角。
上述说法是否为真？
答：

参照回答：真

対応する日本語訳

第 33 回金鶏賞の結果が発表され、黄暁明と周冬雨が、再び最優秀男優賞と最優秀女優賞をそれぞれ受賞した。
この記述は真実か。

参照回答：真

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS4.Px4 ／ 事実確認。 https://arxiv.org/html/2308.04813

実例９：不満を含む商品レビュー

公開例の原文

这个产品评价是正面还是负面的？
评价：今天刚拿到手机，打电话时发现手机听筒有吱吱吱的杂声，不满意，真怀疑是不是正品
答案：

参照回答：負面

対応する日本語訳

この商品レビューは肯定的か、否定的か。
レビュー：今日、携帯電話が届いたばかりなのに、通話すると受話口からジジジという雑音がする。不満だ。本当に正規品なのか疑わしい。

参照回答：否定的

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS2.SSS0.Px6 ／感情分析。 https://arxiv.org/html/2308.04813

実例 10 ：ニュースの話題を分類する

公開例の原文

“全国青年教师教学艺术大赛举行”这段新闻的类别属于

参照回答：教育

対応する日本語訳

「全国の若手教員による授業技術大会が開催された」というニュースの分類は、

参照回答：教育

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS2.SSS0.Px7 ／ 文章分類。 https://arxiv.org/html/2308.04813

実例 11 ：文章の中心となる対象を抜き出す

公開例の原文

“《恋恋笔记本》是导演尼克·卡萨维茨 2004 年的一部爱情类影片。”中主要围绕着什么进行描述？

参照回答：恋恋笔记本

対応する日本語訳

「『きみに読む物語』は、ニック・カサヴェテス監督による 2004 年の恋愛映画である。」この記述は、主に何について述べているか。

参照回答：きみに読む物語

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS2.SSS0.Px8 ／意見の対象抽出。 https://arxiv.org/html/2308.04813

実例 12 ：演算記号の意味を変える

公開例の原文

将“ +” 视为数字 1 而不是数学运算。问： 6+1 的第一位数字是啥？答：

参照回答： 6

対応する日本語訳

「 + 」を数学の演算記号ではなく、数字の 1 として扱う。問： 6+1 の最初の桁は何か。

参照回答： 6

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS5.Px2 ／指示追従。 https://arxiv.org/html/2308.04813

実例 13 ：例から計算の規則を推定する

公開例の原文

推断符号 -> 的含义并计算下列公式。
512 + 372 -> 885
528 + 170 -> 699
859 + 133 -> 993
199 + 944 -> 1144
154 + 521 -> 676
67 + 987 ->

参照回答： 1055

対応する日本語訳

記号「→」の意味を推測し、
最後の式を計算しなさい。
512 + 372 → 885
528 + 170 → 699
859 + 133 → 993
199 + 944 → 1144
154 + 521 → 676
67 + 987 →

参照回答： 1055

[1] Li, Zhao et al. (2023), CLEVA. 公開説明例。 公開例 A2.SS1.SSS3.Px2 ／帰納的推論。 https://arxiv.org/html/2308.04813

参照回答の単位と文脈を確かめる

- 実例 7 では、数学の知識を、図形の名称という短い語で答える。参照ラベルは「四辺形」である。
- 実例 8 は、 2020 年の第 33 回金鶏賞に関する主張。時点を外し、現在の受賞結果に関する質問として扱わない。
- 実例 13 は、通常の和より 1 大きい値を返す規則を例から推定する。 67 ＋ 987 ＝ 1054 なので、提示された規則の参照値は 1055 。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

設定・統計・利用条件

31 課題のうち、実務に近い 11 課題

区分	課題
質問・読解	読解、外部資料なしの質問応答
文章の判定	言い換え判定、感情分析、文章分類
文章の生成	要約、データからの文章生成、言い換え生成
その他	意見抽出、対話生成、翻訳

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

特定の能力を調べる 20 課題

区分	課題
言語： 5	言語モデル、共参照、ピンイン、意図、古典中国語
知識： 2	分野別知識、文化的知識
推論： 7	基礎推論、帰納・演繹・常識・数学推論、コード、概念汎化
害： 4	著作物の再現、有害表現の検出、偏りの判定、事実確認
その他： 2	指示追従、算術計算

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

文脈内の提示例は、条件の一部になる

- 入力に何件の例を添えるかだけでなく、どの例をどの順に添えたかも回答に影響する。複数のテンプレートや乱数設定を使う評価では、集計する範囲をそろえる。
- HELM 実装は、ラベルの言い換え、項目の連結、選択肢の番号付けなどを行う Converter を持つ。元レコードのラベルと、モデルが実際に返す文字列を対応させる。

[1] Stanford CRFM, HELM v0.4.0. CLEVA scenario / Converter.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

新しい二つの軸を、具体的に測る

- 多様性は、 n-gram の種類数を出現総数で割る。全出力をまとめる inter-distinct と、事例ごとに計算して平均する intra-distinct を定義している。
- プライバシーの PII_match は、個人を識別しうる情報が 1 件以上検出された出力を持つ事例数を、全評価事例数で割る指標。
- 2023 年の評価では Azure の PII 検出サービスを使う。文字数に占める個人情報の割合ではなく、検出された事例の割合を測る。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

公開条件と、収録元の権利を確かめる

- CLEVA 公式リポジトリのライセンス表示は CC BY-NC-ND 4.0 。非商用、改変物の共有に関する制限などを含む。
- 収録データの出所は一様ではない。元データの利用条件と、 CLEVA が公開した加工済みデータの条件を、それぞれ確認する。
- この資料の日本語訳は、公開説明例を読むために添えたもの。 CLEVA の公式訳や、公式評価ラベルではない。

[1] LaVi Lab, CLEVA. 公式 README ・ローカル評価・参照結果・利用条件。 https://github.com/LaVi-Lab/CLEVA

後続の C²LEVA と、対象を分ける

- 公式 README は、後続の C²LEVA を 2024 年 12 月に案内し、 2025 年の Findings of ACL への採択を報告している。
- C²LEVA は、英語と中国語を対象に、学習データへの混入を防ぐ仕組みを体系化する後続の評価。
- ここで扱う 31 課題・ 84 データセット・約 37 万事例は、CLEVA の 2023 年の報告値。後続版の構成や結果へ、そのまま移さない。

[1] Li et al., C²LEVA: Toward Comprehensive and Contamination-Free Language Model Evaluation. Findings of ACL 2025. https://arxiv.org/abs/2412.04947

研究と参考文献

香港中文大学と上海 AI 実験室の共同研究

- Yanyang Li と Jianqiao Zhao が共同第一著者、 Liwei Wang が責任著者。香港中文大学と上海 AI 実験室の研究者が参加した。
- 2023 年の EMNLP System Demonstrations で、ベンチマーク、評価手順、オンラインの利用例とモデル比較を報告している。
- 公開リポジトリには HELM 統合の手順が追加され、オンライン評価とローカル評価の二つの入口が示されている。

[1] Li, Zhao et al. (2023), CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li, Jianqiao Zhao et al. · 2023 · EMNLP System Demonstrations, pp.186–217

中国語の 31 課題、九つの評価軸、複数プロンプトと評価集合の抽出をまとめた評価基盤を提案する。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVA: Chinese Language Models EVAluation Platform

LaVi Lab · 公式リポジトリ

v1 の配布案内、 HELM でのローカル評価、四つの参照結果とライセンスを公開する。

https://github.com/LaVi-Lab/CLEVA

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · Transactions on Machine Learning Research

能力だけでなく、信頼性や害を含む複数の観点から言語モデルを比較する HELM を提示する。

https://openreview.net/forum?id=iO4LZibEqW

C²LEVA: Toward Comprehensive and Contamination-Free Language Model Evaluation

Yanyang Li et al. · 2025 · Findings of ACL

英語・中国語を対象に、学習データへの混入を防ぐ仕組みを体系化する後続の評価研究。

https://arxiv.org/abs/2412.04947

参考文献

CLEVA Scenario and v1 Run Configuration

Stanford CRFM · HELM v0.4.0 · 2023

CLEVA 形式の入力・ラベル・テンプレートを変換する実装と、ローカル評価の課題設定を含む。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py