CLUEWSC2020

Chinese Winograd Schema Challenge

CLUE: Chinese Language Understanding Evaluation

中国語の文章で、代名詞と名詞句の指示関係を問う

sasakiy84

CLUEWSC2020 の公式公開リポジトリ



README

CLUEWSC2020: WSC Winograd模式挑战中文版，中文指代消解任务

数据集介绍

Winograd Scheme Challenge（WSC）是一类代词消歧的任务。

即判断句子中的代词指代的是哪个名词。题目以真假判别的方式出现，如：

句子：这时候放在床上枕头旁边的手机响了，我感到奇怪，因为欠费已被停机两个月，现在它突然响了。需要判断"它"指代的是"床"、"枕头"，还是"手机"？

数据来源：数据有CLUE benchmark提供，从中国现当代作家文学作品中抽取，再经语言专家人工挑选、标注。

数据形式：

{"target": {"span2_index": 37, "span1_index": 5, "span1_text": "床", "span2_text": "它"}, "idx": 261, "label": "false", "text": "这时候放在床上枕头旁边的手机响了，我感到奇怪，因为欠费已被停机两个月，现在它突然响了。"} "true"表示代词确实是指代span1_text中的名词的，"false"代表不是。 数据集大小：

训练集：1244

开发集：304

CLUEWSC2020数据集下载

模型效果

Custom properties

80 stars

2 watching

2 forks

Report repository

[1] CLUE team. CLUEWSC2020 official repository. https://github.com/CLUEbenchmark/CLUEWSC2020

1. 代名詞が指す対象を読む
2. 収集と、データの構成
3. 評価と歴史的な性能
4. CLUE と CLEVA での利用

「それ」は、何を指しているか

二つの指定箇所が、同じ対象を指すか

- CLUEWSC2020 は、中国語の文章と、指定された名詞句・代名詞を入力にする二値分類のデータ。二つが同じ対象を指すなら true 、違えば false 。
- 登場人物や物が何をしているかを読み、代名詞が指す対象を判断する。語の位置だけでなく、動作の対象や話し手の意図が手掛かりになる。
- 2020 年に CLUE の新しい指示関係課題として公開され、後に CLEVA の共参照解決にも採用された。

[1] CLUE team. CLUEWSC2020: WSC Winograd 模式挑战中文版，中文指代消解任务 .
https://github.com/CLUEbenchmark/CLUEWSC2020/blob/446646278671444c79a67e7434b3a1d1d1cbbe88/README.md
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例１：すくい上げるのは、煮汁の中の塊

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

渐渐地，汤中凝结出一团团**块状物**，将**它们**捞起放进盆里冷却，肥皂便出现在世上了。

候选名词：块状物
指定代词：它们

日本語訳：全文と指定された語句

次第に、煮汁の中に塊がいくつもできた。それらをすくい上げてボウルに入れて冷ますと、石けんがこの世に生まれた。

候補の名詞句：塊
指定された代名詞：それら

正解： true （同じ対象）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

「すくう」「冷ます」の対象を追う

- すくい上げて冷ます対象は、煮汁の中にできた塊。「它们」は複数の塊を指すので、答えは true になる。
- 「煮汁」と「塊」の両方が出てくる文章で、代名詞と動作の対象を結び付ける問題になっている。
- この問題は、 HELM にある CLEVA の共参照解決シナリオでも説明例に使われている。

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

[2] Stanford CRFM. CLEVACoreferenceResolutionScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

実例２：同業者が招いたのは、准教授

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

蒋盈波原来所在的教研室有位副教授去德国参加一个学术活动，活动中结识了一位华裔德籍的**同行**，那同行在自己家中招待了**他**一次，言谈之间，双方忽然都感到巧事真多，而世界真小

候选名词：同行
指定代词：他

日本語訳：全文と指定された語句

蒋盈波が以前所属していた教育・研究部門の准教授が、学術行事に参加するためドイツへ行った。そこで中国系ドイツ人の同業者と知り合い、その同業者は自宅で彼を一度もてなした。話すうちに、双方は偶然の一致の多さと、世間の狭さに気付いた。

候補の名詞句：同業者
指定された代名詞：彼

正解： false （同じ対象ではない）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

同業者が招いたのは、准教授

- 自宅に招いたのは同業者で、招かれたのはドイツへ行った准教授。「他」が指す准教授と、候補の同業者は別人なので false になる。
- 蒋盈波、准教授、同業者という複数の人物が出てくる。誰が誰を招いたかを、文の主語が変わっても追う必要がある。
- CLEVA の論文でも、この文章と二つの指定箇所が共参照解決の例に使われている。

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例３：突然鳴った物を特定する

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

这时候放在**床**上枕头旁边的手机响了，我感到奇怪，因为欠费已被停机两个月，现在**它**突然响了。

候选名词：床
指定代词：它

日本語訳：全文と指定された語句

そのとき、ベッドの枕の横に置いた携帯電話が鳴った。料金未払いで 2 か月も利用停止になっていたので、今それが突然鳴ったことを不思議に思った。

候補の名詞句：ベッド
指定された代名詞：それ

正解： false （同じ対象ではない）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

候補はベッド、鳴った物は携帯電話

- 利用停止になっていて、突然鳴ったのは携帯電話。「それ」が指す物と、候補のベッドは異なるので false になる。
- この問題では、代名詞が指す物を見つけたうえで、指定された候補と一致するかを判定する。文章にはベッドや枕も出てくるが、電話が鳴るという動作と利用停止の説明が手掛かりになる。

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

文学作品から、指示関係の問題を作る

中国語の自然な文章を、人手で選ぶ

- 36 の現代中国文学作品から文章を選び、言語の専門家が選別・注釈した。 2020 年の構成は学習 1,244 問、開発 304 問、テスト 290 問の計 1,838 問。
- 一つの文章から、異なる名詞句と代名詞の組を指定して複数の問題を作れる。たとえば実例 2 の文章では、准教授を候補にすると true 、同業者を候補にすると false になる。
- 配布データには文章と指定箇所、正解が収められている。個々の文章の作品名・作者名は記載されていない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

2020 年の分割と、後のテスト更新

分割	2020 年の構成	現在の公開 ZIP
train	1,244 問	1,244 問・正解あり
dev	304 問	304 問・正解あり
test	290 問	2,574 問・正解なし
旧 test	上の 290 問	test1.0.json で 290 問を保存

2021 年 8 月 29 日にテストを更新。学習・開発・新テストは計 4,122 問。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

一つの文章から、複数の問題を作る

ファイル	問題数	文章数	ラベル
train.json	1,244	387	true 517 / false 727
dev.json	304	104	true 111 / false 193
test.json	2,574	1,424	非公開
test1.0.json	290	88	非公開

学習では 387 文章から 1,244 問、開発では 104 文章から 304 問を作っている。表は現在の公開データの構成。

[1] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

性・数・動作・談話の流れを組み合わせる

- 他・她・它に加え、他们・她们・它们のような複数形や「其」も含む。人と物、単数と複数の違いが手掛かりになる。
- 招く側と招かれる側、物を運ぶ人と運ばれる物など、文の役割と動作の対象も読み取る。複数の人物が続けて登場する文章では、談話の流れが重要になる。
- 本資料では、正解が公開されている学習・開発データから、異なる文章の 13 問を紹介する。

[1] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

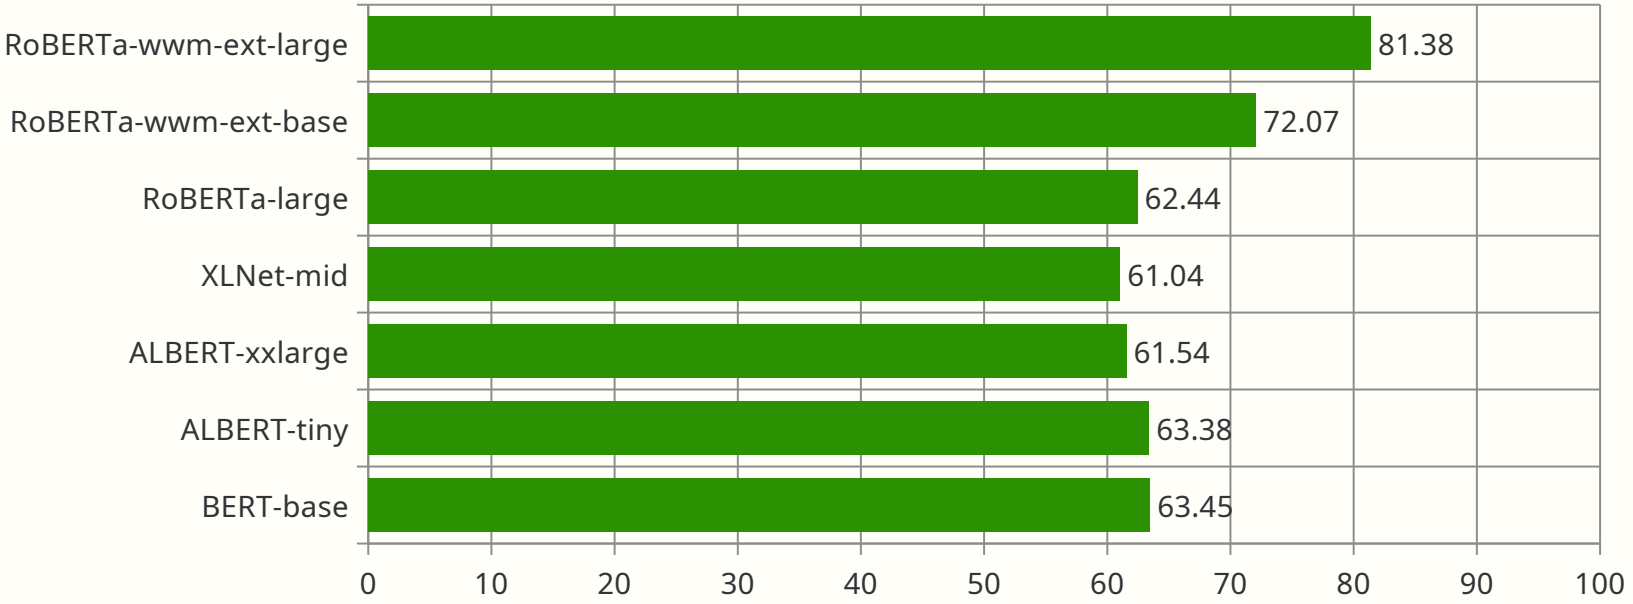
正答率を、評価条件とともに読む

正答率は、指定された組の判定が合う割合

- 正答率は、予測した true/false が正解ラベルと一致した問題の割合。指定された名詞句と代名詞が、同じ対象を指すかを評価する。
- 次のモデル性能は、構築時の 2020 年テスト 290 問に対する報告値。現在公開されているテストは 2,574 問に更新されている。
- CLEVA の共参照解決でも正答率を用い、言語モデルがプロンプトへ答える形で評価する。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

構築時のモデルは、最大 81.38 %



[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. 2020 年の test 。 9 モデル中 7 モデルを表示。
https://aclanthology.org/2020.coling-main.419/

人手評価 98 %は、 100 問の多数決

- テストから無作為に選んだ 100 問を 3 人が解き、個人の正答率は 94 %、 97 %、 95 %。平均は 95.3 %、多数決の正答率は 98 % だった。
- 注釈者は、開発データ 30 〜 50 問を解いて議論した後に評価した。
- モデルの正答率は旧テスト全 290 問、人手の正答率はそのうち 100 問に基づく。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

モデルは 3 回微調整し、開発成績で選ぶ

- 各モデルを 3 回微調整し、開発データで最も良い成績を出したモデルのテスト値を報告した。
- この結果は、教師あり学習で指示関係を判定するモデルの歴史的な比較。後に CLEVA では、生成モデルにプロンプトを与えて答えさせる課題としても利用された。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUE team. CLUEWSC2020: WSC Winograd 模式挑战中文版，中文指代消解任务 .
https://github.com/CLUEbenchmark/CLUEWSC2020/blob/446646278671444c79a67e7434b3a1d1d1cbbe88/README.md

中国語の指示関係を、モデル評価へ

元 WSC の発想を、中国語の自然な文章へ

- Winograd Schema Challenge （ 2012 年）は、常識を使って曖昧な代名詞を解く課題。語を一つか二つ変えると、指す対象が入れ替わる文の対を重視した。
- CLUEWSC2020 は、中国語の文学作品から自然な文章を選び、指定された名詞句と代名詞が同じ対象を指すかを二値で判定する。
- 語を置き換えた文の対に限らず、作品中の動作や会話、常識を手掛かりに、文章内の人物や物の関係を読む。

[1] Levesque, Davis & Morgenstern (2012). The Winograd Schema Challenge. KR 2012. https://cdn.aaai.org/ocs/4492/4492-21843-1-PB.pdf
[2] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

CLEVA は、 CLUEWSC から問題を採用

- CLEVA は、 CLUEWSC から抽出した問題を共参照解決の評価に使う。論文に掲載された例が、本資料の実例 2 に当たる。
- HELM の CLEVA 実装では、プロンプトに文章と問いを組み込み、回答候補を用意する。実例 1 は「不是／是」の二候補を使う説明例として載っている。
- CLEVA で選定された全問題や推論条件の詳細は確認できないため、ここでは元の CLUEWSC2020 の構成と、公開されている利用方法を紹介する。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

[2] Stanford CRFM. CLEVACoreferenceResolutionScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

公開データの入手先と、文章の利用条件

- 公式リポジトリから公開 ZIP をダウンロードできる。学習・開発データは正解付きで、テストデータの正解は非公開。
- 課題リポジトリには、データ専用の利用許諾が明記されていない。文章は文学作品に由来するため、再利用や再配布の際には、データ提供者の条件と元の文章の権利を確認する必要がある。

[1] CLUE team. CLUEWSC2020: WSC Winograd 模式挑战中文版，中文指代消解任务 .
https://github.com/CLUEbenchmark/CLUEWSC2020/blob/446646278671444c79a67e7434b3a1d1d1cbbe88/README.md
[2] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

文学作品の文脈で、代名詞の指示対象を判定

- CLUEWSC2020 は、中国語の自然な文章で、指定された名詞句と代名詞が同じ対象を指すかを問うデータセット。
- 文学作品に現れる人物や物の関係を読み、性・数だけでなく、動作や談話の流れも手掛かりにする。
- 構築時のテストでは最良モデルの正答率が 81.38 %、 100 問の人手評価は多数決で 98 %だった。中国語理解の課題として、CLUE から CLEVA へと利用が広がった。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

Appendix

1. 追加の公開実例
2. データの読み方と評価値
3. 研究と参考文献

追加の公開実例

実例４：服に残る素朴さ

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

当然，他自己的衣服还是老模样。一身家织的老粗布，尽管金波妈给他裁剪成制服式样，但仍然不能掩饰它本质上的土气。

候选名词：衣服
指定代词：它

日本語訳：全文と指定された語句

もちろん、自分の服は相変わらずだった。自家製の粗い布の服を金波の母が制服の形に仕立てても、その本来の田舎くささは隠せなかった。

候補の名詞句：服
指定された代名詞：その

正解： true （同じ対象）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例５：崩れそうでも残る橋

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

村里现在最高寿的人，也不知这**小桥**是什么年间建造的。**它**年年摇摇欲坠，但年年都存在着。

候选名词：小桥
指定代词：它

日本語訳：全文と指定された語句

村でいちばん長生きしている人にも、この小さな橋がいつ架けられたのか分からない。それは毎年崩れそうになりながら、毎年そこにある。

候補の名詞句：小さな橋
指定された代名詞：それ

正解： true （同じ対象）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例６：繰り返される男女の代名詞

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

只要孙少平看过的书，就借给郝红梅看。无论是他给她借书，还是她给他还书，两个人不约而同地都是悄悄进行的。

候选名词：孙少平
指定代词：她

日本語訳：全文と指定された語句

孫少平が読んだ本は、どれも郝紅梅にも貸していた。彼が彼女へ本を貸すときも、彼女が彼へ返すときも、二人とも、示し合わせることなく、ひっそりと行っていた。

候補の名詞句：孫少平
指定された代名詞：彼女

正解： false （同じ対象ではない）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例７：発見の経緯を話している父親

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

我父亲杨金彪和他的扳道工同事郝强生坐在外面的房间里，那时我父亲只有二十一岁，**他**擦着脸上的汗水，详细讲述了发现我的经过。

候选名词：我父亲
指定代词：他

日本語訳：全文と指定された語句

父の楊金彪と、転轍係の同僚の郝強生が外側の部屋に座っていた。そのとき父はまだ 21 歳で、彼は顔の汗を拭きながら、私を見つけた経緯を詳しく話した。

候補の名詞句：私の父
指定された代名詞：彼

正解： true （同じ対象）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例８：縛り付けたのは、小麦粉の袋

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

他先到街上给祖母买好了**药**，然后就把那一小袋面粉提到金波的宿舍里。两个人相帮着把**它**绑在后车座的旁边，就准备一起相跟回家了。

候选名词：药
指定代词：它

日本語訳：全文と指定された語句

彼はまず街で祖母のための薬を買い、それから小さな小麦粉の袋を金波の寮へ持って行った。二人は協力してそれを後部座席の脇へ縛り付け、一緒に家へ帰る準備をした。

候補の名詞句：薬
指定された代名詞：それ

正解： false （同じ対象ではない）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例９：一人の女性と、女性たちの集団

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

这时候，双水村妇女主任**贺凤英**，正领着本村和外村的一些“铁姑娘”，忙碌地布置会场。**她们**把课桌从教室里抬出两张来，拼在一起放到人群面前

候选名词：贺凤英
指定代词：她们

日本語訳：全文と指定された語句

そのとき双水村の女性担当主任の賀鳳英は、村内外の「鉄の娘たち」を率いて、忙しく会場を整えていた。彼女たちは教室から机を二つ運び出し、並べて人々の前へ置いた。

候補の名詞句：賀鳳英
指定された代名詞：彼女たち

正解： false （同じ対象ではない）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例 10 ：二人の子供をまとめて指す

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

我回来，咱们两个人劳动，一定要把**少平和兰香**的书供成。只要他两个有本事，能考到哪里，咱们就把**他们**供到哪里。

候选名词：少平和兰香
指定代词：他们

日本語訳：全文と指定された語句

私が戻ったら二人で働いて、少平と蘭香が学業を終えるまで、必ず支えよう。二人に力があって、どこの学校に受かろうと、私たちは彼らをそこへ通わせよう。

候補の名詞句：少平と蘭香
指定された代名詞：彼ら

正解： true （同じ対象）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例 11 ：鑑賞する姿勢と、聴こえる音

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

她索性以毒攻毒，干脆用欣赏的**态度**来感受她所讨厌的风雨声。她把**它**想象成那些迷人的小夜曲，或者庞大的层次复杂的交响乐，企图在这种“陶醉”中入睡。

候选名词：态度
指定代词：它

日本語訳：全文と指定された語句

彼女はいっそ毒をもって毒を制そうと、嫌いだった風雨の音を楽しむ姿勢で聴くことにした。彼女はそれを魅力的な小夜曲や、壮大で複雑な構成の交響曲に見立て、その「陶酔」の中で眠ろうとした。

候補の名詞句：姿勢
指定された代名詞：それ

正解： false （同じ対象ではない）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例 12 ：一家を、複数の人として受ける

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

老张一家十分厚道，都说怎能收高老师的钱呢？房子他尽管住；娃娃放下，**他们**尽力照顾。

候选名词：老张一家
指定代词：他们

日本語訳：全文と指定された語句

張さん一家はとても親切で、高先生からお金など取れるものかと皆が言った。家には自由に住んでもらえばよい。子供を預ければ、彼らが精いっぱい面倒を見る。

候補の名詞句：張さん一家
指定された代名詞：彼ら

正解： true （同じ対象）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例 13 ：「其」が指す、拾ったボトル

緑：候補の名詞句／青：指定された代名詞

中国語：文章全文と指定された語句

记得在十年前的沙依横布拉克牧场，塑料袋之类的东西更少见，偶尔在河边捡到一个从上游漂来的**塑料瓶**都会心花怒放，将**其**大派用场。

候选名词：塑料瓶
指定代词：其

日本語訳：全文と指定された語句

10 年前の沙依横布拉克牧場では、ビニール袋のような物はさらに珍しかった。上流から流れてきたプラスチック製のボトルを川岸でたまたま拾うだけでも大喜びし、それを大いに活用したのを覚えている。

候補の名詞句：プラスチック製のボトル
指定された代名詞：それ

正解： true （同じ対象）

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例ごとの判定の手掛かり

実例	説明
1	すくい上げて冷ます対象は、煮汁の中にできた塊。動作と対象の関係を読む。
2	自宅に招いたのは同業者で、招かれたのはドイツへ行った准教授。「他」は准教授を指す。
3	鳴る物と利用停止の説明は携帯電話を指す。指定された候補はベッドなので false 。
4	田舎くさい性質が残る対象は服。「它」は物を表す代名詞。

[1] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例ごとの判定の手掛かり

実例	説明
5	建造年代の話から、毎年残っている橋の状態へつながる。
6	指定位置の她は郝紅梅を指す。候補の孫少平とは同じ人物ではない。
7	年齢の説明の後、父親が発見の経緯を話す。「他」は父親を指す。
8	縛り付けた対象は小麦粉の袋。先に登場した薬を選ぶ判定は false 。

[1] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

実例ごとの判定の手掛かり

実例	説明
9	代名詞は複数の女性を表す。指定された一人の主任だけとの同一指示は false 。
10	二人を並べた名詞句を、複数代名詞で受けている。
11	音楽に見立てる対象は風雨の音。音を聴く姿勢そのものを指しているのではない。
12	一家という集団名を、その家族の人々を表す他们で受ける。
13	其は拾ったボトルを指す。先に出た牧場や袋ではなく、直前に拾った物を受ける。

[1] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

データの読み方と評価値

同じ文章で、候補を変えると正解も変わる

文章	span1	span2	label
実例 2	蒋盈波	他	false
実例 2	同行	他	false
実例 2	副教授	他	true
実例 1	块状物	它们	true
実例 1	汤	它们	false

実例 2 では「准教授」、実例 1 では「块状物」を候補にすると true になる。候補の名詞句も、問題を構成する入力の一部。

[1] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

指定箇所は、文字位置と語句で表す

- target は、名詞句と代名詞それぞれの文字位置と語句を持つ。span1_index と span2_index は、文章の先頭を 0 とする文字位置。
- 同じ代名詞が文中に繰り返されても、この位置によって、どの箇所が判定対象かが分かる。
- 候補の名詞句が代名詞より後ろにある問題も含む。前後の文脈を読み、指定された二箇所の関係を判断する。

[1] CLUEbenchmark. CLUEWSC2020 public data; test update 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

正式論文で報告された 9 モデルの精度

モデル	test 正答率（%）
BERT-base	63.45
BERT-wwm-ext-base	62.41
ALBERT-tiny	63.38
ALBERT-xxlarge	61.54
ERNIE-base	63.44

2020 年のテスト 290 問に対する正答率。 3 回の微調整から、開発成績が最良のモデルを選択。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

正式論文で報告された 9 モデルの精度

モデル	test 正答率（%）
XLNet-mid	61.04
RoBERTa-large	62.44
RoBERTa-wwm-ext-base	72.07
RoBERTa-wwm-ext-large	81.38

2020 年のテスト 290 問に対する正答率。 3 回の微調整から、開発成績が最良のモデルを選択。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

学習データの一問を読み込む

```
import json
with open('train.json', encoding='utf-8') as f:
    row = json.loads(next(f))
print(row['text'])
target = row['target']
print(target['span1_text'], target['span2_text'])
print(row['label'])
```

拡張子は .json だが、中身は 1 行 1 問の JSON 。文章・二つの指定語句・正解を読み出せる。

[1] CLUEbenchmark. CLUEWSC2020 public data. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

研究と参考文献

中国語の言語理解を、共通の基盤で測る

- CLUE チームは、 Liang Xu 、 Hai Hu 、 Xuanwei Zhang らによる共同プロジェクト。 COLING 2020 では 9 種類の中国語理解課題と事前学習モデルの比較を示した。
- CLUEWSC2020 はそのうち、指定された代名詞の指示対象を判定する課題。英語中心の評価基盤を補い、中国語の自然な文脈で理解を測る位置付けを持つ。
- 元 WSC の発想、 CLUE での中国語データ整備、 CLEVA での言語モデル評価という、異なる段階の取り組みがつながっている。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

参考文献

CLUE: A Chinese Language Understanding Evaluation Benchmark

Liang Xu et al. · 2020 · COLING, pp.4762–4772

中国語 9 課題を整備。 CLUEWSC2020 の収集・分割と、モデルおよび人手の評価を報告する。
https://aclanthology.org/2020.coling-main.419/

The Winograd Schema Challenge

Hector J. Levesque, Ernest Davis, Leora Morgenstern · 2012 · KR

代名詞の解釈に常識を要する問題を提案。少数の語の変更で指示対象が変わる文の対を論じる。
https://cdn.aaai.org/ocs/4492/4492-21843-1-PB.pdf

参考文献

CLUEWSC2020: WSC Winograd 模式挑战中文版，中文指代消解任务

CLUE team · 2020 · Official task repository

中国語文学作品からの収集、二値ラベル、指定 span の形式、配布先を説明する。

https://github.com/CLUEbenchmark/CLUEWSC2020

CLUEWSC2020 public data: test version 1.1 / 1.0

CLUEbenchmark · README 2021-08-29 · Public ZIP

学習・開発と新旧テストを配布。旧テストを残し、新 test への切替えを説明する。

https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations

中国語モデルの多面的評価基盤。付録 B.1.1 で CLUEWSC の採用と共参照例を示す。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVACoreferenceResolutionScenario and Converter

Stanford CRFM · 2023 · HELM v0.4.0 implementation

テンプレートから入力と参照を作る。塊と代名詞の一致を問う中国語の例を含む。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py