# CLUEWSC2020

Chinese Winograd Schema Challenge

CLUE: Chinese Language Understanding Evaluation

中国語の文章で、代名詞と名詞句の指示関係を問う

sasakiy84

# CLUEWSC2020 の公式公開リポジトリ




[1] CLUE team. CLUEWSC2020 official repository. Fixed commit 44664627. https://github.com/CLUEbenchmark/CLUEWSC2020

1. 代名詞が指す対象を読む
2. 収集と、データの構成
3. 評価と歴史的な性能
4. CLUE と CLEVA での利用

# 「それ」は、何を指しているか

# 二つの指定箇所が、同じ対象を指すか

- CLUEWSC2020 は、中国語の文章と、指定された名詞句・代名詞を入力にする二値分類のデータ。二つが同じ対象を指すなら true 、違えば false 。
- 文中の人物や物の役割を結び付ける。近くにある名詞を機械的に選ぶだけでは、動作の対象や話し手の意図を取り違える。
- 2020 年に CLUE の新しい指示関係課題として公開された。後に CLEVA の共参照解決にも採用された。

[1] CLUE team. CLUEWSC2020: data format and task description. https://github.com/CLUEbenchmark/CLUEWSC2020/blob/446646278671444c79a67e7434b3a1d1d1cbbe88/README.md
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

# 実例１：すくい上げるのは、煮汁の中の塊

train.json / 行 681 / idx 25　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

渐渐地，汤中凝结出一团团**块状物**，将**它们**捞起放进盆里冷却，肥皂便出现在世上了。

候选名词：块状物
指定代词：它们

日本語訳：全文と指定された語句

次第に、煮汁の中に塊がいくつもできた。それらをすくい上げて盆に入れて冷ますと、石けんがこの世に生まれた。

候補の名詞句：塊
指定された代名詞：それら

**正解： true （同じ対象）**

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 681 / idx 25. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 「すくう」「冷ます」の対象を追う

- すくい上げて冷ます対象は、煮汁の中にできた塊。動作と対象の関係を読む。
- 同じ文には煮汁も出てくるが、指定された「它们」は複数の塊を受ける。ラベルは単語の一致ではなく、指示関係の一致を表す。
- この文章と対象の組は、 HELM の CLEVA シナリオにも例として載る。元 CLUE 公開データの一件と、実装中の説明例を区別して示している。

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 681 / idx 25. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

[2] Stanford CRFM. CLEVACoreferenceResolutionScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

# 実例２：招いた人と、招かれた人を分ける

train.json / 行 346 / idx 154　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

蒋盈波原来所在的教研室有位副教授去德国参加一个学术活动，活动中结识了一位华裔德籍的**同行**，那同行在自己家中招待了**他**一次，言谈之间，双方忽然都感到巧事真多，而世界真小

候选名词：同行
指定代词：他

日本語訳：全文と指定された語句

蒋盈波が以前所属していた教研室のある副教授が、学術行事に参加するためドイツへ行った。そこで中国系ドイツ人の同業者と知り合い、その同業者は自宅で彼を一度もてなした。話すうちに、双方は偶然の一致の多さと、世間の狭さに気付いた。

候補の名詞句：同業者
指定された代名詞：彼

**正解： false （同じ対象ではない）**

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 346 / idx 154. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 同業者が招いたのは、副教授

- 自宅に招いたのは同業者で、招かれたのはドイツへ行った副教授。二人の役割を区別する。
- 同じ文章に蒋盈波、副教授、同業者が登場する。文の主語が変わっても、誰が誰を自宅へ招いたかを保つ必要がある。
- この「同行」と「他」を問う組は、 CLEVA の紙面例と一致する。元の一文からは複数の対象組を作れるため、文章だけでは一問を識別できない。

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 346 / idx 154. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

# 実例３：突然鳴った物を特定する

train.json / 行 4 / idx 261　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

这时候放在**床**上枕头旁边的手机响了，我感到奇怪，因为欠费已被停机两个月，现在**它**突然响了。

候选名词：床
指定代词：它

日本語訳：全文と指定された語句

そのとき、ベッドの枕の横に置いた携帯電話が鳴った。料金未払いで 2 か月も利用停止になっていたので、今それが突然鳴ったことを不思議に思った。

候補の名詞句：ベッド
指定された代名詞：それ

**正解： false （同じ対象ではない）**

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 4 / idx 261. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 候補はベッド、鳴った物は携帯電話

- 鳴る物と利用停止の説明は携帯電話を指す。指定された候補はベッドなので false 。
- 文章中に床・枕・携帯電話があっても、元レコードが指定した候補は「床」。候補を携帯電話へ読み替えると、別の問題になる。
- ここに示す対象欄と色分けは、元の text と target を読みやすく並べたもの。元データは文章・指定箇所・二値ラベルを持つ。

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 4 / idx 261. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 文学作品から、指示関係の問題を作る

# 中国語の自然な文章を、人手で選ぶ

- 36 の現代中国文学作品から文章を選び、言語の専門家が選別・注釈した。 2020 年の構成は学習 1,244 問、開発 304 問、テスト 290 問の計 1,838 問。
- 一つの文章に対して、異なる名詞句と代名詞の組を指定できる。同じ文章から作った複数の行を、独立した文章数と混同しない。
- 原レコードには作品名や作者名の欄がない。登場人物の名前から、作品や著者を推測して補っていない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 文章、二つの span 、二値ラベル

**文章 text**

場面・動作・登場人物を読む

→

**対象 target**

名詞句と代名詞の位置を指定

→

**ラベル label**

同じ対象： true ／違う： false

分類する単位は、文章と指定された二つの箇所の組。
同じ文章が複数行に現れても、対象の組が違えば別の判定になる。

[1] CLUE team. CLUEWSC2020: data format and task description.
https://github.com/CLUEbenchmark/CLUEWSC2020/blob/446646278671444c79a67e7434b3a1d1d1cbbe88/README.md

# 2020 年の分割と、後のテスト更新

| 分割 | 2020 年の構成 | 現在の公開 ZIP |
|---|---|---|
| train | 1,244 問 | 1,244 問・正解あり |
| dev | 304 問 | 304 問・正解あり |
| test | 290 問 | 2,574 問・正解なし |
| 旧 test | 上の 290 問 | test1.0.json で 290 問を保存 |

README は 2021 年 8 月 29 日の新 test への切替えを説明。現在の train/dev/test は計 4,122 行。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 文章数と、対象組の行数は異なる

| ファイル | 行数 | 異なる text 数 | ラベル |
|---|---|---|---|
| train.json | 1,244 | 387 | true 517 / false 727 |
| dev.json | 304 | 104 | true 111 / false 193 |
| test.json | 2,574 | 1,424 | 非公開 |
| test1.0.json | 290 | 88 | 非公開 |

現在の公開 ZIP から再集計。四ファイル合計 4,412 行には、新旧テストの両方が含まれる。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 性・数・動作・談話の流れを組み合わせる

- 他・她・它に加え、他们・她们・它们のような複数形や「其」も含む。人と物、単数と複数の区別が手掛かりになる。
- それだけで決まるとは限らない。招く側と招かれる側、物を運ぶ人と運ばれる物など、文の役割と動作の対象を読み分ける。
- 本資料の 13 例は、異なる文章を使った学習・開発の公開例。ラベルを取得できないテストに、推測で正解を付けていない。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

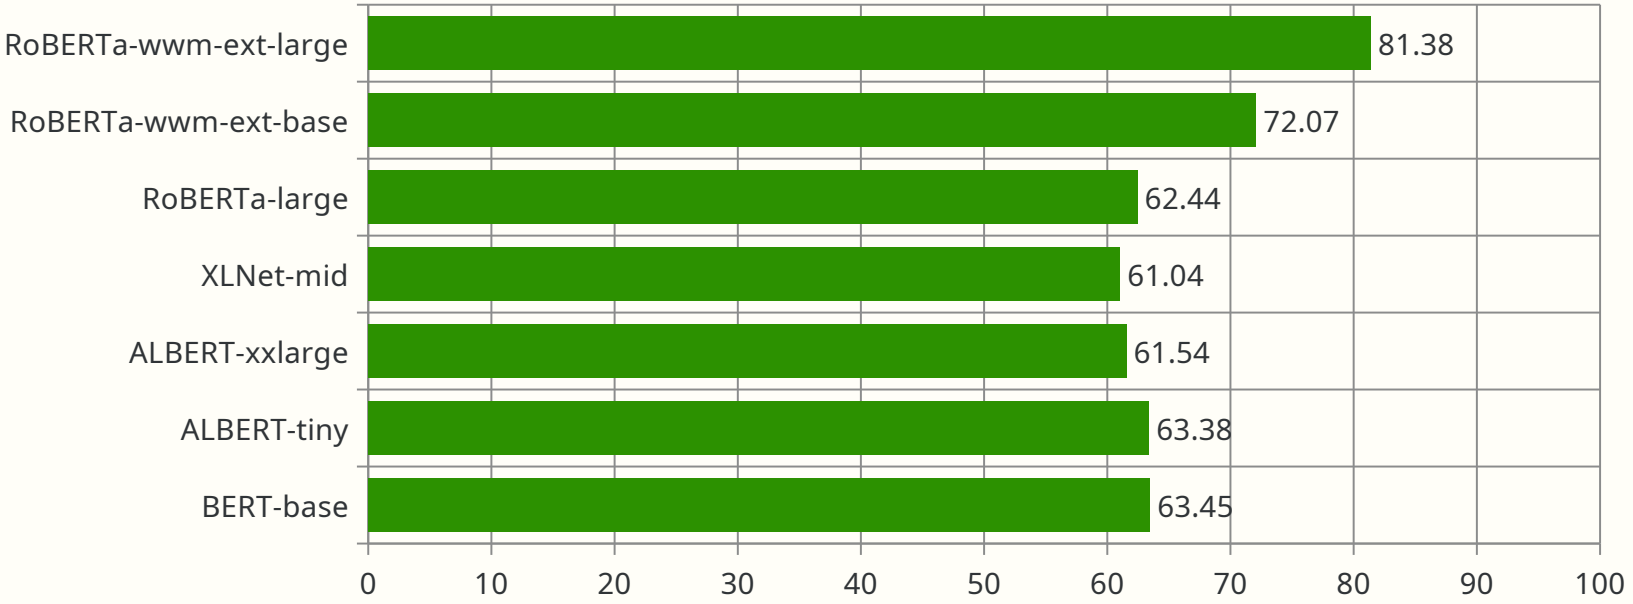
# 正答率を、評価条件とともに読む

# 正答率は、指定された組の判定が合う割合

- 予測した true/false と、参照ラベルが一致した問題の割合を正答率とする。文章中の名詞を自由に生成して、文字列の類似度を測る課題ではない。
- 歴史的なモデル性能は、 2020 年のテスト 290 問に対する報告値。現在の 2,574 問の公開テストを採点し直した値ではない。
- CLEVA も accuracy を用いる。テンプレートで整形した回答やモデルへの提示方法は、元の JSONL とは区別する。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

# 構築時のモデルは、最大 81.38 %




[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. 2020 年の test 。 9 モデル中 7 モデルを表示。
https://aclanthology.org/2020.coling-main.419/

# 人手評価 98 %は、 100 問の多数決

- テストから無作為に選んだ 100 問を 3 人が解き、個人の正答率は 94 %、 97 %、 95 %。平均は 95.3 %、多数決の正答率は 98 %だった。
- 注釈者は、開発データ 30 〜 50 問を解いて議論した後に評価した。未経験の一般読者が、説明なしに解いた結果ではない。
- モデルは 290 問、人手はそのうち 100 問。評価問題数が違うため、 81.38 %と 98 %の差を、同じ問題で比べた厳密な差とは扱わない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

# 学習の反復と、プロンプトの違いを分ける

- 各モデルを 3 回微調整し、その中で開発成績が最良のモデルのテスト値を報告した。チェックポイントは早期停止で選び、ハイパーパラメータも開発データで調整した。
- これは、生成モデルにプロンプトを与えて答えさせる CLEVA の評価とは異なる。 3 回の微調整を、 3 種類のプロンプトや 3 候補の生成と読み替えない。
- 公式リポジトリの開発精度と、正式論文のテスト精度も評価対象が違う。ここでは正式論文のテスト値を歴史的な比較として示した。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/
[2] CLUE team. CLUEWSC2020: data format and task description.
https://github.com/CLUEbenchmark/CLUEWSC2020/blob/446646278671444c79a67e7434b3a1d1d1cbbe88/README.md

# 採用先と、元の公開データを分ける

# 元 WSC の発想を、中国語の自然な文章へ

- 元の Winograd Schema Challenge は、曖昧な代名詞を解く課題。語を一つか二つ変えると、指す対象が入れ替わる文の対を重視した。
- CLUEWSC2020 は中国語の文学作品から文章を選び、指定された二箇所の同一指示を二値で判定する。元 WSC の英語問題をそのまま翻訳した集合ではない。
- 公開の各行が、語を少し変えた最小対になっているとは限らない。作品の文脈、動作、常識を読む自然な文章として扱う。

[1] Levesque, Davis & Morgenstern (2012). The Winograd Schema Challenge. KR 2012. https://cdn.aaai.org/ocs/4492/4492-21843-1-PB.pdf
[2] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

# CLEVA は、 CLUEWSC から問題を採用

- CLEVA の論文は、共参照解決に CLUEWSC から抽出したデータを使うと記す。紙面例は本資料の実例 2 と、文章・対象組・否定の正解が一致する。
- HELM v0.4.0 の CLEVACoreferenceResolutionScenario は、実例 1 の塊と「它们」を「不是／是」の二候補で示す。
- ただし、 CLEVA が選んだ全問題と変換済みファイルは今回取得できていない。元 CLUE の全件数や分割を、 CLEVA の実行件数と同一視しない。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

[2] Stanford CRFM. CLEVACoreferenceResolutionScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

# 設定の存在と、公開 run の存在

| 確認対象 | 確認できること |
|---|---|
| CLEVA v1 設定 | coreference_resolution の prompt_id 0 〜 5 |
| HELM v0.4.0 実装 | テンプレートを読み、入力と参照を構成 |
| Classic 公開索引 | 8,526 spec 中、 CLEVA 名の項目は 0 件 |
| 未取得の実体 | 選定問題全体、テンプレート、推論パラメータ |

6 個の prompt_id を、 6 モデル・ 6 回試行・ 6 件の公開 run と読み替えない。

[1] Stanford CRFM. CLEVA v1 run configuration. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf
[2] Stanford CRFM. HELM Classic v0.4.0 public release / run index. https://crfm.stanford.edu/helm/classic/v0.4.0/

# 公開 ZIP は読めるが、権利条件は別に確認する

- 公式リポジトリから、公開 ZIP へ到達できる。提供文の全文と指定箇所を読み出せるが、テストには正解ラベルが含まれない。
- 固定した課題リポジトリには README のみがあり、データ専用の利用許諾は見当たらない。関連するコードのライセンスを、文学作品の文章へ拡張しない。
- ここでは識別可能な 13 件の短い提供文を示す。配布データ全体や元の文学作品を、無条件に再配布できるとは述べない。

[1] CLUE team. CLUEWSC2020: data format and task description. https://github.com/CLUEbenchmark/CLUEWSC2020/blob/446646278671444c79a67e7434b3a1d1d1cbbe88/README.md

[2] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 小さな対象組から、文章全体の役割を読む

- 入力は文章と二つの指定箇所。 true/false は、その二つが同じ対象を指すかを表す。語の距離や性・数だけでは決まらない問題も含む。
- 2020 年の構築時評価、後のテスト更新、 CLEVA への採用を分けることで、件数と正答率の意味がはっきりする。
- 原データの位置と指示語の位置を保てば、どの文章のどの対象組を解いた結果なのかを追跡できる。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

# Appendix

1. 追加の公開実例
2. 版・原位置・実装
3. 研究と参考文献

# 追加の公開実例

# 実例 4 ：服に残る素朴さ

dev.json / 行 3 / idx 3　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

当然，他自己的**衣服**还是老模样。一身家织的老粗布，尽管金波妈给他裁剪成制服式样，但仍然不能掩饰**它**本质上的土气。

候选名词：衣服
指定代词：它

日本語訳：全文と指定された語句

もちろん、自分の服は相変わらずだった。自家製の粗い布の服を金波の母が制服の形に仕立てても、その本来の田舎くささは隠せなかった。

候補の名詞句：服
指定された代名詞：その

**正解： true （同じ対象）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 3 / idx 3. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例５：崩れそうでも残る橋

dev.json / 行 14 / idx 14　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

村里现在最高寿的人，也不知这**小桥**是什么年间建造的。**它**年年摇摇欲坠，但年年都存在着。

候选名词：小桥
指定代词：它

日本語訳：全文と指定された語句

村でいちばん長生きしている人にも、この小さな橋がいつ架けられたのか分からない。それは毎年崩れそうになりながら、毎年そこにある。

候補の名詞句：小さな橋
指定された代名詞：それ

**正解： true （同じ対象）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 14 / idx 14. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例６：繰り返される男女の代名詞

dev.json / 行 16 / idx 16　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

只要孙少平看过的书，就借给郝红梅看。无论是他给她借书，还是她给他还书，两个人不约而同地都是悄悄进行的。

候选名词：孙少平
指定代词：她

日本語訳：全文と指定された語句

孫少平が読んだ本は、どれも郝紅梅にも貸していた。彼が彼女へ本を貸すときも、彼女が彼へ返すときも、二人とも、示し合わせることなく、ひっそりと行っていた。

候補の名詞句：孫少平
指定された代名詞：彼女

**正解： false （同じ対象ではない）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 16 / idx 16. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例 7 ：父親と同僚を区別する

train.json / 行 37 / idx 294　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

**我父亲**杨金彪和他的扳道工同事郝强生坐在外面的房间里，那时我父亲只有二十一岁，**他**擦着脸上的汗水，详细讲述了发现我的经过。

候选名词：我父亲
指定代词：他

日本語訳：全文と指定された語句

父の楊金彪と、転轍係の同僚の郝強生が外の部屋に座っていた。そのとき父はまだ 21 歳で、彼は顔の汗を拭きながら、私を見つけた経緯を詳しく話した。

候補の名詞句：私の父
指定された代名詞：彼

**正解： true （同じ対象）**

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 37 / idx 294. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例 8 ：薬と小麦粉の袋を区別する

dev.json / 行 37 / idx 37　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

他先到街上给祖母买好了**药**，然后就把那一小袋面粉提到金波的宿舍里。两个人相帮着把**它**绑在后车座的旁边，就准备一起相跟回家了。

候选名词：药
指定代词：它

日本語訳：全文と指定された語句

彼はまず街で祖母のための薬を買い、それから小さな小麦粉の袋を金波の寮へ持って行った。二人は協力してそれを後部座席の脇へ縛り付け、一緒に家へ帰る準備をした。

候補の名詞句：薬
指定された代名詞：それ

**正解： false （同じ対象ではない）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 37 / idx 37. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例 9 ：一人の女性と、女性たちの集団

dev.json / 行 40 / idx 40　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

这时候，双水村妇女主任**贺凤英**，正领着本村和外村的一些“铁姑娘”，忙碌地布置会场。**她们**把课桌从教室里抬出两张来，拼在一起放到人群面前

候选名词：贺凤英
指定代词：她们

日本語訳：全文と指定された語句

そのとき双水村の女性担当主任の賀鳳英は、村内外の「鉄の娘たち」を率いて、忙しく会場を整えていた。彼女たちは教室から机を二つ運び出し、並べて人々の前へ置いた。

候補の名詞句：賀鳳英
指定された代名詞：彼女たち

**正解： false （同じ対象ではない）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 40 / idx 40. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例 10 ：二人の子供をまとめて指す

dev.json / 行 44 / idx 44　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

我回来，咱们两个人劳动，一定要把**少平和兰香**的书供成。只要他两个有本事，能考到哪里，咱们就把**他们**供到哪里。

候选名词：少平和兰香
指定代词：他们

日本語訳：全文と指定された語句

私が戻ったら二人で働いて、少平と蘭香の勉学を必ず支え切ろう。二人に力があって、どこの学校に受かろうと、私たちは彼らをそこへ通わせよう。

候補の名詞句：少平と蘭香
指定された代名詞：彼ら

**正解： true （同じ対象）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 44 / idx 44. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例 11 ：鑑賞する姿勢と、聴こえる音

dev.json / 行 61 / idx 166　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

她索性以毒攻毒，干脆用欣赏的**态度**来感受她所讨厌的风雨声。她把**它**想象成那些迷人的小夜曲，或者庞大的层次复杂的交响乐，企图在这种“陶醉”中入睡。

候选名词：态度
指定代词：它

日本語訳：全文と指定された語句

彼女はいっそ毒をもって毒を制そうと、嫌いだった風雨の音を楽しむ姿勢で聴くことにした。彼女はそれを魅力的な小夜曲や、壮大で複雑な構成の交響曲に見立て、その「陶酔」の中で眠ろうとした。

候補の名詞句：姿勢
指定された代名詞：それ

**正解： false （同じ対象ではない）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 61 / idx 166. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例 12 ：一家を、複数の人として受ける

dev.json / 行 81 / idx 186　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

**老张一家**十分厚道，都说怎能收高老师的钱呢？房子他尽管住；娃娃放下，**他们**尽力照顾。

候选名词：老张一家
指定代词：他们

日本語訳：全文と指定された語句

張さん一家はとても親切で、高先生からお金など取れるものかと皆が言った。家には自由に住んでもらえばよい。子供を預ければ、彼らが精いっぱい面倒を見る。

候補の名詞句：張さん一家
指定された代名詞：彼ら

**正解： true （同じ対象）**

[1] CLUEbenchmark. CLUEWSC2020 / dev.json / line 81 / idx 186. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例 13 ：「其」が指す、拾ったボトル

train.json / 行 698 / idx 42　　緑：候補の名詞句　青：指定された代名詞

中国語：配布 text 全文と指定 span

记得在十年前的沙依横布拉克牧场，塑料袋之类的东西更少见，偶尔在河边捡到一个从上游漂来的**塑料瓶**都会心花怒放，将**其**大派用场。

候选名词：塑料瓶
指定代词：其

日本語訳：全文と指定された語句

10 年前の沙依横布拉克牧場では、ビニール袋のような物はさらに珍しかった。上流から流れてきたプラスチック製のボトルを川岸でたまたま拾うだけでも大喜びし、それを大いに活用したのを覚えている。

候補の名詞句：プラスチック製のボトル
指定された代名詞：それ

**正解： true （同じ対象）**

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 698 / idx 42. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例ごとの判定の手掛かり

| 実例 | 説明 |
|---|---|
| 1 | すくい上げて冷ます対象は、煮汁の中にできた塊。動作と対象の関係を読む。 |
| 2 | 自宅に招いたのは同業者で、招かれたのはドイツへ行った副教授。二人の役割を区別する。 |
| 3 | 鳴る物と利用停止の説明は携帯電話を指す。指定された候補はベッドなので false 。 |
| 4 | 田舎くさい性質が残る対象は服。人を表す代名詞と、物を表す代名詞を区別する。 |

説明は本資料による。原文は各実例頁に省略せず示す。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例ごとの判定の手掛かり

| 実例 | 説明 |
|---|---|
| 5 | 建造年代の話から、毎年残っている橋の状態へつながる。 |
| 6 | 指定位置の她は郝紅梅を指す。候補の孫少平とは同じ人物ではない。 |
| 7 | 年齢の説明の後、父親が発見の経緯を話す。近くの男性名だけで判定しない。 |
| 8 | 縛り付けた対象は小麦粉の袋。先に登場した薬を選ぶ判定は false 。 |

説明は本資料による。原文は各実例頁に省略せず示す。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 実例ごとの判定の手掛かり

| 実例 | 説明 |
|---|---|
| 9 | 代名詞は複数の女性を表す。指定された一人の主任だけとの同一指示は false 。 |
| 10 | 二人を並べた名詞句を、複数代名詞で受けている。 |
| 11 | 音楽に見立てる対象は風雨の音。音を聴く姿勢そのものを指しているのではない。 |
| 12 | 一家という集団名を、その家族の人々を表す他们で受ける。 |
| 13 | 其は拾ったボトルを指す。先に出た牧場や袋ではなく、直前に拾った物を受ける。 |

説明は本資料による。原文は各実例頁に省略せず示す。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 版・原位置・実装

# 13 件の公開位置と、指定された対象

| 実例 | ファイル / 行 | span1 → span2 | 正解 |
|---|---|---|---|
| 1 | train.json / 681 | 块状物 → 它们 | true |
| 2 | train.json / 346 | 同行 → 他 | false |
| 3 | train.json / 4 | 床 → 它 | false |
| 4 | dev.json / 3 | 衣服 → 它 | true |
| 5 | dev.json / 14 | 小桥 → 它 | true |
| 6 | dev.json / 16 | 孙少平 → 她 | false |
| 7 | train.json / 37 | 我父亲 → 他 | true |

行番号は 1 起算。学習の idx は一意ではない。各行の SHA256 と元レコードを付属記録に保存。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 13 件の公開位置と、指定された対象

| 実例 | ファイル / 行 | span1 → span2 | 正解 |
|---|---|---|---|
| 8 | dev.json / 37 | 药 → 它 | false |
| 9 | dev.json / 40 | 贺凤英 → 她们 | false |
| 10 | dev.json / 44 | 少平和兰香 → 他们 | true |
| 11 | dev.json / 61 | 态度 → 它 | false |
| 12 | dev.json / 81 | 老张一家 → 他们 | true |
| 13 | train.json / 698 | 塑料瓶 → 其 | true |

行番号は 1 起算。学習の idx は一意ではない。各行の SHA256 と元レコードを付属記録に保存。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 文章が同じでも、対象が違えば別の行

| 元位置 | span1 | span2 | label |
|---|---|---|---|
| train / 345 | 蒋盈波 | 他 | false |
| train / 346 | 同行 | 他 | false |
| train / 347 | 副教授 | 他 | true |
| train / 681 | 块状物 | 它们 | true |
| train / 682 | 汤 | 它们 | false |

同じ文章の行を、 13 件の独立文章の数へ重複計上していない。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 文字位置は、 UTF-8 のバイト位置ではない

- target の span1_index と span2_index は 0 起算の文字位置。指定された位置から文字数分を切り出すと、各 span の文字列に一致する。
- 同じ代名詞が複数回現れる文章では、文字列の検索だけでは指定箇所を確定できない。本資料では位置に従って一箇所だけ色を付けた。
- 現在の新テストには、候補名詞句が代名詞より後にある行も 464 件ある。すべての候補が代名詞より前にあるとは仮定しない。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 一意な ID と、一意な入力は違う

- 学習 1,244 行にある idx は 347 種類。同じ idx を持つ行があるため、原位置はファイル名、行番号、元行の SHA256 で固定する。
- 文章と target を組にした異なる入力は、学習 1,239 種類、新テスト 2,568 種類。異なる行が同じ入力を繰り返す場合もある。
- 四ファイル間に完全一致する text はなかった。ただし、同じ作品・著者・近い文章が分割をまたがないことまで保証する検査ではない。

[1] CLUEbenchmark. cluewsc2020_public.zip; README dated 2021-08-29. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 正式論文で報告された 9 モデルの精度

| モデル | test 正答率（%） |
|---|---|
| BERT-base | 63.45 |
| BERT-wwm-ext-base | 62.41 |
| ALBERT-tiny | 63.38 |
| ALBERT-xxlarge | 61.54 |
| ERNIE-base | 63.44 |

2020 年の旧 test 290 問。現在の公開 test や、 CLEVA の公開 run による値ではない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

# 正式論文で報告された 9 モデルの精度

| モデル | test 正答率（%） |
|---|---|
| XLNet-mid | 61.04 |
| RoBERTa-large | 62.44 |
| RoBERTa-wwm-ext-base | 72.07 |
| RoBERTa-wwm-ext-large | 81.38 |

2020 年の旧 test 290 問。現在の公開 test や、 CLEVA の公開 run による値ではない。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

# ラベルを保って、公開の一行を読む

```
import json
with open('train.json', encoding='utf-8') as f:
    row = json.loads(f.readlines()[680])
t = row['target']
for k in ('span1', 'span2'):
    start = t[k + '_index']
    span = t[k + '_text']
    assert row['text'][start:start + len(span)] == span
assert row['label'] == 'true'
print(t['span1_text'], t['span2_text'], row['label'])
```

拡張子は .json だが、各行が独立した JSON 。上の 680 は 0 起算。

[1] CLUEbenchmark. CLUEWSC2020 / train.json / line 681 / idx 25. https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# HELM はテンプレートから入力と参照を作る

- Converter は変換済みの input と choices を読み、 label に含まれる候補位置へ正解タグを付ける。文字列ラベルの true/false を、全タスク共通でそのまま比較する仕組みではない。
- 提示方法は prompt の meta.mul_as_gen などで分岐する。生成、選択肢の一括提示、候補ごとの比較という方法を切り替えられる。
- 具体的な推論値は infer_params.json から読む。未取得の値を、温度 0 ・ 5 提示例・出力 1 候補などで補っていない。

[1] Stanford CRFM. CLEVACoreferenceResolutionScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

# 公開されていない条件を、得点へ補わない

- Classic v0.4.0 公開 run 索引の 8,526 件と、 run から suite への対応表を対象に CLEVA 名を照合したが、該当は 0 件だった。
- CLEVA v1 の設定には共参照解決の 6 種類の prompt_id が存在する。設定ファイルと、公開された実行結果・モデル出力は別の資料である。
- 変換済み集合や推論値を取得できていないため、元の CLUEWSC2020 と同一条件の CLEVA 得点は示さない。

[1] Stanford CRFM. CLEVA v1 run configuration. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf
[2] Stanford CRFM. HELM Classic v0.4.0 public release / run index. https://crfm.stanford.edu/helm/classic/v0.4.0/

# 研究と参考文献

# 中国語の言語理解を、共通の基盤で測る

- CLUE チームは、 Liang Xu 、 Hai Hu 、 Xuanwei Zhang らによる共同プロジェクト。 COLING 2020 では 9 種類の中国語理解課題と事前学習モデルの比較を示した。
- CLUEWSC2020 はそのうち、指定された代名詞の指示対象を判定する課題。英語中心の評価基盤を補い、中国語の自然な文脈で理解を測る位置付けを持つ。
- 元 WSC の発想、 CLUE での中国語データ整備、 CLEVA での言語モデル評価という、異なる段階の取り組みがつながっている。

[1] Xu et al. (2020). CLUE: A Chinese Language Understanding Evaluation Benchmark. COLING, pp.4762–4772. https://aclanthology.org/2020.coling-main.419/

# 参考文献


## CLUE: A Chinese Language Understanding Evaluation Benchmark

Liang Xu et al. · 2020 · COLING, pp.4762–4772

中国語 9 課題を整備。 CLUEWSC2020 の収集・分割と、モデルおよび人手の評価を報告する。
https://aclanthology.org/2020.coling-main.419/

## The Winograd Schema Challenge

Hector J. Levesque, Ernest Davis, Leora Morgenstern · 2012 · KR

代名詞の解釈に常識を要する問題を提案。少数の語の変更で指示対象が変わる文の対を論じる。
https://cdn.aaai.org/ocs/4492/4492-21843-1-PB.pdf

# 参考文献


## CLUEWSC2020: WSC Winograd 模式挑战中文版，中文指代消解任务

CLUE team · 2020 · Official task repository

中国語文学作品からの収集、二値ラベル、指定 span の形式、配布先を説明する。

https://github.com/CLUEbenchmark/CLUEWSC2020

## CLUEWSC2020 public data: test version 1.1 / 1.0

CLUEbenchmark · README 2021-08-29 · Public ZIP

学習・開発と新旧テストを配布。旧テストを残し、新 test への切替えを説明する。

https://storage.googleapis.com/cluebenchmark/tasks/cluewsc2020_public.zip

# 参考文献

## CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations

中国語モデルの多面的評価基盤。付録 B.1.1 で CLUEWSC の採用と共参照例を示す。

https://aclanthology.org/2023.emnlp-demo.17/

## CLEVACoreferenceResolutionScenario and Converter

Stanford CRFM · 2023 · HELM v0.4.0 implementation

テンプレートから入力と参照を作る。塊と代名詞の一致を問う中国語の例を含む。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py