# 領域認識用データセット

# MS COCO

Microsoft COCO: Common Objects in Context

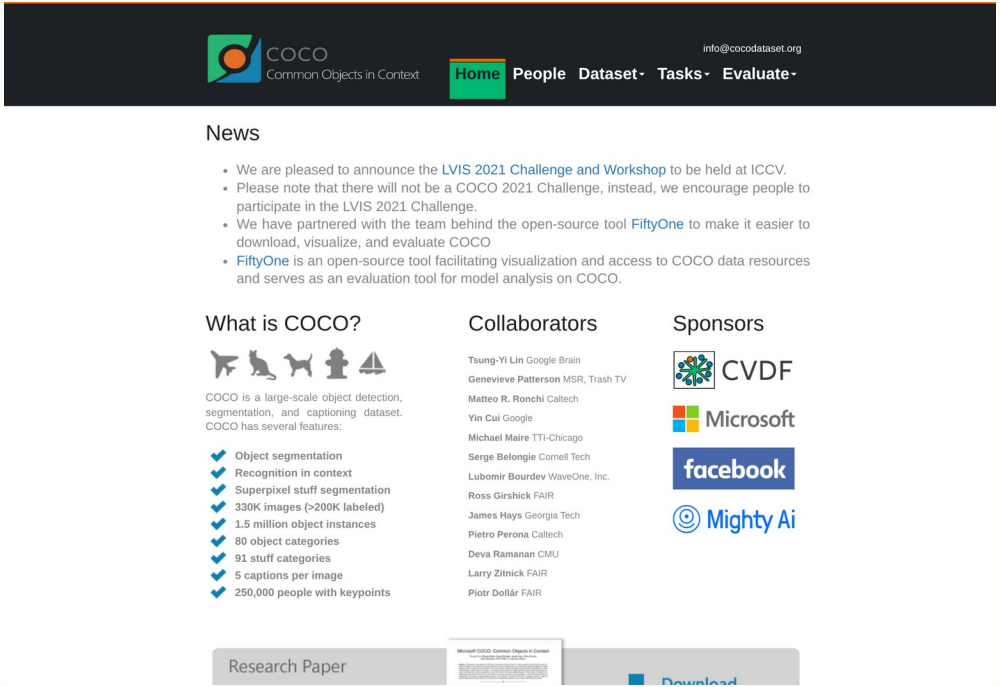
sasakiy84

# 本編の構成

1. 目的と実例
2. 作成方法とデータの範囲
3. 評価方法と代表モデル
4. 利用の変遷と入手

# 1 目的と実例

# 公式サイトの公開ソースによるトップ画面




https://cocodataset.org/

公開元 https://github.com/cocodataset/cocodataset.github.io （ライブ画面ではなく公開HTMLの再描画）

# 何が、どこに、いくつあるかを認識する

- 画像を入力し、物体のカテゴリと位置を出力する。
- 物体検出は矩形、インスタンス分割は物体ごとの画素領域を予測する。
- Panoptic 分割は人・車などの個体と、空・道などの背景領域を一体で扱う [1]。

[1] https://cocodataset.org/#panoptic-2018

# 食卓の複数の物体を領域ごとに分ける



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000009 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 遮蔽された人と重なり合う傘を分ける



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000315 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 人の個体と、芝・木・空の領域を分ける



[1] https://github.com/cocodataset/panopticapi

COCO image ID 000000142238 / 公式 Panoptic API サンプルの正解領域

# 日常の文脈の中にある物体を集めた

- 大きな物体が中央に一つある画像だけでは、日常場面の認識を十分に試せない。
- COCO は複数物体の共起、小さな物体、遮蔽を含む場面を重視した。
- Tsung-Yi Lin らが ECCV 2014 で発表。最終著者は C. Lawrence Zitnick [1] 。

[1] https://arxiv.org/abs/1405.0312

# 2 作成方法とデータの範囲

# 画像選定と領域注釈を段階に分けた

- Flickr から日常の場面を収集し、物体カテゴリの組合せで多様な文脈を探した。
- カテゴリの存在確認、個体の特定、輪郭の作成を分業し、各段階で品質を確認した [1]。
- 現在の配布では矩形・カテゴリ・領域マスクを同じ物体注釈にまとめる [2]。

[1] https://arxiv.org/abs/1405.0312
[2] https://cocodataset.org/#format-data

# 画像・物体・カテゴリを区別する

- 1 枚の画像に複数の物体注釈が対応する。
- 物体注釈は画像 ID 、カテゴリ ID 、矩形、領域、面積、 iscrowd を持つ。
  - 矩形は左上の x ・ y と幅・高さ。領域は多角形または RLE 形式で記録する [1] 。

[1] https://cocodataset.org/#format-data

# COCO 2017 の画像分割

| 分割 | 画像数の概数 | 正解領域 |
|---|---|---|
| train | 118K | 公開 |
| val | 5K | 公開 |
| test | 41K | 非公開 |

2014 年版の train 83K ／ val 41K を、同じ画像で再分割した。 2017 は撮影年ではなく分割の公開年 [1] 。

[1] https://cocodataset.org/#download

# 全体の規模と 2017 年版の範囲

- 公式サイトは全体を約 330K 画像、うち 200K 超を注釈付きとし、約 150 万物体を収録すると説明する。
- 2017 年版の train ＋ val は約 123K 画像。検出用の正解領域が公開されている。
- 全体規模の概数と、手元の train ＋ val で数える件数は対象範囲が異なる [1]。

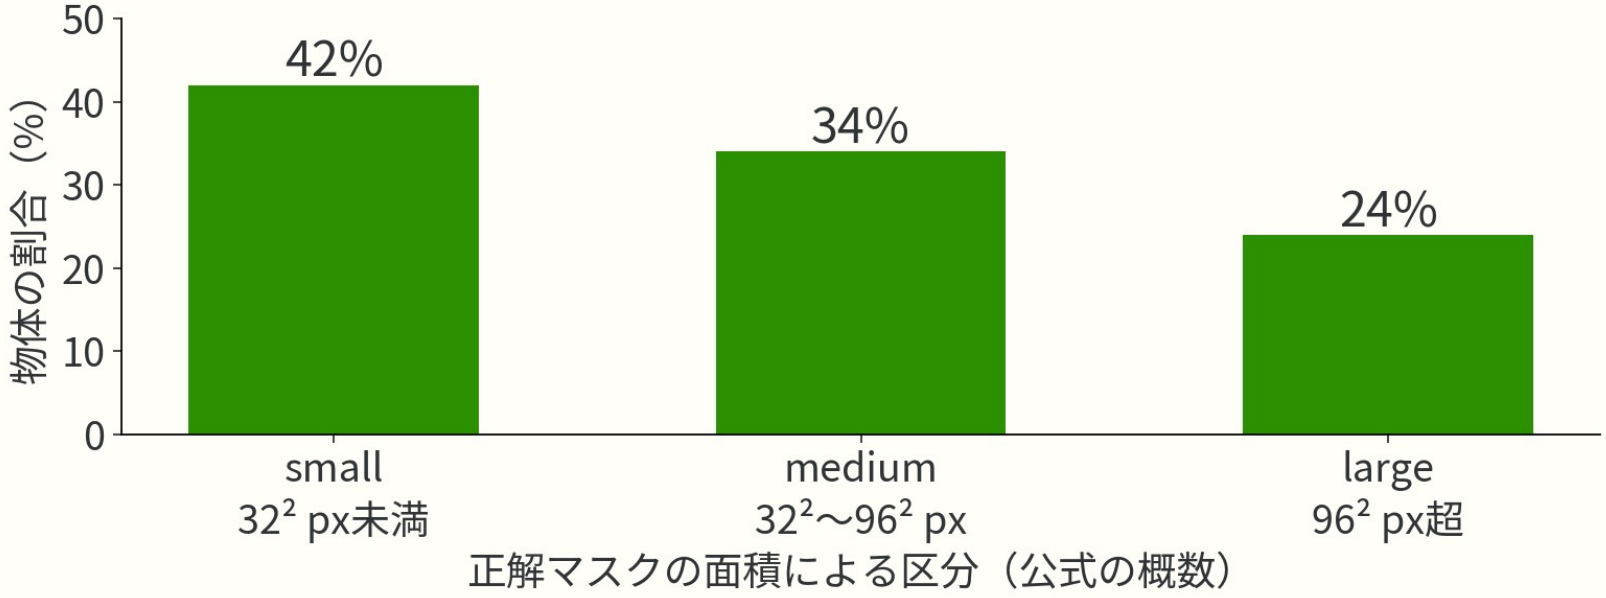
[1] https://cocodataset.org/ / https://cocodataset.org/#download

# 80 物体カテゴリと背景カテゴリ

- 物体検出・インスタンス分割は 80 カテゴリ。人、乗り物、動物、食品、家具などを含む。
- COCO-Stuff は 80 物体＋ 91 背景の 171 カテゴリ。
- COCO Panoptic は 80 物体＋ 53 背景の 133 カテゴリ。背景カテゴリを統合した体系を使う [1, 2] 。

[1] https://github.com/nightrome/cocostuff
[2] https://github.com/cocodataset/panopticapi/blob/master/panoptic_coco_categories.json

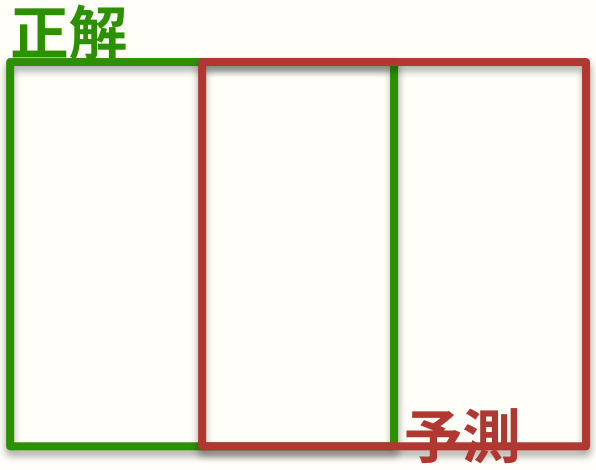
# 小さな物体が多く、位置合わせも難しい




[1] https://cocodataset.org/#detection-eval / 公式ページの物体面積別の概数（42%、34%、24%）

# 3 評価方法と代表モデル

# IoU は領域の重なりを測る




**IoU = 共通部分 ÷ 和集合**

この矩形例では 2 ÷ 6 = 1/3
IoU 0.50 で一致とはならない。
マスクは画素単位で評価する。

[1] https://cocodataset.org/#detection-eval / 図は指標を説明する矩形例

# AP は全予測を集計して評価する

- カテゴリごとに予測を信頼度順に並べ、同じ画像の正解へ対応付ける。
- 適合率・再現率から AP を計算する。
- 主指標はカテゴリと IoU 0.50 〜 0.95 の 10 閾値で平均した AP 。 AP50 より位置精度に厳しい [1] 。

[1] https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocotools/cocoeval.py

# 数えにくい集団には crowd 注釈がある

- 密集して個体ごとの区切りが難しい領域は、iscrowd=1 でまとめて注釈する。
- crowd への一致は通常の真陽性に数えず、条件を満たす予測を評価から除外する。
- 同じ物体への重複検出や、小さい対象の見落としも AP に影響する [1]。

[1] https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocotools/cocoeval.py

# 異なる検出方式の公開結果

| 方式・設定 | box AP | 評価集合 |
|---|---|---|
| Faster R-CNN R50-FPN 3x [1] | 40.2 | COCO val2017 |
| RetinaNet R50-FPN 3x [1] | 38.7 | COCO val2017 |
| RT-DETRv2-L 640 px [2] | 53.4 | COCO val |

各公開実装の単一モデルの値（%）。学習期間・入力解像度・事前学習などが異なるため、方式だけの優劣を示す比較ではない。

[1] https://github.com/facebookresearch/detectron2/blob/main/MODEL_ZOO.md
[2] https://github.com/lyuwenyu/RT-DETR

# Panoptic 分割には PQ を使う

- 同じカテゴリの正解と予測を IoU > 0.50 で対応付ける。
- PQ は対応した領域の IoU の和を、 TP ＋ 0.5FP ＋ 0.5FN で割って求める。
- 領域形状の精度と、領域を見つけて数える精度を同時に測り、カテゴリ間で平均する [1] 。

[1] https://cocodataset.org/#panoptic-eval

# 4 利用の変遷と入手

# 公開から現在まで、共通の評価基盤へ

- 2014 年に物体の文脈と領域を重視したデータとして登場し、 2017 年に学習・検証分割を再編した。
- 2018 年には Panoptic 分割を追加した [1] 。
- 2026-10-15 の確認では、 RT-DETR 系の公式実装が COCO での評価設定と結果を公開している [2] 。

[1] https://cocodataset.org/#download
[2] https://github.com/lyuwenyu/RT-DETR

# 先行する VOC 、後続の LVIS との関係

- PASCAL VOC は 20 物体カテゴリ。 COCO は 80 カテゴリで、複数物体の文脈を扱う [1] 。
- LVIS は COCO 画像を使い、物体カテゴリを 1,000 以上へ拡張した [2] 。
- COCO の得点だけでは、まれな物体や専門領域への汎化は分からない。

[1] https://cocodataset.org/#external
[2] https://github.com/lvis-dataset/lvis-api

# 画像と注釈を別々に入手する

| 公式配布物 | 圧縮容量の目安 |
|---|---|
| train2017 画像 ZIP | 18 GB |
| val2017 画像 ZIP | 1 GB |
| train ＋ val 注釈 ZIP | 241 MB |
| Panoptic 注釈 ZIP | 821 MB |

公式ページの圧縮配布サイズ。展開後の容量ではない。画像の利用条件は Flickr 側のライセンスも確認する [1]。

[1] https://cocodataset.org/#download

# 公式 API で物体注釈を読み込む

```
from pycocotools.coco import COCO

coco = COCO("annotations/instances_val2017.json")
ids = coco.getImgIds(catIds=coco.getCatIds(catNms=["cat"]))
info = coco.loadImgs(ids[0])[0]
anns = coco.loadAnns(coco.getAnnIds(imgIds=[info["id"]]))
```

pycocotools を導入し、公式配布 ZIP を展開して使う。画像ファイルは画像 ZIP から別に取得する。

[1] https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocoDemo.ipynb

# COCO が測る領域認識

- 日常場面の複数物体を、矩形・個体ごとの領域・背景を含む領域として扱う。
- 物体の 80 カテゴリと、 Panoptic の 133 カテゴリを区別する。
- 主指標 AP は位置精度を含み、 Panoptic の PQ は領域形状と個体の検出を合わせて測る。

# Appendix の構成

1. 定義・著者・評価の詳細
2. 128 画像で見る注釈の分布
3. 追加の領域注釈例
4. 全 80 カテゴリと利用条件
5. 参考文献

# 原著の著者と研究の位置付け

- 第一著者 Tsung-Yi Lin は、物体認識・検出の研究者。後の Feature Pyramid Networks でも第一著者を務めた。
- 最終著者 C. Lawrence Zitnick は、視覚認識や画像理解の研究者。
- 原著は ECCV 2014 で発表され、日常場面の文脈と物体領域の注釈をデータ設計の中心に据えた [1]。

[1] https://arxiv.org/abs/1405.0312

Tsung-Yi Lin et al., Microsoft COCO: Common Objects in Context, ECCV 2014, pp. 740–755.

# 同じ画像でもタスクごとに正解が異なる

| 課題 | 出力単位 | 主指標 |
|---|---|---|
| 物体検出 | 物体ごとの矩形 | box AP |
| インスタンス分割 | 物体ごとの領域 | mask AP |
| 意味的領域分割 | 各画素のカテゴリ | mIoU |
| Panoptic 分割 | カテゴリ＋個体 ID | PQ |

意味的領域分割では、同じカテゴリに属する複数の人を個体として区別する必要がない。

[1] https://cocodataset.org/#panoptic-eval
[2] https://github.com/nightrome/cocostuff

# 通常注釈と crowd 注釈の扱い

- 通常の一致判定は、交差面積を和集合面積で割る IoU を用いる。
- crowd との判定は交差面積を予測面積で割る。一つの crowd 領域へ複数の予測を対応付けられる。
- crowd 正解は再現率の分母から除外され、そこへ一致した予測も適合率の集計から除外される [1]。

[1] https://github.com/cocodataset/cocoapi/blob/master/common/maskApi.c
https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocotools/cocoeval.py

# AP の平均には複数の軸がある

- 各カテゴリ・各 IoU 閾値で、信頼度順の予測から適合率・再現率を作る。
- 再現率 0.00 〜 1.00 の 101 点で補間した適合率を平均し、カテゴリと 10 個の IoU 閾値で平均する。
- 通常 AP は maxDets=100 。公式 Python 実装では、画像・カテゴリごとに上位 100 予測を使う [1] 。

[1] https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocotools/cocoeval.py

# 1 領域の一致と、 PQ 全体の計算

- 同一カテゴリの正解 2 領域に対し、予測 2 領域のうち 1 領域が IoU 0.80 で一致したとする。
- TP=1 、 FP=1 、 FN=1 なので、 PQ=0.80÷(1 ＋ 0.5 ＋ 0.5)=0.40 。
- 実評価はカテゴリごとに全画像の一致・誤検出・見落としを集計し、カテゴリ間で平均する [1] 。

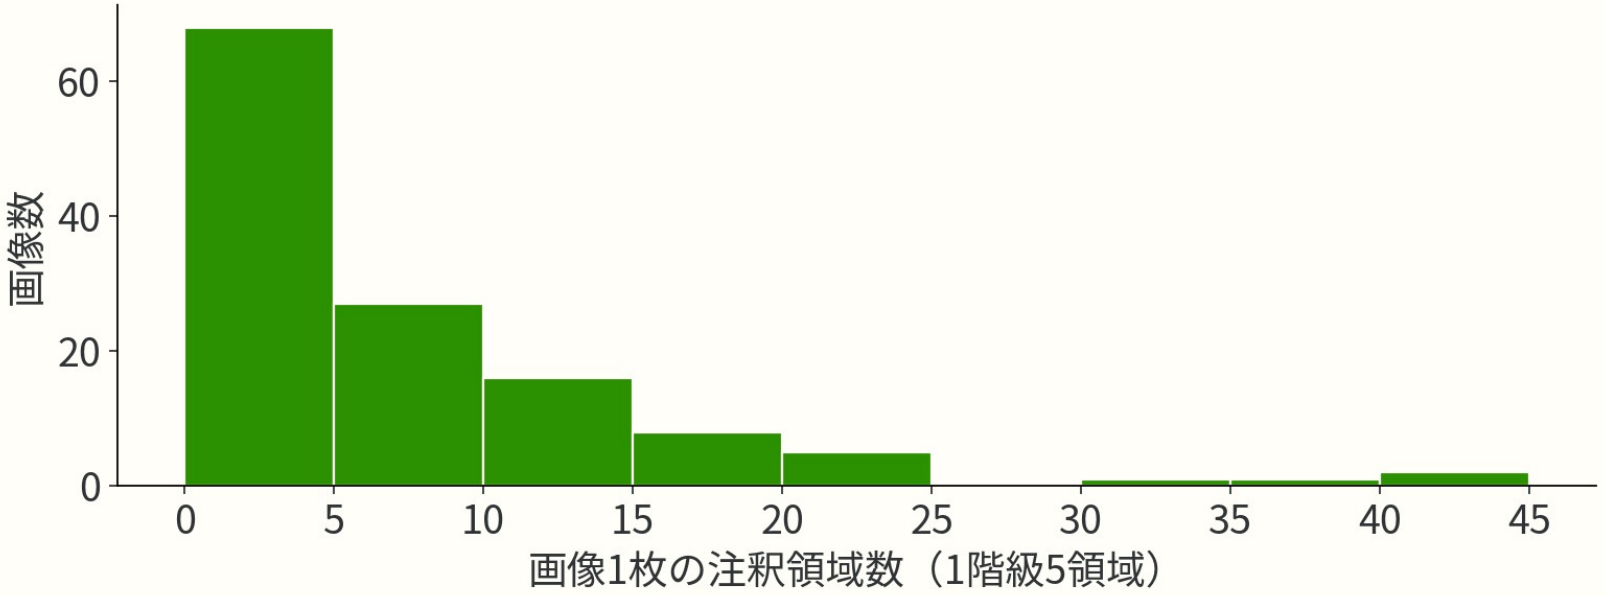
[1] https://github.com/cocodataset/panopticapi/blob/master/panopticapi/evaluation.py / 数値は計算説明の例

# ここからは公開 128 画像の部分集合を見る

- 全体の配布画像は約 330K 枚だが、以下の集計は COCO128-seg の 128 画像に限定する。
- 公開変換された領域注釈を画像ごとに数え、注釈ファイルがない 2 画像は 0 領域として含める。
- これは例示用の小さな部分集合。カテゴリ頻度や領域数の分布を COCO 全体へ一般化しない [1]。

[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip

# 128 画像の注釈領域数の分布




[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip

128 画像すべて。画像ごとの注釈行数、 1 階級 5 領域、表示範囲外 0 画像。

# 128 画像に含まれる 929 領域

| 統計量 | 注釈領域数／画像 |
|---|---|
| 平均／中央値 | 7.26 ／ 4 |
| 母標準偏差 | 7.76 |
| 第 1 ／第 3 四分位点 | 2 ／ 10 |
| 最小／最大 | 0 ／ 42 |

全 128 画像を等重みで計算。分位点は線形補間。 80 カテゴリ中 71 カテゴリの注釈を含む。

[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip

# 最多の 42 領域を含む食卓



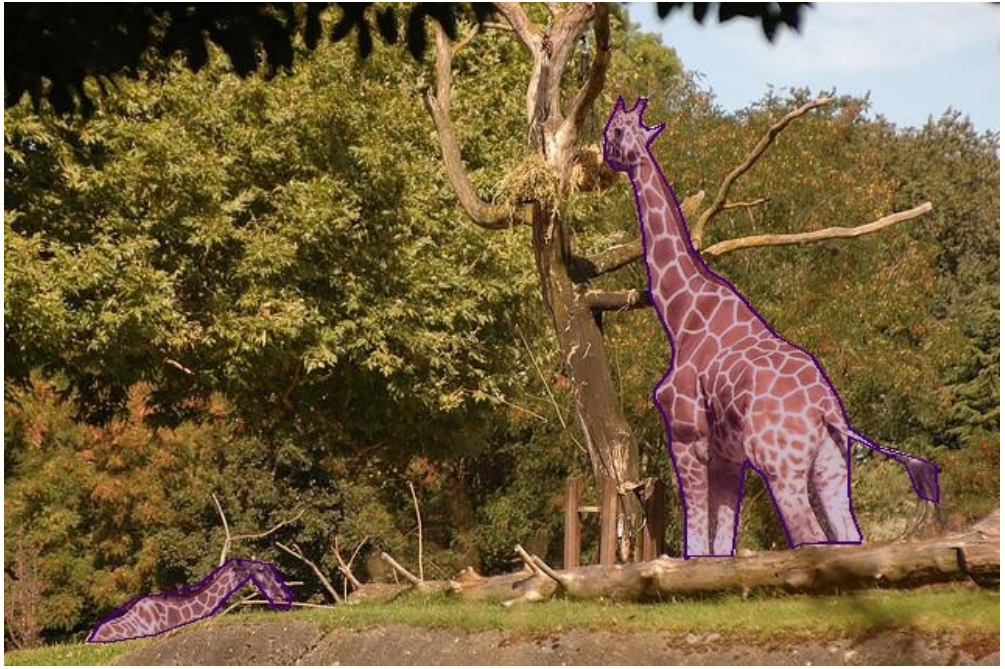
[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000196 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 注釈が 0 領域の画像にも物体は写る




[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000250 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# キリン giraffe



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000025 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# シマウマ zebra



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000034 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 猫 cat




[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000042 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 街路の時計 clock




[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000064 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 重なり合う自転車 bicycle




[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000073 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 飛行機 airplane




[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000081 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# ケーキとフォーク cake / fork



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000092 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 野球の人と道具 person / bat / glove



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000192 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# スキーとスノーボード skis / snowboard



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000201 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 前後に重なるゾウ elephant



[1] https://github.com/ultralytics/assets/releases/download/v0.0.0/coco128-seg.zip
COCO image ID 000000000263 / COCO128-seg 公開変換注釈の輪郭を重ねて表示

# 全 80 カテゴリ（ 1/4 ）

- person （ 1 カテゴリ） : person
- vehicle （ 8 カテゴリ） : bicycle, car, motorcycle, airplane, bus, train, truck, boat
- outdoor （ 5 カテゴリ） : traffic light, fire hydrant, stop sign, parking meter, bench

[1] https://github.com/cocodataset/panopticapi/blob/master/panoptic_coco_categories.json / isthing=1の全80カテゴリ

# 全 80 カテゴリ（ 2/4 ）

- animal （ 10 カテゴリ） : bird, cat, dog, horse, sheep, cow, elephant, bear, zebra, giraffe
- accessory （ 5 カテゴリ） : backpack, umbrella, handbag, tie, suitcase
- sports （ 10 カテゴリ） : frisbee, skis, snowboard, sports ball, kite, baseball bat, baseball glove, skateboard, surfboard, tennis racket

[1] https://github.com/cocodataset/panopticapi/blob/master/panoptic_coco_categories.json / isthing=1の全80カテゴリ

# 全 80 カテゴリ（3/4）

- kitchen （7 カテゴリ）: bottle, wine glass, cup, fork, knife, spoon, bowl
- food （10 カテゴリ）: banana, apple, sandwich, orange, broccoli, carrot, hot dog, pizza, donut, cake
- furniture （6 カテゴリ）: chair, couch, potted plant, bed, dining table, toilet

[1] https://github.com/cocodataset/panopticapi/blob/master/panoptic_coco_categories.json / isthing=1の全80カテゴリ

# 全 80 カテゴリ（ 4/4 ）

- electronic （ 6 カテゴリ） : tv, laptop, mouse, remote, keyboard, cell phone
- appliance （ 5 カテゴリ） : microwave, oven, toaster, sink, refrigerator
- indoor （ 7 カテゴリ） : book, clock, vase, scissors, teddy bear, hair drier, toothbrush

[1] https://github.com/cocodataset/panopticapi/blob/master/panoptic_coco_categories.json / isthing=1の全80カテゴリ

# 画像・注釈・ソフトウェアの利用条件

- 注釈と Web サイトは COCO Consortium の CC BY 4.0 で提供される。
- 画像の著作権は撮影者側にあり、 Flickr の画像ごとの利用条件に従う。
- 公式 API は BSD 形式の利用条件を持つ。画像・注釈・コードで利用条件が異なる [1] 。

[1] https://cocodataset.org/#termsofuse
https://github.com/cocodataset/cocoapi/blob/master/license.txt

# 参考文献

## Microsoft COCO: Common Objects in Context

Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, C. Lawrence Zitnick (2014).

European Conference on Computer Vision (ECCV), pp. 740–755.

COCO の原著論文。日常場面の画像選定、物体の領域注釈、データの性質と初期評価を報告する。

https://arxiv.org/abs/1405.0312

# 参考文献

## COCO API

COCO Consortium (n.d.; 参照日 2026-10-15).

GitHub, cocodataset/cocoapi.

COCO の公式実装。画像・注釈の読込み、マスク表現、検出と領域分割の評価コードを提供する。

https://github.com/cocodataset/cocoapi

# 参考文献

## COCO-Stuff: Thing and Stuff Classes in Context

Holger Caesar, Jasper Uijlings, Vittorio Ferrari (2018).

IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1209–1218.

COCO へ背景領域の画素注釈を加えた研究。物体と背景を合わせた場面理解用データを提示する。

https://arxiv.org/abs/1612.03716

# 参考文献

## Panoptic Segmentation

Alexander Kirillov, Kaiming He, Ross Girshick, Carsten Rother, Piotr Dollár (2019).

IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 9404–9413.

意味的領域分割とインスタンス分割を統合する課題を定義した研究。共通指標 Panoptic Quality を提案する。

https://arxiv.org/abs/1801.00868

# 参考文献

## Mask R-CNN

Kaiming He, Georgia Gkioxari, Piotr Dollár, Ross Girshick (2017).

IEEE International Conference on Computer Vision (ICCV), pp. 2961–2969.

検出器へ物体ごとのマスク予測を加えた代表的な領域分割モデル。 COCO 上で検出・分割・人物姿勢の評価を報告する。

https://arxiv.org/abs/1703.06870

# 参考文献

## LVIS: A Dataset for Large Vocabulary Instance Segmentation

Agrim Gupta, Piotr Dollár, Ross Girshick (2019).

IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5356–5364.

COCO 画像へ大語彙の物体領域注釈を追加した後続データセット。まれなカテゴリを含む長い裾の分布を評価対象にする。

https://arxiv.org/abs/1908.03195