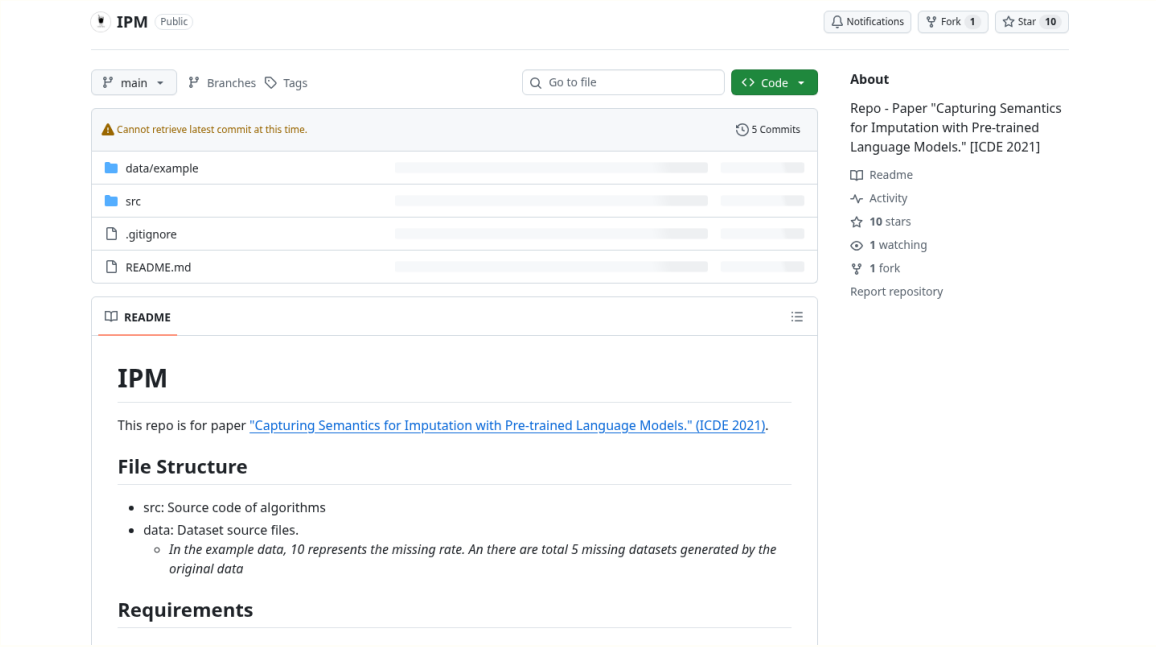
表の欠損補完

Abt-Buy の Buy 表 / Restaurant

商品と飲食店の属性値を補う

sasakiy84

補完研究 IPM の公式実装



[1] Mei et al. (2021). Capturing Semantics for Imputation with Pre-trained Language Models — IPM 公式実装。
https://github.com/EliasMei/IPM

1. 表の空欄を、一つの値で埋める
2. 公開表から、補完問題を作る
3. 補完結果を確かめる
4. 手掛かりと利用条件

表の空欄を、一つの値で埋める

一つの行から、隠した属性を復元する

- データ補完は、表の空欄を他の属性から埋める処理。本資料では、商品表 Buy と飲食店表 Restaurant を例に、メーカーや都市を補う方法を考える。
- 元のセルに値がある行なら、その値をいったん隠すことで、答えが分かる補完問題を作れる。商品名や説明、住所や電話番号など、同じ行に残した属性を手掛かりにする。
- Liang らが 2022 年に公開した研究でも、この 2 表の値を言語モデルで補う課題が扱われた。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. 初稿 2022 。
https://arxiv.org/abs/2211.09110v1

対象は、商品と飲食店の二つの表

使う表	隠す属性	手掛かりとして残す属性
Buy	manufacturer メーカー	name 、 description 、 price 商品名、説明、価格
Restaurant	city 都市	name 、 addr 、 phone 、 type 店名、住所、電話、料理の種類

商品の特徴や所在地の違いが伝わる 13 例を紹介する。各行を文章化し、メーカーまたは都市の元セルを正解として示す。

[1] Database Group, Universität Leipzig. Abt-Buy.
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

[2] University of Texas at Austin. RIDDLE / Restaurant data.
https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

実例１：リモコンのメーカー

表の行を文章化した補完問題（全文）

name: Sony Universal Remote Control - RM-EZ4. description: TV, Cable Box - Universal Remote. price: $12.72. manufacturer?

対応する日本語訳

商品名： Sony の汎用リモコン – RM-EZ4 。説明：テレビ、ケーブルテレビ受信機用 – 汎用リモコン。価格： $12.72 。メーカーは？

正解： Sony

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例２：住所と電話番号から都市を補う

表の行を文章化した補完問題（全文）

name: kelly's on trinity. addr: 333 bush st.. phone: 415-362-4454. type: californian. city?

対応する日本語訳

店名： kelly’s on trinity 。住所： 333 bush st. 。電話： 415-362-4454 。料理の種類：カリフォルニア料理。都市は？

正解： san francisco

サンフランシスコ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

実例３：正解には製品分野まで含まれる

表の行を文章化した補完問題（全文）

name: Canon VIXIA HF100 High Definition Digital Camcorder - 2708B001. description: Canon VIXIA HF100 High Definition Camcorder. price: $529.00. manufacturer?

対応する日本語訳

商品名： Canon VIXIA HF100 高精細デジタルビデオカメラ – 2708B001 。説明： Canon VIXIA HF100 高精細ビデオカメラ。価格： $529.00 。メーカーは？

正解： Canon Camcorders

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

公開表から、補完問題を作る

商品・飲食店の照合用に公開された表を使う

- Buy は、商品照合用の Abt-Buy に含まれる片側の表。商品名、説明、価格、メーカーなどの属性があり、メーカーを補う例に使える。
- Restaurant は、飲食店照合のために公開されたデータ。電話番号を含む fz.arff には店名、住所、電話番号、都市、料理の種類があり、同じ店を示す class も付く。

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution
[2] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff).
https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

Buy.csv から、手掛かりと正解を取り出す

```
import pandas as pd
table = pd.read_csv("Buy.csv").dropna(subset=["description"])
row = table.iloc[0]
answer = row["manufacturer"]
print(row[["name", "description", "price"]])
print("正解:", answer)
```

配布 ZIP から Buy.csv を展開し、同じフォルダで実行する。メーカー欄を正解として取り出し、商品名・説明・価格を表示する。

[1] Database Group, Universität Leipzig. Abt-Buy.
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

説明文を使うときは、空欄を確認する

処理と残った空欄	件数
配布 Buy.csv	1,092 行
description が欠損した行を除外	441 行
説明文がある商品行	651 行
残った表で price が欠損	269 行

説明文がある 651 行では、メーカー欄の値がそろっている。価格は 269 行で空欄。本資料の文章化した例では、価格の空欄を nan と表示する。

[1] Database Group, Universität Leipzig. Abt-Buy.
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

補完する列を隠し、元の値を正解にする

- 元の表にある manufacturer または city の値を保存し、その列を手掛かりから外す。補完した値は、保存した元の値と比べられる。
- 学習用と評価用の行を分けて使う。同じ店の別レコードを同じ分割へまとめると、未知の店の属性を補えるかを調べられる。

[1] Database Group, Universität Leipzig. Abt-Buy.
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

[2] University of Texas at Austin. RIDDLE / Restaurant data.
https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

補完結果を確かめる

元の値の表記と、意味を確かめる

- 補完した値を元のセルと照合すると、どの行で値が復元できたかを確かめられる。表記をそのまま比べるか、大文字・小文字や空白をそろえるかを決めておく。
- メーカー欄の LACIE と、商品名の LaCie のように、表記が異なる場合がある。 Canon Camcorders のように、製品分野まで含む値もある。
- 都市の略記や地区名も、補完する値の範囲に関わる。元の表記と、どの場所や企業を指す値なのかを合わせて確認する。

[1] Database Group, Universität Leipzig. Abt-Buy.
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

[2] University of Texas at Austin. RIDDLE / Restaurant data.
https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

手掛かりと利用条件

商品名はメーカーの強い手掛かりになる

- Buy の商品名や説明には、 Sony や Canon などのメーカー名が現れる。文字列からメーカーを取り出せる行もあり、価格が空欄でも有用な手掛かりが残る。
- メーカー欄には、 Canon Camcorders や LG Electronics のような値も含む。短いブランド名、企業名、製品分野を含む名前など、その列で使う表し方を確かめる。

[1] Database Group, Universität Leipzig. Abt-Buy.
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

都市欄には、略記や地区名が混在する

- Restaurant には住所と電話番号があり、所在地を推定する手掛かりになる。 city 欄には、 los feliz のような地区名や la のような略記も入る。
- 補完結果を照合するときは、元の表記を保存する。略記を正式名へそろえて扱う場合は、 la と los angeles などの対応を明確にする。

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

言語モデルを追加学習して値を補う IPM

- Mei らは 2021 年、事前学習言語モデルで属性値の意味を捉え、欠損値を補う手法 IPM を提案した。 8 種類のデータを扱い、Buy の manufacturer と Restaurant の city も対象に含む。
- IPM-Multi は属性値を分類し、 IPM-Binary は候補値ごとの適否を判定する。利用時には、補完する属性と候補値、学習用データを用意して追加学習する。

[1] Mei et al. (2021). Capturing Semantics for Imputation with Pre-trained Language Models.
https://doi.org/10.1109/ICDE51399.2021.00013
[2] Yinan Mei et al. IPM 公式実装 .
https://github.com/EliasMei/IPM

入手元と利用条件を確認する

- Buy は Leipzig 大学の Abt-Buy 配布から取得でき、同ページは CC BY 4.0 を示す。商品同士を照合する用途では Abt 側や対応表も使い、ここでは Buy 側の属性を補う例を紹介した。
- Restaurant は UT Austin の公開アーカイブから取得できる。添付 README には独立した再配布ライセンスの表示がない。

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution
[2] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff).
https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

公開表から、答えのある補完問題を作れる

- Buy のメーカーと Restaurant の都市を、同じ行にある他の属性から補う例を示した。元の値を隠すことで、補完した値を確かめられる。
- 商品名や電話番号が手掛かりになる一方、メーカー名の表し方や都市の略記も扱う必要がある。元表の値と文脈を読み、利用目的に合う比較方法を選ぶ。

[1] Database Group, Universität Leipzig. Abt-Buy.
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

[2] University of Texas at Austin. RIDDLE / Restaurant data.
https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

Appendix

1. 追加の実例
2. 参考文献

実例 4 ：価格が欠けたノート PC 用スタンド

表の行を文章化した補完問題（全文）

name: Griffin Elevator Desktop Stand for Portable Laptops - 1093-CURV2. description: Aluminum. price: nan. manufacturer?

対応する日本語訳

商品名： Griffin Elevator ノート PC 用デスクトップスタンド – 1093-CURV2 。説明：アルミニウム。価格： nan 。メーカーは？

正解： Griffin

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例５：メーカー欄に企業名が入るテレビ

表の行を文章化した補完問題（全文）

name: LG LG70 Series 52LG70 52' LCD TV. description: LG 52LG70 - 52' Widescreen 1080p LCD HDTV - 120Hz - 15,000:1 Dynamic Contrast Ratio - 4ms Response Time. price: nan. manufacturer?

対応する日本語訳

商品名： LG LG70 シリーズ 52LG70 52 インチ液晶テレビ。説明： LG 52LG70 – 52 インチ・ワイド画面・ 1080p 液晶ハイビジョンテレビ – 120Hz – ダイナミックコントラスト比 15,000:1 – 応答時間 4ms 。価格： nan 。メーカーは？

正解： LG Electronics

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例 6 ：大文字と小文字の表記差

表の行を文章化した補完問題（全文）

name: LaCie Big Disk Extreme+ Hard Drive - 301199U. description: LaCie Big Disk Extreme 1TB Hard Drive - Triple Interface (USB 2.0 & FireWire 400/800) External Hard Drive. price: nan. manufacturer?

対応する日本語訳

商品名： LaCie Big Disk Extreme+ ハードドライブ – 301199U 。説明： LaCie Big Disk Extreme 1TB ハードドライブ – 3 種類の接続方式（ USB 2.0 、 FireWire 400/800 ）を備える外付けハードドライブ。価格： nan 。メーカーは？

正解： LACIE

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例 7 ：対応機器と、ケースのメーカー

表の行を文章化した補完問題（全文）

name: Speck Products SeeThru Case for Apple 13' MacBook - MB13-ORG-SEE-V2. description: Plastic - Orange. price: nan. manufacturer?

対応する日本語訳

商品名： Apple 13 インチ MacBook 用 Speck Products SeeThru ケース – MB13-ORG-SEE-V2 。説明：プラスチック – オレンジ色。価格： nan 。メーカーは？

正解： Speck Products

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例 8 ：都市欄には地区名も入る

表の行を文章化した補完問題（全文）

name: katsu. addr: 1972 hillhurst ave.. phone: 213-665-1891. type: japanese. city?

対応する日本語訳

店名： katsu 。住所： 1972 hillhurst ave. 。電話： 213-665-1891 。料理の種類：日本料理。都市は？

正解： los feliz

ロス・フェリズ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

実例 9 ：都市が la と略記されている

表の行を文章化した補完問題（全文）

name: cassell's. addr: 3266 w. sixth st.. phone: 213-480-8668. type: hamburgers. city?

対応する日本語訳

店名： cassell’s 。住所： 3266 w. sixth st. 。電話： 213-480-8668 。料理の種類：ハンバーガー。都市は？

正解： la

ロサンゼルスの略記

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

実例 10 ： city 欄が new york city の飲食店

表の行を文章化した補完問題（全文）

name: sylvia's. addr: 328 lenox ave.. phone: 212-996-0660. type: southern/soul. city?

対応する日本語訳

店名： sylvia’s 。住所： 328 lenox ave. 。電話： 212-996-0660 。料理の種類：米国南部料理／ソウルフード。都市は？

正解： new york city

ニューヨーク市

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

実例 11 ：大都市周辺の別の都市

表の行を文章化した補完問題（全文）

name: house of chan. addr: 2469 cobb pkwy.. phone: 770-955-9444. type: chinese. city?

対応する日本語訳

店名： house of chan 。住所： 2469 cobb pkwy. 。電話： 770-955-9444 。料理の種類：中国料理。都市は？

正解： smyrna

スマーナ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

実例 12 ：店名にも所在地が現れる

表の行を文章化した補完問題（全文）

name: morton's of chicago (las vegas). addr: 3200 las vegas blvd. s.. phone: 702-893-0703. type: steakhouses. city?

対応する日本語訳

店名： morton’s of chicago （ las vegas ）。住所： 3200 las vegas blvd. s. 。電話： 702-893-0703 。料理の種類：ステーキハウス。都市は？

正解： las vegas

ラスベガス

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

実例 13 ：サンタモニカのイタリア料理店

表の行を文章化した補完問題（全文）

name: remi. addr: 3rd st. promenade. phone: 310/393-6545. type: italian. city?

対応する日本語訳

店名： remi 。住所： 3rd st. promenade 。電話： 310/393-6545 。料理の種類：イタリア料理。都市は？

正解： santa monica

サンタモニカ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

参考文献

参考文献

Capturing Semantics for Imputation with Pre-trained Language Models

Yinan Mei, Shaoxu Song, Chenguang Fang, Haifeng Yang, Jingyun Fang, Jiang Long · 2021 · IEEE ICDE, 61–72

事前学習言語モデルで属性値の意味を捉える補完方法 IPM を提案する。

https://doi.org/10.1109/ICDE51399.2021.00013

IPM

Yinan Mei et al. (n.d.). 公式実装。 2026-10-18 参照。

IPM-Multi ・ IPM-Binary の学習コード、補完対象属性、実行例、欠損率 10% のサンプルを公開する。

https://github.com/EliasMei/IPM

参考文献

Benchmark Datasets for Entity Resolution

Database Group, Universität Leipzig (n.d.). 2026-10-18 参照。

Abt-Buy を含む照合用データと対応表、配布条件 CC BY 4.0 を掲載する。

https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

Restaurant data — RIDDLE

University of Texas at Austin (n.d.). 公開データアーカイブ。 2026-10-18 参照。

電話番号あり・なしの ARFF 、元の飲食店記録、由来を記した README を収録する。

https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

参考文献

Evaluation of entity resolution approaches on real-world match problems

H. Köpcke, A. Thor, E. Rahm · 2010 · Proceedings of the VLDB Endowment 3(1)

異なる出所のレコードを照合する方法の精度と効率を比較し、 Abt-Buy を含む実データの評価課題を公開した。

https://dbs.uni-leipzig.de/research/publications/evaluation-of-entity-resolution-approaches-on-real-world-match-problems

Holistic Evaluation of Language Models

Percy Liang et al. (2023). TMLR. 初稿 2022 。

Buy と Restaurant の属性値を言語モデルで補う課題を、 2022 年の初稿から記載する。

https://arxiv.org/abs/2211.09110