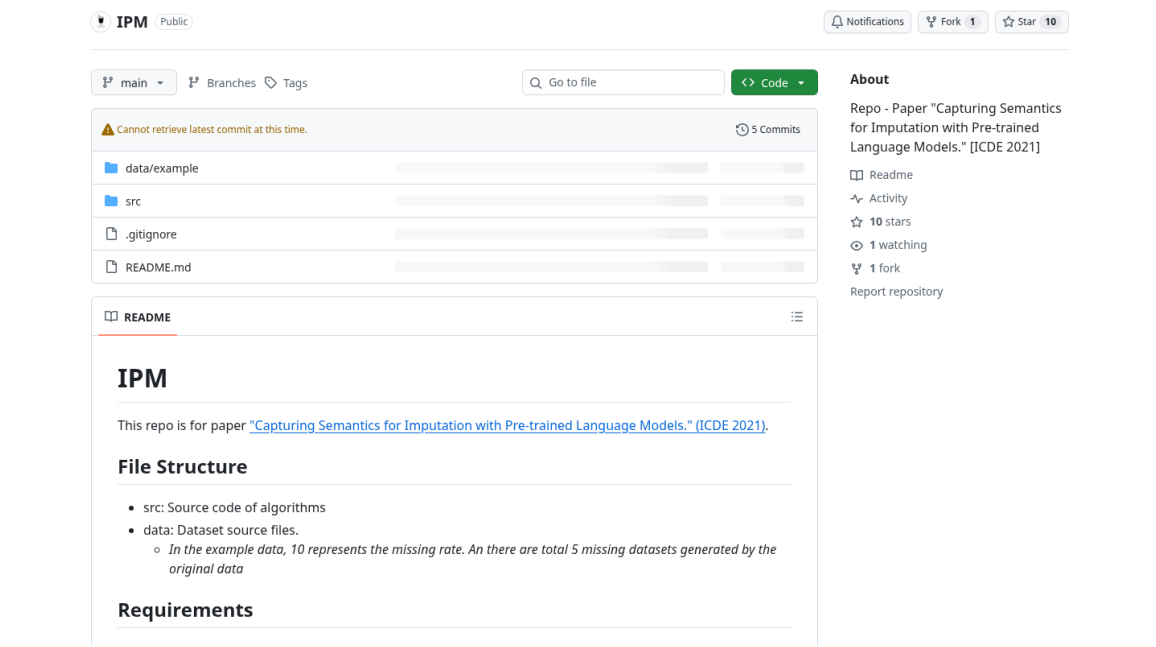
Data imputation

HELM ： Buy / Restaurant

表の属性から、隠したメーカーや都市を補う

sasakiy84

補完研究 IPM の公式実装



[1] Mei et al. (2021). Capturing Semantics for Imputation with Pre-trained Language Models — IPM 公式実装。 commit 583826e 。 https://github.com/EliasMei/IPM

1. 表の空欄を、一つの値で埋める
2. 二つの表と、欠損を作る手順
3. HELM の提示条件と採点
4. 何が得点を左右するか

表の空欄を、一つの値で埋める

一つの行から、隠した属性を復元する

- データ補完は、表の空欄を他の属性から埋める処理。 HELM の Data imputation では、値が分かっているセルを隠し、元の値を生成できるか測る。
- 対象は商品表 Buy と飲食店表 Restaurant 。メーカーと都市をそれぞれ補う。正解候補の一覧は付けず、残りの属性を文章に直して入力する。

[1] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

対象は、商品と飲食店の二つの表

HELM の表	隠す属性	手掛かりとして残す属性
Buy	manufacturer メーカー	name 、 description 、 price 商品名、説明、価格
Restaurant	city 都市	name 、 addr 、 phone 、 type 店名、住所、電話、料理の種類

以下の 13 例は、公開テスト 151 行から内容の違いが伝わるように選定。本編 3 例、 Appendix10 例。

[1] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

実例１：リモコンのメーカー

HELM 入力の原文全文

name: Sony Universal Remote Control - RM-EZ4. description: TV, Cable Box - Universal Remote. price: $12.72. manufacturer?

対応する日本語訳

商品名： Sony の汎用リモコン – RM-EZ4 。説明：テレビ、ケーブルテレビ受信機用 – 汎用リモコン。価格： $12.72 。メーカーは？

正解： Sony

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。 Buy.csv 行 435 / HELM test id587
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例２：住所と電話番号から都市を補う

HELM 入力の原文全文

name: kelly's on trinity. addr: 333 bush st.. phone: 415-362-4454. type: californian. city?

対応する日本語訳

店名： kelly’s on trinity 。住所： 333 bush st. 。電話： 415-362-4454 。料理の種類：カリフォルニア料理。都市は？

正解： san francisco

サンフランシスコ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

fz.arff 行 856 / HELM test id781

実例３：正解には製品分野まで含まれる

HELM 入力の原文全文

name: Canon VIXIA HF100 High Definition Digital Camcorder - 2708B001. description: Canon VIXIA HF100 High Definition Camcorder. price: $529.00. manufacturer?

対応する日本語訳

商品名： Canon VIXIA HF100 高精細デジタルビデオカメラ – 2708B001 。説明： Canon VIXIA HF100 高精細ビデオカメラ。価格： $529.00 。メーカーは？

正解： Canon Camcorders

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。 Buy.csv 行 508 / HELM test id586
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

同じ入力に対する、公開モデルの実出力

実例	元の正解	text-davinci-003	準完全一致
1 ：リモコン	Sony	Sony	1
2 ：飲食店	san francisco	san francisco	1
3 ：ビデオカメラ	Canon Camcorders	Canon	0

公開 test ・第 1 試行の出力から前後の空白を除いて表示。準完全一致の定義は後述する。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

二つの表と、欠損を作る手順

照合用の公開表を、補完課題へ転用した

- Buy は Abt-Buy の片側で、商品照合のために公開された表。HELM は Buy.csv だけを読み、 Abt.csv や商品間の対応表は入力に使わない。
- Restaurant は飲食店の照合用データ。 HELM は電話番号を含む fz.arff を読み、同じ店を示す class 列を取り除く。都市以外の 4 属性を入力に残す。

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution
[2] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

元の配布物と、 HELM で使う範囲

配布物	含まれるもの	HELM で読むもの
Abt-Buy.zip	Abt 1,081 行、 Buy 1,092 行 対応表 1,097 組	Buy.csv
restaurant.tar.gz	fz.arff 、 fz-nophone.arff 元の Fodor’s ・ Zagat’s 記録など	fz.arff 864 行

対応表の組数と、商品・飲食店の行数はそれぞれの単位で示す。

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution
[2] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

Buy は、説明文がある 651 行を残す

処理・残存欠損	件数
配布 Buy.csv	1,092 行
description が欠損した行を除外	441 行
補完課題に使う表	651 行
残った表で price が欠損	269 行

manufacturer の欠損は除外後 0 行。 price の欠損は文字列 nan として入力に残り、テスト 65 行中 33 行にも現れる。

[1] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

Restaurant は、引用符と前後の空白を除く

- fz.arff から 6 列を読み、識別用の class 列を除く。各値に残った二重引用符と前後の空白を削除し、欠損行を除く。今回の配布では 864 行が全て残る。
- 名前・住所・都市の表記は元データを保つ。例えば都市欄には new york と new york city 、 los angeles と la が別の文字列として含まれる。

[1] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

行を乱択し、学習・開発・テストへ分ける

表	学習	開発	テスト	合計
Buy	469	117	65	651
Restaurant	622	156	86	864

seed=1234 。全行から 10% を test 、残りから 20% を valid に抽出し、残りを train へ。 pandas.sample の丸めを含む実装の実測値。

[1] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

セル値は、改めて人手で付けた正解ではない

- 元の表にある manufacturer または city の値を保存し、その列を入力から外す。正解は、取り除いたセルの文字列。自然に発生した空欄へ新しい正解を注釈する手順ではない。
- 分割の単位は行。 Restaurant の class は分割条件に使われず、テスト 86 行中 17 行は同じ class の別行が学習表にもある。実際のプロンプトへは学習表から 5 例を選ぶ。

[1] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

HELM の提示条件と採点

5 例を示し、値の文字列を生成させる

- 標準条件は generation 。指示は“ What is the missing value?” 。正解付きの学習例を 5 件示し、対象行の末尾を manufacturer? または city? で終える。
- モデルは“ Answer:” に続く値を生成する。公開記録では、選んだ 3 モデルとも全テストで 5 例が入り、入力の切り詰めはなかった。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

実際の提示では、入力の後に答えが続く

text-davinci-003 ・第 1 試行： 5 学習例の後に続く、評価対象の末尾

name: Sony Universal Remote Control - RM-EZ4. description: TV, Cable Box - Universal Remote. price: $12.72. manufacturer? Answer:

実出力： Sony

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。 Buy / test id587 、プロンプト末尾を連続して引用。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

主指標は、表記を正規化した一致率

- quasi_exact_match （準完全一致）は、正解と出力を小文字化し、 ASCII 句読記号、英語の冠詞 a ・ an ・ the 、余分な空白を除いて比較する。テスト行ごとの 0 ／ 1 を平均する。
- 別名や地域の包含関係を解釈する採点ではない。 LACIE と LaCie は一致するが、 Canon Camcorders と Canon 、 la と los angeles は一致しない。

[1] Stanford CRFM. HELM v0.3.0, BasicMetric / normalize_text ・一致指標。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

テストの準完全一致率を表ごとに比較

モデル（公開年）	試行数	Buy 65 行	Restaurant 86 行
OPT-175B （2022）	3	85.13%	59.30%
text-davinci-003 （2022）	3	85.64%	82.17%
Llama 2 70B （2023）	1	86.15%	81.40%

HELM Classic v0.4.0 （2023-11-17）、 run suite v0.3.0 。 OPT と davinci は各試行の全行を採点した 3 試行平均。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

一致指標を変えると、得点も変わる

Restaurant ／試行平均	完全一致	準完全一致	前方一致
OPT-175B	59.30%	59.30%	88.76%
text-davinci-003	81.01%	82.17%	81.01%
Llama 2 70B	81.40%	81.40%	81.40%

前方一致は、出力が正解文字列から始まるかを測る。 OPT の実出力 new york city は、正解 new york に前方一致する（ id778 ・第 1 試行）。 4 指標を全出力から再計算し、公開値と一致した。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation
[2] Stanford CRFM. HELM v0.3.0, BasicMetric / normalize_text ・一致指標。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

何が得点を左右するか

商品名はメーカーの強い手掛かりになる

- Buy の入力には、 Sony や Canon などのメーカー名が商品名や説明に現れる。メーカーを単に抜き出せる行もあり、価格が nan でも推定できる。
- 一方、正解は元セルの表記。 Canon Camcorders や LG Electronics のように、よく知られた短いブランド名だけでは一致しない値も含む。

[1] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py
[2] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

都市欄には、略記や地区名が混在する

- Restaurant には住所と電話番号があり、所在地を推定する手掛かりになる。ただし正解の city 欄には、 los feliz のような地区名や la のような略記も入る。
- 同じ地域を指すつもりの出力でも、元のセルと異なる文字列なら不一致になる。追加例では、 new york city 、 smyrna などの実際の正解と予測を示す。

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz
[2] Stanford CRFM. HELM v0.3.0, BasicMetric / normalize_text ・一致指標。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

IPM と HELM では、回答の作り方が異なる

- Mei らの IPM は、事前学習言語モデルを補完に使う研究。 IPM-Multi は属性値を分類し、 IPM-Binary は候補値ごとの適否を判定する。公式実装はモデルを追加学習する。
- HELM は Buy と Restaurant を取り込み、 5 例を提示する共通の生成形式で比較する。 IPM の分類候補の選択と、 HELM の自由な文字列生成では、回答の作り方が異なる。

[1] Mei et al. (2021). Capturing Semantics for Imputation with Pre-trained Language Models — IPM 公式実装。 commit 583826e 。 https://github.com/EliasMei/IPM
[2] Liang et al. (2023). Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

入手元と利用条件を確認する

- Buy は Leipzig 大学の配布ページから取得でき、同ページは CC BY 4.0 を示す。元の Abt-Buy は照合用で、 HELM では Buy 側だけを使う。
- Restaurant は UT Austin の公開アーカイブから取得できる。添付 README には独立した再配布ライセンスの表示がない。この資料では出典を付けて選定した実例を引用する。

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution
[2] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

まとめ：空欄補完を、元セルとの一致で測る

- Buy のメーカーと Restaurant の都市を、同じ行の残りの属性から生成する。元表のセルを隠して正解を作り、行単位の固定分割で比較する。
- 入力に残る商品名や電話番号が手掛かりになる一方、メーカー名の粒度や都市の略記が一致率を左右する。公開値を読む際は、対象の表と一致指標を合わせる。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

Appendix

1. 追加の実例
2. 配布・実装・集計の補足
3. 参考文献

実例 4 ：価格が欠けたノート PC 用スタンド

HELM 入力の原文全文

name: Griffin Elevator Desktop Stand for Portable Laptops - 1093-CURV2. description: Aluminum. price: nan. manufacturer?

対応する日本語訳

商品名： Griffin Elevator ノート PC 用デスクトップスタンド – 1093-CURV2 。説明：アルミニウム。価格： nan 。メーカーは？

正解： Griffin

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。 Buy.csv 行 218 / HELM test id588
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例 5 ：ブランド名だけでは一致しない

HELM 入力の原文全文

name: LG LG70 Series 52LG70 52' LCD TV. description: LG 52LG70 - 52' Widescreen 1080p LCD HDTV - 120Hz - 15,000:1 Dynamic Contrast Ratio - 4ms Response Time. price: nan. manufacturer?

対応する日本語訳

商品名： LG LG70 シリーズ 52LG70 52 インチ液晶テレビ。説明： LG 52LG70 – 52 インチ・ワイド画面・ 1080p 液晶ハイビジョンテレビ – 120Hz – ダイナミックコントラスト比 15,000:1 – 応答時間 4ms 。価格： nan 。メーカーは？

正解： LG Electronics

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。 Buy.csv 行 901 / HELM test id589
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例 6 ：大文字と小文字の表記差

HELM 入力の原文全文

name: LaCie Big Disk Extreme+ Hard Drive - 301199U. description: LaCie Big Disk Extreme 1TB Hard Drive - Triple Interface (USB 2.0 & FireWire 400/800) External Hard Drive. price: nan. manufacturer?

対応する日本語訳

商品名： LaCie Big Disk Extreme+ ハードドライブ – 301199U 。説明： LaCie Big Disk Extreme 1TB ハードドライブ – 3 種類の接続方式（ USB 2.0 、 FireWire 400/800 ）を備える外付けハードドライブ。価格： nan 。メーカーは？

正解： LACIE

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。 Buy.csv 行 390 / HELM test id595
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例 7 ：対応機器と、ケースのメーカー

HELM 入力の原文全文

name: Speck Products SeeThru Case for Apple 13' MacBook - MB13-ORG-SEE-V2. description: Plastic - Orange. price: nan. manufacturer?

対応する日本語訳

商品名： Apple 13 インチ MacBook 用 Speck Products SeeThru ケース – MB13-ORG-SEE-V2 。説明：プラスチック – オレンジ色。価格： nan 。メーカーは？

正解： Speck Products

[1] Database Group, Universität Leipzig. Benchmark Datasets for Entity Resolution. CC BY 4.0 、 2026-10-18 取得。 Buy.csv 行 825 / HELM test id596
https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

実例 8 ：都市欄には地区名も入る

HELM 入力の原文全文

name: katsu. addr: 1972 hillhurst ave.. phone: 213-665-1891. type: japanese. city?

対応する日本語訳

店名： katsu 。住所： 1972 hillhurst ave. 。電話： 213-665-1891 。料理の種類：日本料理。都市は？

正解： los feliz

ロス・フェリズ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

fz.arff 行 33 / HELM test id780

実例 9 ：短縮表記 la を正解として保持する

HELM 入力の原文全文

name: cassell's. addr: 3266 w. sixth st.. phone: 213-480-8668. type: hamburgers. city?

対応する日本語訳

店名： cassell’s 。住所： 3266 w. sixth st. 。電話： 213-480-8668 。料理の種類：ハンバーガー。都市は？

正解： la

ロサンゼルスの略記

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

fz.arff 行 670 / HELM test id782

実例 10 ： new york と new york city の違い

HELM 入力の原文全文

name: sylvia's. addr: 328 lenox ave.. phone: 212-996-0660. type: southern/soul. city?

対応する日本語訳

店名： sylvia’s 。住所： 328 lenox ave. 。電話： 212-996-0660 。料理の種類：米国南部料理／ソウルフード。都市は？

正解： new york city

ニューヨーク市

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

fz.arff 行 767 / HELM test id793

実例 11 ：大都市周辺の別の都市

HELM 入力の原文全文

name: house of chan. addr: 2469 cobb pkwy.. phone: 770-955-9444. type: chinese. city?

対応する日本語訳

店名： house of chan 。住所： 2469 cobb pkwy. 。電話： 770-955-9444 。料理の種類：中国料理。都市は？

正解： smyrna

スマーナ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

fz.arff 行 819 / HELM test id796

実例 12 ：店名にも所在地が現れる

HELM 入力の原文全文

name: morton's of chicago (las vegas). addr: 3200 las vegas blvd. s.. phone: 702-893-0703. type: steakhouses. city?

対応する日本語訳

店名： morton’s of chicago （ las vegas ）。住所： 3200 las vegas blvd. s. 。電話： 702-893-0703 。料理の種類：ステーキハウス。都市は？

正解： las vegas

ラスベガス

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

fz.arff 行 790 / HELM test id789

実例 13 ：サンタモニカのイタリア料理店

HELM 入力の原文全文

name: remi. addr: 3rd st. promenade. phone: 310/393-6545. type: italian. city?

対応する日本語訳

店名： remi 。住所： 3rd st. promenade 。電話： 310/393-6545 。料理の種類：イタリア料理。都市は？

正解： santa monica

サンタモニカ

[1] University of Texas at Austin. RIDDLE / Restaurant data (fz.arff). 2026-10-18 取得。 https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

fz.arff 行 283 / HELM test id804

追加例で見る、正解と実際の生成文字列

実例	正解	davinci-003 ／第 1 試行
4	Griffin	Griffin
5	LG Electronics	LG
6	LACIE	LaCie
7	Speck Products	Speck Products

実例 6 は完全一致 0 、準完全一致 1 。実例 5 は両指標とも 0 。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

都市名・略記・地区名の一致を確かめる

実例	正解	davinci-003 ／第 1 試行
8	los feliz	los angeles
9	la	los angeles
10	new york city	new york
11	smyrna	atlanta
12 ・ 13	las vegas ／ santa monica	las vegas ／ santa monica

表示した 8 〜 11 の出力は全て準完全一致 0 。 12 ・ 13 はそれぞれ 1 。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

配布・実装・集計の補足

公開実行の生成設定と、実送信値

項目	3 モデル共通の設定	全テストの実送信値
学習例数	5	5
max_tokens	5	5
num_outputs ／ completions	1	1
温度／停止列	0 ／改行	0 ／改行

出力は一つ。各モデルでトークナイザが異なり、 5 トークンの生成上限が掛かる。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

HELM 本文の件数と、実装・公開入力の差

表	HELM 論文	実装・公開入力
Buy	470 ／ 118 ／ 66	469 ／ 117 ／ 65
Restaurant	623 ／ 157 ／ 87	622 ／ 156 ／ 86

各欄は学習／開発／テスト。再取得した元配布、固定 v0.3.0 コード、 3 モデルの公開入力は右列と一致。本文には 2 表を説明しながら「 3 datasets 」とする箇所もある。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110
[2] Stanford CRFM. HELM v0.3.0, EntityDataImputationScenario. 2026-10-18 取得。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

IPM の 8 データのうち、 HELM は 2 表を使う

データ名	公式 README で指定する補完属性
walmart ／ amazon	category 、 brand
restaurant ／ buy	city ／ manufacturer
housing	region 、 price 、 sqfeet 、 beds 、 baths ほか
phone ／ zomato ／ flipkart	brand ／ location ／ brand

[1] Mei et al. (2021). Capturing Semantics for Imputation with Pre-trained Language Models — IPM 公式実装。 commit 583826e 。
https://github.com/EliasMei/IPM

13 実例を、配布行と公開記録へ結び付けた

- 各例に元ファイル名、行位置、 HELM の ID 、入力全文、元セルの正解、日本語訳、公開出力を保存した。元の行とファイルの SHA-256 も記録した。
- 3 モデルでは、 Buy の開発 117 行・テスト 65 行と、 Restaurant の開発 156 行・テスト 86 行を全件照合した。テストの全 1,057 出力を使い、 4 種類の一致指標を再計算した。

[1] Stanford CRFM. HELM Classic v0.4.0, Data imputation. 2023-11-17 の固定版。 2026-10-18 参照。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

参考文献

参考文献

Capturing Semantics for Imputation with Pre-trained Language Models

Yinan Mei, Shaoxu Song, Chenguang Fang, Haifeng Yang, Jingyun Fang, Jiang Long · 2021 · IEEE ICDE, 61–72

事前学習言語モデルで属性値の意味を捉える補完方法 IPM を提案する。

https://doi.org/10.1109/ICDE51399.2021.00013

IPM

Yinan Mei et al.· 公式実装 · commit 583826e41205c04a4854867394521318108553 6c

IPM-Multi ・ IPM-Binary の学習コード、補完対象属性、実行例、欠損率 10% のサンプルを公開する。

https://github.com/EliasMei/IPM

参考文献

Benchmark Datasets for Entity Resolution

Database Group, Universität Leipzig · 2026-10-18 参照

Abt-Buy を含む照合用データと対応表、配布条件 CC BY 4.0 を掲載する。

https://dbs.uni-leipzig.de/research/projects/benchmark-datasets-for-entity-resolution

Restaurant data — RIDDLE

University of Texas at Austin · 公開データアーカイブ · 2026-10-18 取得

電話番号あり・なしの ARFF 、元の飲食店記録、由来を記した README を収録する。

https://www.cs.utexas.edu/users/ml/riddle/data/restaurant.tar.gz

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · Transactions on Machine Learning Research

構造化データの補完を含む多様な課題を、共通の提示方法と指標で評価する。

https://arxiv.org/abs/2211.09110

HELM Classic — Data imputation

Stanford CRFM · v0.4.0 （2023-11-17） · 2026-10-18 参照

Buy と Restaurant のモデル別成績、実行条件、実際の予測記録を保存する。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_data_imputation

参考文献

EntityDataImputationScenario

Stanford CRFM · HELM v0.3.0 · Python 実装

表の読込、欠損行の選別、分割、属性列の文章化、正解文字列の取得を実装する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_data_imputation_scenario.py

BasicMetric — text matching metrics

Stanford CRFM · HELM v0.3.0 · Python 実装

小文字化・句読記号・冠詞・空白の正規化と、完全一致・前方一致の採点を定義する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

参考文献

Evaluation of entity resolution approaches on real-world match problems

H. Köpcke, A. Thor, E. Rahm · 2010 · Proceedings of the VLDB Endowment 3(1)

異なる出所のレコードを照合する方法の精度と効率を比較し、 Abt-Buy を含む実データの評価課題を公開した。

https://dbs.uni-leipzig.de/research/publications/evaluation-of-entity-resolution-approaches-on-real-world-match-problems