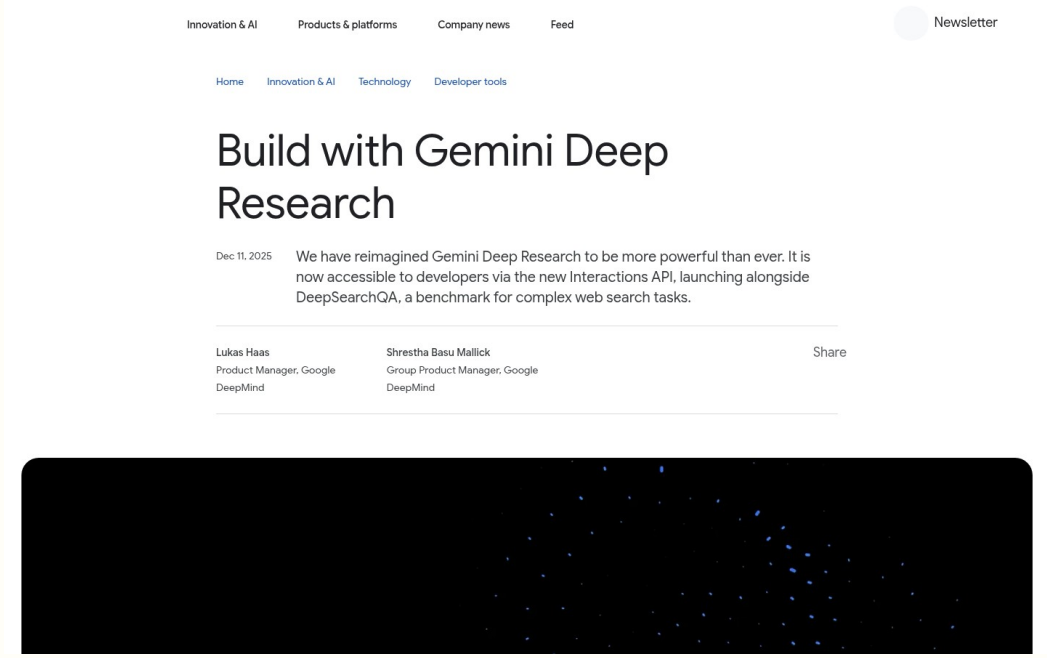
DeepSearchQA

検索エージェントの回答の正確さと網羅性を測る

sasakiy84

1. 課題と三つの実例
2. 構築方法とデータの広がり
3. 採点方法とモデルの成績
4. 検索エージェントの評価での利用

DeepSearchQA の公式公開案内



[1] Haas & Mallick (2025), Build with Gemini Deep Research. https://blog.google/technology/developers/deep-research-agent-gemini-api/

1. 課題と三つの実例

一つの事実から、条件に合う回答の集合へ

- DeepSearchQA は、ウェブを調べる AI エージェント向けの 900 問のベンチマーク。 Google DeepMind が 2025 年 12 月に公開した。
- 複数の資料をたどり、条件に合う名前や地域、年などを答える。答えが複数ある問題では、正しい項目を漏れなく集め、余分な項目を除く必要がある。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

質問と参照回答を対応させて読む

- 入力は英語の質問。対象の年、情報源、人数や数値の条件などが書かれている。エージェントは検索やページの閲覧を通じて回答をまとめる。
- 公開データには質問、分野、参照回答、回答形式がある。以下の実例は、その公開 900 問から選んだもの。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

例 1 三州に共通する人気の名前

質問の原文（全文）

> According to the Social Security Administration, what are the identical names that show up in the top five boy's names of 1975 for the states of Maine, Texas, and California?

質問の日本語訳

米国社会保障局（ SSA ）による 1975 年の男の子の名前の人気順位で、メイン州、テキサス州、カリフォルニア州のすべてで 5 位以内に入っている名前は何か。

参照回答： Michael 、 Christopher 、 Jason

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] SSA (2026-10-25 参照), Popular Baby Names. https://www.ssa.gov/oact/babynames/limits.html

三州で人気の名前の上位 5 件を照合する

州	1975 年の男の子の名前・上位 5 件
メイン	Jason, Michael, Christopher, Matthew, Robert
テキサス	Michael, Christopher, Jason, David, James
カリフォルニア	Michael, Jason, David, Christopher, Robert

三つの一覧に共通するのは Michael 、 Christopher 、 Jason 。

[1] SSA (2026-10-25 参照), Popular Baby Names. https://www.ssa.gov/oact/babynames/limits.html

例 2 三つの巻すべてに登場する著者

質問の原文（全文）

Could you please provide a complete list of authors who published at least one article in each of the first three volumes (Volumes 1, 2, and 3) of the Journal of Machine Learning Research?

質問の日本語訳

機械学習の学術誌 Journal of Machine Learning Research の最初の 3 巻（第 1 ・ 2 ・ 3 巻）のそれぞれに、少なくとも 1 本の論文を発表した著者を全員挙げてほしい。

参照回答： Robert C. Williamson 、 Yoram Singer 、 David Maxwell Chickering

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] JMLR (2026-10-25 参照), Published Papers. https://jmlr.org/papers/

例 3 二つの条件を満たす洪水の年

質問の原文（全文）

I'm researching extreme weather in the United States. Between 2017 and 2021 (inclusive), which year saw flood-related fatalities in over 20 states, with over 100 total deaths (with all states combined)? This includes both flash flooding and river flooding. Use National Weather Service and NOAA data.

質問の日本語訳

米国の極端な気象を調べている。 2017 年から 2021 年までのうち、洪水による死者が出た州が 20 を超え、全州の死者数が合計 100 人を超えた年はいつか。鉄砲水と河川の氾濫をともに含め、米国国立気象局（ NWS ）と米国海洋大気庁（ NOAA ）のデータを用いる。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

例 3 二つの条件を満たす洪水の年：回答と二つの条件

参照回答： 2021 年

年	死者が出た州の数	死者数（人）
2017	18	136
2018	23	80
2019	24	92
2020	18	57
2021	22	146

2021 年は 22 州で計 146 人。 2017 年は計 136 人だが 18 州。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] NWS / NOAA (2026-10-25 参照), U.S. Natural Hazard Statistics (2017–2021). https://www.weather.gov/hazstat/

2. 構築方法とデータの広がり

専門の作業者が質問を作り、別の三人が調べる

- 現実の調査に近く、客観的に答えを確かめられる質問を作る。質問には、参照する年や情報源を指定するものが多い。
- 別の３人の確認者が参照回答を見ずに調べ、その結果を作成者の回答と照合する。不一致を解決し、解釈が曖昧な質問を除いた。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

約 3 分の 2 が、複数項目を答える問題

回答形式	設問数	割合（%）
Set Answer （回答の集合）	584	64.9
Single Answer （単一の回答）	316	35.1
合計	900	100.0

公開 CSV の 900 行を回答形式ごとに集計した。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

政治・経済などの分野に多くの質問がある

分野	設問数
政治・行政	148
金融・経済	132
地理	95
教育	94
健康	92
科学	90

全 17 分野。言語学は 1 問、生物学は 2 問など、分野ごとの件数には差がある。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

資料を集め、同じ対象をまとめ、探索を終える

- 資料の収集では、複数のサイトや文書に分散した情報を集める。検索で得た候補に、年や数値などの条件を当てはめる。
- 同じ人物や団体の表記の違いを整理し、重複を除く。候補を広げるだけでなく、条件を満たす対象を調べ切ったか判断することも課題になる。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

3. 採点方法とモデルの成績

正確さと、答えを集め切った度合いを測る

- 適合率（ Precision ）は、提出した項目のうち正しかった割合。再現率（ Recall ）は、参照回答の項目をどれだけ見つけたかを表す。
- F1 は、この二つの調和平均。各設問について計算し、有効な採点結果の F1 を平均する。回答の表記が違っても、同じ対象を指していれば一致と判定できる。

[1] Wang (2026-10-25 参照), DeepSearchQA Starter Code. https://www.kaggle.com/code/andrewmingwang/deepsearchqa-starter-code

三つの正解を使って、 F1 の違いを見る

回答例	適合率	再現率	F1
正解 3 名すべて	1	1	1
正解 2 名だけ	1	2/3	0.80
正解 3 名＋誤答 1 名	3/4	1	0.86
正解 1 名＋誤答 1 名	1/2	1/3	0.40

例 1 の参照回答 3 名を使った採点の説明例。 F1 = 2PR / (P + R) 。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

完全正解は、漏れも余分な答えもない回答

分類	参照回答との関係
完全正解	正しい項目をすべて含み、余分な項目がない
一部正解	正しい項目を含むが、一部が欠ける
正解と余分な答え	正しい項目をすべて含むが、誤答も含む
すべて不正解	正しい項目を一つも含まない

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

自動採点は、回答の意味を項目ごとに照合する

- 公式の採点方法では、 Gemini 2.5 Flash が質問、参照回答、提出回答を読み、正解の各項目が含まれるかと、余分な項目を判定する。
- その判定から適合率、再現率、 F1 と回答の分類を求める。公式スターターは、採点に失敗した例などを別に数えて集約する。

[1] Wang (2026-10-25 参照), DeepSearchQA Starter Code. https://www.kaggle.com/code/andrewmingwang/deepsearchqa-starter-code

公開時は、 F1 と完全正解率に差があった

モデル・エージェント	F1 （%）	完全正解（%）
Gemini Deep Research Agent	81.90	66.09
GPT-5 Pro High Reasoning	78.98	65.18
Gemini 3 Pro Preview	76.86	56.56
Claude 4.5 Opus	40.20	24.01

2025 年 12 月公開時の実験。 Kaggle が独立に評価した報告値。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

Kimi K3 の公式評価にも採用された

- Moonshot AI の 2026 年の Kimi K3 モデルカードは、検索を使う課題の一つとして DeepSearchQA を掲載している。
- Kimi K3 の F1 は 95.0% 。推論の設定は max 。質問に合う回答集合を調べる力の評価に、公開後も使われている。

[1] Moonshot AI (2026), Kimi K3 Model Card. https://huggingface.co/moonshotai/Kimi-K3

ウェブの変化と、探索過程を採点しない制約

- 参照する年や資料を指定した質問でも、検索先のサイトが削除・更新されると、同じ情報を取り出せなくなることがある。
- 採点が見るのは最終的な回答の集合。どの資料を調べ、どの段階で条件を見落としたかは、探索の記録を別に調べる必要がある。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

4. 検索エージェントの評価での利用

同じ質問に対する回答と、検索の設定をそろえる

- ウェブ検索を使うモデルや、複数回の検索・閲覧を繰り返すエージェントを評価する。使うツール、探索の予算、モデルの設定を結果に対応させる。
- 公開時の実験では最終回答を Kaggle が評価した。その後もモデルカードや検索サービスの評価に採用されている。入手した問題の年や情報源の指定を保って比較する。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

公開 CSV から、質問と参照回答を確認できる

- Google DeepMind の公式配布は 900 問の CSV 。約 0.36 MB で、質問、分野、参照回答、回答形式の 4 列を持つ。
- ライセンスは Apache License 2.0 。回答を生成するときは質問を入力し、参照回答と回答形式は採点用に保持する。公式スターターには採点のプロンプトと集計コードがある。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

複数の条件を満たす答えを、過不足なく集める

- DeepSearchQA は、 900 問・ 17 分野の公開質問を通じて、検索エージェントが複数の資料を結び付け、条件に合う答えを集める力を測る。
- 回答集合の正確さと網羅性を F1 で評価し、漏れも余分な答えもない完全正解率も示す。検索を早く終えすぎる問題と、候補を広げすぎる問題の両方を捉える。

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

Appendix

1. 異なる分野の追加例
2. 分野の内訳と周辺の課題
3. 参考文献

1. 異なる分野の追加例

例 4 二つの説明ページをつなぐ

質問の原文（全文）

By using the NHS website for “Shoulder Pain”, which of the possible causes of the condition creates symptoms like poor balance and coordination?

質問の日本語訳

英国の公的医療サービス（ NHS ）の「 Shoulder Pain 」のページを使い、肩の痛みの原因として挙げられているもののうち、バランスや動作の協調がうまくできないといった症状を伴うのはどれか。

参照回答： Hypermobility （関節の過可動性）

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] NHS (2026-10-25 参照), Joint hypermobility syndrome. https://www.nhs.uk/conditions/joint-hypermobility-syndrome/

例 5 運送会社の営業費用の減少

質問の原文（全文）

> Among Saia, Inc., Matson, Inc., and ArcBest Corporation, which company had the greatest reduction in operating expenses for the fiscal year ended December 31, 2023? Use the SEC website and filings.

質問の日本語訳

Saia, Inc.、 Matson, Inc.、 ArcBest Corporation のうち、 2023 年 12 月 31 日を期末とする会計年度に営業費用が最も大きく減少した会社はどれか。 SEC のウェブサイトと提出書類を用いる。

参照回答： ArcBest Corporation

営業費用の減少額は ArcBest 約 3.80 億ドル、 Matson 約 2.38 億ドル。 Saia は増加。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] ArcBest (2024), 2023 Form 10-K. https://www.sec.gov/Archives/edgar/data/894405/000155837024001622/arcb-20231231x10k.htm

例 6 共著者から授業の担当者を探す

質問の原文（全文）

Which of Isabelle Darcy's (2012) coauthors on the article "Direct Mapping of Acoustics to Phonology: On the Lexical Encoding of Front Rounded Vowels in L1 English-- L2 French acquisition" has taught courses on both the German language and constructed languages at Indiana University-Bloomington?

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

例 6 共著者から授業の担当者を探す：日本語訳と回答

質問の日本語訳

Isabelle Darcy の 2012 年の論文「 Direct Mapping of Acoustics to Phonology: On the Lexical Encoding of Front Rounded Vowels in L1 English-- L2 French acquisition 」の共著者のうち、インディアナ大学ブルーミントン校でドイツ語と人工言語の両方の授業を担当したことがあるのは誰か。

参照回答： John H.G. Scott

論文の共著者を確認してから、各人の担当授業を調べる。「人工言語」は、人が意図的に設計した言語を指す。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] John H.G. Scott (2026-10-25 参照), Teaching. https://www.johnhgscott.com/teaching.html

例 7 首都以外の都市で開かれた万博

質問の原文（全文）

Consider all European cities that have ever hosted a World Expo (up to and including 2020) according to the Bureau International des Expositions (not Specialized Expos) but are not the capital of their respective country. List the year of the most recent World Expo hosted by each of those cities that are on the Iberian Peninsula.

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

例 7 首都以外の都市で開かれた万博：日本語訳と回答

質問の日本語訳

国際博覧会事務局（ BIE ）による 2020 年までの World Expo の開催都市から、その国の首都ではないヨーロッパの都市を考える。イベリア半島にある該当都市について、それぞれで最も最近開かれた World Expo の開催年を挙げよ。 Specialized Expo は含めない。

参照回答： 1929 年、 1992 年

該当する開催都市はバルセロナとセビリア。 World Expo と Specialized Expo の区分を確認し、開催年と都市を対応させる。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] BIE (2026-10-25 参照), All World Expos. https://www.bie-paris.org/site/en/all-world-expos

例 8 画材と描かれた場所で絞る作品

質問の原文（全文）

Which of Georgia O’Keeffe's works at the Art Institute of Chicago, as of June 2024, were landscapes of New Mexico created before 1940 with oil painting?

質問の日本語訳

2024 年 6 月時点のシカゴ美術館の所蔵品のうち、 Georgia O’Keeffe が 1940 年より前に制作した、ニューメキシコの風景を描いた油彩作品はどれか。

参照回答： Red Hills with Flowers （1937 年）
Black Cross, New Mexico （1929 年）

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] Art Institute of Chicago (2026-10-25 参照), Collection. https://www.artic.edu/collection

例 9 二人分の身長を比較する

質問の原文（全文）

> Which combined height is greater? Those of the two tallest players on the 2022-2023 Lehman College basketball team, or their counterparts on the 2023-2024?

質問の日本語訳

レーマン・カレッジのバスケットボールチームで、 2022–2023 シーズンの身長が高い上位 2 人と、 2023–2024 シーズンの上位 2 人では、身長の合計はどちらが大きいか。

参照回答： 2023–2024 シーズンの上位 2 人

上位 2 人の身長の合計は、 2022–2023 が 156 インチ、 2023–2024 が 158 インチ。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] Lehman College Athletics (2023), 2023-24 Men’s Basketball Roster. https://lehmanathletics.com/sports/mens-basketball/roster/2023-24

例 10 二つの賞に共通する受賞者

質問の原文（全文）

> Who has won a Ripple of Hope Award before the year 2017 and has also won a Nobel Prize before the year 2010?

質問の日本語訳

2017 年より前に Ripple of Hope Award を受賞し、かつ 2010 年より前にノーベル賞を受賞した人は誰か。

参照回答： Al Gore 、 Muhammad Yunus 、 Desmond Tutu

二つの賞の受賞者一覧と受賞年を照合する。該当する 3 人のノーベル平和賞は、それぞれ 2007 年、 2006 年、 1984 年だった。

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] RFK Human Rights (2026-10-25 参照), Ripple of Hope Awards. https://rfkhumanrights.org/our-programs/ripple-of-hope-awards/

例 11 肩書と研究歴から編集者を探す

質問の原文（全文）

Who is the Associate Editor of the SBL Study Bible who is a graduate of the University of Chicago, who teaches at a public university in Florida, and who co-authored an article on the Qumran manuscripts in 2014 with Dennis Duke?

質問の日本語訳

SBL Study Bible の編集委員（ Associate Editor ）のうち、シカゴ大学の卒業生で、フロリダ州の公立大学で教え、 2014 年に Dennis Duke とクムラン文書に関する論文を共著したのは誰か。

参照回答： Matthew Goff

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] Florida State University (2026-10-25 参照), Matthew Goff. https://religion.fsu.edu/person/matthew-goff

例 12 同じ執筆者の最初の記事を探す

質問の原文（全文）

Look at the Smithsonian Libraries and Archives official blog titled “Unbound”. Among the September 2023 posts is an article titled "Exploring Yellowstone in 1919". What was the title of the first Unbound blog post written by the author of "Exploring Yellowstone in 1919"?

質問の日本語訳

スミソニアン図書館・文書館の公式ブログ「Unbound」の 2023 年 9 月の記事に「Exploring Yellowstone in 1919」がある。その執筆者が Unbound で最初に書いた記事の題名は何か。

参照回答： Chocolate Rabbits and...Elephants!

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] Smithsonian Libraries and Archives (2026-10-25 参照), Unbound. https://blog.library.si.edu/

例 13 受験率と平均点で州を選ぶ

質問の原文（全文）

Determine which states had an ACT participation rate of 50% or higher for the graduating class of 2023 and received an average composite score of 20 or above. What percentage of each state's students met the science benchmark?

質問の日本語訳

2023 年の高校卒業者について、米国の大学進学適性試験 ACT の受験率が 50% 以上、平均総合点が 20 点以上だった州を特定せよ。それぞれの州で、 ACT 受験者のうち理科の到達基準を満たしたのは何 % だったか。

参照回答：ミネソタ州 41% 、サウスダコタ州 41%

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa
[2] ACT (2023), Average ACT Scores by State. https://www.act.org/content/dam/act/unsecured/documents/2023-Average-ACT-Scores-by-State.pdf

2. 分野の内訳と周辺の課題

公開 900 問の分野別内訳（ 1/3 ）

配布データの分野名	日本語	設問数
Politics & Government	政治・行政	148
Finance & Economics	金融・経済	132
Geography	地理	95
Education	教育	94
Health	健康	92
Science	科学	90

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

公開 900 問の分野別内訳（ 2/3 ）

配布データの分野名	日本語	設問数
Other	その他	65
History	歴史	44
Travel	旅行	36
Media & Entertainment	メディア・娯楽	29
Arts	芸術	26
Technology	技術	22

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

公開 900 問の分野別内訳（ 3/3 ）

配布データの分野名	日本語	設問数
Sports	スポーツ	20
Current Events	時事	3
Biology	生物学	2
Linguistics	言語学	1
Arts & Entertainment	芸術・娯楽	1

[1] Google DeepMind (2026-10-25 参照), DeepSearchQA. https://huggingface.co/datasets/google/deepsearchqa

単一の答えを探す課題から、回答集合の評価へ

対象	中心となる課題
SimpleQA Verified	短い質問に対する、一つの事実の正確さ
BrowseComp	見つけにくい事実を探す、単一回答の検索
DeepSearchQA	条件に合う回答の集合を集め、その過不足を採点

[1] Gupta et al. (2026), DeepSearchQA. https://arxiv.org/abs/2601.20975

3. 参考文献

参考文献

DeepSearchQA: Bridging the Comprehensiveness Gap for Deep Research Agents

Nikita Gupta et al. (2026), arXiv:2601.20975.

900 問の構築、複数項目の採点方法、公開時の実験を報告する。

https://arxiv.org/abs/2601.20975

Build with Gemini Deep Research

Lukas Haas & Shrestha Basu Mallick (2025), The Keyword / Google.

Gemini Deep Research とともに、 DeepSearchQA の公開を紹介する。

https://blog.google/technology/developers/deep-research-agent-gemini-api/

参考文献

DeepSearchQA

Google DeepMind (n.d.; 2026-10-25 参照), Hugging Face. Apache License 2.0.

質問、分野、参照回答、回答形式を含む 900 問の CSV を配布する。

https://huggingface.co/datasets/google/deepsearchqa

DeepSearchQA Starter Code

Andrew Wang (n.d.; 2026-10-25 参照), Kaggle.

意味の一致と余分な回答を判定し、設問ごとの指標を集約する。

https://www.kaggle.com/code/andrewmingwang/deepsearchqa-starter-code

参考文献

DeepSearchQA Leaderboard

Google / Kaggle (n.d.; 2026-10-25 参照).

完全正解率、すべて不正解の割合、余分な回答、 F1 を掲載する。

https://www.kaggle.com/benchmarks/google/dsqa/leaderboard

Kimi K3 Model Card

Moonshot AI (2026), Hugging Face.

2026 年のモデル比較と、 DeepSearchQA の F1 を掲載する。

https://huggingface.co/moonshotai/Kimi-K3