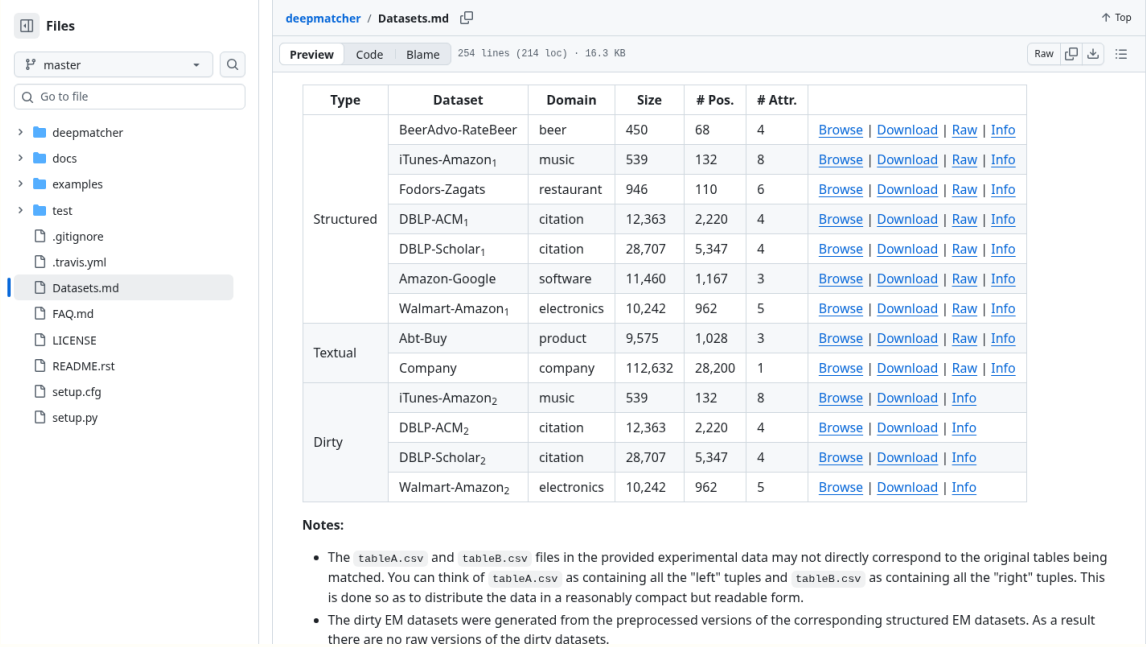
DeepMatcher

二つの記録が同じ実体を指すか

構造化・文章・属性を移したデータで比べる

sasakiy84

DeepMatcher が公開するデーター一覧



Type	Dataset	Domain	Size	# Pos.	# Attr.	
Structured	BeerAdvo-RateBeer	beer	450	68	4	Browse | Download | Raw | Info
	iTunes-Amazon$_1$	music	539	132	8	Browse | Download | Raw | Info
	Fodors-Zagats	restaurant	946	110	6	Browse | Download | Raw | Info
	DBLP-ACM$_1$	citation	12,363	2,220	4	Browse | Download | Raw | Info
	DBLP-Scholar$_1$	citation	28,707	5,347	4	Browse | Download | Raw | Info
	Amazon-Google	software	11,460	1,167	3	Browse | Download | Raw | Info
	Walmart-Amazon$_1$	electronics	10,242	962	5	Browse | Download | Raw | Info
Textual	Abt-Buy	product	9,575	1,028	3	Browse | Download | Raw | Info
	Company	company	112,632	28,200	1	Browse | Download | Raw | Info
Dirty	iTunes-Amazon$_2$	music	539	132	8	Browse | Download | Info
	DBLP-ACM$_2$	citation	12,363	2,220	4	Browse | Download | Info
	DBLP-Scholar$_2$	citation	28,707	5,347	4	Browse | Download | Info
	Walmart-Amazon$_2$	electronics	10,242	962	5	Browse | Download | Info

Notes:

- The `tableA.csv` and `tableB.csv` files in the provided experimental data may not directly correspond to the original tables being matched. You can think of `tableA.csv` as containing all the "left" tuples and `tableB.csv` as containing all the "right" tuples. This is done so as to distribute the data in a reasonably compact but readable form.
- The dirty EM datasets were generated from the preprocessed versions of the corresponding structured EM datasets. As a result there are no raw versions of the dirty datasets.

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

1. 二つの記録が同じものを指すか
2. 三種類のデータと候補ペア
3. 同じ実体を見つける精度を測る
4. データの入手と使い方

二つの記録が同じものを指すか

二つの記録が、同じ実体を指すか

- 二つのレコードが同じ実体を指すかを判定する。対象は商品、楽曲、飲食店、論文、企業など。
- 各ペアには、同じ実体を指すかという二値のラベルが付く。本資料では、同じなら Yes 、別なら No と表示する。
- 同じ実体でも、名称や属性の表記が異なる。省略、価格差、空欄、別の欄へ移った情報も手掛かりになる。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

候補を探した後のペアを判定する

- 名寄せでは、まず比較する候補を絞る処理（ blocking ）を行い、その後で候補ペアを判定する。
- このデータでは、あらかじめ絞った候補ペアに、同じ実体なら 1 、別なら 0 の正解を付けている。
- 元表の ID から二つのレコードを取り出し、その属性を合わせて読むことで判定する。

[1] DeepMatcher authors. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 1 ： Amber Waves の度数差

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Amber Waves Ale. Brew_Factory_Name: Capitol City Brewing. Style: American Amber / Red Ale. ABV: 5.40 %. Product B is Beer_Name: Capitol City Amber Waves Ale. Brew_Factory_Name: Capitol City Brewing Company. Style: Amber Ale. ABV: 5.60 %. Are A and B the same?

日本語訳

A の商品：ビール名は Amber Waves Ale 。醸造所は Capitol City Brewing 。スタイルはアメリカン・アンバー／レッドエール。アルコール度数は 5.40% 。 B の商品：ビール名は Capitol City Amber Waves Ale 。醸造所は Capitol City Brewing Company 。スタイルはアンバーエール。アルコール度数は 5.60% 。A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

表記や一部の数値が違っても、同じビールを指す

- 醸造所名に Company が加わり、度数にも差があるが、正解ラベルは同じビールを示す。
- A の名称 Amber Waves Ale に対し、 B は醸造所名を含む Capitol City Amber Waves Ale 。スタイルの表し方も異なる。
- 名称、醸造所、スタイルなどを合わせて読む。すべての属性が完全に一致している必要はない。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例２：同じ Sony シリーズでも容量が違う

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: sony 1gb memory stick pro duo mark 2 media card msmt1g. description: sony 1gb memory stick pro duo mark 2 media card msmt1g 160 mbps transfer speed 940mb actual capacity. price: 19.0. Product B is name: sony 8gb memory stick pro duo card msmt8g. description: 8 gb. price: 49.85. Are A and B the same?

日本語訳

A の商品：名称は Sony 1GB Memory Stick PRO Duo Mark 2 メディアカード、型番 msmt1g 。説明は、同じ名称と型番、転送速度 160Mbps 、実容量 940MB 。価格は 19.0 。 B の商品：名称は Sony 8GB Memory Stick PRO Duo カード、型番 msmt8g 。説明は 8GB 。価格は 49.85 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

型番と容量が、似た商品を分ける

- ブランドやシリーズの一致だけでは足りない。 1GB と 8GB 、型番の末尾も異なる。
- このデータでは、製品の説明が長い文章として残る。名称と説明の両方を読み、同じシリーズ内の別製品を区別する。
- 本資料の文章化した例では、 price や description の空欄を nan と表す。

[1] DeepMatcher authors. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例３：別の欄へ移動した曲の情報

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Illusion (feat . Echosmith) Zedd True Colors Dance , Music , Electronic $ 1.29 2015 Interscope Records 6:30. Artist_Name: nan. Album_Name: nan. Genre: nan. Price: nan. CopyRight: nan. Time: nan. Released: 18-May-15. Product B is Song_Name: Illusion [feat . Echosmith] True Colors $ 1.29 (C) 2015 Interscope Records 6:25. Artist_Name: Zedd. Album_Name: nan. Genre: Dance & Electronic. Price: nan. CopyRight: nan. Time: nan. Released: May 18 , 2015. Are A and B the same?

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例３：別の欄へ移動した曲の情報（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Illusion （ Echosmith 参加） Zedd True Colors ダンス、音楽、エレクトロニック $1.29 2015 Interscope Records 6:30 」。アーティスト、アルバム、ジャンル、価格、著作権、時間の各欄は nan 。発売日は 18-May-15 。
B の商品：曲名欄は「 Illusion ［ Echosmith 参加］ True Colors $1.29 (C) 2015 Interscope Records 6:25 」。アーティストは Zedd 。アルバムは nan 。ジャンルはダンス＆エレクトロニック。価格、著作権、時間の各欄は nan 。発売日は May 18, 2015 。
A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

Dirty は、属性値を別の欄へ移したデータ

- 曲名以外の各属性値を、同じレコードの曲名欄へ 50% の確率で移す。移動した元の欄は空欄になる。
- 曲名欄にアーティスト、アルバム、ジャンル、価格、時間が混在する。列名だけで比較する方法には難しい配置になる。
- 時間は 6:30 と 6:25 。欠測欄があっても、移動先の曲名欄に情報が残っている。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

三種類のデータと候補ペア

研究の 23 課題から、 13 設定を公開した

- 2018 年の研究は、構造化 11 、文章 6 、 Dirty 6 の計 23 課題で、教師ありの照合手法を比較した。
- 公式一覧は、そのうち構造化 7 、文章 2 、 Dirty 4 の計 13 設定を公開する。
- 本資料は Beer 、 Abt-Buy 、 Dirty iTunes-Amazon の 3 対象を例に、各形式で照合するときの手掛かりを見る。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926
[2] DeepMatcher authors. Datasets for DeepMatcher paper. https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

候補ペアに、同じか別かの正解を付ける

- Beer は 2015 年秋の UW–Madison の授業で、 BeerAdvocate と RateBeer から集めた情報を表にまとめた。比較候補を絞り、無作為に選んだ候補へ、同じか別かを人手で注釈した。
- iTunes-Amazon も同じ手順。 Abt-Buy などは、既存の正解対応を使い、候補集合内の一致を正例、それ以外を負例にした。
- ペアを train 、 validation 、 test へ 3:1:1 で分割する。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

配布のペア数と、正例の数

対象	train	valid	test
Beer	268 / 40	91 / 14	91 / 14
Abt_Buy	5,743 / 616	1,916 / 206	1,916 / 206
Dirty_iTunes_Amazon	321 / 78	109 / 27	109 / 27

各セルは全ペア数／同じ実体を指す正例数。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

元表の規模と、比較に使う属性

対象	表 A の行	表 B の行	属性数
Beer	4,345	3,000	4
Abt_Buy	1,081	1,092	3
Dirty_iTunes_Amazon	6,907	55,923	8

表 A と表 B の規模。ラベルは、これらの表から選ばれた候補ペアに付いている。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

空欄でも、情報が別の欄に残ることがある

- Abt-Buy の表 B は 1,092 行。そのうち description は 441 行、price は 502 行が空欄。表 A の price も 1,081 行中 663 行が空欄である。
- Dirty iTunes-Amazon の表 B は 55,923 行。 Artist_Name の 27,950 行が空欄だが、値が Song_Name へ移動している場合がある。
- 本資料の入力例では空欄を nan と表示する。 Beer の度数欄の「 - 」は、文字として記録されている。

[1] DeepMatcher authors. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

同じ実体を見つける精度を測る

同じ実体のペアに、適合率と再現率を使う

- 同じだと判定したペアのうち、実際に同じだった割合が適合率。実際に同じペアのうち、見つけられた割合が再現率である。
- F1 は、この二つの調和平均。見つけたペアの正確さと、見逃しの少なさをまとめる。
- 別の実体を指すペアが多いので、全体の正解率だけでなく、同じペアをどれだけ拾えたかも見る。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926

2018 年の教師あり評価は、正例の F1

対象	Hybrid	Magellan
Beer	72.7	78.8
Abt-Buy	47.7	33.0
Dirty iTunes-Amazon	74.5	46.8

2018 年の教師あり学習での F1 （％）。学習・開発・テストを 3:1:1 へ分割。実例で扱う 3 対象の値。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926

学習・開発・テストの役割を分けて使う

- train で照合モデルを学習し、 validation で調整、 test で最後の性能を測る。
- 分割は候補ペア単位。同じ商品や楽曲が、別の相手とのペアとして複数の分割へ現れる場合がある。
- 未知の実体だけへの性能を調べるときは、元表の ID を使って分割を設計する。

[1] DeepMatcher authors. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

データの入手と使い方

公式一覧から、元表と候補ペアを入手する

- DeepMatcher の公式一覧から、二つの元表とラベル付き候補ペアをまとめた ZIP を取得できる。
- ZIP には、元表の tableA.csv ・ tableB.csv と、 train.csv ・ valid.csv ・ test.csv の候補ペアが含まれる。ペアの左右の ID を使い、対応する元レコードを取り出せる。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

コードのライセンスと元データの条件

- DeepMatcher のコードは BSD 3-Clause で公開されている。
- データは BeerAdvocate 、 RateBeer 、商品サイト、楽曲販売サイトなどに由来する。公開 Datasets.md と取得 ZIP には、全データ共通の独立したライセンス文を確認できなかった。
- 再配布や業務利用には、元データと取得時点の利用条件を確認する。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md
[2] Mudgal & Li. DeepMatcher LICENSE （ BSD 3-Clause 、コード） .
https://github.com/anhaidgroup/deepmatcher/blob/master/LICENSE

表記差を読み、同じ実体かを答える

- Entity Matching は、候補ペアの二レコードを同じ実体へ対応付ける課題。 DeepMatcher は構造化、文章、属性移動という違いを比較するデータを公開した。
- 元表と候補ペアが分かれているので、同じペアと正解を使って、異なる照合手法を比べられる。
- 型番や容量が違う負例、表記や一部属性が食い違う正例を含め、文字列の重なりだけでは決まらない照合を評価できる。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926
[2] DeepMatcher authors. Datasets for DeepMatcher paper. https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

Appendix

1. 追加の実例
2. 収録データと読み込み方
3. 研究と参考文献

追加の実例

実例 4 ： Easy を共有する別のビール

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Easy Amber Ale. Brew_Factory_Name: Scottsdale Beer Company. Style: American Amber / Red Ale. ABV: 5.70 %. Product B is Beer_Name: Upland Easy Chair Amber Ale. Brew_Factory_Name: Upland Brewing Company. Style: Amber Ale. ABV: 5.60 %. Are A and B the same?

日本語訳

A の商品：ビール名は Easy Amber Ale 。醸造所は Scottsdale Beer Company 。スタイルはアメリカン・アンバー／レッドエール。度数は 5.70% 。 B の商品：ビール名は Upland Easy Chair Amber Ale 。醸造所は Upland Brewing Company 。スタイルはアンバーエール。度数は 5.60% 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例５：度数が欠けても同じ銘柄

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Centurion Barleywine Ale. Brew_Factory_Name: Golden City Brewery. Style: American Barleywine. ABV: -. Product B is Beer_Name: Golden City Centurion Barleywine Ale. Brew_Factory_Name: Golden City Brewery. Style: Barley Wine. ABV: 11.20 %. Are A and B the same?

日本語訳

A の商品：ビール名は Centurion Barleywine Ale 。醸造所は Golden City Brewery 。スタイルはアメリカン・バーレーワイン。度数は「 - 」。 B の商品：ビール名は Golden City Centurion Barleywine Ale 。醸造所は Golden City Brewery 。スタイルはバーレーワイン。度数は 11.20% 。 A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 6 ： Organic と Non-Organic の違い

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Green Lakes Organic Ale. Brew_Factory_Name: Deschutes Brewery. Style: American Amber / Red Ale. ABV: 5.20 %. Product B is Beer_Name: Deschutes Green Lakes Non-Organic Ale. Brew_Factory_Name: Deschutes Brewery. Style: Amber Ale. ABV: 6.40 %. Are A and B the same?

日本語訳

A の商品：ビール名は Green Lakes Organic Ale 。醸造所は Deschutes Brewery 。スタイルはアメリカン・アンバー／レッドエール。度数は 5.20% 。 B の商品：ビール名は Deschutes Green Lakes Non-Organic Ale 。醸造所は Deschutes Brewery 。スタイルはアンバーエール。度数は 6.40% 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 7 ：型番が一致する充電器

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: canon battery charger 1133b001. description: canon battery charger 1133b001 compatible with canon nb-5l lithium battery black finish. price: nan. Product B is name: canon cb-2lx battery charger 1133b001. description: nan. price: nan. Are A and B the same?

日本語訳

A の商品：名称は Canon バッテリー充電器 1133b001 。説明は、 Canon バッテリー充電器 1133b001 、Canon NB-5L リチウム電池に対応、黒仕上げ。価格は nan 。 B の商品：名称は Canon CB-2LX バッテリー充電器 1133b001 。説明と価格は nan 。 A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 8 ：対応機種が一部共通するインク

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: canon photo ink cartridge cl52. description: canon photo ink cartridge cl52 compatible with pixma ip6210d and ip6220d printers. price: 25.0. Product B is name: canon ink cartridge for pixma ip1600 , ip6210d and ip6220d printers 0617b002. description: color. price: 19.11. Are A and B the same?

日本語訳

A の商品：名称は Canon 写真用インクカートリッジ CL52 。説明は、同製品が PIXMA iP6210D と iP6220D に対応すること。価格は 25.0 。 B の商品：名称は Canon PIXMA iP1600 、 iP6210D 、 iP6220D プリンター用インクカートリッジ 0617b002 。説明はカラー。価格は 19.11 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例９：価格が少し異なる電気ケトル

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: cuisinart cordless electric kettle kua17. description: cuisinart cordless electric kettle kua17 1-3/4 quart capacity automatic shut-off indicator light splash guard spout cord storage in base chrome finish. price: 70.0. Product B is name: cuisinart cordless automatic electric kettle. description: nan. price: 69.95. Are A and B the same?

日本語訳

A の商品：名称は Cuisinart コードレス電気ケトル KUA17 。説明は同名称と型番、容量 1 と 3/4 クォート、自動電源オフ、表示灯、飛び散り防止の注ぎ口、台座にコード収納、クローム仕上げ。価格は 70.0 。B の商品：名称は Cuisinart コードレス自動電気ケトル。説明は nan 。価格は 69.95 。 A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 10 ：セットと単体の違い

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: garmin suction cup mount and 12-volt adapter kit 0101097900. description: garmin suction cup mount and 12-volt adapter kit 0101097900 suction cup mount and 12-volt adapter included. price: 30.0. Product B is name: garmin suction cup mount 010-10823-00. description: nan. price: 24.84. Are A and B the same?

日本語訳

A の商品：名称は Garmin 吸盤マウントと 12V アダプターのキット 0101097900 。説明は同名称と型番、吸盤マウントと 12V アダプターを含むこと。価格は 30.0 。 B の商品：名称は Garmin 吸盤マウント 010-10823-00 。説明は nan 。価格は 24.84 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 11 ：同じ曲名のカラオケ版

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Bad Blood (Karaoke Version) Taylor Swift Pop , Music $ 1.29 3:29. Artist_Name: nan. Album_Name: Taylor Swift Karaoke : 1989. Genre: nan. Price: nan. CopyRight: ‰ ãÑ 2014 Big Machine Records , LLC. Time: nan. Released: 3-Mar-15. Product B is Song_Name: Bad Blood Taylor Swift Pop 3:31 October 27 , 2014. Artist_Name: nan. Album_Name: 1989. Genre: nan. Price: $ 1.29. CopyRight: (C) 2014 Big Machine Records , LLC .. Time: nan. Released: nan. Are A and B the same?

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 11 ：同じ曲名のカラオケ版（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Bad Blood （カラオケ版） Taylor Swift ポップ、音楽 $1.29 3:29 」。アーティストは nan 。アルバムは Taylor Swift Karaoke: 1989 。ジャンルと価格は nan 。著作権欄は「‰ ãÑ 2014 Big Machine Records, LLC 」。時間は nan 。発売日は 3-Mar-15 。
B の商品：曲名欄は「 Bad Blood Taylor Swift ポップ 3:31 October 27, 2014 」。アーティストは nan 。アルバムは 1989 。ジャンルは nan 。価格は $1.29 。著作権欄は「 (C) 2014 Big Machine Records, LLC 」。時間と発売日は nan 。
A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 12 ：同じアルバムの異なる曲

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Illusion (feat . Echosmith) True Colors 2015 Interscope Records 6:30. Artist_Name: Zedd. Album_Name: nan. Genre: Dance , Music , Electronic. Price: $ 1.29. CopyRight: nan. Time: nan. Released: 18-May-15. Product B is Song_Name: Papercut [feat . Troye Sivan] Zedd Dance & Electronic 7:23. Artist_Name: nan. Album_Name: True Colors. Genre: nan. Price: $ 1.29. CopyRight: (C) 2015 Interscope Records. Time: nan. Released: May 18 , 2015. Are A and B the same?

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 12 ：同じアルバムの異なる曲（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Illusion （ Echosmith 参加） True Colors 2015 Interscope Records 6:30 」。アーティストは Zedd 。アルバムは nan 。ジャンルはダンス、音楽、エレクトロニック。価格は $1.29 。著作権と時間は nan 。発売日は 18-May-15 。
B の商品：曲名欄は「 Papercut ［ Troye Sivan 参加］ Zedd ダンス＆エレクトロニック 7:23 」。アーティストは nan 。アルバムは True Colors 。ジャンルは nan 。価格は $1.29 。著作権は (C) 2015 Interscope Records 。時間は nan 。発売日は May 18, 2015 。
A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 13 ：年の表記が異なる同じ曲

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Billy Keith Urban In the Ranch Country , Music , Honky Tonk , Contemporary Country 3:46. Artist_Name: nan. Album_Name: nan. Genre: nan. Price: $ 1.29. CopyRight: 1997 Capitol Nashville. Time: nan. Released: 1997. Product B is Song_Name: Billy Country (c) 1997 Capitol Nashville February 10 , 2004. Artist_Name: Keith Urban. Album_Name: Keith Urban In The Ranch. Genre: nan. Price: $ 1.29. CopyRight: nan. Time: 3:46. Released: nan. Are A and B the same?

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 13 ：年の表記が異なる同じ曲（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Billy Keith Urban In the Ranch カントリー、音楽、ホンキートンク、現代カントリー 3:46 」。アーティスト、アルバム、ジャンルは nan 。価格は $1.29 。著作権は 1997 Capitol Nashville 。時間は nan 。発売年は 1997 。
B の商品：曲名欄は「 Billy カントリー (c) 1997 Capitol Nashville February 10, 2004 」。アーティストは Keith Urban 。アルバムは Keith Urban In The Ranch 。ジャンルは nan 。価格は $1.29 。著作権は nan 。時間は 3:46 。発売日は nan 。
A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

収録データと読み込み方

構造化された 7 種類のデータ

対象	ペア数	正例数	属性
BeerAdvo-RateBeer	450	68	4
iTunes-Amazon	539	132	8
Fodors-Zagats	946	110	6
DBLP-ACM	12,363	2,220	4
DBLP-Scholar	28,707	5,347	4
Amazon-Google	11,460	1,167	3
Walmart-Amazon	10,242	962	5

構造化データでは、各属性が決まった列に整理されている。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

文章 2 種類と、属性を移した 4 種類

対象	ペア数	正例数	属性
Abt-Buy	9,575	1,028	3
Company	112,632	28,200	1
iTunes-Amazon	539	132	8
DBLP-ACM	12,363	2,220	4
DBLP-Scholar	28,707	5,347	4
Walmart-Amazon	10,242	962	5

上 2 行が文章、下 4 行が Dirty 。公開一覧の値。

[1] Mudgal & Li et al. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

候補ペアを読み、二つの元レコードを取り出す

```
import pandas as pd
a = pd.read_csv("tableA.csv").set_index("id")
b = pd.read_csv("tableB.csv").set_index("id")
pairs = pd.read_csv("test.csv")
pair = pairs.iloc[0]
print(a.loc[pair["ltable_id"]])
print(b.loc[pair["rtable_id"]])
print("正解:", "Yes" if pair["label"] else "No")
```

Beer の ZIP を展開し、 exp_data フォルダで実行する。 test.csv の左右の ID で元表を引き、二つの記録と同一／別の正解を表示する。

[1] DeepMatcher authors. Datasets for DeepMatcher paper.
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

研究と参考文献

文章や属性の乱れで、深層学習の強みを調べた

- Mudgal 、 Li らは 2018 年、データの構造や属性の乱れが、照合手法の性能にどう関わるかを 23 課題で比較した。
- DeepMatcher の深層モデルは、属性の文章から特徴を学ぶ。比較した Magellan は、人が設計した特徴量を使う手法である。
- 構造化データでは深層学習の優位が限られ、長い文章や、属性を別の欄へ移した Dirty データでは改善が報告された。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926

参考文献

Deep Learning for Entity Matching: A Design Space Exploration

Sidharth Mudgal, Han Li, Theodoros Rekatsinas, AnHai Doan, Youngchoon Park, Ganesh Krishnan, Rohit Deep, Esteban Arcaute & Vijay Raghavendra. 2018. SIGMOD.

23 課題を用い、データの構造と属性の乱れによる照合手法の違いを分析する。

https://doi.org/10.1145/3183713.3196926

Datasets for DeepMatcher paper

DeepMatcher authors. (n.d.). GitHub. 2026-10-18 参照。

公開 13 設定の規模、候補生成、ラベル付け、 Dirty 変換と配布先を記載する。

https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

参考文献

DeepMatcher

DeepMatcher authors (n.d.). 公式リポジトリ。 2026-10-18 参照。

照合モデルの学習・評価コードと、公開データの一覧や利用例を提供する。

https://github.com/anhaidgroup/deepmatcher

DeepMatcher LICENSE

DeepMatcher authors (n.d.). BSD 3-Clause 。 2026-10-18 参照。

実装コードの再利用・再配布に必要な著作権表示などの条件を示す。

https://github.com/anhaidgroup/deepmatcher/blob/master/LICENSE