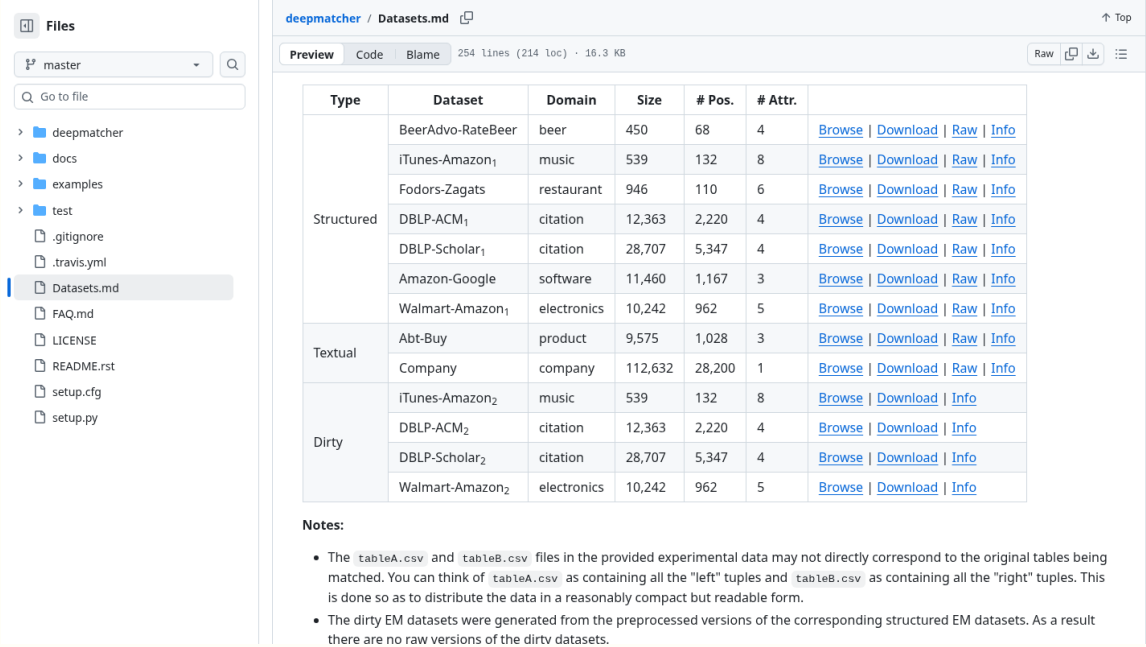
Entity Matching

レコードの同一実体判定

DeepMatcher のデータと HELM Classic での評価

sasakiy84

DeepMatcher が公開するデーター一覧



Type	Dataset	Domain	Size	# Pos.	# Attr.	
Structured	BeerAdvo-RateBeer	beer	450	68	4	Browse | Download | Raw | Info
	iTunes-Amazon$_1$	music	539	132	8	Browse | Download | Raw | Info
	Fodors-Zagats	restaurant	946	110	6	Browse | Download | Raw | Info
	DBLP-ACM$_1$	citation	12,363	2,220	4	Browse | Download | Raw | Info
	DBLP-Scholar$_1$	citation	28,707	5,347	4	Browse | Download | Raw | Info
	Amazon-Google	software	11,460	1,167	3	Browse | Download | Raw | Info
	Walmart-Amazon$_1$	electronics	10,242	962	5	Browse | Download | Raw | Info
Textual	Abt-Buy	product	9,575	1,028	3	Browse | Download | Raw | Info
	Company	company	112,632	28,200	1	Browse | Download | Raw | Info
Dirty	iTunes-Amazon$_2$	music	539	132	8	Browse | Download | Info
	DBLP-ACM$_2$	citation	12,363	2,220	4	Browse | Download | Info
	DBLP-Scholar$_2$	citation	28,707	5,347	4	Browse | Download | Info
	Walmart-Amazon$_2$	electronics	10,242	962	5	Browse | Download | Info

Notes:

- The `tableA.csv` and `tableB.csv` files in the provided experimental data may not directly correspond to the original tables being matched. You can think of `tableA.csv` as containing all the "left" tuples and `tableB.csv` as containing all the "right" tuples. This is done so as to distribute the data in a reasonably compact but readable form.
- The dirty EM datasets were generated from the preprocessed versions of the corresponding structured EM datasets. As a result there are no raw versions of the dirty datasets.

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

1. 二つの記録が同じものを指すか
2. 三種類のデータと候補ペア
3. 正解率と実行条件
4. 入手方法と評価の使い方

二つの記録が同じものを指すか

二つの記録が、同じ実体を指すか

- 二つのレコードが同じ実体を指すかを判定する。対象は商品、楽曲、飲食店、論文、企業など。
- 入力は二つのレコードの属性。出力は、同一なら Yes 、別なら No という二値の回答である。
- 同じ実体でも、名称や属性の表記が異なる。省略、価格差、欠測、別の欄へ移った情報も手掛かりになる。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

候補を探した後のペアを判定する

- 一般の名寄せでは、まず比較候補を絞る blocking を行い、その後で候補ペアを判定する。
- このデータには、候補生成後の二レコードと、同一かどうかのラベルがある。 HELM は与えられた各ペアに答える。
- 表全体の全組合せを探索する処理は、ここで採点する範囲には含まれない。

[1] Stanford CRFM. EntityMatchingScenario. HELM v0.3.0.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario.py

実例 1 ： Amber Waves の度数差

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Amber Waves Ale. Brew_Factory_Name: Capitol City Brewing. Style: American Amber / Red Ale. ABV: 5.40 %. Product B is Beer_Name: Capitol City Amber Waves Ale. Brew_Factory_Name: Capitol City Brewing Company. Style: Amber Ale. ABV: 5.60 %. Are A and B the same?

日本語訳

A の商品：ビール名は Amber Waves Ale 。醸造所は Capitol City Brewing 。スタイルはアメリカン・アンバー／レッドエール。アルコール度数は 5.40% 。 B の商品：ビール名は Capitol City Amber Waves Ale 。醸造所は Capitol City Brewing Company 。スタイルはアンバーエール。アルコール度数は 5.60% 。A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Beer test pair row 29 （0 始まり）、 A=563 / B=1177 。 https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

一致する名前と、食い違う度数を読む

- 醸造所名に Company が加わり、度数にも差があるが、配布ラベルは同じビール。
- A の名称 Amber Waves Ale に対し、 B は醸造所名を含む Capitol City Amber Waves Ale 。スタイルの粒度も異なる。
- 正解は配布されたペアのラベルを使う。実例では、同じ商品をすべての属性の完全一致で定義していない。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例２：同じ Sony シリーズでも容量が違う

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: sony 1gb memory stick pro duo mark 2 media card msmt1g. description: sony 1gb memory stick pro duo mark 2 media card msmt1g 160 mbps transfer speed 940mb actual capacity. price: 19.0. Product B is name: sony 8gb memory stick pro duo card msmt8g. description: 8 gb. price: 49.85. Are A and B the same?

日本語訳

A の商品：名称は Sony 1GB Memory Stick PRO Duo Mark 2 メディアカード、型番 msmt1g 。説明は、同じ名称と型番、転送速度 160Mbps 、実容量 940MB 。価格は 19.0 。 B の商品：名称は Sony 8GB Memory Stick PRO Duo カード、型番 msmt8g 。説明は 8GB 。価格は 49.85 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Abt_Buy test pair row 1849 （0 始まり）、 A=658 / B=669 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

型番と容量が、似た商品を分ける

- ブランドやシリーズの一致だけでは足りない。 1GB と 8GB 、型番の末尾も異なる。
- このデータでは、製品の説明が長い文章として残る。名称と説明の両方を読み、同じシリーズ内の別製品を区別する。
- price や description の空欄は、 HELM の文字列では nan として現れる。

[1] Stanford CRFM. EntityMatchingScenario. HELM v0.3.0.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario.py

実例３：別の欄へ移動した曲の情報

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Illusion (feat . Echosmith) Zedd True Colors Dance , Music , Electronic $ 1.29 2015 Interscope Records 6:30. Artist_Name: nan. Album_Name: nan. Genre: nan. Price: nan. CopyRight: nan. Time: nan. Released: 18-May-15. Product B is Song_Name: Illusion [feat . Echosmith] True Colors $ 1.29 (C) 2015 Interscope Records 6:25. Artist_Name: Zedd. Album_Name: nan. Genre: Dance & Electronic. Price: nan. CopyRight: nan. Time: nan. Released: May 18 , 2015. Are A and B the same?

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 43 （0 始まり）、A=1413 / B=51590 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例３：別の欄へ移動した曲の情報（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Illusion （ Echosmith 参加） Zedd True Colors ダンス、音楽、エレクトロニック $1.29 2015 Interscope Records 6:30 」。アーティスト、アルバム、ジャンル、価格、著作権、時間の各欄は nan 。発売日は 18-May-15 。
B の商品：曲名欄は「 Illusion ［ Echosmith 参加］ True Colors $1.29 (C) 2015 Interscope Records 6:25 」。アーティストは Zedd 。アルバムは nan 。ジャンルはダンス＆エレクトロニック。価格、著作権、時間の各欄は nan 。発売日は May 18, 2015 。
A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 43 （ 0 始まり）、 A=1413 / B=51590 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

Dirty は、属性値を別の欄へ移したデータ

- 曲名以外の各属性値を、同じレコードの曲名欄へ 50% の確率で移す。移動した元の欄は空欄になる。
- 曲名欄にアーティスト、アルバム、ジャンル、価格、時間が混在する。列名だけで比較する方法には難しい配置になる。
- 時間は 6:30 と 6:25 。欠測欄があっても、移動先の曲名欄に情報が残っている。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

三種類のデータと候補ペア

研究 23 課題、公開 13 設定、 HELM 実行 3 対象

- 2018 年の研究は、構造化 11 、文章 6 、 Dirty 6 の計 23 課題で、教師ありの照合手法を比較した。
- DeepMatcher の公開一覧と HELM の実装は 13 設定。公開一覧は構造化 7 、文章 2 、 Dirty 4 である。
- 固定 Classic 版の 201 実行は Beer 、 Abt-Buy 、 Dirty iTunes-Amazon の 3 対象。各対象に 67 モデル設定がある。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926
[2] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

候補ペアに、人手や既存正解を付ける

- Beer は 2015 年秋の UW–Madison 授業で、 BeerAdvocate と RateBeer を収集し、表へ抽出、候補生成、候補の無作為標本への同一／別の注釈を行った。
- iTunes-Amazon も同じ手順。 Abt-Buy などは、既存の正解対応を使い、候補集合内の一致を正例、それ以外を負例にした。
- ペアを train 、 validation 、 test へ 3:1:1 で分割する。作業者数や一致率は、ここで用いた公開説明に記載がない。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

配布のペア数と、正例の数

対象	train	valid	test
Beer	268 / 40	91 / 14	91 / 14
Abt_Buy	5,743 / 616	1,916 / 206	1,916 / 206
Dirty_iTunes_Amazon	321 / 78	109 / 27	109 / 27

各セルは全ペア数 / 正例数。元の配布 CSV を全件集計。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

学習プールだけ、正負を同数へそろえる

- 学習ペアの正例と負例を同数にする。 HELM は負例を正例数まで間引き、正例も同数抽出する。
- 元の train から、 Beer は 80 、 Abt-Buy は 1,232 、 Dirty iTunes-Amazon は 156 ペアになる。この中から提示例を選ぶ。
- valid と test の正負比は変更しない。同じ片側レコードが分割間で再登場するため、未知の実体だけで評価する分割ではない。

[1] Stanford CRFM. EntityMatchingScenario. HELM v0.3.0.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario.py

二つの表と、ラベル付き候補は別の件数

対象	表 A の行	表 B の行	属性数
Beer	4,345	3,000	4
Abt_Buy	1,081	1,092	3
Dirty_iTunes_Amazon	6,907	55,923	8

表 A/B は配布 tableA.csv と tableB.csv の実測行数。候補ペア数は分割表に示す。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

空欄と、別の欄へ移った値を区別する

- Abt-Buy の表 B は 1,092 行。そのうち description は 441 行、price は 502 行が空欄。表 A の price も 1,081 行中 663 行が空欄である。
- Dirty iTunes-Amazon の表 B は 55,923 行。 Artist_Name の 27,950 行が空欄だが、値が Song_Name へ移動している場合がある。
- pandas で読み込んだ空欄は nan になる。 Beer の度数欄の「 - 」は文字列として保持され、空欄とは扱いが異なる。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md
[2] Stanford CRFM. EntityMatchingScenario. HELM v0.3.0.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario.py

正解率と実行条件

正解率： Yes か No が参照と一致するか

- HELM は、生成した回答と配布ラベルの文字列を比較する。ここでは大文字小文字、句読点、空白を正規化する quasi exact match を示す。
- 9 実行の全保存出力を再採点したところ、 Yes/No 以外の回答はなく、 exact match と prefix 系の値も一致した。
- test 内のペアごとの 0/1 を平均し、 OPT と davinci は 3 試行を等重み平均する。 Llama 2 は 1 試行である。

[1] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

公開 HELM 実行の test 正解率

モデル	Beer	Abt-Buy	Dirty 音楽
OPT-175B	34.07%	35.84%	42.20%
text-davinci-003	90.48%	92.02%	96.64%
Llama 2 70B	92.31%	71.20%	55.96%

OPT / davinci は 3 試行、 Llama 2 は 1 試行。各試行の test は 91 / 493 / 109 ペア。

[1] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

常に No と答えた場合との比較

対象	test 正例 / 全体	常に No
Beer	14 / 91	84.62%
Abt_Buy	62 / 493	87.42%
Dirty_iTunes_Amazon	27 / 109	75.23%

正例が少ない集合では、常に No と答えても正解率が高くなる。

[1] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

OPT は提示例の試行ごとに挙動が変わる

対象	試行 0	試行 1	試行 2
Beer	70.33%	15.38%	16.48%
Abt_Buy	81.95%	12.58%	12.98%
Dirty_iTunes_Amazon	77.06%	24.77%	24.77%

試行 1 は 3 対象とも全ペアへ Yes と回答。温度は 0 だが、提示する学習例が試行間で異なる。

[1] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

2018 年の教師あり評価は、正例の F1

対象	Hybrid	Magellan
Beer	72.7	78.8
Abt-Buy	47.7	33.0
Dirty iTunes-Amazon	74.5	46.8

ペアを 3:1:1 に分割して学習・調整・ test 。正例の適合率と再現率の調和平均（％）。 HELM の正解率とは指標・学習条件が異なる。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926

公開保存実行で確認した条件

- 9 実行すべてで、実際の提示例は 5 件、温度 0 、出力上限 5 トークン、生成 1 件、改行で停止する設定だった。入力の切り詰めは 0 件。
- valid と test を合わせて最大 1,000 ペアを評価する。 Beer と Dirty 音楽は全 valid/test 、 Abt-Buy は valid 507 と test 493 ペアを評価した。
- Abt-Buy の配布 test は 1,916 ペア。成績表の 493 ペアはその部分集合で、 3 モデル間では入力と正解が一致した。

[1] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

入手方法と評価の使い方

配布一覧から、実装のファイル名を照合する

- 公開一覧は元表、候補ペア、正解を含む zip へのリンクを持つ。3 対象の zip を取得し、 CSV と公開 run 入力を全件照合した。
- HELM の 13 設定のうち、 Fodors と DBLP-Scholar 系の 3 設定は、実装が作る zip 名と配布先の zip 名が異なった。取得時には公式一覧のリンクを使う。
- 公開固定版は 2023 年の評価。今回確認した配布 repo の最終 commit は 2021-06-13 で、最新モデルの順位として扱わない。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

コードのライセンスと元データの条件

- DeepMatcher のコードは BSD 3-Clause 、 HELM のコードは Apache 2.0 で公開されている。
- データは BeerAdvocate 、 RateBeer 、商品サイト、楽曲販売サイトなどに由来する。公開 Datasets.md と取得 zip には、全データ共通の独立したライセンス文を確認できなかった。
- この資料は出所・ ID を添えた短いレコード引用を使う。再配布や業務利用には、元データと取得時点の利用条件を確認する。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md
[2] Mudgal & Li (2018). DeepMatcher LICENSE （ BSD 3-Clause 、コード）。 https://github.com/anhaidgroup/deepmatcher/blob/master/LICENSE

表記差を読み、同じ実体かを答える

- Entity Matching は、候補ペアの二レコードを同一実体へ対応付ける課題。 DeepMatcher は構造化、文章、属性移動という違いを比較するデータを公開した。
- HELM は属性を文章化し、 5 件の提示例から Yes/No を生成させる。負例比、評価するペア、試行ごとの提示例をそろえて成績を読む。
- 型番や容量が違う負例、表記や一部属性が食い違う正例を含め、文字列の重なりだけでは決まらない照合を評価できる。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926
[2] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

Appendix

1. 追加の実例
2. 対象と再現条件
3. 研究と参考文献

追加の実例

実例 4 ： Easy を共有する別のビール

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Easy Amber Ale. Brew_Factory_Name: Scottsdale Beer Company. Style: American Amber / Red Ale. ABV: 5.70 %. Product B is Beer_Name: Upland Easy Chair Amber Ale. Brew_Factory_Name: Upland Brewing Company. Style: Amber Ale. ABV: 5.60 %. Are A and B the same?

日本語訳

A の商品：ビール名は Easy Amber Ale 。醸造所は Scottsdale Beer Company 。スタイルはアメリカン・アンバー／レッドエール。度数は 5.70% 。 B の商品：ビール名は Upland Easy Chair Amber Ale 。醸造所は Upland Brewing Company 。スタイルはアンバーエール。度数は 5.60% 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Beer test pair row 57 （0 始まり）、 A=2494 / B=2565 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 5 ：度数が欠けても同じ銘柄

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Centurion Barleywine Ale. Brew_Factory_Name: Golden City Brewery. Style: American Barleywine. ABV: -. Product B is Beer_Name: Golden City Centurion Barleywine Ale. Brew_Factory_Name: Golden City Brewery. Style: Barley Wine. ABV: 11.20 %. Are A and B the same?

日本語訳

A の商品：ビール名は Centurion Barleywine Ale 。醸造所は Golden City Brewery 。スタイルはアメリカン・バーレーワイン。度数は「 - 」。 B の商品：ビール名は Golden City Centurion Barleywine Ale 。醸造所は Golden City Brewery 。スタイルはバーレーワイン。度数は 11.20% 。 A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Beer test pair row 88 （ 0 始まり）、 A=4161 / B=2409 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 6 ： Organic と Non-Organic の違い

Beer / test / 二レコードと質問の全文

入力原文（全文）

Product A is Beer_Name: Green Lakes Organic Ale. Brew_Factory_Name: Deschutes Brewery. Style: American Amber / Red Ale. ABV: 5.20 %. Product B is Beer_Name: Deschutes Green Lakes Non-Organic Ale. Brew_Factory_Name: Deschutes Brewery. Style: Amber Ale. ABV: 6.40 %. Are A and B the same?

日本語訳

A の商品：ビール名は Green Lakes Organic Ale 。醸造所は Deschutes Brewery 。スタイルはアメリカン・アンバー／レッドエール。度数は 5.20% 。 B の商品：ビール名は Deschutes Green Lakes Non-Organic Ale 。醸造所は Deschutes Brewery 。スタイルはアンバーエール。度数は 6.40% 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Beer test pair row 53 （0 始まり）、 A=76 / B=2831 。 https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 7 ：型番が一致する充電器

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: canon battery charger 1133b001. description: canon battery charger 1133b001 compatible with canon nb-5l lithium battery black finish. price: nan. Product B is name: canon cb-2lx battery charger 1133b001. description: nan. price: nan. Are A and B the same?

日本語訳

A の商品：名称は Canon バッテリー充電器 1133b001 。説明は、 Canon バッテリー充電器 1133b001 、 Canon NB-5L リチウム電池に対応、黒仕上げ。価格は nan 。 B の商品：名称は Canon CB-2LX バッテリー充電器 1133b001 。説明と価格は nan 。 A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Abt_Buy test pair row 750 （ 0 始まり）、 A=797 / B=259 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 8 ：対応プリンターが同じインク

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: canon photo ink cartridge cl52. description: canon photo ink cartridge cl52 compatible with pixma ip6210d and ip6220d printers. price: 25.0. Product B is name: canon ink cartridge for pixma ip1600 , ip6210d and ip6220d printers 0617b002. description: color. price: 19.11. Are A and B the same?

日本語訳

A の商品：名称は Canon 写真用インクカートリッジ CL52 。説明は、同製品が PIXMA iP6210D と iP6220D に対応すること。価格は 25.0 。 B の商品：名称は Canon PIXMA iP1600 、 iP6210D 、 iP6220D プリンター用インクカートリッジ 0617b002 。説明はカラー。価格は 19.11 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Abt_Buy test pair row 1785 （ 0 始まり）、 A=110 / B=84 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例９：価格が少し異なる電気ケトル

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: cuisinart cordless electric kettle kua17. description: cuisinart cordless electric kettle kua17 1-3/4 quart capacity automatic shut-off indicator light splash guard spout cord storage in base chrome finish. price: 70.0. Product B is name: cuisinart cordless automatic electric kettle. description: nan. price: 69.95. Are A and B the same?

日本語訳

A の商品：名称は Cuisinart コードレス電気ケトル KUA17 。説明は同名称と型番、容量 1 と 3/4 クォート、自動電源オフ、表示灯、飛び散り防止の注ぎ口、台座にコード収納、クローム仕上げ。価格は 70.0 。B の商品：名称は Cuisinart コードレス自動電気ケトル。説明は nan 。価格は 69.95 。 A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Abt_Buy test pair row 1249 （0 始まり）、 A=18 / B=211 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 10 ：セットと単体の違い

Abt_Buy / test / 二レコードと質問の全文

入力原文（全文）

Product A is name: garmin suction cup mount and 12-volt adapter kit 0101097900. description: garmin suction cup mount and 12-volt adapter kit 0101097900 suction cup mount and 12-volt adapter included. price: 30.0. Product B is name: garmin suction cup mount 010-10823-00. description: nan. price: 24.84. Are A and B the same?

日本語訳

A の商品：名称は Garmin 吸盤マウントと 12V アダプターのキット 0101097900 。説明は同名称と型番、吸盤マウントと 12V アダプターを含むこと。価格は 30.0 。 B の商品：名称は Garmin 吸盤マウント 010-10823-00 。説明は nan 。価格は 24.84 。 A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Abt_Buy test pair row 516 （ 0 始まり）、 A=421 / B=275 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 11 ：同じ曲名のカラオケ版

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Bad Blood (Karaoke Version) Taylor Swift Pop , Music $ 1.29 3:29. Artist_Name: nan. Album_Name: Taylor Swift Karaoke : 1989. Genre: nan. Price: nan. CopyRight: ‰ ãÑ 2014 Big Machine Records , LLC. Time: nan. Released: 3-Mar-15. Product B is Song_Name: Bad Blood Taylor Swift Pop 3:31 October 27 , 2014. Artist_Name: nan. Album_Name: 1989. Genre: nan. Price: $ 1.29. CopyRight: (C) 2014 Big Machine Records , LLC .. Time: nan. Released: nan. Are A and B the same?

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 95 （0 始まり）、 A=6621 / B=784 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 11 ：同じ曲名のカラオケ版（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Bad Blood （カラオケ版） Taylor Swift ポップ、音楽 $1.29 3:29 」。アーティストは nan 。アルバムは Taylor Swift Karaoke: 1989 。ジャンルと価格は nan 。著作権欄は「‰ ãÑ 2014 Big Machine Records, LLC 」。時間は nan 。発売日は 3-Mar-15 。
B の商品：曲名欄は「 Bad Blood Taylor Swift ポップ 3:31 October 27, 2014 」。アーティストは nan 。アルバムは 1989 。ジャンルは nan 。価格は $1.29 。著作権欄は「 (C) 2014 Big Machine Records, LLC 」。時間と発売日は nan 。
A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 95 （ 0 始まり）、 A=6621 / B=784 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 12 ：同じアルバムの異なる曲

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Illusion (feat . Echosmith) True Colors 2015 Interscope Records 6:30. Artist_Name: Zedd. Album_Name: nan. Genre: Dance , Music , Electronic. Price: $ 1.29. CopyRight: nan. Time: nan. Released: 18-May-15. Product B is Song_Name: Papercut [feat . Troye Sivan] Zedd Dance & Electronic 7:23. Artist_Name: nan. Album_Name: True Colors. Genre: nan. Price: $ 1.29. CopyRight: (C) 2015 Interscope Records. Time: nan. Released: May 18 , 2015. Are A and B the same?

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 32 （0 始まり）、A=1410 / B=51576 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 12 ：同じアルバムの異なる曲（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Illusion （ Echosmith 参加） True Colors 2015 Interscope Records 6:30 」。アーティストは Zedd 。アルバムは nan 。ジャンルはダンス、音楽、エレクトロニック。価格は $1.29 。著作権と時間は nan 。発売日は 18-May-15 。
B の商品：曲名欄は「 Papercut ［ Troye Sivan 参加］ Zedd ダンス＆エレクトロニック 7:23 」。アーティストは nan 。アルバムは True Colors 。ジャンルは nan 。価格は $1.29 。著作権は (C) 2015 Interscope Records 。時間は nan 。発売日は May 18, 2015 。
A と B は同じか。

正解： No — 別の実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 32 （ 0 始まり）、 A=1410 / B=51576 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 13 ：年の表記が異なる Billy の正例

Dirty_iTunes_Amazon / test / ニレコードと質問の全文

Product A is Song_Name: Billy Keith Urban In the Ranch Country , Music , Honky Tonk , Contemporary Country 3:46. Artist_Name: nan. Album_Name: nan. Genre: nan. Price: $ 1.29. CopyRight: 1997 Capitol Nashville. Time: nan. Released: 1997. Product B is Song_Name: Billy Country (c) 1997 Capitol Nashville February 10 , 2004. Artist_Name: Keith Urban. Album_Name: Keith Urban In The Ranch. Genre: nan. Price: $ 1.29. CopyRight: nan. Time: 3:46. Released: nan. Are A and B the same?

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 76 （0 始まり）、A=4547 / B=26140 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

実例 13 ：年の表記が異なる Billy の正例（訳）

日本語訳：同じニレコードと質問

A の商品：曲名欄は「 Billy Keith Urban In the Ranch カントリー、音楽、ホンキートンク、現代カントリー 3:46 」。アーティスト、アルバム、ジャンルは nan 。価格は $1.29 。著作権は 1997 Capitol Nashville 。時間は nan 。発売年は 1997 。
B の商品：曲名欄は「 Billy カントリー (c) 1997 Capitol Nashville February 10, 2004 」。アーティストは Keith Urban 。アルバムは Keith Urban In The Ranch 。ジャンルは nan 。価格は $1.29 。著作権は nan 。時間は 3:46 。発売日は nan 。
A と B は同じか。

正解： Yes — 同じ実体

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。 Dirty_iTunes_Amazon test pair row 76 （0 始まり）、A=4547 / B=26140 。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

対象と再現条件

構造化の 7 データ設定

対象	ペア数	正例数	属性
BeerAdvo-RateBeer	450	68	4
iTunes-Amazon	539	132	8
Fodors-Zagats	946	110	6
DBLP-ACM	12,363	2,220	4
DBLP-Scholar	28,707	5,347	4
Amazon-Google	11,460	1,167	3
Walmart-Amazon	10,242	962	5

公開一覧の値。 DBLP-Scholar は HELM では DBLP_GoogleScholar 。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

文章 2 設定と Dirty 4 設定

対象	ペア数	正例数	属性
Abt-Buy	9,575	1,028	3
Company	112,632	28,200	1
iTunes-Amazon	539	132	8
DBLP-ACM	12,363	2,220	4
DBLP-Scholar	28,707	5,347	4
Walmart-Amazon	10,242	962	5

上 2 行が文章、下 4 行が Dirty 。公開一覧の値。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

同じレコードは、別の分割にも現れる

train / test 共有	表 A の ID	表 B の ID	候補ペア
Beer	27	36	0
Abt_Buy	674	650	0
Dirty_iTunes_Amazon	24	15	0

元 CSV を ID で照合。ペアの重複は 0 だが、片側レコードは共有する。

[1] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

Beer ： Llama 2 の 91 ペアを数える

配布ラベル	回答 Yes	回答 No
同じ（ Yes ）	11	3
別（ No ）	4	73

正解 84 / 91 = 92.31% 。正例の再現率は 11 / 14 。正解率だけではこの内訳は表れない。

[1] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。公開保存 run の入力・出力・ stats を再照合。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching

属性を列順に文章へ変換する

```
A = ". ".join(f"{col}: {row[col]}" for col in columns)
# id 列を除外し、列順を保つ。空欄は nan 。
text = f"Product A is {A}. Product B is {B}."
text += " Are A and B the same?"
answer = "Yes" if label else "No"
```

説明用に変数名を短縮。検証では公式 serialize_row を変更せず実行し、9,800 件の公開入力と正解を配布 CSV へ照合した。

[1] Stanford CRFM. EntityMatchingScenario. HELM v0.3.0.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario.py

保存された状態で、同じ評価ペアを追跡する

- HELM の初期実行は NumPy 乱数状態を 0 へ初期化していなかった。その後の実装は、データごとの保存乱数状態を読み込み、同じ抽出を再現する。
- 保存状態の CodaLab URL は今回 503 を返した。乱数 seed 0 で同じペアを得たとは主張せず、公開 scenario_state に保存されたペア・提示例・出力を根拠とした。
- 13 実例は配布 test CSV の原行、二つの表の原行、 SHA256 、公開 run の instance ID と対応する。

[1] Stanford CRFM. Entity matching fixed random state. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario_fixed_random_state.py

13 設定の実装名と、配布 zip 名の相違

- Fodors_Zagats の実装は fodors_zagats_exp_data.zip を要求するが、公式一覧は fodors_zagat_exp_data.zip 。
- DBLP_GoogleScholar の実装は dblp_googlescholar_exp_data.zip を要求するが、公式一覧は dblp_scholar_exp_data.zip 。 Dirty 版も同じ scholar 名である。
- 2026-10-18 に HTTPS で 13 生成 URL を確認し、この 3 件は 404 、他 10 件は 200 だった。 Company は HEAD のみで、全量を取得していない。

[1] Stanford CRFM. EntityMatchingScenario. HELM v0.3.0.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario.py
[2] Mudgal & Li et al. DeepMatcher: Datasets for DeepMatcher paper. 固定 commit a89ffe6 、 2026-10-18 参照。
https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

研究と参考文献

深層学習の得意な照合条件を比較した研究

- Sidharth Mudgal と Han Li らは、 Wisconsin–Madison 、 Johnson Controls 、 WalmartLabs 、 Facebook の研究者と 2018 年 SIGMOD で発表した。
- SIF 、 RNN 、 Attention 、 Hybrid と、特徴量を設計する Magellan を 23 課題で比較。構造化データでは優位が限られ、文章や Dirty で改善を報告した。
- HELM は同じ公開候補ペアを言語モデルの生成課題へ変換する。 2018 年の教師あり F1 と、 2023 年の少数例提示の正解率は異なる設定である。

[1] Mudgal et al. (2018). Deep Learning for Entity Matching: A Design Space Exploration. SIGMOD. https://doi.org/10.1145/3183713.3196926

参考文献

Deep Learning for Entity Matching: A Design Space Exploration

Sidharth Mudgal, Han Li, Theodoros Rekatsinas, AnHai Doan, Youngchoon Park, Ganesh Krishnan, Rohit Deep, Esteban Arcaute & Vijay Raghavendra. 2018. SIGMOD.

23 課題を用い、データの構造と属性の乱れによる照合手法の違いを分析する。

https://doi.org/10.1145/3183713.3196926

Datasets for DeepMatcher paper

DeepMatcher authors. GitHub. 固定 commit a89ffe6 （2021-06-13）。

公開 13 設定の規模、候補生成、ラベル付け、 Dirty 変換と配布先を記載する。

https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md

参考文献

EntityMatchingScenario and fixed random state

Stanford CRFM. HELM v0.3.0.

13 設定の登録、正負の学習抽出、属性の文章化、 Yes/No 参照、乱数状態を定義する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/entity_matching_scenario.py

HELM Classic — Entity matching

Stanford CRFM. v0.4.0 （ 2023-11-17 固定版）。

3 対象の保存実行と、モデル別・試行別の正解率、入力、生成出力を公開する。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/entity_matching