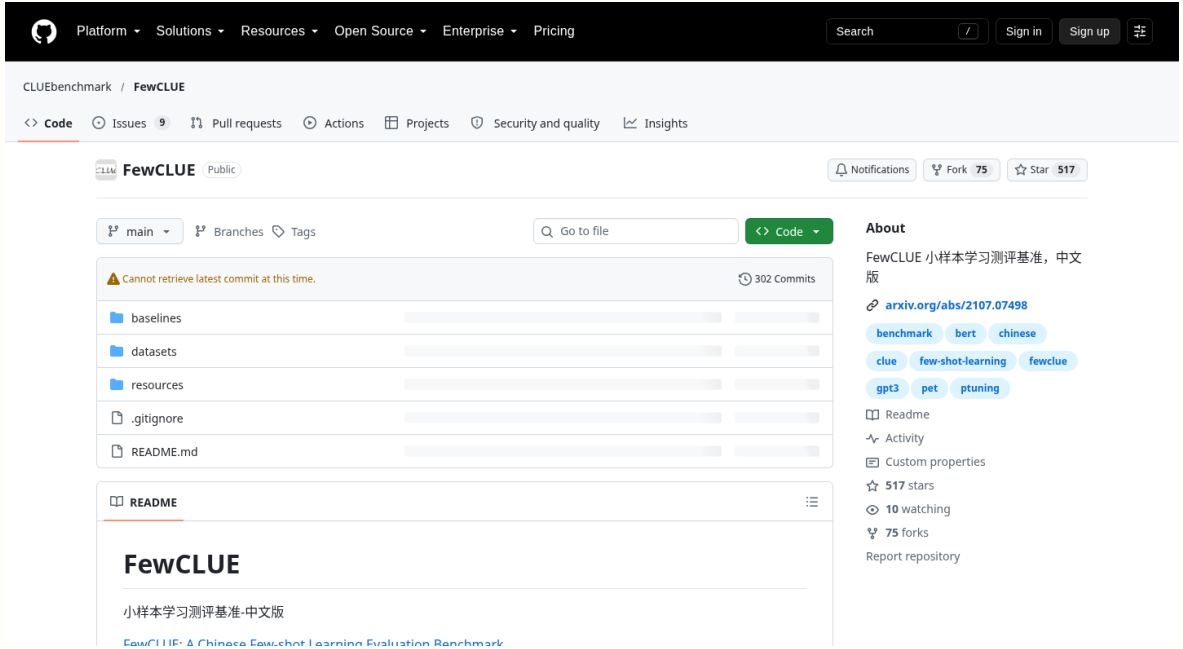
EPRSTMT

E-commerce Product Review Dataset for Sentiment Analysis

短い商品レビューから、評価の向きを読む

sasakiy84

EPRSTMT の公式配布ページ



[1] CLUE team. FewCLUE official README. 固定版 62a02c6f31cf 、 EPRSTMT の定義・配布構造。 現在の公式画面。解析した原データは固定 commit 版。
https://github.com/CLUEbenchmark/FewCLUE

1. 商品レビューの感情を読む
2. 作成の由来と、少数例の分割
3. 評価の分母と、実装で変わる入力
4. CLEVA での採用と利用条件

商品レビューの感情を読む

商品の品質より、レビューの評価を分類する

- EPRSTMT は、中国語の商品レビューを読み、投稿された評価が正面（肯定的）か負面（否定的）かを二つのラベルで表すデータセット。
- FewCLUE では EPR-sentiment とも呼ばれる。電子商取引の商品レビューを使う、単文の感情分析課題。
- 出力は Positive か Negative 。星の数や、商品の故障原因、レビューが事実かどうかを答える課題ではない。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498v2

正面と負面は、配布された二つのラベル

- 原データは id 、 sentence 、 label を持つ。 Positive は正向、 Negative は負向と、公式 README が定義する。
- 配送の速さ、価格、音質、同梱品などへの評価が、一つのレビューで食い違うことがある。部分的な否定語と、レコード全体の配布ラベルを分けて読む。
- 以下の 13 例では、レビューの中国語全文と日本語訳を同じページに置き、公開ラベルをそのまま示す。

[1] CLUE team. FewCLUE official README. 固定版 62a02c6f31cf 、 EPRSTMT の定義・配布構造。 https://github.com/CLUEbenchmark/FewCLUE

実例１：通話中の雑音と、正規品への疑念

train_4.json / 0 起算行 7 / ローカル ID 7

中国語原文（全文）

今天刚拿到手机，打电话时发现手机听筒有吱吱吱的杂声，不满意，真怀疑是不是正品

日本語訳（全文）

今日、携帯電話を受け取りました。電話をかけると受話口からジージーという雑音がすることに気づきました。不満です。本当に正規品なのか疑ってしまいます。

正解：負面（否定的） / Negative

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 train_4.json 、 0 起算行 7 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

雑音への不満から、正規品かを疑う

- 不満と正規品への疑念を述べる。 CLEVA 論文の公開例と原文が一致する。
- 受取直後の通話で、受話口から雑音がする。最後の疑いは投稿者の発言であり、正規品でないと確認した結果ではない。
- 元ラベル Negative は、レビューの否定的な評価を表す。CLEVA で引用された文も、元コーパスの 1 件として位置を特定できる。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例２：速さ・良さ・安さを繰り返す

train_0.json / 0 起算行 29 / ローカル ID 29

中国語原文（全文）

商城就是快好省，快好省

日本語訳（全文）

このモールは本当に速くて、よくて、お得。速くて、よくて、お得。

正解：正面（肯定的） / Positive

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 train_0.json 、 0 起算行 29 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

同じ短文でも、元データと選択肢付き課題は違う

- 元のレコードはレビュー文と Positive ラベル。 HELM の公開説明例は、「正面か負面か」と問い、 A. 負面、 B. 正面を選ばせる。
- 公開説明例の正解 B は、原データの Positive に対応する。ただし、全テンプレートや CLEVA の採用集合を取得できたわけではない。
- この文は train の複数分割に現れる。同じレビューが別 ID で現れても、異なる内容の例が増えたことにはならない。

[1] Stanford CRFM. CLEVASentimentAnalysisScenario / Converter. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

実例３：包装の傷より、試聴後の評価

train_0.json / 0 起算行 23 / ローカル ID 23

中国語原文（全文）

外包装上有点磨损，试听后感觉不错

日本語訳（全文）

外箱に少し擦れがありますが、試聴した感じはよいです。

正解：正面（肯定的） / Positive

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 train_0.json 、 0 起算行 23 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

傷がある、という一節だけでは決めない

- 一部に不満が含まれても、配布ラベルは Positive 。単語一つの極性とレビュー全体を分ける。
- 「外箱に少し擦れ」と「試聴した感じはよい」が同居する。全体のラベルは Positive 。原文が示さない評価の重みを、後から数式で補わない。
- 解釈が難しい例や、不満が並ぶ Positive も含まれる。配布ラベルを保持し、モデルの誤りと人手で再注釈した結果を混同しない。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

作成の由来と、少数例の分割

ICIP の収集と、 FewCLUE での再構成を分ける

- FewCLUE 論文は、北京師範大学の ICIP Lab が収集した商品レビューを、 FewCLUE 向けにフィルタ・検査・再構成したと説明する。
- 原収集全体の規模、注釈者数、星評価からラベルを作ったかどうかは、確認した一次資料では特定できない。特定の EC サイト名も推測しない。
- 対象は、 FewCLUE 公式リポジトリの固定公開版。 ICIP の元配布と同一の全コーパスだとは扱わない。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498v2

1 組 32 件と、公開・非公開テストを区別する

公開ファイル	行数	正解ラベル
train_0 〜 4 （各）	32	あり
dev_0 〜 4 （各）	32	あり
test_public.json	610	あり
test.json	753	なし
unlabeled.json	19,565	なし

5 組の train/dev と、一つずつのテスト。行数は固定公開ファイルを再集計。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

32 件の中の、二つのラベルの内訳

組	train 正面 / 負面	dev 正面 / 負面
0	17 / 15	13 / 19
1	16 / 16	16 / 16
2	18 / 14	19 / 13
3	18 / 14	14 / 18
4	15 / 17	12 / 20

各組は合計 32 件。各クラス 32 件ではなく、内訳も組ごとに異なる。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

集約版の 160 行は、 160 の異なる文ではない

- 集約ファイルは 160 行だが、一意なレビュー文は train が 131 件、 dev が 135 件。同じ文が別の分割や ID で繰り返されても、独立した新しい用例とは数えない。
- README は train_few_all と dev_few_all を「合併・重複除去した結果」と説明する。しかし固定ファイルは、 ID 以外を比較すると 0 〜 4 の各分割を順に連結した内容と完全一致する。
- 集約版の ID は 0 〜 159 へ振り直される。 ID が異なることと、レビュー文が異なることは同じではない。

[1] CLUE team. FewCLUE official README. 固定版 62a02c6f31cf 、 EPRSTMT の定義・配布構造。 https://github.com/CLUEbenchmark/FewCLUE
[2] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

同じ組の train/dev と、別の組の共有を分ける

- 同じ番号の train_i と dev_i を、 Unicode 文字列の完全一致で照合すると、同じレビュー文の共有は 5 組とも 0 件。
- 一方、別番号の train 同士や dev 同士には同文がある。少数例の分割をまたぐ再出現と、同じ組内の train/dev の共有を分けて読む。
- 空白や句読点を消さずに数える。異なる文章を、意味が似ているという理由で重複扱いにしない。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

評価の分母と、実装で変わる入力

基本指標は、正解ラベルとの一致率

- 公式 EFL baseline の compute_metrics は、 eprstmt に対して simple_accuracy を呼ぶ。一致した予測数を、ラベル付き評価例数で割る。
- ここで公式関数を実行できるのは公開 test の 610 件。公開されていない 753 件の正解を仮定して、テスト成績を作らない。
- 32 件で学習する few-shot 設定と、大規模言語モデルの入力に何例を置くかという in-context の shot 数は別の条件。

[1] CLUE team. compute_metrics / simple_accuracy. EFL baseline 、固定版 62a02c6f31cf 。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/baselines/models_pytorch/EFL/metrics/clue_compute_metrics.py

公開 610 件では、定数予測はどちらも 50%

定数予測	一致 / 分母	Accuracy
全て Negative	305 / 610	50.00%
全て Positive	305 / 610	50.00%

配布正解を使った公式関数の再計算。訓練済みモデルや非公開 test の成績ではない。

[1] CLUE team. compute_metrics / simple_accuracy. EFL baseline 、固定版 62a02c6f31cf 。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/baselines/models_pytorch/EFL/metrics/clue_compute_metrics.py

2021 年に報告された、 EPRSTMT の成績

方法	報告値（%）
Fine-tuning / RoBERTa	65.4
Zero-shot / RoBERTa	85.2
PET	86.7
P-tuning / RoBERTa	88.3

FewCLUE 論文 v2 の EPRSTMT 列。原論文の報告値を引用し、公開 610 件で再採点した値とは分ける。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498v2

人手 90.0% も、モデルと同じ分母ではない

- 論文の人手評価は、練習と討議を経た注釈者が test の 100 件を読む手順。 EPRSTMT の報告値は 90.0% だが、全件に対するモデル値と分母をそろえた再採点ではない。
- 論文では、注釈者は dev の 30 〜 50 件で練習し、正解と比べ、議論してから test の 100 件を注釈する。 EPRSTMT の原ラベル作成手順とは別の人手評価。
- 元の個別予測や非公開正解を取得していないため、論文のモデル値・人手値をこの資料で再現したとは呼ばない。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498v2

ラベル語や文ペアへ変換しても、原例数は同じ

- PET の公開実装は Negative を 0 、 Positive を 1 へ写し、「不」「很」というラベル語を使う。モデル入力のテンプレートは、原レビューそのものとは別の処理。
- EFL はレビューとラベル説明の文ペアを作り、 entail / not_entail を学習する。変換後の文ペア数を、原コーパスのレビュー数と呼ばない。
- test.json には正解ラベルがない。 PET の読み込み関数が置く仮の 0 を、配布された Negative の正解とみなして採点しない。

[1] CLUE team. PET baseline pet_eprstmt.py. ラベル語・読み込み・評価。固定版 62a02c6f31cf 。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/baselines/models_keras/pet/pet_eprstmt.py

[2] CLUE team. EprstmtProcessor. EFL baseline 、固定版 62a02c6f31cf 。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/baselines/models_pytorch/EFL/processors/efl_fewclue.py

CLEVA での採用と利用条件

元の感情分類と、 CLEVA での利用範囲を分ける

- CLEVA 論文は、感情分析に FewCLUE を採用し、通話中の雑音を訴えるレビューを公開例として示す。原データの train_4 行 7 と全文・ Negative ラベルが一致する。
- HELM v0.4.0 の感情分析クラスは、モールを褒める別の公開例を示す。これは原データの train_0 行 29 などと一致する。
- 説明例の一致で確認できるのは、その原票との対応。 CLEVA が使ったレビュー全件・選び方・実際の全入力は未取得のまま区別する。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM. CLEVASentimentAnalysisScenario / Converter. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

設定 6 通りと、固定公開実行 0 件は別の情報

- HELM の CLEVA v1 設定には、 sentiment_analysis の prompt_id が 0 〜 5 の 6 通りある。設定の数を、実行済みの件数や採用レビュー数とは呼ばない。
- HELM Classic v0.4.0 の固定公開 run 索引 8,526 件では、 CLEVA の対象実行は 0 件。公開実行から生成結果や Accuracy を読み取ったとはしない。
- 変換済みの集合を読み込む Converter があり、入力やラベルの形は変換後のデータに依存する。公開説明例から全設定の候補順を決めつけない。

[1] Stanford CRFM. CLEVA v1 run configuration. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

[2] Stanford CRFM. HELM Classic v0.4.0 、 2023-11-17 固定公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/

出所の表示と、再利用の条件を区別する

- 収集元としての ICIP Lab 、 FewCLUE の作成・配布者、原レビューの権利者は同じとは限らない。引用は原文と訳を区別し、配布版と原位置を添えて参照する。
- 確認した固定リポジトリには、 EPRSTMT データ全体への包括ライセンスを特定できなかった。公開ダウンロードできることだけで、無条件の再配布許諾とはしない。
- BERT コードのサブディレクトリにある Apache 2.0 を、商品レビュー本文全体の許諾へ広げない。研究利用や再配布では、配布元の条件を個別に確認する。

[1] CLUE team. FewCLUE official README. 固定版 62a02c6f31cf 、 EPRSTMT の定義・配布構造。 https://github.com/CLUEbenchmark/FewCLUE

公開版・原位置・評価範囲を併せて参照する

- 固定 commit 、各 JSON ファイルの SHA-256 、ファイル名と 0 起算行、原レコードの ID で、用例と公開版を特定する。 ID だけでは異なる分割の文を特定できない。
- 13 例は全て独立したレビュー文。主な 3 例は CLEVA 論文・HELM 説明・公式 README に対応し、追加 10 例は公開 test から選んだ。
- 公開テストの再計算、論文の報告値、 HELM の設定、未取得の CLEVA 採用集合は、それぞれ異なる根拠と分母として扱う。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

読むときに残したい、三つの区別

- 短いレビューでも、複数の評価対象や皮肉が同居する。日本語訳で原文にない事情を補わず、配布ラベルを読み解く。
- 32 件の各分割、重複を含む 160 行の集約版、正解付き 610 件と正解非公開 753 件を混同しない。
- 公式 Accuracy の再計算と、 2021 年の研究報告値、CLEVA/HELM の採用情報を分けて利用する。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498v2
[2] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

Appendix

1. 追加の原レビュー
2. 原位置・重複・実装の補足
3. 研究と参考文献

追加の原レビュー

実例 4 ：配送への皮肉を読む

test_public.json / 0 起算行 0 / ローカル ID 835

中国語原文（全文）

呵呵了 这物流速度也是没谁了 同城网购竟然三天了还不到

日本語訳（全文）

ははは、この配送スピードには参りました。同じ市内のネット購入なのに、３日たってもまだ届きません。

正解：負面（否定的） / Negative

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 0 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 5 ：短い肯定と、今後の試用

test_public.json / 0 起算行 1 / ローカル ID 59

中国語原文（全文）

还不错，等试用一段时间再说

日本語訳（全文）

悪くありません。しばらく使ってから、また評価します。

正解：正面（肯定的） / Positive

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 1 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 6 ：使わなくても電池がなくなる

test_public.json / 0 起算行 3 / ローカル ID 65

中国語原文（全文）

冲满电 2 天没用过就没电 客服说正常的

日本語訳（全文）

満充電にして、２日間使っていないのに電池がなくなりました。カスタマーサービスは正常だと言っています。

正解：負面（否定的） / Negative

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 3 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 7 ：高齢者にも使いやすい携帯電話

test_public.json / 0 起算行 16 / ローカル ID 303

中国語原文（全文）

手机好用，声音大，手写流利，老人非常中意。

日本語訳（全文）

携帯電話は使いやすく、音も大きく、手書き入力も滑らかです。高齢者がとても気に入っています。

正解：正面（肯定的） / Positive

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 16 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 8 ：期待との差や痛みがあっても正面

test_public.json / 0 起算行 7 / ローカル ID 10

中国語原文（全文）

耳机做工还行，音效的话没有想象中的那么好，可能需要煲机吧，耳机戴了一两个小时耳朵就有点疼

日本語訳（全文）

イヤホンの作りはまあまあです。音は想像していたほどよくなく、慣らし運転が必要なのかもしれません。１、２時間着けると、耳が少し痛くなります。

正解：正面（肯定的） / Positive

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 7 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例９：中国製品を応援しつつ、操作に戸惑う

test_public.json / 0 起算行 12 / ローカル ID 996

中国語原文（全文）

支持国产，用起来挺好的，操作有点不习惯。

日本語訳（全文）

中国製品を応援します。使い心地はよいですが、操作には少し慣れません。

正解：正面（肯定的） / Positive

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 12 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 10 ：厚さが期待と合わない

test_public.json / 0 起算行 18 / ローカル ID 209

中国語原文（全文）

太厚了，和期待值有差距 . 夏天揣口袋里绝对不和谐 . 看来只能应急用用了 .

日本語訳（全文）

厚すぎて、期待とは差があります。夏にポケットへ入れたら、どう見ても不格好です。どうやら非常用に使うしかなさそうです。

正解：負面（否定的） / Negative

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 18 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 11 ：使って分かった複数の問題

test_public.json / 0 起算行 22 / ローカル ID 315

中国語原文（全文）

用了几天，发现很多问题，无线网容易掉线，屏幕容易刮花，打开网页容易死掉，不值的买

日本語訳（全文）

数日使って、多くの問題に気づきました。無線ネットワークは切れやすく、画面は傷つきやすく、ウェブページを開くとフリーズしやすいです。買う価値はありません。

正解：負面（否定的） / Negative

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 22 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 12 ：イヤホンが見当たらず、気分が変わる

test_public.json / 0 起算行 24 / ローカル ID 1050

中国語原文（全文）

收到手机的时候挺高兴的。 但是我找了半天都没有找到耳机，跟我想象的不太一样 心情立马不好了

日本語訳（全文）

携帯電話が届いたときはうれしかったです。でも、しばらく探してもイヤホンが見つからず、想像していたものとは少し違いました。たちまち嫌な気分になりました。

正解：負面（否定的） / Negative

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 24 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

実例 13 ：イヤホンへの不満を含む正面ラベル

test_public.json / 0 起算行 27 / ローカル ID 994

中国語原文（全文）

一分钱一分货嘛，毕竟价格在这里，也不错了，没送耳机，本人不高兴

日本語訳（全文）

値段なりですよね。結局この価格ですし、悪くありません。イヤホンが付いてこなかったので、私は不満です。

正解：正面（肯定的） / Positive

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。 test_public.json 、 0 起算行 27 。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

原位置・重複・実装の補足

13 例のファイル・行位置・配布ラベル

例	原ファイル	0 起算行	原ラベル
1	train_4.json	7	Negative
2	train_0.json	29	Positive
3	train_0.json	23	Positive
4	test_public.json	0	Negative
5	test_public.json	1	Positive
6	test_public.json	3	Negative
7	test_public.json	16	Positive

ID はファイル内の値。同文の別 ID を区別する。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

13 例のファイル・行位置・配布ラベル

例	原ファイル	0 起算行	原ラベル
8	test_public.json	7	Positive
9	test_public.json	12	Positive
10	test_public.json	18	Negative
11	test_public.json	22	Negative
12	test_public.json	24	Negative
13	test_public.json	27	Positive

ID はファイル内の値。同文の別 ID を区別する。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

README の説明と、集約ファイルの実内容

集約版	行数	一意な文	重複分
train_few_all.json	160	131	29
dev_few_all.json	160	135	25

ID を除く全項目が、 0 〜 4 の分割を順に連結した内容と一致。同文のラベル違いは集約版内 0 件。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

[2] CLUE team. FewCLUE official README. 固定版 62a02c6f31cf 、 EPRSTMT の定義・配布構造。 https://github.com/CLUEbenchmark/FewCLUE

無ラベル資料の行数と、同文の共有も分ける

照合対象	一意な文・共有数
unlabeled 全 19,565 行	一意な文 18,744
train 集約版と unlabeled	共有文 6
dev 集約版と unlabeled	共有文 4
公開 test と unlabeled	共有文 45
非公開 test と unlabeled	共有文 47

完全一致する文の共有数。無ラベル資料の利用は公式ルールで認められる。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

公開 test の分母と、定数予測を確かめる

```
import json
rows = [json.loads(s) for s in open(
    'datasets--eprstmt--test_public.json')]
hits = sum(r['label'] == 'Negative' for r in rows)
print(hits, len(rows), hits / len(rows))
```

出力は 305 、 610 、 0.5 。ラベルなし test.json や unlabeled.json を分母に混ぜない。

[1] ICIP Lab / CLUE team. EPRSTMT official public files via FewCLUE. 固定版 62a02c6f31cf 。原レビューの権利は出所に帰属。
https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf32814cfe522f78ef088228840f8d/datasets/eprstmt

PET では、正解がないファイルにも仮の 0 が入る

- 公開実装の load_data は、 label があれば Positive を 1 、それ以外を 0 へ写す。 label 自体がない場合も 0 を入れる。
- この関数を全 15 ファイルに実行すると、 test の 753 件、unlabeled の 19,565 件が全て 0 になる。元ファイルの Negative ラベルを見つけた結果ではない。
- 検証用には dev_0 〜 4 を結合する公開コードもある。どの baseline を使うかで、学習・検証の入力範囲が異なるため、 32 件という課題説明だけから全実装の条件を決めない。

[1] CLUE team. PET baseline pet_eprstmt.py. ラベル語・読み込み・評価。固定版 62a02c6f31cf 。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/baselines/models_keras/pet/pet_eprstmt.py

EFL の変換後ペア数は、原レビュー数ではない

元 train	原レビュー	変換ペア（ratio=1）
train_0	32	62
train_1	32	64
train_2	32	60
train_3	32	60
train_4	32	62

公式処理の結果。原例に、少数クラス数を基準とする負の文ペアを加える。

[1] CLUE team. EprstmtProcessor. EFL baseline 、固定版 62a02c6f31cf 。
https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf32814cfe522f78ef088228840f8d/baselines/models_pytorch/EFL/processors/efl_fewclue.py

2021 年： EPRSTMT 列の追加報告値

方法	報告値（%）
LM-BFF	85.6
EFL	84.9
Fine-tuning / ERNIE1.0	66.5
PET / ERNIE1.0	84.0
P-tuning / ERNIE1.0	80.6
EFL / ERNIE1.0	76.7
Zero-shot / GPT 系	57.5

論文の中心値のみ引用。括弧内の統計や試行数は推定しない。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498v2

研究と参考文献

2021 年の研究と、固定公開版の役割

- FewCLUE 研究は、中国語の少数例学習を 9 課題で比較するベンチマーク。 EPRSTMT はその単文感情分析課題であり、元レビュー収集全体の説明とは範囲が異なる。
- FewCLUE 論文は arXiv のプレプリントとして公開されている。参照版は v2 （ 2021 年 9 月 29 日）で、 CLEVA 書誌に示された 2021 年版との版情報を区別する。
- 公開ファイルから確かめた件数・重複・ラベルと、論文に記された収集説明・成績を、それぞれの根拠に沿って利用する。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv:2107.07498v2. https://arxiv.org/abs/2107.07498v2
[2] CLUE team. FewCLUE official README. 固定版 62a02c6f31cf 、 EPRSTMT の定義・配布構造。 https://github.com/CLUEbenchmark/FewCLUE

参考文献

FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark

Liang Xu, Xiaojing Lu, Chenyang Yuan, Xuanwei Zhang, Huilin Xu, Hu Yuan, Guoao Wei, Xiang Pan, Xin Tian, Libo Qin & Hai Hu · 2021 · arXiv:2107.07498v2

中国語の少数例学習を 9 課題で比較し、 EPRSTMT の由来・分割・報告成績を説明する。

https://arxiv.org/abs/2107.07498v2

FewCLUE: official repository and EPRSTMT files

CLUE team · commit 62a02c6f31cf · README / 15 JSON files

公開分割、原レビュー、二つの感情ラベル、 baseline 実装を配布する。

https://github.com/CLUEbenchmark/FewCLUE

参考文献

FewCLUE EPRSTMT: PET baseline

CLUE team · pet_eprstmt.py · commit 62a02c6f31cf

原ラベル・仮値の読み込み、ラベル語、学習・検証入力の範囲を定める PET 実装。

https://github.com/CLUEbenchmark/FewCLUE/blob/62a02c6f31cf/baselines/models_keras/pet/pet_eprstmt.py

FewCLUE EFL: compute_metrics / simple_accuracy

CLUE team · clue_compute_metrics.py · commit 62a02c6f31cf

eprstmt で呼び出される Accuracy の公式計算関数。予測と正解の一致率を返す。

https://github.com/CLUEbenchmark/FewCLUE/tree/62a02c6f31cf/baselines/models_pytorch/EFL/metrics

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations

感情分析の採用元として FewCLUE を挙げ、商品レビューの公開例を示す。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVASentimentAnalysisScenario and Converter

Stanford CRFM · HELM v0.4.0

元レビューに対応する説明例と選択肢・正解ターゲット、変換済み集合の読み込みを定義する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

CLEVA v1 run configuration

Stanford CRFM · HELM v0.4.0

sentiment_analysis の prompt_id 0 〜 5 を含む設定。実行結果の公開とは別の情報。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

HELM Classic v0.4.0: public run index

Stanford CRFM · release 2023-11-17

固定公開 8,526 run の索引。 CLEVA の対象実行 0 件という公開範囲を示す。

https://crfm.stanford.edu/helm/classic/v0.4.0/