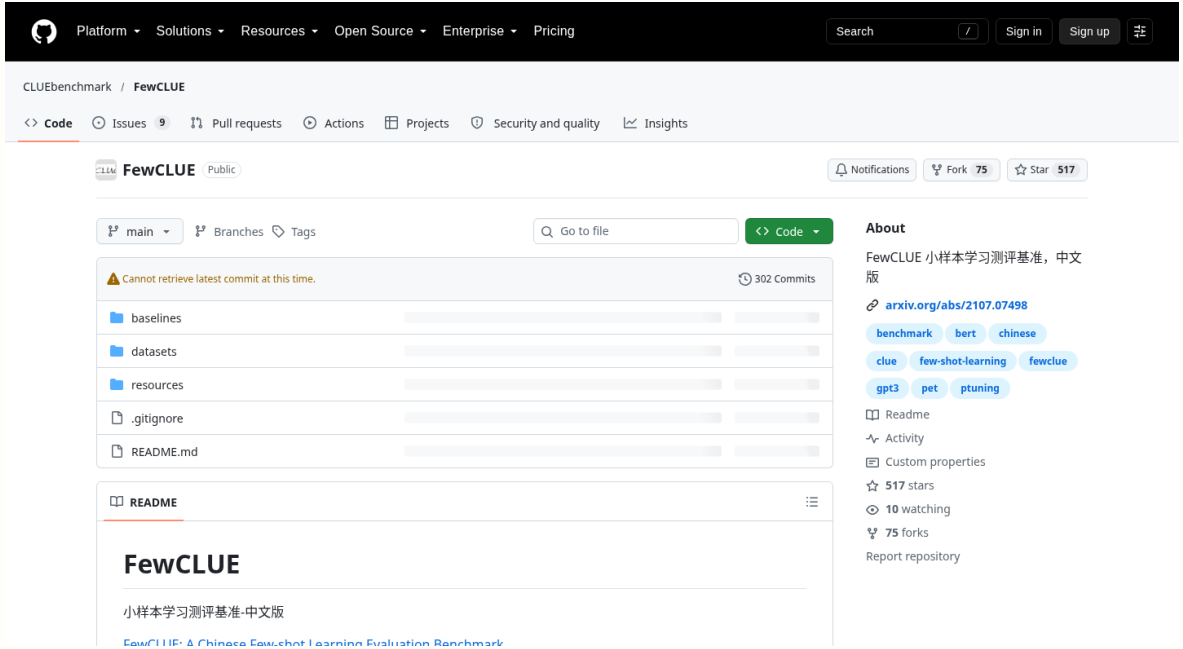
EPRSTMT

E-commerce Product Review Dataset for Sentiment Analysis

中国語の商品レビューを、肯定的・否定的に分類する

sasakiy84

EPRSTMT の公式配布ページ



[1] CLUE team (n.d.). FewCLUE: 小样本学习测评基准 . GitHub. https://github.com/CLUEbenchmark/FewCLUE

1. 商品レビューを分類する
2. FewCLUE での作成と構成
3. 評価方法とモデルへの入力
4. CLEVA での利用と入手方法

商品レビューを分類する

商品レビューの評価を、二つのラベルで表す

- EPRSTMT は、中国語の商品レビューを、肯定的な評価と否定的な評価に分類するデータセット。肯定的なら Positive 、否定的なら Negative というラベルを付ける。
- FewCLUE では EPR-sentiment とも呼ばれる。少数のラベル付きデータから学習するモデルを評価するために使われる。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

入力はレビュー文、出力は感情のラベル

- sentence には商品レビューの本文、 label には Positive か Negative が入っている。モデルはレビュー文を読み、二つのラベルのどちらかを予測する。
- レビューには、配送、価格、音質、使いやすさなどへの評価が含まれる。一つの文に、良い点と不満が一緒に書かれることもある。

[1] CLUE team (n.d.). FewCLUE: 小样本学习测评基准 . GitHub. https://github.com/CLUEbenchmark/FewCLUE

実例１：通話中の雑音と、正規品への疑念

中国語原文（全文）

今天刚拿到手机，打电话时发现手机听筒有吱吱吱的杂声，不满意，真怀疑是不是正品

日本語訳

今日、携帯電話を受け取りました。電話をかけると受話口からジージーという雑音がすることに気づきました。不満です。本当に正規品なのか疑ってしまいます。

正解：否定的 / Negative

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. train_4.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/train_4.json

実例２：速さ・良さ・安さを繰り返す

中国語原文（全文）

商城就是快好省，快好省

日本語訳

この通販サイトは、速い、良い、お得。速い、良い、お得。

正解：肯定的 / Positive

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. train_0.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/train_0.json

実例３：包装の傷より、試聴後の評価

中国語原文（全文）

外包装上有点磨损，试听后感觉不错

日本語訳

外箱に少し擦れがありますが、試聴した感じはよいです。

正解：肯定的 / Positive

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. train_0.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/train_0.json

良い点と不満が、一つのレビューに混在する

- 包装の傷を挙げつつ、試聴した感想を「よい」とするレビューには、 Positive が付いている。投稿者が何を評価し、最後にどのような感想を述べているかが、分類の手掛かりになる。
- 一方、音や装着感への不満が続いていても Positive となっている例がある。文章から受ける印象と正解ラベルが合いにくい例も含まれるため、感情の解釈とラベルの品質が評価上の課題になる。

[1] ICIP Lab / CLUE team (n.d.). EPRSTMT (FewCLUE). GitHub. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/eprstmt

FewCLUE での作成と構成

商品レビューを、少数例学習の評価用に整備

- 北京師範大学の ICIP Lab が集めた商品レビューをもとに、FewCLUE 向けにフィルタリング・検査・再構成した。
- FewCLUE は、中国語の少数例学習を 9 課題で評価するベンチマーク。 EPRSTMT は、その中の商品レビューの感情分析課題に当たる。
- FewCLUE の説明では、元のレビューの収集先や、ラベル付けの具体的な基準までは分からない。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

学習・開発は各 32 件、テストは二種類

用途	レビュー数	正解ラベル
学習用（5 組）	各 32	公開
開発用（5 組）	各 32	公開
公開テスト	610	公開
評価提出用テスト	753	非公開
ラベルなしデータ	19,565	なし

ラベルなしデータは、教師なし学習や半教師あり学習にも利用する。

[1] ICIP Lab / CLUE team (n.d.). EPRSTMT (FewCLUE). GitHub. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/eprstmt

学習する 32 件を変えて、結果の安定性を調べる

- 少数例で学習すると、どのレビューが学習用に選ばれるかによって結果が変わりやすい。そこで、学習用と開発用を 5 組ずつ用意している。
- 各組の 32 件は、肯定的・否定的なレビューを合わせた件数。二つのラベルの内訳は、組によって異なる。
- 5 組をまとめた学習用・開発用ファイルもある。複数の組に共通するレビューがあるため、まとめたファイルには同じ文が含まれる。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498
[2] CLUE team (n.d.). FewCLUE: 小样本学习测评基准 . GitHub. https://github.com/CLUEbenchmark/FewCLUE

評価方法とモデルへの入力

正答率で、感情の分類結果を評価する

- 予測したラベルが正解と一致したレビューの割合を、正答率（Accuracy）として報告する。
- 公開テストは、肯定的 305 件・否定的 305 件の計 610 件。全てに同じラベルを答えた場合の正答率は 50% になる。
- 正解が非公開のテスト 753 件は、評価用の予測を提出するためのもの。公開テストでは、手元で予測と正解を比べられる。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

2021 年の FewCLUE 実験における正答率

学習方法	正答率（%）
通常のファインチューニング	65.4
ゼロショット	85.2
PET	86.7
P-tuning	88.3

いずれも RoBERTa を使った EPRSTMT の報告値。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

人による評価では、正答率 90%

- 人手による EPRSTMT の評価では、テストから選んだ 100 件に対する正答率が 90.0% だった。
- モデルの報告値はテスト全体を対象とするため、人手評価とは対象件数が異なる。短いレビューでも、評価の混在や解釈の揺れが残る。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

少数例を生かす、入力の工夫

- PET は、レビューを穴埋め形式の文にし、感情に対応する語をモデルに選ばせる。公開実装では「不」「很」をラベルに対応させる。
- EFL は、レビューと「肯定的な感情を表す」といった説明文を組にし、その説明が成り立つかを判定する問題へ変換する。
- P-tuning は、モデルへの指示に相当する表現も学習する方法。少数のラベル付きデータから、事前学習したモデルの知識を引き出すことを目指す。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

CLEVA での利用と入手方法

CLEVA では、二つの選択肢から答える

公開されている中国語の設問

这个产品评价是正面还是负面的？
评价：商城就是快好省，快好省
A. 负面
B. 正面
答案：

日本語訳

この商品レビューは肯定的ですか、否定的ですか？
レビュー：この通販サイトは、速い、良い、お得。速い、良い、お得。
A. 否定的
B. 肯定的
答え：

正解： B （肯定的）

[1] Stanford CRFM (n.d.). CLEVASentimentAnalysisScenario. HELM.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

公式配布先と、利用条件

- FewCLUE の公式リポジトリから、 EPRSTMT の学習用・開発用・テスト用データを入手できる。
- 付属する BERT コードには Apache 2.0 が適用される。一方、商品レビュー本文を含むデータ全体の利用条件は明示されていないため、再利用の条件は配布元への確認が必要。
- CLEVA では FewCLUE の感情分析を採用しているが、評価対象のレビュー全体や抽出方法の詳細は公開資料からは確認できない。

[1] CLUE team (n.d.). FewCLUE: 小样本学习测评基准 . GitHub. https://github.com/CLUEbenchmark/FewCLUE
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

JSON ファイルから、レビューとラベルを読む

```
import json
with open('train_0.json', encoding='utf-8') as f:
    review = json.loads(next(f))
print(review['sentence'])
print(review['label'])
```

1 行が 1 件のレビュー。 sentence が本文、 label が Positive または Negative 。

[1] ICIP Lab / CLUE team (n.d.). EPRSTMT (FewCLUE). GitHub. https://github.com/CLUEbenchmark/FewCLUE/tree/main/datasets/eprstmt

短いレビューで、少数例学習の力を測る

- EPRSTMT は、中国語の商品レビューを肯定的・否定的に分類するデータセット。 32 件ずつの小さな学習セットで、少数例から学ぶ方法を評価する。
- 短い文章にも、複数の評価や皮肉が含まれる。良い点と不満の両方があるレビューや、文章の印象とラベルが合いにくい例が、分類の難しさを表している。
- FewCLUE で少数例学習に使われ、 CLEVA では選択式の感情分析にも利用されている。

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

Appendix

1. 追加の商品レビュー
2. 学習方式の比較と参考文献

追加の商品レビュー

実例４：配送への皮肉を読む

中国語原文（全文）

呵呵了 这物流速度也是没谁了 同城网购竟然三天了还不到

日本語訳

いやあ、この配送の遅さにはあきれます。同じ市内なのに、ネットで注文してから３日たっても届きません。

正解：否定的 / Negative

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例５：短い肯定と、今後の試用

中国語原文（全文）

还不错，等试用一段时间再说

日本語訳

悪くありません。しばらく使ってから、また評価します。

正解：肯定的 / Positive

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例 6 ：使わなくても電池がなくなる

中国語原文（全文）

冲满电 2 天没用过就没电　客服说正常的

日本語訳

満充電にしてから 2 日間使っていないのに、電池が切れました。カスタマーサービスは正常だと言っています。

正解：否定的 / Negative

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例７：高齢者にも使いやすい携帯電話

中国語原文（全文）

手机好用，声音大，手写流利，老人非常中意。

日本語訳

携帯電話は使いやすく、音が大きく、手書き入力もスムーズです。高齢の人がとても気に入っています。

正解：肯定的 / Positive

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例８：音や装着感への不満と肯定的ラベル

中国語原文（全文）

耳机做工还行，音效的话没有想象中的那么好，可能需要煲机吧，耳机戴了一两个小时耳朵就有点疼

日本語訳

イヤホンの作りはまあまあです。音は想像していたほどよくなく、慣らし運転が必要なのかもしれません。１、２時間着けると、耳が少し痛くなります。

正解：肯定的 / Positive

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例９：中国製品を応援しつつ、操作に戸惑う

中国語原文（全文）

支持国产，用起来挺好的，操作有点不习惯。

日本語訳

中国製品を応援します。使い心地はよいですが、操作には少し不慣れです。

正解：肯定的 / Positive

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例 10 ：厚さが期待と合わない

中国語原文（全文）

太厚了，和期待值有差距 . 夏天揣口袋里绝对不和谐 . 看来只能应急用用了 .

日本語訳

厚すぎて、期待していたものとは違いました。夏にポケットへ入れたら、どう見ても不格好です。どうやら非常用に使うしかなさそうです。

正解：否定的 / Negative

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例 11 ：使って分かった複数の問題

中国語原文（全文）

用了几天，发现很多问题，无线网容易掉线，屏幕容易刮花，打开网页容易死掉，不值的买

日本語訳

数日使って、多くの問題に気づきました。無線ネットワークは切れやすく、画面は傷つきやすく、ウェブページを開くとフリーズしやすいです。買う価値はありません。

正解：否定的 / Negative

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例 12 ：イヤホンが見当たらず、気分が変わる

中国語原文（全文）

收到手机的时候挺高兴的。 但是我找了半天都没有找到耳机，跟我想象的不太一样 心情立马不好了

日本語訳

携帯電話が届いたときはうれしかったです。でも、ずいぶん探してもイヤホンが見つからず、想像していたものとは少し違いました。たちまち嫌な気分になりました。

正解：否定的 / Negative

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

実例 13 ：イヤホンへの不満と肯定的ラベル

中国語原文（全文）

一分钱一分货嘛，毕竟价格在这里，也不错了，没送耳机，本人不高兴

日本語訳

値段なりですよね。結局この価格ですし、悪くありません。イヤホンが付いてこなかったので、私は不満です。

正解：肯定的 / Positive

[1] CLUE team (n.d.). FewCLUE — EPRSTMT. test_public.json. https://github.com/CLUEbenchmark/FewCLUE/blob/main/datasets/eprstmt/test_public.json

学習方式の比較と参考文献

2021 年：学習方法による成績

学習方法	正答率（%）
LM-BFF / RoBERTa	85.6
EFL / RoBERTa	84.9
通常のファインチューニング / ERNIE1.0	66.5
PET / ERNIE1.0	84.0
P-tuning / ERNIE1.0	80.6
EFL / ERNIE1.0	76.7
ゼロショット / GPT 系	57.5

[1] Xu et al. (2021). FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark. arXiv. https://arxiv.org/abs/2107.07498

参考文献

FewCLUE: A Chinese Few-shot Learning Evaluation Benchmark

Liang Xu et al. · 2021 · arXiv preprint

中国語の少数例学習を 9 課題で比較する研究。 EPRSTMT の構成と学習方式別の評価を報告する。

https://arxiv.org/abs/2107.07498

FewCLUE: 小样本学习测评基准，中文版

CLUE team · n.d. · GitHub

EPRSTMT などの学習・開発・テスト用データと、少数例学習の実装を公開する。

https://github.com/CLUEbenchmark/FewCLUE

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations

中国語の言語モデルを広い課題群で評価する枠組み。商品レビューの感情分析にも FewCLUE を利用する。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVASentimentAnalysisScenario

Stanford CRFM · n.d. · HELM

商品レビューに肯定的・否定的の選択肢を付けた設問例を示す、感情分析課題の実装。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py