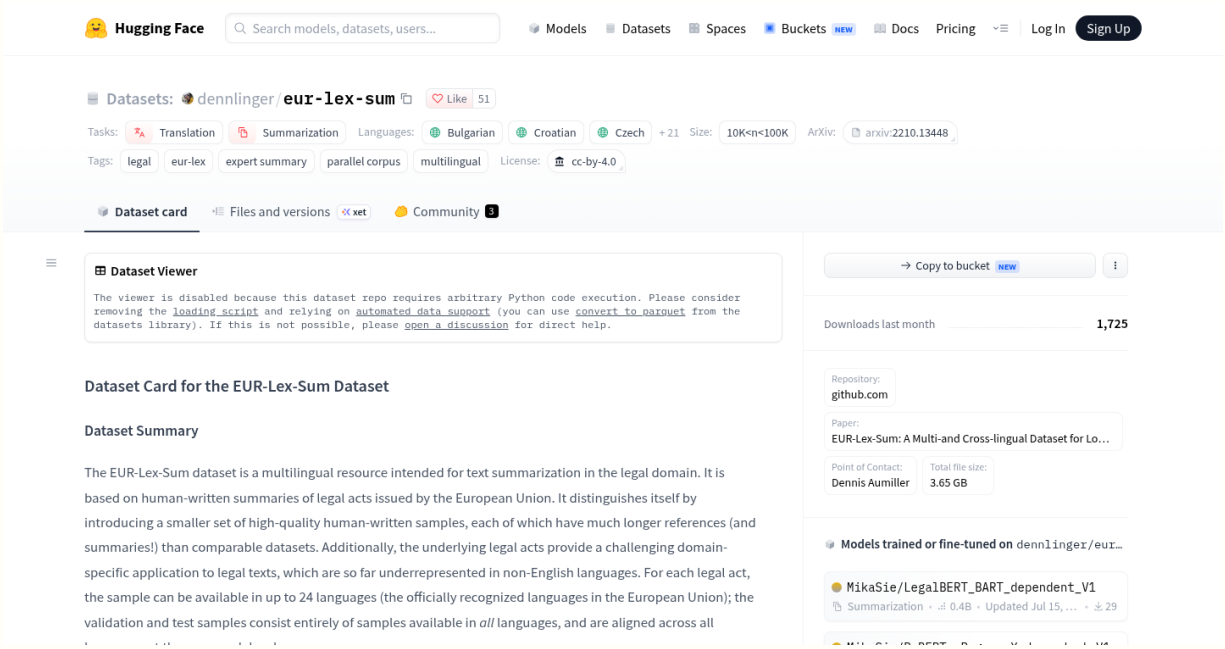
EUR-Lex-Sum

EU 法令と専門家による要約を、 24 言語で結ぶ

sasakiy84

公式配布： EUR-Lex-Sum



[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 公式配布のトップ画面。法令本文・参照要約・ Celex ID を JSONL で公開。
https://huggingface.co/datasets/dennlinger/eur-lex-sum

1. 法令と要約を対応させる
2. 24 言語の収集と分割
3. 長文・言語間要約の評価
4. HELM での範囲と入手

法令と要約を対応させる

長い法令から、制度の要点をまとめる

- EU が公開する法令本文と、人が書いた説明用の要約を組にした、 2022 年のデータセット。
- 入力は法令本文、出力は要約。本文の一部を選ぶ抽出型と、新しい文で書く生成型の両方を評価できる。
- 最大 24 言語で同じ法令と要約が対応し、英語入力から別言語の要約を作る課題にも使う。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

実例は、本文と参照要約の連続抜粋

- 法令本文は数百語から 100 万語超に及ぶ。ここでは条文の一段落と、対応する要約の一節を切り出す。
- 各例には元の全文語数、言語、法令を識別する Celex ID を添える。日本語は表示した範囲の訳である。
- 配布要約は出力の参照例。表示した一段落だけから要約全文を再現する課題ではない。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例１：ユーロ硬貨を二種類に分ける

英語 ／ 全文：入力 1,610 語・要約 698 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
1. Member States may issue two types of euro coin: circulation coins and collector coins.
参照要約の抜粋
Regulation (EU) No 651/2012 defines the types of euro coins and lays down the conditions to be respected at coin issue.

入力の訳
1. 加盟国は、流通用硬貨と収集用硬貨という二種類のユーロ硬貨を発行できる。
参照要約の訳
規則（EU）第 651/2012 号はユーロ硬貨の種類を定義し、発行時に守る条件を定める。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32012R0651 ／ english ／ test row 141 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

条文の規則を、読者向けの説明へ言い換える

- 条文は、加盟国が発行できる硬貨を流通用と収集用に分ける。参照要約は、硬貨の種類と発行条件を定める制度として説明する。
- 入力はこの一段落だけではなく、 1,610 語の法令本文。参照要約も 698 語あり、目的・主要点・用語の説明などを含む。
- 要約全文は二つの規則を説明するが、配布入力には、そのうち長い一つの法令だけが収められている。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例２：人口統計の共通枠組み

ドイツ語 ／ 全文：入力 2,665 語・要約 398 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
Mit dieser Verordnung wird ein gemeinsamer Rechtsrahmen für die Entwicklung, Erstellung und Verbreitung von europäischen Statistiken über Bevölkerung und Lebensereignisse geschaffen.
参照要約の抜粋
Ziel dieser Verordnung ist die Regulierung der Harmonisierung und Bereitstellung von Daten zur Bevölkerung und zu den sie betreffenden Lebensereignissen (d. h. Geburten und Todesfälle).

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32013R1260 ／ german ／ test row 143 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例２：人口統計の共通枠組み（訳）

日本語訳：原文と同じ表示範囲

入力の訳
この規則は、人口と出生・死亡などの人口動態に関する欧州統計の開発・作成・普及のための共通の法的枠組みを設ける。
参照要約の訳
この規則は、人口とそれに関する出来事、すなわち出生と死亡のデータを調和させ、提供するための共通ルールを定めることを目的とする。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32013R1260 ／ german ／ test row 143 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

同じ言語の中でも、専門語を説明し直す

- ドイツ語の条文は、人口と人口動態の統計を作成・普及する共通の法的枠組みを定める。
- 参照要約では、出生と死亡という具体例を添え、どのデータをそろえる制度なのかを説明する。
- これはドイツ語から日本語への翻訳課題ではない。日本語は、この資料で原文を読むために添えた訳である。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例３：持続不可能な漁業への措置：入力

スペイン語 ／ 全文：入力 3,150 語・要約 786 語。表示は入力の連続抜粋。

1. El presente Reglamento establece un marco para la adopción de determinadas medidas relativas a las actividades y las políticas de terceros países relacionadas con la pesca, para garantizar la conservación a largo plazo de las poblaciones de peces de interés común para la Unión y esos terceros países.

1. この規則は、 EU と第三国が共通の利害を持つ魚類資源の長期的な保全を確保するため、漁業に関する第三国の活動と政策を対象とした一定の措置を採る枠組みを定める。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32012R1026 ／ spanish ／ test row 107 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例３：持続不可能な漁業への措置：参照

スペイン語 ／ 全文：入力 3,150 語・要約 786 語。表示は参照要約の連続抜粋。

Este Reglamento establece un sistema que permite a la Unión Europea (UE) adoptar medidas relativas a las actividades y las políticas de determinados países no pertenecientes a la UE que autorizan una pesca no sostenible. Estas medidas están destinadas a ayudar a la conservación de las poblaciones de peces de interés común* tanto para los países de la UE como para los países no pertenecientes a la UE en cuestión.

この規則は、持続不可能な漁業を認める一部の EU 域外国の活動と政策について、 EU が措置を採れる仕組みを設ける。これらの措置は、 EU 諸国と該当する域外国に共通の利害がある魚類資源 * の保全を支援するためのものである。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32012R1026 ／ spanish ／ test row 107 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

複数言語で同じ制度を比較できる

- スペイン語の例は、 EU と域外国が共通の利害を持つ魚類資源の保全を扱う。要約は、持続不可能な漁業を認める国への措置として説明する。
- 同じ Celex ID を使えば、他言語の同じ法令と参照要約へ対応させられる。
- 以下では、言語ごとに量が異なる学習集合と、 24 言語で対応する評価集合の作り方を見る。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

24 言語の収集と分割

既存の EU 法令と要約を収集した

- 2022 年 5 〜 6 月、 EUR-Lex の施行中法令の 20 分野を入口として、法令本文と対応する要約を収集した。
- 法令には言語を越えて共通の Celex ID があり、 HTML の段落構造も対応付けに利用できる。
- 要約と訳文は EU が契約する専門家が作成。データ構築者が全要約を新たに書いたものではない。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

HTML 本文と要約がそろう法令を採る

- 本文の HTML 版と要約が利用できる組を選び、スキャン PDF だけの文書などを除いた。
- 一つの要約が複数の法令を扱う場合には、最長の法令だけを入力として残す。対象によって要約の情報が入力の外にも由来する。
- 最終的に 31,987 の言語別ペアを収録。これは 31,987 件の別々の法令という意味ではない。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

言語ごとに得られる学習量が異なる

言語	全ペア	train
フランス語	1,505	1,130
英語	1,504	1,129
ドイツ語	1,490	1,115
マルタ語	1,315	940
アイルランド語	391	16

validation 187 ／ test 188 は全言語共通。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP.
https://aclanthology.org/2022.emnlp-main.519/

375 法令を、 24 言語共通の評価用に分ける

- 24 言語すべてで本文と要約がそろう 375 法令を取り出し、 187 件を validation 、 188 件を test に無作為に割り当てた。
- 残りは言語ごとの train 。 Celex ID の分割を共有するため、同じ評価対象を言語間で比較できる。
- 今回取得した 8 言語の test は、 188 個の ID と並び順が全件一致した。英語の 3 分割には共通 ID がなかった。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

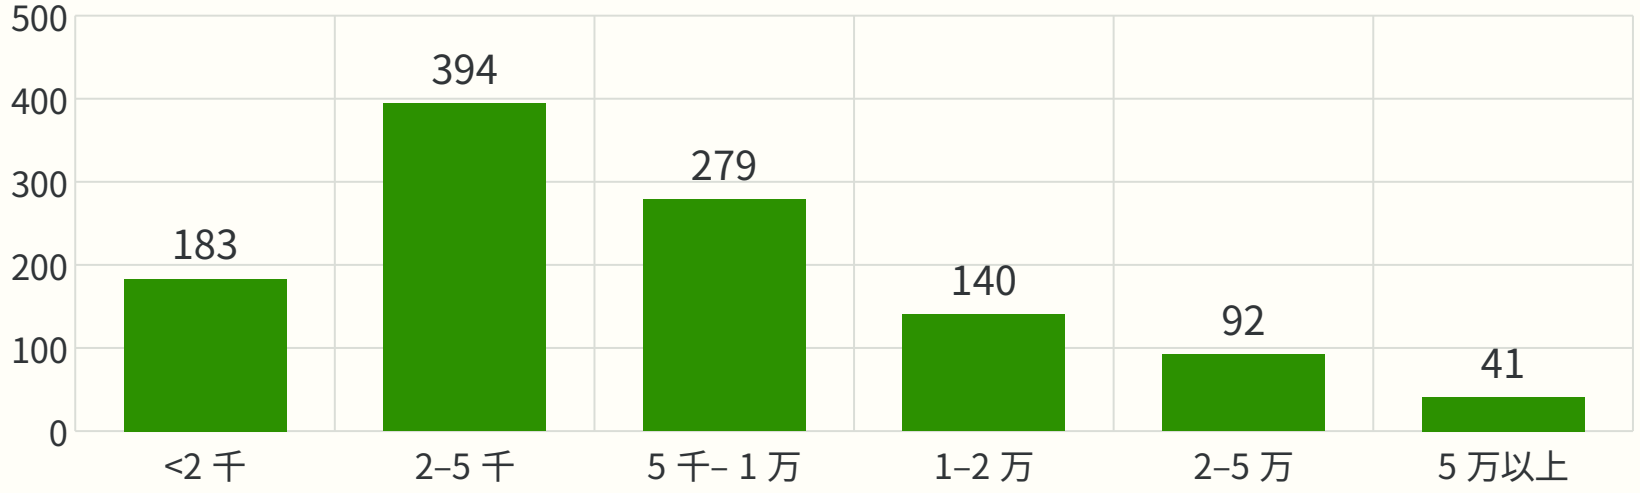
長い入力には、大きなばらつきがある

英語 train ・ 1,129 件	法令本文	参照要約
平均	12,883 語	783 語
中央値	4,818 語	694 語
最大	1,087,217 語	2,930 語

固定 HF 配布を空白区切り str.split() で実測。 2022 年の論文集計とは区別する。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

多くの文書と、非常に長い裾を一緒に見る



英語 train 1,129 件。横軸：空白区切り語数。縦軸：文書数。各階級は左端以上・右端未満。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

長文・言語間要約の評価

ROUGE ：参照要約との表現の重なりを測る

- ROUGE-1 は単語、 ROUGE-2 は連続する二語、 ROUGE-L は順序を保つ共通の語列を手掛かりにする。
- ここで示す 2022 年の成績は F1 。参照をどれだけ含むかと、生成文にどれだけ重なりがあるかを合わせて測る。
- 言語間の比較では語幹処理を無効にした。同じ法令でも、語の分割や言い換えは得点に影響する。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

段落を選ぶ LexRank を、各言語へ適用した

test ・ 188 件 / 言語	ROUGE-1	ROUGE-2	ROUGE-L
英語	26.68	13.65	13.58
ドイツ語	26.72	13.75	12.56
スペイン語	28.34	17.12	15.23
アイルランド語	41.93	17.16	15.25

2022 年の改良 LexRank 、言語ごとの本文→同言語要約。 F1 （％）、語幹処理なし。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

段落の中心性を使い、要約の長さを決める

- 改良 LexRank は、多言語文埋め込みで段落どうしの類似度を求め、中心的な段落を選ぶ抽出型の方式。
- 要約の目標段落数は、各言語の train の段落圧縮率と、入力の段落数から決める。
- 追加学習は行わない。アイルランド語は埋め込みモデルの対応言語外だが、 ROUGE-1 が高く、報告では原因を特定できていない。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

英語からスペイン語の要約を作る

test ・ 188 件	ROUGE-1	ROUGE-2	ROUGE-L
LED→ 西語訳	31.14	13.01	16.20
英語 LexRank→ 西語訳	39.44	20.02	18.73
西語 LexRank	28.34	17.12	15.23
英語参照要約→西語訳	54.55	41.01	45.06

2022 年の英語→スペイン語評価。最下段は人手の英語要約を使う比較用条件。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

要約してから訳す手順と、参照を使う条件

- LED は BillSum で学習したモデル。英語の法令から要約を生成し、 OPUS-MT でスペイン語へ翻訳する。
- 別の条件では、英語 LexRank の出力を翻訳する。公開コードでも、英語要約を読んでから翻訳器へ渡している。
- 人手の英語参照要約を翻訳する条件は、入力法令だけから要約を作る方式とは利用できる情報が異なる。

[1] Aumiller et al., EUR-Lex-Sum. 公式コード・データ・ baseline 。 https://github.com/achouhan93/eur-lex-sum

入力も出力も、長さへの対応が必要

- 法令本文だけでなく、参照要約も数百語以上ある。短い記事から数十語を作る要約とは、情報選択の量が異なる。
- 2022 年の LED 実験は約 4,096 トークンで入力を分割し、区間ごとの要約を連結した。翻訳も約 500 subword 単位で分割した。
- 各条文をつなぐ条件や、複数法令にまたがる要約をどう保持するかが、長文・言語間要約の課題になる。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

HELM での範囲と入手

HELM は英語の本文→要約を実装する

- HELM v0.4.0 の LegalSummarizationScenario は、EurLexSum の english 設定を読み、 reference 欄を入力、summary 欄を参照にする。
- 改行を空白に直し、空白区切りで整形する。doc_max_length を指定した場合は、本文の先頭をその語数まで残す。
- 同じデータで可能な 24 言語の評価と、 HELM が実装している英語の範囲を対応させて読む。

[1] Stanford CRFM, HELM v0.4.0. LegalSummarizationScenario.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/legal_summarization_scenario.py

固定 Classic 版に、公開実行はなかった

- Classic v0.4.0 の公開 run_specs 全 8,526 件を、データ名とシナリオ指定から照合したところ、 EurLexSum の実行は 0 件だった。
- この資料のモデル値は 2022 年の研究で報告された baseline 。 HELM で再実行した値としては扱わない。
- 実装を利用するときは、本文の最大長、学習例の長さによる選別、出力長を設定とともに残す。

[1] HELM Classic v0.4.0 、 2023-11-17 固定版。公開 run_specs 全 8,526 件を検索。 https://crfm.stanford.edu/helm/classic/v0.4.0/

現在は、固定した JSONL を直接取得できる

- Hugging Face に言語別の train ・ validation ・ test を公開。各行は celex_id 、 reference 、 summary を持つ。
- 今回の実例と集計は、配布 revision 33ecb2d を固定して取得した。 13 例の原行と抜粋位置、原文・訳を記録している。
- 公式 GitHub は収集・分析・ baseline コードを公開し、2024 年まで依存関係の更新が確認できた。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

データとコードの利用条件を分けて読む

- 現在の公式 README は、データを CC BY 4.0 、ソフトウェアを MIT と記載する。 EUR-Lex の現行利用条件も確認した。
- Hugging Face の先頭メタデータは CC BY 4.0 だが、カード本文は CC BY-SA 、旧ローダーは CC BY-NC-SA と表記が異なる。
- 利用時点の公式 README と元の EUR-Lex の条件、取得した版の表記を合わせて確認する。

[1] Aumiller et al., EUR-Lex-Sum. 公式コード・データ・ baseline 。 https://github.com/achouhan93/eur-lex-sum

長さ・言語・参照の作り方が評価を決める

- EU 法令の専門家による説明を、最大 24 言語で同じ ID へ対応させることが、このデータの特徴。
- 学習量が少ない言語でも共通の評価対象を持ち、長い本文から長い要約を作る課題を比較できる。
- 入力に残した法令、出力の言語、本文の分割・切り詰めをそろえ、同じ条件の結果を比べる。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

Appendix

1. 追加の実例
2. 言語と統計の補足
3. 研究と参考文献

追加の実例

実例 4 ：四半期ごとの求人統計

フランス語 ／ 全文：入力 2,840 語・要約 937 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
1. Le présent règlement fixe les exigences en matière de production régulière de statistiques trimestrielles sur les emplois vacants dans la Communauté.
参照要約の抜粋
Il fixe les exigences en matière de production régulière de statistiques trimestrielles sur les emplois vacants* dans l’Union européenne (UE).

入力の訳
1. この規則は、欧州共同体において、四半期ごとの求人統計を定期的に作成するための要件を定める。
参照要約の訳
EU において、四半期ごとの求人 * 統計を定期的に作成するための要件を定める。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32008R0453 ／ french ／ test row 155 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 5 ： COVID-19 後の経済回復

イタリア語 ／ 全文：入力 2,778 語・要約 959 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
1. Al fine di sostenere la ripresa all’indomani della crisi COVID-19, il presente regolamento istituisce lo strumento dell’Unione europea per la ripresa («strumento»).
参照要約の抜粋
Il regolamento istituisce lo strumento dell’Unione europea per la ripresa, NextGenerationEU, per promuovere la ripresa economica dopo la crisi COVID-19, e ne definisce la modalità di funzionamento.

入力の訳
1. COVID-19 危機後の回復を支えるため、この規則は EU 復興支援手段（以下「支援手段」）を設ける。
参照要約の訳
この規則は、 COVID-19 危機後の経済回復を促すため、 EU 復興支援手段 NextGenerationEU を設け、その運用方法を定める。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32020R2094 ／ italian ／ test row 70 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 6 ：読書を助ける複製物の交換：入力

アイルランド語 ／ 全文：入力 3,187 語・要約 983 語。表示は入力の連続抜粋。

Leis an Rialachán seo leagtar síos rialacha aonfhoirmeacha maidir leis an malartú trasteorann de chóipeanna i bhformáid inrochtana de shaothair áirithe agus ábhar eile idir an tAontas agus tríú tíortha atá ina bpáirtithe i gConradh Marrakech gan údarú ón sealbhóir cirt, chun leasa daoine dalla, daoine lagamhairc nó daoine atá faoi mhíchumas léitheoireachta cló ar aon bhealach eile, laistigh den réimse atá comhchuibhithe le Treoir 2001/29/CE agus le Treoir (AE) 2017/1564, chun nach ndéanfar an comhchuibhiú ar chearta eisiacha agus eisceachtaí sa mhargadh inmheánach a chur i mbaol.

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32017R1563 ／ irish ／ test row 134 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 6 ：読書を助ける複製物の交換：入力（訳）

日本語訳：原文と同じ表示範囲

この規則は、視覚障害やその他の障害により印刷物を読むことが困難な人の利益のため、 EU とマラケシュ条約の締約国である第三国との間で、一定の著作物その他の対象物をアクセシブルな形式の複製物として、権利者の許諾なしに国境を越えて交換するための統一規則を定める。対象は指令 2001/29/EC と指令（ EU ） 2017/1564 で調和された領域であり、域内市場における排他的権利と例外の調和を損なわないことを目的とする。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32017R1563 ／ irish ／ test row 134 （ 0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 6 ：読書を助ける複製物の交換：参照

アイルランド語 ／ 全文：入力 3,187 語・要約 983 語。表示は参照要約の連続抜粋。

Leagtar amach ann na rialacha maidir leis an dóigh a ndéantar saothair agus ábhar eile* i gcóipeanna i bhformáid inrochtana* a chomhroinnt idir tíortha AE agus tíortha neamh-AE atá ina bpáirtí i gConradh Marrakech, chun leasa daoine dalla, daoine lagamhairc nó daoine atá faoi mhíchumas léitheoireachta cló ar aon bhealach eile, agus gan gá dóibh cead a fháil ón úinéir cóipchirt.

視覚障害やその他の障害により印刷物を読むことが困難な人の利益のため、著作物その他の対象物 * をアクセシブルな形式の複製物 * として、 EU 諸国とマラケシュ条約の締約国である EU 域外国の間で共有する方法を定める。著作権者の許諾を得る必要はない。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32017R1563 ／ irish ／ test row 134 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 7 ：養殖業の統計を集める

ギリシャ語 ／ 全文：入力 3,010 語・要約 740 語。表示は入力と参照要約の連続抜粋。

入力の抜粋

Τα κράτη μέλη υποβάλλουν στην Επιτροπή στατιστικά στοιχεία σχετικά με όλες τις δραστηριότητες του τομέα της υδατοκαλλιέργειας σε γλυκά και αλμυρά νερά στην επικράτειά τους.

参照要約の抜粋

Θεσπίζει κοινό σύστημα για την παραγωγή στατιστικών στοιχείων της ΕΕ για τον τομέα της υδατοκαλλιέργειας*, για την εξέταση και την αξιολόγηση της αγοράς προϊόντων υδατοκαλλιέργειας στο πλαίσιο της ορθής διαχείρισης της κοινής αλιευτικής πολιτικής.

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32008R0762 ／ greek ／ test row 183 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 7 ：養殖業の統計を集める（訳）

日本語訳：原文と同じ表示範囲

入力の訳
加盟国は、自国領域の淡水と海水における養殖部門のすべての活動に関する統計を、欧州委員会に提出する。
参照要約の訳
共通漁業政策の適切な運営の一環として養殖製品市場を調査・評価するため、養殖業 * に関する EU 統計を作成する共通制度を設ける。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32008R0762 ／ greek ／ test row 183 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 8 ：人口・住宅の国勢調査

マルタ語 ／ 全文：入力 2,346 語・要約 906 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
Dan ir-Regolament jistabbilixxi regoli komuni għall-provvista, kull għaxar snin, ta' data komprensiva dwar il-popolazzjoni u d-djar.
参照要約の抜粋
Jistabbilixxi regoli komuni għall-provvediment ta’ statistika taċ-ċensiment dwar il-popolazzjoni u d-djar fl-UE.

入力の訳
この規則は、人口と住宅に関する包括的なデータを 10 年ごとに提供するための共通規則を定める。
参照要約の訳
EU における人口と住宅の国勢調査統計を提供するための共通規則を定める。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32008R0763 ／ maltese ／ test row 73 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 9 ： InvestEU の三つの仕組み：入力

英語 ／ 全文：入力 32,985 語・要約 1,703 語。表示は入力の連続抜粋。

This Regulation establishes the InvestEU Fund, which shall provide for an EU guarantee to support financing and investment operations carried out by the implementing partners that contribute to objectives of the Union’s internal policies.

この規則は、 EU 域内政策の目的に寄与し、実施パートナーが行う資金調達・投資活動を支える EU 保証を提供する、 InvestEU 基金を設ける。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32021R0523 ／ english ／ test row 27 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 9 ： InvestEU の三つの仕組み：参照

英語 ／ 全文：入力 32,985 語・要約 1,703 語。表示は参照要約の連続抜粋。

It establishes the InvestEU programme comprising 3 building blocks:
the InvestEU Fund, providing an EU guarantee to support financing of and investment in internal EU policies;
the InvestEU Advisory Hub, supporting project development, access to finance and capacity-building assistance;
the InvestEU Portal, giving visibility to projects seeking finance and information on investment opportunities.

三つの要素からなる InvestEU プログラムを設ける。
InvestEU 基金： EU 域内政策に関する資金調達と投資を支える EU 保証を提供する。
InvestEU 助言ハブ：事業開発、資金へのアクセス、能力構築支援を行う。
InvestEU ポータル：資金を求める事業を周知し、投資機会の情報を提供する。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32021R0523 ／ english ／ test row 27 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 10 ：中央清算機関の再建と破綻処理

英語 ／ 全文：入力 58,303 語・要約 1,597 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
This Regulation lays down rules and procedures relating to the recovery and resolution of central counterparties (CCPs) authorised in accordance with Regulation (EU) No 648/2012 and rules relating to arrangements with third countries in the field of recovery and resolution of CCPs.
参照要約の抜粋
It lays down rules and procedures for the recovery and resolution of central counterparties (CCPs)*.

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32021R0023 ／ english ／ test row 40 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 10 ：中央清算機関の再建と破綻処理（訳）

日本語訳：原文と同じ表示範囲

入力の訳
この規則は、規則（ EU ）第 648/2012 号に基づいて認可された中央清算機関（ CCP ）の再建と破綻処理の規則・手続、および CCP の再建・破綻処理に関する第三国との取決めの規則を定める。
参照要約の訳
中央清算機関（ CCP ） * の再建と破綻処理の規則・手続を定める。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32021R0023 ／ english ／ test row 40 （ 0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 11 ：離職した労働者を支援する

英語 ／ 全文：入力 12,799 語・要約 866 語。表示は入力と参照要約の連続抜粋。

入力の抜粋

1. This Regulation establishes the European Globalisation Adjustment Fund for Displaced Workers (EGF) for the period of the MFF 2021 to 2027.

参照要約の抜粋

The aim of the regulation is to renew the European Globalisation Adjustment Fund (EGF) for the period covered by the multiannual financial framework (MFF) 2021-2027. Subsequently, the fund has been renamed the European Globalisation Adjustment Fund for Displaced Workers (EGF).

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32021R0691 ／ english ／ test row 67 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 11 ：離職した労働者を支援する（訳）

日本語訳：原文と同じ表示範囲

入力の訳
1. この規則は、 2021 ～ 2027 年の多年次財政枠組み（ MFF ）の期間について、離職労働者のための欧州グローバル化調整基金（ EGF ）を設ける。
参照要約の訳
この規則は、 2021 ～ 2027 年の多年次財政枠組み（ MFF ）の期間について、欧州グローバル化調整基金（ EGF ）を更新することを目的とする。これに伴い、基金は「離職労働者のための欧州グローバル化調整基金（ EGF ）」へ改称された。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32021R0691 ／ english ／ test row 67 （ 0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 12 ：香味付けワインの表示規則

英語 ／ 全文：入力 11,607 語・要約 424 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
1. This Regulation lays down rules on the definition, description, presentation and labelling of aromatised wine products as well as on the protection of geographical indications of aromatised wine products.
参照要約の抜粋
This regulation stipulates the specifications of aromatised wine products and protection of their geographical indications.

入力の訳
1. この規則は、香味付けワイン製品の定義、説明、提示、表示に関する規則と、その地理的表示の保護に関する規則を定める。
参照要約の訳
香味付けワイン製品の仕様と、その地理的表示の保護を定める。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32014R0251 ／ english ／ test row 85 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

実例 13 ：教育と生涯学習の統計

英語 ／ 全文：入力 3,340 語・要約 725 語。表示は入力と参照要約の連続抜粋。

入力の抜粋
This Regulation establishes a common framework for the systematic production of Community statistics in the field of education and lifelong learning.
参照要約の抜粋
It establishes a common framework on statistical standards for the production of harmonised data in the area of education and lifelong learning.

入力の訳
この規則は、教育と生涯学習の分野で欧州共同体の統計を体系的に作成するための共通枠組みを設ける。
参照要約の訳
教育と生涯学習の分野で調和されたデータを作成するため、統計基準の共通枠組みを設ける。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 32008R0452 ／ english ／ test row 180 （0 始まり）
https://huggingface.co/datasets/dennlinger/eur-lex-sum

言語と統計の補足

24 言語の全内訳（1/4）

言語	全ペア	train
英語 (en)	1,504	1,129
フランス語 (fr)	1,505	1,130
ドイツ語 (de)	1,490	1,115
スペイン語 (es)	1,487	1,112
イタリア語 (it)	1,403	1,028
ポルトガル語 (pt)	1,376	1,001

validation 187 ／ test 188 は全言語共通。 2022 年公表。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

24 言語の全内訳（ 2/4 ）

言語	全ペア	train
オランダ語 (nl)	1,376	1,001
デンマーク語 (da)	1,377	1,002
ギリシャ語 (el)	1,366	991
フィンランド語 (fi)	1,366	991
スウェーデン語 (sv)	1,362	987
ルーマニア語 (ro)	1,353	978

validation 187 ／ test 188 は全言語共通。 2022 年公表。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

24 言語の全内訳（3/4）

言語	全ペア	train
ハンガリー語 (hu)	1,336	961
チェコ語 (cs)	1,359	984
ポーランド語 (pl)	1,353	978
ブルガリア語 (bg)	1,332	957
ラトビア語 (lv)	1,334	959
スロベニア語 (sl)	1,332	957

validation 187 ／ test 188 は全言語共通。 2022 年公表。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

24 言語の全内訳（ 4/4 ）

言語	全ペア	train
エストニア語 (et)	1,332	957
リトアニア語 (lt)	1,335	960
スロバキア語 (sk)	1,325	950
マルタ語 (mt)	1,315	940
クロアチア語 (hr)	1,278	903
アイルランド語 (ga)	391	16

validation 187 ／ test 188 は全言語共通。 2022 年公表。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

英語の長さ：公表値と固定配布の実測

対象	2022 年公表	今回の固定配布
train 本文・平均	12,206	12,883
train 要約・平均	799	783
test 本文・最大	403,319	429,593
test 要約・最大	2,987	3,031

単位：空白区切り語。配布版・集計前処理の同一性は確認できず、差の原因は断定しない。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

法令の古さと、言語のそろい方を分ける

- 公表分析では、収録法令は 1990 年以降に増える。 HTML での公開と要約の利用可能性に依存する。
- 24 言語をそろえる validation/test は、 train より新しい法令に偏る。翻訳や要約は、法令の初回公開より後に追加される場合もある。
- 法令の年、要約の更新日、データ取得日を、同じ時点とみなさない。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

一つの要約に、複数の法令が対応する

- 言語によって約 20 〜 30% の要約が複数法令を扱うと報告されている。配布では最長の法令だけを残す。
- 入力中にない語句を含む割合には、言い換えだけでなく、入力から除かれた法令の内容も影響し得る。
- 現在の英語 train には、空白区切りで数えると、法令本文より要約の方が長い組が 1 件含まれる。

[1] Aumiller et al., EUR-Lex-Sum. 固定 HF revision 33ecb2d 、 test 実レコード。 https://huggingface.co/datasets/dennlinger/eur-lex-sum

三つの欄と、 HELM への変換

```
row = json.loads(line)
celex_id = row["celex_id"]
article = " ".join(row["reference"].split())
summary = " ".join(row["summary"].split())
# optional: article = " ".join(article.split()[:N])
```

実際の入力は法令本文全体。スライドの抜粋位置は記録から元の文字列へ照合できる。

[1] Stanford CRFM, HELM v0.4.0. LegalSummarizationScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/legal_summarization_scenario.py

研究と参考文献

Aumiller・Chouhan・Gertz の研究

- Dennis Aumiller と Ashish Chouhan は共同第一著者。Michael Gertz とともに、ハイデルベルク大学のデータベースシステム研究グループで制作した。
- Chouhan が収集用 crawler を実装し、 Aumiller がフィルタリングと修正を担当したと配布カードに記載されている。
- EMNLP 2022 で発表。多言語の法令要約を、長文・低資源言語・言語間生成の研究につなげた。

[1] Aumiller, Chouhan & Gertz (2022), EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain. EMNLP. https://aclanthology.org/2022.emnlp-main.519/

参考文献

EUR-Lex-Sum: A Multi- and Cross-lingual Dataset for Long-form Summarization in the Legal Domain

Dennis Aumiller, Ashish Chouhan, Michael Gertz (2022) ／ EMNLP

24 言語の法令要約の収集・分割、長さと抽象性の分析、同言語と言語間の baseline を報告。

https://aclanthology.org/2022.emnlp-main.519/

EUR-Lex-Sum ：公式コードとデータ

Aumiller et al. ／公式 GitHub ・ Hugging Face

収集・分析・ LexRank のコードと、言語別の本文・要約・ Celex ID を公開する。

https://github.com/achouhan93/eur-lex-sum

参考文献

ROUGE: A Package for Automatic Evaluation of Summaries

Chin-Yew Lin (2004) ／ Text Summarization Branches Out

参照要約と生成要約の語や語列の重なりを使い、複数の自動評価指標を定義する。

https://aclanthology.org/W04-1013/

LegalSummarizationScenario

Stanford CRFM ／ HELM v0.4.0

BillSum ・ MultiLexSum ・ EurLexSum を共通形式へ変換し、文書長と訓練例の選別を指定する実装。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/legal_summarization_scenario.py