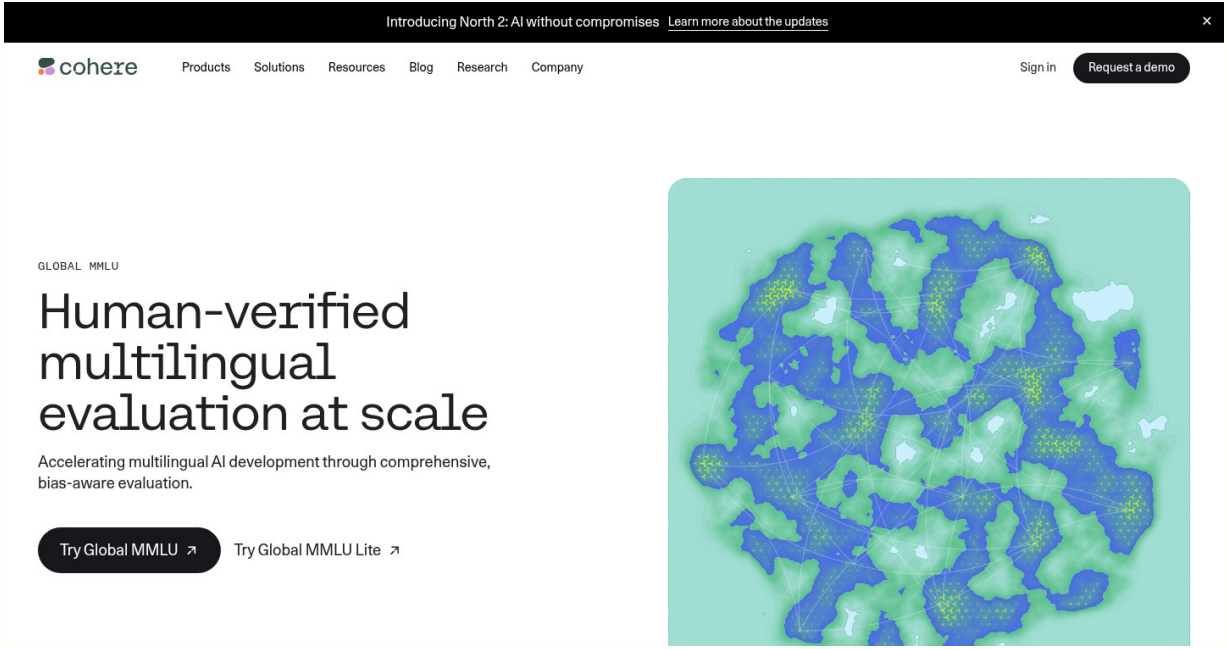
Global-MMLU

MMLU: Massive Multitask Language Understanding

42 言語で知識を問う評価と、文化への依存性

sasakiy84

Global-MMLU の公式サイト



[1] Cohere Labs, Global MMLU （2026-10-21 参照）
https://cohere.com/research/globalmmlu

1. 多言語の設問と文化の知識
2. 翻訳・注釈とデータの構成
3. 正答率と文化依存性の分析
4. 現在の利用と入手方法

1. 多言語の設問と文化の知識

設問と 4 選択肢を読み、正解の記号を答える

- Global-MMLU は、 57 科目の知識を問う MMLU の設問を 42 言語へ広げた評価データである。モデルは設問と A ～ D の選択肢を読み、一つの答えを選ぶ。
- 文化・地域・方言の知識が正解に必要かという注釈を加え、言語ごとの正答率と、問われる知識の性質をあわせて調べられる。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

翻訳した設問にも、元の社会や制度が残る

- MMLU には米国の歴史・法律・会計など、特定の社会を前提とする設問がある。日本語やスワヒリ語へ訳しても、知識の対象がその言語の地域へ変わるわけではない。
- Global-MMLU は翻訳品質を改善すると同時に、こうした文化への依存性を注釈した。単なる言語別の順位から、何を知っていると解けるかへ分析を広げる。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

例 1 アウグストゥスの神性

配布原文（フランス語・全文 / CS ）

Le numen d’Auguste faisait référence à l’une des caractéristiques suivantes. Laquelle ?
A. Pouvoir divin
B. Virilité sexuelle
C. Perspicacité militaire
D. Intellect philosophique

日本語訳（本資料）

アウグストゥスのヌーメンは、次のどの特性を指したか。
A. 神的な力
B. 性的な活力
C. 軍事的な才覚
D. 哲学的な知性

正解： A　神的な力

[1] Cohere Labs, Global-MMLU / fr / world_religions/test/170
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/fr/test?row=14041

例 1 訳す言語と、問われる文化は別に見える

- ヌーメンは神的な力や意思を表す語。ローマの皇帝崇拝に関する文化的知識が必要になる。
- この問題の配布注釈は CS （ Culturally Sensitive ）。フランス語の設問でも、問われるのは古代ローマの宗教・政治に関する知識である。

[1] Cohere Labs, Global-MMLU / fr / world_religions/test/170
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/fr/test?row=14041

例２ 尿をためる器官：原文

配布原文（スワヒリ語・全文 / CA ）

Ni muundo gani kati ya yafuatayo unafafanua vyema muundo unaokusanya mkojo mwilini?
A. Kibofu cha mkojo
B. Figo
C. Kojojito
D. Mrija wa mkojo

正解： A　Kibofu cha mkojo

[1] Cohere Labs, Global-MMLU / sw / anatomy/test/2
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/sw/test?row=102

例２ 尿をためる器官：日本語訳

体内で尿をためる構造を最も適切に表すものはどれか。
A. 膀胱
B. 腎臓
C. 尿管
D. 尿道

正解： A　膀胱

[1] Cohere Labs, Global-MMLU / sw / anatomy/test/2
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/sw/test?row=102

例３ 北へ進むと北極星はどう見えるか：原文

配布原文（ヒンディー語・全文 / CS）

संयुक्त राज्य अमेरिका से कनाडा में उत्तर की यात्रा करते समय आपको नॉर्थ स्टार (पोलारिस) _____ होता हुआ दिखेगा।
A. अधिक चमकदार
B. अधिक धुंधला
C. आकाश में और ऊपर
D. आकाश में और नीचे

正解： C　आकाश में और ऊपर

[1] Cohere Labs, Global-MMLU / hi / astronomy/test/58
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/hi/test?row=293

例 3 北へ進むと北極星はどう見えるか：日本語訳

米国からカナダへ北上すると、北極星はどのように見えるか。
A. 明るくなる
B. 暗くなる
C. 空の中で高くなる
D. 空の中で低くなる

正解： C　空の中で高くなる

[1] Cohere Labs, Global-MMLU / hi / astronomy/test/58
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/hi/test?row=293

CS は文化・地域・方言のいずれかに依存する

- CS （ Culturally Sensitive ）は、特定の文化、地域、英語の方言の知識が答えに必要だと注釈された設問である。 CA （ Culturally Agnostic ）は、そのいずれも必要とされなかった設問である。
- 膀胱を選ぶ例 2 は CA 、米国からカナダへの移動を含む例 3 は CS 。 CS には宗教や制度に加え、地域の位置関係を含む問題も入る。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

2. 翻訳・注釈とデータの構成

同じ 14,042 問を、 42 言語で配布する

分割	問数／言語	42 言語の件数
test	14,042	589,764
dev	285	11,970

test を評価に、 dev を回答例の提示に使う。翻訳版を含むレコード数である。

[1] Cohere Labs, Global-MMLU Dataset Card （2026-10-21 参照）
https://huggingface.co/datasets/CohereForAI/Global-MMLU

英語に加え、 41 言語の翻訳を組み合わせた

- 日本語・中国語・アラビア語などの利用者が多い言語から、ヨルバ語・イボ語・チェワ語などまでを含む。 42 言語の設問を、共通の問題 ID で対応させている。
- 内容は代数・物理・医学・法律・歴史・宗教など 57 科目。初等教育から大学・専門職向けまで、幅広い水準の知識を問う。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

42 言語を 4 種類の出所で構成した

出所	言語数	作成・確認の方法
英語の MMLU	1	元の英語問題
人手翻訳・専門家の修正	14	MMMLU の 10 言語＋独自の 4 言語
コミュニティの修正	11	母語話者が一部の機械翻訳を修正
機械翻訳	16	Google Translate による翻訳

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

専門家と母語話者が翻訳の意味を確認した

- アラビア語・フランス語・ヒンディー語・スペイン語では、有償の専門作業者が機械翻訳を読み、必要な修正を加えた。
- 別の 11 言語では、コミュニティの母語話者が英語と翻訳を比べ、意図が伝わらない箇所を修正した。各言語で 50 件以上の人手翻訳・修正を得たものを採用した。
- 残りの人手翻訳 10 言語には OpenAI の MMMLU を使った。日本語・スワヒリ語・ヨルバ語などがここに含まれる。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

文化への依存性は、英語の 2,850 問へ注釈した

- 57 科目から 50 問ずつ抽出し、英語の設問と回答に文化・地域・方言の知識が必要かを人手で判断した。研究には、有償作業者とコミュニティの計 200 人が参加した。
- 各問を最低 3 人が確認し、半数以上の作業者が付けたタグを採用した。三つの知識のいずれかが必要なら CS 、どれも該当しなければ CA となる。
- この注釈を、同じ問題に対応する 41 言語の翻訳へ引き継いだ。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

文化注釈は、全 test の一部に付いている

test 内の範囲	問題数	割合 (%)
文化・地域・方言に依存： CS	792	5.6
上記に依存しない： CA	2,058	14.7
文化注釈の対象外	11,192	79.7

注釈済み 2,850 問の中では、 CS が 27.8% 、 CA が 72.2% を占める。

[1] Cohere Labs, Global-MMLU Dataset Card （2026-10-21 参照）
https://huggingface.co/datasets/CohereForAI/Global-MMLU

注釈値をたどり、判断の根拠も調べられる

- 配布データには、正解の記号に加えて、作業者ごとの知識タグ、文化名、地域・国、時間による変化の有無、参照した表現が入る。
- 例えばアウグストゥスの問題では、文化の候補として Western Culture 、地域として Europe や North America 、国として Italy が記録されている。複数の作業者の判断を残している。

[1] Cohere Labs, Global-MMLU / fr / world_religions/test/170
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/fr/test?row=14041

MMMLU の翻訳に、言語と文化注釈を追加した

対象	翻訳の範囲	文化注釈
MMLU	英語の 57 科目	なし
OpenAI MMMLU	14 言語へ専門翻訳	なし
Global-MMLU	英語を含む 42 言語	2,850 問に CS / CA など

Global-MMLU は MMMLU の 10 言語を利用し、 4 言語は独自に専門家が修正した。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

3. 正答率と文化依存性の分析

正解記号との一致を、正答率として集計する

- 一つの問題で、モデルが選んだ A ～ D と配布正解が一致すれば 1 、不一致なら 0 とする。集合内で平均し、正答率を百分率で報告する。
- 公開時の研究は、 14 モデル・ 9 系列を 5-shot で評価した。 5-shot とは、設問の前に正解付きの例を 5 件示す設定である。
- 公開モデルには選択肢の尤度、 API 経由のモデルには生成した回答記号を使った。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

公開時の分析では、 CS の成績のほうが高かった

公開モデルの規模	CA 正答率 (%)	CS 正答率 (%)
小規模モデル群	51.3	54.8
中規模モデル群	59.1	61.7
大規模モデル群	61.6	66.8

2024/2025 年の研究で報告されたモデル群の平均。 5-shot 評価、非公開モデルは除く。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

CS と CA は、科目の構成も異なる

- CS には人文・社会科学の設問が多く、 CA には STEM や医学の設問が多い。研究では前者の正答率が高い傾向があった。
- 一方で、言語間の成績のばらつきは CS のほうが大きく、CS ・ CA を切り替えるとモデルの順位も動いた。
- 文化への依存性を切り口に加えると、全体平均だけでは見えにくい成績の差を調べられる。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

Fable 5.1 は 42 言語の GMMLU で 94.0%

モデル	平均正答率 (%)
Claude Fable 5.1	94.0
Claude Fable 5	93.6
Claude Opus 5	92.5
Claude Sonnet 5	89.0

2026 年の System Card 。 adaptive thinking ・ max effort 、各モデル 1 試行。

[1] Anthropic (2026), Claude Fable 5.1 & Mythos 5.1 System Card
https://www.anthropic.com/claude-fable-and-mythos-5-1

文化別の分析と、全体の到達水準を使い分ける

- 公開時の研究は CS ・ CA によるモデル挙動の違いを調べた。 Fable 5.1 の System Card は、 42 言語にわたる平均正答率を報告している。
- 全体の正答率は多言語で知識を選べる水準を示す。文化・地域の知識への依存性を調べたいときは、注釈された CS ・ CA の部分集合を選ぶ。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

[2] Anthropic (2026), Claude Fable 5.1 & Mythos 5.1 System Card
https://www.anthropic.com/claude-fable-and-mythos-5-1

4. 現在の利用と入手方法

英語の知識評価から、翻訳と文化の分析へ広がった

公開時点	データと役割
2020/2021 年	MMLU ：英語で 57 科目の知識を評価
2024 年 9 月	MMMLU ： 14 言語の専門翻訳を公開
2024 年 12 月	Global-MMLU ： 42 言語と文化注釈を公開
2026 年	Fable 5.1 ： 42 言語の平均正答率を報告

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

[2] Anthropic (2026), Claude Fable 5.1 & Mythos 5.1 System Card
https://www.anthropic.com/claude-fable-and-mythos-5-1

言語と分割を選び、設問とラベルを確認する

```
from datasets import load_dataset

ds = load_dataset("CohereForAI/Global-MMLU",
                  "sw", split="test")
r = ds[0]
print(r["question"], r["answer"])
print(r["cultural_sensitivity_label"])
```

sw はスワヒリ語。 CS / CA を絞る前に、 is_annotated で注釈の有無を確認する。

[1] Cohere Labs, Global-MMLU Dataset Card （2026-10-21 参照）
https://huggingface.co/datasets/CohereForAI/Global-MMLU

言語と分割を選び、 Parquet で入手する

- 公式配布先は Hugging Face 。言語ごとに dev ・ test を選べる。申請なしで取得でき、 Apache License 2.0 で利用・改変・配布できる。
- 1 言語の test は 14,042 問。配布 Parquet の容量は、英語が約 3.73 MiB 、日本語が約 4.16 MiB である。
- 全 test は広い科目の多言語評価、 CS ・ CA は文化への依存性の分析に使える。

[1] Cohere Labs, Global-MMLU Dataset Card （2026-10-21 参照）
https://huggingface.co/datasets/CohereForAI/Global-MMLU

42 言語の知識評価に文化注釈を加えた

- 共通の 14,042 問を 42 言語に展開し、言語による成績の違いを調べる。人手翻訳・専門家やコミュニティの修正・機械翻訳を組み合わせている。
- 2,850 問の文化注釈により、宗教・制度・地域・方言の知識が関わる CS と、該当しない CA を分析できる。
- 言語を増やすことと、問われる文化を増やすことの違いを、具体的な設問と注釈から確かめられる。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

Appendix

1. 言語と内容の異なる追加例
2. 注釈の内訳と評価条件
3. 参考文献

例 4 マシアハの語義

配布原文（ヨルバ語・全文 / CS ）

Kí ni ọ̀rọ̀ Hébérù mèsáyà túmọ̀ sí?
A. Ẹni àmì òróró
B. Ọlọ́run
C. Wòlíì
D. Ìlà ti Dáfídì

日本語訳（本資料）

ヘブライ語の mashiach は何を意味するか。
A. 油を注がれた者
B. 神
C. 預言者
D. ダビデの家系

正解： A　油を注がれた者

[1] Cohere Labs, Global-MMLU / yo / world_religions/test/26
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/yo/test?row=13897

例 5 二本の剣を帯びたグル：原文

配布原文（ヒンディー語・全文 / CS ）

किस गुरु ने लौकिक और आध्यात्मिक सत्ता के प्रतीक के रूप में दो तलवारें धारण कीं?
A. गुरु नानक
B. गुरु अर्जन
C. गुरु हरगोबिंद
D. गुरु राम दास

正解： C　गुरु हरगोबिंद

[1] Cohere Labs, Global-MMLU / hi / world_religions/test/57
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/hi/test?row=13928

例 5 二本の剣を帯びたグル：日本語訳

世俗的権威と精神的権威を象徴する二本の剣を帯びたのは、どのグルか。
A. グル・ナーナク
B. グル・アルジャン
C. グル・ハルゴービンド
D. グル・ラーム・ダース

正解： C　グル・ハルゴービンド

グルはシク教の指導者。二本の剣は世俗と精神の権威を表す。

[1] Cohere Labs, Global-MMLU / hi / world_religions/test/57
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/hi/test?row=13928

例 6 米国で宣戦の権限を持つ機関：原文

配布原文（スペイン語・全文 / CS ）

En el gobierno de los Estados Unidos, el poder de declarar la guerra recae sobre:
A. el Presidente de los Estados Unidos;
B. el Ministerio de Defensa;
C. el presidente del Estado Mayor Conjunto;
D. el Congreso.

正解： D　el Congreso.

[1] Cohere Labs, Global-MMLU / es / us_foreign_policy/test/9
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/es/test?row=13614

例 6 米国で宣戦の権限を持つ機関：日本語訳

米国政府で、宣戦を行う権限を持つのは誰か。
A. 米国大統領
B. 国防省
C. 統合参謀本部議長
D. 連邦議会

正解： D　連邦議会

[1] Cohere Labs, Global-MMLU / es / us_foreign_policy/test/9
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/es/test?row=13614

例 7 地域の呼び名が指す道具

配布原文（英語・全文 / CS ）

The 'Arkansas toothpick' is better known by what name?
A. Scottie Pippen
B. spare rib
C. pinkie finger
D. Bowie knife

日本語訳（本資料）

「 Arkansas toothpick 」は、どの名前でよく知られているか。
A. スコッティ・ピッペン
B. スペアリブ
C. 小指
D. ボウイナイフ

正解： D　ボウイナイフ

Arkansas toothpick は、大型ナイフの地域的な呼び名。

[1] Cohere Labs, Global-MMLU / en / miscellaneous/test/648
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/en/test?row=8032

例 8 カントが考える行為の道徳的価値：原文

配布原文（フランス語・全文 / CS ）

Selon Kant, la valeur morale d’une action dépend :
A. du caractère moral de l’agent qui l’exécute.
B. des conséquences de l’action.
C. de la maxime sur laquelle se base l’action.
D. toutes les propositions ci-dessus.

正解： C　de la maxime sur laquelle se base l’action.

[1] Cohere Labs, Global-MMLU / fr / philosophy/test/85
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/fr/test?row=9799

例 8 カントが考える行為の道徳的価値：日本語訳

カントによると、行為の道徳的価値は何に依存するか。
A. 行為者の道徳的な性格
B. 行為がもたらす結果
C. その行為が従う格率
D. 上のすべて

正解： C　その行為が従う格率

格率は、行為するときに自分が従う主観的な原則を指す。

[1] Cohere Labs, Global-MMLU / fr / philosophy/test/85
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/fr/test?row=9799

例 9 インカの軍事的拡大

配布原文（スワヒリ語・全文 / CS ）

Inca ilianza lini upanuzi wake wa kijeshi kote Amerika Kusini?
A. 200 A.D.
B. 900 A.D.
C. 1450 A.D.
D. 1650 A.D.

日本語訳（本資料）

インカが南米各地への軍事的拡大を始めたのはいつか。
A. 西暦 200 年
B. 西暦 900 年
C. 西暦 1450 年
D. 西暦 1650 年

正解： C　西暦 1450 年

[1] Cohere Labs, Global-MMLU / sw / prehistory/test/254
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/sw/test?row=10279

例 10 乗法群における逆元

配布原文（スペイン語・全文 / CA ）

El inverso de -i en el grupo multiplicativo, {1, -1, i, -i} es
A. 1
B. -1
C. i
D. -i

日本語訳（本資料）

乗法群 {1, −1, i, −i} において、− i の逆元はどれか。
A. 1
B. −1
C. i
D. −i

正解： C　 i

[1] Cohere Labs, Global-MMLU / es / abstract_algebra/test/16
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/es/test?row=16

例 11 太陽系で二番目に多い元素

配布原文（ヨルバ語・全文 / CA ）

Kí ni ẹ́límẹ́ntì kejì tó wọ́pọ̀ jù nínú ètò ìyíká òrùn?
A. Irin
B. Olù-omi
C. Mẹ̀tánì
D. Ìlíọ́mù

日本語訳（本資料）

太陽系で二番目に多い元素は何か。
A. 鉄
B. 水素
C. メタン
D. ヘリウム

正解： D　ヘリウム

[1] Cohere Labs, Global-MMLU / yo / astronomy/test/8
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/yo/test?row=243

例 12 米国の司法部門の役割：原文

配布原文（ヒンディー語・全文 / CS）

संयुक्त राज्य अमरीका की सरकार की न्यायिक शाखा के पास कानून _____ की शक्ति होती है।
A. की व्याख्या करने
B. बनाने
C. का प्रवर्तन करने
D. की अवहेलना करने

正解： A　की व्याख्या करने

[1] Cohere Labs, Global-MMLU / hi / jurisprudence/test/78
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/hi/test?row=6642

例 12 米国の司法部門の役割：日本語訳

米国政府の司法部門は、法律をどのように扱う権限を持つか。
A. 解釈する
B. 制定する
C. 執行する
D. 無視する

正解： A　解釈する

[1] Cohere Labs, Global-MMLU / hi / jurisprudence/test/78
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/hi/test?row=6642

例 13 銀河系中心のブラックホール

配布原文（日本語・全文 / CA）

天の川銀河の中心にあるブラックホールの名前は次のうちどれか？
A. アルタイル A*
B. アルセフィナ A*
C. フォーマルハウト A*
D. サギタリウス A*

正解： D　サギタリウス A*

[1] Cohere Labs, Global-MMLU / ja / astronomy/test/41
https://huggingface.co/datasets/CohereForAI/Global-MMLU/viewer/ja/test?row=276

注釈済み 2,850 問は 6 分野に分かれる

分野	問数	CS	CA
STEM	950	23	927
人文	650	442	208
社会科学	600	208	392
医学	350	19	331
ビジネス	200	36	164
その他	100	64	36

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

Global-MMLU Lite 3.0 は 23 言語を収録する

- 初版（2024 年 12 月）は 15 言語、CS200 問＋ CA200 問／言語の計 6,000 レコード。人手翻訳・修正済みの小規模版として公開した。
- 2.0 （2025 年 12 月）は 3 言語を追加。 3.0 （2026 年 5 月）はチェコ語・ハンガリー語・オディア語・スロバキア語・タジク語を追加し、イタリア語を更新した。
- 現行 3.0 の test は 23 言語・ 9,200 レコード。論文の Lite 評価は初版の 15 言語の結果である。

[1] Cohere Labs, Global-MMLU-Lite Dataset Card / Version 3.0 （2026-10-21 参照）
https://huggingface.co/datasets/CohereLabs/Global-MMLU-Lite

注釈は英語の設問に対する作業者の判断である

- 文化・地域・方言への依存性は、英語の設問を見て判定し、そのラベルを翻訳へ引き継いだ。言語ごとに別々の文化注釈を収集した設計ではない。
- 作業者間の一致度は科目で異なり、解剖学では文化依存の判断が一致した一方、道徳的状況判断などでは判断が分かれた。
- 英語の MMLU が問う知識の偏りを、 42 言語への翻訳と文化注釈によって可視化したデータである。

[1] Singh et al. (2024/2025), Global MMLU
https://arxiv.org/abs/2412.03304

参考文献

Global MMLU: Understanding and Addressing Cultural and Linguistic Biases in Multilingual Evaluation

Shivalika Singh et al. / 2024, revised 2025 / arXiv:2412.03304

42 言語への翻訳と、文化・地域・方言への依存性を調べた研究。

https://arxiv.org/abs/2412.03304

Global-MMLU Dataset Card

Cohere Labs / n.d. / Hugging Face / 2026-10-21 参照

言語別のデータ、文化注釈のフィールド、利用条件を公開。

https://huggingface.co/datasets/CohereForAI/Global-MMLU

参考文献

Measuring Massive Multitask Language Understanding

Dan Hendrycks et al. / ICLR 2021 / arXiv:2009.03300

57 科目にわたる英語の知識評価 MMLU を提案。

https://arxiv.org/abs/2009.03300

MMMLU Dataset Card

OpenAI / 2024 / Hugging Face

MMLU の test を専門翻訳者が 14 言語へ翻訳した配布物。

https://huggingface.co/datasets/openai/MMMLU

参考文献

Claude Fable 5.1 & Mythos 5.1 System Card

Anthropic / 2026

GMMLU の 42 言語の平均正答率と、評価時の思考設定を報告。

https://www.anthropic.com/claude-fable-and-mythos-5-1

Global-MMLU-Lite Dataset Card

Cohere Labs / Version 3.0, May 2026 / Hugging Face

23 言語の Lite 3.0 と、公開版ごとの言語追加を記載する。

https://huggingface.co/datasets/CohereLabs/Global-MMLU-Lite