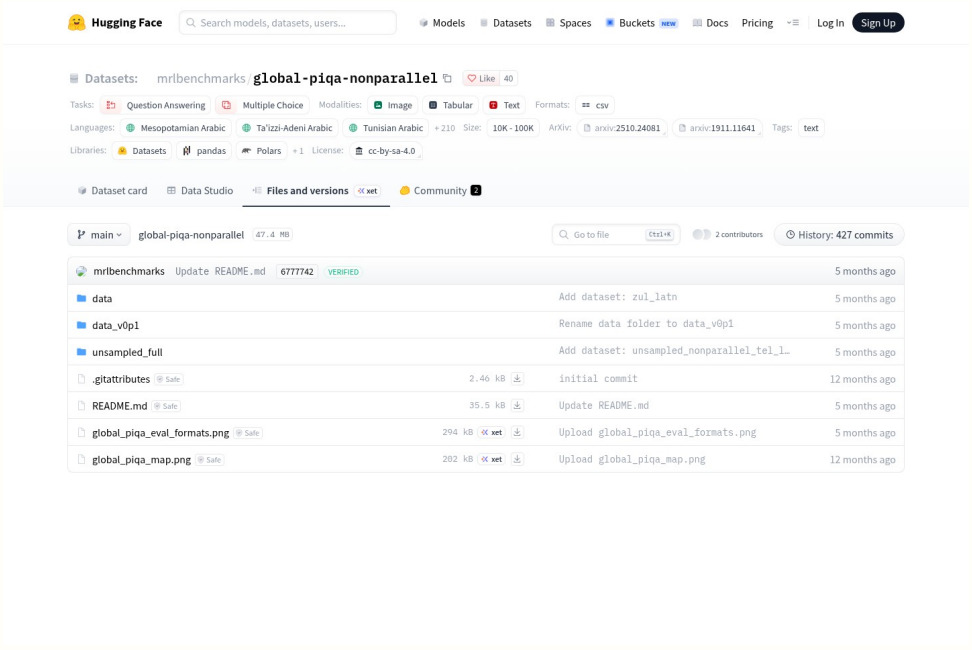
# Global PIQA

PIQA = Physical Interaction: Question Answering

言語と文化に根ざした日常の常識を測る
100 以上の言語へ広がる選択式問題

sasakiy84

# Global PIQA の公式配布ページ




Global PIQA contributors. Non-Parallel v1 / 改訂 6777742 / CC BY-SA 4.0 。 https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

1. 文化と言語に根ざした常識問題

2. 採点とモデルの成績

3. 作成方法とバージョン

4. 入手と使い分け

# 1. 文化と言語に根ざした常識問題

# 日常の場面で、どちらの行動や説明が適切か

- Global PIQA は、日用品・食事・住居・慣習などの常識を測るデータセット。地域と言語の話者が、自分たちの暮らしに即した問題を作る。
- 2025 年にバージョン 0.1 を公開し、 2026 年にバージョン 1 へ改訂した。この資料は、改訂後の v1 を紹介する。
- 設問に対して候補を選び、配布された正解と比較する。独自に作る non-parallel 集合は二択、翻訳した parallel 集合は四択。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 二つの集合は、問題の作り方が違う

| 集合 | 作り方 | 選択肢 |
|---|---|---|
| non-parallel | 各言語の話者が、地域の日常から作る | 2 |
| parallel | 共通の英語問題を各言語へ翻訳する | 4 |

各言語の独自問題と、同じ問題の多言語版を用意している。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 公開 v1 から、本編 3 件と追加 10 件を選ぶ

- 本編では、日本の生活習慣、英語圏の調理用具、密封した袋の物理的な性質を扱う。二択と四択の両方を見る。
- Appendix では、華道・畳・書道・傘・茶道、クリスマスや野球など、別の 10 問を示す。
- 設問と選択肢は公式 TSV の全文。元の正解ラベル 0 〜 3 を、スライドでは A 〜 D へ対応させて示す。

Global PIQA contributors. Non-Parallel v1 / 改訂 6777742 / CC BY-SA 4.0 。 https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 実例１：トイレ用スリッパ

設問・選択肢（配布原文・全文）

トイレ用スリッパは部屋へ？

A) 持ち出さないで使う。
B) 持ち出して使う。

**配布正解： A**

場所に応じた履物の使い分けを問う、日本語の独自問題。

Global PIQA v1 / nonparallel / group0035_ex000062_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 実例２：調味料を分けて出す

設問・選択肢（配布原文・全文）

To serve condiments at a BBQ,

A) use a waffle iron for the various condiments.
B) use a muffin tin for the various condiments.

**配布正解： B**

BBQ の調味料を出すなら、仕切りのあるマフィン型を使う。

Global PIQA v1 / nonparallel / group0123_ex000088_eng_latn_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 同じ物理的な場面を、四択で各言語へ訳す

- parallel 集合では、文化的な固有名への依存を抑えた共通問題を各言語へ訳す。物の性質・位置関係・時間・簡単な個数などを扱う。
- 次の例では、空気を密封した袋の上へ物を置いたとき、袋の中の空気の量がどうなるかを問う。
- 同じ問題でも、選択肢の並びは言語間で変わる。各言語に付いた正解ラベルと、選択肢の内容を対応させる。

Global PIQA contributors. Parallel v1 / 改訂 b0b1851 / CC BY-SA 4.0 。 https://huggingface.co/datasets/mrlbenchmarks/global-piqa-parallel

# 実例３：密封した袋の空気（日本語）

設問・選択肢（配布原文・全文）

ビニール袋に空気を入れて密封します。その袋の上に物を置くと、どうなりますか？

A) 袋の中の空気の量は変わらない
B) 袋の中の空気の量が減る
C) 袋の中の空気の色が変わる
D) 袋の中の空気の量が増える

**配布正解： A**

Global PIQA v1 / parallel / parallel_ex000000_jpn_jpan 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-parallel

# 同じ袋の問題を、英語で読む

設問・選択肢（配布原文・全文）

A plastic bag is filled with air and then sealed. When an object is placed on the bag, what happens?

A) The amount of air in the bag decreases
B) The amount of air in the bag increases
C) The color of the air in the bag changes
D) The amount of air in the bag stays the same

**配布正解： D**

Global PIQA v1 / parallel / parallel_ex000000_eng_latn 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-parallel

# 2. 採点とモデルの成績

# 回答記号が参照正解と一致すれば 1 点

| 段階 | 生成形式での評価 |
| --- | --- |
| 入力 | 設問と二つ、または四つの選択肢を提示 |
| 出力 | best answer is: A など、指定の形式で回答 |
| 採点 | 回答記号を取り出し、配布正解と照合 |
| 集計 | 言語ごとに正答率を出し、言語間で平均 |

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 2026 年の公開評価：言語別正答率の平均

| モデル | non-parallel | parallel |
|---|---|---|
| Gemini 3.1 Pro | 93.93% | 96.83% |
| GPT-5.4 | 91.27% | 91.18% |
| Claude Sonnet 4.6 | 90.17% | 87.66% |

著者らの v1 評価。 non-parallel は二択、 parallel は四択。

Global PIQA contributors (2026). v1：言語別正答率の平均、公開 CSV 。 https://github.com/mrlbenchmarks/global-piqa/blob/main/eval_results/aggregated_by_split.csv

# 同じ生成予算で、思考を使って評価した

- 原著のプロプライエタリモデル評価は、 temperature 0.90 、生成上限 2,048 トークン。 Gemini と Claude は、思考用に 1,024 トークンを割り当てる。
- GPT-5.4 は medium 推論設定。上限を超えた一部の応答は、 low 設定で再実行した。
- 記号を含む指定の回答表現を文字列で照合して採点する。評価コードは LM Evaluation Harness 向けに公開している。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# Gemini 3.1 Pro でも、言語によって幅がある

| parallel の言語 | 正答率 |
|---|---|
| 英語 | 100.00% |
| ペルーのスペイン語 | 99.03% |
| 日本語 | 97.09% |
| エクペイ語 | 31.68% |

英語・日本語・ペルーのスペイン語は 103 問、エクペイ語は 101 問。

Global PIQA contributors (2026). v1: parallel 集合、言語別の正答率。 https://github.com/mrlbenchmarks/global-piqa/blob/main/eval_results/results_per_language.csv

# 3. 作成方法とバージョン

# 350 人以上の研究者が、母語の問題を持ち寄る

- 65 か国以上、 350 人以上の研究者が参加した。主に各言語を話す自然言語処理の研究者が、地域の知識を生かして作成する。
- 作成者は、設問と正しい候補・誤った候補を用意する。食物、衣服、交通、習慣など、地域に根ざした題材を含める。
- 各言語で少なくとも 100 問を作り、母語話者が確認する。作成・確認の方法は各チームの説明として公開した。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 独自問題を整え、各言語 100 問にそろえる

| 工程 | 処理の内容 |
| --- | --- |
| 作成 | 各言語で問題と二つの候補を書く |
| 確認 | 母語話者が自然さ・正解・日常性を確認する |
| 整理 | 形式を統一し、英訳と文化的特徴を注記する |
| 選別 | 課題外・極端に簡単な問題や重複を除く |
| 抽出 | 文化に特有の問題を優先し、 100 問を選ぶ |

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# non-parallel ： 136 種類、合計 13,600 問

| 構成・注釈 | v1 の値 |
|---|---|
| 言語・文字・地域を区別した種類 | 136 |
| 各種類の問題数 | 100 |
| 文化に特有と注釈された問題 | 59.9% |
| LLM の補助を使って作成した問題 | 4.1% |
| 母語話者が複数回確認した問題 | 97.8% |

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# parallel は、翻訳後に母語話者が修正する

- 英語母語話者が 109 問を作り、 Gemini 2.5 Pro または Gemini 3 Flash で翻訳した。対象言語の母語話者が訳文と正解を確認した。
- 訳語で「溶ける」と「溶解する」を区別できない問題や、元の内容が曖昧な問題を除外し、最終 103 問とした。
- 131 種類の言語に展開した。エクペイ語では方角を扱う 2 問も除いたため 101 問となり、合計 13,491 問を配布している。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# v0.1 から v1 へ、言語と評価形式を広げた

| 項目 | v0.1 （2025 年） | v1 （2026 年） |
|---|---|---|
| 独自問題の言語の種類 | 116 | 136 |
| 翻訳した共通問題の集合 | なし | 131 種類・四択 |
| 両集合を合わせた言語の種類 | 116 | 141 |

公開バージョン v1 は、 2026 年 5 月の論文改訂で説明されている。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 4. 入手と使い分け

# 文化の知識と、多言語での常識理解を調べる

- 元になった PIQA は、物体の性質や使い方を扱う英語の二択評価。 Global PIQA はその形式を、多言語と文化ごとの常識へ広げた。
- non-parallel は、各言語の話者が選んだ地域の日常を扱う。言語ごとに固有の生活習慣や道具を問う問題がある。
- parallel は、共通の場面を多言語へ翻訳したもの。同じモデルの回答が言語間でどう変わるかを調べるために使う。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 日本語の独自問題を読み込む

```
from datasets import load_dataset

ds = load_dataset(
    "mrlbenchmarks/global-piqa-nonparallel",
    "jpn_jpan", split="test",
)
row = ds[0]
print(row["prompt"], row["label"])
```

jpn_jpan は日本語・日本文字の設定名。 label は 0 または 1 。

Global PIQA contributors. Non-Parallel v1 / 改訂 6777742 / CC BY-SA 4.0 。 https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 日常の常識を、地域と言語の両面から評価する

- Global PIQA v1 は、地域ごとに作った二択 13,600 問と、同じ場面を訳した四択 13,491 問を持つ。両集合を合わせて 141 種類の言語を含む。
- 母語話者による作成・確認を重視し、生活習慣や物の使い方などを出題する。各地域の独自問題と、翻訳した共通問題を使い分けられる。
- GPT-5.4 、 Claude Sonnet 4.6 、 Gemini 3.1 Pro などを評価しており、全体の成績と、言語ごとの成績の幅を調べる資料になる。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# Appendix

1. 生活場面の追加例
2. データと評価の詳細
3. 制作機関と参考文献

# 1. 生活場面の追加例

# 追加例 1 ：華道の花を固定する

設問・選択肢（配布原文・全文）

華道で花を固定するときは？

A) 机に挿す。
B) 剣山に挿す。

**配布正解： B**

剣山の針で茎を支え、花を固定する。

Global PIQA v1 / nonparallel / group0035_ex000003_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例２：竹筒で運ぶもの

設問・選択肢（配布原文・全文）

竹筒は、

A) 巻いた掛け軸を運べる。
B) 盆栽を運べる。

**配布正解： A**

細長い竹筒は、巻いた掛け軸を収める形に対応する。

Global PIQA v1 / nonparallel / group0035_ex000079_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例３：玄関の段差を上がる

設問・選択肢（配布原文・全文）

民泊の玄関で段差を上がるときは？

A) 靴を脱いで上がる。
B) 靴を履いて上がる。

**配布正解： A**

玄関から室内へ上がる場面で、靴を脱ぐ習慣を問う。

Global PIQA v1 / nonparallel / group0035_ex000014_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例 4 ：土鍋を洗う道具

設問・選択肢（配布原文・全文）

土鍋を洗うときは？

A) 柔らかいスポンジで洗う。
B) 金属たわしで洗う。

**配布正解： A**

土鍋の表面を洗う道具として、柔らかいスポンジを選ぶ。

Global PIQA v1 / nonparallel / group0035_ex000012_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例 5 ：畳を拭く布

設問・選択肢（配布原文・全文）

畳を拭くときは？

A) 固く絞った布で拭く。
B) びしょ濡れの布で拭く。

**配布正解： A**

畳を水でぬらしすぎないよう、固く絞った布を使う。

Global PIQA v1 / nonparallel / group0035_ex000036_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例 6 ：墨を磨るために使うもの

設問・選択肢（配布原文・全文）

書道の墨は？

A) 硯に油を入れて磨る。
B) 硯に水を入れて磨る。

**配布正解： B**

硯に水を入れて、固形の墨を磨る。

Global PIQA v1 / nonparallel / group0035_ex000013_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例７：濡れた傘を持ち込む

設問・選択肢（配布原文・全文）

濡れた傘はコンサートホールでは？

A) 傘袋に入れて持つ。
B) 傘袋に入れずに持つ。

**配布正解： A**

床などがぬれないように、傘袋に入れて持つ場面。

Global PIQA v1 / nonparallel / group0035_ex000007_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例 8 ：茶筅を使う準備

設問・選択肢（配布原文・全文）

茶筅は使う前に？

A) 穂先を乾いたまま強く当てて使う。
B) 穂先を湯でほぐして使う。

**配布正解： B**

茶筅の穂先を湯でほぐしてから使う。

Global PIQA v1 / nonparallel / group0035_ex000053_jpn_jpan_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例 9 ：ツリーを置く場所がないとき

設問・選択肢（配布原文・全文）

To celebrate Christmas without room for a tree,

A) tape holiday lights to the wall in pattern of a tree.
B) tape holiday treats to the wall in pattern of a tree.

**配布正解： A**

ツリーの形になるよう、壁へ電飾を取り付ける。

Global PIQA v1 / nonparallel / group0123_ex000012_eng_latn_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 追加例 10 ：野球で勝つための条件

設問・選択肢（配布原文・全文）

To win a baseball game,

A) hit more baseballs than the opposing team.
B) score more runs than the opposing team.

**配布正解： B**

相手より多くの得点を取る。

Global PIQA v1 / nonparallel / group0123_ex000075_eng_latn_0_v1 。 CC BY-SA 4.0 。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 2. データと評価の詳細

# 言語コードは、言語・文字・地域を組み合わせる

| コードの例 | 言語・文字・地域 |
|---|---|
| jpn_jpan | 日本語・日本文字 |
| eng_latn | 英語・ラテン文字 |
| por_latn_braz | ポルトガル語・ラテン文字・ブラジル |
| spa_latn_peru | スペイン語・ラテン文字・ペルー |

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# non-parallel の主要な列

| 列 | 内容 |
| --- | --- |
| prompt | 設問、または文の書き出し |
| solution0 / solution1 | 二つの候補 |
| label | 正解候補の番号： 0 または 1 |
| approx_cultural_score | 文化的な特徴に関する注釈 |
| llm_used | 作成時に LLM の補助を使ったか |
| example_id | 問題を識別する ID |

Global PIQA contributors. Non-Parallel v1 / 改訂 6777742 / CC BY-SA 4.0 。 https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 日本語の掲載例には、 LLM 補助のフラグが付く

- 掲載した日本語 non-parallel の問題は llm_used が 1 である。 Global PIQA 全体での割合 4.1% とともに、日本語のこの選定例の属性を確認できる。
- データカードには、 LLM の補助を用いた例も含め、すべて少なくとも一人の母語話者が確認したと記載されている。
- non-parallel の example_id には、制作グループ、言語、バージョンなどの情報が含まれる。

Global PIQA contributors. Non-Parallel v1 / 改訂 6777742 / CC BY-SA 4.0 。 https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# ベースモデルは、候補の生成確率で採点できる

- 指示に合わせた回答生成とは別に、候補ごとの対数確率を計算する cloze 形式も用意している。主に事前学習のみのベースモデルに使う。
- 候補の対数確率を、その候補の UTF-8 バイト数で割る。正解候補の値が他の候補より大きければ、その問題を正解とする。
- 原著のオープンモデルの評価は、モデルの種類に応じて生成形式と cloze 形式を使い分けている。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 二つの集合と言語ごとの問題数

| 集合・対象 | 問題数 |
|---|---|
| non-parallel ： 136 種類 | 各 100 |
| parallel ：通常の 130 種類 | 各 103 |
| parallel ：エクペイ語 | 101 |
| 二つの集合の延べ問題数 | 27,091 |

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 公開バージョンと利用条件

- v0.1 は 2025 年 10 月の初稿で、 116 種類の言語を対象とした。 v1 では独自問題を 136 種類へ増やし、 131 種類の parallel 集合を加えた。
- 参照した non-parallel は改訂 6777742 、 parallel は改訂 b0b1851 。公開ディレクトリには旧バージョンも残されている。
- データは CC BY-SA 4.0 で、掲載例と追加した日本語訳も同ライセンス。提供元は、 Global PIQA 自体や、それを種に生成した合成データによる AI システムの学習を認めないと明記している。

Global PIQA contributors. CC BY-SA 4.0 。 AI 学習への使用を認めない旨をデータカードに記載。
https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel#license

# 3. 制作機関と参考文献

# 多言語研究者の共同制作として公開した

- 共同第一著者は Tyler A. Chang （ UC San Diego ）と Catherine Arnett （ EleutherAI ）。 MRL Workshop の参加者を中心に、 350 人以上が制作へ参加した。
- 各言語の担当者は、母語の話者・研究者として問題を書き、翻訳の確認や文化に関する判断にも関わった。
- 原著では全著者と各チームの所属・データ作成方法が付録に掲載されている。公開された全著者リストの最終著者は David Ifeoluwa Adelani 。

Chang, Arnett et al. (2026). Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures. v2 。 https://arxiv.org/abs/2510.24081v2

# 参考文献


## Global PIQA: Evaluating Commonsense Reasoning Across 100+ Languages and Cultures

Tyler A. Chang, Catherine Arnett et al. / 2026 / arXiv v2

v1 の独自問題と共通問題、作成・翻訳・確認、モデル評価を説明する。

https://arxiv.org/abs/2510.24081v2

## Global PIQA Non-Parallel / Parallel

Global PIQA contributors / Hugging Face / v1 / CC BY-SA 4.0

掲載した設問・選択肢・参照正解の取得元。二つの集合を別々に配布する。

https://huggingface.co/datasets/mrlbenchmarks/global-piqa-nonparallel

# 参考文献


## Global PIQA v1: Evaluation Results

Global PIQA contributors / 2026 / 公開 CSV

モデル別・言語別の結果を公開。本資料の平均正答率と、言語ごとの幅の出典。

https://github.com/mrlbenchmarks/global-piqa/tree/main/eval_results

## PIQA: Reasoning about Physical Commonsense in Natural Language

Yonatan Bisk et al. / AAAI 2020

物の性質や使い方を問う英語の二択評価。 Global PIQA の課題形式の出発点。

https://arxiv.org/abs/1911.11641

# 参考文献

## Global PIQA v0.1

Tyler A. Chang, Catherine Arnett et al. / 2025 / arXiv v1

116 種類の言語で始まった初稿。 2026 年改訂との構成の違いを確認できる。

https://arxiv.org/abs/2510.24081v1

## Global PIQA: Evaluation Harness

Global PIQA contributors / LM Evaluation Harness 向け実装

生成形式と cloze 形式での入力構成と採点を実装する。

https://github.com/mrlbenchmarks/lm-eval-global-piqa