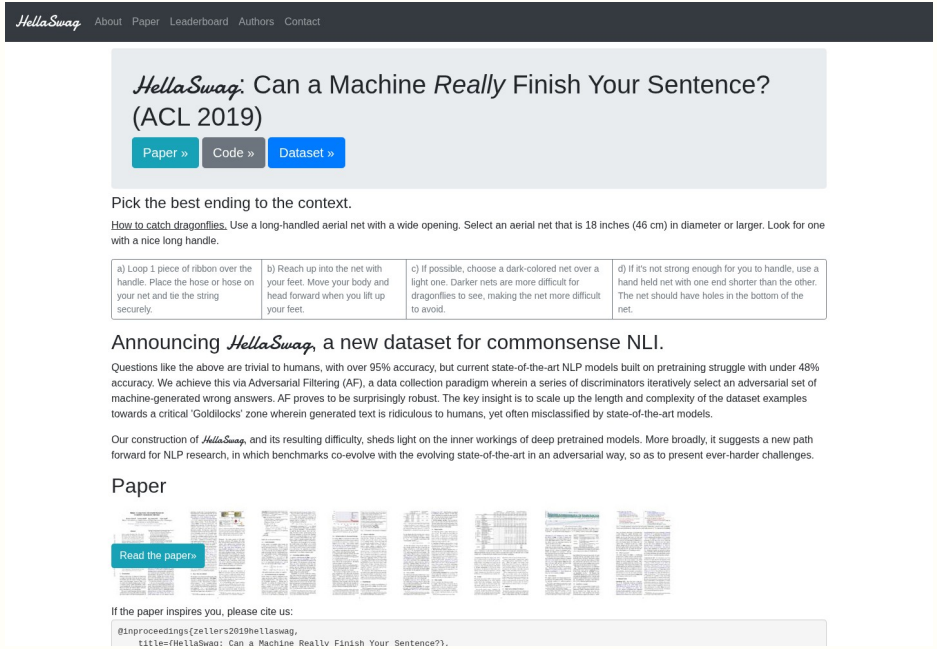
HellaSwag

日常の動作や手順の続きを
四つの候補から選ぶ

sasakiy84

HellaSwag の公式公開ページ



[1] HellaSwag 公式公開ページ。 2026-10-17 参照。 https://rowanzellers.com/hellaswag/

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

文脈の後に、自然に続く候補を一つ選ぶ

- HellaSwag は、日常の動作や手順を記述した英語の文脈と、四つの続きの候補を収録している。正解は一つである。
- 素材は動画の説明文と WikiHow の記事だが、標準の課題でモデルに渡すのは文章である。動画の映像を入力する課題ではない。
- 単語のつながりに加え、動きが物理的に可能か、作業の順序が自然かを読み取る。

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

入力と正解の対応

配布フィールド	意味
ctx	前半の文章。文の途中で終わることもある
endings	続きを表す四つの文字列
label	正解の位置。配布値は 0 〜 3
source_id	元の動画や WikiHow 記事の識別子

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 https://huggingface.co/datasets/Rowan/hellaswag

実例１：屋根材をはがす

原文

Context: A man is sitting on a roof. he
A. is using wrap to wrap a pair of skis.
B. is ripping level tiles off.
C. is holding a rubik's cube.
D. starts pulling up roofing on a roof.

日本語訳

正解： D

文脈：男性が屋根に座っている。彼は
A ：ラップでスキー板を一組包んでいる。
B ：平らなタイルをはがしている。
C ：ルービックキューブを持っている。
D ：屋根の屋根材を引きはがし始める。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 0 。 正解： D 。 https://huggingface.co/datasets/Rowan/hellaswag

実例２：バーベルを持ち上げる

原文

Context: A lady walks to a barbell. She bends down and grabs the pole. the lady
A. swings and lands in her arms.
B. pulls the barbell forward.
C. pulls a rope attached to the barbell.
D. stands and lifts the weight over her head.

正解： D

日本語訳

文脈：女性がバーベルに歩み寄る。かがんでバーをつかむ。その女性は
A ：揺れて自分の腕の中に着地する。
B ：バーベルを前へ引く。
C ：バーベルに付いたロープを引く。
D ：立ち上がり、重りを頭上へ持ち上げる。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 1 。 正解： D 。 https://huggingface.co/datasets/Rowan/hellaswag

実例３：走り高跳び

関連する入力・回答／左：原文　右：日本語訳

Context: A boy is running down a track. the boy
A. runs into a car.
B. gets in a mat.
C. lifts his body above the height of a pole.
D. stands on his hands and springs.

正解： C

文脈：少年が走路を走っている。その少年は
A ：選択肢：車にぶつかる。
B ：選択肢：マットの中に入る。
C ：選択肢：体をバーより高く持ち上げる。
D ：選択肢：逆立ちをして跳ねる。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 3 。 正解： C 。 https://huggingface.co/datasets/Rowan/hellaswag

続きは、文脈の末尾につなげて読む

- 屋根の例は、文脈が he で終わる。各選択肢をつなげると、 he starts pulling up roofing on a roof. のような文になる。
- バーベルの例は、単に運動に関係する語があるかではなく、つかんだ後にどう動くかを読む。
- この資料では A ～ D で表示する。配布ラベル 0 ～ 3 は順に A ～ D へ対応させている。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 https://huggingface.co/datasets/Rowan/hellaswag

作成方法とデータの構成

表面的な手掛かりで解ける負例を減らす

- 先行する SWAG （2018）は、動画説明の続きを選ぶ常識推論のデータセットだった。事前学習モデルの性能向上で、多くの問題が解けるようになった。
- HellaSwag では、文章としてもっともらしい誤答候補を生成し、識別モデルが簡単に見分けられる候補を繰り返し取り除いた。
- 語彙や文法が似ていても、その場面で起きそうな出来事かどうかを問うことが狙いである。

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

実際の続きと、生成した誤答を組み合わせる

- ActivityNet Captions の動画説明と、 WikiHow の手順記事から、文脈と実際の続きを取り出す。
- 言語モデルが文脈に対する続きの候補を生成する。識別モデルによる adversarial filtering で、容易に判別される負例を交換する。
- 人手の検証も行い、実際の続き一つと、紛らわしい負例三つからなる問題を作る。

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

既知の話題と、未学習の話題を分けて測る

- 評価には、学習側に登場するカテゴリと、登場しないカテゴリを含めた。配布フィールド split_type がこの違いを示す。
- validation は indomain が 5,001 問、 zeroshot が 5,041 問。これはデータ分割上のカテゴリの違いである。
- zeroshot というフィールド名と、モデルに例題を一つも示さない 0-shot の評価設定は、別の軸である。

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

分割と件数

集合	件数	役割
train	39,905	正解ラベル付きの学習問題
validation	10,042	正解ラベル付きの開発問題
test	10,003	公開ファイルの正解欄は空

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

動画と手順記事では、読む内容が異なる

- validation の 10,042 問のうち、 WikiHow が 6,799 問、 ActivityNet が 3,243 問を占める。
- 動画説明は人物の動作や場面の変化、 WikiHow は料理や清掃などの手順を多く含む。
- 追加例では両方を取り上げ、 [header] 、 [title] 、 [step] といった記事の構造も配布文字列のまま示す。

[1] Rowan/hellaswag 、改訂 218ec52e 。 validation 全 10,042 件を集計。 https://huggingface.co/datasets/Rowan/hellaswag

validation の素材は二つの公開資源



validation 全 10,042 問。縦軸は質問数。

[1] Rowan/hellaswag 、改訂 218ec52e 。 validation 全 10,042 件を集計。 https://huggingface.co/datasets/Rowan/hellaswag

採点方法とモデルの成績

四択の正解率で、続きを選ぶ能力を測る

- 各問について、選んだ候補が配布ラベルと一致すれば 1 、それ以外は 0 。全問の平均を正解率とする。
- 四つの候補を一様にランダム選択する場合の期待値は 25% である。
- HELM の multiple_choice_separate_original は、各続きを個別に採点し、長さで正規化した文の確率に基づいて候補を選ぶ。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

登場時の代表的な結果

2019 年の比較	テスト正解率
一様ランダム選択の期待値	25.0%
BERT-Large	47.3%
人間	95.6%

Overall test の結果。 BERT は学習集合で微調整した条件。

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

HELM での評価条件

- HELM Classic v0.4.0 （2023-11-17）の canonical 結果。validation から 1,000 問を使い、解答例を示さない 0-shot で評価した。
- 各候補を別々に入力して確率を比較する方式で、正解率を報告する。試行回数は各 1 回である。
- 選択肢を一つのプロンプトに並べて A ～ D を生成する方式や、例題を示す方式とは入力条件が異なる。

[1] HELM Classic v0.4.0 。公開 run_specs と実行別 stats の canonical 設定を照合。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の比較

モデル	正解率	試行数
OPT-175B	79.10%	1
text-davinci-003	82.20%	1

validation 1,000 問。 0-shot 。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

得点と評価条件を一緒に読む

- この比較は、指定 URL が指す 2023 年 11 月 17 日の HELM Classic の結果である。現在の最高性能の一覧を意図していない。
- 少数例提示では、例題の選び方や、候補の並べ方、入力の長さが条件になる。表には評価集合と試行数を添えた。
- 正解率のほか、入力を少し変えた際の頑健性や、自信のある予測がどの程度正しいかも評価できる。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

モデルの進歩後も、日常場面の指標として使う

- HellaSwag は、 HELM や Language Model Evaluation Harness に組み込まれ、汎用言語モデルの常識的な文章補完を測る指標となっている。
- 高得点でも、あらゆる物理常識を獲得したとはいえない。公開問題に対する文章候補の識別を測っている。
- 採点時の長さの正規化、例題数、候補の提示方法が、モデル間の比較条件になる。

[1] HellaSwag 公式公開ページ。 2026-10-17 参照。 https://rowanzellers.com/hellaswag/

データの入手と利用

- 作者の公式ページから、論文、データ、評価用の情報へ進める。 Rowan/hellaswag の公開ミラーでも配布されている。
- ミラーの test には正解ラベルがない。正解を確認したり、手元で採点したりするには validation を使う。

[1] HellaSwag 公式公開ページ。 2026-10-17 参照。 https://rowanzellers.com/hellaswag/

公開データを読み込む

```
from datasets import load_dataset
ds = load_dataset("Rowan/hellaswag",
                  revision="218ec52e")
example = ds["validation"][0]
print(example["ctx"])
```

この資料で照合した改訂を指定して読み込む。各フィールドの意味は本編の対応表を参照。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 https://huggingface.co/datasets/Rowan/hellaswag

HellaSwag の要点

- 日常の動作や手順に対し、実際の続き一つと生成した誤答三つを見比べる。
- 識別しやすい負例を除く工程により、文法的な自然さだけでは解きにくい問題を作った。
- データ内の未知カテゴリと、評価時の例題なし設定を区別し、候補の採点方法をそろえて比べる。

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：ハーモニカの演奏（原文）

正解： C

原文

Context: A man is standing in front of a camera. He starts playing a harmonica for the camera. he
A. begins to play the harmonica with his body while looking at the camera.
B. seems to be singing while playing the harmonica.
C. rocks back and forth to the music as he goes.
D. painted a fence in front of the camera.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 6 。 正解： C 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例１：ハーモニカの演奏（日本語訳）

正解： C

日本語訳

文脈：男性がカメラの前に立っている。カメラに向かってハーモニカを吹き始める。彼は
A ：カメラを見ながら、体でハーモニカを演奏し始める。
B ：ハーモニカを吹きながら歌っているように見える。
C ：音楽に合わせて体を前後に揺らす。
D ：カメラの前の塀を塗った。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 6 。 正解： C 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例２：公園での演奏（原文）

正解： A

原文

Context: A person is playing bagpipes out in a park. A man and two boys watching from a far. the camera
A. shoots areas all around the park while the bagpipes play.
B. is covered to the boy that is playing there.
C. then goes black and we see a black opening scene.
D. watching the boy and boy as they play a game of drums.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 14 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例２：公園での演奏（日本語訳）

正解： A

日本語訳

文脈：公園でバグパイプを演奏している人がいる。男性と少年２人が遠くから見ている。カメラは
A ：バグパイプの演奏中、公園のあちこちを映す。
B ：そこで演奏する少年に覆われる。
C ：その後暗転し、黒いオープニング場面になる。
D ：少年と少年がドラムの遊びをするのを見ている。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 14 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例３：チアリーディング（原文）

原文

正解： A

Context: A group of cheerleaders run onto a stage before a cheering audience. they
A. get into formation, then begin dancing and flipping as male cheerleaders join them.
B. perform a cheer routine before the girls, along with makeup artists, spread out and pose.
C. take turns jumping on each other like they are performing karate.
D. are then shown performing the type of cheerleading dance, using batons and pole vaults.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 17 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例３：チアリーディング（日本語訳）

正解： A

日本語訳

文脈：歓声を上げる観客の前で、チアリーダーたちが舞台へ走り込む。彼女たちは
A ：隊形を作り、男性チアリーダーも加わって踊ったり宙返りしたりし始める。
B ：演技を披露した後、女子とメイク担当者が散らばってポーズを取る。
C ：空手をするかのように、交互に互いの上へ跳び乗る。
D ：その後、バトンや棒高跳びの棒を使ったチアダンスを披露する。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 17 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 4 ：芝刈りの動き（原文）

正解： A

原文

Context: A man is outside of a building. He is using commercial lawn mowing equipment. he
A. walks back and forth as he mows the grass.
B. is animated as he does the task.
C. relaxes, making sure his lawn is pristine.
D. runs from one side of the building to the other.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 21 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 4 ：芝刈りの動き（日本語訳）

正解： A

日本語訳

文脈：男性が建物の外にいる。業務用の芝刈り機を使っている。彼は
A ：芝を刈りながら行ったり来たりする。
B ：作業中、活発な様子である。
C ：芝生が完璧な状態なのを確かめながらくつろぐ。
D ：建物の一方の側から反対側まで走る。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 21 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 5 ：家族のデザート

原文

Context: Children bring desert out for their family member. the family
A. floats in a river.
B. member stands looking into a hut and then handing people photographs.
C. member cuts a piece of sunscreen.
D. enjoys eating the desert together.

日本語訳

正解： D

文脈：子どもたちが家族にデザートを運んでくる。その家族は
A ：川に浮かんでいる。
B ：小屋をのぞき込み、その後、人々に写真を手渡す。
C ：日焼け止めを一切れ切る。
D ：一緒にデザートを食べて楽しむ。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 22 。 正解： D 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 6 ：壁の下地を清掃する（原文）

正解： D

原文

Context: [header] How to caulk walls [title] Clean the wall. [step] Caulk should never go on a dirty surface. Wipe down the wall with a dry cloth to remove dust.
A. Also use a brush to vacuum the surface. Don't use a brush on a dirty surface.
B. Then let the caulk dry and smooth out any uneven surfaces. Use a knife to cut a 2 inch (5.1 cm) square at the edge of the wall.
C. Next, caulk around the entire wall with a rag. A putty knife or a mop may work, too.
D. Wash with an all-purpose cleaner to remove grease and dirt. Rubbing alcohol and a wire brush will remove stubborn stains.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 8029 。 正解： D 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 6 ：壁の下地を清掃する（日本語訳）

正解： D

日本語訳

文脈：［見出し］壁をコーキングする方法［項目］壁をきれいにする。［手順］汚れた面にコーキングしてはいけない。乾いた布で壁を拭き、ほこりを除く。
A ：ブラシを使って表面を吸引する。汚れた面にはブラシを使わない。
B ：次にコーキング材を乾かし、凹凸をならす。ナイフで壁の端に 2 インチ（ 5.1cm ）の正方形を切る。
C ：次に布で壁全体の周囲をコーキングする。パテ用ナイフやモップでもよい。
D ：万能洗剤で洗い、油や汚れを落とす。しつこい汚れは消毒用アルコールとワイヤーブラシで落とす。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 8029 。 正解： D 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 7 ：リンゴジャムの下ごしらえ（原文）

正解： C

原文

Context: [header] How to make apple jam [title] Peel and chop your apples. [step] Wash your apples and peel them. Core the apples to remove their stems.
A. Trim the apples into smaller pieces to use as jam. Use 3 to 4 large apple chunks in the jam.
B. Some may have chunks of skin if you cut them off. You'll need about two peeled apples for the total jam.
C. Carefully dice the apples finely so they're no larger than 1/4 " cubes. Place all of the apples in a large 4-cup measuring cup.
D. From the core, you should cut off all the small, stringy flesh. You should also grate them on a separate cutting board.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 8042 。 正解： C 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 7 ：リンゴジャムの下ごしらえ（日本語訳）

正解： C

日本語訳

文脈：［見出し］リンゴジャムの作り方［項目］リンゴの皮をむいて切る。［手順］洗って皮をむき、芯を取り、軸を除く。
A ：ジャムにするため、リンゴを小さく切る。大きめの塊を 3 〜 4 個使う。
B ：皮を切り取ると、一部に皮の塊が残ることがある。全体で皮をむいたリンゴを約 2 個使う。
C ： 1 辺 1/4 インチ以下の角切りになるよう、注意して細かく切る。すべてのリンゴを 4 カップ用の大きな計量カップに入れる。
D ：芯から小さな筋っぽい果肉をすべて切り落とす。別のまな板ですりおろすことも必要だ。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 8042 。 正解： C 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 8 ：ポプリ用のリンゴ（原文）

正解： A

原文

Context: [header] How to make fall potpourri [title] Dry the apple. [step] Preheat your oven to 150 degrees f (65 degrees c). Wash one apple and slice it into 1/4-inch slices.
A. Lay the slices in a single layer on a baking sheet. Bake the apple slices for 30 minutes.
B. Place the slices onto a stove top burner over medium high heat. Set the burner to 350 degrees f (177 degrees c) and heat it.
C. Set the apple slices on a spice rack on your counter. Run cold water over them until they are dry.
D. Place the apple slices on a lightly greased baking sheet. Then, lay the sheet on the kitchen counter with the apples face down.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 4264 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 8 ：ポプリ用のリンゴ（日本語訳）

正解： A

日本語訳

文脈：［見出し］秋のポプリの作り方［項目］リンゴを乾燥させる。［手順］オーブンを 150°F （ 65°C ）に予熱する。リンゴ 1 個を洗い、 1/4 インチの薄切りにする。
A ：天板に重ならないように並べ、 30 分焼く。
B ：コンロのバーナーに載せ、中強火にする。バーナーを 350°F （ 177°C ）に設定して加熱する。
C ：調理台のスパイスラックに載せ、乾くまで冷水を流す。
D ：薄く油を塗った天板に載せる。その後、リンゴを下向きにして天板を調理台に置く。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 4264 。 正解： A 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 9 ：食洗機の外側を拭く（原文）

正解： B

原文

Context: [header] How to clean a frigidaire dishwasher [title] Get a dish cloth damp. [step] Dip a dish rag in warm, soapy water. Use a mild dish detergent over a chemical cleaner.
A. [title] Scrub the sides and bottom of the frigidaire. [step] You will need to use a scrubbing tool, like a fork.
B. Ring the rag out slightly so it's just damp. [title] Wipe the exterior with the damp cloth.
C. Wring out the excess moisture before wiping down the top and sides of the frigidaire. [title] Pat the rusty surface of the frigidaire with the cloth.
D. Dampen the rag and wring it out between uses. [title] Remove your frigidaire from the dishwasher.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 6675 。 正解： B 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 9 ：食洗機の外側を拭く（日本語訳）

正解： B

日本語訳

文脈：［見出し］ Frigidaire 製食洗機の掃除方法［項目］布巾を湿らせる。［手順］温かい石けん水に布巾を浸す。強い化学洗剤よりも、刺激の少ない食器用洗剤を使う。
A ：［項目］ Frigidaire の側面と底をこする。［手順］フォークなど、こする道具が必要だ。
B ：少し絞って、軽く湿った状態にする。［項目］湿った布で外側を拭く。
C ：上面と側面を拭く前に、余分な水分を絞る。［項目］さびた表面を布で軽くたたく。
D ：使うたびに布を湿らせて絞る。［項目］食洗機から Frigidaire を取り出す。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 6675 。 正解： B 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 10 ：塩と酢を混ぜる（原文）

正解： B

原文

Context: [header] How to unclog a drain with salt and vinegar [title] Mix salt and vinegar. [step] In a small bowl, pour 1 cup of salt. Add 1 cup of vinegar.
A. Place 1 cup of distilled white vinegar in a small bowl. The salt and vinegar will help the solution penetrate the clogged drain.
B. Stir well so the salt soaks up all the vinegar. Continue stirring until the mixture is smooth and even.
C. Mix the salt in, going slowly but bringing the mixture to a boil. Always stir the solution well, making sure nothing gets broken.
D. If possible, give it an extra stir. The vinegar will set the clog, and it will give it a smoother initial scrubbing.

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 6051 。 正解： B 。 https://huggingface.co/datasets/Rowan/hellaswag

追加例 10 ：塩と酢を混ぜる（日本語訳）

正解： B

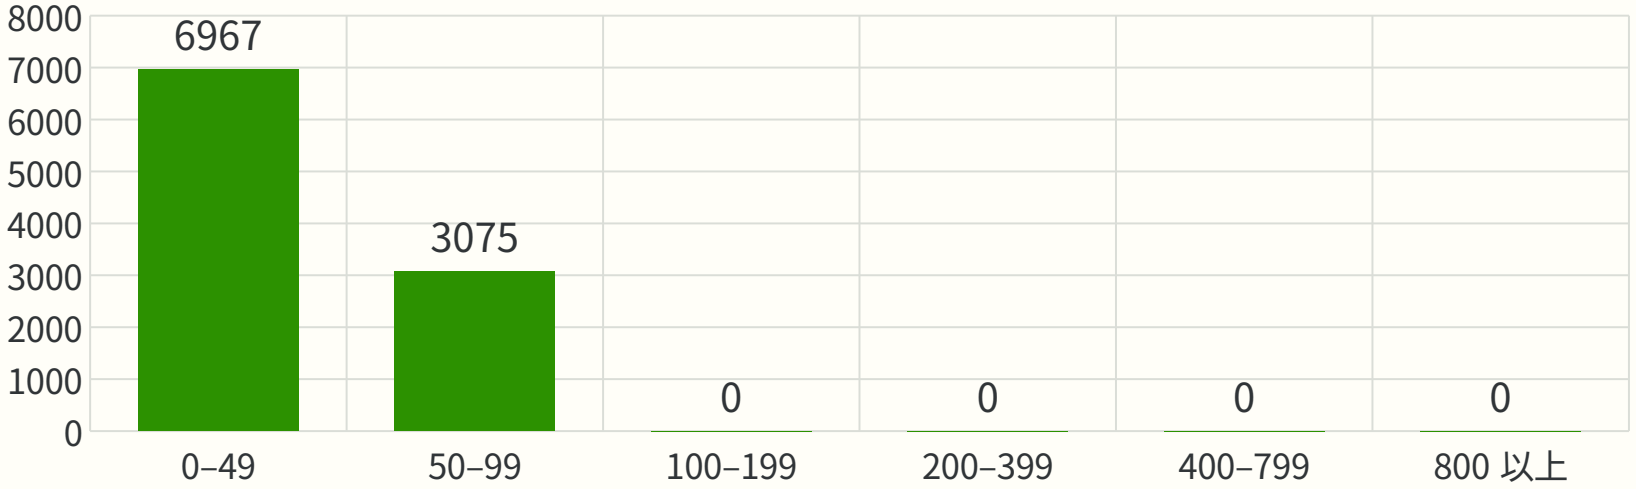
日本語訳

文脈：［見出し］塩と酢で排水口の詰まりを解消する方法［項目］塩と酢を混ぜる。［手順］小さなボウルに塩 1 カップを入れ、酢 1 カップを加える。
A ：小さなボウルに蒸留白酢 1 カップを入れる。塩と酢が詰まった排水口に浸透する助けになる。
B ：塩が酢をすべて吸うようによく混ぜる。滑らかで均一になるまで混ぜ続ける。
C ：ゆっくり塩を混ぜながら、沸騰させる。何も壊れないよう、必ずよくかき混ぜる。
D ：できればさらに混ぜる。酢が詰まりを固め、最初にこすりやすくする。

[1] Rowan/hellaswag 、改訂 218ec52e 。 2026-10-17 参照。 validation の 0 始まり行 6051 。 正解： B 。 https://huggingface.co/datasets/Rowan/hellaswag

集計と評価条件

入力の語数分布



validation 全 10,042 件。横軸は空白区切りの語数、縦軸は件数。

[1] Rowan/hellaswag 、改訂 218ec52e 。 validation 全 10,042 件を集計。 https://huggingface.co/datasets/Rowan/hellaswag

入力の長さを同じ方法で集計した

統計量	空白区切りの語数
平均	40.1
中央値	42.0
母標準偏差	15.5
最小	8.0
最大	85.0

入力は ctx 。四つの endings は含めていない。

[1] Rowan/hellaswag 、改訂 218ec52e 。 validation 全 10,042 件を集計。 https://huggingface.co/datasets/Rowan/hellaswag

集計の対象と測り方

- 対象は改訂 218ec52e の validation 全 10,042 件。表示した 13 例だけの集計ではない。
- 語数は Python の str.split() による空白区切り。母標準偏差を用い、分位点は NumPy の線形補間で求めた。
- 図は 0 〜 49 、 50 〜 99 、 100 〜 199 、 200 〜 399 、 400 〜 799 、 800 以上の階級で、最後の階級に長い入力もすべて含める。

[1] Rowan/hellaswag 、改訂 218ec52e 。 validation 全 10,042 件を集計。 https://huggingface.co/datasets/Rowan/hellaswag

研究と参考文献

研究者と発表の位置付け

- Rowan Zellers と最終著者 Yejin Choi ら、ワシントン大学と Allen Institute for AI の研究者が参加した。
- ACL 2019 で発表された。 SWAG に続き、生成モデルと識別モデルを使って常識推論の負例を作る研究である。

[1] Rowan Zellers et al. (2019). HellaSwag: Can a Machine Really Finish Your Sentence?. ACL 2019. https://aclanthology.org/P19-1472/

参考文献

HellaSwag: Can a Machine Really Finish Your Sentence?

Rowan Zellers, Ari Holtzman, Yonatan Bisk, Ali Farhadi, Yejin Choi / ACL 2019

HellaSwag の作成方法、実例、初期評価を報告した研究。

https://aclanthology.org/P19-1472/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

HELM のシナリオ、評価指標、少数例提示による多面的な比較をまとめる。

https://arxiv.org/abs/2211.09110

参考文献

HellaSwag ：公開データと配布情報

Rowan/hellaswag / 改訂 218ec52e / 2026-10-17 参照

掲載した 13 例の原文・正解と、公開集合の全件集計を照合した。

https://huggingface.co/datasets/Rowan/hellaswag