ICE

International Corpus of English

共通の設計で世界の英語を比較する

sasakiy84

公式サイト



[1] International Corpus of English. University of Zurich. https://www.ice-corpora.uzh.ch/en.html

1. 世界の英語と実際のテキスト
2. 共通設計と収集・注釈
3. HELM での言語モデル評価
4. 入手方法と活用

世界の英語と実際のテキスト

英語の地域差を比べるためのコーパス

- ICE は、各国・地域の英語を同じ構成で集め、語法や文法などを比較するためのコーパス群。 1990 年に始まった。
- 標準設計は 1 地域につき約 100 万語。会話、講演、ニュース、手紙、学術文などを含む。
- 質問と正解の組ではなく、実際に使われた話し言葉・書き言葉のテキストが基本単位になる。

[1] International Corpus of English. University of Zurich. https://www.ice-corpora.uzh.ch/en.html

HELM では、本文に付けた確率を採点する

- 言語モデルにテキストを与え、各語や記号にどれだけ高い確率を付けるかを測る。本文を予測しやすいモデルほど、よい得点になる。
- 以下の 13 例は、 HELM の公開評価に含まれるインドの英語 12 件と、公式実装に掲載された米国の英語 1 件からの短い抜粋。実際の評価には、抜粋元のテキスト全体を使う。

[1] Stanford CRFM, HELM ICEScenario.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

実例１：学校設立の背景を語る

原文：連続した抜粋（空白を整形）

<$A> I will take, exactly ten minutes of yours, to brief you <,,> about our institution, Many people may not know, the background, under which this institution was born,

日本語訳

<$A>
皆さんの時間をちょうど 10 分いただき、 <,,> 私たちの学校についてご説明します。
この学校がどのような経緯で生まれたのか、ご存じない方も多いでしょう。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

書き起こしには話し方の痕跡が残る

- 「 <$A> 」は話者を表す。「 <,,> 」は長い休止を表す転記記号。言いよどみや反復もテキストの一部になる。
- 学校の成り立ちを説明するまとまった発話で、会話のやり取りとは異なる文章の展開が現れる。

[1] Nelson (2002), Markup Manuals for Spoken and Written Texts. ICE.
https://www.ice-corpora.uzh.ch/en/manuals.html

実例２：出身地を尋ねる会話

原文：連続した抜粋（空白を整形）

<$A> Uhm, Mr Yadav, you told something about your native place na , <$B> Yeah <$A> Which is your native place, <$B> Native Place is uh, U P, Azamgarh,

日本語訳

<$A> ええと、ヤーダヴさん、出身地のことを少し話していましたね。
<$B> はい。
<$A> ご出身はどちらですか。
<$B> 出身は、ええと、ＵＰのアーザムガルです。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

話者交替や地域の表現も入力になる

- この会話では、問いと短い応答が交互に続く。「 uh 」のような言いよどみや「 na 」のような表現も残る。
- ＵＰはインドのウッタル・プラデーシュ州。 Azamgarh はその州の地名である。
- HELM は文法や地名の正誤を判定せず、記録されたテキストへの確率を採点する。

[1] Stanford CRFM, HELM ICEScenario.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

実例３：米国造幣局の案内

原文：連続した抜粋（空白を整形）

The U.S. Mint: United States coins are made at four Mint facilities: Philadelphia, Denver, San Francisco, and West Point, NY. One easy way to start your collection is with the circulating coins you use daily - pennies, nickels, dimes, quarters and dollars.

日本語訳

米国造幣局
米国の硬貨は、フィラデルフィア、デンバー、サンフランシスコ、ニューヨーク州ウェストポイントの４施設で作られています。収集を手軽に始める方法の一つは、毎日使う流通硬貨――１セント、５セント、10セント、25セント、１ドル――を集めることです。

[1] Stanford CRFM (2023). HELM ICEScenario: ICE-USA example.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

話し言葉と書き言葉を同じ枠で比較

- USA の例は硬貨収集の案内。文として整えられた書き言葉で、転記された会話とは形が異なる。
- 標準設計には話し言葉 300 テキストと書き言葉 200 テキストがある。 USA の HELM 対象は書き言葉 200 件だけ。
- 地域ごとの得点には、語法の差に加えて、収録ジャンルの構成も関わる。

[1] International Corpus of English. Design of ICE Corpora.
https://www.ice-corpora.uzh.ch/en/design.html
[2] HELM Classic v0.4.0, ICE.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/ice

共通設計と収集・注釈

同じ構成で集め、地域間の比較を支える

- 各チームが自国・地域の英語を収集する。公式サイトでは 26 の研究チームが参加している。
- 各地域は約 2,000 語のテキスト 500 件で構成する。短い素材を組み合わせて 1 件にする場合もある。
- 収録ジャンルと注釈方式を共通化し、地域ごとに集めた英語を同じ枠組みで比較できるようにした。

[1] International Corpus of English. University of Zurich. https://www.ice-corpora.uzh.ch/en.html

標準設計：話し言葉 60% 、書き言葉 40%

区分	テキスト数	構成比
対話	180	36%
独話	120	24%
非刊行の文章	50	10%
刊行された文章	150	30%

1 地域 500 テキストの標準構成。 1 件は約 2,000 語。

[1] International Corpus of English. Design of ICE Corpora.
https://www.ice-corpora.uzh.ch/en/design.html

話者・筆者には共通の採用条件がある

- 収録対象は 1990 年以降の英語。話者・筆者は 18 歳以上で、英語を教育言語とする教育を受けた人を対象にする。
- その国で生まれた人、または幼少時に移住し、その国で英語による教育を受けた人を採る。
- 性別と年齢層には幅があるが、政治・法律・教育などの活動に参加する人の構成は人口全体と同じではない。

[1] International Corpus of English. Design of ICE Corpora. https://www.ice-corpora.uzh.ch/en/design.html

転記・注釈は用途と地域で異なる

- 話し言葉は正書法で書き起こし、休止、重なり、言い直し、話者交替などを記す。書き言葉は段落・見出し・組版などを記す。
- ICE-GB では品詞タグと構文木を付与し、構文木を専用ソフト ICECUP で編集・修正した。
- ICE-online の PENN ・ CLAWS 品詞タグと依存構造は自動付与で、手作業での修正は行われていない。

[1] International Corpus of English. Annotation. https://www.ice-corpora.uzh.ch/en/annotate.html

HELM は注釈を整理し、本文を評価する

- 前処理では見出し・段落・強調などのタグを外し、コーパスに含めないと指定された部分や削除部分は内容ごと除く。
- 話者記号や一部の休止記号は残るため、書き起こしの特徴を含むテキストが評価対象になる。
- 文書はテスト用の入力として読み込み、本文への確率を評価する。質問に対する参照回答は付いていない。

[1] Stanford CRFM, HELM ICEScenario.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

HELM での言語モデル評価

指標：本文に付けた確率を要約する

- perplexity は、本文のトークンに付けた負の平均対数確率を指数に戻した値。小さいほど、そのモデルが高い確率を付けたことを示す。
- HELM は文字列の UTF-8 バイト数で正規化した bits per byte も報告する。これも小さいほどよい。
- モデルごとにトークン分割が異なるため、以下では共通のバイト単位による指標を使う。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR.
https://arxiv.org/abs/2211.09110

4 地域の英語で、モデルを比較する

地域	OPT-175B	text-davinci-003
East Africa	0.661	0.764
Hong Kong	0.767	0.891
India	0.794	0.895
USA （書き言葉）	0.700	0.720

HELM Classic の 2023 年の公開結果。各 1 試行、 bits per byte は小さいほどよい。

[1] HELM Classic v0.4.0, ICE.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/ice

地域ごとに、異なる構成のテキストを評価

- 2023 年の公開結果では、 OPT-175B と text-davinci-003 の 2 モデルを比較できる。ともに 2022 年に登場したモデルで、示した 4 地域では OPT-175B の bits per byte が小さい。
- 評価対象は East Africa が 625 件、 Hong Kong と India が各 500 件、 USA が 200 件。 USA は書き言葉のみで、他地域とは件数やジャンル構成が異なる。

[1] HELM Classic v0.4.0, ICE.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/ice

長い文書は、入力長に合わせて評価する

- HELM は例題を提示せず、本文の語や記号にモデルが付けた確率を取得する。新しい回答文は生成しない。
- 一つの文書が長い場合は、モデルの入力長に合わせて複数回に分けて処理する。文書数と、モデルを呼び出す回数は一致しない。

[1] HELM Classic v0.4.0, ICE.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/ice

地域や性別による差を調べる入口になる

- HELM は地域に加え、利用可能なメタデータに基づく male ／ female の条件も用意した。
- 収録ジャンル、話題、話者の属性、残った転記記号などが同時に変わるため、得点差だけで地域英語への偏りの原因を特定できない。
- 目的は、英語を一つの均質な集合として扱わず、条件を分けて言語モデルの振る舞いを調べることにある。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR.
https://arxiv.org/abs/2211.09110
[2] Stanford CRFM, HELM ICEScenario. v0.3.0.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

入手方法と活用

比較言語学の資料から、モデル評価にも

- 1990 年に、世界の英語を共通設計で比較する計画として始まった。品詞・構文や談話の分析が主要な用途だった。
- HELM では、複数地域の英語への言語モデルの適合度を測る資料として使う。
- 2026 年の公式サイトには Uganda や Trinidad and Tobago の完成案内もあり、 HELM の対象地域より活動範囲が広い。

[1] International Corpus of English. University of Zurich. https://www.ice-corpora.uzh.ch/en.html

地域ごとの配布窓口で、利用を申請する

- Zurich から配布されるコーパスは、非商用の学術研究向け。申請書を送り、教育機関のメールアドレスで資格を示す。Great Britain などは各編纂機関が配布する。
- 取得したコーパスの再配布は認められておらず、著作権は元の権利者に残る。出版物での短い引用も、著作権法で認められる範囲に従う。
- HELM で利用する場合は、取得済みの地域別ファイルを restricted/ice 以下へ配置する。

[1] International Corpus of English. Getting Access. https://www.ice-corpora.uzh.ch/en/access.html

ICE は多様な英語を比較する基盤

- 共通のジャンル構成と採用条件により、世界の英語を比較するための基盤を作った。
- HELM は本文への確率を採点し、地域やメタデータの条件ごとに言語モデルを比較する。
- 利用する地域や、話し言葉・書き言葉の構成、前処理を踏まえて比較し、各地域の利用条件に従う。

[1] International Corpus of English. Design of ICE Corpora.
https://www.ice-corpora.uzh.ch/en/design.html
[2] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR.
https://arxiv.org/abs/2211.09110

Appendix

1. 追加の実例
2. 収録ジャンルと評価対象
3. 研究と参考文献

実例 4 ：インドボダイジュと送粉

原文：連続した抜粋（空白を整形）

COVER STORY POLLINATION : THE FOUNTAINHEAD OF LIFE THE peepal tree, Ficus religiosa , also known as ashwattha , is a sacred tree for most Hindus and is also revered by Buddhists. This tree, found so commonly all over India, is home for a species of wasp - - Blastophaga quadraticeps .

日本語訳

特集記事
送粉：生命の源
インドボダイジュ（ Ficus religiosa ）は ashwattha とも呼ばれ、多くのヒンドゥー教徒にとって神聖な木で、仏教徒にも尊ばれている。インド各地にごく普通に見られるこの木は、 Blastophaga quadraticeps というハチのすみかになっている。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例５：ニュースの見出し

原文：連続した抜粋（空白を整形）

<$A> Good morning The headlines, Several nations are for sending, food and medicines for foreign nationals in Iraq and Kuwait, India urges the U N Secretary General for urgent steps to provide relief to the refugees stranded at the Iraq-Jordan border,

日本語訳

<$A> おはようございます。主なニュースです。
複数の国が、イラクとクウェートにいる外国人へ食料と医薬品を送ることに賛成しています。
インドは国連事務総長に、イラクとヨルダンの国境で足止めされている難民を救援するため、緊急の措置を求めています。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例 6 ：自動車工学の講義

原文：連続した抜粋（空白を整形）

<$A> My name is Madhu Purohit an Automobile Engineer done my, masters in Motor Vehicle Technology from Germany,

日本語訳

<$A> 私はマドゥ・プロヒトです。自動車エンジニアで、ドイツで自動車技術の修士号を取りました。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例７：下院議員の紹介

原文：連続した抜粋（空白を整形）

<$A> Good morning, Professor Savitri Laxmanan is a Congress-I member of parliament representing Mukundapuram of Kerala in the Lok Sabha , This is her first term as a member of parliament, Her entry into politics has been fairly recent,

日本語訳

<$A> おはようございます。サヴィトリ・ラクシュマナン教授は、ケーララ州のムクンダプラムを代表する国民会議派の下院議員です。議員を務めるのは今回が初めてで、政界入りしてからまだそれほどたっていません。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例 8 ：宇宙と破局をめぐる記事

原文：連続した抜粋（空白を整形）

SPACEWATCH KILLER STREAKERS FROM THE SKY ? ENVISIONING scenarios of the end of life on our planet is a favourite preoccupation of doomsday prophets. Nuclear war, natural disasters, attack from extra-terrestrial beings - - all these have been the subjects of science fiction stories.

日本語訳

宇宙ウォッチ
空から飛来する殺し屋？
地球上の生命が終わる筋書きを思い描くことは、終末を予言する人々が好んで取り組むことだ。核戦争、自然災害、地球外の存在による攻撃――これらはすべて SF 作品の題材になってきた。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例９：税制と経済発展の論考

原文：連続した抜粋（空白を整形）

Taxation Policies as an Aid to Economic Development JAL E. DASTUR * THE least that can be said is that we are today living in interesting times. It would not be untrue, or even an exaggeration, to say that no other period of 12 months in the whole history of our planet has seen such incredible changes as have taken place in the last 12 months. The Berlin Wall has been broken; the two Germanies have been united.

日本語訳

経済発展を支える税制
JAL E. DASTUR *
控えめに言っても、私たちは今、興味深い時代に生きている。地球の歴史のどの 12 か月を取っても、直近の 12 か月ほど信じ難い変化が起きた時期はない、と言っても誤りでも誇張でもないだろう。ベルリンの壁は崩れ、二つのドイツは統一された。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例 10 ：法の支配をめぐる論考

原文：連続した抜粋（空白を整形）

RULE OF LAW AND THE JUDICIAL PROCESS : SOME EMERGING CONCERNS THERE ARE several factors in modern democracies which constantly threaten the civilised and civilising principle of Rule of Law. Lack of legal certainty, decline in the effectiveness of the law and inequality in the legal processes tend to erode the supremacy of the law in varying degrees.

日本語訳

法の支配と司法過程：新たな懸念
現代の民主主義には、文明を支え育む「法の支配」の原則を絶えず脅かす要因がいくつもある。法的確実性の不足、法の実効性の低下、法的手続きの不平等が、程度の差はあれ法の優位を損なう傾向にある。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B. https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例 11 ：食後の体調を話す会話

原文：連続した抜粋（空白を整形）

<$A> Hello Chandrakala, how are you, <$B> Fine, And how are you You seem to be quite lethargic, <$A> Oh it is because, uh one of our friends here, invited me for this, uh lunch you know, Uh I had a puran poli , and perhaps it has its effect,

日本語訳

<$A> こんにちは、チャンドラカラ。お元気ですか。
<$B> 元気です。あなたはどうですか。ずいぶんだるそうですね。
<$A> それは、ええと、ここの友人に昼食へ招かれたからなんです。プラン・ポリを食べたので、そのせいかもしれません。

プラン・ポリ：甘いあんを包んだ、インドの薄焼きパン。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例 12 ：国民所得の講演

原文：連続した抜粋（空白を整形）

<$A> Ah uhm, uh thank you very much, uh professor Kohli, spoke, so nice words about me, uh, I don't know how much I deserve them, Uhm, professor Kohli requested me to talk on, " National income uh accounts ", Uhm, my purpose here was, to, make things very simple,

日本語訳

<$A> ああ、ええと、ありがとうございます。コーリ教授に素晴らしいお言葉をいただきました。私がどれほどそのお言葉にふさわしいかは分かりませんが。
教授から「国民所得勘定」について話すよう頼まれました。私の目的は、ごく分かりやすくお話しすることです。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

実例 13 ：財政赤字についての社説

原文：連続した抜粋（空白を整形）

EDITORIAL <*> five blank lines</*> DISQUIETING FISCAL SCENARIO <*> four blank lines</*> IN its Report on Currency and Finance for 1989-90, the Reserve Bank of India has forecast a higher deficit in the current year and has called for adjustments to reduce the serious fiscal imbalance in order to foster growth with stability.

日本語訳

社説 <*> 空行 5 行 </*>
不穏な財政状況 <*>
空行 4 行 </*>
インド準備銀行は 1989 ～ 90 年の通貨・金融報告で、今年度の赤字が拡大すると予測し、安定した成長を促すため、深刻な財政不均衡を是正する措置を求めた。

[1] Stanford CRFM (2023). HELM Classic: ICE India / OPT-175B.
https://crfm.stanford.edu/helm/classic/v0.4.0/#/runs/ice:subset=ind,model=together_opt-175b

話し言葉：対話 180 件の構成

区分	内容	件数
私的対話	対面会話／電話	90 ／ 10
公的対話	授業／放送討論	20 ／ 20
公的対話	放送インタビュー／議会討論	10 ／ 10
公的対話	法廷尋問／商取引	10 ／ 10

[1] International Corpus of English. Design of ICE Corpora.
https://www.ice-corpora.uzh.ch/en/design.html

話し言葉：独話 120 件の構成

区分	内容	件数
台本なし	実況／スピーチ	20 ／ 30
台本なし	実演／法的陳述	10 ／ 10
台本あり	放送ニュース／放送講話	20 ／ 20
台本あり	放送以外の講話	10

[1] International Corpus of English. Design of ICE Corpora. https://www.ice-corpora.uzh.ch/en/design.html

書き言葉 200 件の構成

種類	テキスト数
学生の文章／手紙	20 ／ 30
学術文／一般向け解説	40 ／ 40
報道／説明・手引き	20 ／ 20
社説／創作	10 ／ 20

[1] International Corpus of English. Design of ICE Corpora. https://www.ice-corpora.uzh.ch/en/design.html

地域とジャンルを選んで、 HELM へ読み込む

- HELM の実装は、 Canada 、 Jamaica 、 Hong Kong 、 India 、 Singapore 、 Philippines 、 USA 、 East Africa 、 Ireland の 9 地域に対応する。コーパス本体は、各配布元で取得する。
- category で話し言葉（ S ）と書き言葉（ W ）を選べる。さらに対話（ S1 ）・独話（ S2 ）、非刊行（ W1 ）・刊行（ W2 ）の文章に絞ることもできる。

[1] Stanford CRFM, HELM ICEScenario.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

性別で文書を選ぶ方法は、地域ごとに異なる

- Canada 、 Hong Kong 、 India 、 USA では、付属のメタデータから male ／ female の文書を選べる。
- India と USA では、読み取った性別情報がすべて指定条件に合う文書を選ぶ。 Canada と Hong Kong では、所定の列のいずれかが一致すれば選ぶ。
- 地域ごとに選び方が異なるため、性別別の結果を比べる際には、どの話者を含む文書なのかを確認する。

[1] Stanford CRFM, HELM ICEScenario.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

参考文献

International Corpus of English

University of Zurich ／ ICE teams. (n.d.). 1990 年開始。 2026-10-18 参照。

地域別コーパスの目的、共通設計、参加チームと配布窓口をまとめる。

https://www.ice-corpora.uzh.ch/en.html

Markup Manual for Spoken Texts

Gerald Nelson (2002). International Corpus of English.

休止、話者交替、重なり、言い直しなどの転記規則と、必須・推奨・任意の注釈を定める。

https://www.ice-corpora.uzh.ch/en/manuals.html

参考文献

Markup Manual for Written Texts

Gerald Nelson (2002). International Corpus of English.

見出し、段落、組版、引用、非コーパス部分などの記号化を規定する。

https://www.ice-corpora.uzh.ch/en/manuals.html

Holistic Evaluation of Language Models

Percy Liang et al. (2023). Transactions on Machine Learning Research.

精度、頑健性、公平性などを共通の枠組みで評価する HELM を提案し、 ICE を言語モデル評価に用いる。

https://arxiv.org/abs/2211.09110

参考文献

ICEScenario

Stanford CRFM (2023). HELM v0.3.0, Python implementation.

地域別ファイルの読み込み、タグ前処理、カテゴリとメタデータの選別を実装する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/ice_scenario.py

HELM Classic: ICE

Stanford CRFM (2023). Classic v0.4.0, released 2023-11-17.

公開 run の地域・性別条件と、言語モデルが本文に与えた確率に基づく評価値を掲載する。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/ice