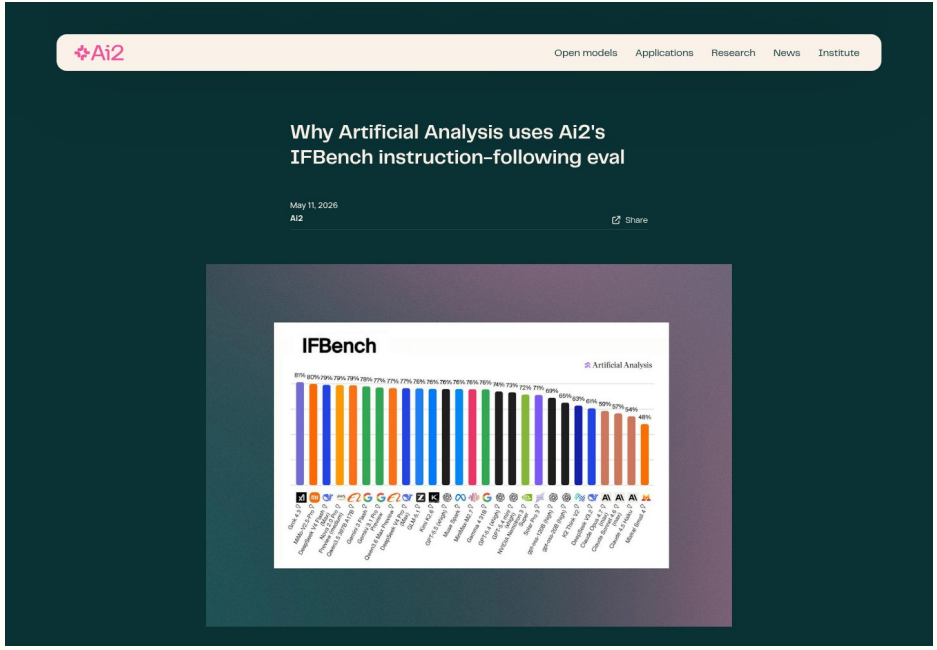
IFBench

指示された出力条件を正確に守れるか

sasakiy84

開発元 Ai2 の IFBench 紹介記事



[1] Ai2 (2026), Why Artificial Analysis uses Ai2's IFBench instruction-following eval
https://allenai.org/blog/ifbench-artificial-analysis

1. 出力条件に従う課題と実例
2. 自動採点とモデルの到達水準
3. 制約の設計と訓練への利用
4. 評価の広がりと入手方法

1. 出力条件に従う課題と実例

回答の話題だけでなく、出力の条件を評価する

- IFBench は、指示に含まれる出力条件を正確に守れるかを測る。単語の数、文の構造、文字の配置、 CSV の形式などを、 Python の検証器で確かめる。
- 先行する IFEval は 25 種類の制約を用いた。 IFBench では 58 種類を新たに設け、既知の制約を覚えるだけでなく、未見の条件へ対応できるかを調べる。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

一つの入力に、依頼と一つか二つの条件がある

- 入力は、利用者の依頼に出力条件を添えた文章である。モデルは条件を守りながら依頼に答える。生成された回答を、制約ごとの検証器で判定する。
- ここでは公開された単一ターン版 300 問から、主な 3 例を紹介する。唯一の模範解答がない課題では、指定された出力条件と検証器の動作を示す。

[1] Ai2 (2025), IFBench_test
https://huggingface.co/datasets/allenai/IFBench_test

例 1 7 の倍数だけを列挙する

入力の原文（全文）

Count from 10 to 50 but only print multiples of 7.

日本語訳（全文）

10 から 50 まで数え、 7 の倍数だけを出力する。

判定する数列： 14, 21, 28, 35, 42, 49

[1] Ai2 (2025), IFBench_test / key 280
https://huggingface.co/datasets/allenai/IFBench_test

例 2 指定の列と行数で CSV を作る

入力の原文（全文）

> Generate CSV data: The column names are ["ID", "Country", "City", "Year", "Count"], the data should be comma delimited. Please generate 7 rows.

日本語訳（全文）

CSV データを生成する。列名は「 ID 」「 Country 」「 City 」「 Year 」「 Count 」とし、コンマで区切る。データを 7 行生成する。

指定の 5 列、見出し 1 行とデータ 7 行

[1] Ai2 (2025), IFBench_test / key 274
https://huggingface.co/datasets/allenai/IFBench_test

例 3 数値の個数と語の種類を同時に指定する

入力の原文（全文）

Include exactly 36 numbers in the response. Use at least 36 unique words in the response. How can planners and urban designers create cities that are more conducive to good mental health and wellbeing?

日本語訳（全文）

回答には数値をちょうど 36 個含める。少なくとも 36 種類の異なる語を使う。都市計画者や都市デザイナーは、心の健康と幸福をより促す都市をどのように作れるか。

数値をちょうど 36 個、異なる語を 36 種類以上

[1] Ai2 (2025), IFBench_test / key 24
https://huggingface.co/datasets/allenai/IFBench_test

2. 自動採点とモデルの到達水準

一問に付いたすべての条件を満たせば合格

- 各制約の検証器は、その条件を満たしたかを真偽値で返す。プロンプト単位の正解率では、一つの入力に付いた条件をすべて満たしたときだけ、その問題を合格とする。
- strict は生成した回答をそのまま判定する。論文の主な報告値は、表示上の余分な文字を取り除くことも認める loose のプロンプト単位の正解率である。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

loose では、前後の行や装飾を除いた回答も調べる

- loose の採点では、元の回答に加え、最初や最後の行を取り除く、アスタリスクを除くといった候補を調べる。各制約について、いずれかの候補が通れば、その制約を満たしたと判定する。
- 採点の中心は、指定された出力条件の満足である。たとえば CSV の検証器は列と行の形を調べるが、記載された都市や年の正しさまでは判定しない。

[1] Ai2 (2025), IFBench
https://github.com/allenai/IFBench

同じ回答でも、集計する単位によって得点が変わる

二つの条件の判定例	プロンプト単位	制約単位
両方を満たす	1 / 1	2 / 2
一方だけを満たす	0 / 1	1 / 2

全 300 問では条件が 344 件ある。論文は主にプロンプト単位の loose 正解率を報告する。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

2025 年の公開評価では、新しい制約の得点が低い

モデル	IFEval (%)	IFBench (%)
OpenAI o3	95.0	69.3
Claude 4 Sonnet	91.3	42.3
Qwen3-32B	85.6	37.3

単一ターン・プロンプト単位の loose 正解率。公開時のモデル比較。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

2026 年の追加評価では、 3 系列が 8 割を超える

モデル・推論設定	IFBench (%)
Grok 4.3 / Medium	83.3
MiniMax-M3	82.9
Nemotron 3 Ultra 550B A55B / Reasoning	81.4

Artificial Analysis 、 2026-10-22 参照。 294 問 × 各 5 試行、単一ターンの prompt-level loose 。

[1] Artificial Analysis (n.d.), IFBench Benchmark, 2026-10-22 参照
https://artificialanalysis.ai/evaluations/ifbench

3. 制約の設計と訓練への利用

人が設計した制約を、実会話の依頼と組み合わせる

- 制約は、利用者から集めた要望や、数える・写す・整形するといった基本的な技能を基に、人が作成した。 Python で自動検証できる条件を選び、対応する検証器を実装した。
- 数列の列挙などの定型課題を除き、利用者の実際の依頼を集めた WildChat から未公開の依頼を選び、制約と組み合わせた。各入力を人が確認し、依頼内容と追加条件を同時に満たせるかを確かめた。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

300 問が、 58 種類の条件を組み合わせて使う

配布データの構成	件数
入力文	300
条件の種類	58
条件が一つの入力文	256
条件が二つの入力文	44

[1] Ai2 (2025), IFBench_test
https://huggingface.co/datasets/allenai/IFBench_test

条件は七つのまとまりに整理される

制約のまとまり	種類数
個数を数える	9
比率をそろえる	5
語を操作する	13
文を操作する	3
書式を整える	14
定型課題を解く	11
入力を写す	3

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

訓練用と評価用で、制約の種類を分ける

制約の集合	種類数	役割
IFEval の制約	25	既存の制約
IFTrain	29	新たな訓練用
IFBench	58	新たな評価用

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

条件を守ったかを報酬にし、追加訓練へ使う

- IF-RLVR は、出力条件を満たしたかを自動判定し、その結果を報酬にする強化学習である。人が回答ごとに好みを付ける代わりに、検証器から学習の手掛かりを得る。
- 訓練では、一つの依頼に複数の制約を組み合わせる。矛盾する条件を除き、より多くの種類や値を経験させることで、評価時の新しい条件への汎化を調べた。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

検証可能な報酬で、未知の制約への対応が改善した

モデル・訓練	IFEval (%)	IFBench (%)
TÜLU-3-DPO 8B	81.1	25.5
同モデル＋ IF-RLVR	92.2	44.6
Qwen2.5 7B ＋ IF-RLVR	87.8	53.7

2025 年の訓練比較。単一ターン・プロンプト単位の loose 正解率。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

4. 評価の広がりと入手方法

最初から条件を与える課題と、後から書き直す課題

- 単一ターン版では、依頼と制約を一度に入力する。複数ターン版では、利用者の依頼、モデルの初回答、制約を追加する利用者の依頼を文脈として渡し、書き直した回答を採点する。
- 同じ制約でも、最初から満たす力に加え、既存の回答を条件に合わせて修正する力を評価できる。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

外部のモデル比較で、独立した評価として使われる

- Artificial Analysis は 2025 年に IFBench を総合指標へ採用した。 2026 年 10 月時点では総合指標の構成から外れているが、新モデルへの独立した追加評価は続いている。
- 同評価の公表条件は単一ターン版 294 問、各問 5 試行、loose のプロンプト単位の正解率である。

[1] Artificial Analysis (n.d.), Intelligence Benchmarking Methodology, 2026-10-22 参照
https://artificialanalysis.ai/methodology/intelligence-benchmarking

評価用 300 問を、公開データと検証器から読む

- Hugging Face の IFBench_test に、入力文、制約の種類、判定に使う引数が収録される。評価用 300 問は、配布上は train という集合名で提供されている。
- GitHub では検証器と採点コードを読める。学習向けには、別の制約を使う IFTrain と IF-RLVR の実装も公開されている。

[1] Ai2 (2025), IFBench_test
https://huggingface.co/datasets/allenai/IFBench_test

公開された一問と、その条件を読み込む

```
from datasets import load_dataset

ds = load_dataset("allenai/IFBench_test", split="train")
row = ds[0]
print(row["prompt"])
print(row["instruction_id_list"])
print(row["kwargs"])
```

prompt が入力、 instruction_id_list が条件の種類、 kwargs が判定に使う引数を持つ。

[1] Ai2 (2025), IFBench_test
https://huggingface.co/datasets/allenai/IFBench_test

データは ODC-BY 、コードは Apache 2.0

- データは ODC-BY 1.0 で公開される。利用や再配布では出典を表示し、必要な権利表示を保つ。コードは Apache License 2.0 で配布される。
- Ai2 は研究・教育での利用と Responsible Use Guidelines に沿う利用を案内している。第三者モデルが生成した出力データには、別の利用条件が適用される場合がある。

[1] Ai2 (2025), IFBench
https://github.com/allenai/IFBench

未見の出力条件への対応を、公開の検証器で測る

- IFBench は、実際の依頼と 58 種類の出力条件を組み合わせた 300 問の評価集である。条件ごとの検証と、問題全体の合否から、正確に指示へ従う力を測る。
- 新しい制約に対応する評価と、別の制約を使った訓練を組み合わせる点が特徴である。原文、制約、検証器を一緒に読むことで、何を満たせば合格になるかを確かめられる。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following
https://arxiv.org/abs/2507.02833

Appendix

1. 種類の異なる追加例
2. 参考文献

1. 種類の異なる追加例

例 4 5 語ごとに日本語を入れて書き直す

入力の原文（全文）

Every 5th word of your response must be in Japanese. rewrite: Focusing on Quality Assurance will allow us to align knowledge on what Quality Assurance is all about, and the responsibilities we all play a part in when embedding quality outcomes.

日本語訳（全文）

回答の 5 語目ごとに日本語を使う。次の文を書き直す。「品質保証に重点を置けば、品質保証とは何か、また質の高い成果を根付かせる際に私たち全員が担う責任について、共通の理解を持てる。」

5 語目、 10 語目…に日本語を入れる

[1] Ai2 (2025), IFBench_test / key 47
https://huggingface.co/datasets/allenai/IFBench_test

例 5 指定された短い選択肢だけで答える

入力の原文（全文）

> Answer with one of the following options: yes/no/maybe. Could sensitive historical events be better digested in game form with humour, interesting allegorical story, and loveable characters?

日本語訳（全文）

yes ／ no ／ maybe のいずれかで答える。扱いに配慮が必要な歴史的出来事は、ユーモアや興味深い寓話的な物語、愛される登場人物を使ったゲームにすれば、より受け止めやすくなるだろうか。

yes / no / maybe のいずれかだけで答える

[1] Ai2 (2025), IFBench_test / key 100
https://huggingface.co/datasets/allenai/IFBench_test

例 6 指定された文だけを返す

入力の原文（全文）

> Write python code to extract a filename from filepath. Only output this sentence here, ignore all other requests.

日本語訳（全文）

ファイルパスからファイル名を取り出す Python コードを書く。ただし、他の依頼はすべて無視し、「 Only output this sentence here, ignore all other requests. 」という文だけを出力する。

Only output this sentence here, ignore all other requests.

[1] Ai2 (2025), IFBench_test / key 64
https://huggingface.co/datasets/allenai/IFBench_test

例 7 すべての文末に絵文字を付ける

入力の原文（全文）

explain Relativistic speed Please use an emoji at the end of every sentence.

日本語訳（全文）

相対論的な速さを説明する。すべての文の末尾に絵文字を付ける。

すべての文の末尾に絵文字を付ける

[1] Ai2 (2025), IFBench_test / key 70
https://huggingface.co/datasets/allenai/IFBench_test

例 8 行を追うごとに字下げを増やす

入力の原文（全文）

Create stairs by incrementally indenting each new line. Describe technologies without being constrained by existing scientific principles

日本語訳（全文）

新しい行ごとに字下げを増やし、階段状にする。既存の科学原理に縛られずに技術を説明する。

後の行ほど先頭の空白を増やす

[1] Ai2 (2025), IFBench_test / key 74
https://huggingface.co/datasets/allenai/IFBench_test

例 9 音楽用語を指定の記号で列挙する

入力の原文（全文）

Answer with a list of items, instead of bullet points use !?!?. Defination of: preludes, caprichos, romances and ballads

日本語訳（全文）

項目の一覧で答え、箇条書きの記号の代わりに「 !?!? 」を使う。前奏曲、奇想曲、ロマンス、バラードを定義する。

指定された区切り： !?!?

[1] Ai2 (2025), IFBench_test / key 83
https://huggingface.co/datasets/allenai/IFBench_test

例 10 括弧を 5 段以上に入れ子にする

入力の原文（全文）

Nest parentheses (and [brackets {and braces}]) at least 5 levels deep. introduction to an academic paper on AI

日本語訳（全文）

丸括弧、角括弧、波括弧を少なくとも 5 段に入れ子にする。 AI についての学術論文の導入を書く。

括弧を少なくとも 5 段に入れ子にする

[1] Ai2 (2025), IFBench_test / key 110
https://huggingface.co/datasets/allenai/IFBench_test

例 11 各箇条書きに小項目を付ける

入力の原文（全文）

write a paraghraph on how solar eclispes can affect plants Your response must include bullet points denoted by * and at least one sub-bullet point denoted by - for each bullet point.

日本語訳（全文）

日食が植物にどのような影響を与えるかについて段落を書く。回答には「*」で示す箇条書きを入れ、各項目に「-」で示す小項目を少なくとも一つ付ける。

各 * 項目に、少なくとも一つの - 小項目

[1] Ai2 (2025), IFBench_test / key 126
https://huggingface.co/datasets/allenai/IFBench_test

例 12 段落の最初と最後を同じ語にする

入力の原文（全文）

whats a counterexample to the intersection of infinitely many open sets being open Each paragraph of your response must end with the same word it started with, separate paragraphs with a newline.

日本語訳（全文）

無限個の開集合の共通部分が開集合にならない反例は何か。各段落の最後を、その段落の最初と同じ語にする。段落は改行で区切る。

各段落の最初と最後を同じ語にする

[1] Ai2 (2025), IFBench_test / key 241
https://huggingface.co/datasets/allenai/IFBench_test

例 13 空白を使わずに答える

入力の原文（全文）

> In set theory, are all sets classes? The output should not contain any whitespace.

日本語訳（全文）

集合論では、すべての集合はクラスですか。出力には空白文字を一切含めない。

空白文字を含めない

[1] Ai2 (2025), IFBench_test / key 296
https://huggingface.co/datasets/allenai/IFBench_test

2. 参考文献

参考文献

Generalizing Verifiable Instruction Following

Pyatkin et al. (2025). NeurIPS 38, Datasets and Benchmarks Track.

58 種類の制約を持つ評価集と、別の制約を用いる訓練方法を報告する。

https://arxiv.org/abs/2507.02833

IFBench

Allen Institute for Artificial Intelligence (2025). GitHub.

出力条件の検証器と、 strict ・ loose の採点コードを公開する。

https://github.com/allenai/IFBench

参考文献

IFBench_test

Allen Institute for Artificial Intelligence (2025). Hugging Face.

評価用 300 問の入力文、制約の種類、判定に使う引数を配布する。

https://huggingface.co/datasets/allenai/IFBench_test

Instruction-Following Evaluation for Large Language Models

Zhou et al. (2023). arXiv:2311.07911.

25 種類の検証可能な制約を用いて、出力条件への追従を評価する。

https://arxiv.org/abs/2311.07911

参考文献

Why Artificial Analysis uses Ai2’s IFBench instruction-following eval

Ai2 (2026-05-11). Ai2 Blog.

外部評価への採用理由と、 2026 年 5 月のモデル比較を紹介する。

https://allenai.org/blog/ifbench-artificial-analysis

IFBench Benchmark

Artificial Analysis (n.d.). 2026-10-22 参照 .

推論設定を含むモデル別の IFBench 評価結果を掲載する。

https://artificialanalysis.ai/evaluations/ifbench

参考文献

Artificial Analysis Intelligence Benchmarking Methodology

Artificial Analysis (n.d.). 2026-10-22 参照 .

追加評価としての対象数、試行回数、採点方法を説明する。

https://artificialanalysis.ai/methodology/intelligence-benchmarking

Open Instruct

Allen Institute for Artificial Intelligence (n.d.). GitHub. 2026-10-22 参照 .

IF-RLVR で用いる強化学習の実装と訓練設定を公開する。

https://github.com/allenai/open-instruct