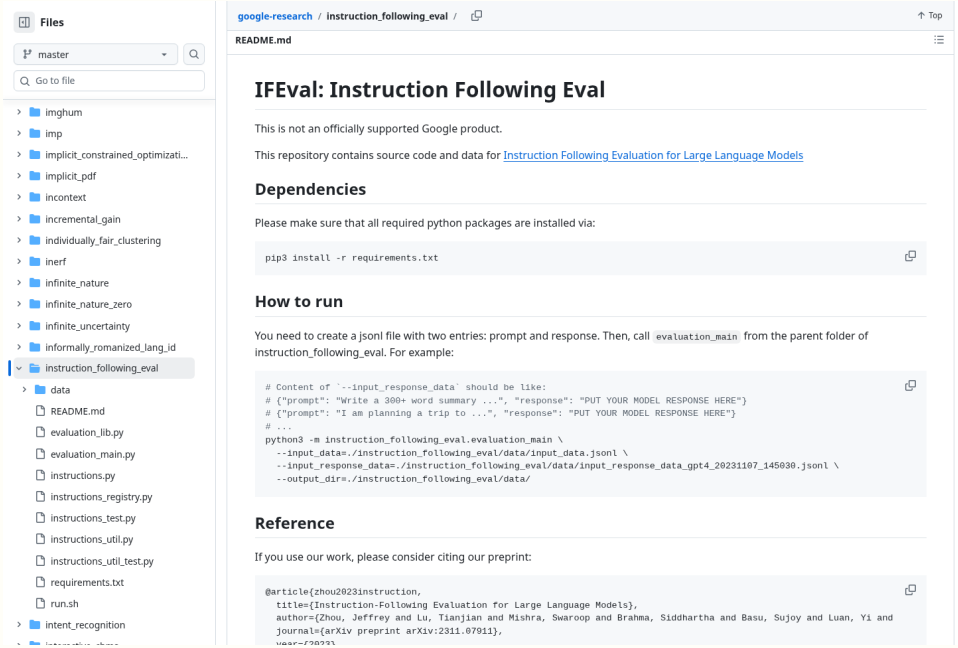
IFEval

Instruction-Following Eval

回答の長さ・単語・形式の指定を守れるかを測る

sasakiy84

IFEval の公式リポジトリ



[1] Google Research (2026-10-26 参照), IFEval: Instruction Following Eval.
https://github.com/google-research/google-research/tree/master/instruction_following_eval

1. 検証できる指示と公開実例
2. 採点方法とモデルの成績
3. 指示の作成とデータの構成
4. 後続研究との関係と入手方法

1. 検証できる指示と公開実例

回答の長さ・単語・形式の指定を守れるか測る

- IFEval は、回答に求めた条件をプログラムで確かめる、言語モデルの指示追従ベンチマークである。例えば「300 語以上」「JSON で返す」「特定の語を含める」といった条件を扱う。
- 541 件の依頼に、一つから三つの検証可能な指示を組み合わせた。自由に文章を書く課題なので、決まった正解文の代わりに、満たすべき条件を確認する。

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

依頼文と、判定する条件を対応させる

- ここで示す 13 例は、公式の 541 件から選んだ。旅行日程、広告、履歴書などの依頼を、原文・日本語訳・要求する形式で示す。
- 自動判定の対象は、データに指定された検証可能な条件である。例えば「面白い広告を書く」依頼に JSON 形式を指定した場合、機械判定では JSON として読めるかを確かめる。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 1 カンマを使わずに旅行日程を書く

問題の原文（全文）

> I am planning a trip to Japan, and I would like thee to write an itinerary for my journey in a Shakespearean style. You are not allowed to use any commas in your response.

日本語訳（全文）

日本への旅行を計画している。旅の日程をシェイクスピア風の文体で書いてほしい。回答にはカンマを一切使わないこと。

要求する形式：カンマを使わない

旅行日程を自由に作る依頼に、句読点の制約を加えている。この問題の自動判定は、回答に半角カンマが含まれていないかを確認する。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 2 広告を JSON 形式で返す

問題の原文（全文）

> Can you help me make an advertisement for a new product? It's a diaper that's designed to be more comfortable for babies and I want the entire output in JSON format.

日本語訳（全文）

新商品の広告を作るのを手伝ってほしい。赤ちゃんがより快適に過ごせるように設計したおむつである。出力全体を JSON 形式にしてほしい。

要求する形式：出力全体を JSON にする

JSON は、名前と値の組などで情報を表す。回答を JSON として読み込めるかを判定する。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 3 キーワードと引用符を両方守る

問題の原文（全文）

> Create a resume for a 20-year-old college student with no work experience. Include the keywords "Python" and "Java" and wrap the response with double quotation marks.

日本語訳（全文）

職歴のない 20 歳の大学生の履歴書を作ってほしい。キーワード「 Python 」と「 Java 」を含め、回答全体を二重引用符で囲むこと。

要求する形式： Python ・ Java と二重引用符

二つのキーワードを含むことと、回答全体を引用符で囲むことを別々に判定する。プロンプト単位では、両方を満たした回答だけが成功となる。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

2. 採点方法とモデルの成績

各指示を判定し、設問全体の成否へまとめる

- まず、回答が個々の条件を満たすかを真・偽で判定する。例えば履歴書の例では、キーワードを含むことと、二重引用符で囲むことを別々に確認する。
- 設問単位の成功には、その設問の全条件を満たす必要がある。指示単位の成功率は、全設問に含まれる個々の条件をまとめて集計する。

[1] Google Research (2026-10-26 参照), IFEval evaluation_lib.py.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/evaluation_lib.py

厳密判定に加え、軽い整形後の判定も報告する

- 厳密判定（strict）は、モデルの回答をそのまま検査する。緩和判定（loose）は、元の回答と、アスタリスクや先頭・末尾の行を除いた候補を検査する。
- 例えば、指定された結びの文が Markdown の太字で囲まれていると、文字列の完全一致では失敗することがある。緩和判定は、このような表面的な差を吸収する。

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

集計単位と判定の厳しさから、四つの指標を作る

集計単位	厳密判定（ strict ）	緩和判定（ loose ）
設問単位	全条件を満たす設問の割合	整形も試した全条件達成率
指示単位	個々の条件を満たす割合	整形も試した条件達成率

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

2023 年の GPT-4 は、厳密な全条件成功率が 76.89%

モデル	設問・厳密	指示・厳密	設問・緩和	指示・緩和
GPT-4	76.89	83.57	79.30	85.37
PaLM 2 S	43.07	55.76	46.95	59.11

単位は % 。 GPT-4 は 2023 年 11 月、 PaLM 2 S は 2023 年 8 月に回答を取得。

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

3. 指示の作成とデータの構成

基本の依頼に条件を加え、人が一件ずつ整える

- まず、基本の依頼へ一つから三つの検証可能な指示を加える。少数の例を示してモデルに処理させる方法で、不合理な組合せを取り除く。
- 続いて、同じ条件をさまざまな表現へ言い換える。最後に人が全件を確認・修正し、条件の矛盾や不自然な依頼を減らす。

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

25 種類の指示を、九つのグループに整理した

- キーワード、言語、長さ、追伸などの内容、箇条書きなどの形式、回答の組合せ、大文字・小文字、冒頭・末尾、句読点を扱う。
- 同じ種類の指示でも、必要な語数や単語、表現を変えている。特定の条件を、同じ言い回しだけで評価しないようにした。

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

検証条件の数では、1 条件の設問が最も多い

1 設問の条件数	設問数
1	305
2	179
3	57
合計	541

公式公開データの全 541 設問を集計。判定条件は計 834 個。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

4. 後続研究との関係と入手方法

IFBench は、未知の種類の指示へ評価を広げた

- 2025 年の IFBench は、 IFEval から発展し、 58 種類の新しい条件を使って、学習時に見ていない指示への対応を調べる。複数ターンで条件を追加する版もある。
- 現在の公開実装には、 IFEval の 25 種類の判定器も含まれる。 IFEval の既存条件と、 IFBench が追加した条件を選んで評価できる。

[1] Ai2 (2026-10-26 参照), Generalizing Verifiable Instruction Following.
https://github.com/allenai/IFBench

2025 年の比較では、既存条件と新条件で差が出た

モデル	IFEval	IFBench
Gemini 2.5 Pro	65.4	52.3
Claude 4 Sonnet	91.3	42.3
OpenAI o3	95.0	69.3

設問単位・緩和判定（％）。通常は温度 0 、 o3 は温度 1 で生成した結果。

[1] Pyatkin et al. (2025), Generalizing Verifiable Instruction Following.
https://arxiv.org/abs/2507.02833

公開された判定器を、モデル比較に利用できる

- IFEval は、主観的な文章の好みを判定する方法と並んで、明示した条件を守る力を調べる基準として使われている。公式データと判定コードは公開されている。
- モデルの成績を比べるときは、設問単位か指示単位か、厳密判定か緩和判定かをそろえる。 IFBench の成績は、別の条件集合の結果として示される。

[1] Ai2 (2026-10-26 参照), Generalizing Verifiable Instruction Following.
https://github.com/allenai/IFBench

公式リポジトリで、依頼文と判定条件を取得する

- input_data.jsonl の prompt に依頼文、 instruction_id_list に判定器の種類、 kwargs に語数やキーワードなどの条件が入っている。 key は設問を特定する番号である。
- Google Research の公式コードとデータは、 Apache License 2.0 で公開される。再配布では、ライセンスと必要な帰属情報を保持する。

[1] Google Research (2026-10-26 参照), IFEval: Instruction Following Eval.
https://github.com/google-research/google-research/tree/master/instruction_following_eval

依頼文と、その形式条件を読み取る

```
import json

with open("input_data.jsonl", encoding="utf-8") as f:
    row = json.loads(next(f))

print(row["prompt"])
print(row["instruction_id_list"], row["kwargs"])
```

公式リポジトリの data/input_data.jsonl を使う。依頼文と、検査する条件を対応させる。

[1] Google Research (2026-10-26 参照), IFEval: Instruction Following Eval.
https://github.com/google-research/google-research/tree/master/instruction_following_eval

自由な文章生成に、確認できる条件を与える

- IFEval は、 541 件の依頼と 25 種類の指示を使い、回答の長さ・単語・形式を守る力を評価する。個々の指示と、全条件を満たした設問をそれぞれ集計する。
- 厳密判定と緩和判定で、形式上の差による失敗も調べられる。公開データから依頼文と条件を読み、後続の IFBench へ広がった指示追従評価につなげられる。

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

Appendix

1. 形式の異なる追加例
2. 指示の一覧と参考文献

1. 形式の異なる追加例

例 4 差し込み欄を含む履歴書を書く

問題の原文（全文）

> Write a resume for a fresh high school graduate who is seeking their first job. Make sure to include at least 12 placeholder represented by square brackets, such as [address], [name].

日本語訳（全文）

初めての仕事を探している、高校を卒業したばかりの人の履歴書を書いてほしい。 [address] や [name] のように、角括弧で表す差し込み欄を 12 個以上含めること。

要求する形式：角括弧の欄を 12 個以上

判定では、角括弧で囲まれた部分を数える。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 5 小文字だけで手紙を書く

問題の原文（全文）

> Write a letter to a friend in all lowercase letters ask them to go and vote.

日本語訳（全文）

友人に投票へ行くよう呼びかける手紙を、すべて小文字で書いてほしい。

要求する形式：英語の小文字だけ

英文の内容に加えて表記を指定している。小文字かどうかと英語かどうかを、公開された判定器で確認する。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 6 対話を三つの箇条書きにする：原文

問題の原文（全文）

Write a dialogue between two people, one is dressed up in a ball gown and the other is dressed down in sweats. The two are going to a nightly event. Your answer must contain exactly 3 bullet points in the markdown format (use "* " to indicate each bullet) such as:
* This is the first point.
* This is the second point.

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 6 対話を三つの箇条書きにする：日本語訳と条件

日本語訳（全文）

一人は舞踏会用のドレス、もう一人はスウェットという対照的な服装の二人が、夜の催しに出かける場面の対話を書いてほしい。回答は Markdown の箇条書きで、項目をちょうど 3 個にする。「* 」で各項目を始める。例：
* これが一つ目の項目。
* これが二つ目の項目。

要求する形式：箇条書きがちょうど 3 項目

自然な会話を書く依頼に、項目数の条件を加えている。公開コードは、行頭の「* 」または「- 」から始まる箇条書きを数える。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 7 物語を二つの段落にする

問題の原文（全文）

> Write a story of exactly 2 paragraphs about a man who wakes up one day and realizes that he's inside a video game. Separate the paragraphs with the markdown divider: ***

日本語訳（全文）

ある日目を覚ますと、自分がビデオゲームの中にいると気付いた男性の物語を、ちょうど 2 段落で書いてほしい。段落は Markdown の区切り「 *** 」で分けること。

要求する形式：「 * 」で分けた 2 段落**

判定も、指定記号「 *** 」による段落の区切りに基づく。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 8 語数の上限を守る

問題の原文（全文）

> Write a short blog post about a trip to Japan using less than 300 words.

日本語訳（全文）

日本旅行について、 300 語未満の短いブログ記事を書いてほしい。

要求する形式： 300 語未満

内容は自由に書けるが、長さに上限がある。公開された単語の数え方で 299 語以下なら、この制約を満たす。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 9 二つの回答を区切って出す

問題の原文（全文）

> What is a name that people call God? Please give exactly two different responses. Separate the responses with 6 asterisk symbols: ******.

日本語訳（全文）

神を呼ぶときに人々が使う名前には、どのようなものがあるか。異なる回答をちょうど二つ示してほしい。回答の間を、アスタリスク 6 個「 ****** 」で区切ること。

要求する形式：「 **** 」で二つに分ける**

区切った二つの部分が空でなく、同じ内容でないことを確かめる。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 10 節の見出しと結びの文を指定する：原文

問題の原文（全文）

> Write a poem about how I am missing my classes. The poem must have 4 sections marked with SECTION X. Finish the poem with this exact phrase: "Can I get my money back for the classes I missed?"

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 10 節の見出しと結びの文を指定する：日本語訳と条件

日本語訳（全文）

授業に出られずにいる気持ちを詩にしてほしい。 SECTION X と記した 4 節で構成し、最後を次の文で終えること。「 Can I get my money back for the classes I missed? 」（欠席した授業の料金を返してもらえますか。）

要求する形式： 4 節と指定された結び

設問は 4 節を要求する。公開コードは SECTION と番号の組を 4 個以上検出し、末尾が指定文と一致するかを別に確認する。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 11 追伸を付ける

問題の原文（全文）

> Write me a template for a product description in the form of a poem and end it with a post script starting with P.P.S

日本語訳（全文）

商品説明のテンプレートを詩の形で書いてほしい。最後に、 P.P.S で始まる追伸を付けること。

要求する形式： P.P.S で始まる追伸

商品説明を詩にする依頼へ、追伸を加える条件を付けている。公開コードは、指定された追伸の印があるかを確認する。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 12 特定の語を繰り返す

問題の原文（全文）

> List the pros and cons of using two different names for the same thing. Make sure the word synonyms appears at least 3 time.

日本語訳（全文）

同じものに二つの異なる名前を使うことの長所と短所を挙げてほしい。「 synonyms 」という語を 3 回以上使うこと。

要求する形式： synonyms を 3 回以上

synonyms は「同義語」を意味する。公開コードは大文字・小文字を区別せず、指定した文字列の出現回数を数える。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

例 13 指定された語を避けて言い換える

問題の原文（全文）

> Make the sentence “The bus arrived at the station” sound more interesting. Avoid using the word “station”.

日本語訳（全文）

「 The bus arrived at the station 」という文を、より興味を引く表現に変えてほしい。「 station 」という語は使わないこと。

要求する形式： station を使わない

元の文は「バスが駅に到着した」という意味である。言い換えた文に、禁止された単語が含まれていないかを確認する。

[1] Google Research (2023), IFEval input_data.jsonl.
https://github.com/google-research/google-research/blob/master/instruction_following_eval/data/input_data.jsonl

2. 指示の一覧と参考文献

単語・言語・長さ・内容を指定する指示

グループ	指示の種類
キーワード	含める語、出現回数、禁止語、文字の回数
言語	回答の言語
長さ	段落数、語数、文数、段落数と冒頭の語
内容	追伸、差し込み欄の数

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

形式・組合せ・表記・末尾を指定する指示

グループ	指示の種類
形式	箇条書き数、題名、候補の選択、強調、節、 JSON
組合せ	依頼の繰り返し、二つの回答
英字の大小	全文大文字、全文小文字、大文字の語の回数
冒頭・末尾	結びの文、二重引用符
句読点	カンマを使わない

[1] Zhou et al. (2023), Instruction-Following Evaluation for Large Language Models.
https://arxiv.org/abs/2311.07911

参考文献

Instruction-Following Evaluation for Large Language Models

Jeffrey Zhou et al. (2023). arXiv:2311.07911.

25 種類の指示と 541 設問の作成、四つの評価指標、初期モデルの比較を報告する。

https://arxiv.org/abs/2311.07911

IFEval: Instruction Following Eval

Google Research (n.d.; 2026-10-26 参照). GitHub.

依頼文、条件のパラメータ、判定器と集計コードを公開する。

https://github.com/google-research/google-research/tree/master/instruction_following_eval

参考文献

Generalizing Verifiable Instruction Following

Valentina Pyatkin et al. (2025). Advances in Neural Information Processing Systems 38.

未知の指示へ評価を広げる IFBench と、検証可能な報酬を使った学習を提案する。

https://arxiv.org/abs/2507.02833

Generalizing Verifiable Instruction Following

Ai2 (n.d.; 2026-10-26 参照). GitHub.

58 種類の新しい条件と、 IFEval の 25 種類を含む判定器を提供する。

https://github.com/allenai/IFBench