IMDb

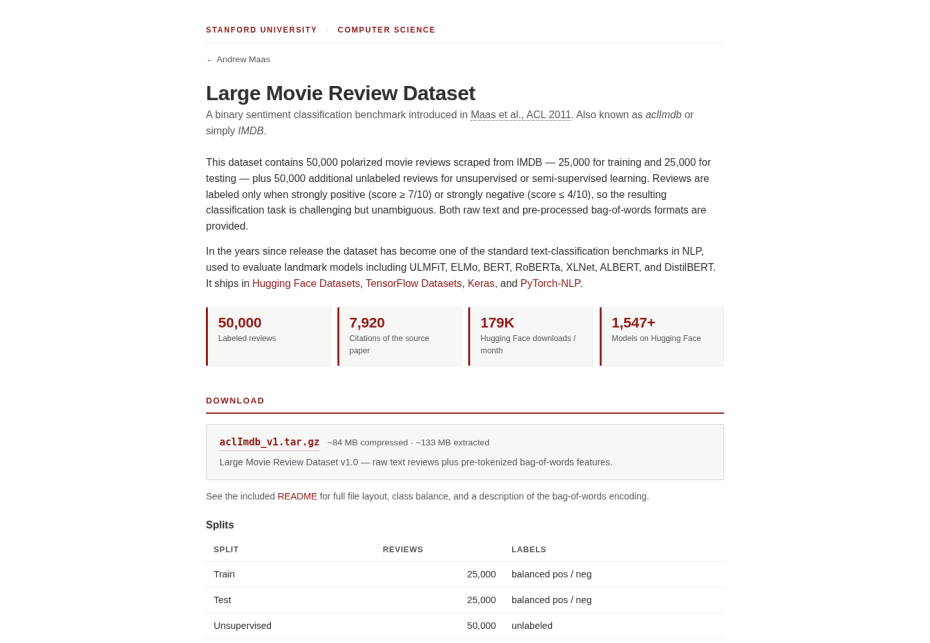
Large Movie Review Dataset

映画レビュー全体が

肯定的か否定的かを分類する

sasakiy84

IMDb の公式公開ページ



STANFORD UNIVERSITY · COMPUTER SCIENCE

← Andrew Maas

Large Movie Review Dataset

A binary sentiment classification benchmark introduced in Maas et al., ACL 2011. Also known as *aclImdb* or simply *IMDB*.

This dataset contains 50,000 polarized movie reviews scraped from IMDB — 25,000 for training and 25,000 for testing — plus 50,000 additional unlabeled reviews for unsupervised or semi-supervised learning. Reviews are labeled only when strongly positive (score ≥ 7/10) or strongly negative (score ≤ 4/10), so the resulting classification task is challenging but unambiguous. Both raw text and pre-processed bag-of-words formats are provided.

In the years since release the dataset has become one of the standard text-classification benchmarks in NLP, used to evaluate landmark models including ULMFiT, ELMo, BERT, RoBERTa, XLNet, ALBERT, and DistilBERT. It ships in Hugging Face Datasets, TensorFlow Datasets, Keras, and PyTorch-NLP.

50,000	7,920	179K	1,547+
Labeled reviews	Citations of the source paper	Hugging Face downloads / month	Models on Hugging Face

DOWNLOAD

`aclImdb_v1.tar.gz` ~84 MB compressed · ~133 MB extracted

Large Movie Review Dataset v1.0 — raw text reviews plus pre-tokenized bag-of-words features.

See the included README for full file layout, class balance, and a description of the bag-of-words encoding.

Splits

SPLIT	REVIEWS	LABELS
Train	25,000	balanced pos / neg
Test	25,000	balanced pos / neg
Unsupervised	50,000	unlabeled

[1] IMDb 公式公開ページ。 2026-10-17 参照。 https://ai.stanford.edu/~amaas/data/sentiment/

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

レビュー全体の評価を二つのクラスへ分ける

- Large Movie Review Dataset は、 IMDb に投稿された英語の映画レビューを、肯定的・否定的に分類するためのデータセットである。
- 入力は一つのレビュー全体で、出力は Positive か Negative である。個々の文や俳優への感情を別々に採点する課題ではない。
- 語彙だけでなく、否定、比較、皮肉、良い点と悪い点の組合せを読み、全体の評価を判断する。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

入力と正解の対応

配布フィールド	意味
text	レビュー本文。複数文からなるものも多い
label ＝ 0	Negative ：否定的な評価
label ＝ 1	Positive ：肯定的な評価

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 https://huggingface.co/datasets/stanfordnlp/imdb

実例１：低い評価が明示されたレビュー

レビュー（全文）／原文と日本語訳

ラベル：否定的

Widow hires a psychopath as a handyman. Sloppy film noir thriller which doesn't make much of its tension promising set-up. (3/10)

未亡人が便利屋として精神病質者を雇う。緊張感を期待させる設定をほとんど生かせていない、雑なフィルム・ノワール風スリラーだ。（3/10）

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 41 。 https://huggingface.co/datasets/stanfordnlp/imdb

実例 1 の読み取り

- 配布されたレビュー全体の評価ラベル： Negative （否定的）。
- 配布ラベルは、レビュー全体に付けられた評点から決まる。一部の単語や一文の評価だけでは決まらない。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 https://huggingface.co/datasets/stanfordnlp/imdb

実例２：好きな点があっても否定的（原文）

正解： Negative （否定的）

原文

This film features two of my favorite guilty pleasures. Sure, the effects are laughable, the story confused, but just watching Hasselhoff in his Knight Rider days is always fun.
I especially like the old hotel they used to shoot this in, it added to what little suspense was mustered. Give it a 3.

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 61 。 https://huggingface.co/datasets/stanfordnlp/imdb

実例２：好きな点があっても否定的（日本語訳）

正解： Negative （否定的）

日本語訳

レビュー：この映画には、好きだが人には少し言いにくい楽しみが二つある。確かに特殊効果は笑ってしまう出来で、話も混乱しているが、『ナイトライダー』時代のハッセルホフを見るだけでも楽しい。
レビュー：特に撮影に使われた古いホテルが好きで、わずかな緊張感を高めていた。評価は３点。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 61 。 https://huggingface.co/datasets/stanfordnlp/imdb

実例２の読み取り

- 配布されたレビュー全体の評価ラベル： Negative （否定的）。
- 配布ラベルは、レビュー全体に付けられた評点から決まる。一部の単語や一文の評価だけでは決まらない。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 https://huggingface.co/datasets/stanfordnlp/imdb

実例３：「最悪」でも勧めている

レビュー（全文）／原文と日本語訳

ラベル：肯定的

Worst horror film ever but funniest film ever rolled in one you have got to see this film it is so cheap it is unbeliaveble but you have to see it really!!!! P.s watch the carrot

史上最悪のホラーと史上最高に笑える映画が一つになっている。ぜひ見てほしい。信じられないほど安っぽいが、本当に見てほしい !!!! 追伸：ニンジンに注目。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 24818 。 https://huggingface.co/datasets/stanfordnlp/imdb

実例３の読み取り

- 配布されたレビュー全体の評価ラベル： Positive （肯定的）。
- 配布ラベルは、レビュー全体に付けられた評点から決まる。一部の単語や一文の評価だけでは決まらない。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 https://huggingface.co/datasets/stanfordnlp/imdb

作成方法とデータの構成

小さなレビュー集合から、 5 万件の比較へ

- Pang and Lee の映画レビュー集合は 2,000 件で、当時の感情分類研究でよく使われていた。
- 2011 年には、より大きな教師あり集合と追加のラベルなし集合を公開し、単語表現と分類器を比較できるようにした。
- 単語の意味が似ているだけでなく、 good と bad のように評価の向きが異なる語を区別することが研究の動機となった。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

投稿時の評点を使って正解を作った

- 10 点満点の評点で、 4 点以下を否定的、 7 点以上を肯定的として採用した。 5 点と 6 点の中間的なレビューは教師あり集合に含めない。
- 同じ映画のレビューは 30 件までとし、一部の映画へ集中しすぎないようにした。
- 学習とテストで映画を共有しないように分割した。既知の映画に関する表現だけに頼らず、別の映画のレビューで評価する。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

部分的な好意と、全体の評価を区別する

- ハッセルホフの実例には「好き」「楽しい」といった表現があるが、最後の評点は 3 点で、配布ラベルは否定的である。
- 一方、「史上最悪のホラー」と呼びながら鑑賞を強く勧める実例には、肯定的なラベルが付いている。
- 単語単位の肯定・否定を数える方法が、文書全体のラベルと食い違う場面を観察できる。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

分割と件数

集合	件数	役割
train	25,000	肯定 12,500 ＋否定 12,500
test	25,000	肯定 12,500 ＋否定 12,500
unsupervised	50,000	追加のラベルなしレビュー

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

極端な評点を選んだ、均衡した二値分類である

- 教師あり集合は、肯定的・否定的なレビューを同じ件数ずつ含む。常に片方を選ぶ分類器は 50% となる。
- 中間の評点を除いているため、一般の投稿全体や、中立を含む三値の感情分類とは対象が異なる。
- 肯定的というラベルはレビュー投稿者の評点を表す。映画に関する記述が事実かどうかを評価しているわけではない。

[1] stanfordnlp/imdb 、改訂 e6281661 。 test 全 25,000 件を集計。 https://huggingface.co/datasets/stanfordnlp/imdb

公開集合のラベル分布



test 全 25,000 件。縦軸はレビュー数。

[1] stanfordnlp/imdb 、改訂 e6281661 。 test 全 25,000 件を集計。 https://huggingface.co/datasets/stanfordnlp/imdb

採点方法とモデルの成績

正解率は、レビュー単位のラベル一致である

- 一つのレビューについて、予測クラスが評点由来のラベルと一致すれば 1 、それ以外は 0 とする。
- 正解率＝正しく分類したレビュー数 ÷ 評価レビュー数。映画ごとの平均ではなく、レビューごとの平均である。
- HELM は Positive ／ Negative を生成させ、正規化後の一致を quasi-exact match で測る。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

登場時の代表的な結果

2011 年の特徴と分類	テスト正解率
Bag of Words	87.80%
意味表現＋ Bag of Words	88.28%
追加のラベルなし学習＋ Bag of Words	88.89%

論文 Table 2 の Our Dataset 列。 25,000 件のテスト、線形 SVM による分類。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

HELM での評価条件

- HELM Classic v0.4.0 （ 2023-11-17 ）の canonical 設定。valid から 1,000 件を評価し、最大 5 件の解答例を示す。
- HELM は、元の test に加え、対照例を持つ元の train の一部も valid へ割り当てる。元の test 全件の評価とは異なる。
- OPT と text-davinci-003 は 3 試行、 Llama 2 は 1 試行。長さの制約により、提示される例が最大数より少なくなる場合がある。

[1] HELM Classic v0.4.0 。公開 run_specs と実行別 stats の canonical 設定を照合。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の比較

モデル	正解率	試行数
OPT-175B	94.73%	3
text-davinci-003	84.83%	3
Llama 2 70B	96.10%	1

valid 1,000 件、最大 5 例提示。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

得点と評価条件を一緒に読む

- この比較は、指定 URL が指す 2023 年 11 月 17 日の HELM Classic の結果である。現在の最高性能の一覧を意図していない。
- 少数例提示では、例題の選び方や、候補の並べ方、入力の長さが条件になる。表には評価集合と試行数を添えた。
- 正解率のほか、入力を少し変えた際の頑健性や、自信のある予測がどの程度正しいかも評価できる。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

単語表現の研究から、汎用モデルの分類評価へ

- 公開時には、感情を捉える単語表現や、ラベルなしレビューを使う学習の効果を比較した。
- 汎用言語モデルでは、少数の入力・正解ペアをプロンプトに示し、追加の微調整なしで分類する評価にも使われる。
- HELM は対照例も利用し、評価を変える短い編集に対して、予測が適切に変わるかを調べる。

[1] IMDb 公式公開ページ。 2026-10-17 参照。 https://ai.stanford.edu/~amaas/data/sentiment/

データの入手と利用

- Stanford の公式配布ページに、圧縮データと論文がある。 stanfordnlp/imdb のミラーでも本文と二値ラベルを読める。
- ミラーには元のレビューに付けられた評点や映画 ID がない。評点や元ファイル名を調べる場合は、公式の圧縮配布物を参照する。

[1] IMDb 公式公開ページ。 2026-10-17 参照。 https://ai.stanford.edu/~amaas/data/sentiment/

公開データを読み込む

```
from datasets import load_dataset
ds = load_dataset("stanfordnlp/imdb",
                  revision="e6281661")
example = ds["test"][0]
print(example["text"])
```

この資料で照合した改訂を指定して読み込む。各フィールドの意味は本編の対応表を参照。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 https://huggingface.co/datasets/stanfordnlp/imdb

IMDb の要点

- レビュー全体を肯定・否定へ分類する。単語の向きだけでなく、文脈や推薦の有無を読む必要がある。
- 評点 4 以下と 7 以上を使い、学習・テストを映画単位で分離した。教師あり 5 万件は二クラスが均衡している。
- 元の test 全件を使う教師あり学習と、 HELM の少数例提示・独自 valid の評価を区別して成績を読む。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：最後まで集中できない

レビュー（全文）／原文と日本語訳

ラベル：否定的

I found this movie really hard to sit through, my attention kept wandering off the tv. As far as romantic movies go..this one is the worst I've seen. Don't bother with it.

見続けるのが本当に苦痛で、テレビから注意がそれてばかりだった。恋愛映画としては、これまで見た中で最悪だ。見る必要はない。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 49 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例２：脚本と脇役への不満

レビュー（全文）／原文と日本語訳

ラベル：否定的

I could almost wish this movie had not been made. Stan Laurel was dying, and it shows in his face, even more angular and gaunt than usual. A poor script, and inept supporting cast.

作られなければよかったとさえ思いかける映画だ。スタン・ローレルは死期が近く、いつもより骨張ってやつれた顔にもそれが表れている。脚本はひどく、脇役陣も下手だ。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 704 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例３：途中で見るのをやめた

レビュー（全文）／原文と日本語訳

ラベル：否定的

This must be the first movie I've rented and not seen to the end. Complete garbage! The acting, the plot, set and wardrobe looked like it came from a porno movie with a plot. Not even a B move.

借りたのに最後まで見なかった映画は、これが初めてだと思う。まったくの駄作だ。演技も筋もセットも衣装も、筋書きのあるポルノ映画から持ってきたようだった。 B 級にすら届かない。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 861 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例 4 ：技術と創造性を分ける

レビュー（全文）／原文と日本語訳

ラベル：否定的

You may like Tim Burton's fantasies, but not in a commercial-like show off lasting 8 minutes. It demonstrates good technical points without real creativity or some established narrative pace.

ティム・バートンの空想の世界は好きかもしれないが、 8 分も続く CM のような見せびらかしは別だ。技術的に良い点はあるが、本当の創造性も、しっかりした物語のテンポもない。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 1013 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例 5 ：人物の描き方を評価

レビュー（全文）／原文と日本語訳

ラベル：肯定的

While the romance in this film is an important aspect, it is largely about the role of responsibility and duty in modern Indian. All of the major characters were well fleshed out, and had their own "inner life". I recommend this strongly

この映画では恋愛も重要な要素だが、主なテーマは現代インドにおける責任と義務の役割である。主要人物は皆よく描かれ、それぞれの内面があった。強く勧めたい。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 12510 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例 6 ：俳優への好意

レビュー（全文）／原文と日本語訳

ラベル：肯定的

I think this movie is my favorite movie. I am not sure why, but it is. Julia Duffy has been my favorite actress for awhile, and when I saw this, I went crazy. It's sort of romantic, and I definitely recommend this movie.

この映画がいちばん好きだと思う。理由ははっきりしないが、そうなのだ。ジュリア・ダフィは以前から大好きな女優で、この映画を見て夢中になった。少しロマンチックで、ぜひ勧めたい。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 13210 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例７：家族で楽しめる作品

レビュー（全文）／左：原文　右：日本語訳

At last, a great film that doesn't have to be edited for profanity or sex! It's a fun film that the whole family can enjoy. Willis is great, as always. "Rusty" was delightful. Just enough action to keep interest going.

ラベル：肯定的

卑語や性描写を編集で削る必要がない、すばらしい映画がついに登場した！ 家族全員で楽しめる。ウィリスはいつもどおりすばらしく、「ラスティ」も魅力的だった。興味を保つのにちょうどよい量のアクションもある。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 13687 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例 8 ：自然な演技

レビュー（全文）／原文と日本語訳

ラベル：肯定的

I couldnt believe how well this kid did on screen, you will completely forget that they are actors and loose yourself in the movie. It is like watching home movies with a twist. I recomend this to everyone. Highly.

この子が画面でこれほど上手に演じるとは信じられなかった。俳優だということをすっかり忘れて、映画に入り込んでしまう。ひとひねりあるホームビデオを見ているようだ。誰にでも、強く勧めたい。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 13691 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例９：別作品との比較

レビュー（全文）／原文と日本語訳

ラベル：肯定的

This movie is based on the novel Island of dr. Moreau By H.G. Wells. It's a fairly good one too, it's at least better than the version by John Frankenheimer.

Ｈ・Ｇ・ウェルズの小説『モロー博士の島』をもとにした映画だ。かなり良い出来でもあり、少なくともジョン・フランケンハイマー版よりは良い。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 13798 。 https://huggingface.co/datasets/stanfordnlp/imdb

追加例 10 ：映画と小説を勧める

レビュー（全文）／左：原文　右：日本語訳

Morte a Venezia is one of my favorite movies. More than beautiful, it's really sublime. It gives you important aesthetic experiences, it's a masterpiece. I also recommend the novel. Luchino Visconti is a genius.

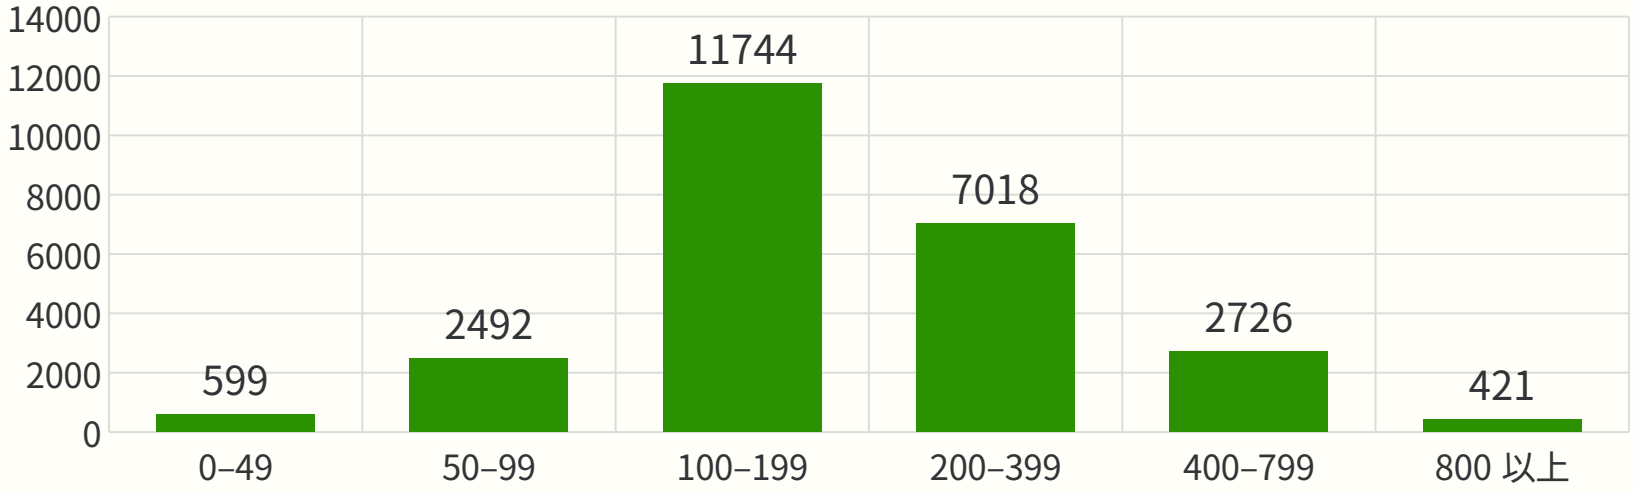
ラベル：肯定的

『ベニスに死す』は大好きな映画の一つだ。美しいだけでなく、本当に崇高である。重要な美的体験をもたらす傑作だ。小説も勧めたい。ルキノ・ヴィスコンティは天才だ。

[1] stanfordnlp/imdb 、改訂 e6281661 。 2026-10-17 参照。 test の 0 始まり行 14107 。 https://huggingface.co/datasets/stanfordnlp/imdb

集計と評価条件

入力の語数分布



test 全 25,000 件。横軸は空白区切りの語数、縦軸は件数。

[1] stanfordnlp/imdb 、改訂 e6281661 。 test 全 25,000 件を集計。 https://huggingface.co/datasets/stanfordnlp/imdb

入力の長さを同じ方法で集計した

統計量	空白区切りの語数
平均	228.5
中央値	172.0
母標準偏差	168.9
最小	4.0
最大	2,278.0

配布 text を加工せずに集計。 HTML タグも文字列の一部として残る。

[1] stanfordnlp/imdb 、改訂 e6281661 。 test 全 25,000 件を集計。 https://huggingface.co/datasets/stanfordnlp/imdb

集計の対象と測り方

- 対象は改訂 e6281661 の test 全 25,000 件。表示した 13 例だけの集計ではない。
- 語数は Python の str.split() による空白区切り。母標準偏差を用い、分位点は NumPy の線形補間で求めた。
- 図は 0 〜 49 、 50 〜 99 、 100 〜 199 、 200 〜 399 、 400 〜 799 、 800 以上の階級で、最後の階級に長い入力もすべて含める。

[1] stanfordnlp/imdb 、改訂 e6281661 。 test 全 25,000 件を集計。 https://huggingface.co/datasets/stanfordnlp/imdb

研究と参考文献

研究者と発表の位置付け

- Andrew L. Maas と最終著者 Christopher Potts を含む Stanford 大学の研究者 6 人による研究である。
- ACL 2011 で発表された。感情に関する情報と、ラベルなしデータの分布情報を用いた単語表現を提案した。

[1] Andrew L. Maas et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL 2011. https://aclanthology.org/P11-1015/

参考文献

Learning Word Vectors for Sentiment Analysis

Andrew L. Maas, Raymond E. Daly, Peter T. Pham, Dan Huang, Andrew Y. Ng, Christopher Potts / ACL 2011

IMDb の作成方法、実例、初期評価を報告した研究。

https://aclanthology.org/P11-1015/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

HELM のシナリオ、評価指標、少数例提示による多面的な比較をまとめる。

https://arxiv.org/abs/2211.09110

参考文献

IMDb ：公開データと配布情報

stanfordnlp/imdb / 改訂 e6281661 / 2026-10-17 参照

掲載した 13 例の原文・正解と、公開集合の全件集計を照合した。

https://huggingface.co/datasets/stanfordnlp/imdb