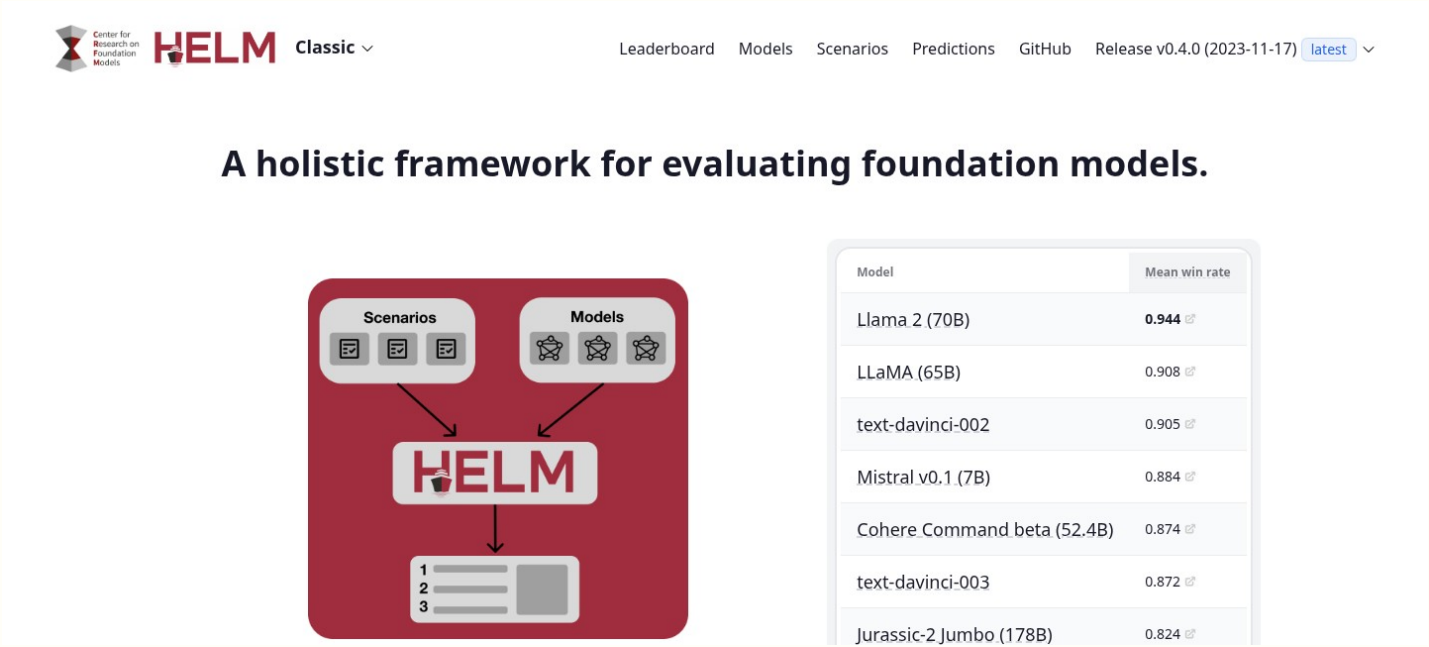
LegalSupport

判例の要約から、主張をより直接支える根拠を選ぶ

sasakiy84

公式サイト： HELM のトップ

HELM 全体のトップ画面。 LegalSupport の得点は課題ごとに別に示す。



[1] Stanford CRFM, HELM Classic. 公式トップ画面。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/latest/

1. 主張を支える二つの判例
2. 判例の引用からデータを作る
3. 採点と HELM の実行条件
4. 研究での位置づけと入手

主張を支える二つの判例

どちらの判例が、主張をより強く支えるか

- 法律に関する主張と、二つの判例の結論を表す短い記述が入力になる。
- A ／ B のうち、主張への根拠として、より直接的で説得力がある方を選ぶ。
- 米国の実際の判決文にある引用から、主張と根拠の関係を取り出した。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

専門用語は、判断する対象と結び付ける

- 最初の例は、陪審に法律上の判断方法を伝える「説示」を扱う。
- 無害な誤りの審査とは、誤りがあっても判決への影響はなかったと扱えるかを検討すること。
- 以下の原文は、主張・二つの選択肢を省略せず示す。正解は配布データのラベルに従う。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

実例１：違憲な説示の扱い

原文：主張・選択肢の全文

In particular, the court has subjected jury instructions plagued by constitutional error to harmless-error analysis.
A. erroneous burden of proof instruction not subject to harmless-error analysis
B. taint of an unconstitutional burden-shifting jury instruction subject to harmless-error analysis

Correct: B

日本語訳：同じ範囲

とりわけ裁判所は、憲法上の誤りを含む陪審への説示についても、無害な誤りの審査を行ってきた。
A. 立証責任に関する誤った説示は、無害な誤りの審査の対象にならない。
B. 憲法に反して立証責任を転換する説示による問題も、無害な誤りの審査の対象になる。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 566 （0 始まり）／ case_id 7825715
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

否定されている点を読み分ける

- 主張は、憲法上の誤りがある説示も、無害な誤りの審査対象になったと述べる。
- B は、その審査の対象になった判例。 A は対象にならないとした判例で、主張を直接支えない。
- 話題の単語が同じでも、肯定・否定と法的な条件を読む必要がある。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例２：債務が発生する時点

原文：主張・選択肢の全文

The question of when a debt arises under the bankruptcy code is governed by federal law.
A. finding that determination of when a claim arises under the bankruptcy code should be governed by federal law
B. applying federal law to determine when parties had obligations under indemnification agreement

Correct: A

日本語訳：同じ範囲

倒産法上、債務がいつ発生するかは、連邦法に従って判断される。
A. 倒産法上、債権がいつ発生するかは連邦法に従って判断すべきだとした。
B. 補償契約上の義務がいつ生じたかを判断するために、連邦法を適用した。

正解： A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 499 （ 0 始まり）／ case_id 1299594
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

両方が関係していても、強さは異なる

- A は倒産法上の債権の発生時点を、連邦法で判断すると述べる。主張に直接対応する。
- B も連邦法を使うが、補償契約上の義務を扱っている。単に同じ法律を使うこととは区別する。
- 「関連があるか」だけでなく、何をどこまで支えるかを比較する課題である。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例３：表現の自由を支える判例

原文：主張と二つの選択肢の全文

The First Amendment protects ideas and the freedom to express them.
A. no First Amendment right to physical originals of audio tapes where reporters received transcripts of tapes and could communicate contents to public if desired
B. the First Amendment "was fashioned to assure unfettered interchange of ideas"

Correct: B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 240 （ 0 始まり）／ case_id 5750974
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例３：表現の自由を支える判例（訳）

日本語訳：主張と二つの選択肢の全文

合衆国憲法修正第１条は、思想と、それを表現する自由を保障する。
A. 記者が録音テープの書き起こしを受け取り、望めば内容を公衆に伝えられる場合、修正第１条によるテープ原本への権利はない。
B. 修正第１条は「思想の自由な交換を保障するために作られた」とした。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 240 （０始まり）／ case_id 5750974
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

法的結論から、主張への支え方を読む

- B は、修正第 1 条が思想の自由な交換を保障するためのものだと述べ、主張の内容に直接対応する。
- A は録音テープの原本への権利の限界を扱う。表現の自由と関連していても、主張との関係が異なる。
- 入力は短い判例記述であり、判決全文を調べて結論を出す課題ではない。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

判例の引用からデータを作る

1965 年より後の米国の判決文を使う

- 州と連邦の裁判所が書いた、 1965 年より後の判決文を対象に構築した。
- Caselaw Access Project （ CAP ）の資料から、主張に複数の判例が引用されている箇所を取り出す。
- 判例の結論を説明する括弧書きと、引用の導入句を手掛かりに、支持の強さを比較する。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

引用の導入句が、ラベルの手掛かり

導入句の例	本文との関係
see	主張を支える根拠として引用
see also	追加の支持根拠として引用
cf.	類似する点から支える根拠として引用

構築時は導入句を使うが、評価入力にはその導入句を渡さない。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

引用の慣行から、二択問題を作る

- 同じ主張に対し、異なる導入句を伴う二つの判例記述を選ぶ。候補が多ければ二つを無作為に選ぶ。
- 主張を本文、括弧書きを選択肢とし、導入句が示す支持の強さから正解を決める。
- 問題ごとに専門家が新たに正解を判定したものとは異なる。引用の仕方から得たラベルである。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

公開されている三つの集合

集合	レコード数	正解 A	正解 B
train	13,862	6,839	7,023
dev	3,125	1,556	1,569
test	3,047	1,535	1,512

公開 JSONL を全件集計。分割件数は HELM の記載とも一致。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

同じ主張から複数の問題が作られる

集合	レコード数	異なる主張の数
train	13,862	3,472
dev	3,125	744
test	3,047	744

主張の数は context 文字列の一意数。レコード数と独立した主張数は同じではない。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

支持の強さを、引用の使い方から近似する

- 同じ内容でも、引用した著者がどの導入句を選ぶかでラベルが決まる。
- 二つの選択肢が似ていて、本文だけから強さを判断しにくい例も含まれる。
- 判例が現時点で有効か、法的結論が妥当かなど、法律判断全体を測るものではない。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

採点と HELM の実行条件

HELM は三つの提示例から A ／ B を出す

- 主張を最もよく支える記述はどちらか、という指示と、正解付きの 3 例を提示する。
- 対象の主張と A ／ B の選択肢を並べ、回答記号を生成する multiple choice joint 形式を使う。
- 公開した三つのモデルの実行では、実提示数は 3 例で、入力の切り詰めは 0% 。

[1] HELM Classic v0.4.0, LegalSupport. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/legal_support

正しい選択肢を選べた割合を測る

- 生成した A ／ B を元の選択肢へ対応させ、正解の参照と一致したかで採点する。
- 部分点付きの文章要約や、法的な説明の質を採点する課題ではない。
- 二択だが、固定の A だけを出す基準と、選択肢を毎回無作為に選ぶ基準は区別する。

[1] Stanford CRFM, LegalSupport scenario. 固定版 v0.3.0 。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/legal_support_scenario.py

公開実行は dev と test にまたがる

元の集合	全件数	HELM の評価対象
dev	3,125	511
test	3,047	489
合計	6,172	1,000

3 モデルとも同じ件数。公開入力 1,000 件を配布レコードへ全件照合。

[1] HELM Classic v0.4.0, LegalSupport. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/legal_support

HELM ： test の正解率を比較

モデル	正解率 (%)	試行数
OPT-175B	53.17	3
text-davinci-003	62.17	3
Llama 2 70B	58.49	1

元の test から 489 問。 3 試行の値は平均、 Llama 2 は 1 試行。

[1] HELM Classic v0.4.0, LegalSupport. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/legal_support

dev の正解率は別に報告される

モデル	正解率 (%)
OPT-175B	49.90
text-davinci-003	65.43
Llama 2 70B	57.53

元の dev から 511 問。 OPT ・ davinci は 3 試行平均、 Llama 2 は 1 試行。

[1] HELM Classic v0.4.0, LegalSupport. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/legal_support

この結果は、固定された条件での比較

- HELM Classic v0.4.0 に掲載された、元 run suite v0.3.0 の公開記録を使う。
- 3 例提示、出力長、試行数などの条件を含む結果であり、法的推論全般の能力順位ではない。
- 固定版の公開日は 2023 年 11 月 17 日。 2026 年の最新モデル全体を比較したものではない。

[1] HELM Classic v0.4.0, LegalSupport. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/legal_support

研究での位置づけと入手

HELM の新規データとして公表された

- 2022 年の HELM 初回公開版に、 LegalSupport の構築方法と評価が記載されている。
- 2023 年の TMLR 掲載版にも、引用に基づく比較的な法的推論課題として説明がある。
- 2026 年に確認した公開コードでも配布先が維持されている。独立した公式サイトは確認できなかった。

[1] Liang et al. (2022), Holistic Evaluation of Language Models. 初回公開版。 https://arxiv.org/abs/2211.09110v1

判例を根拠として読む研究に使う

- 法的な主張と根拠の対応を、二つの候補から比較する評価に向く。
- 判決文の全文検索、法的文書の起案、理由の説明、最新法の調査などとは評価対象が異なる。
- 利用時は、どの情報を入力として渡し、何を正解としたかを明示する。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

配布ファイルと元の注釈を固定する

- 公式シナリオの配布先から、 train ／ dev ／ test の JSONL を取得できる。 ZIP は約 3.0 MB 。
- 主張、二つの判例記述、引用の導入句・識別情報、case_id 、正解ラベルを持つ。
- ここではファイルの SHA-256 と行位置を保存し、 13 実例と公開評価入力を元データへ照合した。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

コードと判例本文の利用条件を分ける

- HELM のコードは Apache 2.0 。これを元の判例本文や配布データ全体の許諾と同一視しない。
- 取得 ZIP には独立した LICENSE がなかった。元資料の出所と、利用時点の配布条件を別に確認する。
- 資料の実例は、配布された短い主張と選択肢を引用し、日本語訳を加えた。

[1] Stanford CRFM, HELM. 公式リポジトリ。 https://github.com/stanford-crfm/helm

関連しているだけでなく、支え方を比べる

- 同じ法律や話題を扱っていても、主張への直接性は同じとは限らない。
- 引用の慣行から得たラベルという特徴を理解し、正解率の意味を読む。
- 同じ主張からの複数問題や、 dev ／ test の範囲などをそろえて比較する。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

Appendix

1. 追加の実例
2. データと採点の補足
3. 研究と参考文献

追加の実例

実例 4 ：過失を判断する陪審の役割

原文：主張・選択肢の全文

Under these circumstances, the jury was authorized to conclude that Love was not negligent.
A. trial court did not err in denying Willis' motion for directed verdict
B. in rear-end collision cases, issues of liability are for the jury to decide

Correct: B

日本語訳：同じ範囲

このような状況では、陪審がラヴには過失がなかったと判断することが認められた。
A. 第一審がウィリスの指示評決の申立てを退けたことに、誤りはなかった。
B. 追突事故の責任の有無は、陪審が判断すべき問題である。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 83 （ 0 始まり）／ case_id 903768
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 5 ：自己負罪拒否と審査方法

原文：主張と二つの選択肢の全文

We review de novo Washington's claim that the sentencing court improperly penalized him for invoking his constitutional right against self-incrimination.
A. reviewing de novo claim sentence was result of "judicial vindictiveness"
B. reviewing evidence de novo on claimed violation of Fifth Amendment

Correct: B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1583 （0 始まり）／ case_id 7064248
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 5 ：自己負罪拒否と審査方法（訳）

日本語訳：主張と二つの選択肢の全文

ワシントンは、自己負罪を拒否する憲法上の権利を行使したために、量刑裁判所から不当に不利益を与えられたと主張する。この主張は de novo で審査する。
A. 量刑が「裁判所による報復」の結果だという主張を、 de novo で審査した。
B. 修正第 5 条違反の主張について、証拠を de novo で審査した。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1583 （ 0 始まり）／ case_id 7064248
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 6 ：不十分な修理と損害の回復

原文：主張・選択肢の全文

.Many of the cases address how to remedy inadequate or defective repairs.
A. finding no repairs were made due to parties' disagreement over the correct measure of damages
B. finding some repairs made but additional repairs could have restored vehicle to the same or as good condition

Correct: B

日本語訳：同じ範囲

多くの事例では、不十分または不適切な修理をどのように是正するかが問題になる。
A. 適切な損害賠償額について当事者の見解が一致せず、修理は行われなかったと認定した。
B. 一部の修理は済んでいたが、追加の修理で車両を元と同じか、同程度に良好な状態に戻せたと認定した。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 26 （0 始まり）／ case_id 11152124
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 7 ：フェアユースと消費者の混同

原文：主張・選択肢の全文

But the Supreme Court rejected Paccar on the precise point for which Kassa cites it. See K.P.
A. "The fair--use defense contemplates and tolerates 'some possibility of consumer confusion.'-"
B. rejecting Paccar and holding that "fair use can - occur along with some degree of [consumer] confusion"

Correct: B

日本語訳：同じ範囲

しかし最高裁は、カッサがパッカー判決を引用する根拠とした、まさにその点で同判決を否定した。 K.P. 判決参照。
A. 「フェアユースの抗弁は、消費者の混同が生じる可能性があることを想定し、それを許容する」とした。
B. パッカー判決を否定し、一定の消費者の混同があってもフェアユースは成立しうるとした。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 851 （ 0 始まり）／ case_id 4275032
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 8 ：よく似た二つの根拠

原文：主張と二つの選択肢の全文

We have sometimes allowed a defendant to preserve a district court error as long as one of his codefendants objected below.
A. holding that objection to instructions by codefendant's counsel is sufficient to preserve any error
B. ruling that objection to instructions by codefendant's counsel preserves any error

Correct: A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1012 （0 始まり）／ case_id 199941
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 8 ：よく似た二つの根拠（訳）

日本語訳：主張と二つの選択肢の全文

共同被告人の一人が第一審で異議を述べていれば、被告人自身も第一審の誤りを争う権利を維持できると認めたことがある。
A. 共同被告人の弁護人による説示への異議で、誤りを争う権利の維持には十分だと判示した。
B. 共同被告人の弁護人による説示への異議で、誤りを争う権利は維持されると判断した。

正解： A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1012 （ 0 始まり）／ case_id 199941
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例９：控訴で述べない主張の扱い

原文：主張・選択肢の全文

On appeal, San Martin has not made these arguments, and therefore has waived them.
A. deeming an issue waived when its only mention in the party's brief was in the Statement of the Case
B. holding that a habeas petitioner abandons the claims he does not address on appeal

Correct: B

日本語訳：同じ範囲

サン・マルティンは控訴でこれらの主張をしていないため、主張する権利を放棄したものとみなされる。
A. 当事者の書面で事件の経過を記す部分にしか言及がない論点は、放棄されたものとみなした。
B. 人身保護の申立人は、控訴で取り上げない主張を放棄したものと判示した。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1240 （0 始まり）／ case_id 4092151
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 10 ：差止め請求の遅れが与えた影響

原文：主張と二つの選択肢の全文

JPMorgan's delay in seeking injunctive relief has neither disadvantaged Plaintiffs nor altered the outcome of this proceeding.
A. finding that the delay in seeking the injunction had not disadvantaged the other party's interests
B. finding that the delay in that instance did not alter the outcome of the proceedings

Correct: A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1623 （0 始まり）／ case_id 4002194
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 10 ：差止め請求の遅れが与えた影響（訳）

日本語訳：主張と二つの選択肢の全文

JPMorgan が差止めを求めるまでに時間を要したことは、原告に不利益を与えず、この手続の結論も変えていない。
A. 差止めを求めるまでの遅れは、相手方の利益を損なっていなかったと認定した。
B. その事案での遅れは、手続の結論を変えていなかったと認定した。

正解： A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1623 （0 始まり）／ case_id 4002194
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 11 ：回復不能な損害の推認

原文：主張と二つの選択肢の全文

Indeed, irreparable harm may be presumed with the finding of a violation of the First Amendment.
A. "It is well established that the deprivation of constitutional rights 'unquestionably constitutes irreparable injury.' "
B. "The loss of First Amendment freedoms, for even minimal periods of time, unquestionably constitutes irreparable injury"

Correct: B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1916 （0 始まり）／ case_id 12267824
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 11 ：回復不能な損害の推認（訳）

日本語訳：主張と二つの選択肢の全文

実際、修正第 1 条違反が認められれば、回復不能な損害を推認することができる。
A. 「憲法上の権利の剥奪が、疑いなく回復不能な損害になることは、十分確立している」とした。
B. 「修正第 1 条が保障する自由の喪失は、ごく短期間でも、疑いなく回復不能な損害になる」とした。

正解： B

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1916 （0 始まり）／ case_id 12267824
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 12 ：申立ての名称より中身を読む

原文：主張と二つの選択肢の全文

Washington's motion may be more properly construed as a Wis. Stat. SS 974.06 postconviction motion.
A. We liberally construe a pro se defendant's motion and are not bound by the defendant's labels.
B. SS 974.06 motions are properly used to bring issues of jurisdictional or constitutional dimension before the court

Correct: A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 2311 （0 始まり）／ case_id 4029386
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 12 ：申立ての名称より中身を読む（訳）

日本語訳：主張と二つの選択肢の全文

ワシントンの申立ては、ウィスコンシン州法 974.06 条に基づく有罪判決後の救済申立てと解する方が適切かもしれない。
A. 本人が訴訟を行う被告人の申立ては柔軟に解釈し、本人が付けた名称には拘束されない。
B. 974.06 条に基づく申立ては、管轄または憲法上の問題を裁判所に提起するために用いられる。

正解： A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 2311 （0 始まり）／ case_id 4029386
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 13 ：法的文書の作成は法律業務か

原文：主張と二つの選択肢の全文

Additionally, Indiana courts have repeatedly held that drafting or preparing legal instruments- is generally considered practicing law. See State ex rel. Ind. State.
A. "Drafting and preparing testamentary and trust documents is clearly the practice of law."
B. preparation of immigration documents and drafting contracts, pleadings, and a will, constituted unauthorized practice of law

Correct: A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1529 （0 始まり）／ case_id 6783929
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

実例 13 ：法的文書の作成は法律業務か（訳）

日本語訳：主張と二つの選択肢の全文

さらにインディアナ州の裁判所は、法的文書を起案・作成することは一般に法律業務とみなされると、繰り返し判示してきた。 State ex rel. Ind. State 判決参照。
A. 「遺言や信託に関する文書を起案・作成することは、明らかに法律業務である」とした。
B. 移民関係書類の作成や、契約書・訴訟書面・遺言書の起案は、無資格の法律業務にあたるとした。

正解： A

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 test 行 1529 （0 始まり）／ case_id 6783929
https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

データと採点の補足

順序を除いて同じ入力となる行がある

集合	全レコード	一意の入力組
train	13,862	5,983
dev	3,125	1,245
test	3,047	1,218

主張と二つの選択肢の組で集計。 A ／ B を入れ替えた行は同じ組とする。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

case_id の共通と入力の共通は異なる

集合の組	共通 case_id	共通の入力組
train / dev	83	0
train / test	94	0
dev / test	20	0

公開配布を照合。 case_id の共通だけから、同じ評価入力の混入とは判断しない。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

二つの選択肢が同じ行もある

- 公開 train に 8 行、 test に 1 行、二つの判例記述が完全に同じ文字列の例があった。
- HELM の変換は、選択肢の文字列が正解文字列と一致すれば正解の参照にする。その場合は両方が正解になる。
- 確認した公開評価入力 1,000 件には、両方が正解の例はなかった。

[1] Stanford CRFM, LegalSupport scenario. 固定版 v0.3.0 。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/legal_support_scenario.py

OPT の方式比較は、提示例数も異なる

方式	test 正解率 (%)	提示例
選択肢を並べて記号を生成	53.17	3 例
候補を別々に採点	56.65	0 例
候補を別々に採点・確率を補正	55.62	0 例

同じ test489 問。生成式は 3 試行平均、別採点の 2 方式は各 1 試行。

[1] HELM Classic v0.4.0, LegalSupport. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/legal_support

モデル別の生成条件も確認する

モデル	提示例	出力上限	試行
OPT-175B	3 例	5 トークン	3
text-davinci-003	3 例	5 トークン	3
Llama 2 70B	3 例	1 トークン	1

temperature 0 。実提示 3 例、 prompt_truncated=0 。上限は adapter_spec の設定。

[1] HELM Classic v0.4.0, LegalSupport. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/legal_support

入力と出力の公開記録を再検証した

- 公開 scenario_state の 1,000 入力を、 train ／ dev ／ test 連結順の ID から元の行へ対応させた。
- 主張、選択肢の順序、正解のタグが全件一致。 davinci の 3,000 出力も独立に採点し、公開値と一致した。
- 13 実例は異なる case_id と主張を持つ。短く対比が分かる例を意図的に選び、頻度を代表する標本とはしていない。

[1] Stanford CRFM, LegalSupport. 公開配布 JSONL 。 https://docs.google.com/uc?export=download&id=1PVoyddrCHChMxYrLhsI-zu7Xzs5S8N77

研究と参考文献

Stanford CRFM による法的推論の評価

- Neel Guha が、 HELM の推論評価の一部として LegalSupport を設計・実装した。
- HELM の第一著者は Percy Liang 。多数の課題と指標で、言語モデルを共通に評価する研究である。
- LegalSupport では、判例の引用を比較するという、法的推論の一つの側面を扱う。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

参考文献

Holistic Evaluation of Language Models

Percy Liang ほか（2023）／Transactions on Machine Learning Research

LegalSupport の構築、引用から得た支持の強さ、共通条件でのモデル評価を報告。

https://arxiv.org/abs/2211.09110

LegalSupportScenario

Stanford CRFM ／ HELM v0.3.0 、公開シナリオ実装

配布データを主張と二つの参照回答へ変換し、正解タグを付ける処理を公開。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/legal_support_scenario.py

参考文献

HELM ：公開コードと配布への入口

Stanford CRFM ／公式リポジトリ

シナリオ、モデルの入出力形式、指標と公開評価の使い方をまとめる。

https://github.com/stanford-crfm/helm

Holistic Evaluation of Language Models ：初回公開版

Percy Liang ほか（ 2022 ）／ arXiv:2211.09110v1

2022 年の時点で LegalSupport の問題形式、作成方法と集合別件数を記載。

https://arxiv.org/abs/2211.09110v1