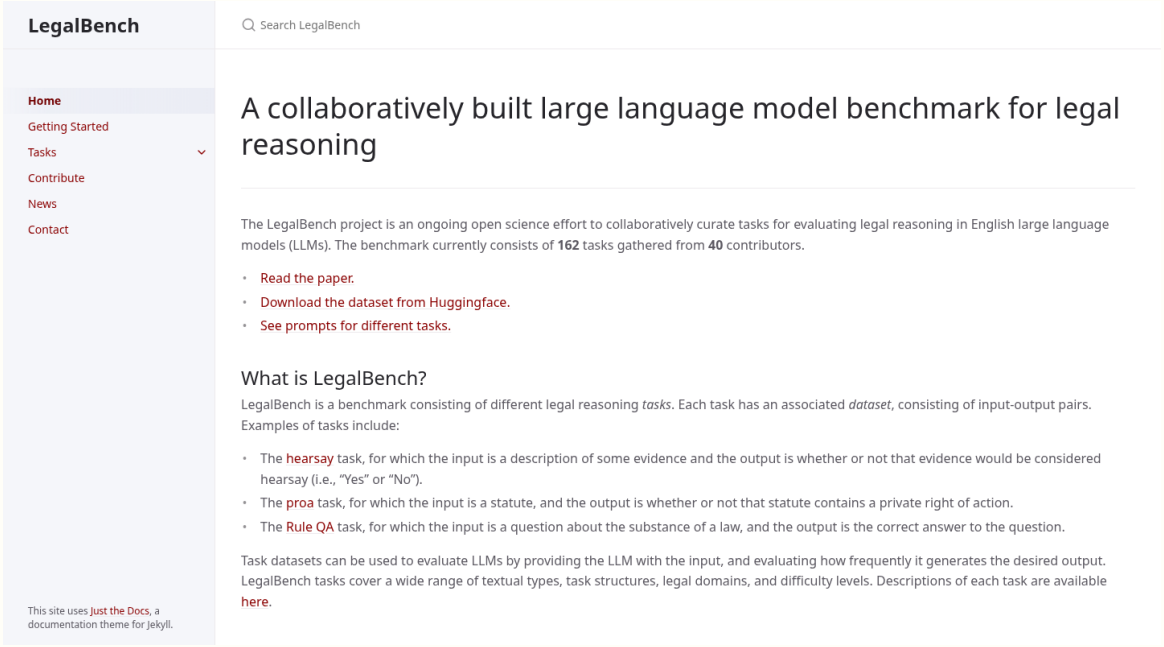
LegalBench

A Collaboratively Built Benchmark for
Measuring Legal Reasoning in Large Language Models

法律の推論を 162 の課題で評価する

sasakiy84

公式サイト



[1] LegalBench. 公式サイト。 2026-10-18 確認。 https://hazyresearch.stanford.edu/legalbench/

1. 実例から見る法律課題
2. 162 課題の構成と作成方法
3. 採点と 2023 年の到達水準
4. HELM での範囲と現在の利用

実例から見る法律課題

一つの試験ではなく、法律課題の集合

- LegalBench は、英語の法律課題ごとに入力と参照出力をそろえたベンチマーク。法律家と研究者が共同で構築した。
- 商標、契約、証拠、裁判手続など、異なる分野の 162 課題を含む。課題によって、ラベル・用語・説明文など出力の形が変わる。
- 2023 年に公開され、 20 モデルを評価した。以下では実例から、何を読み、何を答え、どう採点するかを見る。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

実例は公開された提示例用の集合から選ぶ

- 本編 3 件と追加 10 件は、異なる 13 課題の公開 train レコードから 1 件ずつ選んだ。 train は主にプロンプトの提示例を作るための集合である。
- 原レコードの入力欄は全文を示す。課題の問いを添え、固定のルール説明や他の提示例は省いた。実際のプロンプトは、それらを組み合わせて作る。
- 参照ラベル・原レコード・提示テンプレート・固定改訂とハッシュを保存した。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

商標は、語と商品の関係で分類する

分類	語と商品の関係
generic	その商品そのものの一般名称
descriptive	商品の性質を直接表す
suggestive	性質を間接的に示唆する
arbitrary	商品と関係のない既存語
fanciful	新しく作った語

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例１：パンの商標は何を表すか

原入力・課題の問い

The mark "Tasty" for bread. What is the type of mark?

descriptive

日本語訳・課題

パンに使う商標「Tasty（おいしい）」。この商標はどの種類か。

descriptive（記述的）

[1] LegalBench. 公開 train レコードと参照回答。 abercrombie / train / index 1 https://github.com/HazyResearch/legalbench/tree/main/tasks

同じ語でも、何の商品かで判断が変わる

- Tasty はパンの性質を直接表す。一般名称でも、商品と無関係な既存語でもない。
- abercrombie では 5 分類の名前を出力する。長い説明を書くだけでは、要求されたラベルに一致しない。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

伝聞の判定は、発言を使う目的も含む

- hearsay では、法廷外の発言を、その発言内容が真実だと示すために使う場合を伝聞とする。
- 入力には争点と、提出しようとする証拠がある。発言があったかだけでなく、何を立証するために使うかを判断する。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例２：法廷外の発言を証拠にする

原入力・課題の問い

On the issue of whether Rebecca was ill, the fact that Rebecca told Ronald that she was unwell. Is there hearsay?

Yes

日本語訳・課題

レベッカが病気だったかが争われている。レベッカがロナルドに、体調が悪かったと話したという事実。この証拠は伝聞に当たるか。

Yes （当たる）

[1] LegalBench. 公開 train レコードと参照回答。 hearsay / train / index 1 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例３：期限の規定は提訴権を与えるか

原入力・課題の問い

Does the clause specify a private right of action?
Clause: Amendments to pleadings must be filed within 15 days of the filing of the initial pleading.

No

日本語訳・課題

訴答書面の修正は、最初の訴答書面を提出してから 15 日以内に提出しなければならない。この条項は私人の訴権を明記しているか。

No （明記しない）

[1] LegalBench. 公開 train レコードと参照回答。 proa / train / index 0 https://github.com/HazyResearch/legalbench/tree/main/tasks

出力形式に合わせて、法律上の区別を読む

- 商標では分類名、伝聞と私人の訴権では Yes ／ No が答えになる。入力の語だけでなく、問われた法律上の条件を対応させる。
- proa の期限規定は 15 日という具体的な条件を持つが、私人が提訴できるという規定ではない。
- 同じ法律分野でも、結論を選ぶ課題と、その理由を説明する課題は採点方法が異なる。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

162 課題の構成と作成方法

法律家が、実務や教育の問いを持ち寄った

- 40 人の寄稿者が、実務で役立つ処理や、法律家が測る価値があると考える推論を課題にした。 36 のデータ源を利用した。
- 既存の注釈データを変換した課題と、法律の教科書・演習に着想を得て人手で作った課題がある。
- 判決、契約、合併契約、法令、日常的な法律相談など、文体も入力の長さも異なる。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

六つの推論形式を区別する

形式	モデルに求めること
争点の発見	事実が、どの法律上の問題を含むか見つける
法規範の想起	関連する法や判例についての知識を答える
法規範の適用	規範を事実に当てはめ、理由を説明する

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

解釈や文章の役割も推論の対象にする

形式	モデルに求めること
結論の導出	規範を事実に当てはめた結論を選ぶ
文書の解釈	契約や条文が、ある内容を含むか判断する
修辞的な理解	判決の段落の役割や、定義された用語を捉える

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv.
https://arxiv.org/abs/2308.11462

公開コードは 162 課題を五つの群へ分ける

コード上の群	課題数
争点の発見	17
法規範の想起	5
結論の導出	12
文書の解釈	118
修辞的な理解	10

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

理由を説明する評価は、別データとして足さない

- 固定した tasks.py の五つの群は重複せず、合計 162 課題である。
- 12 課題には、同じ入力に対して理由も説明させる application_prompt がある。推論形式は六つでも、これを 162 課題に新しい 12 課題として加算しない。
- 論文の分類ごとの件数には節間の不一致がある。ここでは、取得したコードの明示的な課題一覧を集計した。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

一つの元データが、多数の課題になる

元データ・系列	課題数
CUAD ：契約条項の分類	38
MAUD ：合併契約の理解	34
Learned Hands ：法律相談	16
ContractNLI ：秘密保持契約	14
Supply Chain Disclosure ：企業開示	10

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

系列名と課題名の単位をそろえる

- OPP-115 のプライバシーポリシー分類は 9 課題。そのほか 41 課題を合わせ、系列別の合計も 162 になる。
- たとえば CUAD は、契約の準拠法、監査権、競業避止などを、それぞれ別の入力・出力課題へ変換している。
- LegalBench は集合の名前、 CUAD などは元データの名前、cuad_audit_rights などは個別課題の識別子である。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

提示例用とテスト用を課題ごとに分ける

- 公開データは課題ごとに train.tsv と test.tsv を持つ。 train は提示例の構築、 test は採点に使う。入力欄やラベル欄は課題ごとに異なる。
- abercrombie や hearsay は、種類ごとの問題を手で作り、各種類から 1 例を提示例用に選んだ。
- rule_qa と scalr はゼロショット用で、 train に例がない。提示例がある課題と同じ条件にそろえて解釈しない。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

採点と 2023 年の到達水準

分類では、各ラベルの正解率を均等に扱う

- 分類の出力を小文字化し、句読点を除き、前後の空白を取り除いて参照ラベルと照合する。
- ラベルごとの再現率を平均した balanced accuracy を使う。多数派のラベルだけを答えて高得点になるのを抑える。
- 1 問の一致・不一致と、集合全体でラベルごとに平均した得点を区別する。

[1] LegalBench. 課題別の採点実装。 https://github.com/HazyResearch/legalbench/blob/main/evaluation.py

抽出・複数回答・説明は採点が異なる

- definition_extraction は、語幹化も使って参照用語と照合する。 successor_liability は、選んだ例外の集合を F1 で採点する。
- 説明を求める rule-application は、法律の訓練を受けた人が「結論の正しさ」と「理由付け」を別々に評価した。 rule_qa も人が採点した。
- 課題の得点を平均する前に、何を正解とした指標かをそろえて読む。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

2023 年：争点・規範・結論の成績

モデル	争点	規範	結論
GPT-4 (2023)	82.9	59.2	89.9
text-davinci-003 (2022)	60.9	46.3	78.0
Claude-1 v1.3 (2023)	58.1	57.7	79.5
Flan-T5-XXL (2022)	66.0	36.0	63.3

各推論群の課題得点の平均（％）。 2023 年 5 〜 8 月の評価。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

2023 年：文書解釈と文章の役割

モデル	解釈	修辞的理解
GPT-4 (2023)	75.2	79.4
text-davinci-003 (2022)	72.6	66.7
Claude-1 v1.3 (2023)	67.4	68.9
Flan-T5-XXL (2022)	64.4	70.7

同じ 2023 年評価の群別平均（％）。分類・抽出など課題別の指標を含む。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

理由付けは、正しい結論より得点が低い

モデル	結論の正しさ	理由付け
GPT-4 (2023)	82.2	79.7
text-davinci-003 (2022)	58.5	44.2
Claude-1 v1.3 (2023)	61.4	59.0

rule-application の人手評価（％）。法律の訓練を受けた 1 人が採点。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

モデルとプロンプトの条件を対応させる

- 全体では 20 モデルを評価。 GPT-3.5 は text-davinci-003 、Claude-1 は v1.3 。課題別の指示と 0 〜 8 件の提示例を使い、温度は 0 とした。
- Claude には専用の提示例タグと、出力候補を明記する形式を使った。入力形式まで完全に同一ではない。
- 理由の説明を求める課題は 3 つの商用モデルだけを人手評価した。六つの diversity 課題は各 30 例、ほかは課題の全例を採点した。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

得意な群の平均だけでは、個別課題は分からない

- GPT-4 は広い群で高いが、法規範の想起では Claude-1 に近い。文書の解釈でも、長い企業開示や合併契約では得点が下がる。
- 同じ群に多数の契約課題があるため、群平均と、扱いたい分野・文書の個別成績を併せて見る。
- この成績は 2023 年のモデル・データ・採点条件の記録である。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

HELM での範囲と現在の利用

HELM Classic は五つの課題を実装する

- v0.4.0 の LegalBench 実装は、 abercrombie 、 corporate_lobbying 、 international_citizenship_questions 、 function_of_decision_section 、 proa を受け付ける。
- 入力欄の順番、指示、ラベル欄を課題別設定から読み、参照回答を使って評価する。
- Classic v0.4.0 の公開 run_specs では LegalBench の実行は 0 件だった。以下に同版のモデル得点は置かない。

[1] Stanford CRFM. HELM v0.4.0 LegalBench scenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/legalbench_scenario.py

実装の範囲と、公開実行の有無を分ける

- LegalBench 全 162 課題と、 HELM が受け付ける 5 課題は範囲が異なる。 LegalSupport は別のシナリオであり、 LegalBench の実行件数へ含めない。
- 現在の HELM 実装にも同じ五つの課題が残り、データには固定の Hugging Face 改訂を指定している。
- 公式 LegalBench は、 HELM Lite などの評価基盤からの利用も案内している。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

2026 年に、一部の入力データが修正された

- 2026-03-29 、 MAUD の 7 課題で、問いと異なる箇所の文章を結び付けていた問題が修正された。
- OPP-115 の 9 課題は、短い注釈スパンから、文脈を含む段落全体を入力にする方式へ変更された。
- 2023 年の公表成績と、修正後のデータで得た値は、同じ評価条件として並べない。

[1] LegalBench. データ更新履歴。 2026-03-29 の修正。 https://github.com/HazyResearch/legalbench/blob/main/CHANGELOG.md

課題ごとの出所と条件を確認して使う

- 公式サイトから課題の説明、プロンプト、 Hugging Face の公開データへ進める。各課題の README に出所とライセンスがある。
- 13 実例のうち definition_extraction は CC BY-SA 4.0 。ほかの手作り課題などは CC BY 4.0 だが、全 162 課題が同じライセンスではない。
- 課題名、データの改訂、提示例、採点コードを固定すると、モデル間や更新前後の比較を再現できる。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

法律のどの推論を、どの出力で測るか

- LegalBench は、法律の多様な入力・出力を 162 課題へ分け、法律家とモデル研究者が共同で評価する基盤である。
- ラベルを選ぶ結論、文書の解釈、用語の抽出、理由の説明を分けると、得点の意味が具体的になる。
- 集計する単位、課題別の採点、提示例と版を対応させて、扱いたい文書の能力を判断する。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

Appendix

1. 追加の実例
2. 課題の一覧と評価の補足
3. 研究と参考文献

追加の実例

実例４：定義される用語を取り出す

原入力・課題の問い

Sentence: "But even petitioner concedes, with its preferred dictionary in hand, that the word “decision” can also mean *306 “something short of a statement of reasons explaining a determination.”

decision

日本語訳・課題

「しかし、申立人でさえ、自ら好む辞書を手に、『decision』という語が、判断を説明する理由の記述に至らないものを意味することもあると認めている。」 *306
定義されている用語を抽出する。

decision

[1] LegalBench. 公開 train レコードと参照回答。 definition_extraction / train / index 2 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 4 の読み方

- 判決文で定義されている用語を抽出する。
- 引用文中の decision を取り出す。定義の内容全体を生成する課題ではない。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 5 ：州が異なっても金額条件がある

原入力・課題の問い

Ava is from Alaska. Mia is from Missouri. Ava sues Mia for wrongful eviction for $61,000. Is there diversity jurisdiction?

No

日本語訳・課題

エイヴァはアラスカ州、ミアはミズーリ州の住民である。エイヴァは不当な立退きを理由に、ミアへ 61,000 ドルを請求して訴える。州籍相違による連邦裁判所の管轄はあるか。

No （ない）

[1] LegalBench. 公開 train レコードと参照回答。 diversity_1 / train / index 1 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 5 の読み方

- 当事者の州と請求額から、州籍相違による管轄の有無を判定する。
- 提示ルールでは、原告・被告の州籍が完全に異なり、かつ請求額が 75,000 ドルを超える必要がある。 61,000 ドルは金額条件を満たさない。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 6 ：国籍取得の居住条件を尋ねる

原入力・課題の問い

Answer the following questions considering the state of international law on January 1st, 2020.
Question: Consider the country of Bolivia. Does the country provide for period of residence in a residence-based acquisition? Answer Yes or No.

Yes

日本語訳・課題

2020 年 1 月 1 日時点の法を前提とする。ボリビアを考える。居住に基づく国籍取得について、同国は居住期間の条件を定めているか。はい、または、いいえで答える。

Yes （定めている）

[1] LegalBench. 公開 train レコードと参照回答。 international_citizenship_questions / train / index 1 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 6 の読み方

- 2020 年 1 月 1 日時点の国際的な国籍法について答える。
- 条文が入力にない知識を問う例。資料の参照回答と、その後の法改正を区別して扱う。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 7 ：判決末尾の文の役割を分類する

原入力・課題の問い

Text: For these reasons, we AFFIRM.

Decree

日本語訳・課題

これらの理由により、原判断を維持する。
この文の役割を分類する。

Decree （主文）

[1] LegalBench. 公開 train レコードと参照回答。 function_of_decision_section / train / index 6 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 7 の読み方

- 段落を事実・手続・争点・法規範・分析・結論・主文の 7 種類へ分類する。
- 参照ラベルは Decree 。理由を分析する段落ではなく、裁判所の処分を告げる文である。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 8 ：引用文と判例名が対応するか

原入力・課題の問い

Text: [T]he law is settled that as a general matter the First Amendment prohibits government officials from subjecting an individual to retaliatory actions . . . for speaking out.
Citation: Feist v. La., Dep't of Justice, Off. of the Att'y Gen.

No

日本語訳・課題

「一般論として、表現を理由に公務員が個人へ報復的な措置を取ることは、合衆国憲法修正第 1 条が禁じているという法は確立している。」
候補判例： Feist v. La., Dep’t of Justice, Off. of the Att’y Gen.
この判例名は引用の出所として正しいか。

No （正しくない）

[1] LegalBench. 公開 train レコードと参照回答。 citation_prediction_classification / train / index 1 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 8 の読み方

- 引用文の出所として示した判例名が正しいかを判定する。
- 自由な判例名の生成と、示された候補が正しいかという二値判定は別の課題になっている。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例９：準拠法の条項と秘密保持

原入力・課題の問い

Clause: This Agreement shall be governed by and construed in accordance with the laws of the State of California
Question: Does the clause waive confidentiality?

No

日本語訳・課題

本契約はカリフォルニア州法に準拠し、同法に従って解釈される。
質問：この条項は秘密保持義務を免除しているか。

No （免除していない）

[1] LegalBench. 公開 train レコードと参照回答。 contract_qa / train / index 4 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 9 の読み方

- 条項と質問を読み、はい・いいえで答える。
- 準拠法を定める条項から、別の秘密保持義務の免除を読み込まない。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 10 ：被告の住所地で訴える

原入力・課題の問い

Dustin is a repairman who lives in Arizona and repairs computers in California, Oregon, and Washington. While traveling to repair a computer in Washington, Dustin is involved in a car crash in Oregon with Laura, a citizen of Oregon. After the accident, Dustin returns to Arizona. Laura sues him in Arizona. Is there personal jurisdiction?

Yes

日本語訳・課題

ダスティンはアリゾナ州に住む修理業者で、カリフォルニア、オレゴン、ワシントン各州でコンピューターを修理している。ワシントン州へ修理に向かう途中、オレゴン州で同州住民のローラと自動車事故を起こす。事故後、ダスティンはアリゾナ州へ戻る。ローラは同州で彼を訴える。人的管轄はあるか。

Yes （ある）

[1] LegalBench. 公開 train レコードと参照回答。 personal_jurisdiction / train / index 0 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 10 の読み方

- 被告に対する人的管轄の有無を判定する。
- 課題に示すルールでは、被告が住所を置く州には、その被告に対する人的管轄がある。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 11 ：資産を買った会社の責任

原入力・課題の問い（固定ルール説明・提示例は除く）

Facts: "Mediocre Corp purchased all of Special Corp's assets. The purchase agreement provides for assumption of all of Special Corp's liabilities. Following the asset purchase, Special Corp dissolved. However, Mediocre Corp now holds itself out as Special Corp. Purchasers of Special Corp's speical television remote controls have alleged a mass tort under a theory of products liability and have brough suit against Mediocre Corp. "

express agreement

[1] LegalBench. 公開 train レコードと参照回答。 successor_liability / train / index 2 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 11 ：資産を買った会社の責任（訳）

日本語訳・課題

ミディオカー社はスペシャル社の全資産を買い取った。売買契約では、スペシャル社の全責任を引き受けると定めている。資産売却後、スペシャル社は解散した。しかし、ミディオカー社は今や自社をスペシャル社として対外的に示している。スペシャル社の特殊なテレビ用リモコンの購入者らは、製造物責任を根拠に多数の被害を伴う不法行為を主張し、ミディオカー社を訴えた。どの例外が当たるか。

express agreement （明示の合意）

[1] LegalBench. 公開 train レコードと参照回答。 successor_liability / train / index 2 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 11 の読み方

- 資産譲受人が売主の責任を負う例外を選ぶ。
- 参照回答は契約による責任の明示的な引受け。課題全体では複数の例外を答える例もあり、 F1 で採点する。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 12 ：農場を売買する契約

原入力・課題の問い

Ava buys James' farm for $50,000. Is this contract governed by the UCC or the common law?

Common Law

日本語訳・課題

エイヴァはジェームズの農場を 50,000 ドルで買う。この契約に適用されるのは UCC か、コモン・ローか。

Common Law （コモン・ロー）

[1] LegalBench. 公開 train レコードと参照回答。 ucc_v_common_law / train / index 4 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 12 の読み方

- 契約が UCC とコモン・ローのどちらに従うかを答える。
- 課題で示す区別では、動産売買を UCC 、不動産とサービスの契約をコモン・ローで扱う。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

実例 13 ：告知した価格と請求額が異なる

原入力・課題の問い

Acme Toys is a telemarketer subject to the Telemarketing Sales Rule. Acme Toys told a customer that its frisbees cost $10 each, when in fact the frisbees cost $12 each. The customer agreed to the sale and was charged $12. Is this a violation of the Telemarketing Sales Rule?

Yes

日本語訳・課題

アクミー・トイズ社は電話勧誘販売ルールの対象である。同社は客にフリスビー 1 枚が 10 ドルだと伝えたが、実際の価格は 12 ドルだった。客は売買に同意し、 12 ドルを請求された。これは電話勧誘販売ルールへの違反か。

Yes （違反）

[1] LegalBench. 公開 train レコードと参照回答。 telemarketing_sales_rule / train / index 0 https://github.com/HazyResearch/legalbench/tree/main/tasks

実例 13 の読み方

- 電話勧誘販売ルールへの違反を判定する。
- 商品価格についての虚偽の説明を判定する。問われるルールの条文番号は 16 C.F.R. § 310.3(a)(1) ・ (2) 。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

課題の一覧と評価の補足

2023 年の入力・出力形式の内訳

形式	課題数
選択式	35
自由生成	7
二値分類	112
多クラス・複数ラベル	8

2023 年の公表分類。合計 162 課題。推論形式の分類とは別の軸。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

ゼロショットと提示例の役割

- 2023 年評価では、課題ごとに 0 〜 8 件の提示例を選んだ。長い開示文書では、複数の提示例を入れられない場合がある。
- 分類・抽出は改行で出力を止めた。 rule_qa と適用課題の大半は 150 トークン、 diversity_jurisdiction_6 は 300 トークンを生成した。
- 提示例用 train の少なさは、モデルの教師あり学習の規模を表すものではない。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

2023 年の件数表記と、固定コードの集計

- 論文本文の推論群別件数は、争点 16 ／ 17 、解釈 119 など、箇所によって値が異なる。
- この資料の課題構成表は、 GitHub の固定改訂 b46bf4ff の TASKS と五つの群を照合した。 162 識別子が重複なく、いずれかの群に一度ずつ入る。
- 理由を説明する 12 の application_prompt は、同じ入力を使う別の評価形式として扱った。

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（1/14）

abercrombie
canada_tax_court_outcomes
citation_prediction_classification
citation_prediction_open
consumer_contracts_qa
contract_nli_confidentiality_of_agreement
contract_nli_explicit_identification
contract_nli_inclusion_of_verbally_conveyed_information
contract_nli_limited_use
contract_nli_no_licensing
contract_nli_notice_on_compelled_disclosure
contract_nli_permissible_acquirement_of_similar_information

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（2/14）

contract_nli_permissible_copy
contract_nli_permissible_development_of_similar_information
contract_nli_permissible_post-agreement_possession
contract_nli_return_of_confidential_information
contract_nli_sharing_with_employees
contract_nli_sharing_with_third-parties
contract_nli_survival_of_obligations
contract_qa
corporate_lobbying
cuad_affiliate_license-licensee
cuad_affiliate_license-licensor
cuad_anti-assignment

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（3/14）

cuad_audit_rights
cuad_cap_on_liability
cuad_change_of_control
cuad_competitive_restriction_exception
cuad_covenant_not_to_sue
cuad_effective_date
cuad_exclusivity
cuad_expiration_date
cuad_governing_law
cuad_insurance
cuad_ip_ownership_assignment
cuad_irrevocable_or_perpetual_license

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（4/14）

cuad_joint_ip_ownership
cuad_license_grant
cuad_liquidated_damages
cuad_minimum_commitment
cuad_most_favored_nation
cuad_no-solicit_of_customers
cuad_no-solicit_of_employees
cuad_non-compete
cuad_non-disparagement
cuad_non-transferable_license
cuad_notice_period_to_terminate_renewal
cuad_post-termination_services

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（5/14）

cuad_price_restrictions
cuad_renewal_term
cuad_revenue-profit_sharing
cuad_rofr-rofo-rofn
cuad_source_code_escrow
cuad_termination_for_convenience
cuad_third_party_beneficiary
cuad_uncapped_liability
cuad_unlimited-all-you-can-eat-license
cuad_volume_restriction
cuad_warranty_duration
definition_classification

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（6/14）

definition_extraction
diversity_1
diversity_2
diversity_3
diversity_4
diversity_5
diversity_6
function_of_decision_section
hearsay
insurance_policy_interpretation
jcrew_blocker
international_citizenship_questions

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（7/14）

nys_judicial_ethics
learned_hands_benefits
learned_hands_business
learned_hands_consumer
learned_hands_courts
learned_hands_crime
learned_hands_divorce
learned_hands_domestic_violence
learned_hands_education
learned_hands_employment
learned_hands_estates
learned_hands_family

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（8/14）

learned_hands_health
learned_hands_housing
learned_hands_immigration
learned_hands_torts
learned_hands_traffic
legal_reasoning_causality
maud_ability_to_consummate_concept_is_subject_to_mae_carveouts
maud_financial_point_of_view_is_the_sole_consideration
maud_accuracy_of_fundamental_target_rws_bringdown_standard
maud_accuracy_of_target_general_rw_bringdown_timing_answer
maud_accuracy_of_target_capitalization_rw_(outstanding_shares)_bringdown_standard_answer

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（ 9/14 ）

maud_additional_matching_rights_period_for_modifications_(cor)
maud_application_of_buyer_consent_requirement_(negative_interim_covenant)
maud_buyer_consent_requirement_(ordinary_course)
maud_change_in_law__subject_to_disproportionate_impact_modifier
maud_changes_in_gaap_or_other_accounting_principles__subject_to_disproportionate_impact_modifier
maud_cor_permitted_in_response_to_intervening_event
maud_cor_permitted_with_board_fiduciary_determination_only
maud_cor_standard_(intervening_event)
maud_cor_standard_(superior_offer)
maud_definition_contains_knowledge_requirement_-_answer
maud_definition_includes_asset_deals

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（10/14）

maud_definition_includes_stock_deals
maud_fiduciary_exception__board_determination_standard
maud_fiduciary_exception_board_determination_trigger_(no_shop)
maud_fls_(mae)_standard
maud_general_economic_and_financial_conditions_subject_to_disproportionate_impact_modifier
maud_includes_consistent_with_past_practice
maud_initial_matching_rights_period_(cor)
maud_initial_matching_rights_period_(ftr)
maud_intervening_event_-_required_to_occur_after_signing_-_answer
maud_knowledge_definition
maud_liability_standard_for_no-shop_breach_by_target_non-do_representatives

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（11/14）

maud_ordinary_course_efforts_standard
maud_pandemic_or_other_public_health_event__subject_to_disproportionate_impact_modifier
maud_pandemic_or_other_public_health_event_specific_reference_to_pandemic-related_governmental_responses_or_measures
maud_relational_language_(mae)_applies_to
maud_specific_performance
maud_tail_period_length
maud_type_of_consideration
opp115_data_retention
opp115_data_security
opp115_do_not_track

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（12/14）

opp115_first_party_collection_use
opp115_international_and_specific_audiences
opp115_policy_change
opp115_third_party_sharing_collection
opp115_user_access,_edit_and_deletion
opp115_user_choice_control
oral_argument_question_purpose
overruling
personal_jurisdiction
privacy_policy_entailment
privacy_policy_qa
proa

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（13/14）

rule_qa
scalr
ssla_company_defendants
ssla_individual_defendants
ssla_plaintiff
sara_entailment
sara_numeric
successor_liability
supply_chain_disclosure_best_practice_accountability
supply_chain_disclosure_best_practice_audits
supply_chain_disclosure_best_practice_certification
supply_chain_disclosure_best_practice_training

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

公開 162 課題の識別子（14/14）

supply_chain_disclosure_best_practice_verification
supply_chain_disclosure_disclosed_accountability
supply_chain_disclosure_disclosed_audits
supply_chain_disclosure_disclosed_certification
supply_chain_disclosure_disclosed_training
supply_chain_disclosure_disclosed_verification
telemarketing_sales_rule
textualism_tool_dictionaries
textualism_tool_plain
ucc_v_common_law
unfair_tos

[1] LegalBench. 公式タスク・プロンプト・採点コード。 2026-10-18 固定版。 https://github.com/HazyResearch/legalbench

入手容量と改訂を分けて記録する

- 公式 Hugging Face の TSV 一覧は、メタデータ上で計 82,311,731 bytes （約 82.3 MB ）。今回、全テスト本文を取得して実測した値ではない。
- GitHub には公開 train と一部修正済み test があり、同じ配布範囲ではない。今回の 13 例は GitHub の固定改訂から取得した。
- 原入力・ラベル・課題別のテンプレートと README 、ファイルごとの SHA256 を調査記録に保存した。

[1] LegalBench. nguha/legalbench 公式公開配布。 https://huggingface.co/datasets/nguha/legalbench

研究と参考文献

法学と機械学習の共同研究

- 第一著者 Neel Guha らを中心に、 Stanford University などの法学者、法律実務家、機械学習研究者が参加した。
- 共通の法律推論の語彙を使い、法律家が作った課題を、言語モデルの評価として共有することを目指した。
- 2023 年の論文は 162 課題と 20 モデルの評価を報告。公式サイトは 40 人の寄稿者を紹介している。

[1] Guha et al. (2023), LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. arXiv. https://arxiv.org/abs/2308.11462

参考文献

LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models

Guha et al. · 2023 · arXiv:2308.11462

六つの法律推論の整理、課題構築、 20 モデルの評価を報告する。

https://arxiv.org/abs/2308.11462

LegalBench

LegalBench contributors · 公式サイト

課題の仕様、寄稿者、参加方法と公開データを案内する。

https://hazyresearch.stanford.edu/legalbench/

参考文献

LegalBench: Tasks, prompts, and evaluation

LegalBench contributors · 公式リポジトリ

課題ごとの README 、提示例、プロンプトと採点実装を公開する。

https://github.com/HazyResearch/legalbench

LegalBench data changelog

LegalBench contributors · 2024–2026 · 更新履歴

MAUD と OPP-115 の入力修正、ラベル修正などの変更内容を記録する。

https://github.com/HazyResearch/legalbench/blob/main/CHANGELOG.md

参考文献

Holistic Evaluation of Language Models

Liang et al. · 2023 · TMLR

課題・指標・モデルを共通条件で比較する評価基盤を提案する。

https://arxiv.org/abs/2211.09110

HELM LegalBench scenario

Stanford CRFM · v0.4.0 · 公開実装

五つの LegalBench 課題の入力整形と、参照回答の読み込みを定義する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/legalbench_scenario.py