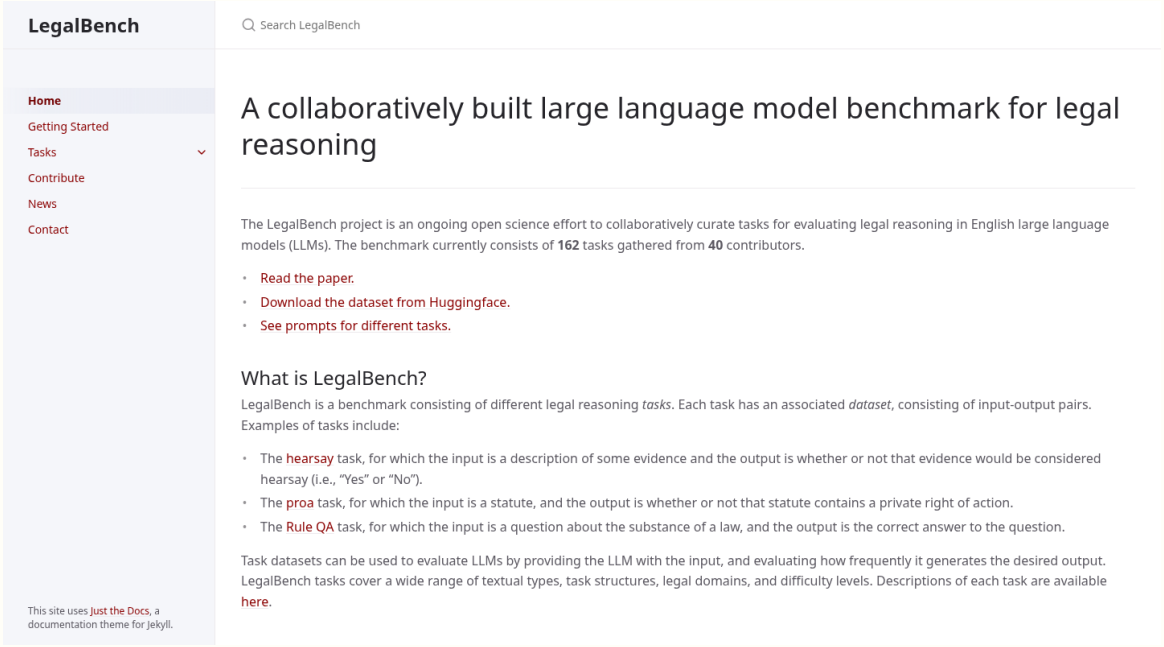
# LegalBench

A Collaboratively Built Benchmark for
Measuring Legal Reasoning in Large Language Models

法律の推論を 162 の課題で評価する

sasakiy84

# 公式サイト




[1] LegalBench (n.d.). Official site. https://hazyresearch.stanford.edu/legalbench/

1. 実例から見る法律課題
2. 162 課題の構成と作成方法
3. 採点と 2023 年の到達水準
4. データの入手と使い方

# 実例から見る法律課題

# 一つの試験ではなく、法律課題の集合

- LegalBench は、英語の法律課題ごとに入力と参照出力をそろえたベンチマーク。法律家と研究者が共同で構築した。
- 商標、契約、証拠、裁判手続など、異なる分野の 162 課題を含む。課題によって、ラベル・用語・説明文など出力の形が変わる。
- 2023 年に公開され、 20 モデルを評価した。以下では実例から、何を読み、何を答え、どう採点するかを見る。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 公開された提示例から、入力と答えを見る

- 実例は、異なる 13 課題の公開 train から 1 件ずつ示す。 train は、モデルへ与える提示例を作るための集合である。
- 各例では原レコードの入力欄全文に、課題の問いを添える。実際のプロンプトは、課題ごとのルール説明や提示例と組み合わせて作る。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 商標は、語と商品の関係で分類する

| 分類 | 語と商品の関係 |
|---|---|
| generic | その商品そのものの一般名称 |
| descriptive | 商品の性質を直接表す |
| suggestive | 性質を間接的に示唆する |
| arbitrary | 商品と関係のない既存語 |
| fanciful | 新しく作った語 |

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 実例１：パンの商標は何を表すか

原入力・課題の問い

The mark "Tasty" for bread. What is the type of mark?

**descriptive**

日本語訳・課題

パンに使う商標「Tasty（おいしい）」。この商標はどの種類か。

**descriptive（記述的）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/abercrombie

# 同じ語でも、何の商品かで判断が変わる

- Tasty はパンの性質を直接表す。一般名称でも、商品と無関係な既存語でもない。
- abercrombie では、五つの分類名のいずれかを答える。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 伝聞の判定は、発言を使う目的も含む

- hearsay では、法廷外の発言を、その発言内容が真実だと示すために使う場合を伝聞とする。
- 入力には争点と、提出しようとする証拠がある。発言があったかだけでなく、何を立証するために使うかを判断する。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 実例２：法廷外の発言を証拠にする

原入力・課題の問い

On the issue of whether Rebecca was ill, the fact that Rebecca told Ronald that she was unwell. Is there hearsay?

**Yes**

日本語訳・課題

レベッカが病気だったかが争われている。レベッカがロナルドに、体調が悪かったと話したという事実。この証拠は伝聞に当たるか。

**Yes （当たる）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/hearsay

# 実例３：期限の規定は提訴権を与えるか

原入力・課題の問い

Does the clause specify a private right of action?
Clause: Amendments to pleadings must be filed within 15 days of the filing of the initial pleading.

**No**

日本語訳・課題

訴答書面の修正は、最初の訴答書面を提出してから 15 日以内に提出しなければならない。この条項は私人の訴権を明記しているか。

**No （明記しない）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/proa

# 出力形式に合わせて、法律上の区別を読む

- 商標では分類名、伝聞と私人の訴権では Yes ／ No が答えになる。入力の語だけでなく、問われた法律上の条件を対応させる。
- proa の期限規定は 15 日という具体的な条件を持つが、私人が提訴できるという規定ではない。
- 同じ法律分野でも、結論を選ぶ課題と、その理由を説明する課題は採点方法が異なる。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 162 課題の構成と作成方法

# 法律家が、実務や教育の問いを持ち寄った

- 40 人の寄稿者が、実務で役立つ処理や、法律家が測る価値があると考える推論を課題にした。 36 のデータ源を利用した。
- 既存の注釈データを変換した課題と、法律の教科書・演習に着想を得て人手で作った課題がある。
- 判決、契約、合併契約、法令、日常的な法律相談など、文体も入力の長さも異なる。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 法律推論を六つの形式で捉える

| 形式 | モデルに求めること |
| --- | --- |
| 争点の発見 | 事実が、どの法律上の問題を含むか見つける |
| 法規範の想起 | 関連する法や判例についての知識を答える |
| 法規範の適用 | 規範を事実に当てはめ、理由を説明する |

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 解釈や文章の役割も推論の対象にする

| 形式 | モデルに求めること |
| --- | --- |
| 結論の導出 | 規範を事実に当てはめた結論を選ぶ |
| 文書の解釈 | 契約や条文が、ある内容を含むか判断する |
| 修辞的な理解 | 判決の段落の役割や、定義された用語を捉える |

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 課題の大半は、文書の解釈を扱う

| 推論の形式 | 課題数 |
|---|---|
| 争点の発見 | 17 |
| 法規範の想起 | 5 |
| 結論の導出 | 12 |
| 文書の解釈 | 118 |
| 修辞的な理解 | 10 |

結論を選ぶ 12 課題には、同じ入力から理由も説明する評価形式がある。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 一つの元データが、多数の課題になる

| 元データ・系列 | 課題数 |
|---|---|
| CUAD ：契約条項の分類 | 38 |
| MAUD ：合併契約の理解 | 34 |
| Learned Hands ：法律相談 | 16 |
| ContractNLI ：秘密保持契約 | 14 |
| Supply Chain Disclosure ：企業開示 | 10 |

OPP-115 の 9 課題など、ほかにも複数の系列がある。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 提示例用とテスト用を課題ごとに分ける

- 多くの課題は train.tsv と test.tsv を持つ。 train でモデルへ示す入力・参照回答を用意し、 test で回答を採点する。入力欄と答えの形式は課題ごとに異なる。
- abercrombie や hearsay は、人が種類ごとの問題を作り、各種類から 1 例を提示例用に選んだ。
- rule_qa と scalr は、提示例を使わないゼロショット用で、 test を公開している。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 採点と 2023 年の到達水準

# 分類では、各ラベルの正解率を均等に扱う

- 分類の出力を小文字化し、句読点を除き、前後の空白を取り除いて参照ラベルと照合する。
- ラベルごとの再現率を平均した balanced accuracy を使う。少数派のラベルを含め、各ラベルを同じ重みで評価する。

[1] LegalBench. Task-specific evaluation. https://github.com/HazyResearch/legalbench/blob/main/evaluation.py

# 抽出・複数回答・説明は採点が異なる

- definition_extraction は、語幹化も使って参照用語と照合する。 successor_liability は、選んだ例外の集合を F1 で採点する。
- 理由を説明する課題は、法律の訓練を受けた人が「結論の正しさ」と「理由付け」を別々に評価した。 rule_qa も人が採点した。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 2023 年：争点・規範・結論の成績

| モデル | 争点 | 規範 | 結論 |
|---|---|---|---|
| GPT-4 (2023) | 82.9 | 59.2 | 89.9 |
| text-davinci-003 (2022) | 60.9 | 46.3 | 78.0 |
| Claude-1 v1.3 (2023) | 58.1 | 57.7 | 79.5 |
| Flan-T5-XXL (2022) | 66.0 | 36.0 | 63.3 |

各推論群の課題得点の平均（％）。 2023 年 5 〜 8 月の評価。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 2023 年：文書解釈と文章の役割

| モデル | 解釈 | 修辞的理解 |
|---|---|---|
| GPT-4 (2023) | 75.2 | 79.4 |
| text-davinci-003 (2022) | 72.6 | 66.7 |
| Claude-1 v1.3 (2023) | 67.4 | 68.9 |
| Flan-T5-XXL (2022) | 64.4 | 70.7 |

同じ 2023 年評価の群別平均（％）。分類・抽出など課題別の指標を含む。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 理由付けは、正しい結論より得点が低い

| モデル | 結論の正しさ | 理由付け |
|---|---|---|
| GPT-4 (2023) | 82.2 | 79.7 |
| text-davinci-003 (2022) | 58.5 | 44.2 |
| Claude-1 v1.3 (2023) | 61.4 | 59.0 |

rule-application の人手評価（％）。法律の訓練を受けた 1 人が採点。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 提示例を与え、課題ごとに回答を評価する

- 分類や抽出などは 20 モデルを評価した。課題別の指示に 0 〜 8 件の提示例を添えて、回答させた。
- 理由の説明は、 GPT-4 、 text-davinci-003 、 Claude-1 の 3 モデルを人手で評価した。州籍相違に関する 6 課題は各 30 例、ほかの課題は全例を採点した。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# モデルの得意分野は、課題ごとに変わる

- GPT-4 は広い群で高いが、法規範の想起では Claude-1 に近い。文書の解釈でも、長い企業開示や合併契約では得点が下がる。
- 同じ群に多数の契約課題があるため、群平均と、扱いたい分野・文書の個別成績を併せて見る。
- 英語の課題で、米国法や契約分野に比重がある。成績は 2023 年のモデル・データ・採点条件による。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# データの入手と使い方

# TSV から、商標の入力と参照回答を読む

```
import csv

with open("tasks/abercrombie/train.tsv",
          encoding="utf-8") as f:
    rows = list(csv.DictReader(f, delimiter="\t"))
row = rows[1]
print(row["text"])
print(row["answer"])
```

公式リポジトリの tasks フォルダを使う。 text が入力、 answer が参照回答で、課題ごとに列の構成が異なる。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 2026 年に、一部の入力データが修正された

- 2026-03-29 、 MAUD の 7 課題で、問いと異なる箇所の文章を結び付けていた問題が修正された。
- OPP-115 の 9 課題は、短い注釈スパンから、文脈を含む段落全体を入力にする方式へ変更された。
- 2023 年の公表成績は、これらの入力修正前のデータで得た結果である。

[1] LegalBench. Data changelog (2024–2026). https://github.com/HazyResearch/legalbench/blob/main/CHANGELOG.md

# 課題ごとの出所と条件を確認して使う

- 公式サイトから課題の説明、プロンプト、 Hugging Face の公開データへ進める。各課題の README に出所とライセンスがある。
- 実例の definition_extraction は CC BY-SA 4.0 。ほかの手作り課題などは CC BY 4.0 で、課題によって利用条件が異なる。
- README とサンプルには、入力欄と答えの形式が示されている。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 法律のどの推論を、どの出力で測るか

- LegalBench は、法律の多様な入力・出力を 162 課題にまとめ、法律家とモデル研究者が共同で構築したベンチマーク。
- 分類名を選ぶ、文書を解釈する、用語を抽出する、理由を説明するなど、複数の形で法律の推論を測る。
- 扱いたい法律分野や文書に応じて、課題ごとの得点と採点方法を読む。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# Appendix

1. 追加の実例
2. 課題形式の補足
3. 研究と参考文献

# 追加の実例

# 実例４：定義される用語を取り出す

原入力・課題の問い

Sentence: "But even petitioner concedes, with its preferred dictionary in hand, that the word “decision” can also mean *306 “something short of a statement of reasons explaining a determination.”

**decision**

日本語訳・課題

「しかし、申立人でさえ、自ら好む辞書を手に、『decision』という語が、判断の理由を説明する記述とまではいえないものを意味することもあると認めている。」*306
定義されている用語を抽出する。

**decision**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/definition_extraction

# 実例 5 ：州が異なっても金額条件がある

原入力・課題の問い

Ava is from Alaska. Mia is from Missouri. Ava sues Mia for wrongful eviction for $61,000. Is there diversity jurisdiction?

**No**

日本語訳・課題

エイヴァはアラスカ州、ミアはミズーリ州の住民である。エイヴァは不当な立退きを理由に、ミアへ 61,000 ドルを請求して訴える。州籍相違による連邦裁判所の管轄はあるか。

**No （ない）**

課題の規則では、州籍が完全に異なり、請求額が 75,000 ドルを超える必要がある。

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/diversity_1

# 実例 6 ：国籍取得の居住条件を尋ねる

原入力・課題の問い

Answer the following questions considering the state of international law on January 1st, 2020.
Question: Consider the country of Bolivia. Does the country provide for period of residence in a residence-based acquisition? Answer Yes or No.

**Yes**

日本語訳・課題

2020 年 1 月 1 日時点の国際法を前提とする。ボリビアを考える。居住に基づく国籍取得について、同国は居住期間の条件を定めているか。はい、または、いいえで答える。

**Yes （定めている）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/international_citizenship_questions

# 実例 7 ：判決末尾の文の役割を分類する

原入力・課題の問い

Text: For these reasons, we AFFIRM.

**Decree**

日本語訳・課題

これらの理由により、原判断を維持する。
この文の役割を分類する。

**Decree （主文）**

判決の文を、事実・手続・争点・法規範・分析・結論・主文の 7 種類に分類する。

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/function_of_decision_section

# 実例 8 ：引用文と判例名が対応するか

原入力・課題の問い

Text: [T]he law is settled that as a general matter the First Amendment prohibits government officials from subjecting an individual to retaliatory actions . . . for speaking out.
Citation: Feist v. La., Dep't of Justice, Off. of the Att'y Gen.

**No**

日本語訳・課題

「一般に、公務員が発言への報復として個人に措置を取ることは、合衆国憲法修正第 1 条で禁じられている。この法理は確立している。」
候補判例： Feist v. La., Dep’t of Justice, Off. of the Att’y Gen.
この判例名は引用の出所として正しいか。

**No （正しくない）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/citation_prediction_classification

# 実例９：準拠法の条項と秘密保持

原入力・課題の問い

Clause: This Agreement shall be governed by and construed in accordance with the laws of the State of California
Question: Does the clause waive confidentiality?

**No**

日本語訳・課題

本契約はカリフォルニア州法に準拠し、同法に従って解釈される。
質問：この条項は秘密保持義務を免除しているか。

**No （免除していない）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/contract_qa

# 実例 10 ：被告の住所地で訴える

原入力・課題の問い

Dustin is a repairman who lives in Arizona and repairs computers in California, Oregon, and Washington. While traveling to repair a computer in Washington, Dustin is involved in a car crash in Oregon with Laura, a citizen of Oregon. After the accident, Dustin returns to Arizona. Laura sues him in Arizona.  Is there personal jurisdiction?

**Yes**

日本語訳・課題

ダスティンはアリゾナ州に住む修理業者で、カリフォルニア、オレゴン、ワシントン各州でコンピューターを修理している。ワシントン州へ修理に向かう途中、オレゴン州で同州住民のローラと自動車事故を起こす。事故後、ダスティンはアリゾナ州へ戻る。ローラは同州で彼を訴える。人的管轄はあるか。

**Yes （ある）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/personal_jurisdiction

# 実例 10 の読み方

- 被告に対する人的管轄の有無を判定する。
- 課題に示すルールでは、被告が住所を置く州には、その被告に対する人的管轄がある。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 実例 11 ：資産を買った会社の責任

原入力・課題の問い

Facts: "Mediocre Corp purchased all of Special Corp's assets. The purchase agreement provides for assumption of all of Special Corp's liabilities. Following the asset purchase, Special Corp dissolved. However, Mediocre Corp now holds itself out as Special Corp. Purchasers of Special Corp's speical television remote controls have alleged a mass tort under a theory of products liability and have brough suit against Mediocre Corp. "

**express agreement**

日本語訳・課題

ミディオカー社はスペシャル社の全資産を買い取った。売買契約では、スペシャル社の全責任を引き受けると定めている。資産売却後、スペシャル社は解散した。しかし、ミディオカー社は今や自社をスペシャル社として対外的に示している。スペシャル社の特殊なテレビ用リモコンの購入者らは、製造物責任を根拠に多数の被害を伴う不法行為を主張し、ミディオカー社を訴えた。どの例外が当たるか。

**明示の合意**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/successor_liability

# 資産の譲受人が責任を負う例外を答える

- 参照回答は契約による責任の明示的な引受け。課題全体では複数の例外を答える例もあり、 F1 で採点する。

[1] LegalBench (n.d.). Tasks, prompts, and evaluation. https://github.com/HazyResearch/legalbench

# 実例 12 ：農場を売買する契約

原入力・課題の問い

Ava buys James' farm for $50,000. Is this contract governed by the UCC or the common law?

**Common Law**

日本語訳・課題

エイヴァはジェームズの農場を 50,000 ドルで買う。この契約に適用されるのは UCC か、コモン・ローか。

**Common Law （コモン・ロー）**

UCC （統一商事法典）は動産売買、コモン・ローは不動産やサービスの契約を扱う規則で判定する。

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/ucc_v_common_law

# 実例 13 ：告知した価格と請求額が異なる

原入力・課題の問い

Acme Toys is a telemarketer subject to the Telemarketing Sales Rule. Acme Toys told a customer that its frisbees cost $10 each, when in fact the frisbees cost $12 each. The customer agreed to the sale and was charged $12. Is this a violation of the Telemarketing Sales Rule?

**Yes**

日本語訳・課題

アクミー・トイズ社は電話勧誘販売ルールの対象である。同社は客にフリスビー 1 枚が 10 ドルだと伝えたが、実際の価格は 12 ドルだった。客は売買に同意し、 12 ドルを請求された。これは電話勧誘販売ルールへの違反か。

**Yes （違反）**

[1] LegalBench. 公開入力と参照回答。 https://github.com/HazyResearch/legalbench/tree/main/tasks/telemarketing_sales_rule

# 課題形式の補足

# 2023 年の入力・出力形式の内訳

| 形式 | 課題数 |
|---|---|
| 選択式 | 35 |
| 自由生成 | 7 |
| 二値分類 | 112 |
| 多クラス・複数ラベル | 8 |

2023 年の公表分類。合計 162 課題。推論形式の分類とは別の軸。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 研究と参考文献

# 法学と機械学習の共同研究

- Neel Guha らによる、法学・法律実務と機械学習の共同研究。スタンフォード大学をはじめ、多くの研究機関や実務家が参加した。
- 法律の推論を表す共通の語彙を使い、法律家が作った課題を、言語モデルの評価に生かすことを目指した。
- NeurIPS 2023 で 162 課題と 20 モデルの評価を報告。公式サイトは 40 人の寄稿者を紹介している。

[1] Guha et al. (2023). LegalBench. NeurIPS. https://arxiv.org/abs/2308.11462

# 参考文献


## LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models

Guha et al. · 2023 · NeurIPS 36, pp.44123–44279

法律家と研究者が共同構築した 162 課題と、 20 モデルの評価を報告する。

https://proceedings.neurips.cc/paper_files/paper/2023/hash/89e44582fd28ddfea1ea4dcb0ebbf4b0-Abstract-Datasets_and_Benchmarks.html

## LegalBench — official site

LegalBench contributors (n.d.). 公式サイト。参照 2026-10-19 。

課題の説明、寄稿者、参加方法と公開データを案内する。

https://hazyresearch.stanford.edu/legalbench/

# 参考文献


## LegalBench: Tasks, prompts, and evaluation

LegalBench contributors (n.d.). 公式リポジトリ。参照 2026-10-19 。

課題ごとの README 、提示例、プロンプトと採点実装を公開する。

https://github.com/HazyResearch/legalbench

## LegalBench data changelog

LegalBench contributors · 2024–2026 · 更新履歴。参照 2026-10-19 。

MAUD と OPP-115 の入力修正、ラベル修正などの変更内容を記録する。

https://github.com/HazyResearch/legalbench/blob/main/CHANGELOG.md