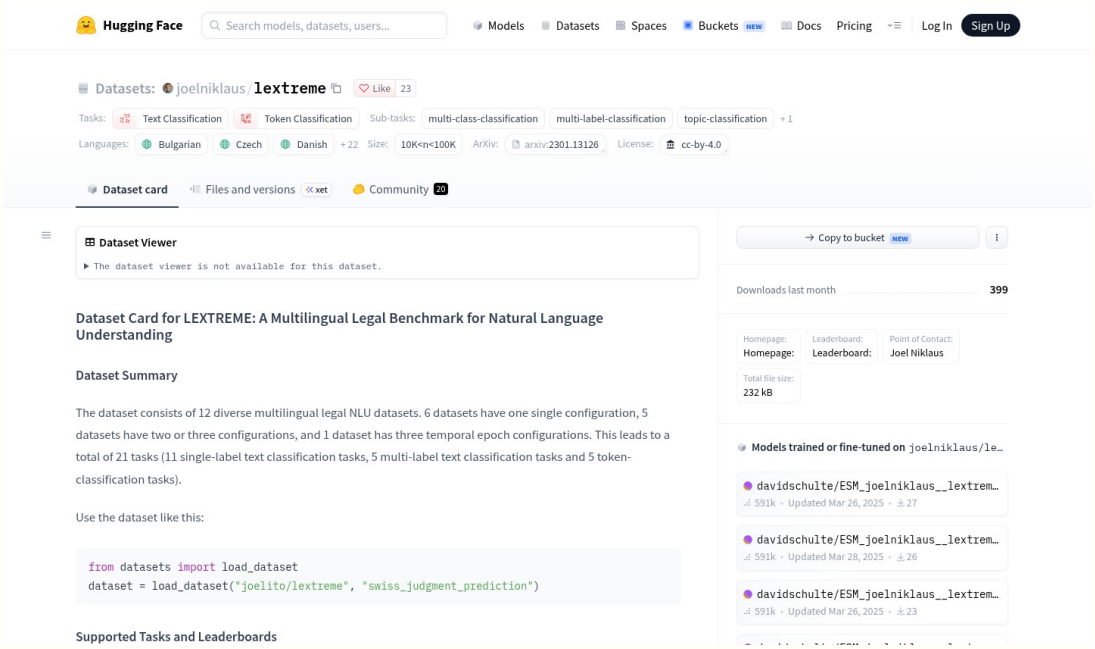
LEXTREME

多言語・多タスクの法律ベンチマーク

文書分類、複数ラベル、固有表現を読む

sasakiy84

公式配布ページ： LEXTREME



[1] Joel Niklaus et al. LEXTREME dataset card. 2026-10-18 参照。 https://huggingface.co/datasets/joelniklaus/lextreme

1. 法律文書の三つの読み取り方
2. データ・言語・法域を組み合わせる
3. 原スイートと HELM の評価条件
4. 入手方法と利用の範囲

1. 法律文書の三つの読み取り方

法律文書の理解を多言語で測る

- LEXTREME は、法律文書の理解を多言語で測るためのデータセット群。既存の裁判例・法令・利用規約などを共通の形式にそろえている。
- 2023 年のスイートは 11 データセットを 18 設定に分けて評価する。単一ラベル分類 8 設定、複数ラベル分類 5 設定、固有表現認識 5 設定からなる。
- 判決の結果、条項の話題、日付や法令名など、異なる粒度の情報を扱う。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/
[2] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

何を答えるかで三つに分かれる

課題	入力	求める答え
単一ラベル分類	判決や規約の文章	カテゴリー一つ
複数ラベル分類	規約や法令の文章	該当するカテゴリの集合
固有表現認識	文を分けたトークン列	各トークンの種類

以下の 3 例は公開構成データから選び、 HELM の入力・正解形式に変換した。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP.
https://aclanthology.org/2023.findings-emnlp.200/

実例１：文の結論を識別する

ドイツ語 / german_argument_mining

入力原文（全文）

1. Der erstmals im Berufungsverfahren gestellte Antrag zu 3. ist zulässig .

日本語訳（意味）

1. 控訴審で初めて提出された第３の申立ては適法である。

正解ラベル

conclusion

conclusion ：結論

各文が判決の議論で果たす役割を分類する。

[1] joelniklaus/german_argument_mining. test.jsonl 、固定版 576b52004ed7 。 test.jsonl line 6 （１始まり）。
https://huggingface.co/datasets/joelniklaus/german_argument_mining/tree/576b52004ed7

実例２：一つの条項に二つの話題を付ける

英語 / online_terms_of_service_clause_topics

入力原文（全文）

By using the Service in any way, you agree to and accept these Terms, our Privacy Notice, and any other legal notices or guidelines posted on the Site.

日本語訳（意味）

本サービスをどのように利用した場合も、本規約、当社のプライバシー通知、本サイト上のその他の法的通知・指針に同意し、受け入れるものとします。

正解ラベル

7, 8

7 ：利用による契約成立／
8 ：プライバシーを含む

[1] joelniklaus/online_terms_of_service. test.jsonl 、固定版 448c5caa985b 。 test.jsonl line 1051 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/online_terms_of_service/tree/448c5caa985b

実例３：日付に対応するトークンを見つける

ルーマニア語 / legalnero

入力原文：トークン列（全文）

"MONITORUL" "OFICIAL" "nr." "959" "din" "28" "noiembrie" "2019"

正解：対応する BIO ラベル列（全文）

"O" "O" "O" "O" "B-TIME" "I-TIME" "I-TIME" "I-TIME"

意味：官報 第 959 号、 2019 年 11 月 28 日付。

原注釈では「 din 」から日付末尾までが時間表現。 O は対象外を表す。

[1] joelniklaus/legalnero. test.jsonl 、固定版 a072e8508049 。 test.jsonl line 4 （ 1 始まり）。 https://huggingface.co/datasets/joelniklaus/legalnero/tree/a072e8508049

原語の位置とラベルを対応させる

- 固有表現認識では、文全体に一つのラベルを付けず、トークンごとに種類を付ける。 B- は開始、 I- は継続、 O は対象外を表す。
- 実例 3 では「 din 」から日付の末尾までが TIME と注釈されている。語の境界と注釈範囲を元データのまま示した。
- 訳は入力の意味を示し、原語のトークン列と正解ラベルは保持する。日本語訳へ機械的に同じ BIO 列を付け替えることはしない。

[1] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py
[2] joelniklaus/legalnero. test.jsonl 、固定版 a072e8508049 。 https://huggingface.co/datasets/joelniklaus/legalnero/tree/a072e8508049

2. データ・言語・法域を組み合わせる

既存データを選び、共通形式にそろえる

- 法律 NLP に関する 108 件の論文を調べ、公開・再配布の条件、注釈の作り方、法的課題との関係などに基づいて 11 データセットを選んだ。
- 元のラベルと入力を共通の input ・ label ・ language へ対応させる。内容を一つの新しい法域へ翻訳・統合したデータではない。
- 各データセットに train ・ validation ・ test を用意する。判決の認容と全員一致、法典の階層などを別の設定として扱う。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/
[2] LEXTREME loader, 2023-02-07 版（65f6046b8083）。 https://huggingface.co/datasets/joelniklaus/lextreme/blob/65f6046b8083/lextreme.py

分類で使う文書と予測対象

構成データ	文書・法域	予測対象／設定数
Brazilian Court Decisions	ブラジルの裁判例	判決結果・全員一致／ 2
German Argument Mining	ドイツの裁判例	文の議論上の役割／ 1
Greek Legal Code	ギリシャの法令	法典の 3 階層／ 3
Swiss Judgment Prediction	スイスの裁判例	上訴の認容・棄却／ 1
Online Terms of Service	EU の利用規約	不公正さ・条項の話題／ 2

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP.
https://aclanthology.org/2023.findings-emnlp.200/

政策措置・ EU 法・固有表現も含む

構成データ	文書・範囲	設定数
COVID-19 Emergency Event	各国の COVID-19 対策文書	1
MultiEURLEX	EU 法の EUROVOC 概念	3
Greek Legal NER	ギリシャの法令・固有表現	1
LegalNERo	ルーマニアの法令・固有表現	1
LeNER-Br	ブラジルの法律文書・固有表現	1
MAPA	EU 法・粗い／細かい固有表現	2

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP.
https://aclanthology.org/2023.findings-emnlp.200/

言語と法域を別の軸として扱う

- 一つの法域に複数の言語があり、同じ言語が複数の法域で使われる。スイスの判決はドイツ語・フランス語・イタリア語で扱う。
- MultiEURLEX と MAPA は複数の EU 公用語を扱う。英語だけを見てもスイート全体は評価できない。
- 言語別の総合集計は 24 EU 言語。 C19 の構成データにはノルウェー語もあるため、データ内の言語と総合集計対象を区別する。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP.
https://aclanthology.org/2023.findings-emnlp.200/

同じ文書を別の観点から分類する

- Greek Legal Code は volume ・ chapter ・ subject の 3 段階のカテゴリを予測する。細かい階層ほどラベル候補が増える。
- Online Terms of Service では、不公正さの程度は単一ラベル、条項の話題は複数ラベルとなる。入力の出所が同じでも答え方は異なる。
- 各設定・言語・分割をそろえて比較する。設定数や多言語の翻訳を単純に足して「別の文書数」と数えない。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/
[2] LEXTREME loader, 2023-02-07 版（65f6046b8083）。 https://huggingface.co/datasets/joelniklaus/lextreme/blob/65f6046b8083/lextreme.py

3. 原スイートと HELM の評価条件

原スイートはタスクごとに学習する

- 基準実験では、各設定で fine-tuning し、 seed=1 〜 3 の 3 試行を用いる。 test の macro-F1 で評価し、平均とばらつきを報告する。
- 少数クラスへの偏りを抑えるため、単一ラベル分類では GLC を除いてランダムな過剰サンプリングを用いる。
- 長い文書は 128 トークンの塊に分けて階層型モデルで処理する。評価条件は HELM の少数例プロンプトと異なる。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/

データ別と、言語別の二方向で集約する

- データ別では、設定内の言語、データセット内の設定、スイート内のデータセットの順に、調和平均を取る。
- 言語別では、各言語について設定とデータセットをまとめ、最後に言語間の調和平均を取る。
- 最終 LEXTREME 得点は、この二つの集約得点の調和平均。大きなデータセットだけが総合得点を左右しないようにする。法域別の総合集計は設けていない。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/

原スイートの基準実験の集約得点

多言語モデル	データ別の集約	言語別の集約
MiniLM	19.9	18.1
DistilBERT	43.2	31.9
mDeBERTa v3	44.1	34.8
XLM-R base	36.8	19.7
XLM-R large	48.5	36.0

0 〜 100 。 3 seed の fine-tuning 基準実験。 HELM の得点ではない。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP.
https://aclanthology.org/2023.findings-emnlp.200/

HELM はラベルを生成する形へ変換する

- HELM v0.3.0 は 18 設定を読み込み、英語の課題指示、Passage 、 Answer という形式でラベル文字列を生成させる。
- 設定別の最大提示例数は 1 〜 5 。長い法令・判決ほど少なく、 NER では 5 例を上限とする。実提示数は公開 run がないため実測していない。
- MultiEURLEX では、そのレコードに存在する言語から一つを乱数で選ぶ。全言語を各文書について順番に評価する実装ではない。

[1] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py
[2] Stanford CRFM. get_lextreme_spec, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/run_specs.py

HELM の生成上限は課題ごとに異なる

設定群	最大提示例	最大出力トークン
ブラジル裁判例	4	5
ドイツ議論／利用規約／ C19	5	5 ／ 10 ／ 10
ギリシャ法典／ MultiEURLEX	1	20 ／ 10
スイス判決	2	5
NER 5 設定	5	274 〜 788

v0.3.0 の設定上限。モデルが実際に読んだ例数・トークン数ではない。

[1] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

Classic v0.4.0 の公開実行は 0 件

確認したもの	公開内容
シナリオ	LEXTREME が登録されている
表示上の主指標	test の classification_macro_f1
run_specs ／ suite 対応表	該当する公開 run は 0 件
モデル別の成績	公開値はない

latest 設定は v0.4.0 （ 2023-11-17 ）。 2026-10-18 に配布 JSON と照合した。

[1] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 固定版）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/lextreme

採点の登録も課題別に確かめる

- 分類では classification_macro_f1 と classification_micro_f1 を計算する。複数ラベルの出力は「, 」で区切り、正規化したラベルの集合を比較する。
- v0.3.0 の run spec では、 NER に分類指標を追加していない。BasicMetric の正解一致指標リストも空で、 NER の品質得点をこの定義だけから読み取れない。
- 公開実行が 0 件なので、モデル別の得点は掲載されていない。原スイートの NER macro-F1 や fine-tuning 得点と同じランキングがあるとは解釈しない。

[1] Stanford CRFM. get_lextreme_spec, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/run_specs.py
[2] Stanford CRFM. ClassificationMetric, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/classification_metrics.py

4. 入手方法と利用の範囲

固定版のローダーと構成データを使う

```
from datasets import load_dataset

ds = load_dataset(
    "joelito/lextreme",
    "german_argument_mining",
    revision="65f6046b8083"
)
```

2023-02-07 のローダーを指定する例。 datasets の旧ローダースクリプト対応環境が必要で、構成データの取得先も別に固定する。

[1] LEXTREME loader, 2023-02-07 版（ 65f6046b8083 ）。 https://huggingface.co/datasets/joelniklaus/lextreme/blob/65f6046b8083/lextreme.py

公開実例は構成データから再取得した

- この資料の 13 例は、 6 つの構成データの test JSONL から選んだ。 HELM の公開モデル応答から採った例ではない。
- 各データのコミット ID 、ファイル SHA-256 、行番号、原レコード全体を保存した。表示した入力と正解を公式変換処理で照合している。
- 8 言語を含むが、全データ・全言語を代表する無作為標本ではない。入力フィールドは省略せず、原文と正解を同じページに置いた。

[1] LEXTREME loader, 2023-02-07 版（ 65f6046b8083 ）。 https://huggingface.co/datasets/joelniklaus/lextreme/blob/65f6046b8083/lextreme.py
[2] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

スイートと構成データの権利を分ける

- 現在の LEXTREME 配布カードは CC BY 4.0 を表示する。構成データごとに権利条件が異なるため、配布物ごとに確認する。
- 例に使った構成データには、 GAM の CC BY 4.0 、 C19 の CC0 、 OTS の CC BY-NC 2.5 、 LegalNERo の CC BY-NC-ND 4.0 、 Greek Legal NER の CC BY-NC-SA 4.0 がある。
- 本資料は出所を付けた短い例の引用と意味の訳を示す。コードの Apache 2.0 を、元文章の再配布条件に読み替えない。

[1] Joel Niklaus et al. LEXTREME dataset card. 2026-10-18 参照。 https://huggingface.co/datasets/joelniklaus/lextreme
[2] Stanford CRFM. HELM v0.3.0. Apache License 2.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/LICENSE

配布ページの更新と HELM 実装を区別する

- 現在の配布カードは、ウクライナの裁判例 3 時期を追加した 12 データセット・ 21 設定・ 25 言語を案内している。
- 2023 年の論文と HELM 実装は 11 データセット・ 18 設定。この資料の 18 設定には、追加されたウクライナの 3 設定を含めていない。
- HELM の main 版も 18 設定。一方、現配布ローダーは 32 設定を登録しており、カードの 21 設定という概要とも一致しない。

[1] Joel Niklaus et al. LEXTREME dataset card. 2026-10-18 参照。 https://huggingface.co/datasets/joelniklaus/lextreme
[2] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

課題・言語・評価条件をそろえて読む

- LEXTREME は、法律文書の分類と固有表現認識を多言語で比べるスイート。法域、入力の長さ、ラベル数、答え方が構成データごとに異なる。
- 原スイートの集約得点は fine-tuning 実験を多段の調和平均でまとめる。 HELM は少数例から文字列を生成する別の評価条件を用意している。
- Classic の公開 run は 0 件。公式実装、構成データの原記録、採点方法の範囲を確かめて利用する。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/
[2] Stanford CRFM. HELM Classic v0.4.0 （2023-11-17 固定版）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/lextreme

Appendix

1. 追加の実例
2. 構成と変換の詳細
3. 研究と参考文献

実例 4 ：一般的な法的判断基準を識別する

ドイツ語 / german_argument_mining

入力原文（全文）

Ob eine überraschende Klausel vorliegt , ist durch Auslegung zu ermitteln .

日本語訳（意味）

意外性のある条項が存在するかどうかは、解釈によって判断しなければならない。

正解ラベル

definition

definition ：定義・抽象的な判断基準

具体的事件への当てはめではなく、判断基準を述べる文。

[1] joelniklaus/german_argument_mining. test.jsonl 、固定版 576b52004ed7 。 test.jsonl line 75 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/german_argument_mining/tree/576b52004ed7

実例 5 ：具体的な事件への当てはめを識別する

ドイツ語 / german_argument_mining

入力原文（全文）

Die ergänzende Darlegung der Nettovorteile ist gem. § 264 Nr. 1 ZPO unschädlich .

日本語訳（意味）

正味の利益についての補充的な説明は、民事訴訟法第 264 条第 1 号により支障を生じさせない。

正解ラベル

subsumption

subsumption ：具体的事実への当てはめ

データの文間スペースと略記を原文のまま保持した。

[1] joelniklaus/german_argument_mining. test.jsonl 、固定版 576b52004ed7 。 test.jsonl line 10 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/german_argument_mining/tree/576b52004ed7

実例６：ドイツ語の免責条項を分類する

ドイツ語 / online_terms_of_service_unfairness_levels

入力原文（全文）

Wir haften nicht für Verluste oder Schäden, die durch Ihre Verletzung dieser Sicherungspflicht entstehen.

日本語訳（意味）

この安全確保義務に対するあなたの違反によって生じる損失や損害について、当社は責任を負いません。

正解ラベル

potentially_unfair

potentially_unfair ：不公正の可能性がある

ここでの答えはデータの注釈。現在の法的有効性を判定したものではない。

[1] joelniklaus/online_terms_of_service. test.jsonl 、固定版 448c5caa985b 。 test.jsonl line 60 （１始まり）。
https://huggingface.co/datasets/joelniklaus/online_terms_of_service/tree/448c5caa985b

実例７：イタリア語の削除条項を分類する

イタリア語 / online_terms_of_service_clause_topics

入力原文（全文）

Avremo altresì diritto a rimuovere ogni Contenuto che violi le presenti Condizioni o che, a nostra assoluta discrezione, riteniamo comunque non appropriato.

日本語訳（意味）

当社はまた、本規約に違反する、または当社の単独の裁量によりその他の点で不適切と判断するあらゆるコンテンツを削除する権利を有します。

２：コンテンツの削除

正解ラベル

2

[1] joelniklaus/online_terms_of_service. test.jsonl 、固定版 448c5caa985b 。 test.jsonl line 2170 （１始まり）。
https://huggingface.co/datasets/joelniklaus/online_terms_of_service/tree/448c5caa985b

実例 8 ：フランス語の学校閉鎖措置を読む

フランス語 / covid19_emergency_event

入力原文（全文）

Les leçons et activités sont suspendues dans l'enseignement maternel, primaire et secondaire.

日本語訳（意味）

就学前教育、初等教育および中等教育では、授業と活動を停止する。

正解ラベル

3

3 ：閉鎖・ロックダウン

ベルギーの公開文書。出力は政策の是非ではなく措置の分類。

[1] joelniklaus/covid19_emergency_event. test.jsonl 、固定版 bba0491bc1ba 。 test.jsonl line 10 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/covid19_emergency_event/tree/bba0491bc1ba

実例９：ノルウェー語の人数制限を読む

ノルウェー語 / covid19_emergency_event

入力原文（全文）

Dette innebærer også at treninger og annen organisert idrettsaktivitet kan gjennomføres for inntil 20 personer som holder minst én meter avstand.

日本語訳（意味）

これは、少なくとも 1 メートルの距離を保つ最大 20 人で、練習やその他の組織的なスポーツ活動を実施できることも意味する。

正解ラベル

2

2 ：日常生活上の自由の制限

[1] joelniklaus/covid19_emergency_event. test.jsonl 、固定版 bba0491bc1ba 。 test.jsonl line 304 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/covid19_emergency_event/tree/bba0491bc1ba

実例 10 ：イタリア語の義務に複数ラベルを付ける

イタリア語 / covid19_emergency_event

入力原文（全文）

obbligo di rimanere raggiungibile per le attività di sorveglianza;

日本語訳（意味）

監視活動のために連絡が取れる状態を保つ義務。

正解ラベル

1, 2

1 ：基本権・市民的自由の制限／ 2 ：日常生活上の自由の制限

原注釈の二つの措置ラベルを保持する。

[1] joelniklaus/covid19_emergency_event. test.jsonl 、固定版 bba0491bc1ba 。 test.jsonl line 212 （ 1 始まり）。 https://huggingface.co/datasets/joelniklaus/covid19_emergency_event/tree/bba0491bc1ba

実例 11 ：ギリシャ語の法令参照を見つける

ギリシャ語 / greek_legal_ner

入力原文：トークン列（全文）

"ΠΡΟΕΔΡΙΚΟ" "ΔΙΑΤΑΓΜΑ" "ΥΠ" "”" "ΑΡΙΘΜ" "." "133"

正解：対応する BIO ラベル列（全文）

"B-LEG-REFS" "I-LEG-REFS" "I-LEG-REFS"
"I-LEG-REFS" "I-LEG-REFS" "I-LEG-REFS" "I-LEG-REFS"

意味：大統領令 第 133 号。

原注釈では 7 トークン全体が一つの法令参照。句読点も含む。

[1] joelniklaus/greek_legal_ner. test.jsonl 、固定版 e2bc5fd22217 。 test.jsonl line 1 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/greek_legal_ner/tree/e2bc5fd22217

実例 12 ：ブラジルの異議申立ての結果を予測する

ポルトガル語 / brazilian_court_decisions_judgment

入力原文（全文）

EMBARGOS DE DECLARAÇÃO. ALEGAÇÃO DE OMISSÃO NO JULGADO. HONORÁRIOS RECURSAIS. DESCABIMENTO. INEXISTÊNCIA DE VÍCIO.

日本語訳（意味）

判決の明確化を求める異議申立て。判決に判断の欠落があるとの主張。上訴審の弁護士報酬。認められない。瑕疵は存在しない。

正解ラベル

no

no ：申立てを退けた

[1] joelniklaus/brazilian_court_decisions. test.jsonl 、固定版 e937c2db8eab 。 test.jsonl line 396 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/brazilian_court_decisions/tree/e937c2db8eab

実例 13 ：同じ裁判資料で全員一致を予測する

ポルトガル語 / brazilian_court_decisions_unanimity

入力原文（全文）

APELAÇÃO CÍVEL. JUSTIÇA GRATUITA. DECISÃO INTERLOCUTÓRIA DE INDEFERIMENTO QUE NÃO FOI IMPUGNADA NO PRAZO LEGAL. PRECLUSÃO. IMPOSSIBILIDADE DE REDISCUSSÃO EM SEDE DE APELAÇÃO. SENTENÇA MANTIDA.

日本語訳（意味）

民事上訴。訴訟費用の免除。法定期間内に争われなかった却下の中間決定。失権。上訴段階で再び争うことはできない。原判決を維持する。

unanimity ：全員一致

正解ラベル

unanimity

[1] joelniklaus/brazilian_court_decisions. test.jsonl 、固定版 e937c2db8eab 。 test.jsonl line 325 （1 始まり）。
https://huggingface.co/datasets/joelniklaus/brazilian_court_decisions/tree/e937c2db8eab

代表的な分類設定の分割件数

設定	train	validation	test
BCD-J	3,234	404	405
BCD-U	1,715	211	204
GAM	19,271	2,726	3,078
SJP	59,709	8,208	17,357
OTS-UL	2,074	191	417
OTS-CT	19,942	1,690	4,297

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP.
https://aclanthology.org/2023.findings-emnlp.200/

法令・固有表現の分割件数

設定	train	validation	test
GLC 各階層	28,536	9,511	9,516
C19	3,312	418	418
MEU 各階層	817,239	112,500	115,000
GLN	17,699	4,909	4,017
LNR	7,552	966	907
LNB	7,828	1,177	1,390

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP.
https://aclanthology.org/2023.findings-emnlp.200/

文書数を横断して単純加算しない

- MAPA は粗い・細かい両設定で train 27,823 、 validation 3,354 、 test 10,590 。トークン化された単位を扱う。
- 同じ文書に対するラベル階層や言語別の翻訳があるため、設定別の件数を足すと、独立した法律文書数にはならない。
- 表示した分割件数は 2023 年の報告値。今回の取得値は、 6 つの test JSONL の行数と区別して stats.json に保存した。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/

NER の出力上限は注釈列の長さに依存

設定	最大提示例数	最大出力トークン
Greek Legal NER	5	430
LegalNERo	5	788
LeNER-Br	5	338
MAPA coarse	5	274
MAPA fine	5	274

各トークンにラベルを返すため、文書分類より出力上限が長い。

[1] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

文字列ラベルを整数番号へ変換する

- LEXTREME ローダーは、 OTS の条項話題を a ・ ch ・ cr ・ j ・ law ・ ltd ・ ter ・ use ・ pinc の順で ClassLabel にする。
- HELM は複数ラベルの整数を文字列へ変換する。そのため実例 2 の use ・ pinc は、正解「 7, 8 」になる。
- C19 も event1 〜 event8 を 0 〜 7 へ対応させる。原ラベル名の数字と、 HELM の 0 始まりの番号を混同しない。

[1] LEXTREME loader, 2023-02-07 版（ 65f6046b8083 ）。 https://huggingface.co/datasets/joelniklaus/lextreme/blob/65f6046b8083/lextreme.py
[2] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

NER では引用符でトークンを区切る

- 入力のトークンと正解の BIO ラベルは、それぞれ「 "token1" "token2" 」という形式の文字列にする。
- 誤答参照は非 O ラベルを別の種類に置き換えて作り、シャッフル後に最大 30 件へ制限する。正解は元の注釈列をそのまま保持する。
- 参照候補の作成に使う乱数は 42 。 MultiEURLEX の言語選択にも同じ乱数状態を使うため、設定と処理順を保存する。

[1] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

未注釈の文と不公正さを区別する

- OTS の原 test JSONL は 4,297 行あるが、不公正さの分類に使うラベルは 3 種類で、 untagged の行をローダーが除外する。
- 同様に BCD の全員一致では、 unanimity と not-unanimity の 2 種類を使い、 not_determined を除外する。指示文に候補が書かれていても、読込対象とは限らない。
- この資料は有効ラベルを持つ行を選んだ。複数ラベルが空の文の参照処理や、全 18 設定の実行成功までは検証していない。

[1] LEXTREME loader, 2023-02-07 版（ 65f6046b8083 ）。 https://huggingface.co/datasets/joelniklaus/lextreme/blob/65f6046b8083/lextreme.py
[2] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

研究・構築・評価コードを公開する

- Joel Niklaus 、 Veton Matoshi 、 Pooja Rani 、 Andrea Galassi 、 Matthias Stürmer 、 Ilias Chalkidis が、多言語の法律ベンチマークとして LEXTREME を提案した。
- 既存の 11 データセットを選び、共通のローダーと、データ別・言語別の集約方法を用意した。論文にはモデル比較と構成データごとの結果がある。
- HELM は同じデータを生成形式で扱うシナリオを別途実装している。データの構築と評価実装は別の貢献として区別する。

[1] Niklaus et al. (2023). LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain. Findings of EMNLP. https://aclanthology.org/2023.findings-emnlp.200/
[2] Stanford CRFM. LEXTREMEScenario, HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

参考文献

LEXTREME: A Multi-Lingual and Multi-Task Benchmark for the Legal Domain

Joel Niklaus, Veton Matoshi, Pooja Rani, Andrea Galassi, Matthias Stürmer & Ilias Chalkidis. 2023. Findings of EMNLP 2023, 3016–3053.

11 データセットの選定、 18 設定、言語別・データ別集約、モデル評価を示す。

https://aclanthology.org/2023.findings-emnlp.200/

LEXTREME dataset card and loader

Joel Niklaus et al. Hugging Face Datasets. 2023 版と 2026-05-20 更新版。

構成データの読込・入力とラベルの対応・追加データを記載する。

https://huggingface.co/datasets/joelniklaus/lextreme

参考文献

LEXTREMEScenario and get_lextreme_spec

Stanford CRFM. HELM v0.3.0.

18 設定、英語指示、生成上限、参照文字列、分類指標を定義する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/lextreme_scenario.py

HELM Classic — LEXTREME

Stanford CRFM. v0.4.0 （2023-11-17）。2026-10-18 参照。

分類指標を登録する。配布 run 一覧には LEXTREME 実行がない。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/lextreme

参考文献

Design and Implementation of German Legal Decision Corpora

Stefanie Urchs, Jelena Mitrović & Michael Granitzer. 2021. ICAART, vol. 2, 515–521.

ドイツ語判決の議論上の役割を注釈したコーパスを構築する。

https://doi.org/10.5220/0010187305150521

A Corpus for Multilingual Analysis of Online Terms of Service

Kasper Drawzeski, Andrea Galassi, Agnieszka Jabłonowska, Francesca Lagioia, Marco Lippi, Hans-Wolfgang Micklitz, Giovanni Sartor, Giacomo Tagiuri & Paolo Torroni. 2021. NLLP, 1–8.

利用規約の不公正さと条項の話題を複数言語で注釈する。

https://aclanthology.org/2021.nllp-1.1/

参考文献

A Multilingual Approach to Identify and Classify Exceptional Measures against COVID-19

Georgios Tziafas, Eugénie de Saint-Phalle, Wietse de Vries, Clara Egger & Tommaso Caselli. 2021. NLLP, 46–62.

各国の COVID-19 対策文書から例外的措置の種類を分類する。

https://aclanthology.org/2021.nllp-1.5/

Romanian Named Entity Recognition in the Legal domain (LegalNERo)

Vasile Păiș, Maria Mitrofan, Carol Luca Gasan, Alexandru Ianov, Corvin Ghiță, Vlad Silviu Coneschi & Andrei Onuț. 2021. Zenodo.

ルーマニア語の法律文書に人名・組織・日時などを注釈する。

https://doi.org/10.5281/zenodo.4922385

参考文献

Named Entity Recognition, Linking and Generation for Greek Legislation

Iosif Angelidis, Ilias Chalkidis & Manolis Koubarakis. 2018. JURIX.

ギリシャ語法令の固有表現と法令参照を認識・関連付けする。

https://huggingface.co/datasets/joelniklaus/greek_legal_ner

Predicting Brazilian Court Decisions

André Lage-Freitas, Héctor Allende-Cid, Orivaldo Santana & Lívia Oliveira-Lage. 2022. PeerJ Computer Science 8, e904.

ブラジルの裁判例から判決結果を予測するデータと手法を示す。

https://doi.org/10.7717/peerj-cs.904