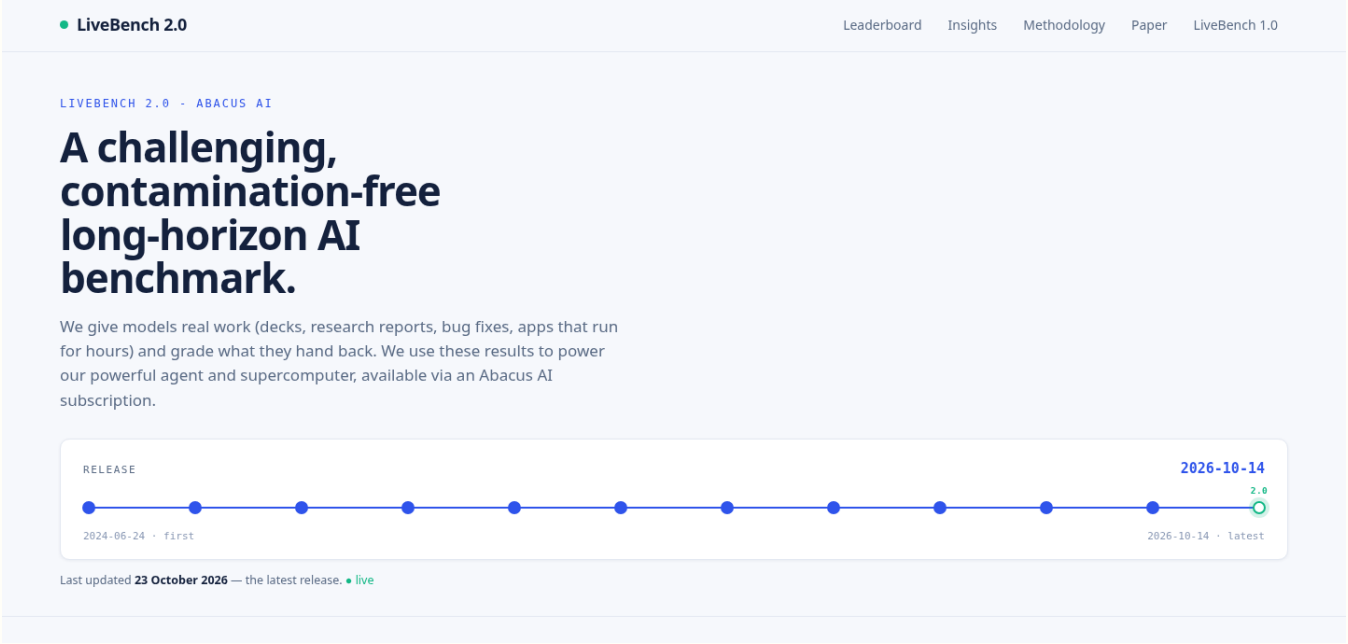
LiveBench

問題を更新し、幅広い能力を評価する

sasakiy84

1. 公開問題で課題と正解を見る
2. 問題の構築と分野の広がり
3. 採点方法とモデルの成績
4. 長い実務課題への展開と入手方法

LiveBench 2.0 の公式サイト



[1] LiveBench (2026-10-25 参照), LiveBench 2.0.
https://livebench.ai/

1. 公開問題で課題と正解を見る

更新型の問題集合から、長い実務課題へ

- LiveBench は、問題を継続的に更新して、幅広いモデル能力を測る評価データセットとして 2024 年に登場した。答えが明確な課題を集め、正解照合やテストで採点する設計を採った。
- 2026 年 10 月公開の 2.0 では、アプリの操作や報告書・スライドの作成など、複数の手順を踏む実務課題へ対象を広げた。

[1] White et al. (2025), LiveBench. https://arxiv.org/abs/2406.19314
[2] LiveBench (2026-10-25 参照), LiveBench 2.0. https://livebench.ai/

13 例は、公開された 1.0 系列から選んだ

- 本編の 3 例と Appendix の 10 例は、 2024 年 6 月・ 7 月に公開された 1.0 系列の問題である。推理、数学、コード、言語、指示への対応、データ分析の六分野を含む。
- 問題の原文、依頼の日本語訳、参照回答や採点条件を対応させる。 2.0 の課題構成と成績は、 2026 年 10 月の公開情報に基づいて紹介する。

[1] LiveBench (2026-10-25 参照), official repository. https://github.com/LiveBench/LiveBench
[2] LiveBench (2026-10-25 参照), Methodology. https://livebench.ai/#/methodology

例 1 三人の属性を推理する：原文

There are 3 people standing in a line numbered 1 through 3 in a left to right order.
Each person has a set of attributes: Food, Nationality, Hobby.
The attributes have the following possible values:
- Food: nectarine, garlic, cucumber
- Nationality: chinese, japanese, thai
- Hobby: magic-tricks, filmmaking, puzzles
and exactly one person in the line has a given value for an attribute.
Given the following premises about the line of people:
- the person that likes garlic is on the far left
- the person who is thai is somewhere to the right of the person who likes magic-tricks
- the person who is chinese is somewhere between the person that likes cucumber and the person who likes puzzles
Answer the following question:
What is the hobby of the person who is thai? Return your answer as a single word, in the following format: ***X***, where X is the answer.

[1] LiveBench (2024), reasoning — public questions.
https://huggingface.co/datasets/livebench/reasoning

例 1 三人の属性を推理する：日本語訳

問題の日本語訳

3 人が左から 1 番、 2 番、 3 番の順に並んでいる。各人には、食べ物・国籍・趣味の三つの属性がある。候補は次のとおり。
食べ物：ネクタリン、ニンニク、キュウリ
国籍：中国人、日本人、タイ人
趣味：手品、映画制作、パズル
各属性のそれぞれの値に当てはまる人は、ちょうど 1 人ずついる。
次の条件が分かっている。
・ニンニクが好きな人は、いちばん左にいる。
・タイ人は、手品が好きな人より右にいる。
・中国人は、キュウリが好きな人とパズルが好きな人の間にいる。
タイ人の趣味は何か。答えを 1 語で、 ***X*** の形式で返す。 X には答えを入れる。

[1] LiveBench (2024), reasoning — public questions.
https://huggingface.co/datasets/livebench/reasoning

例 1 三人の属性を推理する：答えの読み方

正解： filmmaking （映画制作）

位置	食べ物	国籍	趣味
1	ニンニク	日本人	パズル
2	ネクタリン	中国人	手品
3	キュウリ	タイ人	映画制作

中国人は 2 番にいる。ニンニクが 1 番なので、キュウリが 3 番、パズルが 1 番になる。タイ人は 3 番に入り、手品は 2 番に決まるため、 3 番の趣味は映画制作となる。

[1] LiveBench (2024), reasoning — public questions.
https://huggingface.co/datasets/livebench/reasoning

例 2 結合できる列を対応付ける：原文

依頼と二つの表の原文（全文）

Please create a valid join mapping between CSV Table A and CSV Table B. Each column in A maps to 0 or 1 columns in B. Return your response as a Python dictionary, formatted as {col_name_in_df_a : col_name_in_df_b}. Please return only the dictionary.

CSV Table A:

```
email,label
Act now! Limited-tim,spam
Upgrade to our premi,ham
Thank you for subscr,ham
Your order has been ,ham
We're excited to sha,ham
URGENT: Your account,spam
We've extended our s,ham
You've been selected,spam
Your account has bee,spam
Unlock exclusive dis,spam
```

CSV Table B:

```
lG1K/C5s5Ww,t8DtGa8xUVw
ham,0
ham,0
ham,0
ham,0
ham,0
ham,0
spam,0
ham,0
ham,0
ham,0
ham,0
```

Output:

[1] LiveBench (2024), data_analysis — public questions.
https://huggingface.co/datasets/livebench/data_analysis

例 2 結合できる列を対応付ける：日本語訳

依頼の日本語訳（表の値は原文と共通）

CSV 形式の表 A と表 B について、有効な結合用の列の対応を作る。 A の各列に、 B の列を最大 1 列ずつ対応付ける。答えは { 表 A の列名 : 表 B の列名 } という Python 辞書の形式にし、辞書だけを返す。
表 A には email と label がある。表 B では列名が lG1K/C5s5Ww と t8DtGa8xUVw に置き換わっている。表の値は原文に示したとおり。

正解：{"label": "lG1K/C5s5Ww"}

表 A の label には ham と spam が入り、表 B の lG1K/C5s5Ww にも同じ種類の値がある。もう一方の列は 0 だけなので、対応する列は label から lG1K/C5s5Ww への一組となる。

[1] LiveBench (2024), data_analysis — public questions.
https://huggingface.co/datasets/livebench/data_analysis

例 3 引用符と五つの節を守る：原文

問題の原文（全文）

The following are the beginning sentences of a news article from the Guardian.

Should I feel guilty about buying a Christmas tree? Millions are grown and cut each year, but is this an environmental plus or minus? Bill Green, Tring, Herts
Post your answers – and new questions – below or email them to nq@theguardian.com
---
Please paraphrase based on the sentences provided. Wrap your entire response with double quotation marks. Your response must have 5 sections. Mark the beginning of each section with Section X, such as:
Section 1
[content of section 1]
Section 2
[content of section 2]

[1] LiveBench (2024), instruction_following — public questions.
https://huggingface.co/datasets/livebench/instruction_following

例 3 引用符と五つの節を守る：日本語訳

問題の日本語訳

以下は、 The Guardian の記事の冒頭の文である。

クリスマスツリーを買うことに罪悪感を覚えるべきだろうか。毎年、何百万本もの木が育てられ、伐採されている。これは環境にとってプラスなのか、マイナスなのか。 Bill Green 、 Tring 、 Herts 。回答や新しい質問は下欄に投稿するか、nq@theguardian.com へメールで送ってください。

示された文を言い換える。回答全体を二重引用符で囲む。回答は五つの節にする。各節の冒頭には、次の例のように Section X と記す。
Section 1
［第 1 節の内容］
Section 2
［第 2 節の内容］

[1] LiveBench (2024), instruction_following — public questions.
https://huggingface.co/datasets/livebench/instruction_following

例 3 引用符と五つの節を守る：答えの読み方

要求する形式：全体を二重引用符で囲む／五つの節

この例では、回答文は一つに定まらない。公開された機械判定は、回答全体の引用符と、 Section に番号を付けた節見出しを確認する。

[1] LiveBench (2024), instruction_following — public questions.
https://huggingface.co/datasets/livebench/instruction_following

2. 問題の構築と分野の広がり

新しい素材と、既存課題の難化を組み合わせる

- Colin White らは、公開された評価問題がモデルの学習に入り、成績を押し上げる問題に対応するため、評価用の問題を入れ替える仕組みを作った。
- 新しい数学競技、論文の要旨、ニュース記事、データ表を素材にする方法と、既存の推理・数式・指示追従課題を難しく作り直す方法を組み合わせた。

[1] White et al. (2025), LiveBench.
https://arxiv.org/abs/2406.19314

登場時は六分野を含む

分野	代表的な課題
数学	競技問題、数式の穴埋め、式の計算
コード	プログラム生成、途中のコードの補完
推理	属性推理、発言の真偽、空間関係
言語	共通語の分類、誤字訂正、文の並べ替え
指示への対応	言い換え・要約などに形式条件を付ける
データ分析	表の変換、結合列の対応、列の分類

[1] White et al. (2025), LiveBench.
https://arxiv.org/abs/2406.19314

課題ごとに、素材と正解の作り方が異なる

- 空間推理には人が書いた 50 問を用意した。属性推理や数式の計算では生成手順を使い、既存の課題より複雑な条件や数値を取り入れた。
- 誤字訂正では論文要旨のつづりを崩し、表変換ではデータの形式を変える。元の文章や表を参照値として、出力を照合できるようにした。

[1] White et al. (2025), LiveBench.
https://arxiv.org/abs/2406.19314

新しい問題を加え、古い問題を入れ替える

- 2024 年 6 月の初期公開は 960 問。翌月までに課題の追加と除外を行い、全体を 1,000 問にした。
- 当初は平均で約 6 分の 1 ずつを月ごとに入れ替え、約 6 か月で一巡させる運用を設計した。新しい問題は公開を 1 か月遅らせ、未公開の問題も使って評価した。

[1] White et al. (2025), LiveBench.
https://arxiv.org/abs/2406.19314

3. 採点方法とモデルの成績

正解照合と、課題に応じた部分点を使う

- 単語や数値の答えは参照値と照合し、コードはテストで動作を確かめる。表の列対応は適合率と再現率から F1 を計算し、語の組分けは正しく作れた組の割合を得点にする。
- 登場時の集計は、問題ごとの 0 〜 1 の得点を課題ごとに平均し、その平均を分野ごと、最後に六分野全体で平均する。問題の多い分野だけが総合点を支配しない設計である。

[1] White et al. (2025), LiveBench. https://arxiv.org/abs/2406.19314
[2] LiveBench (2026-10-25 参照), official repository. https://github.com/LiveBench/LiveBench

指示追従では、全条件と個別条件を評価する

評価の観点	例 3 で確認する内容
回答全体の条件	最初と最後を二重引用符で囲む
節の形式	Section と番号の見出しを付ける
集計	全条件の成否と、満たした条件の割合を平均

問題の依頼は五つの節を指定する。採点実装では、 Section に番号を付けた見出しを五つ以上検出できるかを調べる。

[1] LiveBench (2026-10-25 参照), official repository.
https://github.com/LiveBench/LiveBench

2025 年の論文では、 o1-preview が 64.7 点

モデル	総合点
o1-preview-2024-09-12	64.7
Claude 3.5 Sonnet-20241022	58.5
Gemini exp-1114	56.0
Llama 3.1 405B Instruct	51.1

ICLR 2025 掲載の 1.0 評価。 6 分野・ 18 課題、得点は 0 〜 100 。単一ターン、原則 temperature=0 。

[1] White et al. (2025), LiveBench.
https://arxiv.org/abs/2406.19314

同じ名前でも、公開時期で課題が変わる

- 2025 年 4 月には、コード課題を競技プログラミング中心から実用ライブラリの利用へ更新し、表の列分類を終了した。 5 月には、実際のリポジトリを修正するエージェント型コード課題を追加した。
- その後も新しい推理やデータ分析を追加した。問題の公開日と除外日、評価に使うバージョンをそろえることで、対象となる問題集合を選べる。

[1] LiveBench (2026-10-25 参照), Changelog.
https://github.com/LiveBench/LiveBench/blob/main/changelog.md

4. 長い実務課題への展開と入手方法

2.0 は、実行して成果物を作る能力へ広がった

- 2026 年 10 月 14 日公開の 2.0 は七つの評価区分を持つ。推理とデータ分析は短い問いへの回答、残る五区分はツールを使って進める課題である。
- アプリを変更後の要件に合わせて運用する、バグを直す、ブラウザーで仕事を終える、根拠付きの報告書を書く、文書やスライドを仕上げるといった成果を評価する。

[1] LiveBench (2026-10-25 参照), Methodology.
https://livebench.ai/#/methodology

2.0 は、 119 の実行課題と 352 問からなる

評価区分	件数	入力・成果の例
エージェント操作	18	変化する要件の下でアプリを運用
コード修正	29	バグ報告とリポジトリから修正
ブラウザー操作	25	Web アプリ内の作業を完了
調査	22	出典付きの報告書を提出
デザイン	25	文書・ PDF ・スライドを作成

別に、推理 202 問とデータ分析 150 問を含む。 2026-10-14 公開分、 2026-10-25 参照。

[1] LiveBench (2026-10-25 参照), Methodology.
https://livebench.ai/#/methodology

2.0 の総合点は、評価区分を等しく平均する

- 各区分をモデルごとに 1 回実行し、課題の成績を 0 〜 100 の得点にする。推理とデータ分析は、下位の課題群の平均を等しい重みでまとめる。
- 総合点は、値のある評価区分の平均である。原則としてモデルが対応する最も高い推論設定を使い、例外の設定は公開表の詳細に示す。

[1] LiveBench (2026-10-25 参照), Methodology.
https://livebench.ai/#/methodology

2.0 では、 Fable 5.1 の総合点が 88.0

モデル	総合	操作	推理
Claude Fable 5.1	88.0	80.8	91.7
Claude Opus 5.5	86.5	85.0	92.2
GPT-6 Astra	86.1	82.4	92.7
Gemini 4 Argon	84.1	69.9	95.1

2026-10-14 公開分、サイト更新表示 2026-10-23 、 2026-10-25 参照。各区分 1 回の評価。操作はエージェント操作の区分。

[1] LiveBench (2026-10-25 参照), LiveBench 2.0.
https://livebench.ai/

公開データで、入力と参照値を確認できる

- 1.0 系列の問題は、分野別の公式配布から取得できる。設問、参照値、課題名、公開日・除外日などが入り、課題に応じて公開テストや形式条件も付く。
- 配布物のライセンスは Apache License 2.0 。実装や出題元の帰属情報も確認する。公開コードには、一部の数式問題でモデルを補助判定に呼ぶ処理もある。

[1] LiveBench (2026-10-25 参照), Dataset Documentation. https://github.com/LiveBench/LiveBench/blob/main/docs/DATASHEET.md
[2] LiveBench (2026-10-25 参照), official repository. https://github.com/LiveBench/LiveBench

問題の原文と参照値を取り出す

```
from datasets import load_dataset

data = load_dataset("livebench/reasoning", split="test")
example = data[0]
print(example["turns"][0])
print(example["ground_truth"])
```

公開問題を読む最小例。評価対象は、使う公開バージョンに合わせて選ぶ。

[1] LiveBench (2026-10-25 参照), official repository.
https://github.com/LiveBench/LiveBench

更新される課題と、正解の確かめ方を押さえる

- LiveBench は、入力・答えが明確な多分野の問題を更新し、学習への混入や採点の偏りを抑えるために作られた。形式条件や部分点も含めて、何を測るかを課題ごとに定める。
- 2.0 では、短い質問に答える力と、ツールを使い成果物を完成させる力を同じ評価系列で扱うようになった。公開バージョンの課題構成と採点単位が、成績を読む前提になる。

[1] White et al. (2025), LiveBench. https://arxiv.org/abs/2406.19314
[2] LiveBench (2026-10-25 参照), Methodology. https://livebench.ai/#/methodology

Appendix

1. 公開問題の追加例
2. 更新の変遷と参考文献

1. 公開問題の追加例

例 4 数字 N を N 回並べる：問題文の原文

問題文・入力・出力・制約・公開例の原文（全文）

You are given an integer N between 1 and 9, inclusive, as input.
Concatenate N copies of the digit N and print the resulting string.
Input: The input is given from Standard Input in the following format: N
Output: Print the answer.
Constraints: N is an integer between 1 and 9, inclusive.
Sample Input 1: 3　Sample Output 1: 333
Concatenate three copies of the digit 3 to yield the string 333.
Sample Input 2: 9　Sample Output 2: 999999999

[1] LiveBench (2024), coding — public questions.
https://huggingface.co/datasets/livebench/coding

例 4 数字 N を N 回並べる：出力指示の原文

モデルに添える共通の生成・出力形式の指示（全文）

````
### Instructions: You are an expert Python programmer. You will be given a question (problem specification) and will generate a correct Python program that matches the specification and passes all tests. You will NOT return anything except for the program.
### Format: Read the inputs from stdin solve the problem and write the answer to stdout (do not directly test on the sample inputs). Enclose your code within delimiters as follows.
```python
# YOUR CODE HERE
```


### Answer: (use the provided format with backticks)
````

[1] LiveBench (2024), coding — public questions.
https://huggingface.co/datasets/livebench/coding

例 4 数字 N を N 回並べる：日本語訳

問題の日本語訳

あなたは Python に詳しいプログラマーである。問題の仕様を読み、すべてのテストに通る正しい Python プログラムを作る。プログラム以外は返さない。
1 以上 9 以下の整数 N が入力される。数字 N を N 個つなげた文字列を出力する。
入力は標準入力から、 N の形式で与えられる。答えを出力する。
制約： N は 1 以上 9 以下の整数。
公開例 1 ：入力 3 、出力 333 。数字 3 を三つつなげると 333 になる。
公開例 2 ：入力 9 、出力 999999999 。
標準入力から値を読み、問題を解き、標準出力へ答えを書く。サンプル入力だけを直接試すプログラムにはしない。コードは次の形式の区切りで囲む。

```python
# YOUR CODE HERE
```

回答には、指定されたバッククォートの形式を使う。

[1] LiveBench (2024), coding — public questions.
https://huggingface.co/datasets/livebench/coding

例 4 数字 N を N 回並べる：答えの読み方

公開例の出力： 3 → 333 ／ 9 → 999999999

文字列として数字 N を N 回繰り返す。公開例では 3 を三つ並べた 333 、 9 を九つ並べた 999999999 が期待される。

[1] LiveBench (2024), coding — public questions.
https://huggingface.co/datasets/livebench/coding

例 5 二数の幾何平均を求める：原文

問題の原文（全文）

> Compute the geometric mean of {1, 9}. Please put your final answer in a $\\boxed{}$.

{1, 9} の幾何平均を求める。最終回答を \boxed{} で囲む。

正解： 3

正の二数の幾何平均は積の平方根なので、$\sqrt{}(1\times9)=3$ となる。

[1] LiveBench (2024), math — public questions.
https://huggingface.co/datasets/livebench/math

例 6 数式の値と回答形式を確かめる：原文

問題の原文（全文）

What is the value of √(2023/(2+0+2+3))? (A) 13 (B) 15 (C) 17 (D) 19 (E) 21 If you cannot determine the correct multiple-choice answer, take your best guess. Once you have your answer, please duplicate that letter five times in a single string. For example, if the answer is F, then write FFFFF.

[1] LiveBench (2024), math — public questions.
https://huggingface.co/datasets/livebench/math

例 6 数式の値と回答形式を確かめる：日本語訳

問題の日本語訳

√(2023 / (2+0+2+3)) の値はいくつか。
(A) 13　(B) 15　(C) 17　(D) 19　(E) 21
正しい選択肢を決められない場合は、最もよいと思う答えを選ぶ。答えが決まったら、その文字を五つ並べて一つの文字列にする。例えば、答えが F なら FFFFF と書く。

正解： C （出力は CCCCC ）

分母は 2+0+2+3=7 、 2023÷7=289 、√ 289=17 である。正解の記号は C だが、要求される出力は C を五つ並べた CCCCC となる。

[1] LiveBench (2024), math — public questions.
https://huggingface.co/datasets/livebench/math

例 7 正方形を対角線で切る：原文

問題の原文（全文）

> Suppose I have a physical, solid square with vertices ABCD, and I make two cuts through AC and BD. How many pieces are there after the cuts? Think step by step, and then put your answer in **bold** as a single integer (for example, **0**). If you don't know, guess.

頂点を ABCD とする正方形の板がある。対角線 AC と BD に沿って二回切ると、何個の断片になるか。順を追って考え、答えを一つの整数として太字で示す（例： **0** ）。分からない場合は推測する。

正解： 4

二本の対角線が中心で交わり、四つの三角形ができる。

[1] LiveBench (2024), reasoning — public questions.
https://huggingface.co/datasets/livebench/reasoning

例 8 発言の真偽をたどる：原文

問題の原文（全文）

In this question, assume each person either always tells the truth or always lies. Ayaan is at the gym. Beatriz is at the museum. The person at the farm saw a firetruck. Mateo is at the barbershop. The person at the gym tells the truth. The person at the barbershop lies. The person at the restaurant thinks their neighbor is telling the truth. Kehinde is at the farm. The person at the museum says the person at the ice skating rink tells the truth. The person at the farm thinks their neighbor is telling the truth. The person at the museum says the person at the restaurant tells the truth. The person at the farm says the person at the gym tells the truth. Jaxon is at the ice skating rink. The person at the restaurant says the person at the farm tells the truth. Hiroshi is at the restaurant. Does the person at the museum tell the truth? Does the person at the restaurant tell the truth? Does the person at the farm tell the truth? Think step by step, and then put your answer in **bold** as a list of three words, yes or no (for example, **yes, no, yes**). If you don't know, guess.

[1] LiveBench (2024), reasoning — public questions.
https://huggingface.co/datasets/livebench/reasoning

例 8 発言の真偽をたどる：日本語訳

問題の日本語訳

各人は、常に真実を話すか、常にうそをつくかのどちらかだとする。 Ayaan はジムにいる。 Beatriz は博物館にいる。農場にいる人は消防車を見た。 Mateo は理髪店にいる。ジムにいる人は真実を話す。理髪店にいる人はうそをつく。レストランにいる人は、隣人が真実を話していると思っている。 Kehinde は農場にいる。博物館にいる人は、スケートリンクにいる人は真実を話すと言う。農場にいる人は、隣人が真実を話していると思っている。博物館にいる人は、レストランにいる人は真実を話すと言う。農場にいる人は、ジムにいる人は真実を話すと言う。 Jaxon はスケートリンクにいる。レストランにいる人は、農場にいる人は真実を話すと言う。 Hiroshi はレストランにいる。
博物館にいる人は真実を話すか。レストランにいる人は真実を話すか。農場にいる人は真実を話すか。順を追って考え、 yes または no を三つ並べ、太字で答える（例： **yes, no, yes** ）。分からない場合は推測する。

[1] LiveBench (2024), reasoning — public questions.
https://huggingface.co/datasets/livebench/reasoning

例 8 発言の真偽をたどる：答えの読み方

正解： yes, yes, yes

農場の人は、真実を話すジムの人について正しい発言をしているため、真実を話す人だと分かる。同じように、農場の人について話すレストランの人、レストランの人について話す博物館の人も、真実を話す人だと分かる。

[1] LiveBench (2024), reasoning — public questions.
https://huggingface.co/datasets/livebench/reasoning

例 9 八つの語を二組に分ける：原文

問題の原文（全文）

You are given 8 words/phrases below. Find two groups of four items that share something in common. Here are a few examples of groups: bass, flounder, salmon, trout (all four are fish); ant, drill, island, opal (all four are two-word phrases that start with 'fire'); are, why, bee, queue (all four are homophones of letters); sea, sister, sin, wonder (all four are members of a septet). Categories will be more specific than e.g., '5-letter-words', 'names', or 'verbs'. There is exactly one solution. Think step-by-step, and then give your answer in **bold** as a list of the 8 items separated by commas, ordered by group (for example, **bass, founder, salmon, trout, ant, drill, island, opal**). If you don't know the answer, make your best guess. The items are: push, sack, hair, raid, loot, bobby, safety, rob.

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 9 八つの語を二組に分ける：日本語訳

問題の日本語訳

次の八つの語句を、共通点を持つ四語ずつの二組に分ける。例として、bass ・ flounder ・ salmon ・ trout は魚、 ant ・ drill ・ island ・ opal は前に fire を付けると二語の表現になる。 are ・ why ・ bee ・ queue はアルファベットの文字名と同じ発音で、 sea ・ sister ・ sin ・ wonder は、七つの海・七姉妹・七つの大罪・七不思議のように、七つで一組になるものを指す。「5 文字の語」「名前」「動詞」といった分類より具体的な共通点を探す。解は一つだけである。
順を追って考え、八つの語を組ごとに並べ、カンマで区切って太字で答える。指定された例は **bass, founder, salmon, trout, ant, drill, island, opal** 。分からない場合は最もよいと思う答えを選ぶ。
対象の語： push, sack, hair, raid, loot, bobby, safety, rob 。

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 9 八つの語を二組に分ける：答えの読み方

正解： loot, raid, rob, sack,
bobby, hair, push, safety

loot ・ raid ・ rob ・ sack は略奪に関係する動詞。 bobby ・ hair ・ push ・ safety は後ろに pin を付けると、 bobby pin ・ hairpin ・ pushpin ・ safety pin になる。語の意味だけでなく、別の語を補った共通点も扱う。

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 10 誤字だけを訂正する：原文

問題の原文（全文）

Please output this exact text, with no changes at all except for fixing the misspellings. Please leave all other stylistic decisions like commas and US vs British spellings as in the original text.
In this artice, we establish nessecary anbd sufficient condidtions for a polynomial of degree n to have exactly n real roots. A complete study of polynomials of degree five is carried out. The results are compared with ethose obtained useing Sturm sequences.

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 10 誤字だけを訂正する：日本語訳

依頼の日本語訳と本文の意味

誤ったつづりだけを直し、それ以外は一切変えずに、次の文章をそのまま出力する。カンマや米国式・英国式のつづりなど、ほかの文体上の選択は原文どおりにする。
文章の意味：次数 n の多項式がちょうど n 個の実根を持つための必要十分条件を示す。 5 次多項式を詳しく調べ、その結果を Sturm 列による結果と比較する。

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 10 誤字だけを訂正する：答えの読み方

正解： In this article, we establish necessary and sufficient conditions for a polynomial of degree n to have exactly n real roots. A complete study of polynomials of degree five is carried out. The results are compared with those obtained using Sturm sequences.

直すのは artice→article 、 nessecary→necessary 、 anbd→and 、 condidtions→conditions 、 ethose→those 、 useing→using の六か所。内容を書き換える校正ではなく、つづりの誤りだけを直す。

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 11 少量とお買い得を表す語を探す：原文

問題の原文（全文）

You are given 8 words/phrases below. Find two groups of four items that share something in common. Here are a few examples of groups: bass, flounder, salmon, trout (all four are fish); ant, drill, island, opal (all four are two-word phrases that start with 'fire'); are, why, bee, queue (all four are homophones of letters); sea, sister, sin, wonder (all four are members of a septet). Categories will be more specific than e.g., '5-letter-words', 'names', or 'verbs'. There is exactly one solution. Think step-by-step, and then give your answer in **bold** as a list of the 8 items separated by commas, ordered by group (for example, **bass, founder, salmon, trout, ant, drill, island, opal**). If you don't know the answer, make your best guess. The items are: value, touch, bit, steal, deal, pinch, dash, buy.

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 11 少量とお買い得を表す語を探す：日本語訳

問題の日本語訳

次の八つの語句を、共通点を持つ四語ずつの二組に分ける。例として、bass ・ flounder ・ salmon ・ trout は魚、 ant ・ drill ・ island ・ opal は前に fire を付けると二語の表現になる。 are ・ why ・ bee ・ queue はアルファベットの文字名と同じ発音で、 sea ・ sister ・ sin ・ wonder は、七つの海・七姉妹・七つの大罪・七不思議のように、七つで一組になるものを指す。「５文字の語」「名前」「動詞」といった分類より具体的な共通点を探す。解は一つだけである。
順を追って考え、八つの語を組ごとに並べ、カンマで区切って太字で答える。指定された例は **bass, founder, salmon, trout, ant, drill, island, opal** 。分からない場合は最もよいと思う答えを選ぶ。
対象の語： value, touch, bit, steal, deal, pinch, dash, buy 。

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 11 少量とお買い得を表す語を探す：答えの読み方

正解： bit, dash, pinch, touch, buy, deal, steal, value

bit ・ dash ・ pinch ・ touch はいずれも少量を表す。 buy ・ deal ・ steal ・ value は、お買い得な商品や有利な取引を表す文脈で使われる。 steal には「盗む」だけでなく「格安品」という意味もある。

[1] LiveBench (2024), language — public questions.
https://huggingface.co/datasets/livebench/language

例 12 TSV 表を CSV 表へ変換する：原文

Input Table: （全 14 行、左から右へ続く。タブは空白で表示）

Please convert the Input Table from TSV format to CSV format. Please respond only with the table.

```
species  quantity
LAKE TROUT  2931
KOKANEE  716220
GRAYLING ARCTIC  84211
SUNFISH BLUEGILL  47840
WIPER  386460
SUCKER JUNE  80510
TIGER TROUT  401119
RAINBOW  3904196
BROOK TROUT  232058
CUTTHROAT  1506513
CHUB  34740
ALL TROUT  1650
BROWN TROUT  245553
GOLDEN TROUT  4581
Output:
```

[1] LiveBench (2024), data_analysis — public questions.
https://huggingface.co/datasets/livebench/data_analysis

例 12 TSV 表を CSV 表へ変換する：日本語訳

依頼の日本語訳（表の値は原文と共通）

入力表を TSV 形式から CSV 形式へ変換する。表だけを返す。
入力表の列名は species と quantity 。 TSV はタブ、 CSV はカンマで列を区切る。種名と数値は原文の全 14 行を保つ。

[1] LiveBench (2024), data_analysis — public questions.
https://huggingface.co/datasets/livebench/data_analysis

例 12 TSV 表を CSV 表へ変換する：答えの読み方

参照出力（全 14 行）

```
species,quantity
LAKE TROUT,2931
KOKANEE,716220
GRAYLING ARCTIC,84211
SUNFISH BLUEGILL,47840
WIPER,386460
SUCKER JUNE,80510
TIGER TROUT,401119
RAINBOW,3904196
BROOK TROUT,232058
CUTTHROAT,1506513
CHUB,34740
ALL TROUT,1650
BROWN TROUT,245553
GOLDEN TROUT,4581
```

[1] LiveBench (2024), data_analysis — public questions.
https://huggingface.co/datasets/livebench/data_analysis

例 13 列の内容から列名を選ぶ：原文

問題の原文（全文）

> Pick the column's class based on the provided column sample. Choose exactly one of the listed classes. Please respond only with the name of the class.
> Column sample: [['ham'], ['spam'], ['ham'], ['ham'], ['spam']]
> Classes: ['email' 'label']
> Output:

列の値の例に基づいて、候補から分類を一つ選び、分類名だけを返す。列の値と候補は原文と共通。

正解： label

ham は通常メール、 spam は迷惑メールを表す分類ラベル。

[1] LiveBench (2024), data_analysis — public questions.
https://huggingface.co/datasets/livebench/data_analysis

2. 更新の変遷と参考文献

更新によって、課題そのものも変わる

時期	主な変更
2024 年 6–8 月	初期公開、空間推理の追加、数学の更新
2025 年 4–5 月	実用コードへ刷新、エージェント型修正を追加
2025 年 11 月–2026 年 1 月	心の理論、移動を伴う論理、連続増加を追加
2026 年 10 月	2.0 で長い実行課題と成果物の評価へ展開

[1] LiveBench (2026-10-25 参照), Changelog. https://github.com/LiveBench/LiveBench/blob/main/changelog.md
[2] LiveBench (2026-10-25 参照), Methodology. https://livebench.ai/#/methodology

参考文献

LiveBench: A Challenging, Contamination-Limited LLM Benchmark

Colin White et al. (2025), ICLR 2025.

新しい問題の継続的な投入と、正解照合に基づく多分野の評価を提案する。

https://proceedings.iclr.cc/paper_files/paper/2025/file/e4a46394ba5378b3f9a186a5b4c650d1-Paper-Conference.pdf

LiveBench 2.0 — Methodology

LiveBench / Abacus.AI (n.d.; 2026-10-25 参照).

七つの評価区分、各区分の採点と総合点の計算方法を示す。

https://livebench.ai/#/methodology

参考文献

LiveBench: Code and Changelog

LiveBench (n.d.; 2026-10-25 参照), GitHub.

課題ごとの採点実装と、問題・実行環境の更新の履歴を公開する。

https://github.com/LiveBench/LiveBench

Datasheet for LiveBench

LiveBench (n.d.; 2026-10-25 参照), GitHub.

データの構築・配布・保守と Apache License 2.0 での利用条件を記載する。

https://github.com/LiveBench/LiveBench/blob/main/docs/DATASHEET.md