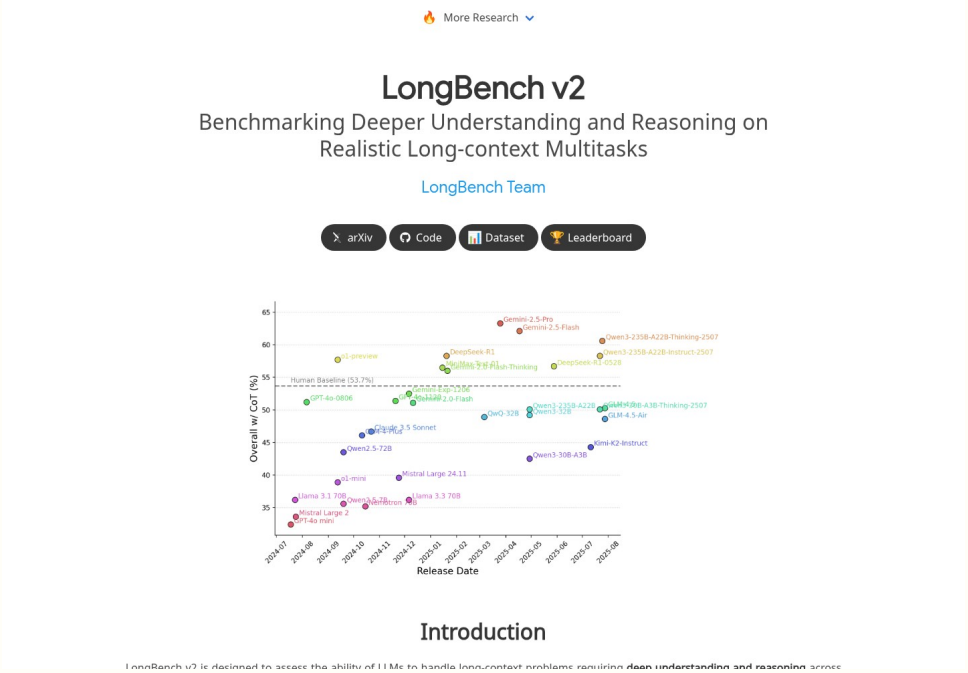
LongBench v2

長い本文の理解と推論を四択問題で評価する

sasakiy84

1. 長い本文を使う課題と実例
2. 構築方法とデータの構成
3. 採点方法とモデルの成績
4. 長文理解の評価での利用と入手

LongBench v2 の公式サイト



[1] LongBench Team (2026-10-26 参照), LongBench v2. https://longbench2.github.io/

1. 長い本文を使う課題と実例

長い入力から、根拠を結び付けて答える

- LongBench v2 は、長い文書や会話、コードなどを読み、四つの選択肢から答える評価データセット。 2024 年 12 月に公開された。
- 503 問はすべて英語。本文は論文で約 8 千〜 200 万語と報告され、複数箇所の関係や、本文で学んだ規則の適用を問う。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

入力は長い本文と設問、出力は一つの記号

- モデルには本文、設問、四つの選択肢を与える。参照正解は A ～ D の一文字で、説明文の似かよい方ではなく、選んだ記号で採点する。
- 以下は公開 503 問から選んだ実例。設問と選択肢は全文を載せ、長い入力本文は答えの根拠が読める範囲を抜粋する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 1 コードから保存先を決める：設問の原文

設問と四つの選択肢（全文）

In this cloud storage system, the scheduler is a crucial component responsible for allocating file blocks to the appropriate slave servers. There are three Raspberry Pi devices acting as slave servers, named pi1, pi2, and pi3, with remaining storage capacities of 800 bytes, 700 bytes, and 500 bytes, respectively. A file has been divided into 9 blocks, each of 100 bytes, and two copies (including the original) need to be stored. Based on the scheduler’s allocation strategy, analyze how the two copies are distributed across the three Raspberry Pi devices:
A: Copy 1: pi3(500), pi2(400). Copy 2: pi2(300), pi1(600)
B: Copy 1: pi1(400), pi2(400), pi3(100). Copy 2: pi3(400), pi2(300), pi1(200)
C: Copy 1: pi1(400), pi2(200), pi3(300). Copy 2: pi1(400), pi1(500)
D: Copy 1: pi1(800), pi2(100). Copy 2: pi2(600), pi3(300)

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 1 コードから保存先を決める：本文の抜粋

空き容量順にブロックを割り当てる原文コード（抜粋）

```
n_empty_chunks.sort(key = lambda x: x[1], reverse = True)
exclude_pi_names.add(n_empty_chunks[0][0])
[...]
for pi_name, n_empty_chunk in n_empty_chunks:
    if cnt_allocated + n_empty_chunk >= n_chunks:
        pi_list.append((pi_name, n_chunks - cnt_allocated))
        cnt_allocated = n_chunks
        break
    else:
        pi_list.append((pi_name, n_empty_chunk))
        cnt_allocated += n_empty_chunk
```

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 1 コードから保存先を決める：本文の抜粋

候補を選び直す原文コード（抜粋・改行整形）

```
capacities = self.slave_states.get_capacities(
    exclude_pi_names = allocated
)
[...]
if total_empty_chunks < n_chunks:
    capacities = self.slave_states.get_capacities(
        exclude_pi_names = exclude_pi_names
    )
```

コードの読み方

コードでは、候補を空き容量順に並べ、必要なブロック数まで順番に割り当てる。各コピーで使った保存先と、先頭に選んだ保存先を別々に記録する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 1 コードから保存先を決める：設問の日本語訳

設問と選択肢の日本語訳

クラウドストレージのスケジューラは、ファイルのブロックを保存先のサーバーへ割り当てる。 pi1 、 pi2 、 pi3 の空き容量は、それぞれ 800 、 700 、 500 バイト。 100 バイトのブロック 9 個を、原本を含めて二組保存するとき、実装に従う配置はどれか。
A ：一組目は pi3 に 500 、 pi2 に 400 。二組目は pi2 に 300 、 pi1 に 600 。
B ：一組目は pi1 に 400 、 pi2 に 400 、 pi3 に 100 。二組目は pi3 に 400 、 pi2 に 300 、 pi1 に 200 。
C ：一組目は pi1 に 400 、 pi2 に 200 、 pi3 に 300 。二組目は pi1 に 400 と 500 。
D ：一組目は pi1 に 800 、 pi2 に 100 。二組目は pi2 に 600 、 pi3 に 300 。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 1 コードから保存先を決める：答えの理由

正解： D ：一組目は pi1 に 800 、 pi2 に 100 。二組目は pi2 に 600 、 pi3 に 300 。

一組目は pi1 に 8 個、 pi2 に 1 個。残る pi3 だけでは二組目の 9 個を置けない。 pi1 を除いて候補を選び直すと、空きが 6 個の pi2 と 5 個の pi3 を使えるため、二組目は pi2 に 6 個、 pi3 に 3 個となる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 2 気象表で三つの条件を確かめる：原文と日本語訳

設問と四つの選択肢（全文）

If we define “wet-cold” as “humidity>95 as well as temperature<-5”, which of the following time is wet-cold without sun?
A: 2017-01-22T04:10:00Z
B: 2017-01-06T02:10:00Z
C: 2017-01-22T00:10:00Z
D: 2017-02-09T15:10:00Z

設問の日本語訳

「湿って寒い」を、湿度が 95 より高く、気温が−5 より低い状態と定義する。この条件を満たし、日照がない時刻はどれか。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 2 気象表で三つの条件を確かめる：判定に使う 4 列

time	sun	temperature	humidity
2017-01-06T02:10:00Z	2	-7.3	96
2017-01-22T00:10:00Z	2	-5.3	96
2017-01-22T04:10:00Z	0	-7.8	96
2017-02-09T15:10:00Z	0	1.1	80

四つの候補の行から、判定に使う 4 列を示した。 sun は日照、 temperature は気温、 humidity は湿度を表す。元の CSV には、ほかの列と多数の時刻の行も含まれる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 2 気象表で三つの条件を確かめる：答えの理由

正解： A ： 2017-01-22T04:10:00Z

A は sun=0 、 temperature=−7.8 、 humidity=96 で、三つの条件をすべて満たす。 B と C は sun=2 。 D は気温も湿度も条件を満たさない。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 3 天秤の説明書と操作を照合する：設問の原文

設問と四つの選択肢（全文）

Which of the following is incorrect according to the instruction book?
A: When I use my right hand to handle the draft sheild and the other hand to load the balance, I push the right coupling element upward.
B: When I determine the additional unit to display the result, I can refer to the table of conversion factors in Appendix.
C: In dynamic weighing mode, I can press the "F" key to display time interval.
D: Key "C" can be used to clear the display information when there's something wrong in calibration.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 3 天秤の説明書と操作を照合する：本文の抜粋

天秤の説明書の原文（風防の操作に関する段落の抜粋）

> Example: If you operate the draft shield with your left hand and wish to load the balance with your right (this corresponds to the normal mode of operation for right-handers), push the right coupling element upward and the left downward. You can now open and close the right draft shield door with the bottom part of the left door handle.

本文の日本語要約

例えば、左手で風防を動かして右手で試料を載せる場合は、右の連結部品を上へ、左を下へ押す。すると、左のドアの取っ手の下部で、右の風防ドアを開閉できる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 3 天秤の説明書と操作を照合する：設問の日本語訳

設問と選択肢の日本語訳

説明書の内容と一致しないものはどれか。
A ：右手で風防を操作し、もう一方の手で試料を載せるとき、右側の連結部品を上へ押す。
B ：結果を表示する追加の単位を決めるときは、付録の換算係数表を参照できる。
C ：動的計量モードでは、 F キーで時間間隔を表示できる。
D ：校正中に問題が起きたときは、 C キーで表示を消せる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 3 天秤の説明書と操作を照合する：答えの理由

正解： A ：右手で操作する場合の、連結部品の向きが逆。

説明書では、左手で風防を動かして右手で試料を載せる場合に、右の部品を上へ、左を下へ押す。 A は操作する手を右手に変えながら同じ部品を上げており、左右の対応が逆になる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

2. 構築方法とデータの構成

97 人が素材と設問を用意し、別担当が検証する

- 大学で学ぶ人や卒業者 97 人が、自分で読んだり使ったりした文書を持ち寄った。 24 人が専門分野に応じて確認を担当した。
- 本文、設問、選択肢、答えとその根拠を作る。英語の本文が 8,192 語未満、または既存の素材と大きく重なる場合は採用しない。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

自動確認と人の確認で難しさをそろえる

段階	確認する内容
三つのモデルで確認	三つとも正解する問題を見直す
人が本文を調べる	3 分以内に解ける問題や、正解に問題があるものを修正
難問の分類	正解したモデルが 1 つ以下で、 人の解答時間が 10 分を超える

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

六つの領域に 503 問を収録する

課題	設問数
単一文書の読解	175
複数文書の読解	125
長い文脈からの学習	81
コードリポジトリの理解	50
長い会話履歴の理解	39
長い構造化データの理解	33

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

文書の長さだけでなく、使い方にも幅がある

- 単一文書には論文、金融報告、法的文書、小説などがある。複数文書では、資料をまたいで説明や数値を比較する。
- 説明書からの規則の適用、未知の言語の翻訳、多数の例からの分類も含む。会話、コード、表、知識グラフでは、形式に応じた情報の対応付けが必要になる。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

本文の長さと難しさを別々に分けて集計する

分類	範囲・意味
Short	3 万 2 千語未満
Medium	3 万 2 千〜 12 万 8 千語
Long	12 万 8 千語超〜約 200 万語
Easy / Hard	作成時のモデルと人の確認による難しさ

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

本文の中央値は約 5 万 4 千語

- 503 問の本文は、論文の集計で中央値が約 5 万 4 千語、平均が約 10 万 4 千語。長い文書を一つ読めるだけでなく、複数の資料の関係を保つ力も試す。
- 本文の長さには領域差もある。単一文書の中央値は約 5 万 1 千語、複数文書は約 3 万 4 千語で、コードの課題は約 16 万 7 千語だった。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

3. 採点方法とモデルの成績

選んだ記号の一致を、正解率にまとめる

- 各問では、抽出した A 〜 D の記号が参照正解と同じなら 1 点、異なる場合や記号を読み取れない場合は 0 点とする。全問の平均を百分率で示す。
- 公式コードは「 The correct answer is (A) 」などの回答形式から記号を取り出す。全体のほか、難しさ別、本文の長さ別の正解率も出す。

[1] LongBench Team (2026-10-26 参照), LongBench. https://github.com/THUDM/LongBench

公開時は、推論を行う o1-preview が 57.7%

モデル（2024 年）	直接回答（%）	推論あり（%）
GPT-4o （08-06）	50.1	51.2
Claude 3.5 Sonnet （10-22）	41.0	46.7
Qwen2.5-72B-Instruct	39.4	38.8
o1-preview （09-12）	57.7	56.2

「直接回答」は追加の推論指示なし。 o1-preview は、その設定でも内部で推論する。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

人の 53.7% は、 1 問 15 分の条件で得た値

- 確認者は本文内の検索を使いながら回答し、 15 分を超える場合は「分からない」としてよい条件だった。正解率は 53.7% で、全問の 8% では回答を保留した。
- 確認者は専攻に合わせて担当し、客観的な答えか、本文が必要か、設問が適切かも点検した。単なる文字列の検索で答えられる問題は修正の対象にした。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

公式サイトには、後続モデルの成績もある

公式掲載モデル	公開日	推論あり（%）
Gemini 2.5 Pro	2025-03-25	63.3
Gemini 2.5 Flash	2025-04-17	62.1
Qwen3-235B-A22B-Thinking-2507	2025-07-25	60.6
DeepSeek-R1	2025-01-20	58.3

2026-10-26 参照。公式掲載の後続評価。初期実験の表とは別の公表値。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://longbench2.github.io/

2026 年の Qwen3.5 の評価にも採用された

- Qwen3.5-397B-A17B の公式モデルカードは、長文理解の評価に LongBench v2 を使い、 63.2 を報告している。
- 同じ表では長文推論や情報検索なども評価している。LongBench v2 は、長い文章に含まれる情報を結び付けて考える課題として使われ続けている。

[1] Qwen Team (2026), Qwen3.5-397B-A17B. https://huggingface.co/Qwen/Qwen3.5-397B-A17B

読み切れない本文と、推論の予算が得点を変える

- 公式の評価コードは、入力がモデルの上限を超えると、先頭と末尾を残して中央を削る。必要な根拠が中央にある場合には、モデルがその情報を読めなくなる。
- 推論ありの設定では、先に考えた内容を作り、その内容を含めて最終回答を求める。検索で選んだ本文だけを読む設定もあり、読む範囲と推論の設定が結果に関わる。

[1] LongBench Team (2026-10-26 参照), LongBench. https://github.com/THUDM/LongBench

4. 長文理解の評価での利用と入手

LongBench から、推論を要する四択問題へ

- 2023 年公開の LongBench は、中国語と英語の読解、要約、検索などをまとめた。課題ごとに F1 や ROUGE などの指標を使う。
- v2 では全問を英語の四択に統一し、人が根拠と難しさを確認した。単純に答えの文字列を探すだけでは解きにくい課題へ重点を移した。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204
[2] Bai et al. (2024), LongBench. ACL 2024. https://aclanthology.org/2024.acl-long.172/

公開データの train は、評価問題の保存名

- 公式配布は Hugging Face の THUDM/LongBench-v2 。train という分割名で 503 問すべてを読み込む。用途はモデルの評価で、独立した学習用の正解データを意味しない。
- 各行には課題名、難しさ、長さの区分、本文、設問、四つの選択肢と正解がある。公開 JSON は約 465 MB 。データカードは Apache License 2.0 を表示する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

一つの公開問題の設問と選択肢を確認する

```
from datasets import load_dataset

x = load_dataset(
    'THUDM/LongBench-v2', split='train'
)[0]
print(x['context'][:200])
print(x['question'])
for key in 'ABCD':
    print(key, x['choice_' + key])
```

context の先頭 200 文字と、設問・四つの選択肢を表示する。

[1] LongBench Team (2026-10-26 参照), LongBench. https://github.com/THUDM/LongBench

長い入力の理解を、根拠のある選択で確かめる

- LongBench v2 は、六つの課題領域に 503 問を持つ、英語の長文理解ベンチマーク。人が読んだ資料と根拠を使い、理解・適用・比較を問う四択問題を作った。
- 正解率とともに、本文の長さ、読む範囲、推論の設定を確認する。文書を受け付けられる長さだけでなく、その内容を使って答えを選ぶ力を調べられる。

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

Appendix

1. 異なる課題の追加例
2. 課題の内訳とバージョン
3. 参考文献

1. 異なる課題の追加例

例 4 電池モデルの容量を合わせる：設問の原文

設問と四つの選択肢（全文）

According to this tutorial, for a cell being calibrated, if the current autolion battery capacity display does not match the experimental value, how to quickly and significantly adjust?
A: Change electrochemical materials in the GT library
B: Change the cathode and anode coating areas
C: Define different Cathode Loading cases
D: Change 7 properties related to battery balance

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 4 電池モデルの容量を合わせる：本文の抜粋（ 1/2 ）

AutoLion 教材の原文（容量を合わせる手順の抜粋）

20. Based upon these results, it is clear that the capacity of the AutoLion cell is much higher than the capacity of the physical (“Experimental”) cell. The overall shape of the two curves seem very similar, but the AutoLion curve appears more “stretched” in the Time axis. Because of this, we should go back to the AutoLion model and vary the Cathode’s “Capacity Loading” attribute until the capacity of the cell more aligns with the experimental data.
[...]

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 4 電池モデルの容量を合わせる：本文の抜粋（ 2/2 ）

AutoLion 教材の原文（容量を合わせる手順の抜粋）

22.In Case Setup: a) Click the “Append Cases” button 9 times or use the “Append Multiple Cases” option to append 9 new cases b) Sweep the “CathodeLoading” attribute from 3.0 to 3.9 in increments of 0.1 across the 10 cases.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 4 電池モデルの容量を合わせる：設問の日本語訳

設問と選択肢の日本語訳

校正中のセルについて、 AutoLion に表示される容量が実験値と一致しないとき、短時間で大きく調整する方法はどれか。
A ： GT ライブラリの電極材料を変える。
B ：正極と負極の塗工面積を変える。
C ： Cathode Loading を変えた複数のケースを設定する。
D ：セルのバランスに関係する七つの特性を変える。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 4 電池モデルの容量を合わせる：答えの理由

正解： C ： Cathode Loading を変えたケースを設定する。

計算上の容量が実験値を上回るため、正極の活物質の量に関わる Cathode Loading を変えて比較する。教材では 10 ケースを用意し、 3.0 から 3.9 まで 0.1 ずつ変える。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 5 注意機構を計算するクラスを探す：設問の原文

設問と四つの選択肢（全文）

If I want to modify BLIP's VQA architecture and load parameters from the caption architecture, but only change the middleware, specifically the internal computation logic of the attention mechanism within the middleware, which class should I modify?
A: BertLayer / B: BertAttention
C: BertSelfAttention / D: BertIntermediate

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 5 注意機構を計算するクラスを探す：本文の抜粋

BertSelfAttention の原文コード（抜粋・改行整形）

```
class BertSelfAttention(nn.Module):
[...]
self.query = nn.Linear(
    config.hidden_size, self.all_head_size
)
[...]
self.key = nn.Linear(
    config.hidden_size, self.all_head_size
)
self.value = nn.Linear(
    config.hidden_size, self.all_head_size
)
```

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 5 注意機構を計算するクラスを探す：本文の抜粋

外側のクラスの原文コード（離れた範囲の抜粋）

```
class BertAttention(nn.Module):
[...]
self.self = BertSelfAttention(
    config, is_cross_attention
)
[...]
class BertLayer(nn.Module):
[...]
self.attention = BertAttention(config)
```

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 5 注意機構を計算するクラスを探す：設問の日本語訳

設問と選択肢の日本語訳

画像と言語を扱う BLIP の、画像質問応答の構成を変更し、画像説明用の構成からパラメータを読み込みたい。中間部分の注意機構の計算だけを変えるには、どのクラスを修正するか。
A ： BertLayer / B ： BertAttention
C ： BertSelfAttention / D ： BertIntermediate

正解： C ： BertSelfAttention

外側の二つのクラスは、注意機構の計算部分を組み込む役割を持つ。内部の計算だけを変える場合は、その本体である BertSelfAttention を修正する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 6 TCP の終了処理を追う：設問の原文（ 1/2 ）

設問と四つの選択肢（ 1/2 ）

Regarding the statements about the TCP connection termination in this codebase, which is correct?
A: When one party is ready to terminate the TCP connection, it first enters the FIN_WAIT_1 state, indicating that it has sent a termination request FIN signal to the other party and is waiting for confirmation.
B: After receiving the FIN signal, the other party needs to return an ACK signal and meanwhile send a FIN signal, waiting for confirmation. Both parties send FIN signals and receive confirmation before the connection is terminated.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 6 TCP の終了処理を追う：設問の原文（ 2/2 ）

設問と四つの選択肢（ 2/2 ）

C: The purpose of tcp->shutdown_waiting is to ensure that all unsent packets in the sending buffer are sent before the connection is terminated, but it cannot guarantee that all packets have been successfully received by the other party.
D: Before terminating the connection, using the Nagle algorithm when sending packets can combine scattered small packets for transmission to reduce network congestion.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 6 TCP の終了処理を追う：本文の抜粋

接続終了関数の原文（分岐の抜粋）

```
else if(tcp->shutdown_waiting){
  send_pkt_directly(tcp);
  if(tcp->send.size == 0){
    // 发送FIN 包
    send_fin_pkt(tcp);
    tcp->snd_nxt += 1;
    tcp->set_state(TCPState::FIN_WAIT_1);
  }
[...]
tcp->shutdown_waiting = true;
```

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 6 TCP の終了処理を追う：設問の日本語訳（ 1/2 ）

設問と選択肢の日本語訳

このコードの TCP 接続終了について、正しい説明はどれか。
A ：一方が TCP 接続を終了しようとすると、まず FIN_WAIT_1 状態に入る。この状態は、相手へ終了要求の FIN 信号を送り、その確認を待っていることを示す。
B ： FIN を受け取った側は ACK 信号を返すと同時に FIN 信号も送り、その確認を待つ。両者が FIN 信号を送り、確認を受け取ってから接続が終了する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 6 TCP の終了処理を追う：設問の日本語訳（ 2/2 ）

設問と選択肢の日本語訳

C ： shutdown_waiting は、送信バッファー内の未送信パケットをすべて送り終えてから接続を終了するためのものだが、すべてのパケットが相手へ届いたことは保証できない。
D ：接続を終了する前に、パケット送信時に Nagle アルゴリズムを使うと、分散した小さいパケットをまとめて送信し、ネットワークの混雑を減らせる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 6 TCP の終了処理を追う：答えの理由

正解： C ：未送信データがなくなるまで待つためのフラグ。

shutdown_waiting が真の場合、パケットを送る処理を呼び出す。送信バッファーの size が 0 になると FIN を送り、状態を FIN_WAIT_1 へ進める。一方、バッファーにデータが残る場合は shutdown_waiting を真にする。

判定するのは送信バッファーの残量で、相手からの確認がすべて済んだかどうかではない。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 7 二つの判例に共通する点を探す：設問の原文

設問と四つの選択肢（全文）

What do these two cases have in common?
A: The truthfulness of the parties' intent in entering into the contract is of paramount importance.
B: The defaulting party's reasons for refusing to honor the agreement are all that the other party's offer was too low.
C: The basic terms of the main agreement are defined.
D: The court upheld all of the plaintiff's claims.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 7 二つの判例に共通する点を探す：本文の抜粋

判例の原文（二つの文書からの抜粋）

The instrument sought to be enforced was written by A. H. Zehmer on December 20, 1952, in these words: “We hereby agree to sell to W. O. Lucy the Ferguson Farm complete for $50,000.00, title satisfactory to buyer,” and signed by the defendants, A. H. Zehmer and Ida S. Zehmer.
[...]
... There was sufficient evidence for the jury to conclude that the parties had reached agreement on all essential terms of the transaction with only the mechanics and details left to be supplied by the parties’ attorneys.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 7 二つの判例に共通する点を探す：設問の日本語訳

設問と選択肢の日本語訳

二つの判例に共通する点は何か。
A ：契約を結ぶ当事者の内心の意思が、何よりも重要である。
B ：契約に従わない理由は、どちらも相手の提示額が低すぎたことだ。
C ：主たる合意の基本的な条件が定まっている。
D ：裁判所は原告の請求をすべて認めた。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 7 二つの判例に共通する点を探す：答えの理由

正解： C ：主たる合意の基本条件が定まっている。

一つ目の判例では、農場全体を 5 万ドルで売り、買い手が納得する権原を条件とする合意書に、売り手夫婦が署名していた。二つ目の判例では、取引の主要条件にすべて合意しており、弁護士が詰めるのは手続や詳細だけだったと、陪審が判断するに足る証拠があった。

両判例は、契約に必要な主要条件の合意を認めている。内心の意思だけを最重要とする A とは異なる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 8 政策文書の内容と選択肢を照合する：設問の原文（ 1/2 ）

設問と四つの選択肢（ 1/2 ）

Which of the following options is not part of the U.S. national COVID-19 preparedness plan ？
A: With insufficient tools to fight COVID-19, the United States mobilized all of society to insist on surviving the outbreak with the least disruption to the United States.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 8 政策文書の内容と選択肢を照合する：設問の原文（ 2/2 ）

設問と四つの選択肢（ 2/2 ）

B: Minimize the impact of new variants on the United States by collecting and analyzing data on previous variants of COVID-19 and strengthening regulation and review of specific variants.
C: Take specific measures for businesses and schools to help businesses and schools continue to operate through COVID-19 to reduce the cost and impact of the pandemic on the U.S. economy.
D: Expand global access to COVID-19 medicines, facilitate the formation of pharmaceutical research alliances, and increase global funding.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 8 政策文書の内容と選択肢を照合する：本文の抜粋（ 1/2 ）

政策文書の原文（計画と対抗手段に関する抜粋）

As the country emerges from the Omicron wave, our path forward relies on maintaining and continually enhancing the numerous tools we now have to protect ourselves and our loved ones – from vaccines, to tests, to treatments, to masks, and more. In January 2021, Americans had very few tools to protect against COVID-19, and the tools we did have were in limited supply. Over the last year, together, with states, localities, and public and private partners, the Administration has mobilized an unprecedented, whole-of-society effort to give Americans the tools they need to protect themselves.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 8 政策文書の内容と選択肢を照合する：本文の抜粋（ 2/2 ）

政策文書の原文（計画と対抗手段に関する抜粋）

> [...]
> This plan lays out the roadmap to help us fight COVID-19 in the future as we begin to get back to our more normal routines.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 8 政策文書の内容と選択肢を照合する：設問の日本語訳

設問と選択肢の日本語訳

米国の国家 COVID-19 対策計画に含まれていない説明はどれか。
A ：対抗手段が不十分な中、社会全体を動員して、混乱を最小限に抑えながら流行を乗り切る。
B ：過去の変異株のデータを収集・分析し、特定の変異株に関する規制と審査を強化することで、新しい変異株が米国に与える影響を最小限にする。
C ：企業や学校が活動を続けられるよう対策し、経済への費用と影響を減らす。
D ： COVID-19 の医薬品を世界で入手しやすくし、医薬品研究の連携体制の形成を促して、世界的な資金供給を増やす。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 8 政策文書の内容と選択肢を照合する：答えの理由

正解： A ：対抗手段が不十分だとする説明。

オミクロン株の流行が落ち着く中、今後の方針はワクチン、検査、治療、マスクなど、すでにある多数の手段を維持し、強化することにある。 2021 年 1 月には手段も供給も限られていたが、その後の社会全体の取組で必要な手段を広げた。計画は、日常へ戻りながら COVID-19 と闘うための道筋を示す。

A の「対抗手段が不十分な中」という部分は、 2021 年 1 月の状況を計画の現状へ当てはめている。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 9 論文の数値から改善幅を求める：原文と日本語訳

設問と四つの選択肢（全文）

How much has Meta-Rewarding training improved on AlpacaEval 2?
A: 39.4% / B: 22.9% / C: 16.5% / D: 18.7%

設問と選択肢の日本語訳

Meta-Rewarding によって、 AlpacaEval 2 の得点はどれだけ改善したか。
A ： 39.4% / B ： 22.9% / C ： 16.5% / D ： 18.7%

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 9 論文の数値から改善幅を求める：本文の抜粋

Meta-Rewarding 論文の原文（実験結果の段落の抜粋）

In our experiments we start from Llama-3-8B-Instruct and perform multiple iterations of our Meta- Rewarding training. When evaluated on AlpacaEval 2 (Dubois et al., 2024b), we see a substantial improvement in the length-controlled (LC) win rate (from 22.9% to 39.4%), even outperforming GPT-4-03141. We also observe that our method outperforms standard Self-Rewarding training even if it is enhanced with our length-bias improvements (35.5% vs 39.4%), highlighting the importance of the meta-judge.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 9 論文の数値から改善幅を求める：答えの理由

正解： C ： 16.5 ポイントの改善。

実験では Llama-3-8B-Instruct から始め、 Meta-Rewarding を複数回繰り返した。 AlpacaEval 2 で、回答の長さを調整した勝率は 22.9% から 39.4% へ上がった。長さの偏りを調整した通常の Self-Rewarding の 35.5% も上回り、判断そのものを評価する工程の効果を示している。

39.4−22.9=16.5 なので、改善幅は 16.5 ポイント。選択肢では C に対応する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：設問の原文（ 1/3 ）

設問と四つの選択肢（ 1/3 ）

During freezing, pure water, ethanol-water mixtures, and nanofluids exhibit different solidification behaviors.Read the given articles and answer: why a sharp tip forms in pure water and ethanol-water mixtures but not in nanofluids? A: In the freezing of pure water and ethanol-water mixtures, heat conduction dominates the solidification process, leading to tip formation. In nanofluids, however, the presence of nanoparticles enhances fluid stability at the liquid-solid interface, suppressing local heat diffusion and flattening the solidification front, resulting in a plateau.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：設問の原文（ 2/3 ）

設問と四つの選択肢（ 2/3 ）

B: Nanoparticles accumulate along the freezing front during nanofluid solidification, generating capillary-driven compensating flows that counteract the formation of a tip, whereas the solute concentration gradient in ethanol-water mixtures induces an upward Marangoni flow, leading to self-lifting behavior, distinct from the sharp tip seen in pure water.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：設問の原文（ 3/3 ）

設問と四つの選択肢（ 3/3 ）

C: In nanofluids, the scattering of heat by nanoparticles lowers the temperature gradient within the droplet, reducing surface tension effects and inhibiting tip formation. In pure water, the higher surface tension maintains the sharp tip structure, while the addition of ethanol creates an asymmetric cooling pattern and localized heat release, encouraging tip formation.
D: In nanofluids, nanoparticles cause a non-uniform freezing front that suppresses deformation at the solid-liquid interface, preventing tip formation. By contrast, the freezing front in pure water and ethanol-water mixtures progresses uniformly, with heat diffusion driving tip formation.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：本文の抜粋

純水と混合液の論文の原文（抜粋）

A drop of water deposited on a cold plate freezes into an ice drop with a pointy tip. While this phenomenon clearly finds its origin in the expansion of water upon freezing, a quantitative description of the tip singularity has remained elusive.
[...]
This counterintuitive observation is attributed to an internal solutal Marangoni flow up to 1 mm=s, which is driven by the enriched solute concentration locally in the vicinity of the solidification front.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：本文の抜粋

ナノ流体の論文の原文（抜粋）

> We propose an analytical model to attribute the plateau formation to a capillary driven compensating flow due to segregated particles moving along the freezing interface.

本文の日本語要約

冷たい板の上の水滴は、尖った先端を持つ氷になる。凍結時に水が膨張することが、この現象の起源である。混合液の特異な動きは、凍結面の近くで溶質の濃度が高くなり、内部に溶質マランゴニ流が生じることで説明される。ナノ流体の平らな上面は、凍結面に沿って動く偏在した粒子による、毛管力で駆動される補償流としてモデル化される。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：設問の日本語訳（ 1/3 ）

設問と選択肢の日本語訳

純水、エタノールと水の混合液、ナノ粒子を含む液体では凍結の仕方が異なる。純水と混合液には尖った先端ができ、ナノ粒子を含む液体にはできないのはなぜか。
A ：純水とエタノール・水の混合液の凍結では熱伝導が支配的になり、先端が形成される。一方、ナノ流体では、ナノ粒子が液体と固体の界面で流体の安定性を高め、局所的な熱拡散を抑える。これによって凍結面が平らになり、平坦な上面ができる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：設問の日本語訳（ 2/3 ）

設問と選択肢の日本語訳

B ：ナノ流体の固化では、ナノ粒子が凍結面に沿って集まり、毛管力による補償流が生じて、先端の形成を打ち消す。一方、エタノールと水の混合液では、溶質の濃度勾配が上向きのマランゴニ流を生み、液滴が自ら持ち上がる。これは純水に見られる尖った先端とは異なる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：設問の日本語訳（3/3）

設問と選択肢の日本語訳

C ：ナノ流体では、ナノ粒子が熱を散乱させることで液滴内部の温度勾配が小さくなり、表面張力の効果が弱まり、先端が形成されにくくなる。純水では高い表面張力が尖った先端を維持する。一方、エタノールを加えると冷却が非対称になって局所的な放熱が生じ、先端の形成を促す。
D ：ナノ流体では、ナノ粒子が不均一な凍結面を作り、固体と液体の界面の変形を抑えるため、先端が形成されなくなる。対照的に、純水とエタノール・水の混合液では凍結面が均一に進み、熱拡散が先端の形成を駆動する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 10 三種類の液滴の凍結を比較する：答えの理由

正解： B ：粒子の集積による流れと、混合液の上向きの流れを説明する。

設問の導入は、混合液も純水と同じように尖った先端ができるとまとめている。 B は、混合液が持ち上がる機構と純水の先端形成の違いまで示している。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 11 過去の会話から購入前の価格を求める：原文と日本語訳

設問と四つの選択肢（全文）

What was the original price of the Up & Up brand cleaning supplies the user bought?
A: $12 / B: $120 / C: $60 / D: $80

設問と選択肢の日本語訳

ユーザーが買った Up & Up ブランドの掃除用品は、割引前にいくらだったか。
A ： 12 ドル / B ： 120 ドル / C ： 60 ドル / D ： 80 ドル

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 11 過去の会話から購入前の価格を求める：本文の抜粋

会話履歴の原文（関係するユーザー発言の全文）

I'm planning to clean my house this weekend and I need to restock on some cleaning supplies. Can you tell me if there are any good deals on all-purpose cleaners or disinfecting wipes at Target this week? By the way, I saved $12 last week using a Cartwheel offer for 20% off on all Up & Up brand cleaning supplies at Target!

ユーザー発言の日本語訳

今週末に家を掃除するので、掃除用品を補充したい。今週、 Target で万能クリーナーや除菌シートのよい特売があるか知りたい。ちなみに先週は、 Up & Up ブランドの全掃除用品が 20% 引きになる Cartwheel の特典を使って 12 ドル節約した。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 11 過去の会話から購入前の価格を求める：答えの理由

正解： C ： 60 ドル

20% 引きによって 12 ドル安くなったので、割引前の価格は 12÷0.20=60 ドル。支払額ではなく、値引き前の価格を求める。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 12 知識グラフで二つの属性を照合する：原文と日本語訳

設問と四つの選択肢（全文）

Which town has a TOID of 4000000074573917 and has an OS grid reference of SP8778?
A: Q984613 / B: Q208143 / C: Q58900 / D: Q279000

設問と選択肢の日本語訳

TOID が 4000000074573917 で、 OS グリッド参照が SP8778 である町はどれか。
A ： Q984613 / B ： Q208143 / C ： Q58900 / D ： Q279000

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 12 知識グラフで二つの属性を照合する：属性の対応

町の ID	TOID	位置の表記
Q984613	4000000074573917	SP8778
Q208143	4000000074548561	SD583055
Q58900	4000000074574343	SE5702
Q279000	4000000074551570	NZ365665

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 12 知識グラフで二つの属性を照合する：答えの理由

正解： A ： Q984613 （ Kettering ）

表では、選択肢に現れる四つの町について、 TOID と OS グリッド参照の属性を取り出している。どちらも同じ町のレコードに含まれる属性である。

地物の識別子 TOID と、英国の位置表記である OS グリッド参照を、同じ町の属性として照合する。 Q984613 の属性が両方に一致する。配布本文では町名 Kettering も確認できる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 13 3D の箱の符号化を読み取る：設問の原文（ 1/2 ）

設問と四つの選択肢（ 1/2 ）

How does the MagicDrive encode the bounding box in training step?
A: MagicDrive encode the class labels of bounding box by the method similar to Li et al, where the pooled embeddings of the class names are considered as the label embeddings. And then uses an MLP to compress both the class and text embeddings into a single hidden vector for each bounding box.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 13 3D の箱の符号化を読み取る：設問の原文（ 2/2 ）

設問と四つの選択肢（ 2/2 ）

B: MagicDrive uses Fourier embedding for 4 corner point and passes them through an MLP for encoding in training step. MagicDrive then uses an MLP to compress both the class label and position embeddings into a single hidden vector for each bounding box.
C: MagicDrive using the text encoder to encode the class label of bounding box, and then uses an MLP to compress both the class and text embeddings into a single hidden vector for each bounding box.
D: MagicDrive encode the class labels and the corner points separately, and then uses an MLP to compress them into a vector.

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 13 3D の箱の符号化を読み取る：本文の抜粋

MagicDrive 論文の原文（ 3D ボックスの符号化に関する抜粋）

> For box positions bi ∈R8×3, represented by the coordinates of its 8 corner points, we utilize Fourier embedding to each point and pass through an MLP for encoding, as in Equation 4. Then, we use an MLP to compress both class and position embedding into one hidden vector, as in Equation 5.

本文の日本語要約

ボックスの位置は、八つの頂点の座標で表す。それぞれの頂点へ Fourier 埋め込みを使い、 MLP で符号化する。その後、クラスと位置の埋め込みを、 MLP で一つの隠れベクトルへまとめる。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 13 3D の箱の符号化を読み取る：設問の日本語訳（ 1/2 ）

設問と選択肢の日本語訳

運転場面の画像を生成する MagicDrive は学習時に物体の境界ボックスをどのように符号化するか。
A ：境界ボックスのクラスラベルは Li らと同様の方法で符号化し、クラス名を埋め込んでプーリングした表現を、ラベルの埋め込みとする。その後、クラスとテキストの埋め込みの両方を、 MLP でボックスごとに一つの隠れベクトルへ圧縮する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 13 3D の箱の符号化を読み取る：設問の日本語訳（ 2/2 ）

設問と選択肢の日本語訳

B ： MagicDrive は、四つの頂点に Fourier 埋め込みを使い、学習時に MLP を通して符号化する。その後、 MLP でクラスラベルと位置の埋め込みの両方を、各ボックスにつき一つの隠れベクトルへ圧縮する。
C ： MagicDrive は、テキストエンコーダーで境界ボックスのクラスラベルを符号化し、その後、 MLP でクラスとテキストの埋め込みの両方を、各ボックスにつき一つの隠れベクトルへ圧縮する。
D ： MagicDrive はクラスラベルと頂点を別々に符号化し、その後、 MLP を使ってそれらを一つのベクトルへ圧縮する。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

例 13 3D の箱の符号化を読み取る：答えの理由

正解： D ：クラスと頂点を別々に符号化して統合する。

ラベルの情報と、八つの頂点で表す位置の情報を別々に符号化してから統合する。 B は頂点数を四つとしており、 A と C は位置の情報をテキストの情報に置き換えている。

[1] LongBench Team (2026-10-26 参照), LongBench v2. https://huggingface.co/datasets/THUDM/LongBench-v2

2. 課題の内訳とバージョン

単一文書と複数文書の課題の内訳

単一文書（175 問）	問	複数文書（125 問）	問
学術	44	学術	50
文学・探偵・出来事の順序	72	法律	14
法律	19	金融	15
金融	22	政府の文書	23
政府の文書	18	複数ニュース	23

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

学習・会話・コード・構造化データの内訳

課題	内訳
長い文脈からの学習： 81 問	説明書 40 、未知言語の翻訳 20 、多数の例からの学習 21
会話履歴の理解： 39 問	エージェントの履歴 20 、対話の履歴 19
コードの理解： 50 問	リポジトリの読解 50
構造化データの理解： 33 問	表 18 、知識グラフ 15

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

初代と v2 では、言語と答えの形式が変わる

対象	中心となる特徴
LongBench （2023）	中国語・英語、 21 課題、課題ごとの生成・抽出と採点
LongBench v2（2024）	英語、 6 領域 20 課題、 503 問の四択と正解率

[1] Bai et al. (2024), LongBench v2. https://arxiv.org/abs/2412.15204

3. 参考文献

参考文献

LongBench v2: Towards Deeper Understanding and Reasoning on Realistic Long-context Multitasks

Yushi Bai et al. (2024), arXiv:2412.15204.

503 問の構築、六領域の課題、人による確認とモデルの初期評価を報告する。

https://arxiv.org/abs/2412.15204

LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding

Yushi Bai et al. (2024), ACL 2024, pp.3119–3137.

初代の中国語・英語の長文課題と、課題別の採点方法を示す。

https://aclanthology.org/2024.acl-long.172/

参考文献

LongBench v2

LongBench Team (n.d.; 2026-10-26 参照), project website.

評価の概要と、モデルごとの正解率、長さ別・難しさ別の結果を掲載する。

https://longbench2.github.io/

LongBench

LongBench Team (n.d.; 2026-10-26 参照), GitHub. MIT License.

v2 の入力形式、回答記号の抽出、推論・検索の評価用コードを公開する。

https://github.com/THUDM/LongBench

参考文献

LongBench-v2

LongBench Team (n.d.; 2026-10-26 参照), Hugging Face.

503 問の本文・設問・選択肢・参照正解を JSON 形式で配布する。

https://huggingface.co/datasets/THUDM/LongBench-v2

Qwen3.5-397B-A17B

Qwen Team (2026), Hugging Face model card.

長文理解を含む 2026 年のモデル評価に、 LongBench v2 を採用する。

https://huggingface.co/Qwen/Qwen3.5-397B-A17B