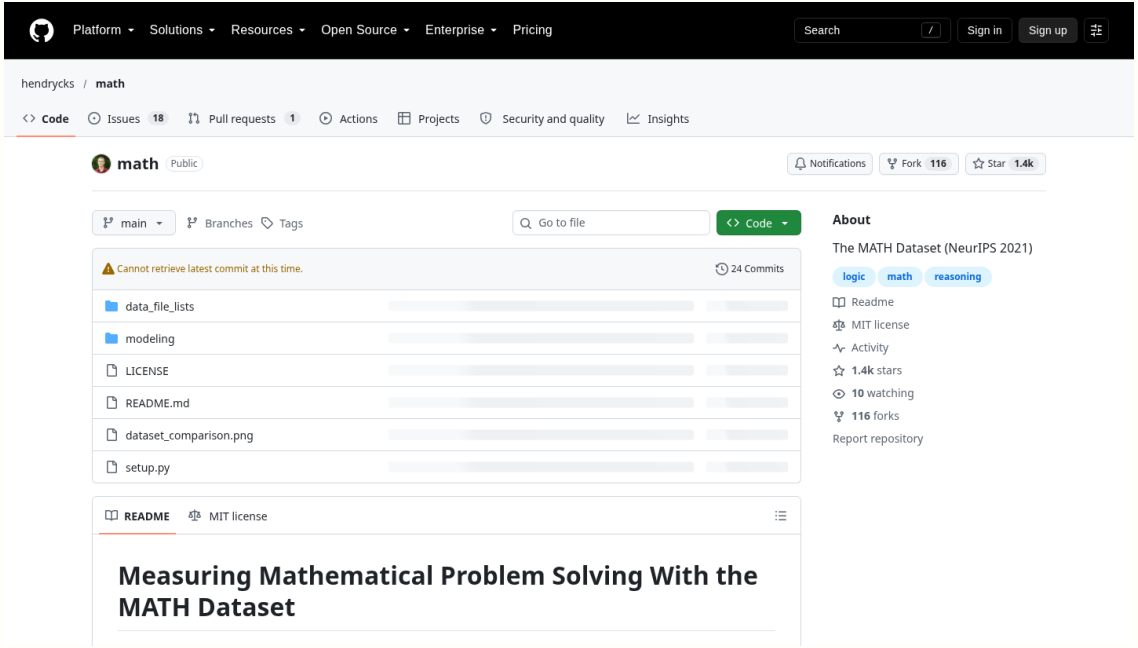
MATH

Mathematics Aptitude Test of Heuristics

競技数学の解法と最終解答を扱う

sasakiy84

公式リポジトリ



[1] Dan Hendrycks et al. MATH. 公式リポジトリ。 2026-10-18 参照。 https://github.com/hendrycks/math

1. 競技数学の問題と解答
2. 採点と HELM の比較条件
3. 収集とデータの全体像
4. 利用の変化と入手方法

競技数学の問題と解答

問題、途中の解説、最終解答がそろう

- MATH は、競技数学の 12,500 問に、途中の解説と最終解答を付けたデータセット。
- AMC や AIME など、米国の数学競技から問題を集めた。入力は英語の問題文で、数式や図の記述も含む。
- 最終解答は LaTeX の boxed に入る。解答だけを出す条件と、解説を含めて出す条件の両方で使われる。

[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks. https://arxiv.org/abs/2103.03874

実例 1 ：差の積を計算する

Algebra / Level 1 / 問題の原文（全文）

Evaluate $(x + y)(x - y)$ when $x = 15$ and $y = 5$.

日本語訳

$x = 15$ 、 $y = 5$ のとき、 $(x + y)(x - y)$ の値を求めよ。

解答： 200

$(15 + 5)(15 - 5) = 20 \times 10 = 200$ 。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 algebra / test row 372
https://huggingface.co/datasets/EleutherAI/hendrycks_math

同じ問題でも、モデルの出力は異なる

- 式に値を代入すれば、 (15 + 5)(15 − 5) = 20 × 10 で 200 になる。
- HELM の公開実行では、 text-davinci-003 が解答だけの条件で 100 、解説を出す条件で 200 と答えた。
- 二つの条件では提示する例も変わる。具体的な入力条件と採点は次の章で扱う。

[1] HELM Classic v0.4.0. MATH 、 Level 1 の固定評価。 2023-11-17 公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/math_regular

実例２：二重根号を外す

Intermediate Algebra / Level 3 / 問題の原文（全文）

Simplify the expression $\sqrt{(41 + 24\sqrt{2})}$.

日本語訳

式 $\sqrt{(41 + 24\sqrt{2})}$ を簡単にせよ。

解答： $3 + 4\sqrt{2}$

$(3 + 4\sqrt{2})^2 = 9 + 32 + 24\sqrt{2}$ 。 $3 + 4\sqrt{2}$ は正なので、平方根はこの値になる。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 intermediate_algebra / test row 457
https://huggingface.co/datasets/EleutherAI/hendrycks_math

形を見抜いて、確かめる

- 平方根を $a + b\sqrt{2}$ と置き、両辺を二乗すると、 $a^2 + 2b^2 = 41$ 、 $2ab = 24$ が必要になる。
- $a = 3$ 、 $b = 4$ なら両方を満たす。正の平方根を求めているので、 $3 + 4\sqrt{2}$ を選ぶ。

[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks.
https://arxiv.org/abs/2103.03874

実例３：偶数の組を数える

Counting & Probability / Level 5 / 問題の原文（全文）

How many triples (a, b, c) of even positive integers satisfy $a^3 + b^2 + c \leq 50$?

日本語訳

$a^3 + b^2 + c \leq 50$ を満たす、正の偶数の 3 つ組 (a, b, c) はいくつあるか。

解答： 35

a は 2 だけ。 b = 2 、 4 、 6 のとき、 c の候補は順に 19 個、 13 個、 3 個なので、合計 35 個。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 counting_and_probability / test row 445
https://huggingface.co/datasets/EleutherAI/hendrycks_math

条件から、候補を絞って数える

a	b	c の範囲	個数
2	2	2, 4, …, 38	19
2	4	2, 4, …, 26	13
2	6	2, 4, 6	3

a が 4 以上なら a^3 だけで 50 を超える。正の偶数という条件から、 a は 2 に限られる。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 https://huggingface.co/datasets/EleutherAI/hendrycks_math

採点と HELM の比較条件

最終解答を正規化して照合する

- 生成した最終解答を、参照解答と照合する。空白や LaTeX の一部を整え、分数や平方根などの表記をそろえる。
- 各問を正解 1 ・不正解 0 で採点し、評価集合の正解率を求める。
- chain-of-thought 条件でも、採点するのは最後の boxed から取り出した解答。途中の推論を個別には採点しない。

[1] Stanford CRFM. MATHScenario v0.3.0. 参照解答の抽出と表記正規化。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/math_scenario.py

HELM の解答抽出は条件で変わる

条件	提示する参照	生成から採点する部分
regular	公式の 8 問と最終解答	生成した解答文字列
chain-of-thought	同じ分野・ Level 1 の学習問題と解説	最後の boxed の中身

正規化した文字列の一致。一般の代数式を記号計算で同値判定する採点ではない。

[1] Stanford CRFM. MATHScenario v0.3.0. 参照解答の抽出と表記正規化。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/math_scenario.py

同じ問題の、実際に生成された二つの出力

text-davinci-003 / trial 0 / x = 15, y = 5 の問題

regular: 100

採点： 0 （参照解答は 200 ）

chain-of-thought: Plugging in the given values for x and y, we get (15 + 5)(15 − 5) = \boxed{200}.

訳： x と y に与えられた値を代入すると、 (15 + 5)(15 − 5) = 200 。

採点： 1 （最後の boxed から 200 を抽出）

[1] HELM Classic v0.4.0. MATH 、 Level 1 の固定評価。 2023-11-17 公開版。 regular id8 / CoT id178 。本文は全文、数式は組版。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/math_regular

正しい最終解答と、正しい推論を分ける

- 公開実行の regular は 100 を出したため不正解。 chain-of-thought は最後の boxed から 200 を抽出できるため正解。
- この採点は、途中の各等式や説明が正しいかを証明するものではない。
- 解説付きの学習データは、最終解答だけでは見えない解法や誤りを調べる材料にもなる。

[1] Stanford CRFM. MATHScenario v0.3.0. 参照解答の抽出と表記正規化。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/math_scenario.py

2021 年：全 5,000 問では低い正解率

方式	正解率
GPT-2 1.5B （2019）：AMPS 事前学習後に微調整	6.9%
GPT-3 175B （2020）：8 例提示	5.2%

MATH test 全 5,000 問、全 7 分野・全難度。 AMPS は別の数学事前学習データで、 MATH とは区別される。

[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks.
https://arxiv.org/abs/2103.03874

HELM は Level 1 の 437 問を評価する

- HELM Classic の二つの条件は、 7 分野の Level 1 に絞った 437 問を評価する。
- 全 test の 5,000 問のうち 8.74% 。 Level 2 〜 5 の 4,563 問は、この二つの公開グループの評価には入らない。
- 以下は各分野の実行値から、評価問題数で重み付けして再集計した正解率。各分野の値は 3 試行平均。

[1] HELM Classic v0.4.0. MATH 、 Level 1 の固定評価。 2023-11-17 公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/math_regular

解説付き条件の正解率はモデルで異なる

モデル（公開年）	regular	解説付き
OPT-175B （2022）	6.25%	1.91%
text-davinci-003 （2022）	38.29%	47.52%
Anthropic v4-s3 （2022）	17.62%	16.09%

437 問の件数重み付き再集計、各 3 試行。異なる提示例と出力条件を含む比較。 2023 年の固定版。

[1] HELM Classic v0.4.0. MATH 、 Level 1 の固定評価。 2023-11-17 公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/math_regular

提示例と生成条件も同時に変わる

設定	regular	解説付き
提示例数の上限	8	8
最大出力トークン	20	400
停止文字列	$	###
候補数 / temperature	1 / 0	1 / 0

二つの条件では、提示例の内容、出力上限、停止文字列も異なる。

[1] Stanford CRFM. HELM v0.3.0 run_specs.py, get_math_spec. 生成・適応条件。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/run_specs.py

収集とデータの全体像

数学競技の問題と、公開された解説を集める

- AMC 10 、 AMC 12 、 AIME などの競技問題と、 Art of Problem Solving のコミュニティにある解説が主な素材。
- 7,500 問を学習、 5,000 問を test に分け、各問に分野・難度・途中の解説・最終解答を対応させた。
- 問題と解説は LaTeX で数式を表し、必要な図は Asymptote という作図言語で記述する。

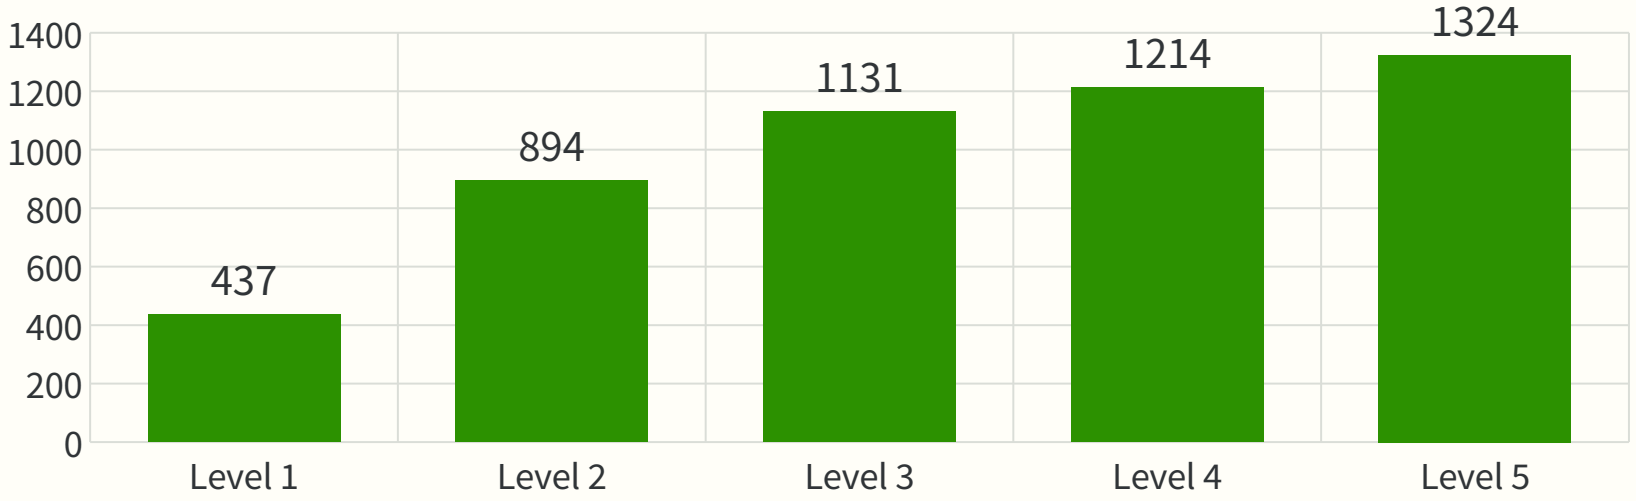
[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks. https://arxiv.org/abs/2103.03874

7 分野を、学習と test に分けて収録

分野	学習	test
代数	1,744	1,187
場合の数・確率	771	474
幾何	870	479
中級代数	1,295	903
整数論	869	540
初等代数	1,205	871
解析の基礎	746	546

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 https://huggingface.co/datasets/EleutherAI/hendrycks_math

test には難度 1 から 5 までを含む



test 全 5,000 問の件数。 HELM の公開評価は Level 1 の 437 問。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 https://huggingface.co/datasets/EleutherAI/hendrycks_math

難度は、同じ分野の中で付けられる

- 難度は各分野の中で 1 〜 5 を付ける。 1 が易しく、 5 が難しい。
- AoPS の難度を使い、 AMC 8 の序盤の問題は Level 1 、 AIME の問題は Level 5 に当たることが多い。
- 分野と難度は別の注釈。例えば複素数の絶対値や三角関数も、 Level 1 に含まれる。

[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks. https://arxiv.org/abs/2103.03874

利用の変化と入手方法

数学の学習と、汎用モデルの評価に使われる

- 2021 年は、解説付きデータでの学習と、別途 AMPS での数学事前学習を組み合わせて評価した。
- HELM では、学習例をプロンプトに入れる方法で複数の汎用言語モデルを比較した。
- 2026-10-18 時点で公式リポジトリ、固定した公開配布、HELM の実装を取得できる。

[1] Dan Hendrycks et al. MATH. 公式リポジトリ。 2026-10-18 参照。 https://github.com/hendrycks/math

分野、分割、バージョンを固定して読む

```
from datasets import load_dataset
data = load_dataset(
    'EleutherAI/hendrycks_math', 'algebra',
    revision='21a5633873b6a120296cce3e2df9d5550074f4a3',
    split='test',
)
print(data[372]['problem'])
print(data[372]['solution'])
```

problem 、 solution 、 level 、 type を持つ。元の LaTeX も含めて保存される。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 https://huggingface.co/datasets/EleutherAI/hendrycks_math

公式リンクと、分割を保つ配布を照合した

- 公式 README が案内する配布では、 12,500 問を 1 つの集合として取得できた。
- 今回の実例には、学習・ test と 7 分野の分割を保つ EleutherAI の公開配布を使った。
- 両方の配布を全件取得し、問題・解説・分野・難度の 12,500 レコードが、重複数も含めて一致することを確認した。

[1] MATH. 公式 README のリンク先配布。 12,500 件を 1 集合で公開。 https://huggingface.co/datasets/qwedsacf/competition_math

元の競技問題の帰属を保って利用する

- 公式コードと公開データカードのライセンス表示は MIT 。元の競技問題や AoPS 上の解説の著者・出所も保持する。
- 今回取得した分割付き Parquet は合計約 4.9 MB 。公式リンク先の統合 Parquet は約 4.8 MB で、どちらも取得実測。
- 実例の問題全文・解説全文・最終解答・固定 revision ・レコード hash を検証記録に保存した。

[1] Dan Hendrycks et al. MATH. 公式リポジトリ。 2026-10-18 参照。 https://github.com/hendrycks/math

式を読み、解法を組み立て、最終解答を出す

- MATH は 12,500 問の競技数学データで、 7 分野・ 5 段階の難度と解説付きの解答を持つ。
- 最終解答の採点と、途中の推論の正しさは別に検討する。
- HELM の regular と解説付き条件は、 Level 1 の 437 問を、異なる提示例と出力条件で比べる。

[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks. https://arxiv.org/abs/2103.03874

Appendix

1. 分野と難度が異なる追加例
2. 実行条件と配布の補足
3. 研究と参考文献

分野と難度が異なる追加例

実例 4 ：負の数を割る

Prealgebra / Level 1 / 問題の原文（全文）

> Compute (−49) ÷ 7.

日本語訳

(−49) ÷ 7 を計算せよ。

解答：− 7

49 ÷ 7 = 7 で、負の数を正の数で割るので答えは− 7 。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 prealgebra / test row 134
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 5 ： 30 度の余弦

Geometry / Level 2 / 問題の原文（全文）

Compute cos 30°.

日本語訳

cos 30° を求めよ。

解答：√3 / 2

30° ・ 60° ・ 90° の直角三角形の辺の比から、 cos 30° = √3 / 2 。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 geometry / test row 235
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 6 ：階乗の約数を数える

Number Theory / Level 4 / 問題の原文（全文）

Find the number of positive divisors of 9!.

日本語訳

9! の正の約数の個数を求めよ。

解答： 160

$9! = 2^7 \times 3^4 \times 5 \times 7$ 。約数は各素因数の指数を選ぶので、 $8 \times 5 \times 2 \times 2 = 160$ 個。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 number_theory / test row 345
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 7 ：複素指数関数の値

Precalculus / Level 1 / 問題の原文（全文）

Compute $e^{\pi i}$.

日本語訳

$e^{\pi i}$ を計算せよ。

解答：− 1

オイラーの公式から、 $e^{\pi i} = \cos \pi + i \sin \pi = -1$ 。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 precalculus / test row 235
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 8 ：平方根の定義域

Algebra / Level 5 / 問題の原文（全文）

Find the domain of $\sqrt{(6 - x - x^2)}$.

日本語訳

$\sqrt{(6 - x - x^2)}$ の定義域を求めよ。

解答： [−3, 2]

根号の中が 0 以上という条件は、 $(x + 3)(x - 2) \leq 0$ 。したがって $-3 \leq x \leq 2$ 。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 algebra / test row 195
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 9 ： 7 の倍数を除く

Counting & Probability / Level 3 / 問題の原文（全文）

How many positive three-digit numbers are not multiples of 7?

日本語訳

正の 3 桁の整数のうち、 7 の倍数でないものはいくつあるか。

解答： 772

3 桁の整数は 900 個。 7 の倍数は 105 から 994 まで 128 個なので、 900 − 128 = 772 個。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 counting_and_probability / test row 156
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 10 ：平方因子を根号の外へ出す

Prealgebra / Level 4 / 問題の原文（全文）

Simplify $\sqrt{242}$.

日本語訳

$\sqrt{242}$ を簡単にせよ。

解答： $11\sqrt{2}$

$242 = 11^2 \times 2$ なので、$\sqrt{242} = 11\sqrt{2}$ 。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 prealgebra / test row 190
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 11 ： 30 度の正弦

Geometry / Level 1 / 問題の原文（全文）

Compute sin 30°.

日本語訳

sin 30° を求めよ。

解答： 1 / 2

30° ・ 60° ・ 90° の直角三角形では、 30° の対辺は斜辺の半分。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 geometry / test row 167
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 12 ：平方数の約数を数える

Number Theory / Level 5 / 問題の原文（全文）

How many factors of $2^5 \cdot 3^6$ are perfect squares?

日本語訳

$2^5 \cdot 3^6$ の約数のうち、平方数はいくつあるか。

解答： 12

平方数では、素因数の指数がすべて偶数になる。 2 の指数は 0 ・ 2 ・ 4 の 3 通り、 3 の指数は 0 ・ 2 ・ 4 ・ 6 の 4 通り。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 number_theory / test row 89
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実例 13 ：三角比の符号を選ぶ

Precalculus / Level 5 / 問題の原文（全文）

If sin x + cos x = 1/5 and 0 < x < π, find tan x.

日本語訳

sin x + cos x = 1/5 、 0 < x < π のとき、 tan x を求めよ。

解答：− 4 / 3

0 < x < π より sin x > 0 。条件から sin x = 4/5 、 cos x = −3/5 となり、 tan x = −4/3 。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 precalculus / test row 541
https://huggingface.co/datasets/EleutherAI/hendrycks_math

実行条件と配布の補足

Level 1 の分野別評価対象数

分野	問題数
代数	135
場合の数・確率	39
幾何	38
中級代数	52
整数論	30
初等代数	86
解析の基礎	57

[1] HELM Classic v0.4.0. MATH 、 Level 1 の固定評価。 2023-11-17 公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/math_regular

text-davinci-003 の分野別正解率

分野	regular	解説付き
代数	28.15%	50.37%
場合の数・確率	35.04%	44.44%
幾何	56.14%	44.74%
中級代数	26.92%	32.05%
整数論	28.89%	38.89%
初等代数	54.65%	61.24%
解析の基礎	43.27%	42.69%

[1] HELM Classic v0.4.0. MATH 、 Level 1 の固定評価。 2023-11-17 公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/math_regular

実際の提示例数はモデルと分野で異なる

- regular では今回の 3 モデルとも 8 例。解説付き条件でも、 text-davinci-003 と Anthropic は全分野で 8 例だった。
- OPT の解説付き条件は、中級代数 5.16 例、幾何 5.88 例、解析の基礎 6.88 例が平均。ほかは 8 例。
- 入力を切り詰めた割合 prompt_truncated は、今回の 42 実行すべて 0 。提示例を減らして収めた場合も、この値は 0 になる。

[1] HELM Classic v0.4.0. MATH chain-of-thought 、 Level 1 の固定評価。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/math_chain_of_thought

表記の正規化を、数学の同値判定と区別する

- 例えば 1/2 と LaTeX の \frac{1}{2} は、表記をそろえて一致と判定される。
- 一方で、 $(x + 1)^2$ と $x^2 + 2x + 1$ を一般に展開して比較する記号計算器は使わない。
- chain-of-thought 条件では、生成と参照解説の最後の boxed を取り出してから、同じ正規化を行う。

[1] Stanford CRFM. MATHScenario v0.3.0. 参照解答の抽出と表記正規化。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/math_scenario.py

人の成績は、 20 問の別標本で調べた

- test から 20 問を無作為に選び、大学生 6 人が 1 時間、手計算で解いた。
- 数学を好まない参加者は 8/20 、 IMO で 3 度金メダルを得た参加者は 18/20 だった。
- ほかの 4 人は 13 問、 14 問、 15 問、 18 問に正解した。数学経験が異なる参加者を、同じ 20 問で比較した。

[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks. https://arxiv.org/abs/2103.03874

解説の符号も、最終解答とは別に確かめる

- 実例 13 の配布解説では、 $\sin x = 4/5$ 、 $\cos x = -3/5$ を導いた後、最後の分数で符号の位置が入れ替わっている。
- 最終解答 $-4/3$ は変わらないが、途中の式は、 $(4/5) \div (-3/5)$ と書くのが導出に対応する。
- 資料の解説はこの対応を保って説明し、配布解説の原文は変更せず検証記録へ保存した。

[1] MATH, EleutherAI/hendrycks_math. 固定 revision の test 分割。元の競技問題・解説の著者に帰属。 https://huggingface.co/datasets/EleutherAI/hendrycks_math

研究と参考文献

競技数学を、大規模な解説付き評価にする

- 第一著者は Dan Hendrycks 、最終著者は Jacob Steinhardt 。計 8 人の著者による研究として NeurIPS 2021 Datasets and Benchmarks に発表された。
- 競技数学の問題、段階的な解説、難度と分野の注釈を組み合わせ、数学的な問題解決を測る資源を作った。
- 同時に AMPS を公開し、数学に特化した事前学習データが性能に与える影響も調べた。

[1] Hendrycks et al. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS Datasets and Benchmarks.
https://arxiv.org/abs/2103.03874

参考文献

Measuring Mathematical Problem Solving With the MATH Dataset

Dan Hendrycks et al. · 2021 · NeurIPS Datasets and Benchmarks

競技数学 12,500 問と解説、分野・難度、解答の正規化による採点を示す。

https://arxiv.org/abs/2103.03874

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · TMLR

共通の適応方法と複数の指標を使い、 MATH を含む多数の課題で言語モデルを比較する。

https://arxiv.org/abs/2211.09110

参考文献

MATH Dataset

Dan Hendrycks et al.・公式リポジトリ

データの取得先、解答抽出と正規化、評価コード、 AMPS の配布を案内する。

https://github.com/hendrycks/math

MATHScenario

Stanford CRFM · HELM v0.3.0

Level 1 の抽出、公式提示例、解説付き条件の参照、解答の比較関数を実装する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/math_scenario.py