Math23K

Chinese Math Word Problems

中国語の文章題から、数と関係を式へ移す

sasakiy84

2019 年追試著者による、公式実装と配布

README GPL-3.0 license

A Goal-Driven Tree-Structured Neural Model for Math Word Problems

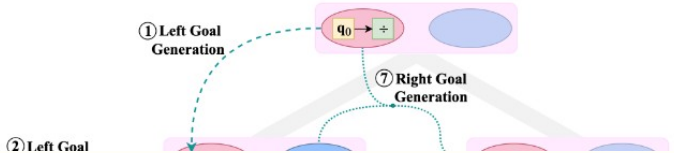
This repository is the PyTorch implementation for the IJCAI 2019 accepted paper:

> Zhipeng Xie* and Shichao Sun*, A Goal-Driven Tree-Structured Neural Model for Math Word Problems
> IJCAI 2019.

* indicates equal contribution.

Seq2Tree Model

A Seq2Tree Neural Network containing top-down Recursive Neural Network and bottom-up Recursive Neural Network



[1] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 2017 年の原配布そのものの画面ではない。
https://github.com/ShichaoSun/math_seq2tree

1. 文章から、式と答えを求める
2. 2017 年の収集と問題の表現
3. 分割と採点条件を読む
4. CLEVA での採用と配布の範囲

文章から、式と答えを求める

文章の数を拾い、求める量を式で表す

- Math23K は、中国語の算数文章題から計算式を作り、数値の答えを求めるためのデータセット。
- 入力は中国語の問題文。配布データには、計算式 equation と答え ans がある。元の研究は文章から式への写像を学習し、式を解いて答える。
- 元論文は 2017 年。今回照合した生データと採点実装は、2019 年の追試著者が配布した固定版である。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/
[2] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 https://github.com/ShichaoSun/math_seq2tree

数値の意味と、求める対象を対応させる

- 同じ数が出てきても、総数・差・割合のどれを問うかで式は変わる。問題文の「より多い」「残り」「平均」などの関係を読む。
- 式の演算順と単位も答えの一部。括弧、百分率、分数、整数で表す指示を落とさずに照合する。
- 以下の 3 例は取得した公開問題の全文。中国語と日本語訳、計算式の読み、配布答えを並べる。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例１：ニワトリがアヒルより多い羽数

2019 年著者配布 / id=19868 / original_text 全文

中国語原文（全文）

一个饲养场，养鸭 1200 只，养的鸡比养的鸭多 (3/5)，养的鸡比鸭多多少只？

日本語訳（全文）

ある飼育場ではアヒルを 1200 羽飼っている。ニワトリはアヒルより 3/5 だけ多い。ニワトリはアヒルより何羽多いか。

配布式の読み： x = 1200 × (3/5)

正解： 720 羽

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=19868 、 0 起算行 19867 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

多い羽数と、ニワトリの総数を分ける

- ニワトリの総数ではなく、アヒルより多い羽数を問う。CLEVA の公開論文例と全文が一致する。
- 1200 × 3/5 = 720 羽が差になる。 1200 + 720 = 1920 羽はニワトリの総数で、この設問が尋ねる量とは異なる。
- CLEVA の論文公開例はこの id19868 と一致する。似たアヒル・ニワトリの問題を、数値だけで同じ原票とみなさない。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json
[2] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

実例２：積を引いてから、差を割る

2019 年著者配布 / id=6 / original_text 全文

中国語原文（全文）

10.6-0.4 与 5.5 的积，所得的差除以 2.1 ，商 = ？

日本語訳（全文）

10.6 から、 0.4 と 5.5 の積を引き、その差を 2.1 で割ると、商はいくつか。

配布式の読み： $x = (10.6 - 0.4 \times 5.5) \div 2.1$

正解： 4

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=6 、 0 起算行 5 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

文章の順番を、括弧と演算順に変える

- 0.4 と 5.5 の積を先に求める。 10.6 から引いた差全体を、2.1 で割る。
- 0.4 × 5.5 = 2.2 、 10.6 − 2.2 = 8.4 、 8.4 ÷ 2.1 = 4 。引く前に積を計算し、引いた結果を割る。
- 式を左から機械的に読むだけでは足りない。文中の「積」「差」「商」が、計算のまとまりを指定している。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例３：年利から、３年間の利息を求める

2019 年著者配布 / id=29 / original_text 全文

中国語原文（全文）

小明把 1800 元存入银行，定期整存整取 3 年．如果按年利率 3.33% 计算，到期后小明可得利息多少元．

日本語訳（全文）

小明は 1800 元を銀行に預け、元金を一括して預け入れ、３年後にまとめて受け取る定期預金にした。年利 3.33% とすると、満期にもらえる利息はいくらか。

配布式の読み： x = 1800 × 3.33% × 3

正解： 179.82 元

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=29 、 0 起算行 28 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

百分率と年数から、利息だけを求める

- 3.33% を 0.0333 に直す。配布式は元金に年利と年数を掛け、利息を求めている。
- 1800 × 0.0333 × 3 = 179.82 元。元金を足した 1979.82 元ではなく、問われた利息を答える。
- 3.33% は 0.0333 として計算する。答えの 10% と小数 0.1 は、同じ値を別の形式で表している。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

2017 年の収集と問題の表現

教育サイトの問題から、式と答えを抽出した

- 2017 年の Wang ・ Liu ・ Shi は、中国語の教育サイトから 6 万件以上の問題を収集した。小学算数の文章題を対象とする。
- 規則により問題文・式・答えを抽出し、適さない例を除いた。元論文は、 1 変数の線形な問題 23,161 件と 2,187 の式テンプレートを報告する。
- 公開問題の収集元にある表現と、著者が作った変換・学習方法を分けて捉える。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/

論文の件数と、取得したファイルの件数

対象	件数	何を数えたか
2017 年論文	23,161	報告された問題数
2019 年追試論文	23,161	比較実験の記述
取得した 2019 年配布	23,162	7 行単位の原レコード
取得版の ID	23,162	異なる id の数

2017 年論文は 23,161 件を報告する。取得した 2019 年配布は 23,162 件で、 1 件の差の理由は確認できていない。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/
[2] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 https://github.com/ShichaoSun/math_seq2tree

数字を記号へ置き換えて、式の形を学ぶ

- 2017 年の方法は、問題文中の数字とその出現位置を対応付け、数字を記号へ置き換える。文章から式テンプレートを生成し、数字を戻して解く。
- 数が出現しても、すべてが式に必要とは限らない。月や学年など、答えに使わない数も問題文に含まれる。
- SNI は significant number identification 。式に使う数を識別し、式生成に不要な数を抑えるための仕組みである。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/

2019 年実装は、配布済みの分かち書きを読む

- 原ファイルは id ・ original_text ・ segmented_text ・ equation ・ ans を持つ。 1 レコードが 7 物理行で、通常の JSON 配列や 1 行 1JSON とは異なる。
- 2019 年実装は segmented_text を空白で分割し、数字を NUM へ置き換える。式中の数を N0 、 N1… として、問題文の数値リストへ結び付ける。
- 定数 1 や 3.14 のように、問題文からコピーする数とは別の値も出力語彙へ加える。今回の実データを公式関数に通して確認した。

[1] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 https://github.com/ShichaoSun/math_seq2tree

分割と採点条件を読む

元論文は 5 分割交差検証で比較した

- 2017 年に報告された成績は 5 分割交差検証の平均正答率。各回で 4 分割を学習、残る 1 分割をテストに使った。
- 同論文は retrieval 、 seq2seq 、両者を組み合わせる hybrid を比較する。 SNI の有無も比較条件であり、別のモデル設定になる。
- 論文の平均値を、今回の 23,162 件を新しい LLM へ入力して得た得点とは呼ばない。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/

2017 年： Math23K の平均正答率

方法	SNI なし	SNI あり
Retrieval	46.0%	47.2%
Seq2seq	53.7%	58.1%
Hybrid	61.1%	64.7%

5 分割交差検証。 ZDC は 42.1% 。別データ Alg514 の値と混ぜない。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/

2019 年の追試は、式を木として生成する

- Xie ・ Sun の GTS は、求める量を目標として式木を上から分解し、完成した部分木を下から表現して次の生成に使う。
- 2019 年論文は Math23K の 5 分割交差検証で GTS74.3% を報告する。 Hybrid64.7% は比較対象であり、 2017 年著者の新しい再実行値とは説明しない。
- 今回取得した公開コードは、この 2019 年の論文に対応する。元論文の全実験条件を同じものとして置き換えない。

[1] Xie & Sun (2019). A Goal-Driven Tree-Structured Neural Model for Math Word Problems. IJCAI, 5299–5305. https://www.ijcai.org/proceedings/2019/736

式の一致と、計算結果の一致を区別する

- 式の文字列が異なっても、計算結果が許容誤差内で一致すれば、値に基づく評価では正解になる。
- 2019 年公開実装の value 判定は、予測式と正解式を数値評価し、差が 10^{-4} 未満かを見る。比較先は raw ans ではなく、正解式の計算結果。
- equation 判定は式トークン列の一致。一般的な代数式の記号的同値性を証明する採点ではない。

[1] Xie & Sun. compute_prefix_tree_result / compute_prefix_expression. math_seq2tree. https://github.com/ShichaoSun/math_seq2tree/tree/master/src

公開採点関数に、式の組を渡して確かめる

予測式／正解式	値の判定	式の一致
2×3 ／ $3 + 3$	正解	不一致
$2 + 3$ ／ $2 + 3$	正解	一致
2^3 ／ $2 \times (2 \times 2)$	不正解	不一致

2019 年固定実装を実行。 3 行目は累乗処理の実装上の制約を示す。同じ値なら常に認めると一般化しない。

[1] Xie & Sun. compute_prefix_tree_result / compute_prefix_expression. math_seq2tree. https://github.com/ShichaoSun/math_seq2tree/tree/master/src

分割の手順と、学習時の乱数を分ける

- 2019 年 run_seq2tree.py は、配布順を連続した 5 区間へ分ける。 23,162 件では 4,632 件が 4 区間、最後が 4,634 件。分割前のシャッフルはない。
- 学習バッチの作成には random.shuffle を使うが、この公開スクリプトには乱数 seed の固定が見当たらない。
- 2017 年論文の「5 分割」という説明だけから、この 2019 年の各原票の所属まで同一だったとは断定しない。

[1] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 https://github.com/ShichaoSun/math_seq2tree

CLEVA での採用と配布の範囲

CLEVA は、文章題を math_word_problem へ採用

- CLEVA の正式論文は Math23K 由来の中国語文章題を採用する。公開例のアヒル 1200 羽と 3/5 の問題は、取得版 id19868 に全文一致し、答えは 720 。
- HELM の説明例には、甲 168 の 4 倍を求める 672 の提示例と、読書量を求める 406 の評価側入力がある。原票は id14819 と id15691 。
- 元問題・説明用の推論文・実際のモデル生成を区別する。コードの docstring にある答えを、公開実行でモデルが生成した出力とは呼ばない。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

[2] Stanford CRFM. HELM v0.4.0 、 CLEVAMathematicalReasoningScenario / Converter. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

公開設定と、取得できた実行結果は別の証拠

- HELM v0.4.0 の数学推論クラスは、 CLEVA v1 の mathematical_reasoning / math_word_problem を扱う。 prompt_id は 0 〜 2 の 3 通り。入力は prompts.json の設定から作る。
- 固定公開版 8,526run に CLEVA の実行は 0 件。 Math23K の公開 HELM モデル出力や得点を、この版から再採点することはできない。
- CLEVA が選んだ全原票・分割・提示文の完全版は取得できていない。 元ファイルの 23,162 件を、そのまま CLEVA の評価分母にしない。

[1] Stanford CRFM. HELM v0.4.0 、 CLEVAMathematicalReasoningScenario / Converter. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py
[2] Stanford CRFM. HELM Classic v0.4.0 、 2023-11-17 固定公開版。 https://crfm.stanford.edu/helm/classic/v0.4.0/

2017 年の配布経路と、 2019 年の取得物を分ける

- 2019 年論文の脚注は、 Tencent AI Lab の Deep Neural Solver プロジェクト頁を案内する。 2017 年の保存ページにも題名・著者・元論文へのリンクがある。
- 現在の同じ URL は Yuanbao 関連のページを返す。 HTTP200 で応答しても、 Math23K の原ファイルが取得できたことにはならない。
- 今回の原データは 2019 年追試著者の公式リポジトリから取得した固定版。 2017 年配布との byte 同一性は確認できていない。

[1] Tencent AI Lab. Deep Neural Solver project page 、 2017-08-30 保存版。
https://web.archive.org/web/20170830114828/http://ai.tencent.com:80/ailab/Deep_Neural_Solver_for_Math_Word_Problems.html
[2] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 https://github.com/ShichaoSun/math_seq2tree

出所を示し、データと実装の権利を分ける

- 2019 年公式リポジトリの LICENSE は GPL-3.0 。コードの利用条件を、教育サイト由来の全設問の権利許諾へ自動的に広げない。
- 2017 年論文は教育サイトからの収集を説明する。元の問題文の著者や出所への帰属を保ち、原文の引用と日本語訳を区別して扱う。
- 公開原文・配布式・配布 ans と固定版の位置を対応付けて参照する。 ID と問題文を確認し、同じ数字を含む別問題と区別する。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/
[2] Xie & Sun. math_seq2tree LICENSE 、 GNU General Public License version 3. https://github.com/ShichaoSun/math_seq2tree/blob/master/LICENSE

文章・式・答えを、同じ問題として確認する

- Math23K は、中国語の数量関係を式へ写し、答えを求める研究のための文章題データ。数の取り違え、演算順、割合、単位が理解を分ける。
- 2017 年の元論文、 2019 年配布と実装、 CLEVA の後続利用は、出所・分割・採点条件を分けて読む。
- 原文・配布式・配布 ans を対応付け、百分率・分数・単位を保って計算を読む。正解式と予測式の比較では、式の形と数値の一致を区別する。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/
[2] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 https://github.com/ShichaoSun/math_seq2tree

Appendix

1. 追加の問題と単位
2. 原データ・式・採点の補足
3. 研究と参考文献

追加の問題と単位

実例 4 ：ある数の 4 倍を求める

2019 年著者配布 / id=14819 / original_text 全文

中国語原文（全文）

甲数是 168，乙数是甲数的 4 倍，乙数 = ？

日本語訳（全文）

甲の数は 168 で、乙の数は甲の 4 倍である。乙の数はいくつか。

配布式の読み： x = 168 × 4

正解： 672

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=14819 、 0 起算行 14818 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 5 ：残りの読書量と、読んだ頁数

2019 年著者配布 / id=15691 / original_text 全文

中国語原文（全文）

小方看一本书，已经看了 136 页，剩下的每天看 15 页， 18 天看完．这本书一共有多少页？

日本語訳（全文）

小方は本を 136 頁読んだ。残りは毎日 15 頁ずつ読み、 18 日で読み終えた。この本は全部で何頁あるか。

配布式の読み： x = 15 × 18 ＋ 136

正解： 406 頁

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=15691 、 0 起算行 15690 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 6 ：両端にも木を植えた道の長さ

2019 年著者配布 / id=1 / original_text 全文

中国語原文（全文）

镇海雅乐学校二年级的小朋友到一条小路的一边植树．小朋友们每隔 2 米种一棵树（马路两头都种了树），最后发现一共种了 11 棵，这条小路长多少米．

日本語訳（全文）

鎮海雅楽学校の 2 年生が、道の片側に木を植えた。 2m ごとに 1 本植え、道の両端にも木を植えたところ、全部で 11 本になった。この道は何 m あるか。

配布式の読み： $x = (11 - 1) \times 2$

正解： 20m

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=1 、 0 起算行 0 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 7 ：卒業と入学を差し引いた増加率

2019 年著者配布 / id=7 / original_text 全文

中国語原文（全文）

象山学校原有学生 700 人，7 月份毕业 280 人，9 月份招入新生 350 人，这时象山学校的学生比原来增加百分之几？

日本語訳（全文）

象山学校にはもともと生徒が 700 人いた。7 月に 280 人が卒業し、9 月に 350 人の新入生が入った。この時点の生徒数は、もとの人数より何 % 増えたか。

配布式の読み： x = (350 − 280) ÷ 700

正解： 10%

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=7 、 0 起算行 6 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 8 ：三つの果樹の本数を比でつなぐ

2019 年著者配布 / id=10 / original_text 全文

中国語原文（全文）

一个果园的李树棵数是桃树的 (7/8)，桃树棵数是梨树的 (5/6)．已知李树有 1680 棵，梨树有多少棵？

日本語訳（全文）

ある果樹園では、スモモの木の本数はモモの木の 7/8 で、モモの木の本数はナシの木の 5/6 である。スモモの木が 1680 本のとき、ナシの木は何本か。

配布式の読み： x = 1680 ÷ (7/8) ÷ (5/6)

正解： 2304 本

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=10 、 0 起算行 9 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 9 ：家庭の水道料金を、 5 人で分ける

2019 年著者配布 / id=19 / original_text 全文

中国語原文（全文）

小芳家 5 月份用水量是 16.5 吨，每吨水的价格是 2.1 元，小芳家一共有 5 口人，平均每人应交多少水费？

日本語訳（全文）

小芳の家は 5 月に水を 16.5t 使った。水 1t の料金は 2.1 元で、家族は全部で 5 人いる。 1 人当たり、平均でいくら水道料金を負担すればよいか。

配布式の読み： x = 16.5 × 2.1 ÷ 5

正解： 6.93 元／人

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=19 、 0 起算行 18 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 10 ： 12% 多い数から、もとの数へ戻す

2019 年著者配布 / id=24 / original_text 全文

中国語原文（全文）

比一个数多 12% 的数是 112，这个数 = ？

日本語訳（全文）

ある数より 12% 多い数は 112 である。このある数はいくつか。

配布式の読み： x = 112 ÷ (1 ＋ 12%)

正解： 100

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=24 、 0 起算行 23 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 11 ：二つの班の割合を合わせる

2019 年著者配布 / id=32 / original_text 全文

中国語原文（全文）

一班开展课外活动，全班人数的 (1/7) 参加科技组，比参加阅读组的少占全班人数的 (2/7) ，参加这两个组的人数占全班人数的几分之几？

日本語訳（全文）

あるクラスで課外活動を行っている。クラス全体の 1/7 が科学班に参加している。この割合は読書班の割合より、クラス全体の 2/7 だけ少ない。この 2 班の参加者を合わせると、全体の何分のいくつか。

配布式の読み： x = (1/7) ＋ (2/7) ＋ (1/7)

正解： 4/7

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=32 、 0 起算行 31 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 12 ：ひもを使った長さと、帯分数の答え

2019 年著者配布 / id=294 / original_text 全文

中国語原文（全文）

一条绳子长 4 米，用去 (1/4) 米，还剩多少米.

日本語訳（全文）

長さ 4m のひもを 1/4m 使った。残りは何 m か。

配布式の読み： x = 4 − (1/4)

正解： 3 と 3/4m （ 3.75m ）

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=294 、 0 起算行 293 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

実例 13 ：等間隔の木と、整数での表示

2019 年著者配布 / id=19661 / original_text 全文

中国語原文（全文）

一条路的一边从头到尾共种了 36 棵树，每两棵树间隔 5.6 米，这条路长约多少米？（得数保留整数）

日本語訳（全文）

道の片側に端から端まで 36 本の木を植え、木と木の間隔は 5.6m とした。この道の長さは約何 m か。（答えは整数に丸める）

配布式の読み： $x = (36 - 1) \times 5.6$

正解： 196m

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。 id=19661 、 0 起算行 19660 。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

原データ・式・採点の補足

13 例の原票： ID と物理行を対応させる

実例	id	0 起算行	先頭物理行
1	19868	19867	139070
2	6	5	36
3	29	28	197
4	14819	14818	103727
5	15691	15690	109831
6	1	0	1
7	7	6	43

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

13 例の原票：追加例の原位置

実例	id	0 起算行	先頭物理行
8	10	9	64
9	19	18	127
10	24	23	162
11	32	31	218
12	294	293	2052
13	19661	19660	137621

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

取得版の全件計算：式と ans の数値を比較する

確認結果	件数	解釈
分数の厳密値が一致	23,156	式と ans の数値整合
数値が異なる	5	丸め等の原因は未断定
自作解析器で解析不可	1	原文字列を保持
計	23,162	2019 年取得版

独立した安全な算術解析器で全件確認。文意の正しさや全ラベル精度を保証する検査ではない。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

数値が合わない例を、推測で修正しない

- 数値差のある id は 4303 ・ 9718 ・ 9761 ・ 12495 ・ 22085 。id17520 は式または答えに自作解析器が扱えない形式がある。
- たとえば id9761 は配布式の値が 295/3 、 ans が 98 。問題文の意図を確認せずに、 ans を書き換えたり誤りの原因を一つに決めたりしない。
- この整合性検査は、予測モデルの採点ではない。公開採点実装は予測式と正解式を比較するため、 raw ans の整合性検査とは別の量である。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json
[2] Xie & Sun. compute_prefix_tree_result / compute_prefix_expression. math_seq2tree. https://github.com/ShichaoSun/math_seq2tree/tree/master/src

数字を取り出す処理にも、固定版の前提がある

- 2019 年 loader は 7 行を結合して JSON として読む。式に付く「千米 / 小时」を除く処理もある。元 byte を保存し、加工後の値と区別する。
- transfer_num は、分かち書き済みトークンから整数・小数・百分率・帯分数を取り出す。数字の表記法によって式への対応付けが変わりうる。
- 全文字列を無制限に eval する再計算は行わず、独立検査では許可した算術演算を分数で評価した。公式コードの関数実行とは別の検査として扱う。

[1] Xie & Sun. 2019 年追試著者の math_seq2tree 実装。固定版 d2310d08818e 。 https://github.com/ShichaoSun/math_seq2tree

配布 ans の表記と、同じ値の読み方

原 ID	配布 ans	日本語での答え
7	10%	10%
19	6.93	6.93 元／人
32	((4)/(7))	4/7
294	3((3)/(4))	3 と 3/4m （ 3.75m ）
19661	196	196m

単位は問題文から補って表示。 raw ans は原データ記録にそのまま残す。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

式評価の累乗処理には、実装上の制約がある

- 固定版の prefix 評価器は、累乗の指数に対する条件分岐に制約がある。異なる形の 2^3 と 2×(2×2) を渡すと、値の判定は偽になることを確認した。
- 一方で式トークン列が完全一致する場合は、数値評価より先に一致として返す。実装の振る舞いと数学的な同値性を分けて説明する。
- 13 例の配布式は、公式の前処理・ prefix 変換・数値評価を通し、独立した厳密計算と一致することを確かめた。

[1] Xie & Sun. compute_prefix_tree_result / compute_prefix_expression. math_seq2tree. https://github.com/ShichaoSun/math_seq2tree/tree/master/src

2019 年：比較したモデル

方法	正答率
Hybrid （2017）	64.7%
Ensemble with EN	68.4%
GTS without Subtree Embedding	70.0%
GTS	74.3%

論文の 5 分割交差検証の報告値。今回コードを学習し直して得た値ではない。

[1] Xie & Sun (2019). A Goal-Driven Tree-Structured Neural Model for Math Word Problems. IJCAI, 5299–5305. https://www.ijcai.org/proceedings/2019/736

似たアヒルの問題にも、別の ID と答えがある

- CLEVA の公開論文例は id19868 ：アヒル 1200 羽、ニワトリは 3/5 多く、多い羽数 720 を問う。
- 取得版には、合計 2100 を問う id3183 、 480 少ない問題の id6285 、ガチョウ 1000 羽を含む id17744 など、似た語の別問題がある。
- 原文全文、問われた量、式、答え、 ID をまとめて照合する。鳥の種類や 1200 などの数字が似ているだけでは同一問題としない。

[1] Math23K 公開問題。 2019 年追試著者配布 data/Math_23K.json 、 d2310d08818e 。元設問の権利は出所に帰属。
https://github.com/ShichaoSun/math_seq2tree/blob/master/data/Math_23K.json

研究と参考文献

2017 年の原研究と、 2019 年の追試の著者

- 2017 年の Deep Neural Solver for Math Word Problems は、 Tencent AI Lab の Yan Wang ・ Xiaojiang Liu ・ Shuming Shi による EMNLP 論文。 Math23K を導入し、 seq2seq と hybrid を提案した。
- 2019 年の追試は Zhipeng Xie ・ Shichao Sun による IJCAI 論文。 目標に基づく式木生成を提案し、 Math23K を比較に用いた。両者は共同第一著者と記される。
- この資料は取得できる原問題と実コードを基に、元データセットを独立して説明する。 CLEVA 全体の得点表の代わりにはしない。

[1] Wang, Liu & Shi (2017). Deep Neural Solver for Math Word Problems. EMNLP, 845–854. https://aclanthology.org/D17-1088/
[2] Xie & Sun (2019). A Goal-Driven Tree-Structured Neural Model for Math Word Problems. IJCAI, 5299–5305. https://www.ijcai.org/proceedings/2019/736

参考文献

Deep Neural Solver for Math Word Problems

Wang, Liu & Shi · 2017 · EMNLP 845–854

Math23K の収集、数値対応、 SNI と 5 分割交差検証を報告する元論文。

https://aclanthology.org/D17-1088/

A Goal-Driven Tree-Structured Neural Model for Math Word Problems

Xie & Sun · 2019 · IJCAI 5299–5305

式木を生成する GTS と Math23K 比較実験を報告する追試論文。

https://www.ijcai.org/proceedings/2019/736

参考文献

math_seq2tree: official implementation and distribution

ShichaoSun · fixed commit d2310d08818e · GPL-3.0 repository

今回照合した 2019 年著者配布の原問題・前処理・採点コード。

https://github.com/ShichaoSun/math_seq2tree

Deep Neural Solver: original project page

Tencent AI Lab · archived 2017-08-30

2019 年論文が示す元のプロジェクト経路。原ファイル同一性は未確定。

https://web.archive.org/web/20170830114828/http://ai.tencent.com:80/ailab/Deep_Neural_Solver_for_Math_Word_Problems.html

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Li et al. · 2023 · EMNLP System Demonstrations 186–217

Math23K を採用し、アヒルとニワトリの実問題を公開例として示す。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVAMathematicalReasoningScenario and Converter

Stanford CRFM · HELM v0.4.0

説明例と、変換済み CLEVA データを入力へ変換する実装。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

参考文献

CLEVA v1 run configuration

Stanford CRFM · HELM v0.4.0

mathematical_reasoning の math_word_problem 設定。固定公開 run の有無とは分けて扱う。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

HELM Classic v0.4.0 public release

Stanford CRFM · release 2023-11-17

固定 8,526run の一覧。 CLEVA 実行は含まれない。

https://crfm.stanford.edu/helm/classic/v0.4.0/