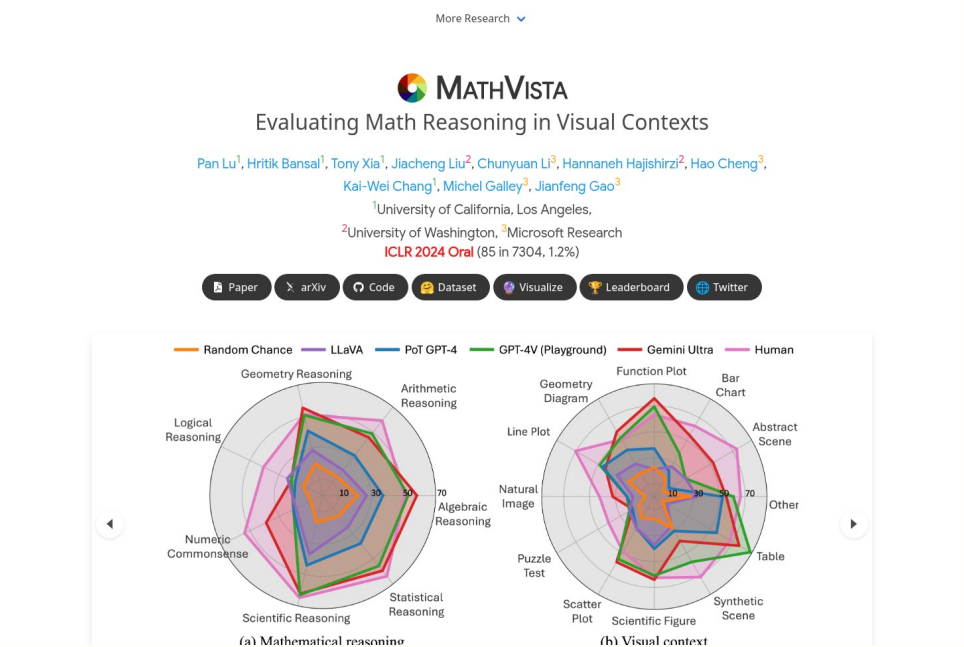
MathVista

Mathematical Reasoning in Visual Contexts

図や表を読み、数学的な操作で答えを求める

sasakiy84

MathVista の公式サイト



[1] MathVista (n.d.), Official Project Page.
https://mathvista.github.io/

1. 図や表を使う数学問題と実例
2. 作成方法とデータの全体像
3. 回答の採点とモデルの成績
4. 視覚モデルの評価と入手方法

1. 図や表を使う数学問題と実例

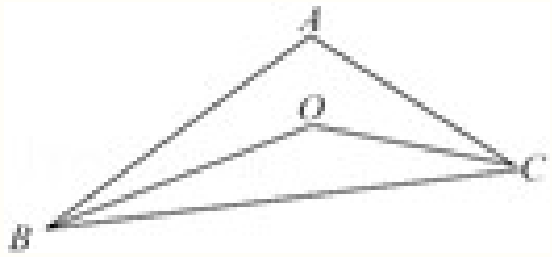
画像を読み、計算や推論で答えを求める

- MathVista は、図形、グラフ、表、写真などを含む数学的な質問に答える評価データセットである。
- 画像と設問を入力し、選択肢または短い数値・語句を返す。図の読み取りと、その情報を使う推論の両方が必要になる。
- ここでは、正解が公開されている testmini から 13 問を紹介する。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

例 1 内角の二等分線から角度を求める

設問・選択肢の原文（全文）と入力画像



△ABC 的两内角平分线 OB 、 OC 相交于点 O ，若 ∠ A ＝ 110° ，则∠ BOC ＝（）
(A) 135°　(B) 140°　(C) 145°　(D) 150°

日本語訳：三角形 ABC で、内角の二等分線 OB と OC が点 O で交わる。∠ A=110° のとき、∠ BOC はいくつか。

正解： C ： 145°

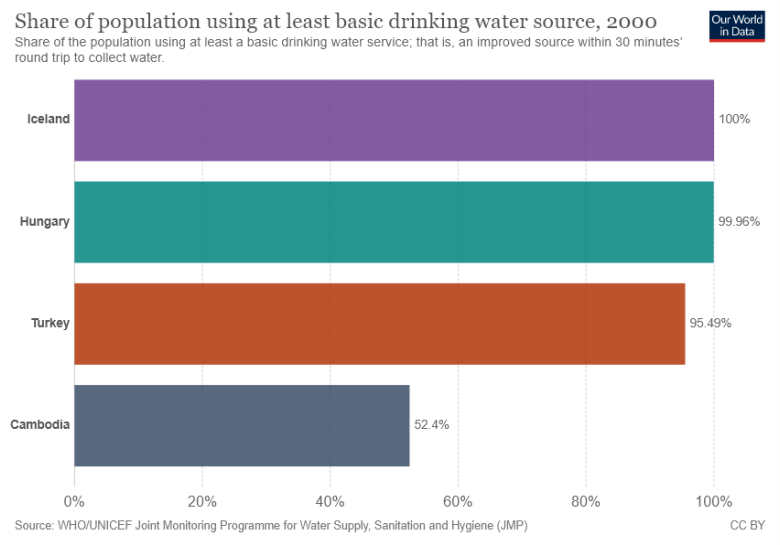
三角形 BOC で、 180°−(180°−110°)/2=145° 。

[1] Lu et al. (2024), MathVista — public testmini. GeoQA+
https://huggingface.co/datasets/AI4Math/MathVista

例 2 棒グラフの最大値と最小値の差を求める：原文

設問・選択肢の原文（全文）と入力画像

What is the difference of largest and smallest bar?



[1] Lu et al. (2024), MathVista — public testmini. ChartQA
https://huggingface.co/datasets/AI4Math/MathVista

例 2 棒グラフの最大値と最小値の差を求める：日本語訳と答え

設問の日本語訳（全文）

最も大きい棒と最も小さい棒の差はいくつか。

正解： 47.6 ポイント

国	割合（%）
アイスランド	100
ハンガリー	99.96
トルコ	95.49
カンボジア	52.4

[1] Lu et al. (2024), MathVista — public testmini. ChartQA
https://huggingface.co/datasets/AI4Math/MathVista

例 3 価格表から買物の代金を計算する

設問の原文（全文）と入力画像

Chase wants to buy 4 kilograms of oval beads and 5 kilograms of star-shaped beads. How much will he spend? (Unit: $)

oval beads	$2/kilogram
rectangular beads	$3/kilogram
star-shaped beads	$2/kilogram
spherical beads	$2/kilogram
heart-shaped beads	$3/kilogram
square beads	$2/kilogram
flower-shaped beads	$2/kilogram

日本語訳（全文）

Chase は楕円形のビーズ 4kg と星形のビーズ 5kg を買いたい。代金はいくらになるか。（単位：ドル）

正解： 18 ドル

どちらも 1kg 当たり 2 ドル。 4×2+5×2=18 ドル。

[1] Lu et al. (2024), MathVista — public testmini. TabMWP
https://huggingface.co/datasets/AI4Math/MathVista

2. 作成方法とデータの全体像

一種類の図表だけでは測れない能力を集めた

- 従来の数学問題は文章だけのものが多く、図表を扱う評価も、幾何や特定形式のグラフなどに分かれていた。
- MathVista は、異なる視覚情報と数学的な操作を組み合わせ、得意・不得意を課題や推論の種類ごとに調べるために作られた。
- Pan Lu らが 2023 年に公開し、 ICLR 2024 で発表した。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

既存 28 データと新たな 3 データを組み合わせた

- 数学を主題とする 9 データから 2,666 問を収録した。幾何、表を使う文章題、理科の教科書問題などが含まれる。
- 一般的な視覚質問応答では 70 件以上のデータを調べ、数量や計算を扱う 19 データから 2,739 問を選んだ。
- さらに、図形の規則、関数のグラフ、論文の図表を扱う 736 問を新たに用意した。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

数量を問う候補を絞り、人が内容を確認した

- 一般的な視覚質問応答では、数値で答える質問や、数量に関係する語を含む質問を自動的に集めた。
- 候補 4,949 問を 3 人の専門家が確認し、数学的な推論を必要とするかを多数決で判定した。
- 特定の収集元に偏らないよう、各データセットから採る問題は最大 400 問とした。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

不足していた図形の規則・関数・論文図表を補った

- IQTest は、図形の並びやパズルから規則を見つける問題を扱う。 FunctionQA は、関数のグラフから値や性質を読み取る。
- PaperQA は、科学論文にある表やグラフについて、数値の比較などを求める。
- 新規問題は理工系の大学院生が注釈し、 3 人が独立に確認した。答えが一致しなかった 6 問は議論で解消した。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

6,141 問には 5,487 枚の異なる画像がある

- 一つの画像に複数の質問が対応する場合があるため、画像数と問題数は異なる。
- 問題形式は選択式 3,392 問と自由回答 2,749 問である。自由回答では整数、小数、リストなどを答える。
- 設問の言語は英語 5,737 問、中国語 400 問、ペルシャ語 4 問。学年・画像の種類・必要な推論も注釈されている。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

五つの課題で、図表と数学の関係を捉える

課題	問数	内容
図表に関する質問	1,647	グラフや表の数値を比較・計算
幾何の問題	1,319	図形の角度や長さを求める
算数・数学の文章題	1,200	表や図を使い、数量を計算
視覚質問応答	1,038	写真や場面の数量などを問う
教科書の質問	937	関数や理科の図を読み解く

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

解く操作を七つの推論の種類で整理する

- 算術、代数、幾何、論理、数に関する常識、科学、統計という七つの種類を付けている。一問に複数の種類が対応する場合もある。
- 例えば、図形の角度を求める問題は幾何、価格表から代金を出す問題は算術、グラフの傾向を比較する問題は統計に関係する。
- 推論の種類の注釈は、収集元の情報を使って付け、 1,000 問を人が確認した。全ラベル集合の一致率は 94.1% だった。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

公開 1,000 問と正解非公開 5,141 問を使い分ける

- testmini の 1,000 問は、開発や検証、計算資源が限られる場合の評価に使う。全問の正解を公開している。
- test の 5,141 問は、標準の評価用である。質問と画像は公開されているが、正解は公開されていない。
- testmini は収集元の構成が全体に近くなるように選んでいる。

[1] MathVista (n.d.), Dataset Usage and Evaluation.
https://github.com/lupantech/MathVista

3. 回答の採点とモデルの成績

長い回答から答えを取り出し、正解率を求める

- 評価では、画像と設問から回答を生成し、説明文に含まれる短い最終回答を抽出する。公開時の方法では抽出に GPT-4 を用いた。
- 選択肢の記号や数値を所定の形式へ変換し、参照回答と一致すればその問題を正解とする。
- 正解率は、正解した問題数を評価した問題数で割った値である。課題別や推論の種類別にも集計する。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

選択肢と数値では、回答のそろえ方が異なる

- 選択式では、記号を選択肢の本文へ対応させる。選択肢の文を答えた場合は、文字列が最も近い候補へ対応させる。
- 整数は整数の表記に、小数は問題で指定された桁数にそろえて比較する。例えば「18.0」は、整数回答なら「18」になる。

[1] MathVista (n.d.), calculate_score.py.
https://github.com/lupantech/MathVista/blob/main/evaluation/calculate_score.py

画像を直接読む方法と、文章へ変換する方法を比べた

- 2023 年の評価では、画像を直接入力するモデルと、画像の説明文や文字認識結果を文章モデルへ渡す方法を調べた。
- GPT-4V は、当時 API がなかったため Playground で手動評価した。公開 1,000 問で 49.9% に達した。
- 人の比較値は、参加資格を確認した作業者が同じ testmini に回答した結果である。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

初期の公開 1,000 問では、 GPT-4V が 49.9%

モデル・回答方法	正解率（%）
GPT-4V / Playground	49.9
Multimodal Bard	34.8
GPT-4 / 画像説明・ OCR ・ 2-shot PoT	33.9
LLaVA-LLaMA-2-13B	26.1
人の回答	60.3

2023 年評価。 2-shot PoT は、例を二つ与え、プログラムを生成して解く方法。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

図の読み違いと、計算・推論の誤りを調べられる

- 初期の分析では、画像の形や数値を読み違える誤りと、読み取った情報から答えを求める途中の誤りが見られた。
- 関数の点の位置、図形の条件、グラフの凡例など、答えに必要な手掛かりを正しく捉えられるかが重要になる。
- 課題や画像の種類ごとの成績を見ると、総合点だけでは分からない弱点を調べられる。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

4. 視覚モデルの評価と入手方法

2025 年の OpenAI 報告でも視覚評価に採用された

- OpenAI は GPT-4.1 の公開時に、 MathVista を図や画像を使う数学問題の評価として報告した。
- 文章中心の知識問題や、図表の読解だけを問う評価と組み合わせ、画像から考える能力を調べている。
- 2026 年の公式 README には、外部の評価ツール EvalScope による実行方法も掲載されている。

[1] OpenAI (2025), Introducing GPT-4.1 in the API. https://openai.com/index/gpt-4-1/
[2] MathVista (n.d.), Dataset Usage and Evaluation. https://github.com/lupantech/MathVista

2025 年の公開報告では、 GPT-4.1 が 72.2%

モデル	正解率（%）
GPT-4.1	72.2
GPT-4.1 mini	73.1
GPT-4.5	72.3
OpenAI o1 / high	71.8
GPT-4o / 2024-11-20	61.4

OpenAI が 2025-04-14 に公開した MathVista の値。

[1] OpenAI (2025), Introducing GPT-4.1 in the API.
https://openai.com/index/gpt-4-1/

問題・画像・正解の形式を確認して利用する

- 公式サイトから、論文、データ、実装、公開結果へ進める。 Hugging Face では testmini と test を選んで読み込める。
- question に設問、 choices に選択肢、 decoded_image に画像、 answer に参照回答が入る。 metadata には収集元や課題がある。
- 正解がある testmini で入出力と採点を確認し、目的に合う課題や推論の種類を選ぶ。

[1] MathVista (n.d.), Dataset Usage and Evaluation.
https://github.com/lupantech/MathVista

一問の画像・設問・参照回答を確かめる

```
from datasets import load_dataset

ds = load_dataset("AI4Math/MathVista", split="testmini")
row = ds[0]
print(row["question"], row["choices"], row["answer"])
image = row["decoded_image"]
image.save("mathvista-example.png")
```

設問と選択肢、参照回答を表示し、対応する画像を保存する。

[1] MathVista (n.d.), Dataset Usage and Evaluation.
https://github.com/lupantech/MathVista

画像・問題の出典と利用条件を引き継ぐ

- MathVista の新たな貢献は CC BY-SA 4.0 で提供される。元の画像と質問の著作権は各作成者にあり、 metadata と source.json で出典をたどれる。
- MathVista の README は試験用途の商用利用を認め、学習用途を禁止している。一方、 IconQA などの収録元には非商用条件もある。
- 利用する例の出典と条件を確認し、帰属表示や同じ条件での共有を引き継ぐ。

[1] MathVista (n.d.), Dataset Usage and Evaluation. https://github.com/lupantech/MathVista
[2] Lu et al. (2021), IconQA — License. https://github.com/lupantech/IconQA

視覚情報と数学的な操作を組み合わせて評価する

- MathVista は、図形、グラフ、表、写真などを含む 6,141 問を集め、画像を読み取って答えを求める能力を調べる。
- 五つの課題と七つの推論の種類から、モデルの得意・不得意を分析できる。
- 公開 1,000 問は、具体的な入出力や採点を確かめ、視覚モデルを比較する入口になる。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

Appendix

1. 内容の異なる追加例
2. データの構成と参考文献

1. 内容の異なる追加例

例 4 時計から時刻を読み取る：原文

設問・選択肢の原文（全文）と入力画像

What time is shown? Answer by typing a time word, not a number. It is (_) after eight.
(A) half (B) quarter (C) o'clock (D) quarter to (E) quarter past



[1] Lu et al. (2024), MathVista — public testmini. IconQA
https://huggingface.co/datasets/AI4Math/MathVista

例 4 時計から時刻を読み取る：日本語訳と答え

設問の日本語訳（全文）

時計は何時を示しているか。数字ではなく、時刻を表す語で答える。「8 時から（　）過ぎ」である。
(A) 30 分　(B) 15 分　(C) ちょうど　(D) 15 分前　(E) 15 分過ぎ

正解：B ： quarter （15 分）

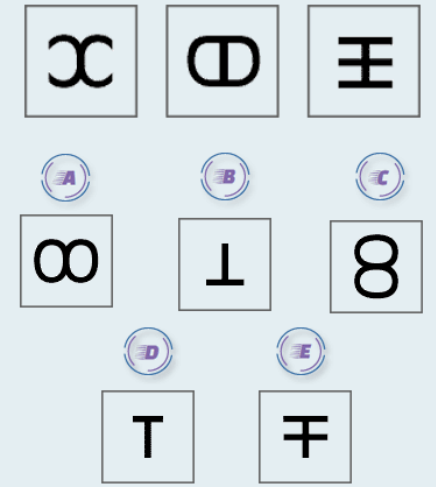
長針は 3 、短針は 8 と 9 の間にあるので 8 時 15 分。空欄の後に after eight が続くため、 15 分を表す quarter を入れる。

[1] Lu et al. (2024), MathVista — public testmini. IconQA
https://huggingface.co/datasets/AI4Math/MathVista

例 5 図形の並びから規則を見つける

設問・選択肢の原文（全文）と入力画像

Which object comes next?
(A) A (B) B (C) C (D) D (E) E



日本語訳（全文）

次に来る図形はどれか。
(A) A (B) B (C) C (D) D (E) E

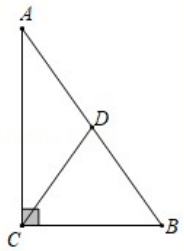
正解： E

図形は C 、 D 、 E を左右反転した形と組み合わせたもの。次は F で、選択肢 E になる。

[1] Lu et al. (2024), MathVista — public testmini. IQTest
https://huggingface.co/datasets/AI4Math/MathVista

例 6 直角三角形の斜辺の中点を使う

設問・選択肢の原文（全文）と入力画像



如图，在 Rt△ABC 中，∠ ACB ＝ 90° ， D 是 AB 的中点， AB ＝ 10 ，则 CD 的长为（）
(A) 5　(B) 6　(C) 8　(D) 10

日本語訳：図の直角三角形 ABC で∠ ACB=90° 、 D は AB の中点、 AB=10 である。 CD の長さはいくつか。

正解： A ： 5

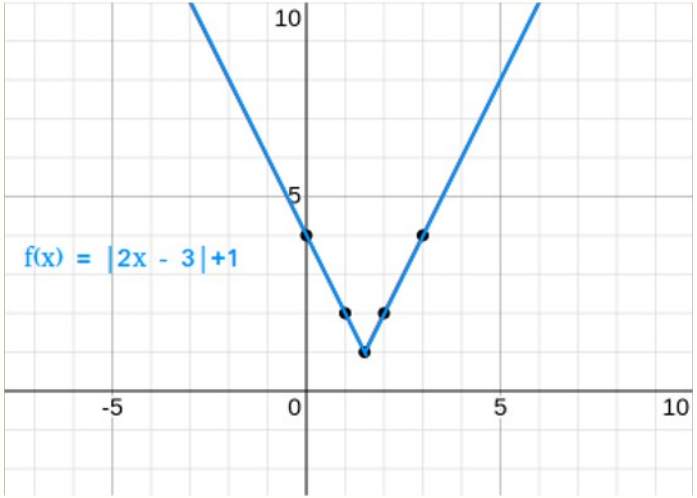
斜辺の中点 D は A 、 B 、 C から等距離にある。 CD=AB/2=5 。

[1] Lu et al. (2024), MathVista — public testmini. GeoQA+
https://huggingface.co/datasets/AI4Math/MathVista

例 7 関数の二点で傾きを比較する：原文

設問・選択肢の原文（全文）と入力画像

The derivative of f(x) at x=2 is ____ that at x=5
(A) larger than (B) equal to (C) smaller than



[1] Lu et al. (2024), MathVista — public testmini. FunctionQA
https://huggingface.co/datasets/AI4Math/MathVista

例 7 関数の二点で傾きを比較する：日本語訳と答え

設問の日本語訳（全文）

x=2 での f(x) の微分係数は、 x=5 での微分係数と比べてどうか。
(A) 大きい　(B) 等しい　(C) 小さい

正解： B ： equal to （等しい）

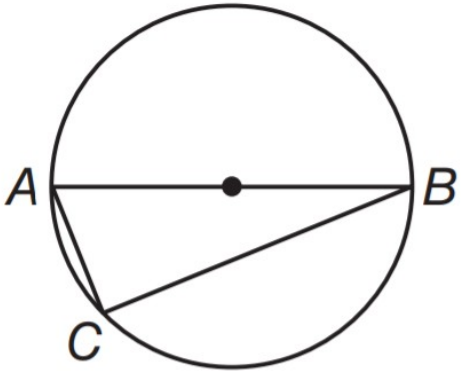
図の関数は f(x)=|2x−3|+1 。 x=2 と x=5 はともに折れ曲がる点の右側にあり、直線の傾きはどちらも 2 である。

[1] Lu et al. (2024), MathVista — public testmini. FunctionQA
https://huggingface.co/datasets/AI4Math/MathVista

例 8 直径と三角形から円の半径を求める：原文

設問・選択肢の原文（全文）と入力画像

AB is a diameter, AC=8 inches, and BC=15 inches. Find the radius of the circle.
(A) 7.5 (B) 8 (C) 8.5 (D) 17



[1] Lu et al. (2024), MathVista — public testmini. Geometry3K
https://huggingface.co/datasets/AI4Math/MathVista

例 8 直径と三角形から円の半径を求める：日本語訳と答え

設問の日本語訳（全文）

AB は直径で、 AC=8 インチ、 BC=15 インチである。円の半径を求めよ。
(A) 7.5　(B) 8　(C) 8.5　(D) 17

正解： C ： 8.5 インチ

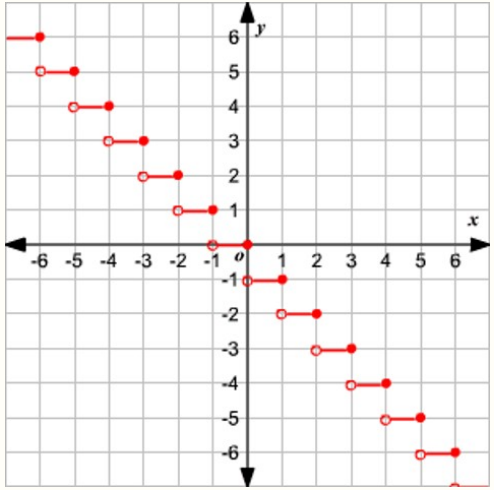
直径に対する円周角∠ ACB は 90° 。 AB=$\sqrt{(8^2+15^2)}$=17 なので、半径は 17/2=8.5 インチとなる。

[1] Lu et al. (2024), MathVista — public testmini. Geometry3K
https://huggingface.co/datasets/AI4Math/MathVista

例 9 階段状のグラフの連続性を判断する

設問・選択肢の原文（全文）と入力画像

Is this function continuous at each point?
(A) Yes (B) No



日本語訳（全文）

この関数は、すべての点で連続か。
(A) はい (B) いいえ

正解： B ： No （いいえ）

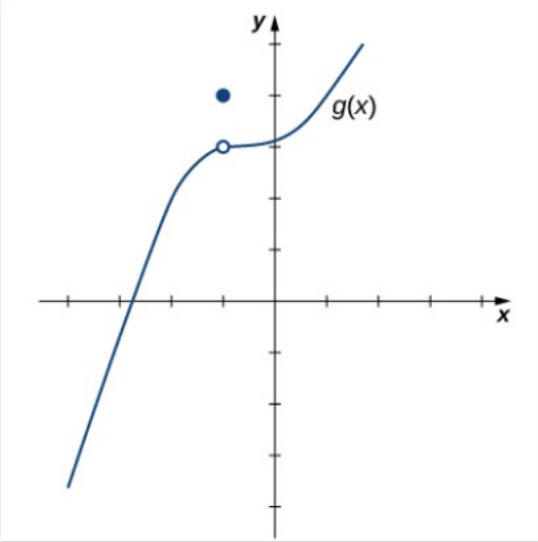
x=0 では左から 0 、右から− 1 へ近づく。左右の極限が異なるので、連続ではない。

[1] Lu et al. (2024), MathVista — public testmini. FunctionQA
https://huggingface.co/datasets/AI4Math/MathVista

例 10 関数の値と極限を区別する

設問・選択肢の原文（全文）と入力画像

What is the limit as x approaches -1?



日本語訳（全文）

x が− 1 に近づくときの極限はいくつか。

正解： 3

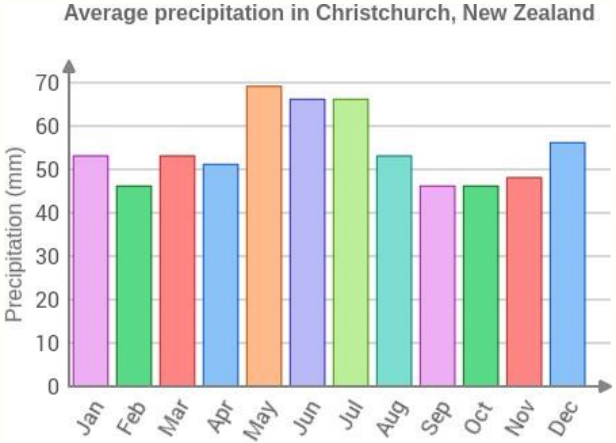
x=−1 へ左右から近づくと、白丸の高さ 3 へ近づく。黒丸の高さ 4 は関数値である。

[1] Lu et al. (2024), MathVista — public testmini. FunctionQA
https://huggingface.co/datasets/AI4Math/MathVista

例 11 月別の降水量の最大値を読む：原文

設問・選択肢の原文（全文）と入力画像

Use the graph to answer the question below. Which month is the wettest on average in Christchurch?
(A) August (B) April (C) May



[1] Lu et al. (2024), MathVista — public testmini. ScienceQA
https://huggingface.co/datasets/AI4Math/MathVista

例 11 月別の降水量の最大値を読む：日本語訳と答え

設問の日本語訳（全文）

グラフを使って答える。クライストチャーチで、平均して最も雨が多いのは何月か。
(A) 8 月　(B) 4 月　(C) 5 月

正解：C ： May （5 月）

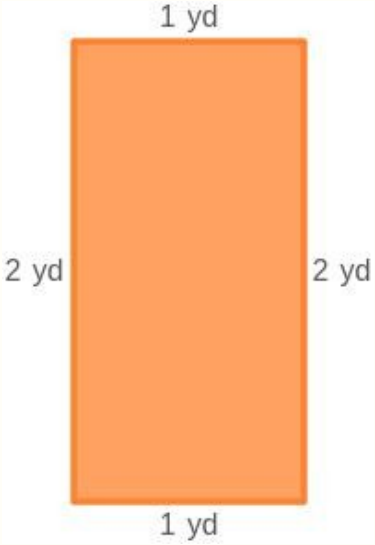
最も高い棒は May （5 月）で、平均降水量は約 69mm 。

[1] Lu et al. (2024), MathVista — public testmini. ScienceQA
https://huggingface.co/datasets/AI4Math/MathVista

例 12 辺の長さから長方形の周囲を求める

設問・選択肢の原文（全文）と入力画像

What is the perimeter of the rectangle?



日本語訳（全文）

長方形の周の長さはいくつか。

正解： 6 ヤード

短辺が 1 ヤード、長辺が 2 ヤードなので、 1+2+1+2=6 ヤードとなる。

[1] Lu et al. (2024), MathVista — public testmini. IconQA
https://huggingface.co/datasets/AI4Math/MathVista

例 13 論文の表で条件に合う手法を数える：原文

設問・選択肢の原文（全文）と入力画像

How many methods in the table achieve an A-847 score higher than 20.0?

Table 7: **Grounding segmentation performance.** The proposed FC-CLIP also demonstrates state-of-the-art performances on grounding segmentation

	grounding PQ			grounding mIoU					
method	ADE20K	Cityscapes	Mapillary Vistas	A-847	PC-459	A-150	PC-59	PAS-21	PAS-20
ALIGN [38, 28]	-	-	-	17.8	21.8	25.7	34.2	-	-
ALIGN w/ proposal [38, 28]	-	-	-	17.3	19.7	25.3	32.0	-	-
LSeg+ [46, 28]	-	-	-	10.5	17.1	30.8	56.7	-	-
OpenSeg [28]	-	-	-	21.8	32.1	41.0	57.2	-	-
OpenSeg [28] w/ L. Narr	-	-	-	25.4	39.0	45.5	61.5	-	-
FC-CLIP (ours)	38.4	48.1	21.5	33.4	41.2	54.1	74.9	88.7	98.5

[1] Lu et al. (2024), MathVista — public testmini. PaperQA
https://huggingface.co/datasets/AI4Math/MathVista

例 13 論文の表で条件に合う手法を数える：日本語訳と答え

設問の日本語訳（全文）

表の A-847 のスコアが 20.0 を超える手法はいくつあるか。

正解： 3

A-847 の列では、 OpenSeg の 21.8 、 OpenSeg w/ L. Narr の 25.4 、 FC-CLIP の 33.4 が 20.0 を超える。

[1] Lu et al. (2024), MathVista — public testmini. PaperQA
https://huggingface.co/datasets/AI4Math/MathVista

2. データの構成と参考文献

31 の収集元を組み合わせている

収集元の区分	問題数
数学を主題とする既存 9 データ	2,666
一般的な視覚質問応答 19 データ	2,739
新たな IQTest ・ FunctionQA ・ PaperQA	736
合計	6,141

既存データは 1 件当たり最大 400 問を採用した。

[1] Lu et al. (2024), MathVista.
https://arxiv.org/abs/2310.02255

参考文献

MathVista: Evaluating Mathematical Reasoning of Foundation Models in Visual Contexts

Pan Lu et al. (2024), ICLR 2024.

視覚情報と数学的推論を組み合わせた評価を提案し、構築・注釈・モデルの分析を報告する。

https://arxiv.org/abs/2310.02255

MathVista: Evaluating Math Reasoning in Visual Contexts

MathVista contributors (n.d.; 2026-10-26 参照), GitHub.

データの形式、分割、回答抽出と採点、利用条件を公開する公式実装。

https://github.com/lupantech/MathVista

参考文献

Introducing GPT-4.1 in the API

OpenAI (2025-04-14).

MathVista を含む視覚課題などで、 GPT-4.1 系列と既存モデルを比較する。

https://openai.com/index/gpt-4-1/

MathVista

AI4Math (n.d.; 2026-10-26 参照), Hugging Face.

設問・画像・注釈と、 testmini の参照回答を配布する。

https://huggingface.co/datasets/AI4Math/MathVista