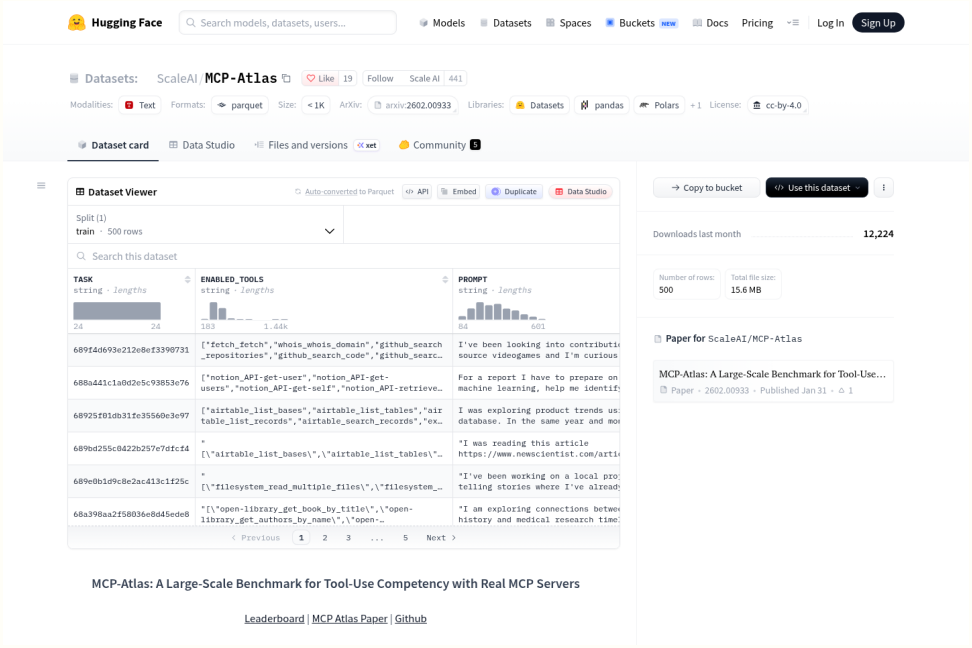
MCP Atlas

外部ツールを組み合わせ、必要な事実をそろえる
実際の MCP サーバーで仕事を進めるエージェント評価

sasakiy84

MCP Atlas の公式配布ページ



Scale AI. MCP-Atlas. CC BY 4.0 。改訂 8c563b5 。 2026-10-16 参照。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas

1. 複数ツールを使う仕事と実例

2. 正解条件による採点とモデル評価

3. 専門家による作成とデータの構成

4. 複数サーバーの連携と利用方法

1. 複数ツールを使う仕事と実例

仕事に必要なツールを選び、結果をつなぐ

- MCP Atlas は、自然言語で頼まれた仕事を、外部ツールを使って完了できるかを評価する。
- MCP （ Model Context Protocol ）は、モデルが外部のデータや機能へアクセスするための共通の接続方式。サーバーは検索・ファイル・データベースなどのツールを提供する。
- 全 1,000 課題は 36 サーバー・ 220 ツールにまたがる。問題文を読み、関連するツールを選んで呼び出し、回答をまとめる。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

一つの依頼から、ツールを使って回答を作る

段階	エージェントが扱うもの
入力	利用者の依頼と、使えるツールの説明
実行	ツール名・引数を選び、返った情報を次の操作に使う
出力	依頼に必要な事実を含む最終回答

各課題には 6 〜 37 のツールを提示する。
正解に必要なものは 2 〜 8 で、似た用途の候補も混ぜる。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

実例は公開されている課題と正解条件を使う

- 全体は公開 500 課題・非公開 500 課題に分かれる。公開側には問題文、使えるツール、回答に必要な事実、参照の操作履歴がある。
- ここでは、公式配布ページで全文を確認できた公開課題から、ゲームの履歴、製品の売上、医学論文の 3 件を紹介する。
- 入力は英語の依頼。採点には、回答が満たすべき事実を列挙した正解条件を使う。

Scale AI. MCP-Atlas. CC BY 4.0 。改訂 8c563b5 。 2026-10-16 参照。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas

実例１：ゲーム開発と公式サイトの年差を調べる

公開課題（原文）

I've been looking into contributions in open source videogames and I'm curious about the longevity of this one open source project. Can you get me the year difference between the creation of the repository of the shooter game assaultcube and the domain registration date of the game's official site

AssaultCube のリポジトリ作成年と、公式サイトのドメイン登録年を調べ、その年差を答える。

Scale AI. MCP-Atlas / 公開 train 。課題 689f4d693e212e8ef3390731 。 CC BY 4.0 。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas/viewer/default/train?row=0

二つの年を取得し、差を計算する

正解条件	配布データが示す答え
リポジトリの作成年	2013 年
公式サイトのドメイン登録年	2006 年
年差	7 年

参照履歴は GitHub で対象リポジトリを確認し、
ドメイン情報を WHOIS で調べ、年差を計算する。

Scale AI. MCP-Atlas / 公開 train 。課題 689f4d693e212e8ef3390731 。 CC BY 4.0 。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas/viewer/default/train?row=0

実例２：宇宙の出来事から売上データをたどる

公開課題（原文）

I was exploring product trends using the cloud database. In the same year and month that SpaceX launched the first car into space, which was the leading product type in commercial performance data? Which was the most sold vehicle in the world for that category in the same year that SpaceX launched the first car into space?

SpaceX が車を宇宙へ打ち上げた年月を調べ、同月の社内売上首位カテゴリと、その年の世界の販売首位車種を答える。

Scale AI. MCP-Atlas / 公開 train 。課題 68925f01db31fe35560e3e97 。 CC BY 4.0 。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas/viewer/default/train?row=2

外部の出来事を、社内データの期間指定へ使う

正解条件	配布データが示す答え
最初の車を宇宙へ打ち上げた年月	2018 年 2 月
同月の売上首位カテゴリ	Electric （電気自動車）
2018 年の同カテゴリの世界首位車種	Tesla Model 3

検索で年月を特定 → Airtable の売上を集計 →
検索でその年の販売首位車種を確認する。

Scale AI. MCP-Atlas / 公開 train 。課題 68925f01db31fe35560e3e97 。 CC BY 4.0 。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas/viewer/default/train?row=2

実例３：医学論文・翻訳・文献史をまとめる

公開課題（原文）

For a report I have to prepare on oncology with machine learning, help me identify the last related study published on november 2024 containing the word cancer in its title and retrieve the abstract of the article. Translate only the title of the study into spanish while keeping the abstract of the study in its original language. Find the type of cancer discussed in the article and tell me who published the first literature and in which year.

Scale AI. MCP-Atlas / 公開 train 。課題 688a441c1a0d2e5c93853e76 。 CC BY 4.0 。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas/viewer/default/train?row=1

論文・翻訳・医学史を正解条件にする

- 対象論文は「 xCG: Explainable Cell Graphs for Survival Prediction in Non-Small Cell Lung Cancer 」。非小細胞肺がんの生存予測を扱う。
- 正解条件は、対象論文の特定、題名のスペイン語訳、原語の要旨、肺がんの初期文献に関する 4 項目。
- 配布正解では、肺がんの最初の文献レビューを Isaac Adler が 1912 年に発表したとしている。

Scale AI. MCP-Atlas / 公開 train 。課題 688a441c1a0d2e5c93853e76 。 CC BY 4.0 。 https://huggingface.co/datasets/ScaleAI/MCP-Atlas/viewer/default/train?row=1

2. 正解条件による採点とモデル評価

回答を、満たすべき事実ごとに採点する

各正解条件の判定	得点
満たしている（ fulfilled ）	1.0
一部を満たす（ partially fulfilled ）	0.5
満たしていない（ not fulfilled ）	0.0

LLM 判定器が、最終回答と各正解条件を照合する。
得点の平均を coverage （正解条件の充足率）とする。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

ゲームの例なら、 3 条件の平均を取る

正解条件	説明用の判定	得点
2013 年のリポジトリ作成	満たす	1
2006 年のドメイン登録	満たす	1
7 年の差	満たさない	0

coverage = (1 + 1 + 0) / 3 ≈ 0.667 。
本論文では 0.75 以上を、その課題の合格とする。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

合格率と、正解条件の充足率を集計する

- 課題ごとの coverage を計算し、 0.75 以上になった課題の割合を合格率として報告する。
- 平均 coverage は、全課題の coverage の平均。部分的に回答できた項目も反映する。
- 参照の操作履歴は、解けることの検証や失敗の分析に使う。合否は、最終回答が正解条件をどれだけ満たすかで決まる。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

論文の改訂版では、上位モデルは約 8 割に達する

モデル／推論設定	合格率
Muse Spark / max	82.2%
Claude Opus 4.7 / max	79.1%
Gemini 3.1 Pro Preview / high	78.2%
GPT-5.5 / xhigh	75.3%

論文 v3 （ 2026 年 5 月）、全 1,000 課題、 coverage ≥ 0.75 。
主判定器は Gemini 3.1 Pro Preview 、 1 課題 100 ツール呼び出し。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

公式モデル比較では、ツール連携を測る

評価データ	扱う仕事
MCP Atlas	複数の MCP サーバーを組み合わせる
τ^2-bench	顧客との対話とツール操作
Terminal-Bench 2.0	端末上の作業を進める
SWE-bench Verified	GitHub の不具合をコード修正で解く

Gemini 3.1 Pro の公式 Performance 表で採用。
MCP Atlas は「 Multi-step workflows using MCP 」と位置付けられている。

Google DeepMind (2026). Gemini 3.1 Pro. Performance: MCP Atlas. 2026-10-16 参照。 https://deepmind.google/models/gemini/pro/

失敗の中心は、得た情報の使い方へ移る

- 論文 v3 では、診断した約 6,900 件の失敗の 63.3% を、課題理解・情報統合・途中終了などの認知側の失敗に分類した。
- ツール呼び出し側の失敗は 36.7% 。引数の誤り、ツール選択、ツールを使わないこと、エラーからの復帰が含まれる。
- 情報を取得できても、必要な証拠をそろえる前に終えたり、結果を取り違えて回答したりする課題が残る。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

3. 専門家による作成とデータの構成

専門家が、外部データの必要な仕事を作る

- 課題作成者は、検索・業務アプリ・コード・分析・金融などの実際の MCP サーバーを使い、複数段階で解く依頼を作る。
- 問題文は自然な依頼として書き、意図したサーバー名やツール名、引数を直接指定しない。
- 参照の操作履歴と、ツールの返した情報に基づく最終回答を用意する。 1 課題の作成・検証・文書化は平均 4.6 時間。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

回答に必要な事実を、独立した条件へ分ける

- 正解条件は、個別に確かめられる事実へ分ける。全体では 1 課題平均 4.7 項目で、範囲は 1 〜 23 項目。
- 専門家による作成と、自動生成した条件の候補の人手レビューを組み合わせて、条件の完全性と根拠を確かめる。
- 各課題の提示ツールには、必要な機能に加え、用途が似ている候補を混ぜる。ツールの説明から適切なものを選ぶ能力も調べる。

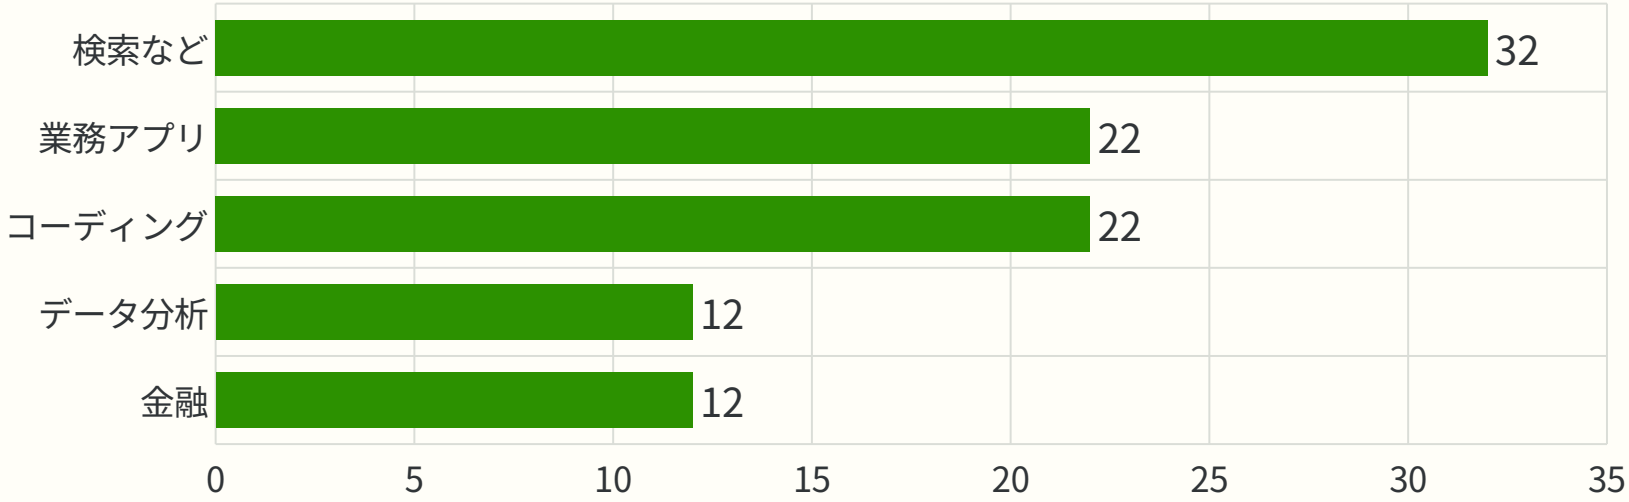
Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

実行・専門家レビュー・自動検証を重ねる

品質確認	確かめる内容
作成者が参照履歴を実行	設定した環境で課題が解けるか
分野の専門家がレビュー	正解と解決可能性
別のレビュー	依頼文にツール名などが漏れていないか
LLM による確認	正解条件の完全性と操作履歴との対応
無作為な標本の人手監査	課題と正解条件の品質

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

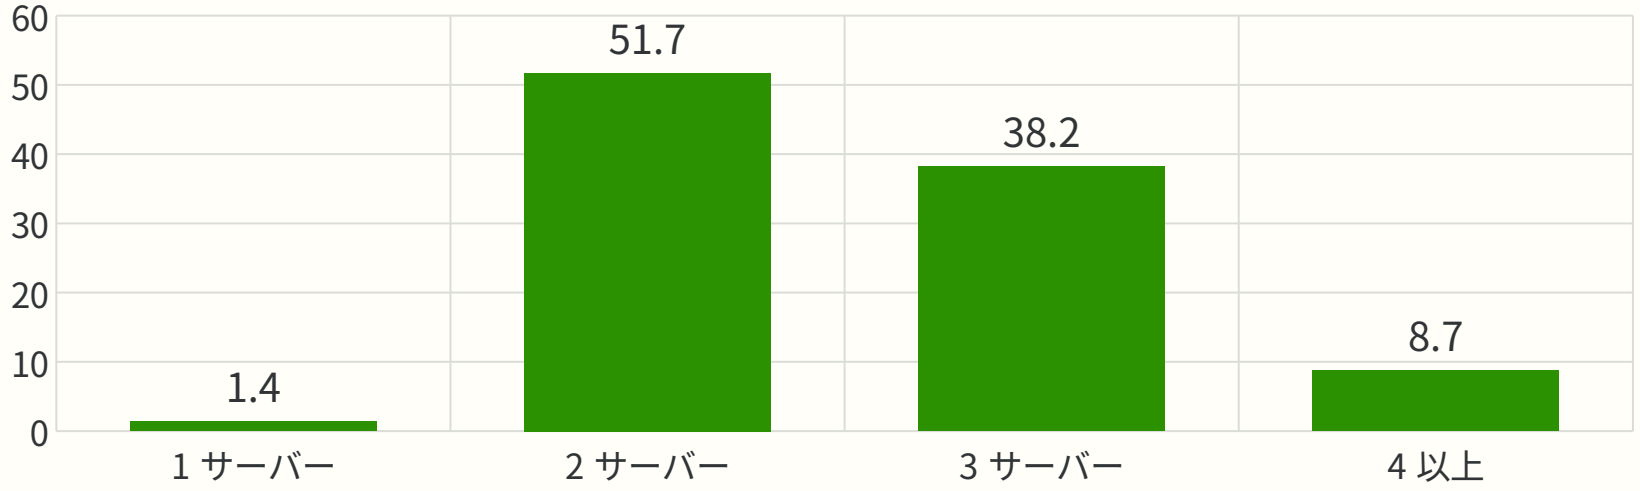
課題は検索・業務・コード・分析・金融に広がる



全 1,000 課題の分野別割合（％）。論文 v3 の分類。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

98.6% の課題で、複数のサーバーを使う



全 1,000 課題の必要サーバー数の割合（％）。平均 2.55 。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

公開 500 課題には、依頼と正解条件を配布する

分割	課題数	入手できるもの
公開	500	依頼・提示ツール・正解条件・参照履歴
非公開	500	運営側で保持する評価用の課題

全 1,000 課題を無作為に 500 / 500 へ分割。
Hugging Face では公開 500 課題を train という split 名で配布。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

4. 複数サーバーの連携と利用方法

MCP サーバーを固定したコンテナーで動かす

役割	使うもの
ツールの実行環境	36 サーバーを Docker 内に用意
モデルの実行	モデルとツールの間で操作を繰り返す
採点プログラム	最終回答と正解条件を LLM で照合する

検索や外部 API にはライブ接続を使う。
サーバーの実装・依存関係は版を固定し、実行条件を記録する。

Scale AI. MCP-Atlas: evaluation harness and instructions. 改訂 5c11ac4 。 https://github.com/scaleapi/mcp-atlas

データ公開と、論文・実行環境の更新が続く

- 2025 年 12 月、 Hugging Face に 500 課題の Parquet を登録。 2026 年に論文を公開し、 5 月の論文 v3 では 20 モデルを比較した。
- 公開リポジトリのエージェント実行プログラムは、バージョン 2.0.0 で Python から TypeScript へ移行した。採点・診断は Python で提供する。
- データの改訂、論文の改訂、実行プログラムのバージョンを指定して、同じ構成で評価を再実行する。

Scale AI. MCP-Atlas: Changelog, agent harness v2.0.0. 改訂 5c11ac4 。 https://github.com/scaleapi/mcp-atlas/blob/5c11ac4/CHANGELOG.md

公開課題を実行し、回答を保存する

```
python run_eval.py \
  --model "provider/model-name" \
  --num-tasks 1 \
  --output runs/model/outputs.csv
```

公式バッチ実行の例。接続するモデルを指定し、最初の 1 課題を実行する。モデルと必要な外部サービスの API キーを設定し、 MCP 環境と実行プログラムを起動して使う。

Scale AI. MCP-Atlas: evaluation harness and instructions. 改訂 5c11ac4 。 https://github.com/scaleapi/mcp-atlas

ツール選択と、回答をそろえる完了判断を測る

- MCP Atlas は、自然な依頼に対して、必要なツールを探し、複数サーバーの結果をつないで回答を作る評価。
- 専門家が用意した正解条件により、最終回答を事実ごとに採点する。課題の合否と部分的な充足率を集計できる。
- 公開 500 課題と実行・採点コードを配布し、 20 モデルの比較では上位モデルが約 8 割の課題に合格した。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

Appendix

1. 追加の課題と分布

2. 版・実装と評価条件

3. 著者と参考文献

1. 追加の課題と分布

広告の論文と、社内キャンペーンを照合する

- 論文の追加例は、広告の効果に関する 2024 年の Jane Castleman の論文の要旨を探し、社内の広告データと照合する依頼。
- 2015 ～ 2023 年に始まったキャンペーンから、反応率が最大のものの日付と地域を答える。
- arXiv で論文を検索し、 Notion で広告データベースを探して照会する。正解条件には、論文、要旨、最大値、該当日、地域を含む。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

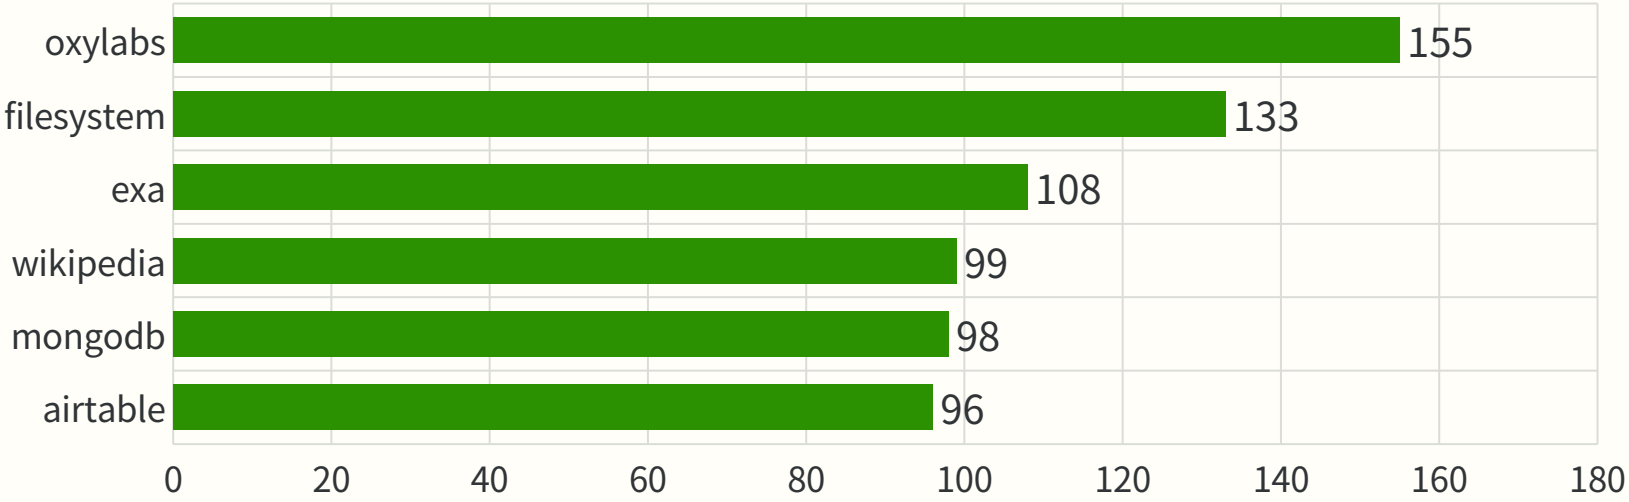
最高の反応率は 3 件で同率になっている

正解条件	論文が示した内容
最大の反応率	15% （3 キャンペーンで同率）
開始日	2022-06-24 / 2019-09-20 / 2017-09-09
地域	National / International / International

Jane Castleman の広告研究と社内データを照合する公開例。
日付と地域は同じ順に対応する。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

36 サーバーのうち、検索系は多くの課題で使う



論文 v3 、全 1,000 課題の必要サーバー上位 6 件（課題数）。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

提示する候補から、必要なツールを選ぶ

構成	平均	範囲
提示ツール	15.2	6 〜 37
必要ツール	4.1	2 〜 8
正解条件	4.7	1 〜 23

全 1,000 課題の論文集計。
参照の操作履歴は、 1 課題平均 9.8 ツール呼び出し。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

ツール呼び出しの失敗を 4 種類に分ける

失敗の種類	何が起きたか
引数の誤り	不正な形式や値で呼び出す
ツールの選択違い	依頼を解けないツールを選ぶ
ツールを使わない	必要な外部データを取得しない
エラーから復帰できない	呼び出し失敗の後、修正や代替を試さない

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

理解・情報統合・完了判断の失敗は 7 種類

失敗の種類	何が起きたか
課題の取り違え	依頼とは異なる質問に答える
情報の統合ミス	取得した事実を誤って組み合わせる
結果の読み違い	別の行やフィールドを読み取る
途中終了	必要な証拠がそろう前に回答する
事実の捏造	得ていない事実を回答に含める
論理の誤り	計算や推論を間違える
制約違反	期間・形式などの指定を守らない

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

2. 版・実装と評価条件

論文の改訂版は、判定器を変えた結果も示す

評価対象	Gemini 判定	GPT 判定	Claude 判定
Muse Spark	82.2%	79.1%	79.6%
Claude Opus 4.7	79.1%	75.1%	74.5%
Gemini 3.1 Pro Preview	78.2%	75.8%	76.4%

論文 v3 、全 1,000 課題、 coverage ≥ 0.75 。判定器は順に
Gemini 3.1 Pro Preview / GPT-5.4 / Claude Opus 4.6 。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

合格の閾値を変えると、合格率も変わる

モデル	0.50 以上	0.75 以上	0.90 以上
Muse Spark	89.6%	82.2%	71.2%
Claude Opus 4.7	89.5%	79.1%	63.2%
Gemini 3.1 Pro Preview	90.6%	78.2%	61.8%

論文 v3 、全 1,000 課題。各列は coverage の合格閾値。
主結果では 0.75 を使う。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

データと実行環境の利用条件を確認する

- 問題文・正解条件・参照履歴などの配布データは CC BY 4.0 。転載・翻訳では出典と変更内容を示す。
- 取得した公開コードの LICENSE は MIT 。論文 v3 の Apache 2.0 という説明に対し、コードの利用条件は当該リポジトリの実ファイルを確認する。
- 実際の MCP サーバーは、それぞれのライセンスと外部 API の利用条件に従う。公開環境では 20 サーバーが鍵不要、残りは API キーやデータ設定が必要。

Scale AI. MCP-Atlas: evaluation harness and instructions. 改訂 5c11ac4 。 https://github.com/scaleapi/mcp-atlas

3. 著者と参考文献

Scale AI と研究者が、課題と採点方式を設計した

- 共同第一著者は Chaithanya Bandi と Razvan-Gabriel Dumitru 。論文では Bandi の所属を National University of Singapore 、他の著者を Scale AI と記載する。
- 最終著者は Bing Liu 。課題、実際の MCP サーバーを使う実行環境、正解条件による評価と失敗診断をまとめて公開した。
- 本資料の論文結果は 2026 年 5 月 19 日の v3 に基づく。データ配布は 2025 年 12 月からの改訂履歴を確認した。

Bandi, Dumitru et al. (2026). MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers. 論文 v3 。 https://arxiv.org/abs/2602.00933v3

参考文献

MCP-Atlas: A Large-Scale Benchmark for Tool-Use Competency with Real MCP Servers

Chaithanya Bandi, Razvan-Gabriel Dumitru et al. / 2026 / v3

課題の設計、専門家による検証、正解条件の採点と 20 モデルの比較。

https://arxiv.org/abs/2602.00933v3

MCP-Atlas

Scale AI / Hugging Face Datasets / CC BY 4.0 / 改訂 8c563b5

公開 500 課題の依頼文、ツール、正解条件、参照の操作履歴を配布する。

https://huggingface.co/datasets/ScaleAI/MCP-Atlas

参考文献

MCP-Atlas: evaluation harness and instructions

Scale AI / GitHub / 改訂 5c11ac4

サーバーの設定と、モデル実行・採点・失敗診断の手順を提供する。

https://github.com/scaleapi/mcp-atlas

MCP-Atlas: claim-coverage scoring

Scale AI / GitHub / 改訂 5c11ac4

各正解条件の判定を 0 ・ 0.5 ・ 1 へ対応させ、充足率と合格率を計算する。

https://github.com/scaleapi/mcp-atlas/blob/5c11ac4/services/scoring/score_claims.py

参考文献

MCP-Atlas: Changelog

Scale AI / Agent harness v2.0.0 / 改訂 5c11ac4

実行プログラムの TypeScript への移行と、採点・診断機能を説明する。

https://github.com/scaleapi/mcp-atlas/blob/5c11ac4/CHANGELOG.md

Gemini 3.1 Pro

Google DeepMind / 2026 / Model performance

MCP Atlas を含む、現行モデルの公式比較と推論設定を掲載する。

https://deepmind.google/models/gemini/pro/