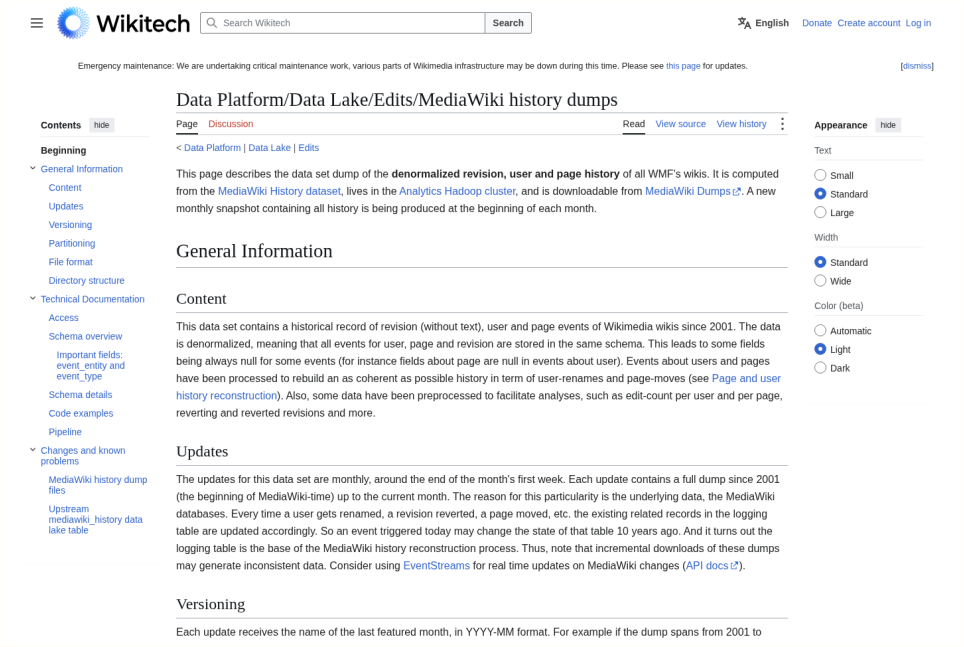
MediaWiki History

Wikipedia などの編集・ページ・利用者の履歴データ

sasakiy84

1. 編集履歴に含まれる情報
2. 履歴の再構成とファイル形式
3. 規模・分析例と利用方法

公式ドキュメント



[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

1. 編集履歴に含まれる情報

編集の履歴に、当時のページ情報を付ける

- Wikimedia の各ウィキについて、編集・ページの移動や削除・利用者の変更を、一つの表にまとめた分析用データである。
- 記事の本文は含まない。編集日時、本文のバイト数、当時の記事名、編集者の属性などを調べられる。
- 公開 TSV は 2020 年 1 月に提供が始まった。毎月、過去にさかのぼって履歴を作り直した版を配布する [1]。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

1 回の編集を、前の版と結び付ける

```
event_entity / event_type revision / create
event_timestamp           2005-07-11 15:16:49.0
revision_id               6835
revision_parent_id        6825
revision_text_bytes_diff  2
```

ナウル語版 Wikipedia の記事「 Ukraina 」の実レコードから主要列を抜粋した。版 6835 では、直前の版 6825 より本文が 2 バイト増えている。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

記事の作成と、版の作成は別のイベント

対象・種類	意味
revision / create	編集によって新しい版ができた
page / create	ページの履歴が始まった
user / create	利用者アカウントが作られた

同じ create でも、 event_entity が何を指すかによって意味が変わる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

記事名が変わっても、ページをたどれる

イベント日時	当時の記事名	公開版での記事名
2005-07-11	Ukraina	Iukrain
2005-07-12	Ukraine	Iukrain

同じ page_id 1967 の編集・移動レコード。 historical 列は当時の値、接尾辞のない列は 2026-09 版の値を示す。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

差し戻された編集と、戻した編集を追う

版 ID	本文の増減（B）	履歴上の関係
94	−4,818	版 95 によって差し戻された
95	4,818	以前と同じ本文へ戻した

nawiki の同じページで 2004-03-19 に記録された 2 編集。本文が以前と一致する差し戻しを検出した情報が付く。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

本文コーパスやライブ配信とは役割が異なる

- 本文を読みたい場合は、記事本文を配布する Content File Exports などを使う。 MediaWiki History は編集や管理操作の履歴を扱う。
- EventStreams は、発生した変更を継続して受け取る配信である。 MediaWiki History は、長い期間を一括して分析する月次のデータである。
- 例えば、記事の改名を考慮した編集回数の推移や、編集が差し戻されるまでの時間を調べる用途に向く。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps
[2] Wikimedia Foundation, n.d. MediaWiki Content File Exports （参照 2026-10-28 ） https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

2. 履歴の再構成とファイル形式

管理ログから、ページや利用者の履歴を復元

- データベースに残る現在の状態と、改名・移動・削除・復元などの管理ログを組み合わせる。
- ログを時間をさかのぼって処理し、記事名や利用者名が変わる前後を、ページ ID ・利用者 ID に結び付ける。
- 古いログの形式をそろえ、編集回数や差し戻しの情報を追加する。復元には欠落や矛盾の処理も含まれる [1] 。

[1] Wikimedia Foundation, n.d. Page and user history reconstruction （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Systems/Page_and_user_history_reconstruction

78 列を、五つのまとまりで読む

まとまり	主な情報
イベント全体	対象、操作の種類、日時、コメント
操作した利用者	ID 、当時と公開版時点の属性
ページ	ID 、記事名、名前空間、編集回数
対象となった利用者	アカウントの ID 、名前、権限など
版	親の版、サイズ、差し戻しなど

2026-09 版は 78 列。名前空間は、記事・カテゴリなどのページの用途を表す。利用者イベントでは、ページ・版の列は空欄になる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

配布形式は、見出し行のない圧縮 TSV

- 各行は一つのイベントで、列はタブで区切られている。ファイルは Bzip2 で圧縮され、公式スキーマの列順に読む。
- 空欄は未定義値を表す。配列はカンマ区切りで保存され、値の中のカンマはエスケープされる。
- 文字列中の改行やタブもエスケープされるため、単純な行・列の区切りを保ったまま扱える。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

操作した人と、変更された対象を表す

列	何を識別するか
event_user_id	イベントを起こした利用者
user_id	利用者イベントで変更の対象となった利用者
page_id	編集・ページイベントの対象ページ
revision_id	編集によって作られた版

ローカルな ID は wiki_db と組み合わせる。複数ウィキの利用者を対応させる中央 ID の列もある。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

当時の状態と、公開版の状態を選べる

- 例えば page_title_historical はイベント時点の記事名、page_title は選んだ公開版の時点での記事名である。
- 同じ区別は利用者名・権限・ボットの判定などにもある。当時の編集を分類するなら historical 側の属性を使う。
- 編集回数の累計や直前の編集からの秒数もあり、編集活動の量や編集間隔を分析できる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

削除された版の情報も、公開範囲に沿って収録

- ページ削除によって通常の版一覧から外れた版も、削除状態や削除日時を示す列で扱う。
- 版の本文・コメント・利用者情報のうち、非表示になった部分を示す列がある。利用者情報が非表示の版では、対応する名前や ID が空欄になる。
- 本文そのものは収録しない。削除・非表示の状態は履歴分析に必要な属性として読める [1]。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

月次更新では、過去のレコードも変わる

- 毎月、履歴全体を再構成したスナップショットを公開する。 2026-09 版は 2026 年 9 月までを収め、 10 月 5 日に配布されている。
- 後の改名やページ移動、差し戻しによって、過去のレコードに付く情報も変わる。そのため、分析には一つの公開版を選んで使う。
- 公開ディレクトリには原則として直近 2 版が置かれる。確認時点では 2026-08 版と 2026-09 版を取得できる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps
[2] Wikimedia Foundation, 2026. MediaWiki History 配布ディレクトリ（参照 2026-10-28 ） https://dumps.wikimedia.org/other/mediawiki_history/

ウィキの大きさに応じてファイルを分ける

分割単位	実際の配布例
月別	enwiki 、 commonswiki 、 wikidatawiki
年別	jawiki など
全期間を 1 ファイル	nawiki などの小規模ウィキ

URL は「公開版 / wiki_db / 公開版 .wiki_db. 対象期間 .tsv.bz2 」の形になる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

3. 規模・分析例と利用方法

小規模なウィキなら、全履歴を手元で読める

2026-09 版 nawiki	規模
イベント行数	116,372
編集の行数	90,024
ページ関連の行数	13,000
利用者関連の行数	13,348

ナウル語版 Wikipedia の全期間ファイルを集計。圧縮容量は約 6.2 MB 。収録イベントは 2003 年 8 月〜 2026 年 9 月。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

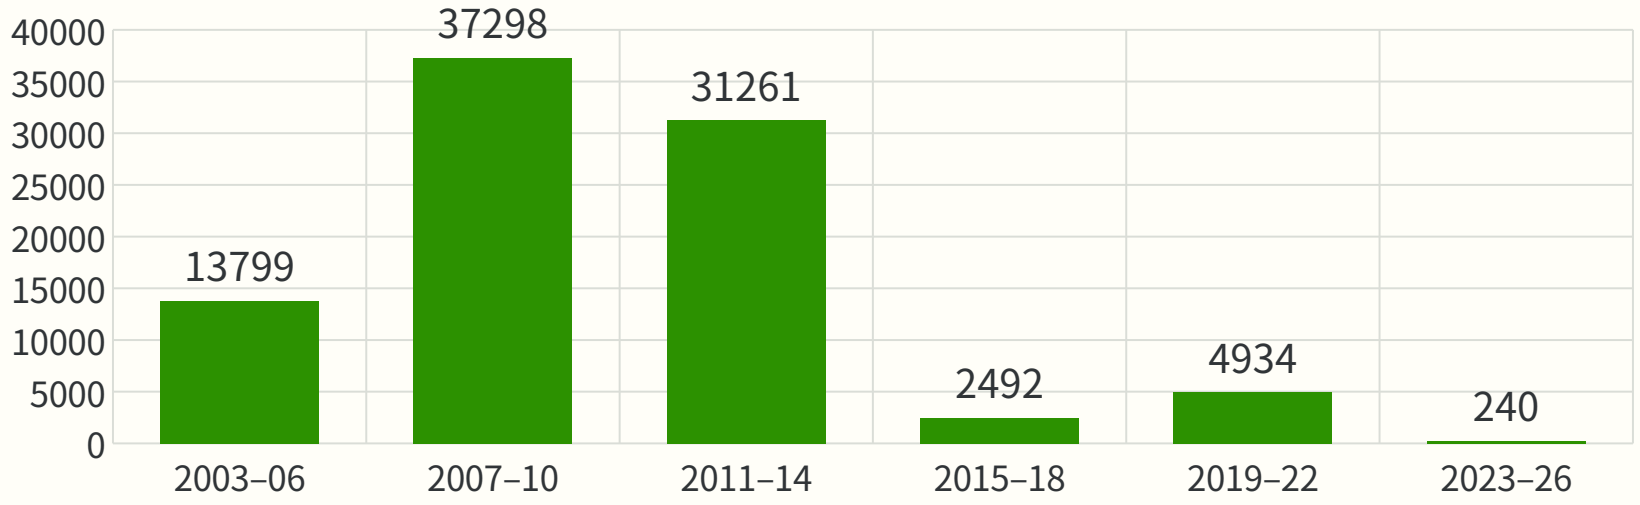
ページ関連では、移動や復元も記録される

イベントの種類	行数
削除 delete	5,989
作成 create	5,820
作成ログ create-page	916
移動 move	261
復元 restore	14

同じ nawiki 全件。行数はイベント数であり、重複を除いたページ数ではない。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

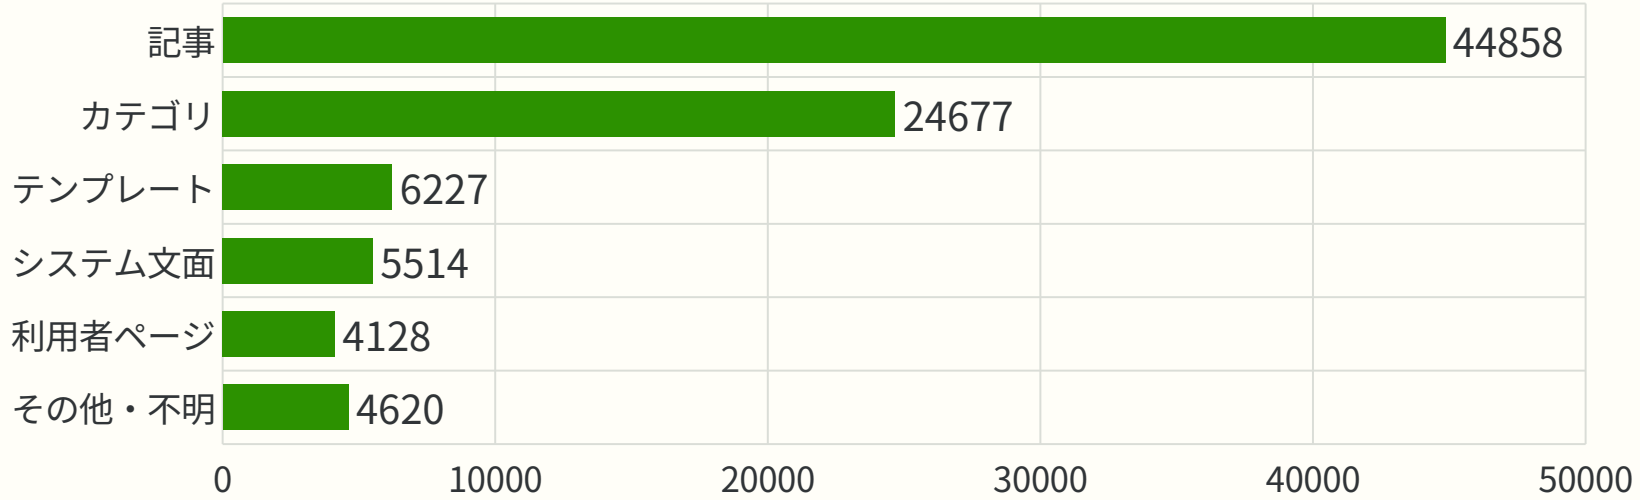
編集の推移を、長い期間にわたって集計する



nawiki の全名前空間・ revision/create を 4 年ごとに合計（件）。 2026 年は 9 月まで。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

記事以外にも、編集の対象がある



nawiki の編集 90,024 件を、イベント当時の名前空間で集計。名前空間はページの用途を表す分類。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

公開版・ウィキ・期間を選んで取得する

- 配布ディレクトリで公開版を選び、 wiki_db のフォルダから必要な期間の .tsv.bz2 を取得する。
- 例えば nawiki は all-time を 1 本、 jawiki は必要な年のファイルを選べる。
- 必要なウィキと分析期間を選んで取得できる。小規模なウィキを選べば、全履歴の読み込みや集計を手元で試しやすい。

[1] Wikimedia Foundation, 2026. MediaWiki History 配布ディレクトリ（参照 2026-10-28 ） https://dumps.wikimedia.org/other/mediawiki_history/

圧縮ファイルから、編集イベントを数える

```
import bz2, csv
path = "2026-09.nawiki.all-time.tsv.bz2"
with bz2.open(path, "rt", encoding="utf-8") as f:
    rows = csv.reader(f, delimiter="\t",
                      quoting=csv.QUOTE_NONE)
    n = sum(r[2:4] == ["revision", "create"] for r in rows)
print(n)
```

列２・３（０始まり）が対象と種類に対応する。上のコードを nawiki 全件で実行すると 90024 を得る。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

改名をまたぐ分析や、過去の状態の集計に使う

- 記事の移動前後を同じページとして追い、長期の編集回数や編集間隔を集計する。
- 当時の名前空間やボット属性で編集を分類し、記事・カテゴリなどの編集活動の違いを調べる。
- 差し戻しの有無や、差し戻しまでの時間を使って、編集がどのように修正されたかを調べる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

データは CC0 で公開されている

- 配布案内では、 Analytics データセットに Creative Commons CC0 を適用すると明示されている。
- 実レコードには公開の利用者名や、過去に公開された IP アドレスが含まれる場合がある。分析では必要な属性を選んで扱う。
- ドキュメント本文は別途 CC BY-SA で公開されている。データの再利用条件は、データの配布案内で確認できる。

[1] Wikimedia Foundation, n.d. MediaWiki History Data （参照 2026-10-28 ） https://dumps.wikimedia.org/other/mediawiki_history/readme.html
[2] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

編集活動を、当時の文脈とともに分析する

- MediaWiki History は、編集・ページ・利用者の変更を共通の表にまとめた、 Wikimedia 公式の派生データである。
- 改名や移動を考慮して復元した履歴に、当時と公開版時点の属性、編集回数、差し戻しの情報が付く。
- 毎月の公開版からウィキと期間を選び、本文を取得せずに、長期の編集活動を分析できる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

Appendix

1. 異なるレコードの追加例
2. 列の選び方と参考文献

地名の表記変更を記録する

```
event_entity                page
event_type                  move
event_timestamp             2005-08-24 15:16:44.0
page_id                     1249
page_title_historical       Krakow
page_title                  Kraków
```

Krakow の移動イベントには、公開版時点の記事名 Kraków も付く。同じページを、名前の表記が変わっても対応させられる。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

削除した記事を復元した記録

```
event_entity                    page
event_type                      restore
event_timestamp                 2017-03-16 09:54:47.0
page_id                         2163
page_title_historical           Keniya
```

記事 Keniya には 2017 年の復元イベントがある。復元は新しい版を作る編集とは別の、ページに対する操作として記録される。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

テンプレートの編集も同じ形式で読む

```
event_entity                revision
event_type                  create
page_namespace_historical   10
page_title_historical       Sitesupportpage
revision_text_bytes_diff    23
```

名前空間 10 はテンプレートを表す。記事だけの編集を集計する場合は、名前空間の条件を付ける。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

カテゴリの編集も、記事の編集と区別できる

```
event_entity                    revision
event_type                      create
page_namespace_historical       14
page_title_historical           Kadudu
revision_text_bytes_diff        11
```

名前空間 14 はカテゴリを表す。カテゴリ用のページを編集した記録も、 revision/create の行になる。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

アカウント作成の行には、版の情報がない

```
event_entity                    user
event_type                      create
event_timestamp                 2003-08-09 22:34:36.0
page_id                         (empty)
revision_id                     (empty)
```

利用者イベントは同じ 78 列に入るが、ページ ID と版 ID は空欄になる。変更の対象となった利用者の情報は、 user_ で始まる列に入る。

[1] Wikimedia Foundation, 2026. MediaWiki History 2026-09, nawiki （全件を集計） https://dumps.wikimedia.org/other/mediawiki_history/2026-09/nawiki/

分析の目的から、使う列を選ぶ

調べたいこと	主な列
編集回数の推移	event_entity 、 event_type 、 event_timestamp
記事名の変更前後	page_id 、 page_title_historical 、 page_title
当時のボットの編集	event_user_is_bot_by_historical
差し戻しまでの時間	revision_seconds_to_identity_revert

列名・型・定義は公式スキーマで確認できる。データ内の空欄は、対象や記録の状態に応じて生じる。

[1] Wikimedia Foundation, n.d. MediaWiki history dumps （参照 2026-10-28 ）
https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

参考文献

Data Platform/Data Lake/Edits/MediaWiki history dumps

Wikimedia Foundation, n.d. Wikitech （参照 2026-10-28 ）

公開ファイルの構成、列の意味、更新の方式をまとめた公式文書。

https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history_dumps

Data Platform/Systems/Page and user history reconstruction

Wikimedia Foundation, n.d. Wikitech （参照 2026-10-28 ）

管理ログから、移動・改名を含むページと利用者の履歴を復元する方法を説明する。

https://wikitech.wikimedia.org/wiki/Data_Platform/Systems/Page_and_user_history_reconstruction

参考文献

Data Platform/Data Lake/Edits/MediaWiki history

Wikimedia Foundation, n.d. Wikitech （参照 2026-10-28 ）

元となる分析用テーブルと、スキーマの変更履歴を記載する。

https://wikitech.wikimedia.org/wiki/Data_Platform/Data_Lake/Edits/MediaWiki_history

MediaWiki History Data

Wikimedia Foundation, n.d. Wikimedia Downloads （参照 2026-10-28 ）

配布データの概要、作成処理への入口と CC0 の適用を案内する。

https://dumps.wikimedia.org/other/mediawiki_history/readme.html