MedQA

医師資格試験の問題から医学知識を問う

sasakiy84

公式配布案内： MedQA

README MIT license

Code and data for MedQA

This is the data and baseline source code for the paper: Jin, Di, et al. "What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams." arXiv preprint arXiv:2009.13081 (2020). If you would like to use the data or code, please cite the paper:

```
@article{jin2020disease,
  title={What Disease does this Patient Have? A Large-scale Open Domain Question Answering Data
  author={Jin, Di and Pan, Eileen and Oufattole, Nassim and Weng, Wei-Hung and Fang, Hanyi and
  journal={arXiv preprint arXiv:2009.13081},
  year={2020}
}
```

Data

The data that contains both the QAs and textbooks can be downloaded from this google drive folder. A bit of details of data are explained as below:

- For QAs, we have three sources: US, Mainland of China, and Taiwan District, which are put in folders, respectively. All files for QAs are in jsonl file format, where each line is a data sample as a dict. The "XX_qbank.jsonl" files contain all data samples while we also provide an official random split into train, dev, and test sets. Those files in the "metamap" folders are extracted medical related phrases using the Metamap tool.
- For QAs, we also include the "4_options" version in for US and Mainland of China since we reported results for 4 options in the paper.

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（2026-10-18 取得）。 https://github.com/jind11/MedQA

1. 医学の問題と実例
2. 3 言語の構成と作成方法
3. 評価方法と HELM の範囲
4. 入手と再現の手順

1. 医学の問題と実例

症状や医学知識から、最も適切な答えを選ぶ

- MedQA は、医師資格試験や模擬試験の問題を集めた多肢選択式のデータセット。患者の症状、機序、検査、治療などを問う。
- 質問と選択肢が入力で、正解は選択肢のうち一つ。症例の記述から複数の医学知識を結び付ける問題も含む。
- ここでは全体の 3 言語版を紹介し、 HELM が読む米国版の英語・ 4 択データから実例を示す。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

質問・選択肢・正解を一つのレコードに持つ

- question は問題文、 options は文字 A ～ D と選択肢本文の対応。 answer_idx が正解の文字、 answer がその本文を表す。
- 実例では質問と全選択肢の原文を省略せず、日本語訳と並べる。正解は配布データの注釈を保つ。
- 本編 3 例と付録 10 例は、短い問題を中心に内容の違いが分かるよう選んだ。全体の問題分布を代表する標本ではない。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（ 2026-10-18 取得）。 https://github.com/jind11/MedQA

実例 1 ：血友病 A の遺伝を考える

US ・ 4 択／ test JSONL 268 行目／ step1

原文：質問と全選択肢（全文）

A 34-year-old male suffers from inherited hemophilia A. He and his wife have three unaffected daughters. What is the probability that the second daughter is a carrier of the disease?

A. 0%
B. 25%
C. 50%
D. 100%

日本語訳：質問と全選択肢

34 歳の男性は遺伝性血友病 A を患っている。妻との間には、発症していない娘が 3 人いる。2 番目の娘がこの病気の保因者である確率はどれか。

A. 0%
B. 25%
C. 50%
D. 100%

正解： D　100%

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

数値の答えにも、医学の前提が必要になる

- 実例 1 の正解は D の 100% 。血友病 A の遺伝様式を踏まえて、娘が保因者となる確率を選ぶ。
- 単純な計算問題のように見えても、病気、遺伝様式、性別と親子関係を読み取る必要がある。
- 選択肢の数値は 0% 、 25% 、 50% 、 100% 。 4 択版では、 5 択版にあった 75% の誤答が取り除かれている。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例２：薬剤による検査値の変化

US ・ 4 択／ test JSONL 837 行目／ step1

原文：質問と全選択肢（全文）

A 72-year-old anthropologist with long-standing hypertension visits your office for a routine exam. You notice an abnormality on his laboratory results caused by his regimen of captopril and triamterene. What abnormality did you most likely find?

A. Hyperkalemia
B. Hypernatremia
C. Thrombocytopenia
D. Anemia

日本語訳：質問と全選択肢

長年高血圧を患っている 72 歳の人類学者が定期診察に来た。カプトプリルとトリアムテレンの服用による検査値の異常が見つかった。最も考えられる異常はどれか。

A. 高カリウム血症
B. 高ナトリウム血症
C. 血小板減少症
D. 貧血

正解： A　高カリウム血症

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

薬剤名と、起こり得る変化を結び付ける

- 実例２は、カプトプリルとトリアムテレンを服用している患者の検査値を問う。注釈の正解は高カリウム血症。
- 年齢や職業だけで答えを選ぶのではなく、薬剤の組合せと選択肢の検査所見を結び付ける。
- 疾患名だけでなく、副作用、機序、検査、対応する処置まで、多様な形で医学知識を問える。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例３：放射線の作用を問う

US ・ 4 択／ test JSONL 51 行目／ step1

原文：質問と全選択肢（全文）

A 65-year-old male is treated for anal carcinoma with therapy including external beam radiation. How does radiation affect cancer cells?

A. Induces the formation of thymidine dimers
B. Induces the formation of disulfide bonds
C. Induces deamination of cytosine
D. Induces breaks in double-stranded DNA

日本語訳：質問と全選択肢

65 歳の男性が肛門癌に対し、外照射を含む治療を受けている。放射線は癌細胞にどのような作用を及ぼすか。

A. チミジン二量体の形成を誘導する
B. ジスルフィド結合の形成を誘導する
C. シトシンの脱アミノ化を誘導する
D. 二本鎖 DNA の切断を誘導する

正解： D　二本鎖 DNA の切断を誘導する

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

知識の直接照合から、症例の推論まで含む

- 実例 3 は、放射線の作用として二本鎖 DNA の切断を選ぶ。症例の背景と、細胞に起こる機序を対応させる。
- 構築時には、知識を直接問う問題と、複数の根拠を要する症例問題を人手で分類した。
- 米国版 dev から無作為抽出した 100 問では、症例に基づく第 2 の型が 98% 。この割合は全件への自動注釈ではない。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

2. 3 言語の構成と作成方法

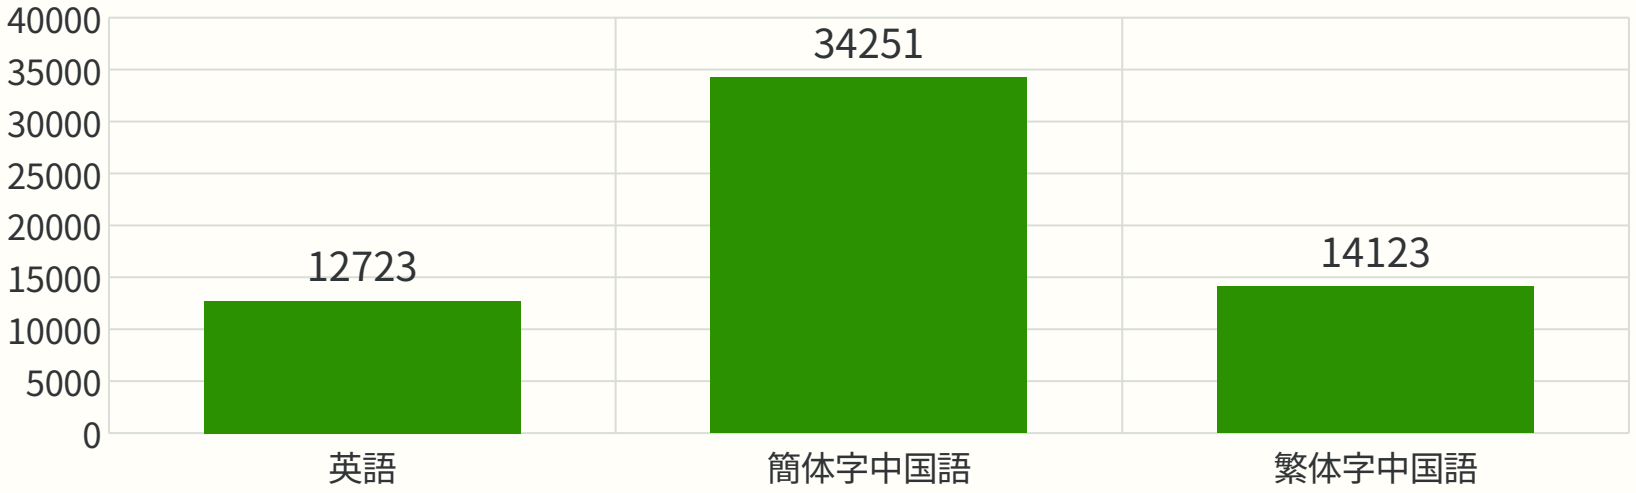
3 言語・ 3 地域、合計 61,097 問

版	言語	問題数	HELM
USMLE	英語	12,723	4 択版を使用
MCMLE	簡体字中国語	34,251	対象外
TWMLE	繁体字中国語	14,123	対象外

地域ごとに収集した問題であり、同じ問題の 3 言語翻訳ではない。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081
[2] Stanford CRFM (2023). MedQAScenario. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/med_qa_scenario.py

簡体字中国語版が最も多い



問題数。 3 版を合わせて 61,097 問。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

公開されている試験・模擬問題を集めた

- 米国、中国本土、台湾の医師資格試験に関する問題を、公開 Web サイトから収集した。実際の試験問題と模擬問題の両方を含む。
- 米国版の出所には Medbullets 、 AMBOSS 、 Lecturio などがある。台湾版は試験機関の公開問題を使う。
- 教科書の段落を知識源として別に用意し、検索した根拠を使って選択肢を解く OpenQA を設計した。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

4 択版では、誤答を一つ減らしている

- US と Mainland の通常 split は 5 択。 4_options 版では誤答の一つを除き、正解 1 件と誤答 3 件にする。論文は選択肢順の並べ替えも説明している。
- 台湾版は 4 択。 3 版の論文実験は、いずれも 4 択で報告された。
- HELM の実装は US/4_options だけを読み、全レコードが 4 択であることを検査する。 docstring の 5 択例とは区別する。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081
[2] Stanford CRFM (2023). MedQAScenario. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/med_qa_scenario.py

公式 split は、およそ 80 ： 10 ： 10

版	train	dev	test
USMLE	10,178	1,272	1,273
MCMLE	27,400	3,425	3,426
TWMLE	11,298	1,412	1,413

配布された split ファイルの件数も直接集計し、全 9 値が一致した。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

同じ問題でも、正解の文字は変わる

版	実例 1 の選択肢	正解
通常の 5 択	A:0% B:25% C:50% D:75% E:100%	E
4_options	A:0% B:25% C:50% D:100%	D

質問と正解本文は同じ。文字だけを別の版から流用せず、選択肢の対応を保持する。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（2026-10-18 取得）。 https://github.com/jind11/MedQA

3. 評価方法と HELM の範囲

構築時は、教科書を検索してから選択肢を解く

- 論文の OpenQA は、質問・候補の答えと、教科書から抽出した文書集合を使う。検索器と読解モデルを組み合わせる。
- 英語の教科書 18 冊と簡体字中国語の教科書 33 冊を収集し、段落に分けた。台湾版の実験では問題を英語に翻訳して英語側の知識源を使う。
- 用意した教科書の根拠を検索できるかと、根拠から正しい選択肢を推論できるかの両方が成績に関わる。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

構築時の最良テスト正解率にも差がある

版	最良の方式	正解率
USMLE	BioBERT-Large	36.7%
MCMLE	RoBERTa-Large-wwm-ext	70.1%
TWMLE	BioBERT-Large	42.0%

検索＋読解による 2020 年の報告。各版は 4 択、偶然の選択は 25% 。言語間で問題も方式も異なる。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

HELM は、選択肢を並べて文字を生成させる

- get_med_qa_spec は multiple_choice_joint を指定し、Question 、 A 〜 D の候補、 Answer を一つのプロンプトに並べる。
- 指示は「 Give a letter answer among A, B, C or D. 」。モデルが生成した文字を、その問題の選択肢本文へ対応付けて採点する。
- この設定は教科書検索を組み込まない。構築時の検索＋読解方式とは、モデルに渡す情報が異なる。

[1] Stanford CRFM (2023). get_med_qa_spec. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/run_specs.py
[2] Stanford CRFM (2023). MultipleChoiceJointAdapter. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/adaptation/adapters/multiple_choice_joint_adapter.py

文字を本文へ写してから、一致を判定する

- 正解が D の実例 1 では、出力 D を選択肢本文の 100% へ写す。別の文字なら、その文字に対応する別の本文を比較する。
- BasicMetric には完全一致と、大文字・小文字、句読点、冠詞、空白を正規化した一致などがある。 Classic の表示設定は test の quasi_exact_match 。
- 生成文字の前後の空白は除くが、 D. や 100% を直接生成しても、文字から本文への写像には一致せず、正解扱いにならない。

[1] Stanford CRFM (2023). BasicMetric. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py
[2] Stanford CRFM. HELM Classic v0.4.0 （ 2023-11-17 ）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

Classic v0.4.0 の公開 run は 0 件

確認対象	公開状態
シナリオ定義	MedQA が登録されている
表示上の主指標	quasi_exact_match / test
run_specs ・ run suite 索引	MedQA に該当する run は 0 件
モデル別の成績	この配布版には掲載値がない

2026-10-18 に latest 設定と v0.4.0 の配布 JSON を照合した。

[1] Stanford CRFM. HELM Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

データの規模と、公開実行の有無を分けて読む

- 米国版の 4 択データ 12,723 件は配布され、 HELM の読込・採点設定も存在する。一方、この Classic 配布版にモデル別の実行結果はない。
- 構築時の 36.7% などを、 HELM によるモデル成績として扱わない。評価方式とモデル、使用する根拠が異なる。
- ここでの実例は公式データから取得した問題であり、公開モデルの予測例ではない。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

4. 入手と再現の手順

公式配布から、使う版と split を選ぶ

- 公式 GitHub の案内から data_clean.zip を取得する。質問と教科書を含むが、 HELM が読むのは questions/US/4_options 内の JSONL 。
- phrases_no_exclude_train 、 dev 、 test の各ファイルを選ぶ。HELM では dev が valid という split 名になる。
- 質問、全候補、 answer_idx を一組として保存する。版、ファイル、行番号、原レコードのハッシュを残すと照合しやすい。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（ 2026-10-18 取得）。 https://github.com/jind11/MedQA
[2] Stanford CRFM (2023). MedQAScenario. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/med_qa_scenario.py

利用条件は、コードと収集した問題を区別する

- 公式リポジトリには MIT License がある。構築論文は、試験問題の利用と選択肢の加工について fair use の考え方を説明する。
- 教科書や試験問題の第三者の権利まで、コードのライセンスだけで判断しない。出所、使う範囲、配布条件を確認する。
- この資料では出典を付して選んだ 13 問を紹介する。教科書や質問全件のファイルは、資料の配布物には含めない。

[1] Di Jin (2022). MIT License. MedQA repository. https://github.com/jind11/MedQA/blob/master/LICENSE

[2] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

原レコードと読込処理を、同じ版で照合する

- 取得した公式 ZIP とコードに SHA-256 を保存し、 HELM v0.3.0 の読込処理を実行した。全 12,723 件が 4 択で、各 1 件の correct タグを持つ。
- 全件で answer_idx と正解本文の対応が一致した。 13 実例にも元ファイルの行とハッシュを保存した。
- HELM は選択肢末尾の引用符と空白を整える。この資料の英語欄は元データを保持し、整形の前後は別記録に残した。

[1] Stanford CRFM (2023). MedQAScenario. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/med_qa_scenario.py

文字情報の範囲と、評価できることを捉える

- 医学の知識を、症例の記述と選択肢に結び付けられるかを調べる。自由記述の診療記録や、実際の診療行動を採点するデータではない。
- 配布テキストには図への言及が残る問題もある。たとえば test[945] は緑の矢印を指すが、 JSONL には図が含まれない。
- 問題の出所や専門分野、言語、選択肢の版をそろえ、何を与えた状態の正解率なのかを記録する。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（ 2026-10-18 取得）。 https://github.com/jind11/MedQA

医学知識の適用を、多肢選択で調べる

- MedQA は英語・簡体字中国語・繁体字中国語の 61,097 問。資格試験と模擬問題から、知識の照合と症例に基づく推論を扱う。
- HELM の範囲は米国版の英語・ 4 択。文字を選択肢本文へ写して一致を採点し、教科書の検索はこの設定に含まれない。
- 配布データ、評価設定、構築時の成績、公開 run を区別して使う。 Classic v0.4.0 には、このシナリオのモデル別成績はない。

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081
[2] Stanford CRFM (2023). MedQAScenario. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/med_qa_scenario.py

Appendix

1. 追加の実例
2. データ形式と集計
3. 研究と参考文献

実例 4 ：免疫グロブリンの役割

US ・ 4 択／ test JSONL 997 行目／ step1

原文：質問と全選択肢（全文）

The only immunoglobulin found as a dimer has what primary function?

A. Protect against invasive helminth infection
B. Protect against viral infections
C. Inhibiting bacterial adherance and colonization of mucous membranes
D. Provides the most specific recognition to circulating antigens in the bloodstream

日本語訳：質問と全選択肢

二量体として存在する唯一の免疫グロブリンの主な機能はどれか。

A. 侵入性の蠕虫感染から防御する
B. ウイルス感染から防御する
C. 粘膜への細菌の付着と定着を阻害する
D. 血中を循環する抗原を最も特異的に認識する

正解： C　粘膜への細菌の付着と定着を阻害する

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例５：筋細胞の弛緩に必要な過程

US ・ 4 択／ test JSONL 944 行目／ step1

原文：質問と全選択肢（全文）

A scientist observes a myocyte beating in cell culture. Which step is the most direct necessary component of relaxation for this cell?

A. Influx of sodium ions
B. Influx of calcium ions from the sacroplasmic reticulum
C. Influx of calcium ions from outside the myocyte
D. Efflux of calcium ions

日本語訳：質問と全選択肢

研究者が細胞培養中で拍動する筋細胞を観察している。この細胞が弛緩するために最も直接必要な過程はどれか。

A. ナトリウムイオンの流入
B. 筋小胞体からのカルシウムイオンの流入
C. 筋細胞外からのカルシウムイオンの流入
D. カルシウムイオンの流出

正解： D　カルシウムイオンの流出

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例 6 ：診断の閾値と偽陰性

US ・ 4 択／ test JSONL 482 行目／ step1

原文：質問と全選択肢（全文）

Current recommendations state that a single hemoglobin A1c value of greater than 6.5% is diagnostic of diabetes mellitus. If this 6.5% cut-off is to be increased to 7.0%, which of the following would be true?

A. Increase in false negative test results
B. Increase in false positive test results
C. Decrease in true negative test results
D. Increase in true positive test results

日本語訳：質問と全選択肢

現行の推奨では、ヘモグロビン A1c が 1 回でも 6.5% を超えれば糖尿病と診断するとされる。この閾値を 6.5% から 7.0% に上げた場合、正しいものはどれか。

A. 偽陰性の検査結果が増える
B. 偽陽性の検査結果が増える
C. 真陰性の検査結果が減る
D. 真陽性の検査結果が増える

正解： A　偽陰性の検査結果が増える

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例７：皮膚の所見から診断を選ぶ

US ・ 4 択／ test JSONL 226 行目／ step1

原文：質問と全選択肢（全文）

A 19-year-old Caucasian male presents to your office with hypopigmented skin. He undergoes a skin biopsy and is found to have an absence of melanocytes in the epidermis. Which of the following is the most likely diagnosis?

A. Tinea versicolor
B. Albinism
C. Vitiligo
D. Melanoma

日本語訳：質問と全選択肢

19 歳の白人男性が皮膚の色素減少を訴えて受診した。皮膚生検で、表皮にメラノサイトが存在しないことが分かった。最も考えられる診断はどれか。

A. 癜風
B. 白皮症
C. 尋常性白斑
D. 悪性黒色腫

正解： C　尋常性白斑

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例８：症状と機能障害を結び付ける

US ・ 4 択／ test JSONL 1071 行目／ step1

原文：質問と全選択肢（全文）

A 72-year-old Caucasian male presents to your office with dysphagia and halitosis. If this patient is also found to have cricopharyngeal muscle dysfunction, which of the following is the most likely cause of his presenting symptoms?

A. Gastroesophageal reflux disease
B. Esophageal candidiasis
C. Meckel's diverticulum
D. Zenker's diverticulum

日本語訳：質問と全選択肢

72 歳の白人男性が嚥下困難と口臭を訴えて受診した。輪状咽頭筋の機能障害も認められる場合、症状の原因として最も考えられるものはどれか。

A. 胃食道逆流症
B. 食道カンジダ症
C. メッケル憩室
D. ツェンカー憩室

正解： D　ツェンカー憩室

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例９：作用機序から薬の種類を選ぶ

US ・ 4 択／ test JSONL 766 行目／ step1

原文：質問と全選択肢（全文）

A 7-year-old boy is brought to your office with complaints of wheezing and dyspnea. Laboratory work reveals eosinophilia and positive skin tests for allergens. Which of the following types of drugs would be an effective treatment in this patient?

A. Beta-2 antagonist
B. Histone deacetylase inhibitor
C. Muscarinic antagonist
D. Anticoagulant

日本語訳：質問と全選択肢

7 歳の男児が喘鳴と呼吸困難を訴えて受診した。検査で好酸球増多とアレルゲンの皮膚試験陽性が認められた。この患者に有効な薬の種類はどれか。

A. β2 受容体拮抗薬
B. ヒストン脱アセチル化酵素阻害薬
C. ムスカリン受容体拮抗薬
D. 抗凝固薬

正解： C　ムスカリン受容体拮抗薬

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例 10 ：過敏反応と関与する細胞

US ・ 4 択／ test JSONL 841 行目／ step1

原文：質問と全選択肢（全文）

Candida is injected into the skin of a 38-year-old female patient. Forty-eight hours later, there is a 14 mm raised, slightly hardened area at the injection site. What type of hypersensitivity reaction has occurred and what cell type plays a role?

A. Type I hypersensitivty; eosinophils
B. Type IV hypersensitivity; mast cells
C. Type III hypersensitivity; CD4+ T cells
D. Type IV hypersensitivity; CD4+ T cells

日本語訳：質問と全選択肢

38 歳の女性の皮膚にカンジダを注射した。 48 時間後、注射部位に 14 mm の隆起した、やや硬い領域が生じた。これは何型の過敏反応で、どの細胞が関与するか。

A. I 型過敏反応・好酸球
B. IV 型過敏反応・肥満細胞
C. III 型過敏反応・ CD4 陽性 T 細胞
D. IV 型過敏反応・ CD4 陽性 T 細胞

正解： D　 IV 型過敏反応・ CD4 陽性 T 細胞

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例 11 ：薬剤の有害作用を問う

US ・ 4 択／ test JSONL 57 行目／ step1

原文：質問と全選択肢（全文）

An otherwise healthy 26-year-old man comes to the physician for medication counseling after recently being diagnosed with schizophrenia. Risperidone therapy is initiated. This patient is at increased risk for which of the following adverse effects?

A. Agranulocytosis
B. Shortened QT interval
C. Gynecomastia
D. Weight loss

日本語訳：質問と全選択肢

ほかに健康上の問題がない 26 歳の男性が、最近統合失調症と診断され、薬の説明を受けるために受診した。リスペリドンによる治療を開始した場合、リスクが高まる有害作用はどれか。

A. 無顆粒球症
B. QT 間隔の短縮
C. 女性化乳房
D. 体重減少

正解： C　女性化乳房

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例 12 ：手術前の薬を選ぶ

US ・ 4 択／ test JSONL 1227 行目／ step2&3

原文：質問と全選択肢（全文）

A 39-year-old woman, with a history of thyroidectomy and primary hyperparathyroidism presents for surgical evaluation for a right adrenal mass. Preoperatively, which of the following medications should she receive to prevent a hypertensive emergency intraoperatively?

A. Atenolol
B. Labetolol
C. Nifedipine
D. Phenoxybenzamine

日本語訳：質問と全選択肢

甲状腺摘出と原発性副甲状腺機能亢進症の既往がある 39 歳の女性が、右副腎腫瘤の手術評価のために受診した。術中の高血圧緊急症を防ぐため、術前に投与すべき薬はどれか。

A. アテノロール
B. ラベタロール
C. ニフェジピン
D. フェノキシベンザミン

正解： D　フェノキシベンザミン

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

実例 13 ：蛋白尿の特徴を問う

US ・ 4 択／ test JSONL 575 行目／ step1

原文：質問と全選択肢（全文）

An 11-year-old boy presents to your office with pitting edema and proteinuria exceeding 3.5g in 24 hours. You suspect that this patient has experienced a loss of polyanions in his glomerular basement membranes. Which of the following findings would confirm your diagnosis?

A. WBC casts in the urine
B. Selective albuminuria
C. Negatively birefringent crystals in the urine
D. Bence-Jones proteinuria

日本語訳：質問と全選択肢

11 歳の男児に圧痕性浮腫と、 24 時間で 3.5 g を超える蛋白尿がある。糸球体基底膜のポリアニオンの喪失が疑われる。この診断を裏付ける所見はどれか。

A. 尿中の白血球円柱
B. 選択的アルブミン尿
C. 尿中の負の複屈折を示す結晶
D. ベンス・ジョーンズ蛋白尿

正解： B　選択的アルブミン尿

[1] Jin et al. (2020). What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. arXiv. https://arxiv.org/abs/2009.13081

1 問のレコードに、正解の文字と本文を持つ

```
"answer": "100%",
"options": {"A": "0%", "B": "25%",
            "C": "50%", "D": "100%"},
"meta_info": "step1",
"answer_idx": "D"
```

実例 1 の JSONL から連続したキーの並びを抜粋。質問と metamap_phrases は、この表示範囲の外にある。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（2026-10-18 取得）。 https://github.com/jind11/MedQA

識別子は、ファイルと行位置に対応させる

- この資料の US/4_options/test/267 は、 test 配列の 0 始まり 267 番目、 JSONL の 268 行目を指す。配布元が付けた固有 ID ではない。
- 13 問はすべて test から選んだ。原レコード全体をキー順で JSON 化し、 UTF-8 の SHA-256 を保存した。
- 医学用語の日本語訳は質問と全候補を対象とし、年齢・数量・薬剤・病態の条件と、正解の対応を保持した。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（ 2026-10-18 取得）。 https://github.com/jind11/MedQA

選択肢数は、ファイル群ごとに異なる

配布ファイル群	実測の選択肢数
US の train/dev/test	全 12,723 問が 5 択
US/4_options の 3split	全 12,723 問が 4 択
Mainland の 3split	全 34,251 問が 5 択
Mainland/4_options の 3split	全 34,251 問が 4 択
Taiwan の 3split	全 14,123 問が 4 択

未分割の US_qbank は 14,369 問・ 4 〜 13 択。上記 split と区別する。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（ 2026-10-18 取得）。 https://github.com/jind11/MedQA

米国版の test には、二つの試験区分がある

meta_info	train	dev	test
step1	5,629	701	679
step2&3	4,549	571	594

US/4_options の配布レコードを集計。問題の meta_info をそのまま分類した。

[1] Di Jin et al. MedQA. 著者の公式コード・データ配布案内（2026-10-18 取得）。 https://github.com/jind11/MedQA

HELM は、末尾の引用符と空白を整える

- 選択肢本文に answer.rstrip('"').rstrip() を適用して Reference を作る。正解は文字キーと answer_idx の比較で付ける。
- 全 50,892 選択肢のうち 647 件が変化した。たとえば train[10] の D は末尾の改行と引用符が除かれる。
- この処理は医学内容の書き換えではない。元データと HELM 入力を別に保存し、どの処理で変わったかを追えるようにする。

[1] Stanford CRFM (2023). MedQAScenario. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/med_qa_scenario.py

実行設定の既定値と、実際の要求を分ける

項目	v0.3.0 の設定・処理
提示例の上限	max_train_instances=5
生成	temperature=0 、 max_tokens=1
要求の完了数	num_completions=1
num_outputs=5 の用途	top_k_per_token=5 へ渡す

公開 run の実測条件ではなくコードの既定値。実際に収まる提示例数は入力長などに依存する。

[1] Stanford CRFM (2023). get_med_qa_spec. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/run_specs.py

[2] Stanford CRFM (2023). MultipleChoiceJointAdapter. HELM v0.3.0. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/adaptation/adapters/multiple_choice_joint_adapter.py

参考文献

What Disease does this Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams

Di Jin, Eileen Pan, Nassim Oufattole, Wei-Hung Weng, Hanyi Fang, Peter Szolovits (2020). arXiv:2009.13081.

3 言語の医学試験問題と教科書の知識源を作り、検索と読解を組み合わせた評価を報告する。

https://arxiv.org/abs/2009.13081

MedQA

Di Jin et al. 著者の公式リポジトリ（ 2026-10-18 取得）。

質問・教科書の配布先、 4 択版の構成、検索ベースラインのコードを掲載する。

https://github.com/jind11/MedQA

参考文献

MedQAScenario

Stanford CRFM (2023). HELM v0.3.0, Python implementation.

米国版の 4 択 split を読み込み、問題と全候補、正解タグをインスタンスにする。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/med_qa_scenario.py

get_med_qa_spec / MultipleChoiceJointAdapter

Stanford CRFM (2023). HELM v0.3.0, Python implementation.

A 〜 D の候補を共同のプロンプトに並べ、生成文字を選択肢本文へ写す設定と処理を定める。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/adaptation/adapters/multiple_choice_joint_adapter.py

参考文献

BasicMetric

Stanford CRFM (2023). HELM v0.3.0, basic_metrics.py.

生成文字を対応する候補へ写し、完全一致や正規化後の一致などを集計する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

Holistic Evaluation of Language Models

Percy Liang et al. (2023). Transactions on Machine Learning Research.

広いシナリオと指標から言語モデルを評価する HELM の枠組みを提案する。

https://arxiv.org/abs/2211.09110