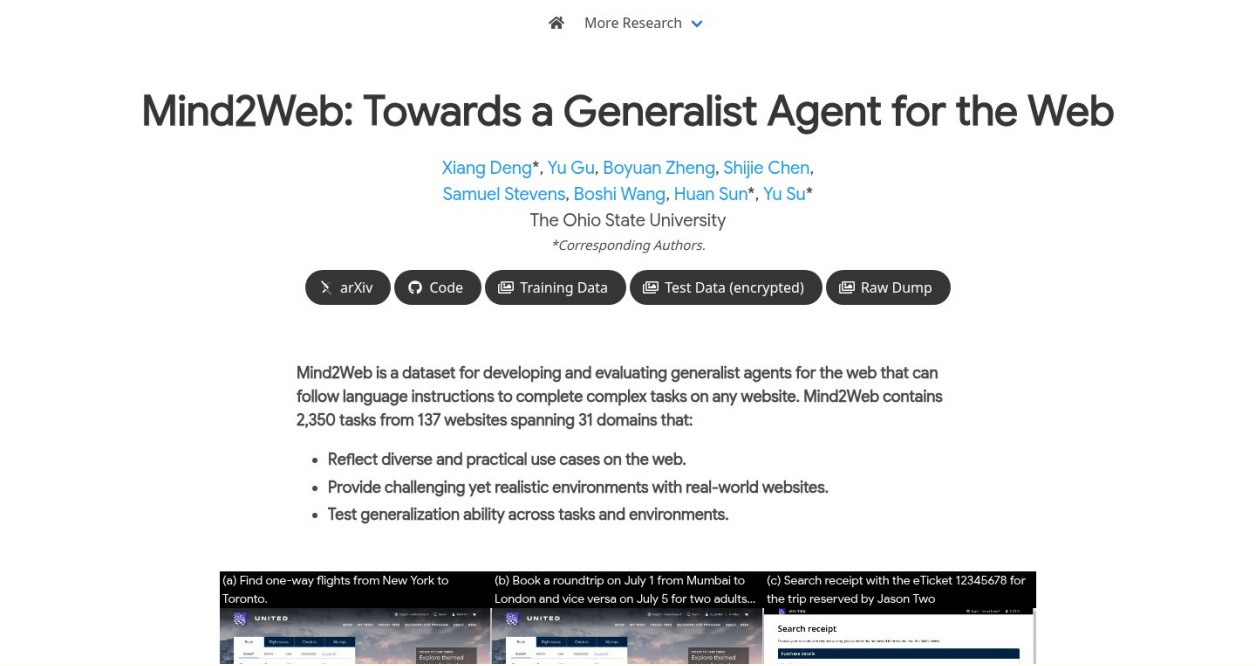
Mind2Web

言葉の指示から
ウェブページの次の操作を選ぶ

sasakiy84

1. 指示からウェブ操作を選ぶ
2. 人が記録したタスクと画面
3. 未知のサイトへの適応を測る
4. 利用と関連する評価

Mind2Web



[1] Deng et al. (2023), Mind2Web project
https://osu-nlp-group.github.io/Mind2Web/

1. 指示からウェブ操作を選ぶ

目的を理解し、操作する場所と方法を選ぶ

- Mind2Web は、言葉で与えた目的を達成するウェブ操作を学習・評価するデータセット。 2023 年に公開された。
- 航空券の検索や商品の絞り込みなど、実在するサイトで人が行った操作を記録している。
- 各時点のページと、それまでの操作履歴を受け取り、次に操作する要素と操作方法を予測する。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

入力は指示・ページ・操作履歴

- ページは HTML で表現する。 HTML は、ボタンや入力欄などの要素と属性を記述した文書。
- 出力は、対象の要素と CLICK ・ TYPE ・ SELECT の組。文字入力と選択では、入力する値や選択肢も答える。
- 元の評価は保存したページで次の操作を判定する。各ステップには正しい過去の操作履歴を与える。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

具体的なタスクと、操作直前の状態を見る

- 異なる 13 タスクから、 1 つずつ操作直前の状態を選んだ。各例に指示の全文と、その時点での参照操作を示す。
- 画面は、元の HTML と画像を対応付けた公式 Multimodal-Mind2Web の保存記録。赤枠が操作対象を示す。
- 画面と HTML は一部を抜粋する。元の 2023 年の手法は、ページの HTML を入力に使った。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

実例１：レンタカーを予約する

タスクの指示（原文全文）

> rent a car in Brooklyn - Central, NY on from April 9 to April 15.

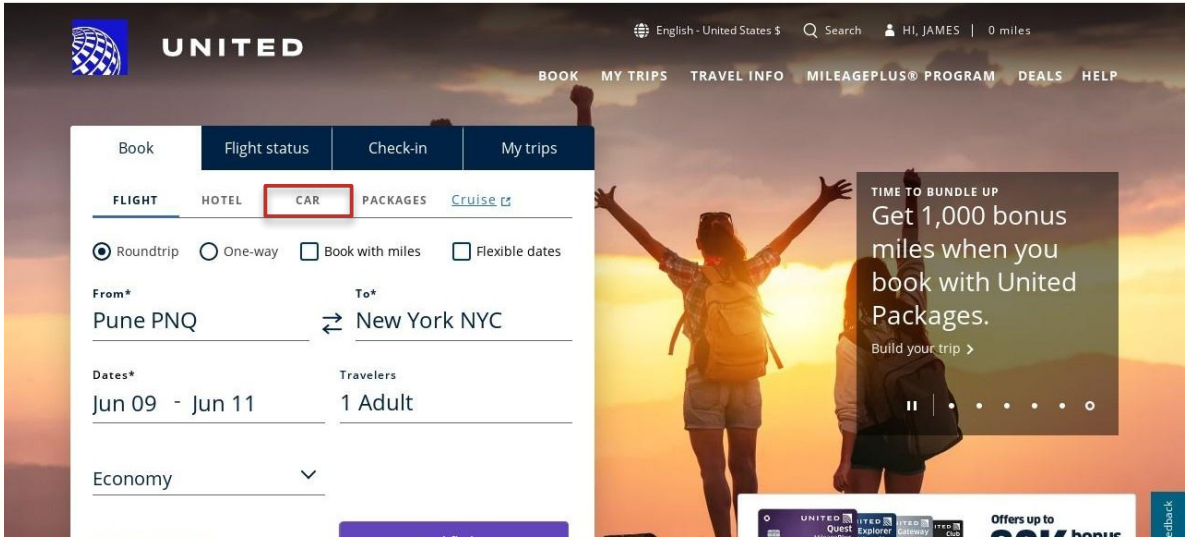
日本語訳（全文）

ニューヨーク州ブルックリン・セントラルで、４月９日から４月15日まで車を借りてください。

united で記録された 7 操作のうち、次頁は第 1 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 401c4e6f / action 6c7a7082 / 1/7
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

実例１：レンタカーのタブを開く



HTML の抜粋

```
<li
 role="tab">
 Car
</li>
```

第 1/7 操作の直前

[heading] CAR -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 401c4e6f / action 6c7a7082 / 1/7
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

実例２：条件に合うタイ料理店を探す

タスクの指示（原文全文）

> Look for a best rated Thai restaurant in Westminster, California, that provides takeout, and whose staff is fully vaccinated and accepts Apple pay.

日本語訳（全文）

カリフォルニア州ウェストミンスターで、評価が最も高いタイ料理店を探してください。テイクアウトができ、スタッフ全員がワクチン接種済みで、 Apple Pay に対応する店が条件です。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task c987dd1d / action 3169cbf4 / 2/12
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

実例２：料理の種類を選ぶ



HTML の抜粋

```
<a
 role="menuitem">
 Thai
</a>
```

第 2/12 操作の直前

[span] Thai -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task c987dd1d / action 3169cbf4 / 2/12
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

実例３：学生交流イベントの会場を探す

タスクの指示（原文全文）

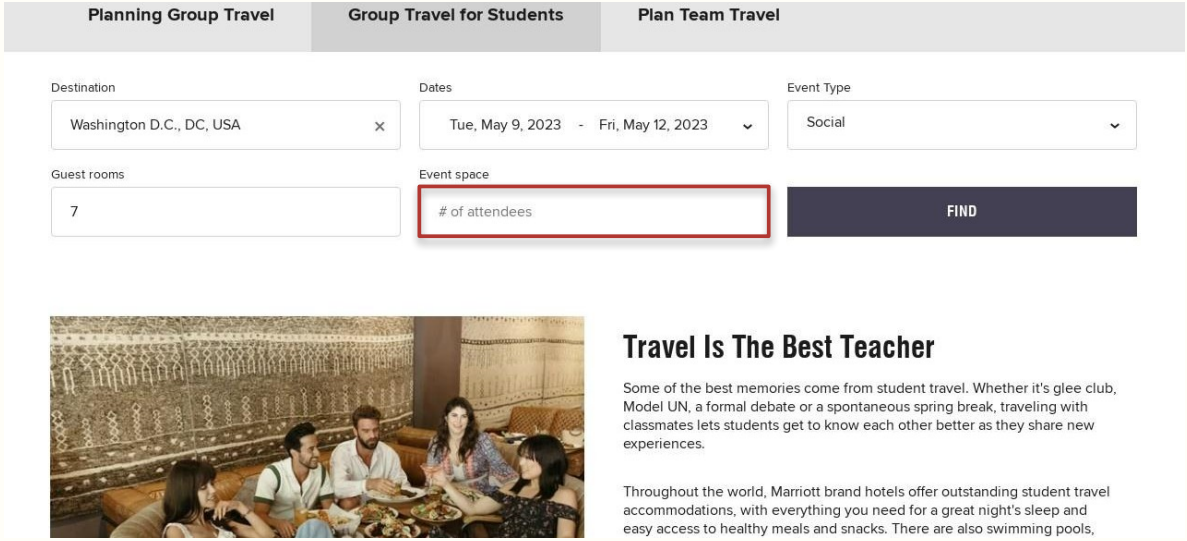
> Find The Ritz-Carlton hotels in Washington DC that can hold a student social event from May 9 to May 12 and will require 7 guest rooms and an event space for 50

日本語訳（全文）

ワシントン DC のザ・リッツ・カールトンで、５月９日から５月 12 日まで学生の交流イベントを開けるホテルを探してください。客室７室と、50 人分のイベント会場が必要です。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task b49f0d3e / action ba56712e / 13/17
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

実例３：会場の人数を入力する



HTML の抜粋

```
<input type="text"
 placeholder=
 "# of attendees">
```

第 13/17 操作の直前

[textbox] Event space -> TYPE: 50

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task b49f0d3e / action ba56712e / 13/17
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

2. 人が記録したタスクと画面

人が提案した目的を、人がブラウザで実演する

- 研究者は、旅行・買い物・サービス・娯楽・情報の 5 大分類から、実在する 137 サイトを選んだ。細かな分類は 31 分野。
- 作業者は、サイトの機能を使う目的を提案した。ChatGPT の案を発想の参考にしたが、そのまま使うことは認めなかった。
- 採用した目的をブラウザで実演し、各操作の前に対象要素と操作方法を確認して記録した。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

指示と操作が対応するように、研究者が確認する

- 研究者が全実演を確認し、操作の正しさ、指示との対応、余分な操作の有無を調べた。
- 2,411 タスクのうち 61 を除き、 2,350 を残した。 390 件で指示を修正し、 187 件で余分な操作を削った。
- 平均 7.3 操作で 1 タスクを構成する。 1 ページには平均 1,135 の HTML 要素があり、対象を選ぶ必要がある。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

学習用と 3 種類の評価用に分ける

分割	タスク数
学習用	1,009
同じサイトの別タスク	252
未学習のサイト	177
未学習の分野	912
合計	2,350

評価では、学習時と異なる目的・サイト・分野へ適応できるかを調べる。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

3. 未知のサイトへの適応を測る

候補の要素を絞り、次の操作を予測する

- 論文の手法 MindAct は、小さな言語モデルで HTML 内の要素を順位付けし、候補を絞る。
- 候補と周辺の HTML を大きな言語モデルに渡し、選択式の問題として対象要素を選ぶ。
- 最後に操作方法と必要な値を予測する。大量の HTML を扱い、目的を具体的な操作へ結び付けるための構成である。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

要素と操作が両方合うと、そのステップが成功

- 要素正解率は、選んだ要素が参照要素と同じ効果を持つ要素に含まれる割合。
- 操作 F1 は、操作方法と入力値のトークンの一致を測る。CLICK では操作の正誤と同じになる。
- ステップ成功率は要素と操作の両方が正しい割合。タスク成功率は、全ステップが成功したタスクの割合。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

未知のサイトでは、次の操作を選ぶのが難しい

MindAct + Flan-T5-XL （2022）	ステップ成功率	タスク成功率
同じサイトの別タスク	52.0%	5.2%
未学習のサイト	38.9%	5.1%
未学習の分野	39.6%	2.9%

Flan-T5-XL は 2022 年公開。 MindAct の評価は 2023 年。
学習用で調整し、ステップ成功率はタスクごとに平均した。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

4. 利用と関連する評価

保存ページの評価から、画像や実サイトの評価へ

- 2023 年の Mind2Web は、保存した HTML で次の操作を評価する。
- 2024 年の Multimodal-Mind2Web は、 HTML と対応する画面画像を操作ごとにまとめた。
- 2025 年の Online-Mind2Web では、実サイト上でタスクを実行する。元の保存 HTML 評価とは条件が異なる。

[1] OSU NLP Group, Mind2Web （ 2026-10-22 参照）
https://github.com/OSU-NLP-Group/Mind2Web

現在のモデル発表でも、 Mind2Web の名前が使われる

- GPT-6 Astra と更新した Codex の実行環境を組み合わせ、従来の GPT-5.6 Sol 環境より 1.9 倍速くタスクを完了したと公式発表は報告する。
- デモの所要時間と、 2023 年の保存 HTML で測る操作の成功率は、条件と指標が異なる。

[1] OpenAI (2026), GPT-6 Astra （ 2026-10-22 参照）
https://openai.com/index/gpt-6-astra/

公式データとコードから、課題の中身を確認できる

- 学習用には、タスク指示、各操作前の HTML 、対象要素と操作方法が公開されている。
- 元のデータは CC BY 4.0 、コードは MIT ライセンス。出典を示し、翻訳や図示などの変更を明記して利用する。
- 本資料の 13 例は公式の学習用から選んだ。画面は対応する Multimodal 版の保存画像を使った。

[1] OSU NLP Group, Mind2Web （ 2026-10-22 参照）
https://github.com/OSU-NLP-Group/Mind2Web

Mind2Web が測るもの

- 言葉で示された目的を、具体的なページ要素と操作へ結び付ける。
- 見慣れたサイトだけでなく、未学習のサイトや分野で次の操作を選べるかを比べる。
- 指示、 HTML 、操作履歴を組み合わせて判断する能力を調べる基盤になる。

[1] Deng et al. (2023), Mind2Web
https://arxiv.org/abs/2306.06070

Appendix

1. 異なるタスクの追加例
2. データの構造と利用条件
3. 参考文献

追加例１：ソフトウェア開発の求人を探す

タスクの指示（原文全文）

> Look for a hybrid job at Resy in software development, if the job is open apply immediately.

日本語訳（全文）

Resy でハイブリッド勤務のソフトウェア開発職を探し、募集されていればすぐに応募してください。

resy で記録された 8 操作のうち、次頁は第 5 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 1bb8d48f / action 6a110bc2 / 5/8
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 1 ：勤務形態を選ぶ



HTML の抜粋

```
<a>
 Hybrid
</a>
```

第 5/8 操作の直前

[a] Hybrid -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 1bb8d48f / action 6a110bc2 / 5/8
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例２：テントを郵送で下取りに出す

タスクの指示（原文全文）

> Trade in a Nemo Front Porch 2P Tent via mail with my membership info Joe Bloggs, phone number 123456789

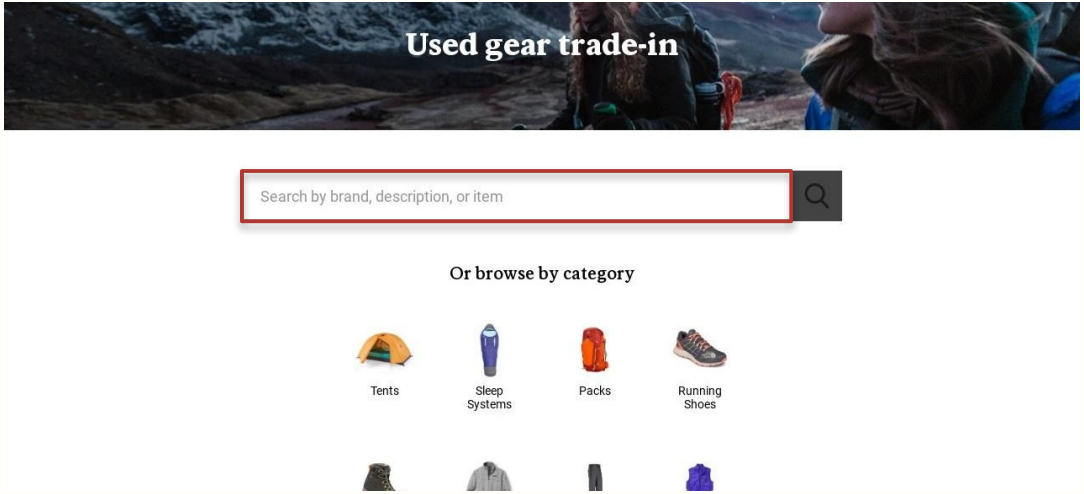
日本語訳（全文）

Nemo Front Porch 2P Tent を郵送で下取りに出してください。会員情報は Joe Bloggs 、電話番号は 123456789 です。

rei で記録された 11 操作のうち、次頁は第 3 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 09675529 / action eb9e2f08 / 3/11
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例２：商品名を入力する



[combobox] search input ->
TYPE: Nemo Front Porch 2P Tent

HTML の抜粋

```
<input
 role="combobox"
 aria_label=
 "search input">
```

第 3/11 操作の直前

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 09675529 / action eb9e2f08 / 3/11
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例３：４人乗りのトラックを安い順に探す

タスクの指示（原文全文）

> Find the lowest rent truck for 4 people, pick up from JFK airport at 11 am on March 27 and return at noon on March 30.

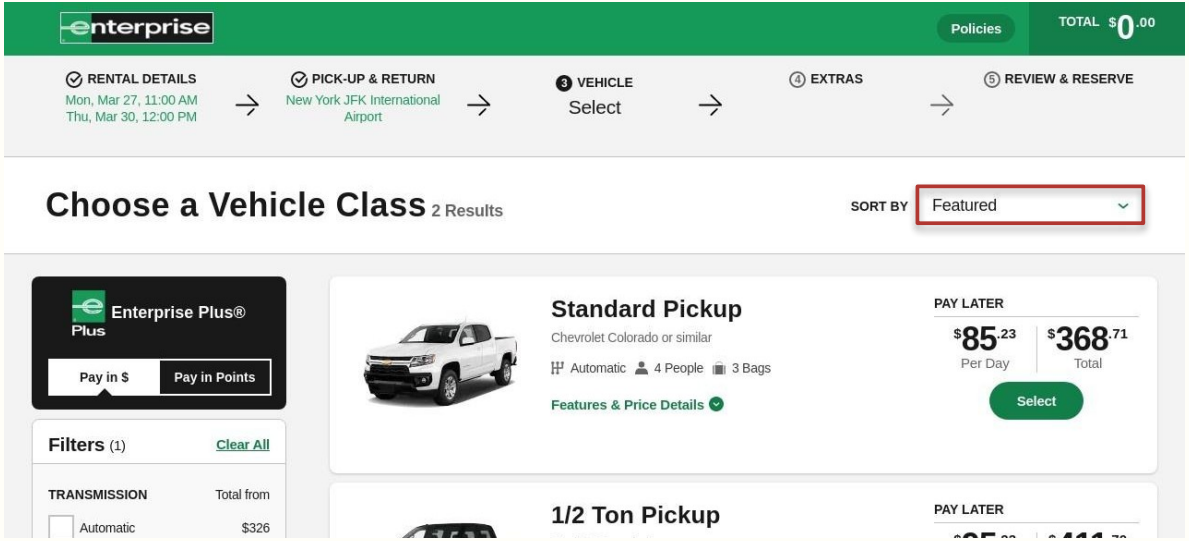
日本語訳（全文）

４人が乗れる、レンタル料金が最も安いトラックを探してください。３月27日午前11時にJFK空港で借り、３月30日正午に返却します。

enterprise で記録された 13 操作のうち、次頁は第 10 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 7180c4d1 / action 8d39083e / 10/13
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例３：料金の安い順に並べ替える



HTML の抜粋

```
<select>
 <option>
  Low to High
 </option>
</select>
```

第 10/13 操作の直前

[combobox] SORT BY -> SELECT: Low to High

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 7180c4d1 / action 8d39083e / 10/13
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 4 ： 4 月の歴史体験イベントを探す

タスクの指示（原文全文）

> Find a living History event to attend in in April .

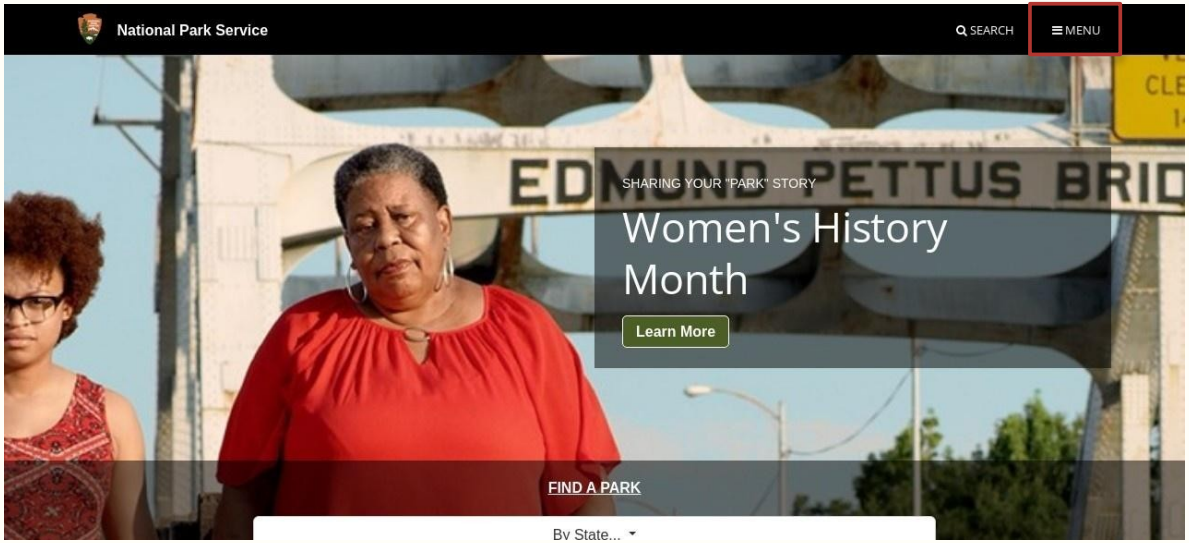
日本語訳（全文）

4 月に参加するリビングヒストリー（当時の暮らしを再現する催し）のイベントを探してください。

nps.gov で記録された 4 操作のうち、次頁は第 1 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 4132002e / action 62df7775 / 1/4
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 4 ：公園サイトのメニューを開く



HTML の抜粋

```
<button
 aria_label="Open
Menu">
</button>
```

第 1/4 操作の直前

[button] Open Menu -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 4132002e / action 62df7775 / 1/4
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 5 ：近隣店舗の BMW を探す

タスクの指示（原文全文）

> Find series 1 and series 2 BMW vehicles in the store nearest to 07055

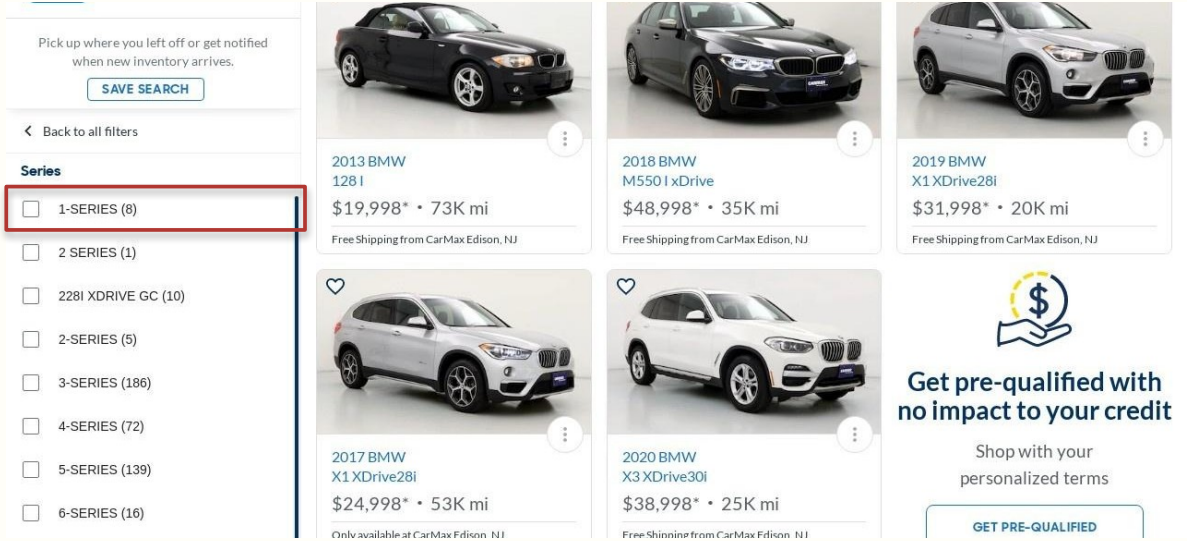
日本語訳（全文）

郵便番号 07055 に最も近い店舗で、 BMW の 1 シリーズと 2 シリーズを探してください。

carmax で記録された 16 操作のうち、次頁は第 15 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 10e17667 / action e6cb09cb / 15/16
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 5 ：車種を絞り込む



HTML の抜粋

```
<li>
 1-SERIES (8)
</li>
```

第 15/16 操作の直前

[listitem] 1-SERIES (8) 1-SERIES (8) -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 10e17667 / action e6cb09cb / 15/16
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 6 ：インド料理店の席を予約する

タスクの指示（原文全文）

> Reserve a dinner table in the first restaurent in the results, any time after 8 pm tomorrow for two in New York in any available Indian cuisine-serving restaurant.

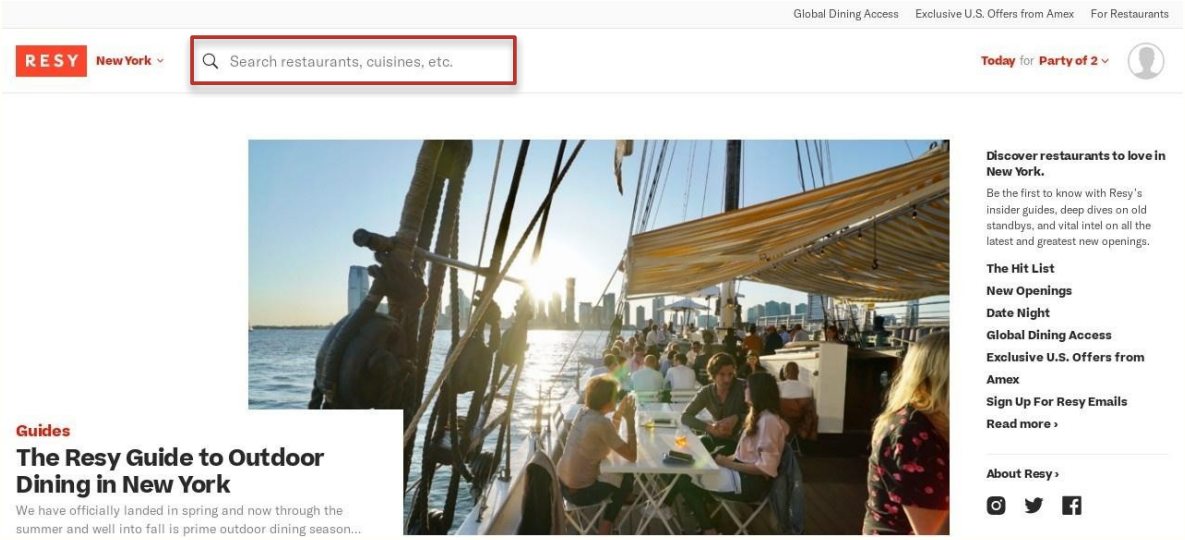
日本語訳（全文）

ニューヨークで明日の午後 8 時以降に 2 人で夕食を取れるインド料理店を探し、検索結果の最初の店で席を予約してください。

resy で記録された 10 操作のうち、次頁は第 3 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task e0ff7945 / action 10d25542 / 3/10
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例６：料理名を検索する



HTML の抜粋

```
<input
 placeholder=
 "Search
restaurants,
 cuisines, etc.">
```

第 3/10 操作の直前

[textbox] Search restaurants, cuisines, etc. -> TYPE: indian

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task e0ff7945 / action 10d25542 / 3/10
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 7 ：最安のマットレスを探す

タスクの指示（原文全文）

> Find a Queen size memory foam mattress with lowest price.

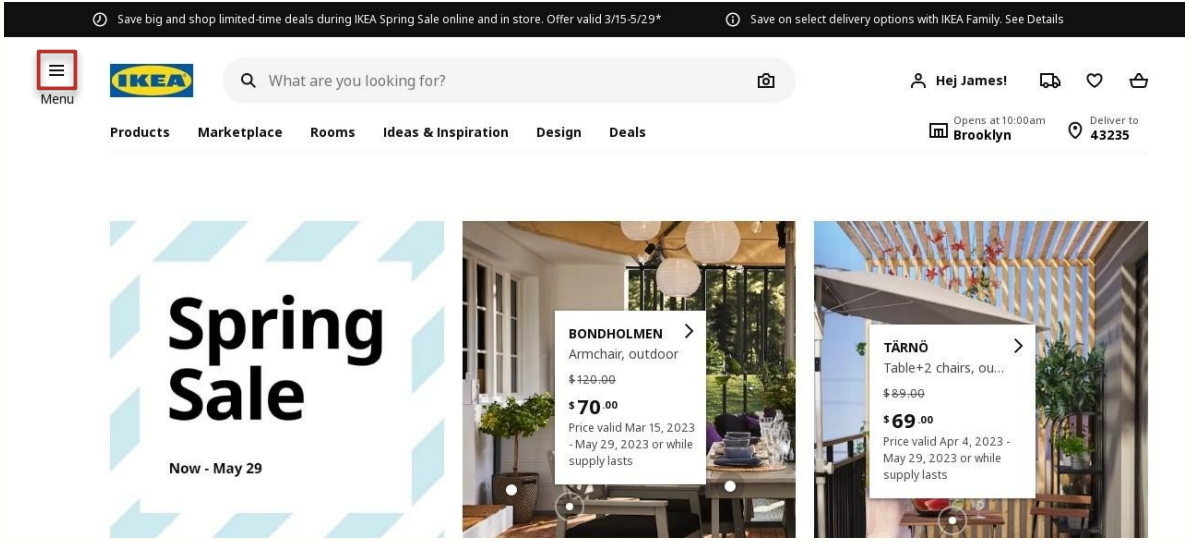
日本語訳（全文）

価格が最も安いクイーンサイズの低反発マットレスを探してください。

ikea で記録された 10 操作のうち、次頁は第 1 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 6b4aa5a9 / action 92ef851f / 1/10
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例７：商品メニューを開く



HTML の抜粋

```
<button
 class="…--open-
menu">
</button>
```

第 1/10 操作の直前

[button] Menu -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 6b4aa5a9 / action 92ef851f / 1/10
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 8 ：暗号資産で買えるプロジェクターを探す

タスクの指示（原文全文）

> Find a projector which accepts crypto currency as payment.

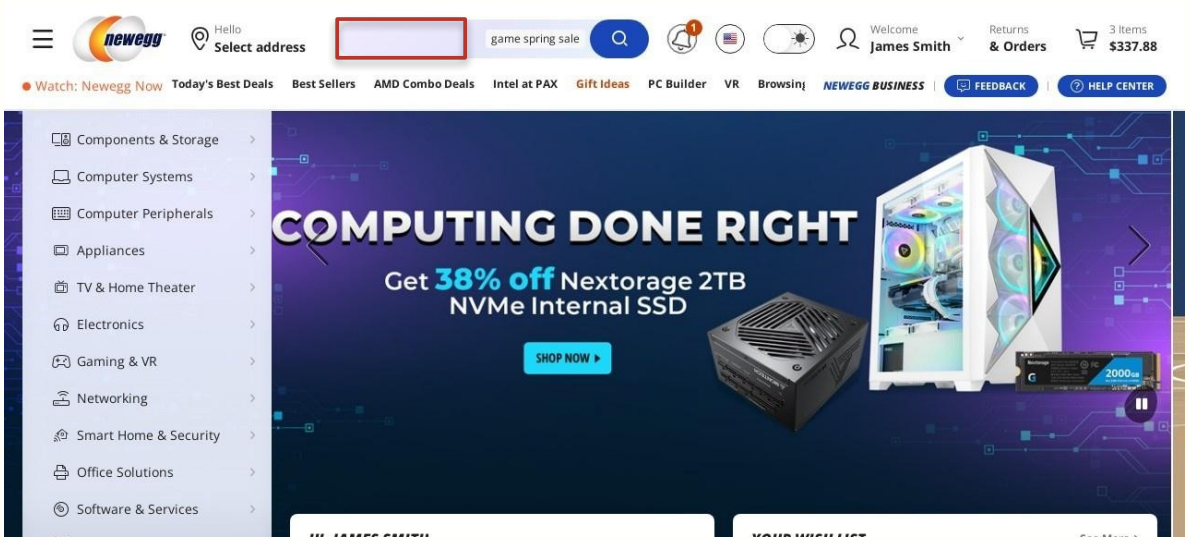
日本語訳（全文）

暗号資産で支払えるプロジェクターを探してください。

newegg で記録された 3 操作のうち、次頁は第 1 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task effb9df8 / action aadbdc6d / 1/3
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 8 ：商品を検索する



HTML の抜粋

```
<input
 type="search"
 title="Search
Site">
```

第 1/3 操作の直前

[searchbox] Search Site -> TYPE: projectors

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task effb9df8 / action aadbdc6d / 1/3
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例９：２人分の往復航空券を探す

タスクの指示（原文全文）

> Find flights from Los Angeles to Miami for two people departing on July 1st and returning on July 7th.

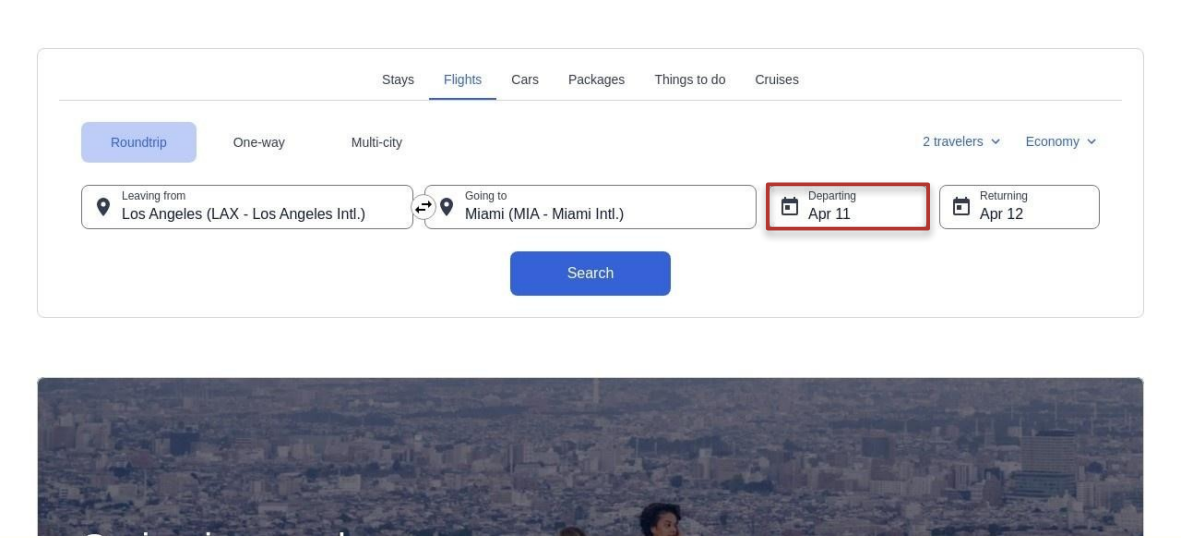
日本語訳（全文）

ロサンゼルスからマイアミへ、７月１日出発、７月７日帰りの２人分の航空便を探してください。

expedia で記録された 15 操作のうち、次頁は第 9 操作の直前。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 5ea9ec16 / action 33320628 / 9/15
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例９：出発日の選択画面を開く



HTML の抜粋

```
<button
 aria_label=
 "Departing April
11,
 2023">
 Apr 11
</button>
```

第 9/15 操作の直前

[button] Departing April 11, 2023 -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 5ea9ec16 / action 33320628 / 9/15
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 10 ：国立公園向けの航空券をカートへ入れる

タスクの指示（原文全文）

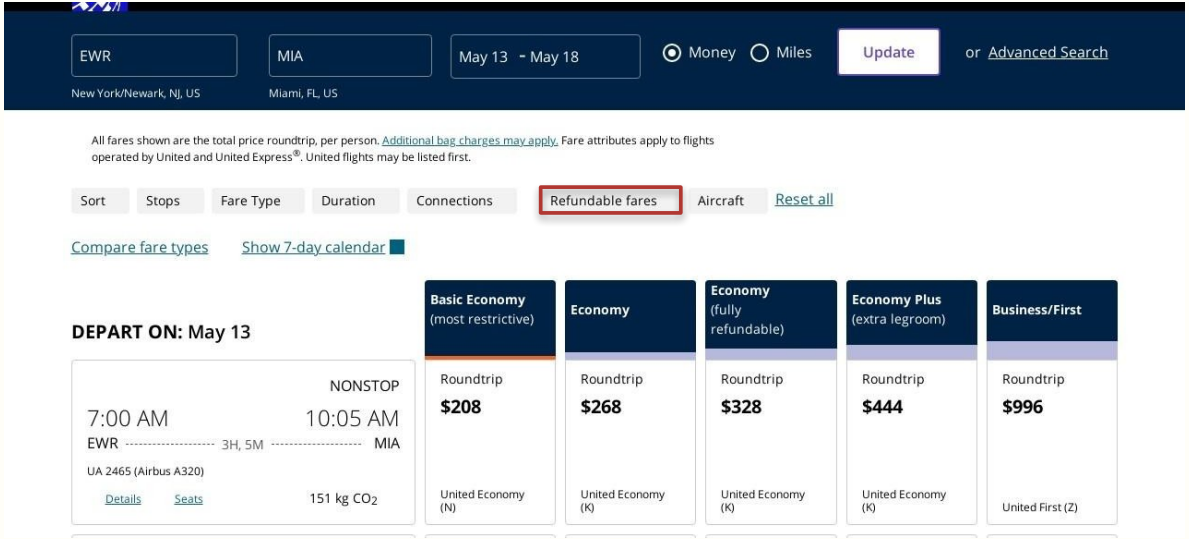
> Find popular deals to USA national parks in the southeast region of Biscayne national park, and add to the cart the fully refundable economy flight from New York to Miami with a departure date of May 13 and a return date of May 18.

日本語訳（全文）

米国南東部のビスケーン国立公園に向かう人気のお得なプランを探してください。 5 月 13 日出発、 5 月 18 日帰りで、ニューヨークからマイアミへ行く全額返金可能なエコノミー航空券をカートに追加してください。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 0b16b42c / action a2427697 / 11/14
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

追加例 10 ：返金可能な運賃を指定する



HTML の抜粋

```
<button
 id="refundable">
 Refundable fares
</button>
```

第 11/14 操作の直前

[span] Refundable fares -> CLICK

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web task 0b16b42c / action a2427697 / 11/14
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

1 タスクの中に、各ステップの状態と参照操作がある

- タスクには、指示、サイトと分野、操作列がある。各操作は固有の ID で識別できる。
- 操作には、操作前の HTML 、操作の種類と値、正解となる要素とその他の候補がある。
- Multimodal 版は 1 行が 1 操作で、対応する画像を付ける。元のタスク数と、操作単位の行数を区別する。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

元データの利用条件と画像版の表示を確認する

- 元の Mind2Web 公式説明は、データを CC BY 4.0 、コードを MIT としている。
- Multimodal 版の公開カードには、ライセンス欄に OpenRAIL という表示がある。元データの説明と表示が異なる。
- 配布カードの条件を確認し、著者とデータの出典、抜粋・翻訳・赤枠追加を明記する。

[1] Deng et al. (2023) / Zheng et al. (2024), Multimodal-Mind2Web
https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

参考文献

Mind2Web: Towards a Generalist Agent for the Web

Deng et al. (2023), NeurIPS / arXiv:2306.06070

タスクの定義、作成手順、 3 種類の評価分割と MindAct の結果を説明する。

https://arxiv.org/abs/2306.06070

Mind2Web

OSU NLP Group, GitHub （ 2026-10-22 参照）

元データの構造、分割、評価方法と利用条件を確認できる。

https://github.com/OSU-NLP-Group/Mind2Web

参考文献

Multimodal-Mind2Web

OSU NLP Group, Hugging Face （2026-10-22 参照）

元の HTML と画面画像を対応付けた公式配布。実例の保存状態を確認できる。

https://huggingface.co/datasets/osunlp/Multimodal-Mind2Web

GPT-6 Astra

OpenAI (2026), OpenAI （2026-10-22 参照）

Mind2Web を使ったデモの所要時間を紹介する、現在のモデル発表。

https://openai.com/index/gpt-6-astra/