MMLU-Pro

MMLU: Massive Multitask Language Understanding

選択肢を増やし、推論を重視した 14 分野の知識評価

sasakiy84

MMLU-Pro の公式リーダーボード

MMLU-Pro Leaderboard

Introduction

We introduce MMLU-Pro, an enhanced benchmark designed to evaluate language understanding models across broader and more challenging tasks. Building on the Massive Multitask Language Understanding (MMLU) dataset, MMLU-Pro integrates more challenging, reasoning-focused questions and increases the answer choices per question from four to ten, significantly raising the difficulty and reducing the chance of success through random guessing. MMLU-Pro comprises over 12,000 rigorously curated questions from academic exams and textbooks, spanning 14 diverse domains including Biology, Business, Chemistry, Computer Science, Economics, Engineering, Health, History, Law, Math, Philosophy, Physics, Psychology, and Others.

Note: For inclusion in our leaderboard, submissions must provide substantial evidence demonstrating that their system is a genuine language model. We maintain strict verification standards to ensure the integrity and comparability of the results.

What's new about MMLU-Pro

Compared to the original MMLU, there are three major differences:

- The original MMLU dataset only contains 4 options, MMLU-Pro increases it to 10 options. The increase in options will make the evaluation more realistic and challenging. The random guessing will lead to a much lower score.
- The original MMLU dataset contains mostly knowledge-driven questions without requiring much reasoning. Therefore, PPL results are normally better than CoT. In our dataset, we increase the problem difficulty and integrate more reasoning-focused problems. In MMLU-Pro, CoT can be 20% higher than PPL.
- By increasing the distractor numbers, we significantly reduce the probability of correct guess by chance to boost the benchmark's robustness. Specifically, with 24 different prompt styles tested, the sensitivity of model scores to prompt variations decreased from 4-5% in MMLU to just 2% in MMLU-Pro.

For detailed information about the dataset, visit our page on Hugging Face: https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro.

[1] TIGER-Lab, 2026. MMLU-Pro Leaderboard.
https://tiger-lab-mmlu-pro.hf.space/

1. 課題と三つの実例
2. 採点方法とモデルの成績
3. 問題の構築とデータの構成
4. 更新と評価での利用

1. 課題と三つの実例

14 分野の設問に、最大 10 個の選択肢で答える

- MMLU-Pro は、幅広い学術・専門分野の知識と推論を測る、英語の選択式問題集である。
- MMLU から簡単・曖昧な問題などを除き、理工系の問題を追加した。誤答の選択肢も増やし、通常は A ～ J の 10 択から選ぶ。
- 評価用 12,032 問と、例示用 70 問を配布している。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例１：減数分裂後の染色体数

設問原文

Imagine an organism whose 2n = 96. Meiosis would leave this organism’s cells with how many chromosomes?

2n=96 の生物を考える。減数分裂後、この生物の細胞の染色体数はいくつになるか。

A. 4
B. 16
C. 32
D. 64
E. 192
F. 2
G. 24
H. 8
I. 96
J. 48

正解：Ｊ． 48

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例２：空気の圧縮とエントロピー

問題の英語原文（全文）

Three kilograms of air are at an initial state of 100kPa, 300°K.The air is then compressedpolytropicallywith n = 2.56, to a final pressure of 500kPa. Assuming constant specificheats, calculate the change in entropy using the threeideal gas equations.

A. 2.50 kJ/°K
B. 1.25 kJ/°K
C. 2.00 kJ/°K
D. 1.75 kJ/°K
E. 2.25 kJ/°K
F. 1.57 kJ/°K
G. 0.75 kJ/°K
H. 1.10 kJ/°K
I. 1.00 kJ/°K
J. 1.40 kJ/°K

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例２：日本語訳と正解

問題の日本語訳（全文）

3kg の空気が初期状態 100kPa 、 300K にある。この空気を指数 n=2.56 でポリトロープ圧縮し、最終圧力を 500kPa とする。比熱一定と仮定し、三つの理想気体の式からエントロピー変化を求めよ。

A. 2.50 kJ/K
B. 1.25 kJ/K
C. 2.00 kJ/K
D. 1.75 kJ/K
E. 2.25 kJ/K
F. 1.57 kJ/K
G. 0.75 kJ/K
H. 1.10 kJ/K
I. 1.00 kJ/K
J. 1.40 kJ/K

正解： F ． 1.57 kJ/K

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例２：正解を導く考え方

- 比熱 $c_p=1.005$ 、気体定数 $R=0.287\ \mathrm{kJ/(kg\cdot K)}$ とする。
- pV^n 一定より $T_2/T_1=\exp[((n-1)/n)\ln 5]$ 。
- $n=2.56$ より、 $\Delta S=3[c_p\cdot(n-1)/n-R]\ln 5\approx 1.57\ \mathrm{kJ/K}$ 。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例３：夫婦による不動産の共同所有

問題の英語原文（全文）

A wife and husband are married and own a dairy as tenants by the entirety. If the wife transfers her interest in the dairy by quitclaim deed to her aunt without the husband's knowledge, what interest, if any, does the aunt have?

A. A temporary leasehold interest.
B. An undivided one-half interest with right of survivorship.
C. An undivided one-third interest with right of survivorship.
D. The right to inhabit the dairy.
E. An undivided one-half interest without right of survivorship.
F. A life estate in the dairy.
G. A legal claim to future profits from the dairy.
H. No interest.
I. A lien against the entire property.
J. Full ownership of the property.

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例３：日本語訳と正解

問題の日本語訳（全文）

夫婦が酪農場を tenancy by the entirety の形で所有している。妻が夫に知らせず、権利放棄証書で自分の持分をおばへ譲渡した場合、おばはどのような権利を持つか。

A. 一時的な賃借権。
B. 生存者権付きの分割されていない２分の１の持分。
C. 生存者権付きの分割されていない３分の１の持分。
D. 酪農場に居住する権利。
E. 生存者権のない、分割されていない２分の１の持分。
F. 酪農場の終身権。
G. 酪農場の将来の利益に対する法的請求権。
H. 権利はない。
I. 不動産全体に対する担保権。
J. 不動産の完全な所有権。

正解：Ｈ．権利はない。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例３：正解を導く考え方

- tenancy by the entirety は米国法で夫婦を一体として扱う共同所有形態。この設問では一方だけで権利を譲れないため、おばの権利は生じない。 quitclaim deed は譲渡人の権利を保証せず移す証書である。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

2. 採点方法とモデルの成績

正解の選択肢と一致した回答の割合を測る

- 設問と全選択肢を示し、モデルに最終的な選択肢の記号を答えさせる。
- 2024 年の評価は、生成した説明から A ～ J を抽出する。抽出できなければ選択肢を無作為に一つ選ぶ。
- 参照正解に一致した設問の割合を正解率とする。 CoT は思考過程を示して回答を導く方法である。

[1] Wang et al., 2024. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark. https://arxiv.org/abs/2406.01574

2024 年の評価では、 GPT-4o が 72.6%

モデル	例示数	正解率 (%)
GPT-4o	5	72.6
Gemini 1.5 Pro	0	69.0
Claude 3 Opus	5	68.5
Llama 3 70B Instruct	5	56.2

CoT で回答。 5-shot は同じ分野の解答例 5 問を示す。 Gemini は例示なし。

[1] Wang et al., 2024. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark.
https://arxiv.org/abs/2406.01574

GPT-4o は、 CoT で 19.09 ポイント高くなる

回答方法	正解率 (%)
解き方を示す CoT	72.55
答えを直接返す Direct	53.46

同じ設問集合での比較。回答の導き方が成績に影響する。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

Mercor の 2026 年評価では、上位が 93% 台

モデル／推論設定	Pass@1(%)
Claude Opus 5.5 Max	93.4
Claude Fable 5.1 Max	93.0
GPT-6 Astra Max	91.5
Gemini 3.1 Pro High	91.3

Mercor の MMLU-Pro 公開評価。 12,032 問、 2026-10-22 参照。

[1] Mercor, 2026. MMLU-Pro leaderboard (2026-10-22 参照).
https://www.mercor.com/apex/oss-benchmarks/oss-mmlu-pro-leaderboard/

3. 問題の構築とデータの構成

MMLU の問題を選び直し、理工系の設問を補った

- MMLU の 57 科目を 14 の広い分野へまとめる。 8 種類の小型モデルで、 5 個以上が正解した問題を簡単と判定し、5,886 問を除いた。
- STEM の Web 教材、 TheoremQA 、 SciBench から問題を加える。解法から短い答えを取り出し、人が対応を確認する。
- 最終的な 12,032 問のうち 6,810 問が MMLU に由来し、5,222 問が追加された問題である。

[1] Wang et al., 2024. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark. https://arxiv.org/abs/2406.01574

誤答の選択肢を加え、専門家が正解を確認した

- 通常 4 択の設問に、 GPT-4-Turbo で誤答候補を 6 個加える。
- 専門家が正解と問題文を点検し、必要な情報が欠ける問題や、画像・表を必要とする問題などを除く。
- Gemini 1.5 Pro で、誤答とされた選択肢に正解が紛れていないかを調べ、人が再確認する。重複した正解候補は除く。

[1] Wang et al., 2024. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark. https://arxiv.org/abs/2406.01574

14 分野は、理工系から人文社会まで広がる

分野	評価用の問数
数学	1351
物理	1299
化学	1132
法律	1101
工学	969
その他	924
経済	844

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

健康・心理・歴史なども評価する

分野	評価用の問数
健康	818
心理	798
ビジネス	789
生物	717
哲学	499
計算機科学	410
歴史	381

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

83% の設問が 10 択で、残りはそれより少ない

2026 年の配布テスト集合	値
10 択の問題数	9981
選択肢数の平均	9.47
10 択以外の問題数	2051
例示用 validation の問数	70

人の点検で不適切な選択肢を除いた結果、すべてが 10 択ではない。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

4. 更新と評価での利用

正解の訂正と選択肢の整形が続いている

- 2025 年 4 月に、医療専門家の確認に基づいて医療分野の正解 15 件を訂正した。
- 2026 年 1 月、理工系の一部で回答の手掛かりとなった選択肢の先頭の空白を修正した。
- モデルの公開評価も更新され、 2026 年には Fable 5.1 や GPT-6 Astra などの成績が報告されている。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

[2] Mercor, 2026. MMLU-Pro leaderboard (2026-10-22 参照).
https://www.mercor.com/apex/oss-benchmarks/oss-mmlu-pro-leaderboard/

公式配布には設問・全選択肢・正解記号が入る

- TIGER-Lab/MMLU-Pro から、 test の 12,032 問と validation の 70 問を取得できる。
- 設問、全選択肢、正解記号、分野、出所を同じレコードで確認できる。
- データカードは MIT を指定する。評価コードのライセンスは Apache 2.0 で、公式リポジトリにある。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro
[2] TIGER-AI-Lab, 2026. MMLU-Pro official repository.
https://github.com/TIGER-AI-Lab/MMLU-Pro

知識の幅と、増えた選択肢から選ぶ推論を評価する

- MMLU-Pro は、 MMLU の設問を選び直し、理工系の問題を補って、 14 分野の知識と推論を評価する。
- 最大 10 択の設問を、専門家が点検した参照正解で採点する。全体では CoT を使うモデルに強みが見られた。
- 公開される設問・正解・分野情報を使い、総合成績と分野別の得手不得手を調べられる。

[1] Wang et al., 2024. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark. https://arxiv.org/abs/2406.01574

Appendix

1. 分野の広がりを示す追加例
2. 評価条件と参考文献

例 4 ：等差数列から等比数列へ

問題の英語原文（全文）

A sequence of three real numbers forms an arithmetic progression with a first term of 9. If 2 is added to the second term and 20 is added to the third term, the three resulting numbers form a geometric progression. What is the smallest possible value for the third term of the geometric progression?

A. 12
B. 16
C. 2
D. 7
E. 5
F. 3
G. -1
H. 0
I. 1
J. 9

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 4 ：日本語訳と正解

問題の日本語訳（全文）

三つの実数が、初項 9 の等差数列をなす。第 2 項に 2 、第 3 項に 20 を加えると、得られる三つの数は等比数列をなす。その等比数列の第 3 項として可能な最小値はいくつか。

A. 12
B. 16
C. 2
D. 7
E. 5
F. 3
G. −1
H. 0
I. 1
J. 9

正解：Ｉ． 1

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 5 ：鋼橋の熱膨張

問題の英語原文（全文）

In the design of a modern steel bridge, provisions must obviously be made for expansion. How much does this amount to in the case of a bridge two miles long which is subjected to temperatures ranging from - 40°F to + 110°F, assuming an average expansion coefficient of .000012/°C?

A. .003 miles
B. .001 miles
C. .008 miles
D. .0005 miles
E. .005 miles
F. .009 miles
G. .006 miles
H. .002 miles
I. .004 miles
J. .007 miles

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 5 ：日本語訳と正解

問題の日本語訳（全文）

現代的な鋼橋を設計する際には、膨張への備えが必要である。長さ 2 マイルの橋が– 40°F から +110°F までの温度にさらされる場合、平均膨張係数を 0.000012/°C とすると、膨張量はどれほどか。

A. 0.003 マイル
B. 0.001 マイル
C. 0.008 マイル
D. 0.0005 マイル
E. 0.005 マイル
F. 0.009 マイル
G. 0.006 マイル
H. 0.002 マイル
I. 0.004 マイル
J. 0.007 マイル

正解： H ． 0.002 マイル

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 6 ：一次反応で分解する割合

問題の英語原文（全文）

The reaction $C_2H_4O \rightarrow CH_4 + CO$ is a first-order reaction with a specific rate constant of .0123 min^{-1} at 415°C. Calculate the percent of original C_2H_4O present that will be decomposed after heating at 415°C for 1 hour.

A. 52.1%
B. 55.5%
C. 47.9%
D. 30%
E. 60%
F. 63.2%
G. 69.7%
H. 75.4%
I. 85%
J. 50%

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 6 ：日本語訳と正解

問題の日本語訳（全文）

反応 $C_2H_4O \rightarrow CH_4+CO$ は一次反応で、 415°C での速度定数は 0.0123 min^{-1} である。 415°C で 1 時間加熱した後、最初に存在した C_2H_4O の何パーセントが分解するか計算せよ。

A. 52.1%
B. 55.5%
C. 47.9%
D. 30%
E. 60%
F. 63.2%
G. 69.7%
H. 75.4%
I. 85%
J. 50%

正解： A ． 52.1%

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 7 ：三値論理で 256 通りを表す

問題の英語原文（全文）

One approach to handling fuzzy logic data might be to design a computer using ternary (base-3) logic so that data could be stored as “true,” “false,” and “unknown.” If each ternary logic element is called a flit, how many flits are required to represent at least 256 different values?

A. 9
B. 4
C. 2
D. 11
E. 10
F. 5
G. 3
H. 6
I. 8
J. 7

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例７：日本語訳と正解

問題の日本語訳（全文）

ファジー論理のデータを扱う方法として、真・偽・不明を保存できる三値（３進）論理のコンピュータを設計することが考えられる。三値論理の各要素を flit と呼ぶとき、少なくとも 256 個の異なる値を表すには何 flit 必要か。

A. 9
B. 4
C. 2
D. 11
E. 10
F. 5
G. 3
H. 6
I. 8
J. 7

正解：Ｈ．６

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 8 ：リンゴの供給と需要が同時に増える

問題の英語原文（全文）

The apple market is in equilibrium. Suppose we observe that apple growers are using more pesticides to increase apple production. At the same time, we hear that the price of pears, a substitute for apples, is rising. Which of the following is a reasonable prediction for the new price and quantity of apples?

A. Price is ambiguous, but quantity rises.
B. Price and quantity remain the same.
C. Quantity rises, but price falls.
D. Price and quantity both rise.
E. Price and quantity both fall.
F. Price rises, but quantity is ambiguous.
G. Price rises, quantity falls.
H. Price is ambiguous, but quantity falls.
I. Price falls, but quantity is ambiguous.
J. Price falls, quantity rises.

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例８：日本語訳と正解

問題の日本語訳（全文）

リンゴ市場は均衡している。リンゴ生産者が生産量を増やすために、より多くの農薬を使っていると分かった。同時に、リンゴの代替財であるナシの価格が上昇していると聞いた。リンゴの新しい価格と取引量について、妥当な予測はどれか。

A. 価格は不確定だが、量は増える。
B. 価格と量は変わらない。
C. 量は増えるが、価格は下がる。
D. 価格と量はともに上がる。
E. 価格と量はともに下がる。
F. 価格は上がるが、量は不確定。
G. 価格は上がり、量は減る。
H. 価格は不確定だが、量は減る。
I. 価格は下がるが、量は不確定。
J. 価格は下がり、量は増える。

正解：Ａ．価格は不確定だが、量は増える。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 9 ：自転車の定額減価償却

問題の英語原文（全文）

Tom bought a new bicycle for $80. After 4 years of use, he sold it to a second-hand dealer for $15. What was the annual depreciation by the straight line method? What was the annual rate of depreciation?

A. $13 per year and 16.25%
B. $16.25 per year and 20.3%
C. $17 per year and 21.25%
D. $19 per year and 23.75%
E. $14.75 per year and 18.4%
F. $15.25 per year and 19%
G. $18 per year and 22.5%
H. $16 per year and 20%
I. $12.50 per year and 15.6%
J. $20 per year and 25%

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 9 ：日本語訳と正解

問題の日本語訳（全文）

トムは新しい自転車を 80 ドルで買った。 4 年間使った後、中古業者へ 15 ドルで売った。定額法による年間の減価償却額と、年間の減価償却率はいくらか。

A. 年 13 ドル、 16.25%
B. 年 16.25 ドル、 20.3%
C. 年 17 ドル、 21.25%
D. 年 19 ドル、 23.75%
E. 年 14.75 ドル、 18.4%
F. 年 15.25 ドル、 19%
G. 年 18 ドル、 22.5%
H. 年 16 ドル、 20%
I. 年 12.50 ドル、 15.6%
J. 年 20 ドル、 25%

正解： B ． 年 16.25 ドル、 20.3%

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 10 ：ヒトの二倍体染色体数

設問原文

The normal human chromosome diploid number is:

正常なヒトの二倍体の染色体数はいくつか。

A. 48
B. 42
C. 22
D. 50
E. 47
F. 40
G. 24
H. 46
I. 44
J. 23

正解： H ． 46

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 11 ：マラパ洞窟のヒト科動物の食性

Analysis of the teeth of a hominid species discovered in Malapa Cave in South Africa, dating just after 2 million years ago, indicates a diet that consisted primarily of:

A. meat, fish, and some plants.

B. primarily C3 plants that included barley and oats.

C. large quantities of insects and small mammals.

D. a balanced diet of fruits, vegetables, meat, and fish.

E. primarily C4 plants that included corn and potatoes.

F. C4 grasses that may have included wild wheat.

G. fruits, leaves, and C3 plants.

H. meat derived from carnivorous mammals.

I. nuts, seeds, and roots.

J. primarily aquatic plants and algae.

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 11 ：日本語訳と正解

問題の日本語訳（全文）

南アフリカのマラパ洞窟で見つかった、 200 万年前より少し後のヒト科動物の一種の歯を分析すると、主に何を食べていたと考えられるか。

A. 肉、魚、および一部の植物。
B. 主にオオムギやエンバクを含む C3 植物。
C. 大量の昆虫と小型哺乳類。
D. 果物、野菜、肉、魚の均衡した食事。
E. 主にトウモロコシやジャガイモを含む C4 植物。
F. 野生のコムギを含んだ可能性がある C4 イネ科植物。
G. 果物、葉、および C3 植物。
H. 肉食哺乳類に由来する肉。
I. 木の実、種子、および根。
J. 主に水生植物と藻類。

正解： G ． 果物、葉、および C3 植物。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 12 ：嘲笑によって論証を退ける誤謬

問題の英語原文（全文）

When someone responds to your argument with a sarcastic statement such as, "Yeah, right. Like that's ever going to happen," that person may have committed which fallacy?

A. tu quoque
B. appeal to ignorance
C. argumentum ad populum
D. false cause
E. appeal to indignation
F. appeal to spite
G. horse laugh
H. slippery slope
I. straw man fallacy
J. argumentum ad hominem

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 12 ：日本語訳と正解

問題の日本語訳（全文）

論証に対して「はいはい。そんなことが起こるわけないでしょう」のような皮肉で返す人は、どの誤謬を犯している可能性があるか。

A. 汝もまたの誤謬。
B. 無知に訴える論証。
C. 大衆に訴える論証。
D. 誤った因果関係。
E. 憤りに訴える論証。
F. 悪意に訴える論証。
G. 嘲笑による論証。
H. 滑りやすい坂の誤謬。
I. 藁人形の誤謬。
J. 人身攻撃。

正解： G ． 嘲笑による論証。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 13 ：心理検査の T 得点

The STANDARD SCORES express raw score distance from mean by SD and considered the most satisfactory type of NR score. Which statement out of the following ones is about T-scores?

A. M=0, SD=1, often used in research studies
B. M=100, SD=15 or 16
C. They express raw scores in terms of percentiles
D. M=500, SD=100, often used in college entrance exams
E. Shows how many standard deviations a score is above or below the mean: a score of +1.0 means it’s 1 SD above the mean
F. M=100, SD=10, commonly used in IQ tests
G. M=100, SD=24, typically used in personality assessments
H. M=50, SD=10- it is used on many psychological tests, MMPI
I. They express raw scores in terms of ranks
J. standard nine: M=5, SD=approx 2

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

例 13 ：日本語訳と正解

標準得点は、平均からの素点の距離を標準偏差で表し、集団基準に準拠した得点の中で最も満足できる種類とされる。次のうち T 得点について述べているものはどれか。

A. 平均 0 、標準偏差 1 で、研究でよく使う。
B. 平均 100 、標準偏差 15 または 16 。
C. 素点を百分位数で表す。
D. 平均 500 、標準偏差 100 で、大学入学試験によく使う。
E. 平均より何標準偏差上か下かを表す。+1.0 は平均より 1 標準偏差上。
F. 平均 100 、標準偏差 10 で、知能検査によく使う。
G. 平均 100 、標準偏差 24 で、人格評価によく使う。
H. 平均 50 、標準偏差 10 で、多くの心理検査や MMPI で使う。
I. 素点を順位で表す。
J. 標準ナイン得点：平均 5 、標準偏差は約 2 。

正解： H ． 平均 50 、標準偏差 10 で、多くの心理検査や MMPI で使う。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

追加例の用語と解き方

- 例 4 ：公差 d に対して $(11+d)^2=9(29+2d)$ を解くと、第 3 項は 49 または 1 になる。
- 例 11 ： C3 と C4 は植物の炭素固定経路の区分。歯に残る炭素同位体比などから食性を調べる。
- 例 12 ： horse laugh は、相手の理由に答えず嘲笑して論証を退けることを指す。
- 例 13 ： MMPI は人格や精神症状を評価する心理検査の一つ。 T 得点は平均 50 ・標準偏差 10 にそろえる。

[1] TIGER-Lab, 2026. MMLU-Pro Dataset.
https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

24 通りの指示文で、得点の変動を調べた

- 2024 年の実験では、問いを選ぶ・答えを特定するなど、意味が近い 24 通りの指示文を比較した。
- 指示文による得点の変動幅は、 MMLU でおおむね 4 〜 5 ポイント、 MMLU-Pro で約 2 ポイントだった。
- 選択肢を増やしたことで、指示文の表現が変わってもモデル間の比較が安定するかを調べている。

[1] Wang et al., 2024. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark. https://arxiv.org/abs/2406.01574

参考文献

MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark

Yubo Wang, Xueguang Ma, Ge Zhang et al. (2024). NeurIPS Datasets and Benchmarks.

選択肢の増強と専門家の点検による構築、分野別の性能、指示文への頑健性を報告する。

https://arxiv.org/abs/2406.01574

MMLU-Pro Dataset

TIGER-Lab (2026). Hugging Face. MIT.

評価用 12,032 問と例示用 70 問、正解、出所、訂正履歴を配布する。

https://huggingface.co/datasets/TIGER-Lab/MMLU-Pro

参考文献

MMLU-Pro official repository

TIGER-AI-Lab (2026). GitHub. Apache 2.0.

評価コード、回答抽出、指示文の比較、モデルの出力を公開する。

https://github.com/TIGER-AI-Lab/MMLU-Pro

MMLU-Pro leaderboard

Mercor (2026). APEX open-source benchmarks. 2026-10-22 参照。

12,032 問を用い、後続の推論モデルを Pass@1 で比較する。

https://www.mercor.com/apex/oss-benchmarks/oss-mmlu-pro-leaderboard/